Criteri NewsGuard, regressione e accordo con gli esperti

Che cosa si vede nel testo, come valutiamo, e il modello come terzo annotatore

John Bianchi

IMT Lucca & IIT-CNR Pisa

I criteri NewsGuard

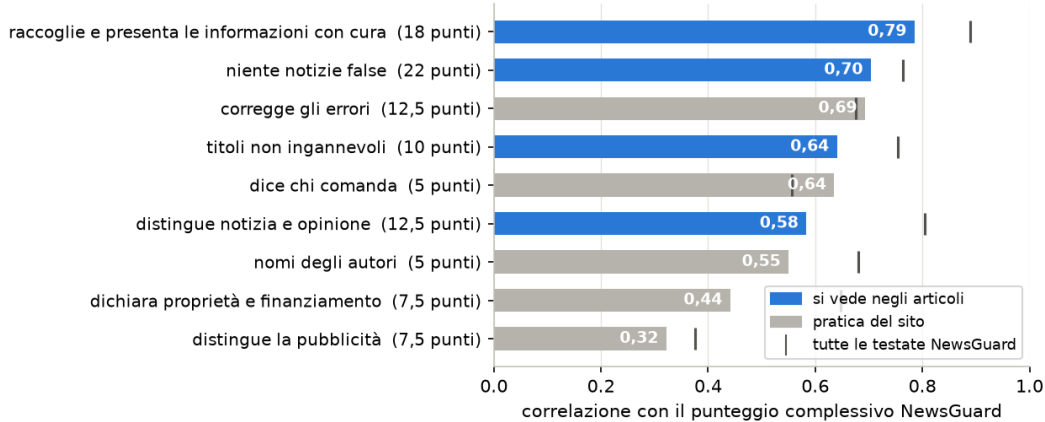
quali si vedono negli articoli, e quanto contano

Il punteggio NewsGuard è la somma di 9 criteri

Criterio	Punti	Dove si vede
Non pubblica notizie false	22	**negli articoli**
Raccoglie e presenta le informazioni con cura	18	**negli articoli**
Corregge gli errori	12,5	pratica del sito
Distingue notizia e opinione	12,5	**negli articoli**
Evita i titoli ingannevoli	10	**negli articoli**
Dichiara proprietà e finanziamento	7,5	pratica del sito
Distingue la pubblicità	7,5	pratica del sito
Dice chi comanda (e i conflitti di interesse)	5	pratica del sito
Mette i nomi degli autori	5	pratica del sito

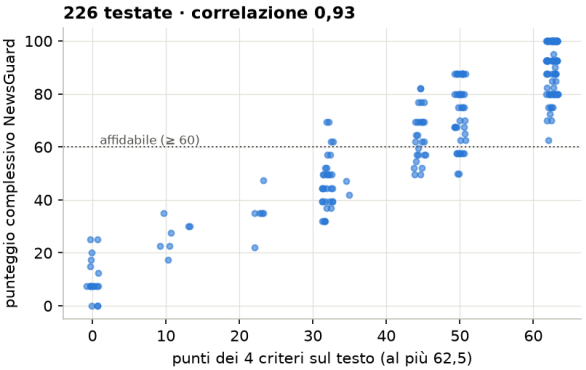
Ogni criterio è un sì o un no; il punteggio (0–100) è la somma dei punti dei sì. Affidabile = almeno 60. **4 criteri** riguardano il contenuto (**62,5 punti**); **5** le pratiche e la trasparenza del sito (37,5 punti), che negli articoli non si vedono.

Quanto ogni criterio va d'accordo con il punteggio complessivo



Barre: le nostre 226 testate (tentativo 16); trattini: tutte le 11.564 testate valutate da NewsGuard. Il criterio più legato al punteggio è **raccoglie e presenta le informazioni con cura** (0,79; 0,89 su tutte): è il più "testuale" e anche il più informativo.

I soli criteri sul testo spiegano quasi tutto il punteggio



- La somma dei punti dei 4 criteri sul testo ha correlazione **0,93** con il punteggio complessivo (0,95 su tutte le testate NewsGuard): ne spiega circa l'**87%**.
- Chi soddisfa tutti e 4 è **sempre affidabile** (94 testate su 94): anche perdendo tutti i punti del sito resta a 62,5.
- Chi ne manca anche uno solo è inaffidabile in 79 casi su 132.

Che cosa ne segue per l'addestramento

- **Il punteggio dei soli criteri sul testo** (0–62,5) è un bersaglio sensato: è quasi lo stesso del punteggio complessivo, ma toglie le pratiche del sito, che un modello che legge gli articoli non può vedere.
- **I criteri presi uno per uno** sono più difficili: "niente notizie false" e "titoli non ingannevoli" li soddisfa circa il 90% delle nostre testate, quindi restano solo 23–29 esempi negativi per imparare.
- I criteri sono legati tra loro: misurano in buona parte la stessa cosa, la qualità generale della testata.

La regressione

tre strategie, passo per passo

Tre strategie di regressione in una pagina

Strategia	Addestramento	Dalla previsione al giudizio	Misure
1. Per classi (tentativo 16)	sul punteggio 0–100; fold per livello	testata = media degli articoli; sì/no se ≥ 60; livelli con le quote del training	F1, tolerant, accuratezza
2. Voto degli articoli (tentativo 17)	come la 1	ogni articolo diventa un livello (quote sugli articoli); la testata prende il livello della maggioranza	F1, accuratezza, kappa, Spearman
3. Punteggio esatto (tentativo 18)	sul punteggio; fold **per punteggio**; 5 modi di pesare le testate	nessuna classe: testata = media degli articoli	errore in punti (MAE), R^2, Spearman

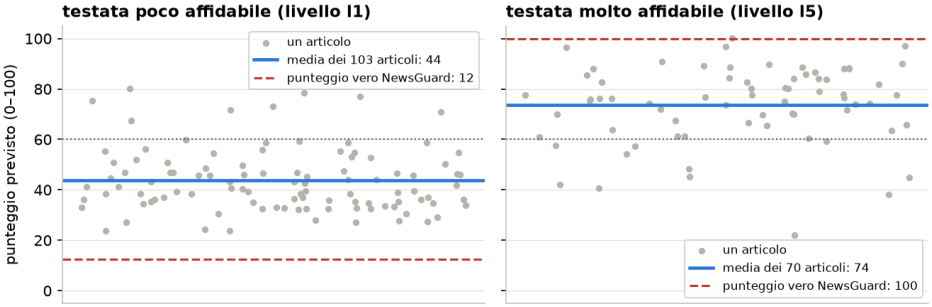
In tutte e tre l'etichetta è il punteggio NewsGuard della testata, ereditato da ogni suo articolo, e ogni testata è giudicata da un modello che non l'ha mai vista.

L'addestramento: tre modi di leggere il testo

Modello	**Il testo diventa numeri**	**Che cosa si addestra**
TF-IDF + ridge	conteggi di parole e coppie (100.000)	una somma pesata delle parole (ridge)
Qwen3 8B, Mistral 24B	il vettore del transformer **congelato**	la stessa ridge sopra il vettore
ModernBERT, DeBERTa	il transformer stesso	**tutto** il transformer, 5 epoche

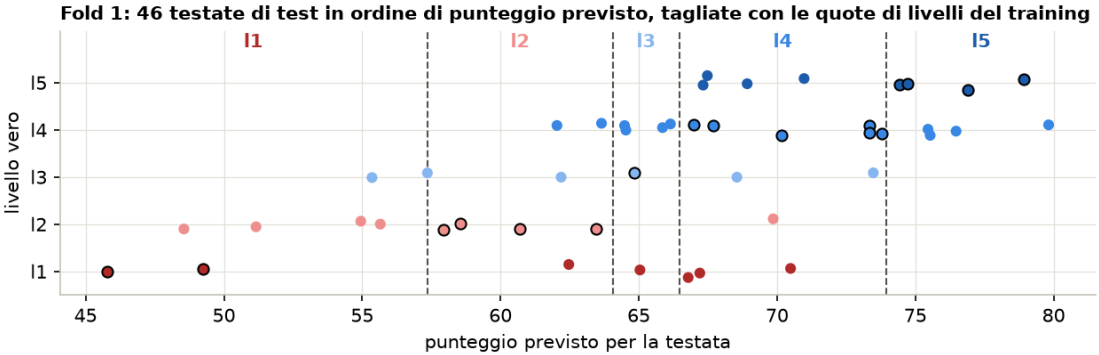
- Bersaglio: il punteggio 0–100 (diviso 100 nei transformer addestrati); si minimizza l'errore quadratico.
- La penalità della ridge si sceglie dentro il training; i transformer addestrati tengono l'ultima epoca.

Strategia 1, passo 1: dagli articoli alla testata



1. Un numero per articolo; **la testata prende la media** dei suoi articoli.
2. **Affidabile** se la media è almeno 60 (giusto se anche il vero è almeno 60).
3. **5 livelli**: le testate in ordine di punteggio previsto, tagliate con le quote di livelli del training (passo 2).

Strategia 1, passo 2: i livelli con le quote del training



I punteggi previsti stanno stretti intorno alla media (43–93): con le fasce di NewsGuard nessuna testata andrebbe in l1 o l5. Si ordinano le testate e si tagliano con le quote del training. L'etichetta vera usa sempre le fasce di NewsGuard.

Strategia 2: il voto degli articoli

1. In ogni fold i punteggi previsti per **tutti gli articoli** di test si ordinano e si tagliano con le quote di livelli degli **articoli** di training: ogni articolo prende un livello.
2. La testata prende il **livello votato dalla maggioranza** dei suoi articoli (a parità vince il più basso).
3. Affidabile: sì se la maggioranza degli articoli è da l3 in su.

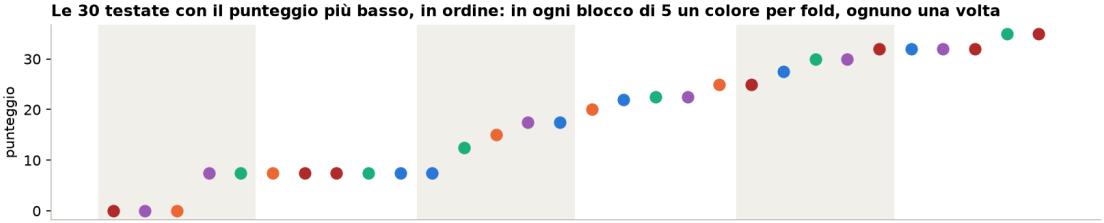
	art. 1	art. 2	art. 3	art. 4	art. 5
previsto	62	71	55	80	66
livello (tagli 57, 64, 67, 74)	l2	l4	l1	l5	l3

Nessuna maggioranza: vince il più basso (l1); 3 articoli su 5 da l3 in su: affidabile.
Il voto mette regressori e classificatori sullo stesso piano e permette la curva del DNA (1, 3, 5... articoli).

Strategia 3: perché un altro tentativo

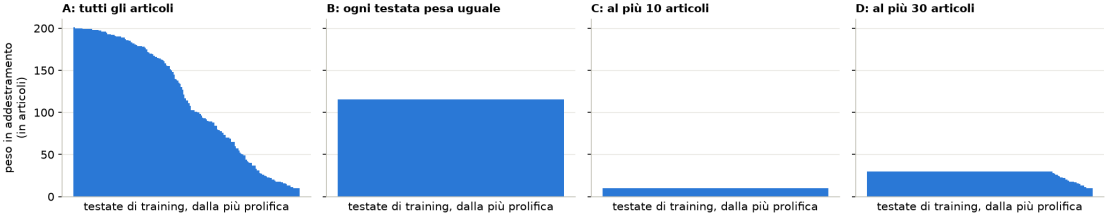
- **Obiettivo**: il punteggio esatto, senza classi né in addestramento né in valutazione.
- **Split per livello**: dentro un livello il punteggio era lasciato al caso; le testate l1 di un fold avevano in media 12 punti, quelle di un altro 31.
- **Testate prolifiche**: le testate hanno da 10 a 201 articoli; addestrando per articolo, chi scrive di più pesa di più.
- **La regressione serve?** Va confrontata con un classificatore sullo stesso terreno, il punteggio.

Strategia 3, passo 1: split stratificati sul punteggio



Le testate si ordinano per punteggio; a blocchi di 5 consecutive, ognuna va in un fold diverso (un colore per fold). Tre split con semi diversi. Ora le testate l1 hanno in media 20–22 punti in ogni fold.

Strategia 3, passo 2: cinque modi di pesare le testate



A tutti gli articoli; **B** ogni testata pesa uguale (peso $1/n$); **C** al più 10 articoli; **D** al più 30; **E** un vettore per testata (la media). Cambia solo l'addestramento: il test sono sempre tutti gli articoli.

Strategia 3, passo 3: regressore o classificatore, sullo stesso terreno

- **Regressore**: la ridge (o il transformer addestrato) prevede il punteggio.
- **Classificatore**: la logistica prevede 5 probabilità; il punteggio è la media dei punteggi medi di ogni livello nel training, pesata con le probabilità.

livello	l1	l2	l3	l4	l5
punteggio medio nel training (circa)	21	50	67	85	100
probabilità	0,1	0,2	0,3	0,3	0,1

$$\text{punteggio} = 0{,}1 \cdot 21 + 0{,}2 \cdot 50 + 0{,}3 \cdot 67 + 0{,}3 \cdot 85 + 0{,}1 \cdot 100 = 67{,}7$$

Lettori: TF-IDF e Mistral 24B congelato (300 addestramenti: 2 lettori $\times$ 2 tipi $\times$ 5 condizioni $\times$ 3 split $\times$ 5 fold); ModernBERT (condizioni A, B, C) e DeBERTa (B) addestrati come regressori, split 1.

Strategia 3, passo 4: come si valuta, in punti

Testata = media dei suoi articoli (E: il vettore medio). Quattro testate di esempio:

vero	10	50	80	100
previsto	30	55	70	85

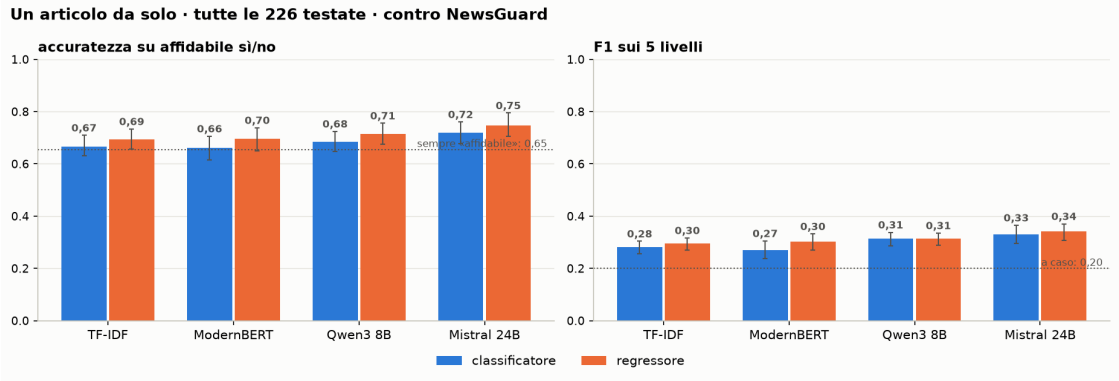
MAE	errore medio assoluto, in punti	$(20+5+10+15)/4 = 12{,}5$
RMSE	pesa di più gli errori grandi	13,7
$\mathbf{R^2}$	quanto si spiega (0 = dire sempre la media, 1 = perfetto)	0,84
Spearman	l'ordine delle testate è giusto?	1

Riferimento: chi dice sempre la media del training sbaglia in media di **22,6 punti**. Anche l'articolo singolo si valuta allo stesso modo (ogni articolo contro il punteggio della sua testata).

I risultati

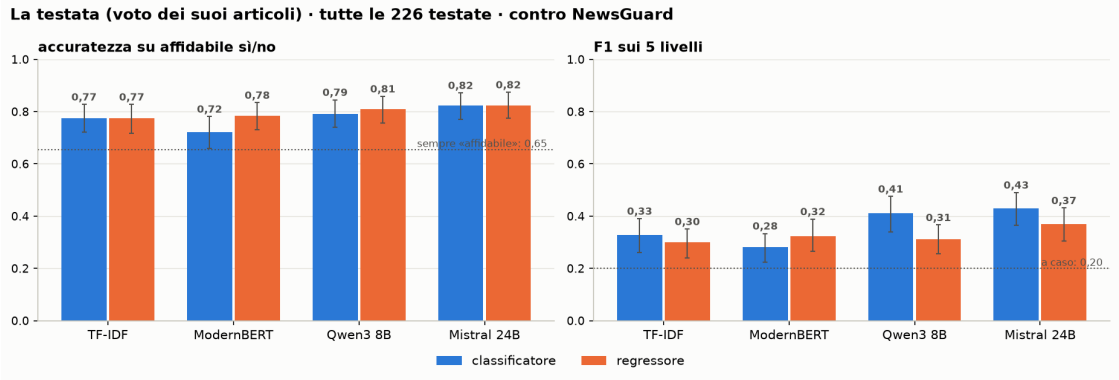
otto modelli contro NewsGuard: articolo singolo e testata

Un articolo da solo – tutte le 226 testate



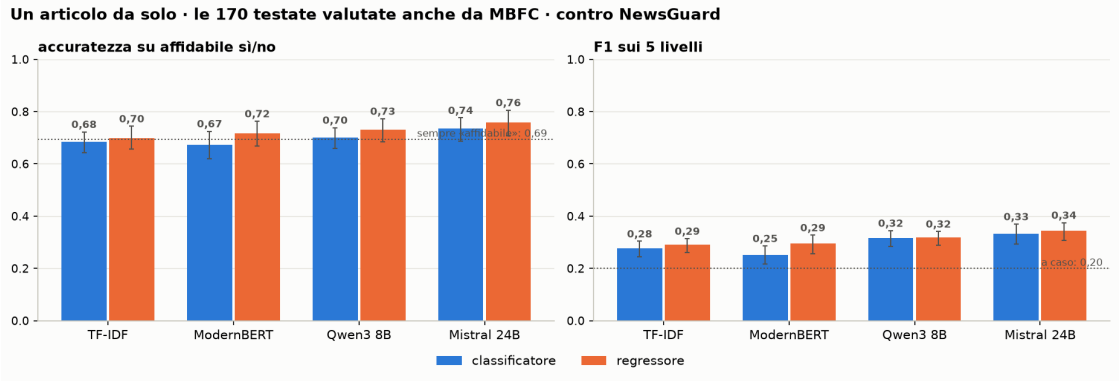
Ogni articolo contro l'etichetta della sua testata.

La testata – tutte le 226 testate



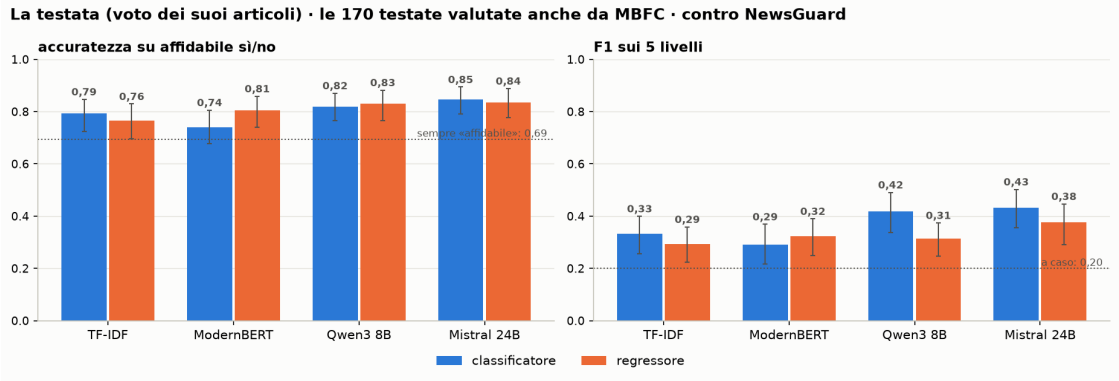
La testata prende il voto dei suoi articoli: tutto sale di 0,05–0,10, ma l'F1 resta tra 0,28 e 0,43.

Un articolo da solo – le 170 testate valutate anche da MBFC



Le stesse misure sulle 170 testate che useremo per il confronto con MBFC.

La testata – le 170 testate valutate anche da MBFC



Numeri quasi uguali a quelli sulle 226: le 170 sono rappresentative.

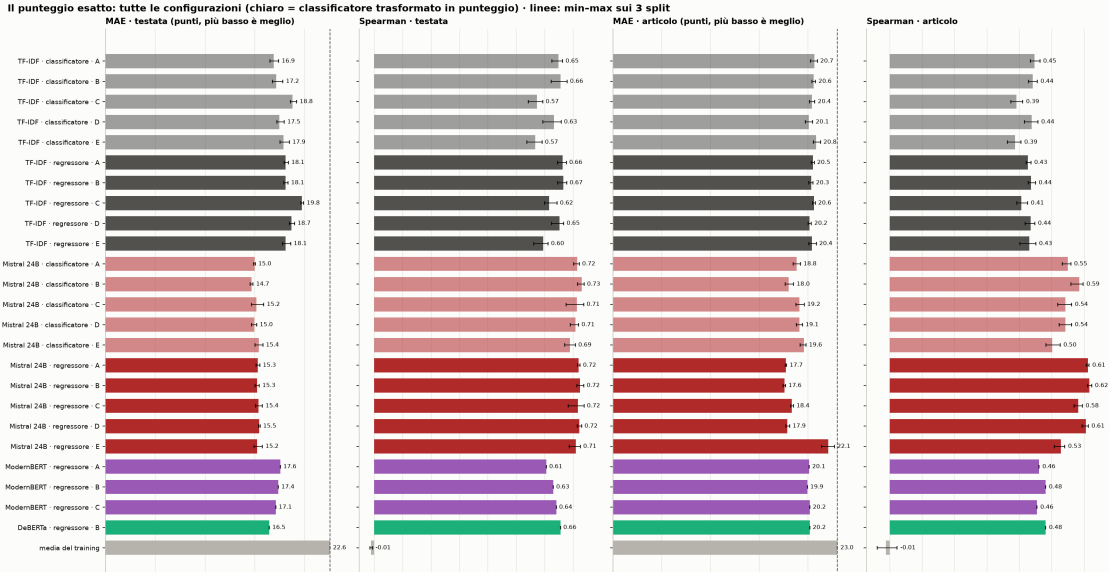
Siamo sempre lì

- Il voto degli articoli aiuta, i modelli grandi congelati sono i migliori, ma l'**F1 sui 5 livelli si ferma a circa 0,43**.
- Mistral 24B (tre volte più grande) va come Qwen3 8B: un lettore più grande non sposta i numeri.
- Accuratezza 0,77–0,82, contro lo 0,65 di chi dice sempre "affidabile".
- **Domanda**: è un limite dei modelli, o delle etichette? Le etichette sono giudizi di esperti: quanto sono d'accordo due esperti tra loro?

Il punteggio esatto

i risultati della strategia 3 (tentativo 18)

Il quadro: tutte le configurazioni

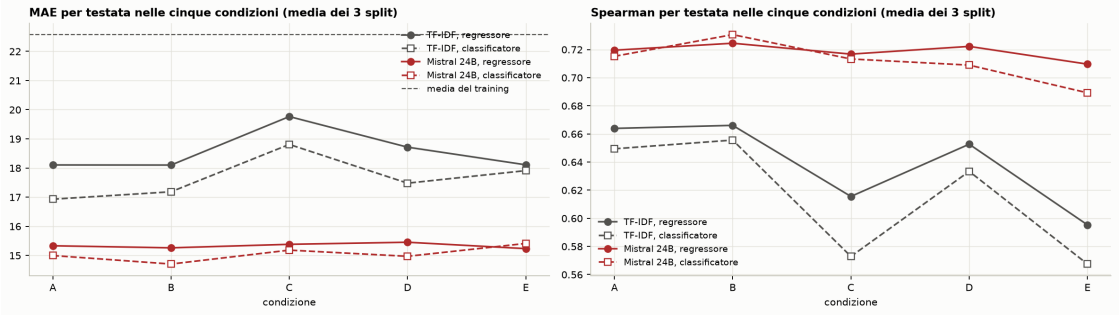


Le migliori configurazioni, per testata

Configurazione (split 1)	MAE (punti)	RMSE	R^2	Spearman
Mistral 24B congelato, classificatore	**14,7** [13,2; 16,3]	19,2	**0,50**	**0,73** [0,66; 0,78]
DeBERTa addestrato, regressore	16,5 [14,7; 18,5]	22,3	0,32	0,66 [0,58; 0,73]
TF-IDF, classificatore	16,8 [15,4; 18,5]	21,1	0,39	0,66 [0,58; 0,72]
ModernBERT addestrato, regressore	17,1 [15,6; 19,0]	21,7	0,36	0,64 [0,56; 0,72]
media del training	22,6 [20,7; 24,6]	27,1	0	0

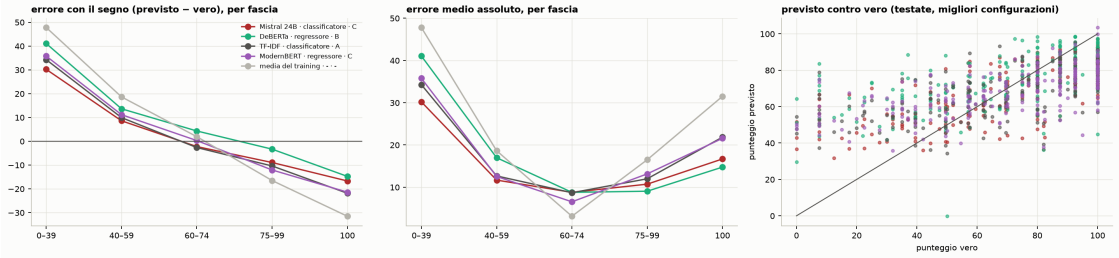
- Il migliore sbaglia in media di **15 punti** contro i 22,6 di chi dice sempre la media: un terzo in meno; spiega metà della variabilità dei punteggi.
- Per articolo singolo l'errore è più grande: 17,6 punti per Mistral, contro 23,0 della media.

Regressore o classificatore? Il peso delle testate?



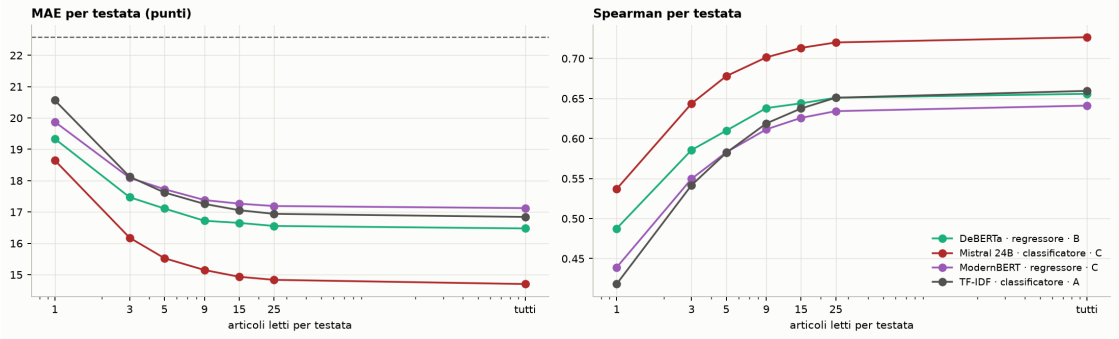
Il **classificatore** trasformato in punteggio fa come il regressore o meglio (Mistral 14,7–15,4 contro 15,2–15,5; TF-IDF 16,9–18,8 contro 18,1–19,8). Pesare le testate (B) aiuta poco; tagliare gli articoli (C, D) peggiora il TF-IDF, che ha bisogno di testo.

Dove si sbaglia: le previsioni schiacciate verso il centro



Le testate da 0–39 sono sovrastimate di 30–40 punti, quelle da 100 sottostimate di 15–20; in mezzo (60–74) l'errore è di 7–9 punti.

Il DNA in punti



Con un solo articolo Mistral sbaglia di 18,6 punti; con 9 articoli di 15,1; con tutti di 14,7. Dopo una decina di articoli si guadagna poco.

Che cosa dice il punteggio esatto

- **La regressione non aggiunge nulla**: un classificatore trasformato in punteggio fa lo stesso o meglio.
- **Il peso delle testate e lo split non falsavano i risultati**: le cinque condizioni cambiano l'errore di meno di un punto per Mistral; i tre split differiscono in media di 0,6 punti.
- **Mistral congelato resta il migliore** (MAE 14,7, Spearman 0,73); i BERT addestrati restano sotto (DeBERTa 16,5, ModernBERT 17,1–17,6).
- **Il limite è agli estremi**: le previsioni si schiacciano verso il centro; le testate peggiori e le migliori sono quelle sbagliate di più.
- Il quadro coincide con quello delle classi e dell'accordo: Spearman 0,73 come i due esperti tra loro (0,70).

Un altro modo di valutare

il modello come terzo annotatore

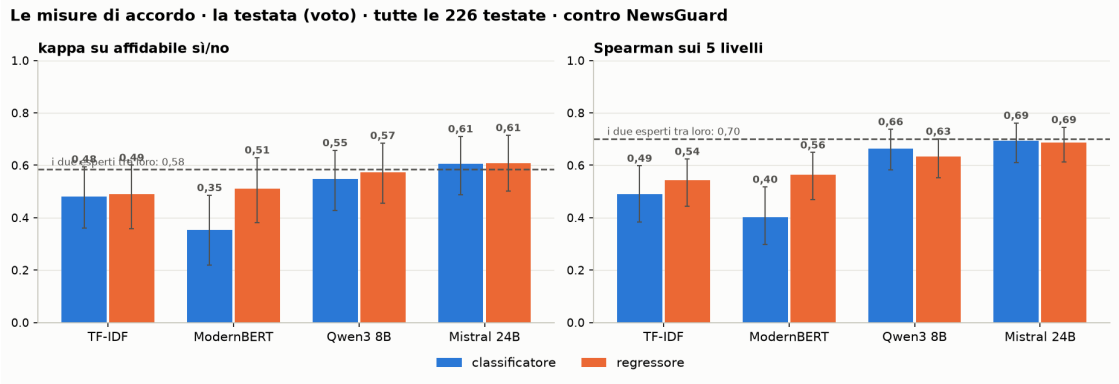
Due esperti non sono sempre d'accordo

NewsGuard (punteggio) e Media Bias/Fact Check (fattualità), sulle **170 testate** valutate da entrambi

0,70	**0,58**	**79%**
Spearman sui livelli	kappa su affidabile sì/no	stesso giudizio sì/no

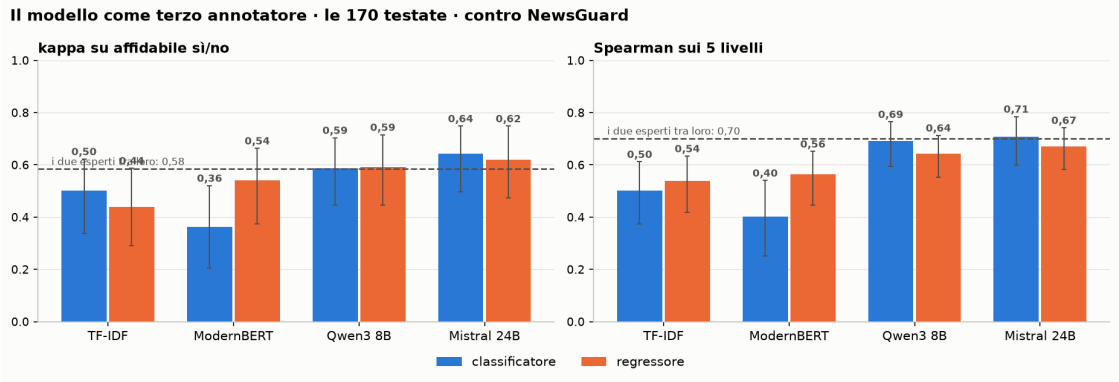
- **Spearman**: mettono le testate nello stesso ordine? **kappa**: danno lo stesso sì/no, oltre il caso?
- Su una testata su cinque due esperti danno giudizi opposti: è il tetto naturale.
- Il modello si tratta come un **terzo annotatore**: va d'accordo con gli esperti quanto loro tra loro?

Le misure di accordo – la testata – tutte le 226 testate



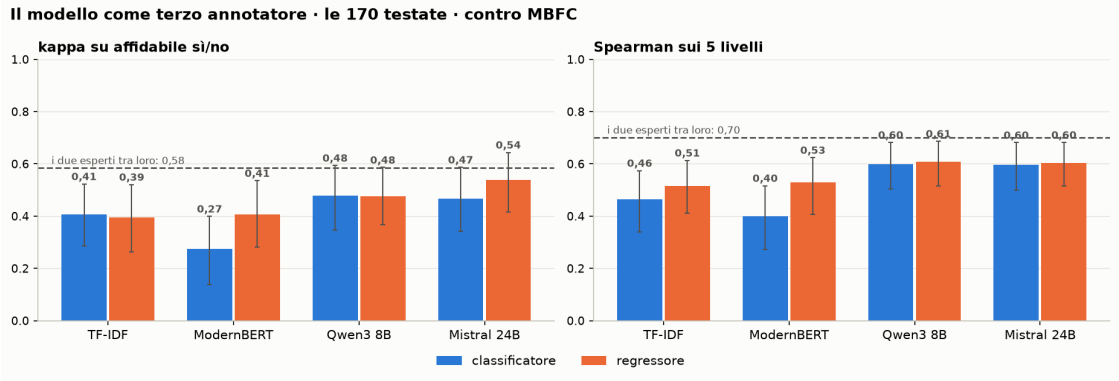
Con kappa e Spearman le differenze tra modelli si vedono; i modelli grandi arrivano alla linea degli esperti.

Terzo annotatore – contro NewsGuard (170 testate)



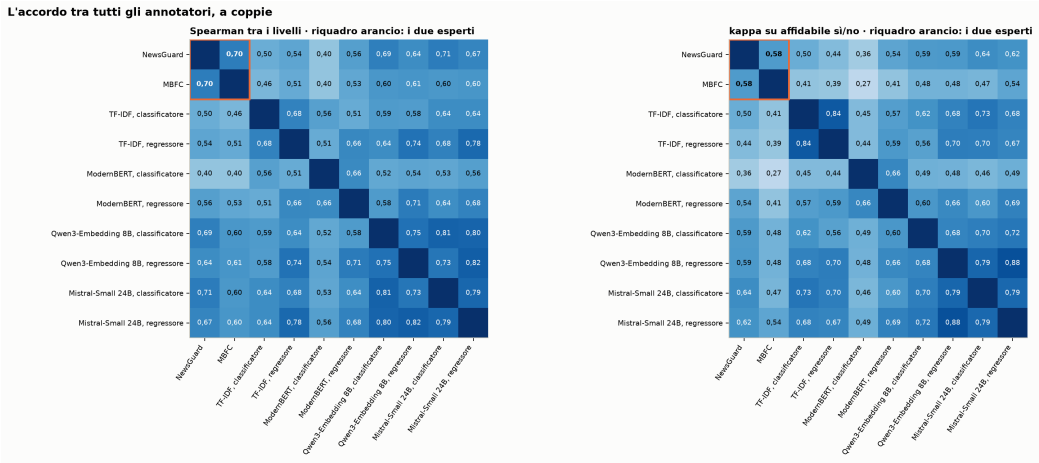
Qwen3 8B e Mistral 24B vanno d'accordo con NewsGuard **quanto MBFC** (differenza intorno a 0, intervallo che contiene lo 0).

Terzo annotatore – contro MBFC (mai visto in addestramento)



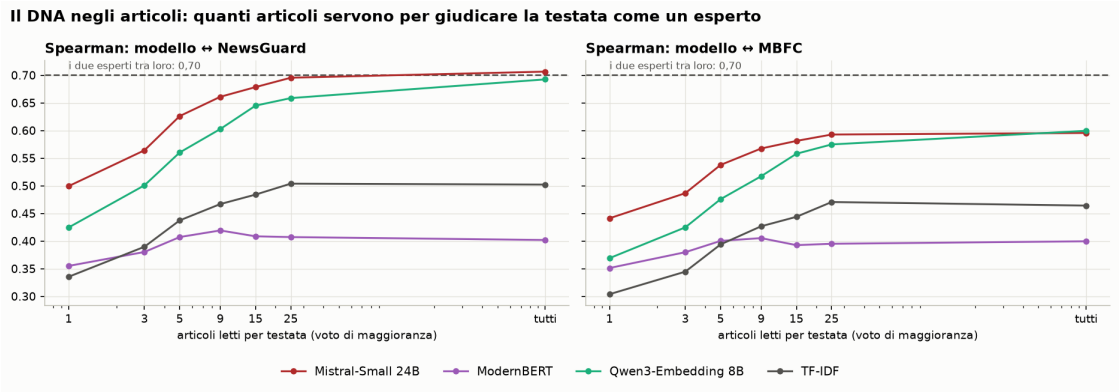
Il confronto indipendente: un po' sotto i due esperti tra loro, ma lontano dal caso.

Chi va d'accordo con chi



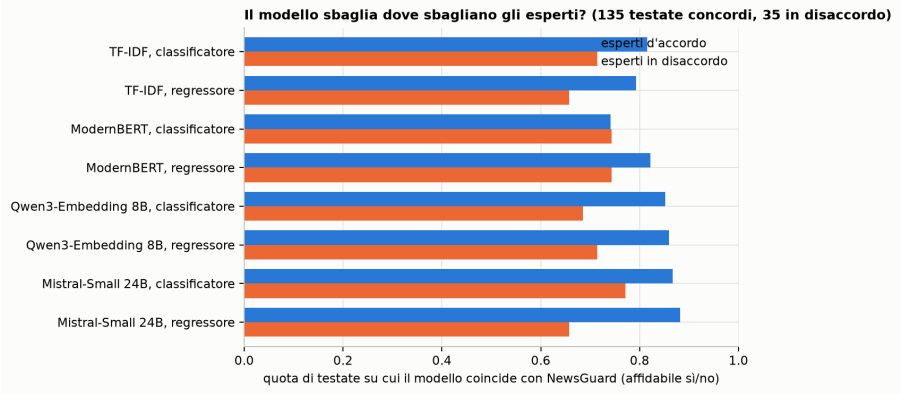
Ogni casella: l'accordo tra due annotatori (riquadro: i due esperti). I modelli grandi sono vicini a NewsGuard quanto MBFC.

Il DNA negli articoli



La testata giudicata leggendo solo k articoli: **uno solo dice già qualcosa**; con 10–25 articoli i modelli grandi arrivano al livello degli esperti.

Dove sbagliano i modelli



Dove i due esperti concordano, i modelli grandi coincidono con NewsGuard nell'85–88% dei casi; dove non concordano, nel 66–77%.

In breve

- Con le misure classiche siamo fermi: F1 al massimo 0,43, accuratezza 0,82.
- Con il punteggio esatto: il migliore sbaglia di **15 punti** (la media 22,6); la regressione non aggiunge nulla rispetto alla classificazione; il peso delle testate e gli split non cambiano il quadro.
- Le etichette sono giudizi: **due esperti concordano con Spearman 0,70 e kappa 0,58**.
- I modelli grandi congelati (Qwen3 8B, Mistral 24B), leggendo solo gli articoli, **vanno d'accordo con NewsGuard quanto MBFC**, e con MBFC (mai visto) poco meno.
- **Il DNA dell'affidabilità sta negli articoli**: uno basta per un indizio, una decina per un giudizio da esperto.
- Prossimi passi: controlli sul nome della testata, addestramento speculare su MBFC.