Criteri NewsGuard e regressione

Che cosa del punteggio si vede nel testo, e come valutiamo un modello che prevede il punteggio

John Bianchi

IMT Lucca & IIT-CNR Pisa

I criteri NewsGuard

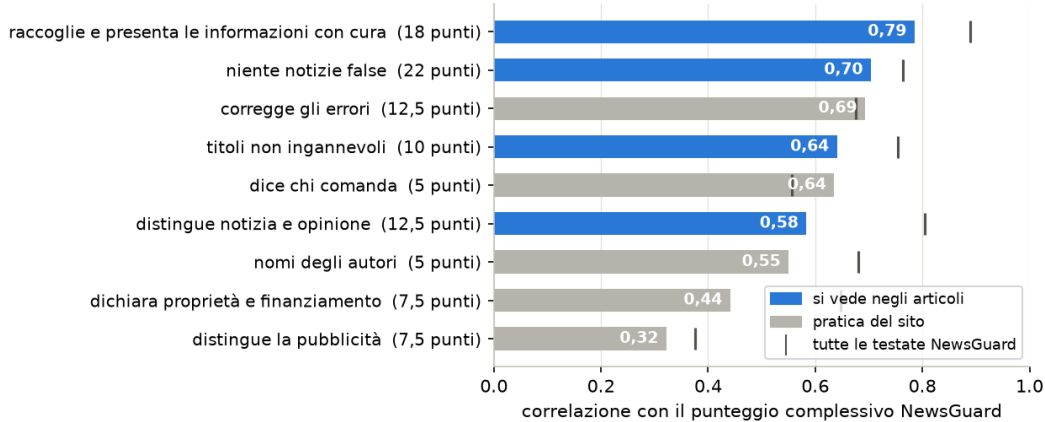
quali si vedono negli articoli, e quanto contano

Il punteggio NewsGuard è la somma di 9 criteri

Criterio	Punti	Dove si vede
Non pubblica notizie false	22	**negli articoli**
Raccoglie e presenta le informazioni con cura	18	**negli articoli**
Corregge gli errori	12,5	pratica del sito
Distingue notizia e opinione	12,5	**negli articoli**
Evita i titoli ingannevoli	10	**negli articoli**
Dichiara proprietà e finanziamento	7,5	pratica del sito
Distingue la pubblicità	7,5	pratica del sito
Dice chi comanda (e i conflitti di interesse)	5	pratica del sito
Mette i nomi degli autori	5	pratica del sito

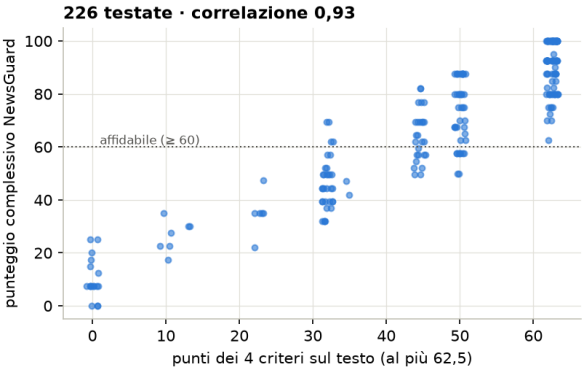
Ogni criterio è un sì o un no; il punteggio (0–100) è la somma dei punti dei sì. Affidabile = almeno 60. **4 criteri** riguardano il contenuto (**62,5 punti**); **5** le pratiche e la trasparenza del sito (37,5 punti), che negli articoli non si vedono.

Quanto ogni criterio va d'accordo con il punteggio complessivo



Barre: le nostre 226 testate (tentativo 16); trattini: tutte le 11.564 testate valutate da NewsGuard. Il criterio più legato al punteggio è **raccoglie e presenta le informazioni con cura** (0,79; 0,89 su tutte): è il più "testuale" e anche il più informativo.

I soli criteri sul testo spiegano quasi tutto il punteggio



- La somma dei punti dei 4 criteri sul testo ha correlazione **0,93** con il punteggio complessivo (0,95 su tutte le testate NewsGuard): ne spiega circa l'**87%**.
- Chi soddisfa tutti e 4 è **sempre affidabile** (94 testate su 94): anche perdendo tutti i punti del sito resta a 62,5.
- Chi ne manca anche uno solo è inaffidabile in 79 casi su 132.

Che cosa ne segue per l'addestramento

- **Il punteggio dei soli criteri sul testo** (0–62,5) è un bersaglio sensato: è quasi lo stesso del punteggio complessivo, ma toglie le pratiche del sito, che un modello che legge gli articoli non può vedere.
- **I criteri presi uno per uno** sono più difficili: "niente notizie false" e "titoli non ingannevoli" li soddisfa circa il 90% delle nostre testate, quindi restano solo 23–29 esempi negativi per imparare.
- I criteri sono legati tra loro: misurano in buona parte la stessa cosa, la qualità generale della testata.

La regressione

come si addestra e come si valuta, passo per passo

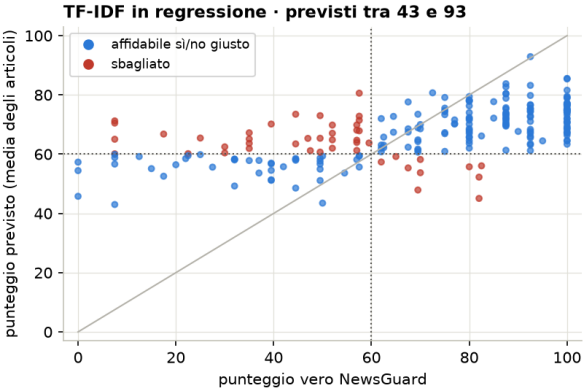
Passo 1 e 2: si impara un numero, la testata prende la media

1. **Addestramento.** Ogni articolo eredita il punteggio NewsGuard della sua testata (da 0 a 100). Il modello (ridge sopra il TF-IDF o gli embedding, oppure ModernBERT) impara a prevedere quel **numero**, sbagliando il meno possibile in media (errore quadratico).

2. **Test.** Le testate di test non sono mai state viste. Il modello dà un numero a ognuno dei loro articoli e la **testata prende la media** dei numeri dei suoi articoli.

Non si misura mai la distanza esatta ("ha detto 70, era 71"): il numero si trasforma in una decisione, come nei passi 3 e 4.

Passo 3: affidabile sì o no

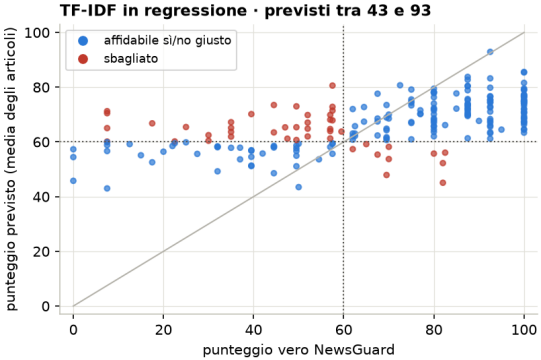


- Se la media prevista è **almeno 60**, la testata è affidabile. È giusto se anche il punteggio vero è almeno 60.
- **Previsto 70, vero 71**: tutti e due sopra 60, **giusto**. Anche previsto 61 e vero 98 è giusto.
- **Previsto 58, vero 61**: da una parte e dall'altra della soglia, **sbagliato**, anche se la distanza è piccola.

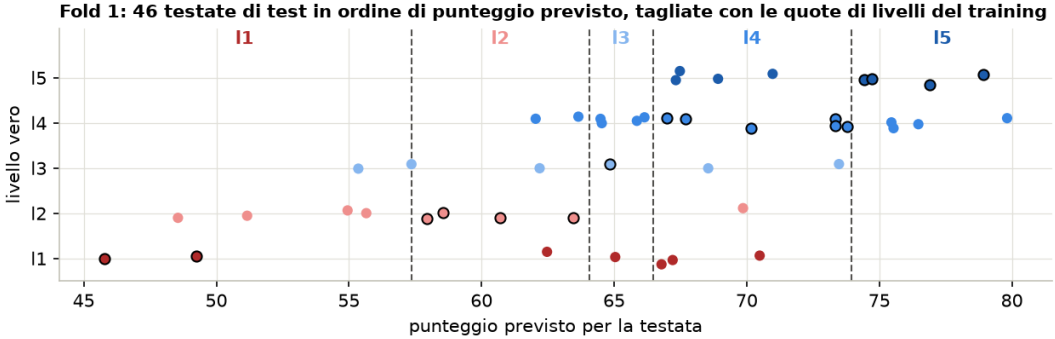
In rosso le testate sbagliate (TF-IDF in regressione).

Passo 4: i 5 livelli, e perché non bastano le soglie di NewsGuard

- I livelli NewsGuard sono fasce di punteggio: l1 0–39, l2 40–59, l3 60–74, l4 75–99, l5 100.
- Ma i numeri previsti stanno **stretti intorno alla media**: il TF-IDF prevede solo tra 43 e 93, mentre i veri vanno da 0 a 100 (nel grafico a fianco, i punti stanno su una fascia orizzontale).
- Con le fasce di NewsGuard nessuna testata finirebbe in **l1** (sotto 40) o in **l5** (100): conta di più l'**ordine** delle testate che il numero esatto.



Passo 4: le quote del training



Le testate di test si mettono **in ordine di punteggio previsto** e si tagliano con le **stesse quote di livelli del training** (fold 1: 16% l1, 19% l2, 13% l3, 35% l4, 17% l5). Contorno nero = livello giusto. **Previsto 70, vero 71** (l3): nel fold 1 il 70 cade in **l4**, quindi per l'F1 sui 5 livelli è un errore, ma per la **tolerant** (± 1 livello) e per affidabile sì/no è giusto.

In breve

Misura	**Come si ottiene dal numero previsto per la testata**
Affidabile sì/no	giusto se previsto e vero stanno dalla stessa parte di 60
F1 sui 5 livelli	testate in ordine di numero previsto, tagliate con le quote di livelli del training; giusto se il livello coincide
Tolerant ± 1	come sopra, ma è giusto anche un livello vicino

- La distanza esatta tra previsto e vero (70 contro 71) non entra mai nelle misure: conta da che parte di 60 sta la testata e in che posizione sta rispetto alle altre.
- I classificatori a 5 classi invece danno direttamente un livello a ogni articolo, e la testata prende il livello votato dalla maggioranza dei suoi articoli.