Criteri NewsGuard, regressione e accordo con gli esperti

Che cosa si vede nel testo, come valutiamo, e il modello come terzo annotatore

John Bianchi

IMT Lucca & IIT-CNR Pisa

I criteri NewsGuard

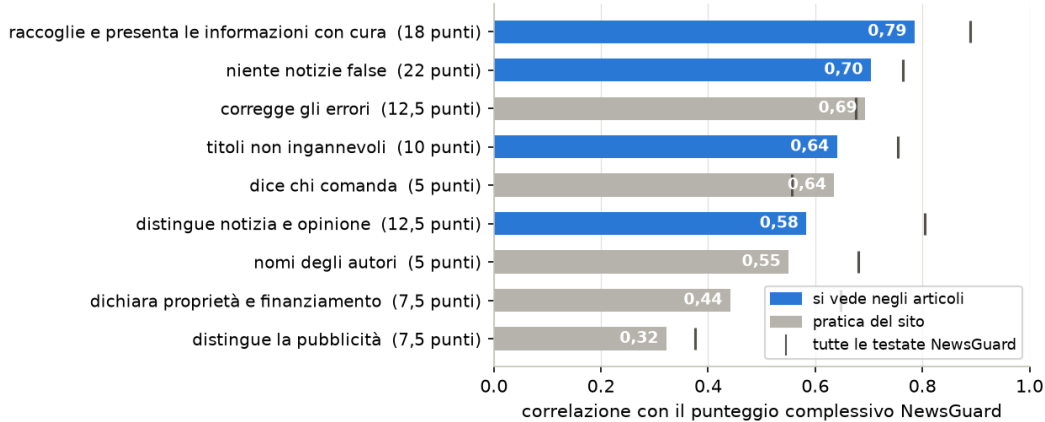
quali si vedono negli articoli, e quanto contano

Il punteggio NewsGuard è la somma di 9 criteri

Criterio	Punti	Dove si vede
Non pubblica notizie false	22	**negli articoli**
Raccoglie e presenta le informazioni con cura	18	**negli articoli**
Corregge gli errori	12,5	pratica del sito
Distingue notizia e opinione	12,5	**negli articoli**
Evita i titoli ingannevoli	10	**negli articoli**
Dichiara proprietà e finanziamento	7,5	pratica del sito
Distingue la pubblicità	7,5	pratica del sito
Dice chi comanda (e i conflitti di interesse)	5	pratica del sito
Mette i nomi degli autori	5	pratica del sito

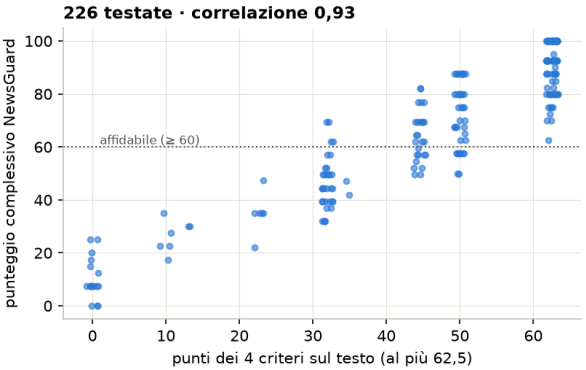
Ogni criterio è un sì o un no; il punteggio (0–100) è la somma dei punti dei sì. Affidabile = almeno 60. **4 criteri** riguardano il contenuto (**62,5 punti**); **5** le pratiche e la trasparenza del sito (37,5 punti), che negli articoli non si vedono.

Quanto ogni criterio va d'accordo con il punteggio complessivo



Barre: le nostre 226 testate (tentativo 16); trattini: tutte le 11.564 testate valutate da NewsGuard. Il criterio più legato al punteggio è **raccoglie e presenta le informazioni con cura** (0,79; 0,89 su tutte): è il più "testuale" e anche il più informativo.

I soli criteri sul testo spiegano quasi tutto il punteggio



- La somma dei punti dei 4 criteri sul testo ha correlazione **0,93** con il punteggio complessivo (0,95 su tutte le testate NewsGuard): ne spiega circa l'**87%**.
- Chi soddisfa tutti e 4 è **sempre affidabile** (94 testate su 94): anche perdendo tutti i punti del sito resta a 62,5.
- Chi ne manca anche uno solo è inaffidabile in 79 casi su 132.

Che cosa ne segue per l'addestramento

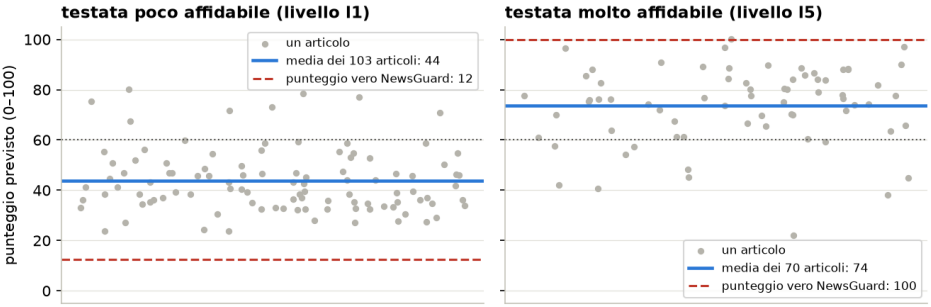
- **Il punteggio dei soli criteri sul testo** (0–62,5) è un bersaglio sensato: è quasi lo stesso del punteggio complessivo, ma toglie le pratiche del sito, che un modello che legge gli articoli non può vedere.
- **I criteri presi uno per uno** sono più difficili: "niente notizie false" e "titoli non ingannevoli" li soddisfa circa il 90% delle nostre testate, quindi restano solo 23–29 esempi negativi per imparare.
- I criteri sono legati tra loro: misurano in buona parte la stessa cosa, la qualità generale della testata.

Come si addestrano i regressori

Modello	**Il testo diventa numeri**	**Che cosa si addestra**
TF-IDF + ridge	conteggi di parole e coppie (100.000)	una somma pesata delle parole (ridge)
Qwen3 8B, Mistral 24B	il vettore del transformer **congelato**	la stessa ridge sopra il vettore
ModernBERT	il transformer stesso	**tutto** il transformer (150 M di pesi), 5 epoche

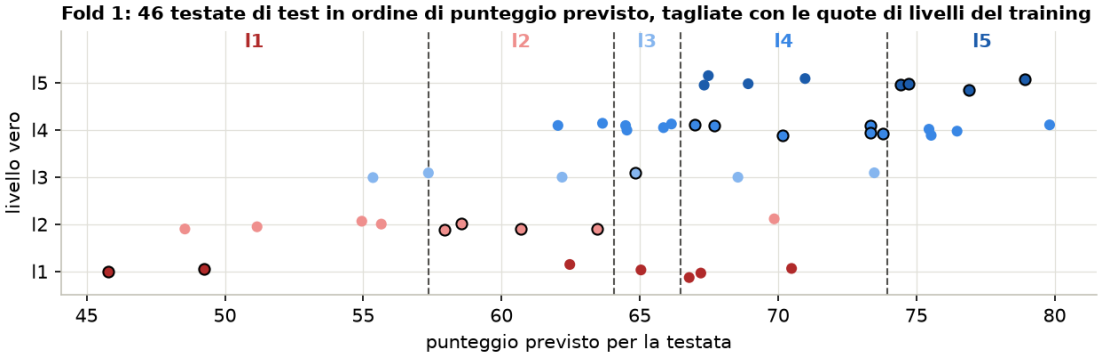
- Etichetta: ogni articolo eredita il punteggio NewsGuard (0–100) della sua testata.
- Si minimizza l'errore quadratico; 5 fold di testate: ogni testata è giudicata da un modello che non l'ha mai vista.

Come si valuta la regressione



1. Un numero per articolo; **la testata prende la media** dei suoi articoli.
2. **Affidabile** se la media è almeno 60 (giusto se anche il vero è almeno 60).
3. **5 livelli**: le testate in ordine di punteggio previsto, tagliate con le quote di livelli del training.

I 5 livelli: le quote del training

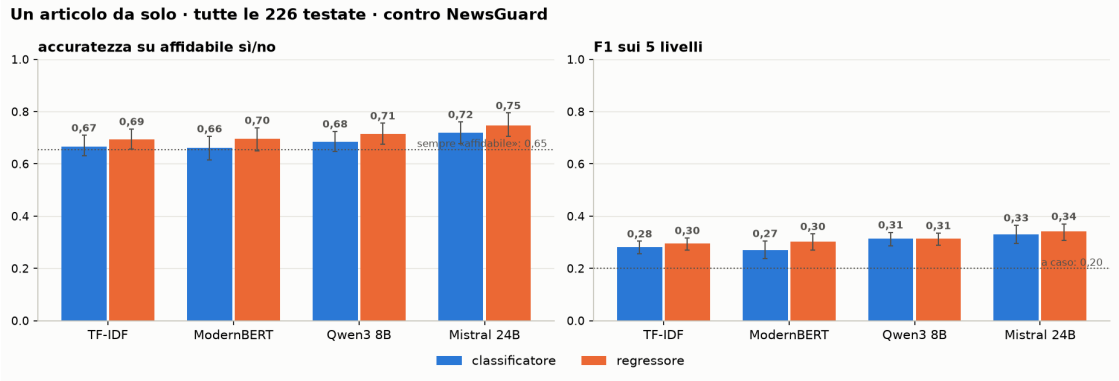


I punteggi previsti stanno stretti intorno alla media (43–93): conta l'**ordine**. Contorno nero = livello giusto. Previsto 70, vero 71 (l3) qui cade in l4: errore per l'F1, giusto per la tolerant e per affidabile sì/no.

I risultati

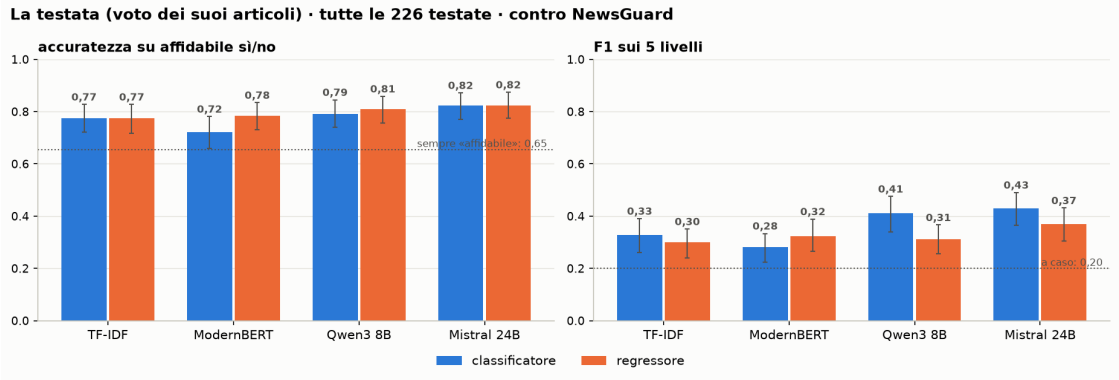
otto modelli contro NewsGuard: articolo singolo e testata

Un articolo da solo – tutte le 226 testate



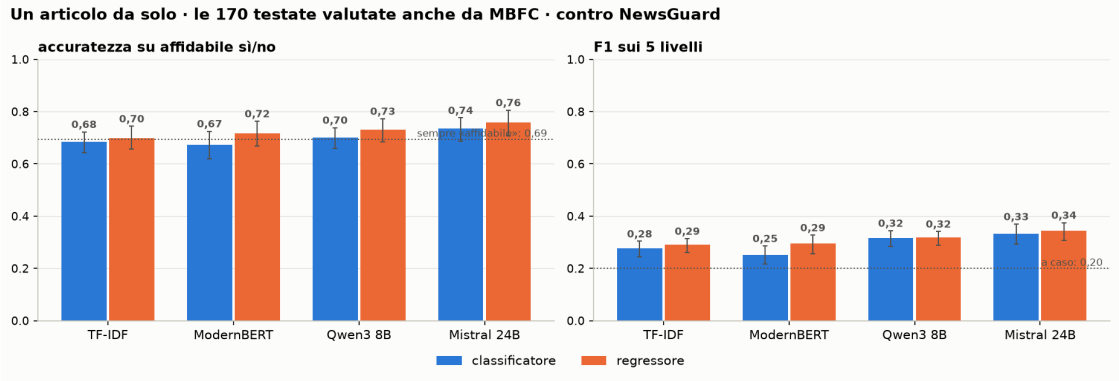
Ogni articolo contro l'etichetta della sua testata.

La testata – tutte le 226 testate



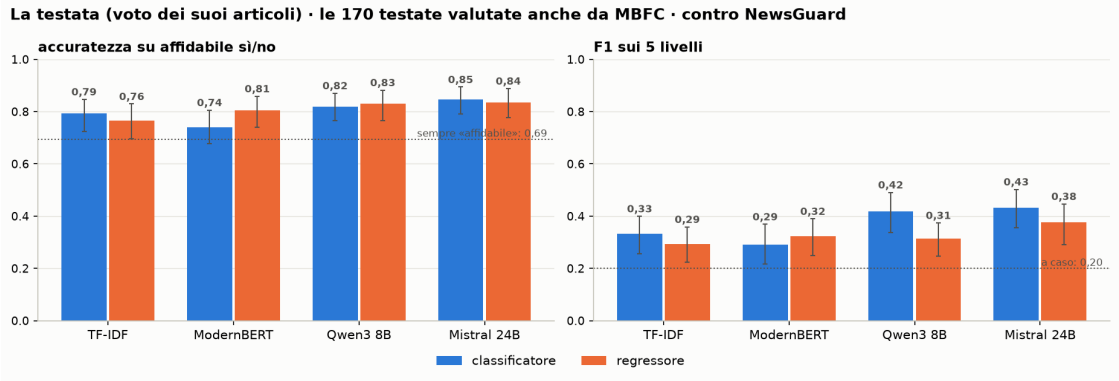
La testata prende il voto dei suoi articoli: tutto sale di 0,05–0,10, ma l'F1 resta tra 0,28 e 0,43.

Un articolo da solo – le 170 testate valutate anche da MBFC



Le stesse misure sulle 170 testate che useremo per il confronto con MBFC.

La testata – le 170 testate valutate anche da MBFC



Numeri quasi uguali a quelli sulle 226: le 170 sono rappresentative.

Siamo sempre lì

- Il voto degli articoli aiuta, i modelli grandi congelati sono i migliori, ma l'**F1 sui 5 livelli si ferma a circa 0,43**.
- Mistral 24B (tre volte più grande) va come Qwen3 8B: un lettore più grande non sposta i numeri.
- Accuratezza 0,77–0,82, contro lo 0,65 di chi dice sempre "affidabile".
- **Domanda**: è un limite dei modelli, o delle etichette? Le etichette sono giudizi di esperti: quanto sono d'accordo due esperti tra loro?

Un altro modo di valutare

il modello come terzo annotatore

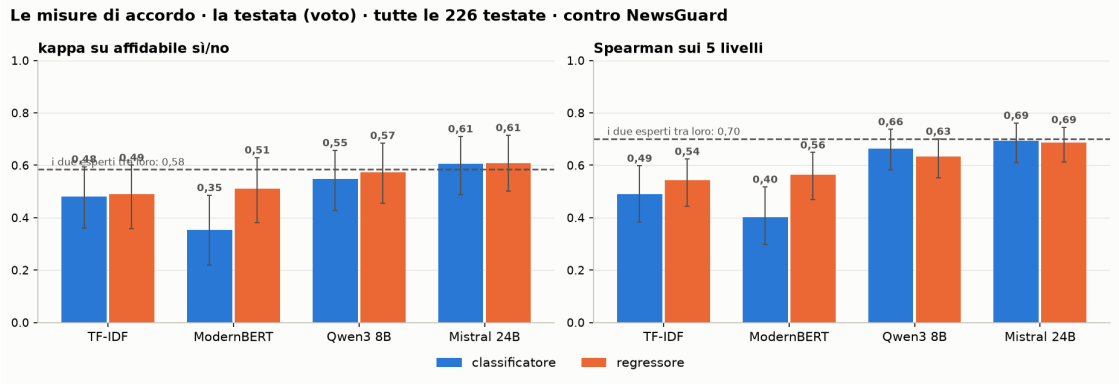
Due esperti non sono sempre d'accordo

NewsGuard (punteggio) e Media Bias/Fact Check (fattualità), sulle **170 testate** valutate da entrambi

0,70	**0,58**	**79%**
Spearman sui livelli	kappa su affidabile sì/no	stesso giudizio sì/no

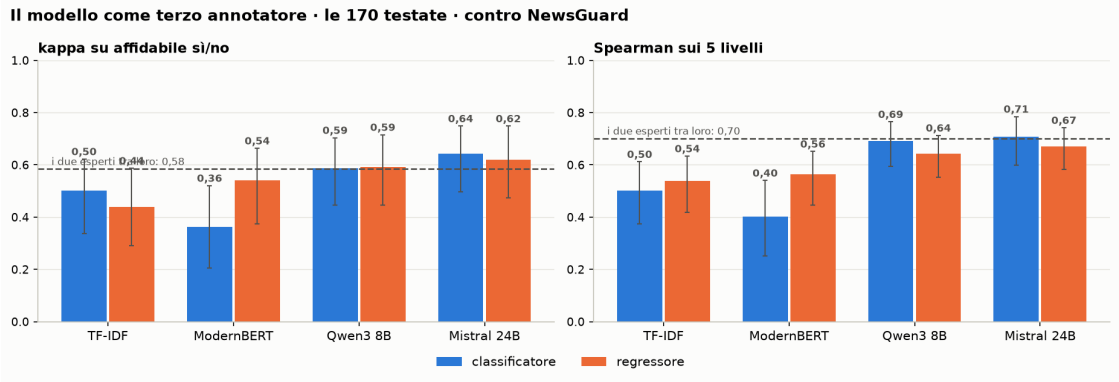
- **Spearman**: mettono le testate nello stesso ordine? **kappa**: danno lo stesso sì/no, oltre il caso?
- Su una testata su cinque due esperti danno giudizi opposti: è il tetto naturale.
- Il modello si tratta come un **terzo annotatore**: va d'accordo con gli esperti quanto loro tra loro?

Le misure di accordo – la testata – tutte le 226 testate



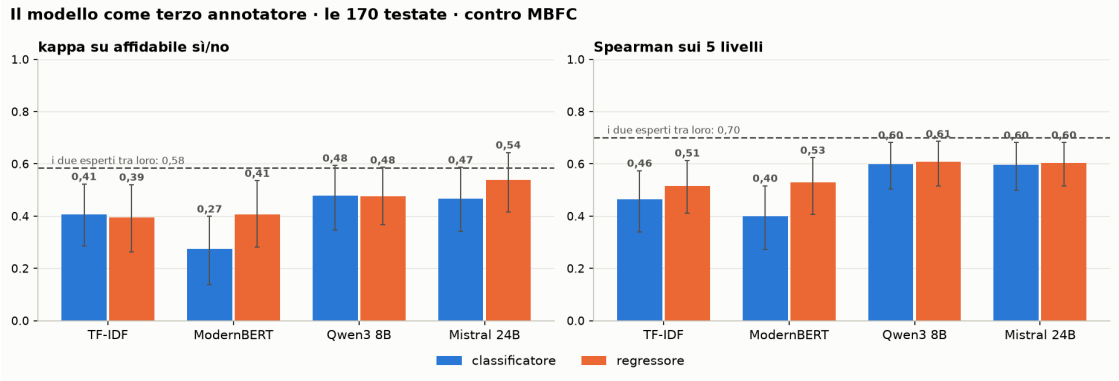
Con kappa e Spearman le differenze tra modelli si vedono; i modelli grandi arrivano alla linea degli esperti.

Terzo annotatore – contro NewsGuard (170 testate)



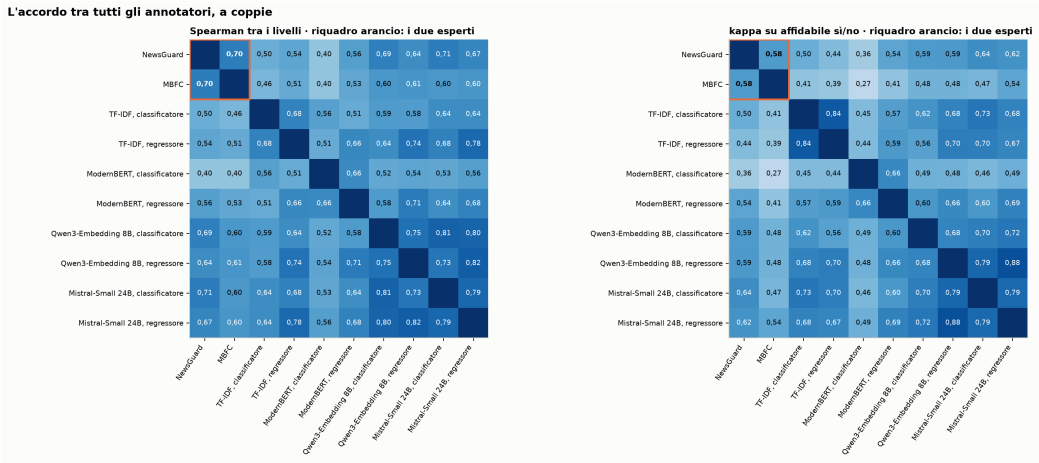
Qwen3 8B e Mistral 24B vanno d'accordo con NewsGuard **quanto MBFC** (differenza intorno a 0, intervallo che contiene lo 0).

Terzo annotatore – contro MBFC (mai visto in addestramento)



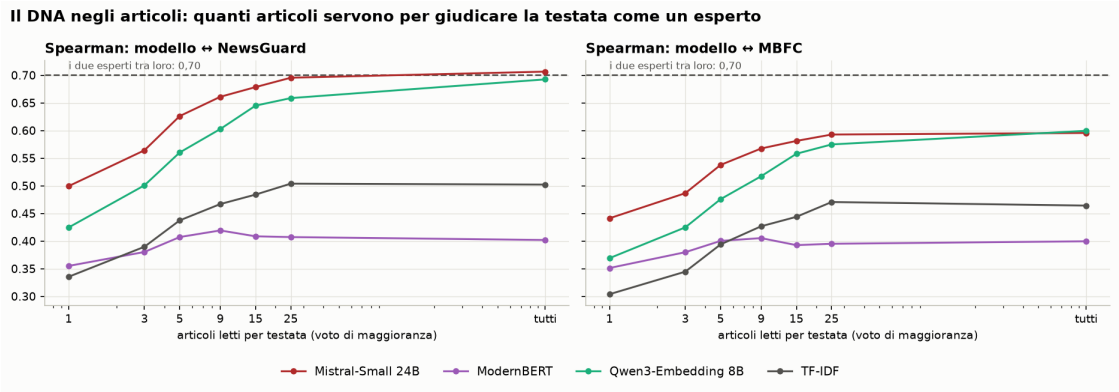
Il confronto indipendente: un po' sotto i due esperti tra loro, ma lontano dal caso.

Chi va d'accordo con chi



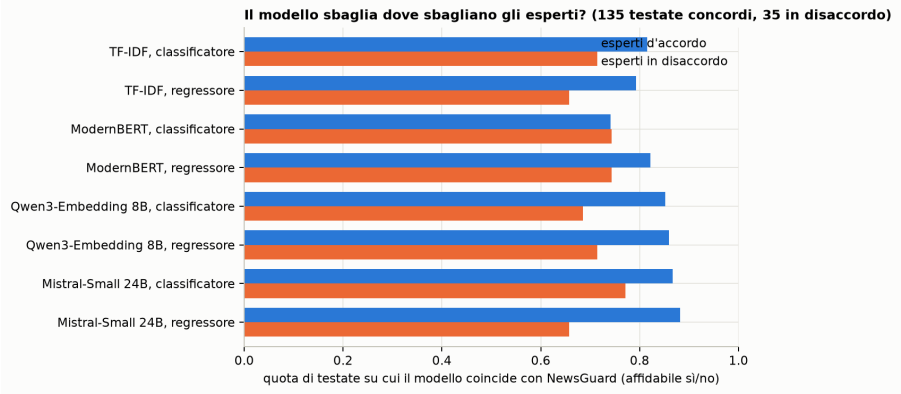
Ogni casella: l'accordo tra due annotatori (riquadro: i due esperti). I modelli grandi sono vicini a NewsGuard quanto MBFC.

Il DNA negli articoli



La testata giudicata leggendo solo k articoli: **uno solo dice già qualcosa**; con 10–25 articoli i modelli grandi arrivano al livello degli esperti.

Dove sbagliano i modelli



Dove i due esperti concordano, i modelli grandi coincidono con NewsGuard nell'85–88% dei casi; dove non concordano, nel 66–77%.

In breve

- Con le misure classiche siamo fermi: F1 al massimo 0,43, accuratezza 0,82.
- Ma le etichette sono giudizi: **due esperti concordano con Spearman 0,70 e kappa 0,58**.
- I modelli grandi congelati (Qwen3 8B, Mistral 24B), leggendo solo gli articoli, **vanno d'accordo con NewsGuard quanto MBFC**, e con MBFC (mai visto) poco meno.
- **Il DNA dell'affidabilità sta negli articoli**: uno basta per un indizio, 10–25 per un giudizio da esperto.
- Prossimi passi: controlli sul nome della testata (il modello la riconosce?), addestramento speculare su MBFC.