La regressione dell'affidabilità

Tre strategie per andare dal testo al punteggio: come si allena il modello, come si valuta

John Bianchi

IMT Lucca & IIT-CNR Pisa

L'allenamento, comune a tutte

un regressore che dà un punteggio a ogni articolo

Il compito e l'etichetta

- Ogni **testata** ha un punteggio NewsGuard da 0 a 100 (es. *lifezette.com* $= 0$, *americanprogress.org* $= 100$).
- L'etichetta è **per testata**: ogni articolo **eredita** il punteggio della sua testata. Tutti i 31 articoli di lifezette.com valgono 0, tutti i 70 di americanprogress.org valgono 100.
- Il **regressore** legge **un articolo** e dà **un numero** (il punteggio previsto per quell'articolo).
- Si allena a sbagliare il meno possibile in media: minimizza $(\text{previsto} - \text{vero})^2$ sugli articoli di training.
- **5 fold di testate**: si allena su 4 gruppi, prevede sul quinto. Ogni testata è giudicata da un modello che **non l'ha mai vista**.

Il bersaglio: il voto esatto, non la classe

Il **regressore** impara il **voto NewsGuard esatto** (0–100). Il **classificatore** impara la **classe** (l1–l5).

testata	**voto 0–100 (bersaglio del regressore)**	**livello (bersaglio del classificatore)**
lifezette.com	0	l1
americanthinker.com	22,5	l1
amgreatness.com	49,5	l2
ammoland.com	67,5	l3
theamericanconservative.com	85	l4
americanprogress.org	100	l5

lifezette.com e americanthinker.com sono **entrambe l1**, ma il regressore impara **0** e **22,5** (due numeri diversi), mentre il classificatore impara **l1** per tutte e due. Il regressore sente le differenze **dentro** il livello; il classificatore no.

Input e output: un esempio

In allenamento (il modello vede testo e punteggio della testata):

testo dell'articolo (input)	**punteggio da imparare (output)**
"*. . . a radical left-wing mob stormed. . .*" (lifezette.com)	0
"*. . . the report, which the agency confirmed. . .*" (americanprogress.org)	100

In test (il modello vede solo il testo e dà un numero):

testo di un articolo mai visto (input)	**punteggio previsto (output)**
un articolo di lifezette.com	34
un altro articolo di lifezette.com	71
un articolo di americanprogress.org	97

Il singolo articolo è rumoroso; il giudizio sulla **testata** nasce mettendo insieme i suoi articoli — ed è qui che cambiano le tre strategie.

I quattro modi di leggere il testo

Lettore	**Come il testo diventa numeri**	**Si addestra?**
TF-IDF + ridge	conteggi di parole e coppie (100.000)	no (solo la ridge sopra)
Qwen3 8B, Mistral 24B + ridge	il vettore del transformer **congelato**	no: è un lettore, si allena la ridge
ModernBERT, DeBERTa	il transformer stesso	**sì**, tutto, 5 epoche

Il lettore cambia **solo come il testo diventa numeri**. Le tre strategie qui sotto valgono per tutti allo stesso modo: cambiano solo **come dai punteggi degli articoli si arriva al giudizio sulla testata**, e **come si misura l'errore**.

Le tre strategie

dai punteggi degli articoli al giudizio sulla testata

Le tre strategie in una pagina

Strategia	Dal testo al giudizio sulla testata	Come si misura
1. Prima la media, poi il livello (tentativo 16)	media dei punteggi dei suoi articoli → un livello (l1–l5) o affidabile sì/no	F1, tolerant, accuratezza
2. Prima il livello, poi il voto (tentativo 17)	ogni articolo → un livello; la testata prende il livello **votato** dai suoi articoli	+ kappa, Spearman
3. Solo il punteggio, in punti (tentativo 18)	media dei punteggi dei suoi articoli; **nessun livello**	errore in punti (MAE), R^2, Spearman

1 e 2 trasformano il punteggio in **classi** (per confrontarsi con NewsGuard a livelli); 3 resta sul **numero**. Tra 1 e 2 non cambia solo "media contro maggioranza": cambiano anche **le quote** e **la regola di affidabile** (slide dedicata dopo la strategia 2).

Strategia 1

prima la media, poi il livello (tentativo 16)

Strategia 1 — come si allena

- **Bersaglio**: il **voto esatto 0–100** (non la classe). Un articolo di lifezette.com → 0, uno di amgreatness.com → 49,5. Le classi **non entrano nell'allenamento** del regressore.
- **Lo split dei fold è per livello**: con `StratifiedKFold` sui 5 livelli, ogni fold ha la stessa quota di testate l1, l2, . . . , l5.
- **Attenzione al disallineamento**: il bersaglio è il voto **continuo**, ma la divisione in fold guarda solo il **livello** — dentro un livello il voto è lasciato al caso. È il dubbio che la strategia 3 risolve.

Strategia 1 — come si valuta (esempio: lifezette.com)

31 articoli, punteggio vero **0** (livello l1, inaffidabile). Punteggi previsti dei primi articoli:

$$22,\ 34,\ 42,\ 44,\ 39,\ 37,\ 71,\ 26,\ \ldots \qquad \textbf{media} = \mathbf{41{,}7}$$

1. **Affidabile sì/no**: soglia **fissa** 60 sulla media **grezza**, **nessuno stiramento**: $41{,}7 < 60 \Rightarrow$ **inaffidabile**. Vero: inaffidabile. **giusto**
2. **5 livelli**: qui sì, le medie si riadattano **con le quote** (non con minimo e massimo). Le quote vengono dalle **testate** di training del fold (l1 15%, l2 19%, l3 13%, l4 35%, l5 18%). Le medie delle 45 **testate di test** si ordinano e si tagliano a quelle quote. Soglie: 53,1 | 60,4 | 67,6 | 84,7. Media $41{,}7 < 53{,}1 \Rightarrow$ **l1**. Vero: l1. **giusto**

Misure: F1 sui 5 livelli, tolerant (± 1 livello), accuratezza su affidabile sì/no.
Perché i due casi sono trattati diversamente? **Sezione seguente**.

Dal numero alla classe

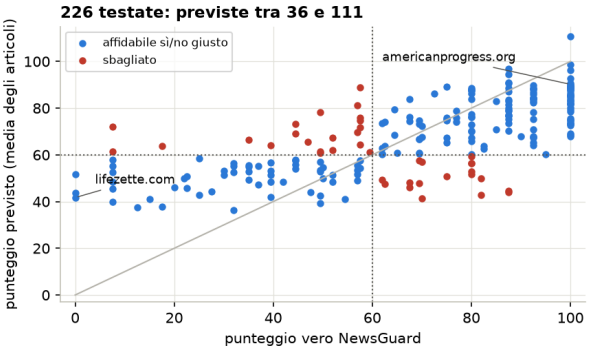
che cosa succede ai punteggi del regressore prima di diventare livelli

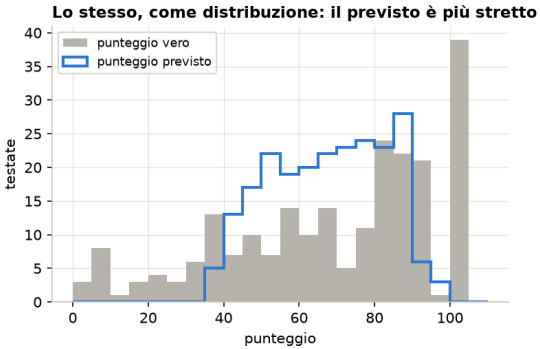
Che cosa succede ai punteggi, caso per caso

Dove	Trasformazione del punteggio previsto
strategia 1, **affidabile sì/no**	**nessuna**: media grezza ≥ 60
strategia 1, **5 livelli**	**quote**: si ordinano le medie delle testate di test e si tagliano alle quote delle testate di training
strategia 2, **livelli e affidabile**	**quote**: si ordinano gli articoli di test e si tagliano alle quote degli articoli di training; affidabile = maggioranza in l3–l5
strategia 3, **errore in punti**	**nessuna**: media grezza contro voto vero

Mai uno stiramento lineare tra minimo e massimo, **mai** un ritaglio a 0–100. Le quote non sono uno stiramento lineare: sono uno stiramento **per ordine**, livello per livello (slide seguenti).

Il problema: il regressore schiaccia verso il centro

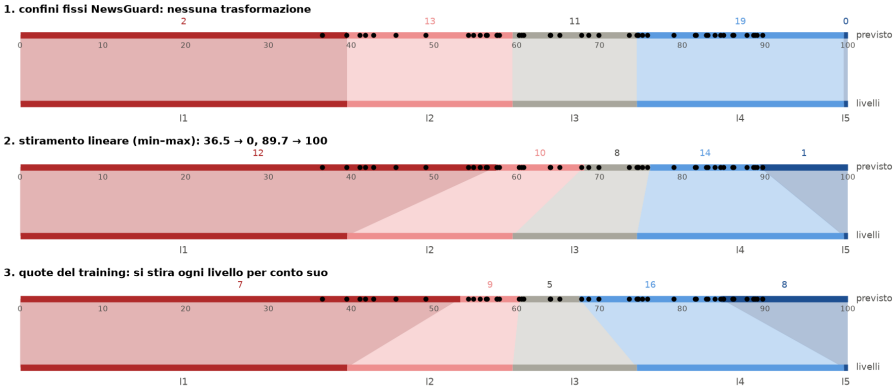




I voti veri vanno da 0 a 100, le medie previste solo da **36 a 111**: nessuna testata sotto 36, quasi nessuna a 100 o oltre. È come una **foto poco contrastata**: l'ordine c'è (Spearman 0,7), ma tutto è grigio medio.

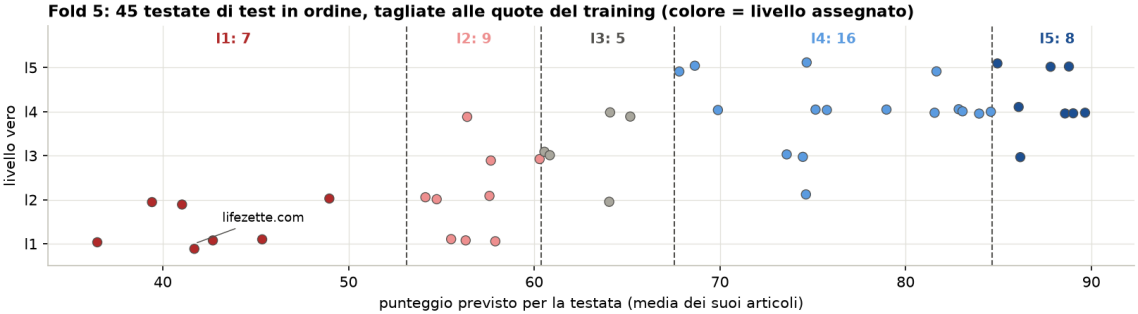
Con i confini NewsGuard (40 | 60 | 75 | 100) sul numero grezzo, l1 e l5 **non escono quasi mai**.

Tre modi di portare le medie sulla scala dei livelli



Fold di lifezette: 45 testate di test (i punti); sopra la scala prevista, sotto i 5 livelli NewsGuard; i numeri sono le testate per livello. **1** nessuna trasformazione. **2** come il **contrasto** di una foto: il punto più scuro va a 0, il più chiaro a 100, in mezzo tutto in proporzione. **3** come l'**equalizzazione dell'istogramma**: ogni livello prende la stessa quota di testate che ha nel training, per quanto stretto sia il suo tratto (l3: da 60,4 a 67,6).

Le quote, passo passo (fold di lifezette)



1. Nelle testate di training del fold: l1 15%, l2 19%, l3 13%, l4 35%, l5 18%.
2. Le 45 medie di test si mettono in ordine; le soglie cadono al 15%, 34%, 47%, 82% della fila: 53,1 | 60,4 | 67,6 | 84,7.
3. Risultato: 7, 9, 5, 16, 8 testate per livello (le vere: 7, 8, 7, 16, 7). Si usano **solo le etichette di training** e l'**ordine** delle previsioni di test.

Le quote: tre cose da sapere

1. **Conta solo l'ordine**. Se tutte le previsioni si moltiplicano per 2, o se ne prende la radice, i livelli non cambiano. Per questo lo schiacciamento non danneggia i livelli: basta che l'ordine sia giusto.

2. **Le soglie si calcolano su tutto il fold di test insieme**, non testata per testata: per tagliare al 15% serve una fila di testate. Una testata nuova, da sola, non si potrebbe valutare così.

3. **Le etichette di test non si usano mai**: le quote vengono dalle etichette di training, del test si usano solo le previsioni.

Quale funziona meglio sui 5 livelli (226 testate)

dal numero al livello	giusti	F1	tolerant	testate per livello l1–l5
1. confini fissi NewsGuard	94	0,32	0,89	**4** / 72 / 61 / 88 / **1**
2. stiramento min–max	69	0,26	0,70	86 / 55 / 42 / 38 / **5**
3. **quote del training**	**95**	**0,40**	0,85	36 / 44 / 28 / 78 / 40
livelli veri				35 / 43 / 30 / 79 / 39

- **Confini fissi**: quasi niente l1 e l5, tutto in mezzo. Il tolerant è alto proprio per questo: chi sta in mezzo è sempre a un livello da tutti.
- **Min–max**: dipende da **una sola** testata per estremo. In questo fold la più bassa è 36,5, e lifezette (41,7) diventa 9,8: troppe l1, quasi nessuna l5.
- **Quote**: le classi escono nelle proporzioni giuste per costruzione, e l'F1 sale. È quella usata.

Mistral 24B regressore, tutti gli articoli, primo split del tentativo 18; ogni metodo calcolato fold per fold.

E affidabile sì/no? Nessuno stiramento, e non serve

Stesse previsioni (226 testate), tre modi di decidere "affidabile":

regola	**accuratezza**	**previste affidabili**	**vere affidabili**
media grezza $\geq$ **60** (strategia 1)	**0,83**	150	148
quota del training (35% inaffidabili)	0,81	146	148
stiramento min–max, poi ≥ 60	0,69	**85**	148

- Lo schiacciamento sposta soprattutto gli **estremi**: le testate vere 0–10 sono previste in media **52** ($+42$), quelle a 100 in media **84** (-16). Quelle tra 55 e 65 in media **64**: solo $+4$. Con le quote, nel fold di lifezette la soglia sarebbe **60,4**: praticamente 60.
- Quindi per il sì/no la soglia fissa basta. Per i 5 livelli no, perché l1 e l5 sono proprio gli estremi.
- **Attenzione**: che 60 grezzo e 60 "a quote" coincidano è verificato per questo modello, non garantito per tutti. Nella strategia 2 il sì/no passa comunque per le quote (articoli in l3–l5).

Strategia 2

prima il livello, poi il voto (tentativo 17)

Strategia 2 — come si allena

- **Identico alla strategia 1**: stesso modello, stesse previsioni, stesso bersaglio (il voto esatto 0–100), stessi fold per livello. Nessun riaddestramento.
- Cambia solo **come dai punteggi degli articoli si arriva al livello della testata**: la strategia 2 è **un altro modo di valutare** le stesse previsioni.
- **Perché serve**: ogni articolo riceve un livello suo, quindi si può chiedere "**quanti articoli servono**?" (la curva del DNA: con 1 articolo, con 5, con 25...) e trattare il modello come un annotatore (kappa, Spearman).

Strategia 2 — come si valuta, passo passo (lifezette.com)

1. **Quote dagli articoli di training** del fold: si contano gli **articoli** (non le testate) per livello: l1 17%, l2 22%, l3 13%, l4 31%, l5 17%.
2. **Soglie**: i punteggi previsti di **tutti i ∼5.000 articoli di test** del fold si ordinano e si tagliano a quelle quote. Soglie: 45,9 | 60,6 | 68,5 | 87,4.
3. **Un livello per articolo**: 22→l1, 34→l1, 42→l1, 44→l1, 39→l1, 37→l1, 71→l4, 26→l1, ...
4. **Voto sui 5 livelli**: l1 23, l2 6, l3 1, l4 1 (su 31) ⇒ **l1**. Vero: l1. **giusto**
   A parità di voti vince il livello **più basso**.
5. **Voto su affidabile**: ogni articolo vota "sì" se il suo livello è l3 o più. Sì: 2, no: 29 ⇒ **inaffidabile**. **giusto** A parità: inaffidabile.

Misure: F1, tolerant, accuratezza (come la 1), più kappa e Spearman (l'accordo tra annotatori).

Strategia 1 e 2: non solo “media contro maggioranza”

	1. Prima la media, poi il livello	**2. Prima il livello, poi il voto**
ordine	media degli articoli → un numero → un livello	ogni articolo → un livello → voto
chi si taglia	le ∼45 medie delle testate di test	i ∼5.000 articoli di test
quote	dalle **testate** di training 16 / 19 / 13 / 36 / 17%	dagli **articoli** di training 18 / 21 / 13 / 30 / 18%
affidabile	media ≥ 60 (soglia **fissa**, sul numero)	maggioranza di articoli in l3–l5 (soglia **a quote**, sull’ordine)
parità	—	livello più basso; inaffidabile

Quote del fold 4. Le quote degli articoli sono diverse perché le testate l4 scrivono meno (36% delle testate, 30% degli articoli). L’allenamento è lo stesso: cambia solo il **conto** finale.

Quando 1 e 2 non sono d'accordo: americanthinker.com

49 articoli, punteggio vero **22,5** (l1, inaffidabile), fold 4. Primi punteggi previsti:

$$52,\ 66,\ 44,\ 48,\ 33,\ 48,\ 38,\ 59,\ \ldots \qquad \textbf{media} = \mathbf{50{,}7}$$

Strategia 1

soglie sulle medie delle testate:
50,7 | 55,3 | 60,7 | 86,8

media 50,7, non sopra la prima soglia
$\Rightarrow$ **l1** **giusto**

$50{,}7 < 60 \Rightarrow$ inaffidabile **giusto**

Strategia 2

soglie sugli articoli:
46,4 | 57,0 | 64,8 | 83,2

l2 l4 l1 l2 l1 l2 l1 l3 ...

conteggi: l1 13, **l2 25**, l3 6, l4 5 $\Rightarrow$ **l2**

in l3–l5: 11 su 49 $\Rightarrow$ inaffidabile **giusto**

La media (50,7) è bassa **rispetto alle altre testate**; ma i singoli articoli stanno quasi tutti appena sopra la prima soglia degli articoli (46,4), e la maggioranza va in l2. Stesse previsioni, **livello diverso**.

Quanto spesso 1 e 2 non sono d'accordo (226 testate)

1 ↓ **2** →	l1	l2	l3	l4	l5
l1	**30**	6	0	0	0
l2	6	**35**	1	2	0
l3	0	**13**	**2**	**13**	0
l4	0	0	1	**72**	5
l5	0	0	0	8	**32**

- Livello diverso per **55 testate su 226**, quasi sempre di un solo livello (53).
- Affidabile diverso per 13.
- Livelli giusti: 95 (strategia 1) contro 96 (strategia 2).
- La differenza vera: con il voto **l3 quasi sparisce** (4 testate contro 28).

Perché: l3 è una fascia stretta (13%). Gli articoli di una testata di mezzo si spargono tra l2, l3 e l4, e il voto va a uno dei vicini più grandi. La media invece li compensa e cade in mezzo.

Esempi e conteggi: Mistral 24B regressore, tutti gli articoli, primo split del tentativo 18.

Strategia 3

solo il punteggio, in punti (tentativo 18)

Strategia 3 — perché un altro tentativo

- **Obiettivo**: prevedere il **punteggio esatto** (0–100), senza mai passare per le classi.
- **Dubbio sullo split**: con i fold per livello, il punteggio **dentro** un livello era lasciato al caso (le testate l1 di un fold avevano in media 12 punti, quelle di un altro 31).
- **Dubbio sul peso**: le testate hanno da 10 a 201 articoli; allenando per articolo, **chi scrive di più pesa di più**.
- **La regressione serve davvero?** Va confrontata con un classificatore sullo stesso terreno, il numero.

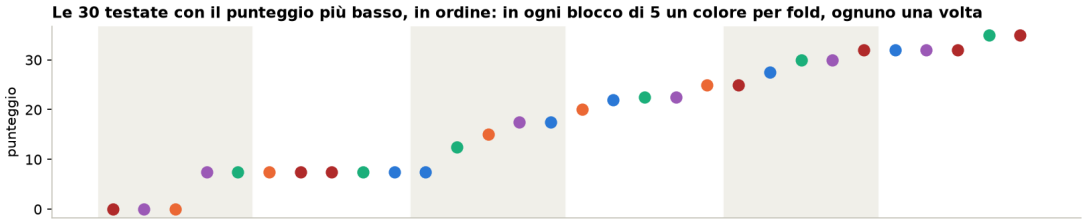
Lo split: per livello (strategie 1 e 2) o per voto (strategia 3)

Il bersaglio è sempre il voto 0–100. Cambia **come si dividono le testate nei fold**. Le 35 testate l1 hanno voti da **0 a 37**: come finiscono nei 5 fold?

voto medio delle testate l1 nel fold	fold 1	fold 2	fold 3	fold 4	fold 5
split **per livello** (strategie 1 e 2)	18	**31**	20	22	**12**
split **per voto** (strategia 3)	22	20	21	21	20

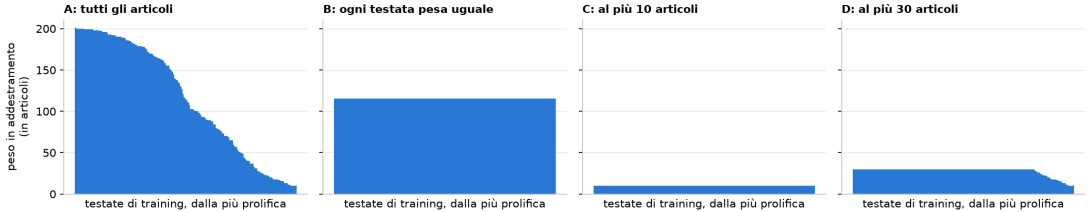
Per livello: ogni fold ha la stessa quota di testate l1, ma **dentro** le l1 un fold prende le più basse (media 12), un altro le più alte (media 31): il modello vede voti diversi a seconda del fold. **Per voto**: le testate si ordinano per voto e si distribuiscono a giro, così ogni fold ha lo stesso spettro (media 20–22 ovunque).

Strategia 3 — lo split per voto, come si costruisce



Le testate si ordinano per punteggio; a blocchi di 5 consecutive, ognuna va in un fold diverso (un colore per fold). Tre split con semi diversi. Ora ogni fold ha testate di tutti i punteggi: le l1 hanno in media 20–22 punti in **ogni** fold.

Strategia 3 — come si allena (2): cinque modi di pesare le testate



A tutti gli articoli (come prima); **B** ogni testata pesa uguale (peso $1/n$); **C** al più 10 articoli; **D** al più 30; **E** un vettore per testata (la media).

Cambia solo l'allenamento: **il test sono sempre tutti gli articoli** delle testate di test.

Strategia 3 — come si valuta (esempio: lifezette.com)

Stessi 31 articoli, punteggio vero **0**, media prevista **41,7**. Nessun livello: si resta sul numero.

$$\text{errore} = |\,\text{media previsto} - \text{vero}\,| = |41{,}7 - 0| = \textbf{42 punti}$$

- **MAE**: errore medio assoluto in punti, su tutte le testate. **RMSE**: pesa di più gli errori grandi.
- $\mathbf{R^2}$: quanta variabilità dei punteggi si spiega (0 = come dire sempre la media, 1 = perfetto).
- **Spearman**: l'ordine delle testate è giusto?

Riferimento: chi dice sempre la media del training (68,5) sbaglia in media di **22,6 punti**.
Qui l'errore è 42 punti: il modello **non arriva a 0**, si ferma a 42. Le classi erano giuste, il numero no.

Un esempio completo: due testate reali, le tre strategie

	lifezette.com	**americanprogress.org**
punteggio vero	0 (l1, inaffidabile)	100 (l5, affidabile)
articoli	31	70
punteggi previsti (alcuni)	22, 34, 42, 44, 39, 71	97, 102, 79, 104, 84, 81
media prevista	41,7	90,2
1. media → livello	l1 **giusto** — inaffidabile **giusto**	l5 **giusto** — affidabile **giusto**
2. livello → voto	l1 **giusto** (23 art. su 31)	l5 **giusto** (51 art. su 70)
3. punteggio in punti	errore **42**	errore **10**

Le strategie 1 e 2 **azzeccano la classe** in tutti e due i casi. La strategia 3 mostra l'errore vero: la testata da 0 prevista 42, quella da 100 prevista 90. Il modello **si schiaccia verso il centro**: non osa gli estremi.

Le normalizzazioni

che cosa si scala, dove, e che cosa no

Normalizzazioni in allenamento

Che cosa	Che cosa si fa	Fittato su
bersaglio, ridge	il voto **così com'è**, 0–100. Nessuna standardizzazione	—
bersaglio, ModernBERT e DeBERTa	voto / 100 (0–1) per la loss; l'uscita si rimoltiplica $\times 100$. Solo un cambio di scala: nessuna sigmoide, l'uscita è libera	—
input TF-IDF	tf sublineare $(1 + \log \text{tf}) \times$ idf, ogni vettore a norma 1	vocabolario e idf: **solo testi di training**
input embedding	Qwen3 8B: ultimo token, a norma 1. Mistral 24B: media dei token. Poi ogni dimensione a media 0 e varianza 1 (StandardScaler)	media e varianza: **solo righe di training**
pesi	strategia 3, condizione B: peso $1/n$ per articolo (ogni testata pesa uguale), riscalato a media 1	articoli di training
penalità	ridge: scelta con 3 fold interni sulle testate di training (errore in punti)	solo training

Niente di quello che si scala vede il test: **tutto si calcola sul training** del fold e poi si applica al test.

Normalizzazioni in valutazione: il punteggio previsto non si tocca

- **Nessun ritaglio a 0–100**: le previsioni restano come escono. Vanno da -14 a 133 (729 articoli su 25.524 sopra 100, 5 sotto 0); una testata ha media 110,6.
  Ritagliando: errore medio 15,33 $\rightarrow$ 15,35 punti. **Non cambia nulla**, quindi non si ritaglia.
- **Nessuna ricalibrazione** del numero (niente riscalatura, niente regressione isotonica). La testata $=$ **media semplice** dei suoi articoli.
- **Strategia 3** usa il numero grezzo: per questo si vede lo schiacciamento al centro (lifezette 42 invece di 0).
- **Classificatore** $\rightarrow$ **punteggio** (strategia 3): probabilità dei 5 livelli $\times$ voto medio di ogni livello nel training (circa 21, 50, 67, 85, 100).

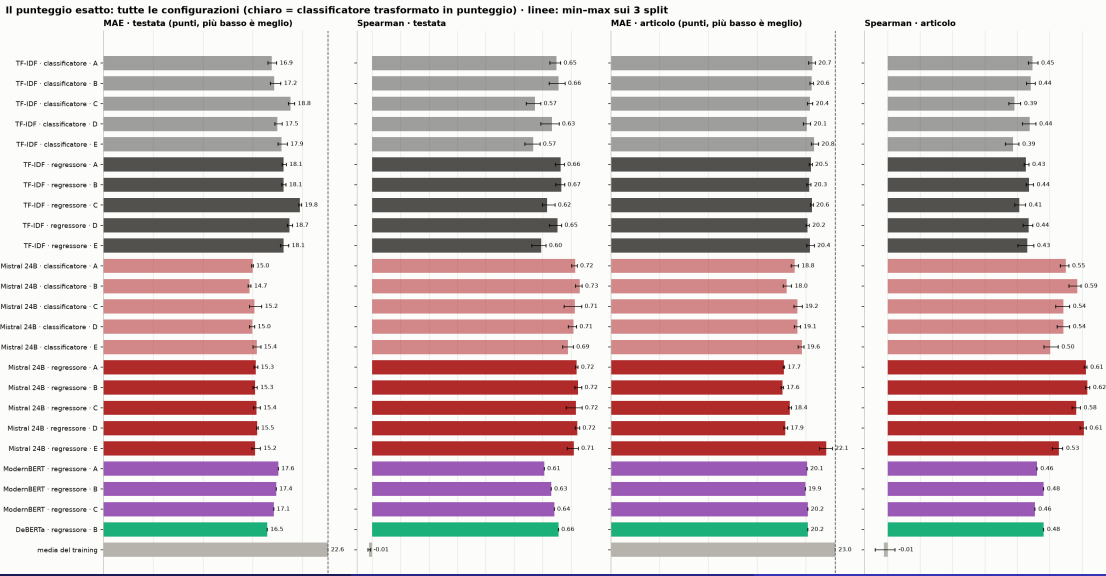
L'unica "normalizzazione" in valutazione è quella delle **quote** (strategie 1 e 2), spiegata nella sezione **Dal numero alla classe**.

Numeri: Mistral 24B regressore, tutti gli articoli, primo split del tentativo 18.

I risultati della strategia 3

il punteggio esatto (tentativo 18)

Il quadro: tutte le configurazioni

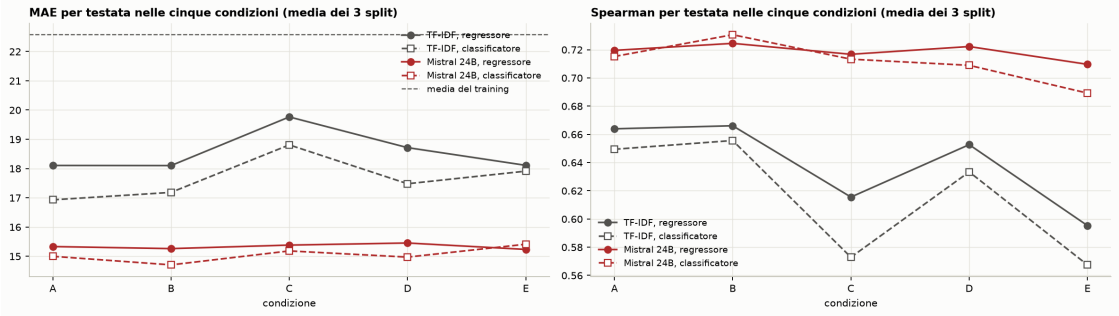


Le migliori configurazioni, per testata

Configurazione (split 1)	MAE (punti)	RMSE	R^2	Spearman
Mistral 24B congelato, classificatore	**14,7** [13,2; 16,3]	19,2	**0,50**	**0,73** [0,66; 0,78]
DeBERTa addestrato, regressore	16,5 [14,7; 18,5]	22,3	0,32	0,66 [0,58; 0,73]
TF-IDF, classificatore	16,8 [15,4; 18,5]	21,1	0,39	0,66 [0,58; 0,72]
ModernBERT addestrato, regressore	17,1 [15,6; 19,0]	21,7	0,36	0,64 [0,56; 0,72]
media del training	22,6 [20,7; 24,6]	27,1	0	0

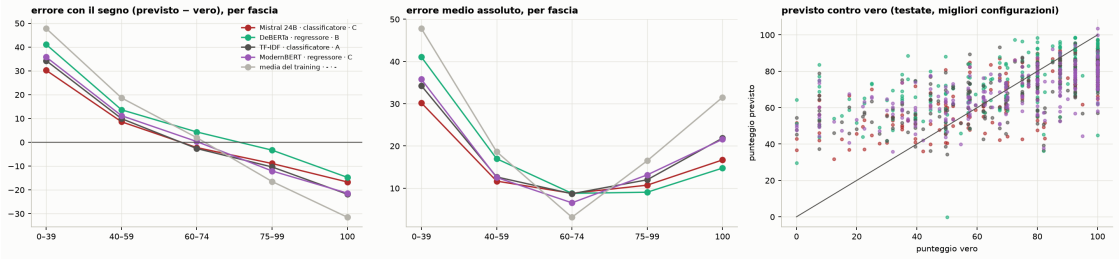
Il migliore sbaglia in media di **15 punti** contro i 22,6 di chi dice sempre la media: un terzo in meno; spiega metà della variabilità. L'ordine delle testate (Spearman 0,73) è buono come tra i due esperti umani (0,70).

Regressore o classificatore? Il peso delle testate?



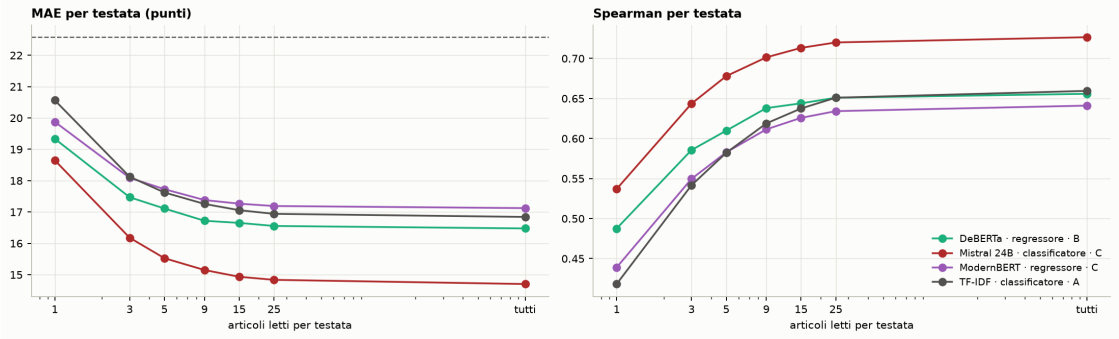
Il **classificatore** trasformato in punteggio fa come il regressore o meglio: **prevedere il numero non aggiunge nulla**. Pesare le testate (B) aiuta poco; tagliare gli articoli (C, D) peggiora il TF-IDF, che ha bisogno di testo.

Dove si sbaglia: le previsioni schiacciate verso il centro



Le testate da 0–39 sono **sovrastimate** di 30–40 punti, quelle da 100 **sottostimate** di 15–20; in mezzo (60–74) l'errore è di 7–9 punti. È il limite della regressione: nel dubbio, il modello va verso la media.

Il DNA in punti: quanti articoli servono



Con un solo articolo Mistral sbaglia di 18,6 punti; con 9 articoli di 15,1; con tutti di 14,7. Già **un articolo** dice molto, e dopo una decina si guadagna poco.

In breve

- Tre strategie, stesso allenamento: cambia come dai punteggi degli articoli si arriva al giudizio, e come si misura.
- Classi (strategie 1 e 2): i modelli grandi azzeccano l'affidabile sì/no e il livello, meglio del TF-IDF soprattutto sulle misure di accordo (kappa, Spearman).
- Punteggio esatto (strategia 3): il migliore sbaglia di **15 punti** (la media 22,6); **la regressione non aggiunge nulla** rispetto alla classificazione; il peso delle testate e gli split cambiano meno di un punto.
- Il limite è agli estremi: le previsioni si **schiacciano verso il centro**.
- Il quadro è coerente nelle tre strategie: i modelli grandi congelati sono già al **tetto** che le etichette permettono.