Criteri NewsGuard e regressione

Che cosa del punteggio si vede nel testo, e come valutiamo un modello che prevede il punteggio

John Bianchi

IMT Lucca & IIT-CNR Pisa

I criteri NewsGuard

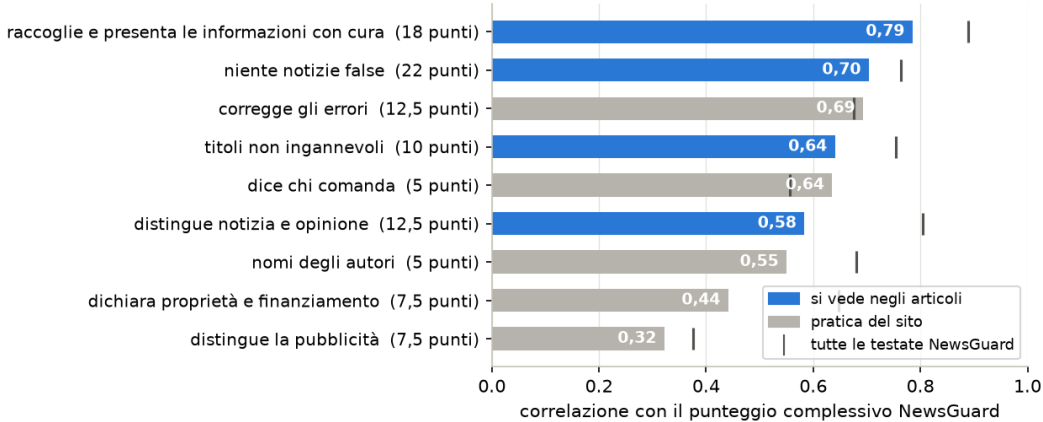
quali si vedono negli articoli, e quanto contano

Il punteggio NewsGuard è la somma di 9 criteri

Criterio	Punti	Dove si vede
Non pubblica notizie false	22	**negli articoli**
Raccoglie e presenta le informazioni con cura	18	**negli articoli**
Corregge gli errori	12,5	pratica del sito
Distingue notizia e opinione	12,5	**negli articoli**
Evita i titoli ingannevoli	10	**negli articoli**
Dichiara proprietà e finanziamento	7,5	pratica del sito
Distingue la pubblicità	7,5	pratica del sito
Dice chi comanda (e i conflitti di interesse)	5	pratica del sito
Mette i nomi degli autori	5	pratica del sito

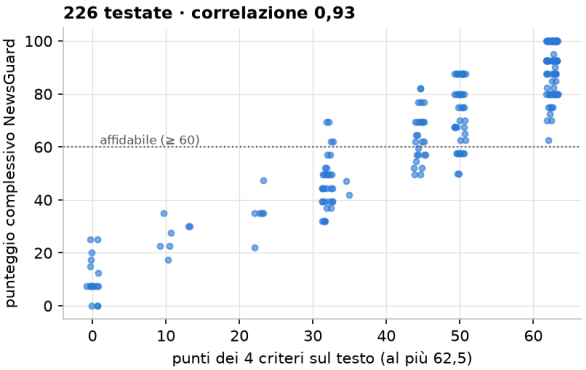
Ogni criterio è un sì o un no; il punteggio (0–100) è la somma dei punti dei sì. Affidabile = almeno 60. **4 criteri** riguardano il contenuto (**62,5 punti**); **5** le pratiche e la trasparenza del sito (37,5 punti), che negli articoli non si vedono.

Quanto ogni criterio va d'accordo con il punteggio complessivo



Barre: le nostre 226 testate (tentativo 16); trattini: tutte le 11.564 testate valutate da NewsGuard. Il criterio più legato al punteggio è **raccoglie e presenta le informazioni con cura** (0,79; 0,89 su tutte): è il più "testuale" e anche il più informativo.

I soli criteri sul testo spiegano quasi tutto il punteggio



- La somma dei punti dei 4 criteri sul testo ha correlazione **0,93** con il punteggio complessivo (0,95 su tutte le testate NewsGuard): ne spiega circa l'**87%**.
- Chi soddisfa tutti e 4 è **sempre affidabile** (94 testate su 94): anche perdendo tutti i punti del sito resta a 62,5.
- Chi ne manca anche uno solo è inaffidabile in 79 casi su 132.

Che cosa ne segue per l'addestramento

- **Il punteggio dei soli criteri sul testo** (0–62,5) è un bersaglio sensato: è quasi lo stesso del punteggio complessivo, ma toglie le pratiche del sito, che un modello che legge gli articoli non può vedere.
- **I criteri presi uno per uno** sono più difficili: "niente notizie false" e "titoli non ingannevoli" li soddisfa circa il 90% delle nostre testate, quindi restano solo 23–29 esempi negativi per imparare.
- I criteri sono legati tra loro: misurano in buona parte la stessa cosa, la qualità generale della testata.

La regressione

come si addestra e come si valuta, passo per passo

Che cosa impara un regressore

- **L'etichetta è un numero.** Ogni articolo eredita il punteggio NewsGuard della sua testata, da 0 a 100: tutti gli articoli di *lifezette.com* valgono 0, tutti quelli di *theweek.com* 100.
- **Il modello impara a prevedere quel numero** leggendo l'articolo, sbagliando il meno possibile in media: si minimizza l'**errore quadratico**, cioè la media di $(\text{previsto} - \text{vero})^2$ sugli articoli di training.
- **Testate mai viste.** Le 226 testate sono divise in 5 gruppi (fold). Si addestra su 4 e si prova sul quinto, a turno: ogni testata viene giudicata da un modello che non l'ha mai vista.
- Tre famiglie di modelli, **stessa etichetta e stessa valutazione**: cambia solo come il testo diventa numeri.

Il regressore a feature: TF-IDF + ridge

1. **Il testo diventa un elenco di numeri**: per ognuna delle 100.000 parole e coppie di parole più utili, quanto compare nell'articolo, pesato da quanto è rara (TF-IDF). Il vocabolario si impara **solo dagli articoli di training**.

2. **Ridge**: il punteggio previsto è una **somma pesata** di questi numeri, più una costante. Ogni parola ha un peso: per esempio "Kyiv" spinge in su e "Kiev" in giù, "Getty Images" in su, "Rumble" e "Gettr" in giù.

3. **Addestramento**: i pesi si scelgono in un colpo solo, con una formula, per minimizzare l'errore quadratico sugli articoli di training più una penalità sui pesi troppo grandi (alpha $= 1$), che evita di imparare a memoria.

4. **Test**: per ogni articolo delle testate di test si calcola la somma pesata, cioè un numero.

I transformer congelati: Qwen3-Embedding 8B e Mistral-Small 24B

1. **Il transformer legge l'articolo intero** (fino a 2.048 token) e lo trasforma in un **vettore** di 4.096 (Qwen3) o 5.120 (Mistral) numeri. **Il transformer non si addestra**: è usato così com'è ("congelato"), come un lettore.
2. Sopra i vettori c'è **la stessa ridge** del modello a feature: una somma pesata dei 4.096 o 5.120 numeri.
3. **Addestramento**: si imparano solo i pesi della ridge (qualche migliaio di numeri), sugli articoli di training. La penalità alpha è 1 nella versione base; nella versione migliore si sceglie con una validazione interna al training (per l'8B quasi sempre 1.000).
4. **Test**: il vettore di ogni articolo di test, moltiplicato per i pesi, dà il punteggio previsto.

Imparare pochi pesi è un pregio: il modello non ha abbastanza libertà per imparare a memoria le testate di training.

Il transformer addestrato: ModernBERT

1. **Modello**: ModernBERT-base (150 milioni di parametri) con **un solo neurone in uscita**: legge l'articolo (fino a 2.048 token) e dà un numero.
2. **Bersaglio**: il punteggio diviso 100 (da 0 a 1), per avere numeri piccoli durante l'addestramento.
3. **Addestramento**, a lotti di 32 articoli di training, in ordine casuale:
   - il modello prevede un numero per ogni articolo del lotto;
   - si misura l'errore quadratico rispetto al punteggio/100;
   - si correggono di poco **tutti** i 150 milioni di pesi nella direzione che riduce l'errore (AdamW, passo 3e-5).

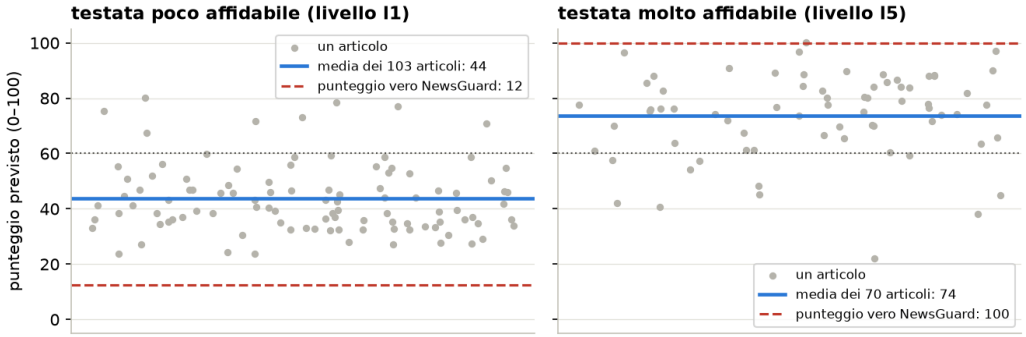
   Si ripete su tutti gli articoli di training per **5 volte** (5 epoche) e si tiene il modello dell'ultima.
4. **Test**: il modello legge ogni articolo delle testate di test; il numero, moltiplicato per 100, è il punteggio previsto.

Tre strade, lo stesso risultato: un numero per articolo

Modello	**Come il testo diventa numeri**	**Che cosa si addestra**	**Quanti pesi si imparano**
TF-IDF + ridge	conteggi di parole e coppie	la ridge	100.000
Qwen3 / Mistral + ridge	il vettore del transformer congelato	la ridge	4.096 / 5.120
ModernBERT	il transformer stesso	tutto il transformer	150 milioni

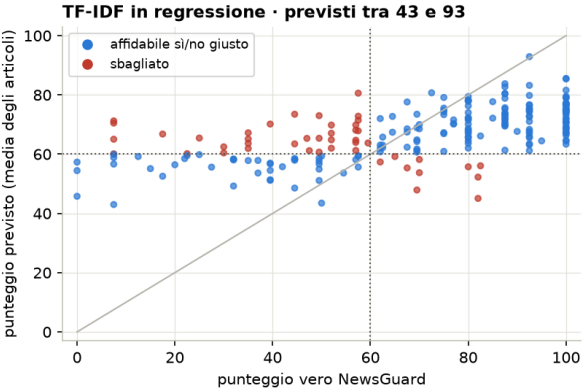
Da qui in poi la valutazione è **identica per tutti**: conta solo il numero che il modello dà a ogni articolo delle testate di test.

Valutazione, passo 1: dagli articoli alla testata



Ogni punto grigio è un articolo di una testata di test (ModernBERT regressore). Il singolo articolo sbaglia molto, ma la **media dei suoi articoli** (blu) è il punteggio previsto della testata. Le medie stanno strette: qui 44 e 74, contro 12 e 100 veri. La valutazione non guarda la distanza dal vero (44 contro 12), ma da che parte di 60 sta la testata (passo 2) e in che posizione sta rispetto alle altre (passo 3).

Valutazione, passo 2: affidabile sì o no

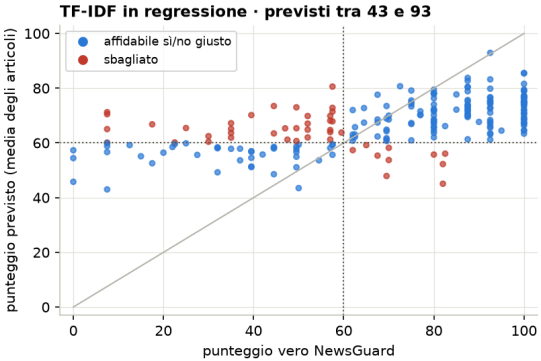


- Se la media prevista è **almeno 60**, la testata è affidabile. È giusto se anche il punteggio vero è almeno 60.
- **Previsto 70, vero 71**: tutti e due sopra 60, **giusto**. Anche previsto 61 e vero 98 è giusto.
- **Previsto 58, vero 61**: da una parte e dall'altra della soglia, **sbagliato**, anche se la distanza è piccola.
- Misura: **accuratezza** (quota di testate giuste).

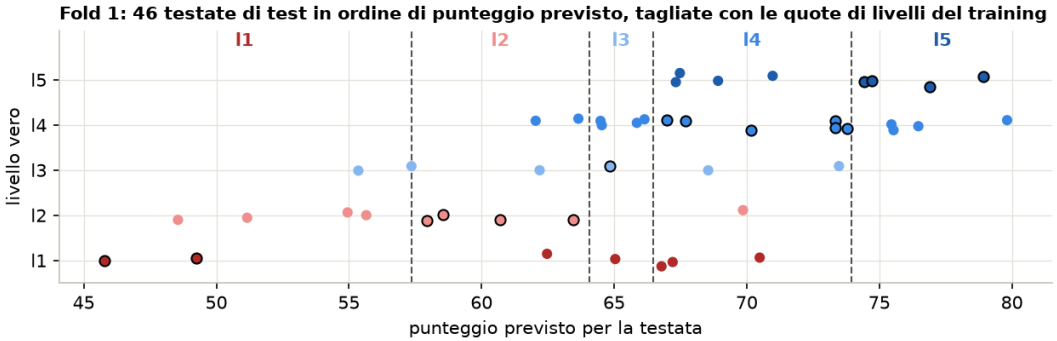
In rosso le testate sbagliate (TF-IDF in regressione).

Valutazione, passo 3: i 5 livelli, e perché non bastano le soglie di NewsGuard

- I livelli NewsGuard sono fasce di punteggio: l1 0–39, l2 40–59, l3 60–74, l4 75–99, l5 100.
- Ma i numeri previsti stanno **stretti intorno alla media**: il TF-IDF prevede solo tra 43 e 93, mentre i veri vanno da 0 a 100 (nel grafico i punti stanno su una fascia orizzontale). È tipico della regressione: nel dubbio, il modello si avvicina alla media.
- Con le fasce di NewsGuard nessuna testata finirebbe in **l1** (sotto 40) o in **l5** (100): conta di più l'**ordine** delle testate che il numero esatto.



Valutazione, passo 3: le quote del training



Le testate di test si mettono **in ordine di punteggio previsto** e si tagliano con le **stesse quote di livelli del training** (fold 1: 16% l1, 19% l2, 13% l3, 35% l4, 17% l5). Contorno nero = livello giusto. Poi si misurano l'**F1** sui 5 livelli (livello esatto) e la **tolerant** (± 1 livello).

Previsto 70, vero 71 (l3): nel fold 1 il 70 cade in **l4**: errore per l'F1, giusto per la tolerant e per affidabile sì/no.

Un esempio completo

Una testata di test con 5 articoli, punteggio vero NewsGuard **71** (livello l3, affidabile). Supponiamo che nel suo fold i tagli delle quote siano 57, 64, 67, 74.

	articolo 1	articolo 2	articolo 3	articolo 4	articolo 5
punteggio previsto	62	71	55	80	66

1. **Testata**: media $= (62 + 71 + 55 + 80 + 66)/5 = 66{,}8$.
2. **Affidabile sì/no**: $66{,}8 \geq 60 \Rightarrow$ affidabile; vero $71 \geq 60 \Rightarrow$ **giusto**.
3. **5 livelli**: 66,8 sta tra 64 e 67 $\Rightarrow$ **l3**; vero l3 $\Rightarrow$ **giusto** per l'F1 e per la tolerant.

La variante con il voto degli articoli (tentativo 17)

Invece della media, **ogni articolo diventa un livello** e la testata prende il **livello votato dalla maggioranza** dei suoi articoli (a parità vince il più basso).

- Il livello di ogni articolo: i punteggi previsti di tutti gli articoli di test del fold si ordinano e si tagliano con le quote di livelli degli **articoli** di training (come prima, ma articolo per articolo).
- Affidabile: sì se la **maggioranza** degli articoli ha un livello da l3 in su.
- Nell'esempio di prima, con i tagli 57, 64, 67, 74: livelli l2, l4, l1, l5, l3 $\Rightarrow$ nessuna maggioranza, vince il più basso (l1); affidabili 3 articoli su 5 $\Rightarrow$ affidabile.

Il voto permette di chiedersi **quanti articoli servono**: con 1 articolo solo, con 5, con 25 (la curva del "DNA").

In breve

Misura	**Come si ottiene dal numero previsto per la testata (media dei suoi articoli)**
Affidabile sì/no	giusto se previsto e vero stanno dalla stessa parte di 60
F1 sui 5 livelli	testate in ordine di numero previsto, tagliate con le quote di livelli del training; giusto se il livello coincide
Tolerant ± 1	come sopra, ma è giusto anche un livello vicino

- Tutti e tre i regressori (TF-IDF, transformer congelati, ModernBERT) si valutano allo stesso modo.
- La distanza esatta tra previsto e vero (70 contro 71) non entra mai nelle misure: conta da che parte di 60 sta la testata e in che posizione sta rispetto alle altre.
- I classificatori a 5 classi invece danno direttamente un livello a ogni articolo, e la testata prende il livello votato dalla maggioranza dei suoi articoli.