Stato dei lavori

Web Science 2027: cosa abbiamo fatto e cosa faremo

John Bianchi

IMT Lucca & IIT-CNR Pisa

Il percorso in breve

Fase	La domanda	Il risultato
Primo dataset (IrForGood, 439 testate)	perché il TF-IDF va come i transformer del paper?	le **reti** di siti gonfiano i numeri: 0,68 → 0,39 con i fold per gruppo
Versione 1 (nuovo dataset, 304 testate)	con pulizia, reti e fold per gruppo, chi vince?	**pari**: TF-IDF F1 0,38, transformer 0,35–0,37
Versione 2	più pulizia e più testate nel training aiutano i transformer?	**no**: niente cambia
Analisi del TF-IDF	come fa ad andare così bene?	legge il **genere** della testata (orientamento, tipo di sito, paese)
Versione 3	a parità di genere, il testo dice l'affidabilità?	sì, ma poco (0,6 contro 0,5), ed è **stile**; il TF-IDF resta davanti
Versione 4	il titolo letto con l'articolo e i criteri NewsGuard aiutano i transformer?	un po', ma il titolo aiuta **anche** il TF-IDF: il distacco resta
Oltre il testo	i link citati e la pagina HTML aiutano?	**no**: tutto arriva a F1 circa 0,34, binario circa 0,70

Sotto, ogni fase con i dettagli.

Il primo dataset

dai transformer del paper a un classificatore più semplice

Il punto di partenza: i transformer del paper

- Il dataset di IrForGood: **439 testate**, **19.476 articoli**; 5 fold, nel test solo testate **mai viste** in addestramento

Il punto di partenza: i transformer del paper

- Il dataset di IrForGood: **439 testate**, **19.476 articoli**; 5 fold, nel test solo testate **mai viste** in addestramento
- **Per articolo**: accuratezza intorno a **0,60** (da 0,58 di BERT a 0,61 di Mistral), F1 macro 0,52–0,55

Il punto di partenza: i transformer del paper

- Il dataset di IrForGood: **439 testate**, **19.476 articoli**; 5 fold, nel test solo testate **mai viste** in addestramento
- **Per articolo**: accuratezza intorno a **0,60** (da 0,58 di BERT a 0,61 di Mistral), F1 macro 0,52–0,55
- **Per testata** (voto di maggioranza dei suoi articoli): accuratezza fino a **0,69** (RoBERTa; Mistral 0,68), tolerant 1 fino a 0,88

Il punto di partenza: i transformer del paper

- Il dataset di IrForGood: **439 testate**, **19.476 articoli**; 5 fold, nel test solo testate **mai viste** in addestramento
- **Per articolo**: accuratezza intorno a **0,60** (da 0,58 di BERT a 0,61 di Mistral), F1 macro 0,52–0,55
- **Per testata** (voto di maggioranza dei suoi articoli): accuratezza fino a **0,69** (RoBERTa; Mistral 0,68), tolerant 1 fino a 0,88

Modelli da 110 milioni a 24 miliardi di parametri, tutti più o meno allo stesso livello.

Un classificatore a feature fa lo stesso, se non meglio

- **TF-IDF**: ogni articolo diventa l'elenco delle sue parole (e coppie di parole), pesate per quanto sono rare; sopra, una **regressione logistica**. Nessuna rete neurale: si addestra in un minuto

Un classificatore a feature fa lo stesso, se non meglio

- **TF-IDF**: ogni articolo diventa l'elenco delle sue parole (e coppie di parole), pesate per quanto sono rare; sopra, una **regressione logistica**. Nessuna rete neurale: si addestra in un minuto
- Sugli **stessi fold** del paper:

Un classificatore a feature fa lo stesso, se non meglio

- **TF-IDF**: ogni articolo diventa l'elenco delle sue parole (e coppie di parole), pesate per quanto sono rare; sopra, una **regressione logistica**. Nessuna rete neurale: si addestra in un minuto
- Sugli **stessi fold** del paper:

	per articolo		**per testata**	
	accuratezza	F1 macro	accuratezza	tolerant 1
migliore dei 4 transformer (misura per misura)	0,61	0,55	0,69	0,88
TF-IDF + regressione logistica	0,58	0,52	**0,68**	**0,88**

Un classificatore a feature fa lo stesso, se non meglio

- **TF-IDF**: ogni articolo diventa l'elenco delle sue parole (e coppie di parole), pesate per quanto sono rare; sopra, una **regressione logistica**. Nessuna rete neurale: si addestra in un minuto
- Sugli **stessi fold** del paper:

	per articolo		**per testata**	
	accuratezza	F1 macro	accuratezza	tolerant 1
migliore dei 4 transformer (misura per misura)	0,61	0,55	0,69	0,88
TF-IDF + regressione logistica	0,58	0,52	**0,68**	**0,88**

- Come fa un modello che **conta parole** ad andare come Mistral da 24 miliardi di parametri?

Un classificatore a feature fa lo stesso, se non meglio

- **TF-IDF**: ogni articolo diventa l'elenco delle sue parole (e coppie di parole), pesate per quanto sono rare; sopra, una **regressione logistica**. Nessuna rete neurale: si addestra in un minuto
- Sugli **stessi fold** del paper:

	per articolo		**per testata**	
	accuratezza	F1 macro	accuratezza	tolerant 1
migliore dei 4 transformer (misura per misura)	0,61	0,55	0,69	0,88
TF-IDF + regressione logistica	0,58	0,52	**0,68**	**0,88**

- Come fa un modello che **conta parole** ad andare come Mistral da 24 miliardi di parametri?
- Per capirlo ho guardato **dentro il dataset**

Quanto si somigliano due articoli? (1) I pezzetti di 5 parole

- Il testo si **normalizza**: minuscole, niente punteggiatura, i numeri diventano #

Quanto si somigliano due articoli? (1) I pezzetti di 5 parole

- Il testo si **normalizza**: minuscole, niente punteggiatura, i numeri diventano #
- Poi si spezza in tutti i **pezzetti di 5 parole consecutive**:

Quanto si somigliano due articoli? (1) I pezzetti di 5 parole

- Il testo si **normalizza**: minuscole, niente punteggiatura, i numeri diventano #
- Poi si spezza in tutti i **pezzetti di 5 parole consecutive**:

  `there was a single gas station in cities across phillips county`

  → `[there was a single gas]` `[was a single gas station]` `[a single gas station in]` ...

Quanto si somigliano due articoli? (1) I pezzetti di 5 parole

- Il testo si **normalizza**: minuscole, niente punteggiatura, i numeri diventano #
- Poi si spezza in tutti i **pezzetti di 5 parole consecutive**:

  `there was a single gas station in cities across phillips county`

  → `[there was a single gas]` `[was a single gas station]` `[a single gas station in]` ...

- **Somiglianza di Jaccard** tra due articoli A e B:

$$J(A,B) = \frac{\text{pezzetti in comune}}{\text{pezzetti di tutti e due, contati una volta}} = \frac{|A \cap B|}{|A \cup B|}$$

Quanto si somigliano due articoli? (1) I pezzetti di 5 parole

- Il testo si **normalizza**: minuscole, niente punteggiatura, i numeri diventano #
- Poi si spezza in tutti i **pezzetti di 5 parole consecutive**:

  `there was a single gas station in cities across phillips county`

  → `[there was a single gas]` `[was a single gas station]` `[a single gas station in]` ...

- **Somiglianza di Jaccard** tra due articoli A e B:

$$J(A,B) = \frac{\text{pezzetti in comune}}{\text{pezzetti di tutti e due, contati una volta}} = \frac{|A \cap B|}{|A \cup B|}$$

- $J = 0$: niente in comune; $J = 1$: lo stesso testo. $J \geq 0{,}5$: più di metà dei pezzetti in comune, gli articoli sono **quasi uguali** (non per forza identici)

Quanto si somigliano due articoli? (2) Un esempio vero

ncindiananews.com

Federal Energy Regulatory Commission (FERC) Commissioner Mark C. Christie | www.ferc.gov

There was a single gas station in cities across **White County** selling premium gas at the lowest price of **$3.81** per gallon . . .

savannahstandard.com

Federal Energy Regulatory Commission (FERC) Commissioner Mark C. Christie | www.ferc.gov

There were two gas stations in cities across **Bulloch County** selling premium gas at the lowest price of **$3.79** per gallon . . .

- Due siti diversi, lo **stesso articolo-modello**: cambiano solo la contea e i numeri

Quanto si somigliano due articoli? (2) Un esempio vero

ncindianananews.com

Federal Energy Regulatory Commission (FERC) Commissioner Mark C. Christie | www.ferc.gov

There was a single gas station in cities across **White County** selling premium gas at the lowest price of **$3.81** per gallon . . .

savannahstandard.com

Federal Energy Regulatory Commission (FERC) Commissioner Mark C. Christie | www.ferc.gov

There were two gas stations in cities across **Bulloch County** selling premium gas at the lowest price of **$3.79** per gallon . . .

- Due siti diversi, lo **stesso articolo-modello**: cambiano solo la contea e i numeri
- Sono articoli **generati in serie** da una rete di siti locali: il testo è quasi tutto uguale (J tra 0,6 e 1)

Quanto si somigliano due articoli? (2) Un esempio vero

ncindiananews.com

Federal Energy Regulatory Commission (FERC) Commissioner Mark C. Christie | www.ferc.gov

There was a single gas station in cities across **White County** selling premium gas at the lowest price of **$3.81** per gallon . . .

savannahstandard.com

Federal Energy Regulatory Commission (FERC) Commissioner Mark C. Christie | www.ferc.gov

There were two gas stations in cities across **Bulloch County** selling premium gas at the lowest price of **$3.79** per gallon . . .

- Due siti diversi, lo **stesso articolo-modello**: cambiano solo la contea e i numeri
- Sono articoli **generati in serie** da una rete di siti locali: il testo è quasi tutto uguale (J tra 0,6 e 1)
- Un classificatore che ha visto uno di questi nel training riconosce subito l'altro nel test

Quanto si somigliano due articoli? (3) Confrontarli tutti

- 19.476 articoli sono quasi **190 milioni di coppie**: calcolare J esatto su tutte, testo contro testo, è **impossibile** in tempi ragionevoli

Quanto si somigliano due articoli? (3) Confrontarli tutti

- 19.476 articoli sono quasi **190 milioni di coppie**: calcolare J esatto su tutte, testo contro testo, è **impossibile** in tempi ragionevoli
- **MinHash** e **LSH** servono a questo: calcolano la somiglianza di Jaccard in modo **fattibile**, accettando una piccola **approssimazione**

Quanto si somigliano due articoli? (3) Confrontarli tutti

- 19.476 articoli sono quasi **190 milioni di coppie**: calcolare J esatto su tutte, testo contro testo, è **impossibile** in tempi ragionevoli
- **MinHash** e **LSH** servono a questo: calcolano la somiglianza di Jaccard in modo **fattibile**, accettando una piccola **approssimazione**

  MinHash riassume ogni articolo in un'**impronta** corta da cui si stima J; LSH propone solo le coppie che **probabilmente** si somigliano

Quanto si somigliano due articoli? (3) Confrontarli tutti

- 19.476 articoli sono quasi **190 milioni di coppie**: calcolare J esatto su tutte, testo contro testo, è **impossibile** in tempi ragionevoli
- **MinHash** e **LSH** servono a questo: calcolano la somiglianza di Jaccard in modo **fattibile**, accettando una piccola **approssimazione**

  MinHash riassume ogni articolo in un'**impronta** corta da cui si stima J; LSH propone solo le coppie che **probabilmente** si somigliano

  È la tecnica standard per togliere i duplicati dai dati di addestramento dei modelli linguistici.

Quanto si somigliano due articoli? (3) Confrontarli tutti

- 19.476 articoli sono quasi **190 milioni di coppie**: calcolare J esatto su tutte, testo contro testo, è **impossibile** in tempi ragionevoli
- **MinHash** e **LSH** servono a questo: calcolano la somiglianza di Jaccard in modo **fattibile**, accettando una piccola **approssimazione**

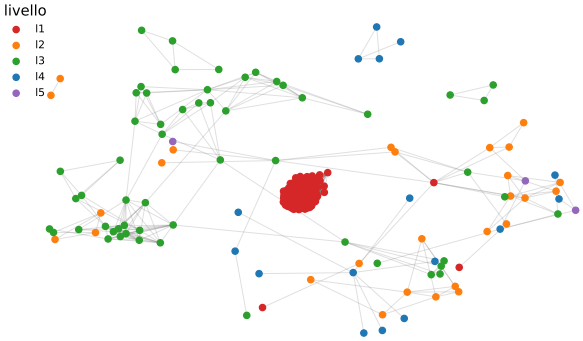
  MinHash riassume ogni articolo in un'**impronta** corta da cui si stima J; LSH propone solo le coppie che **probabilmente** si somigliano

  È la tecnica standard per togliere i duplicati dai dati di addestramento dei modelli linguistici.
- Risultato: **1.557** articoli hanno una copia **identica** su un'altra testata; **4.740** (il **24%**) una copia **quasi uguale** ($J \geq 0{,}5$)

Dagli articoli alle reti di testate

- Due testate sono **collegate** se hanno **almeno 2 articoli** quasi uguali in comune (una sola copia può essere un pezzo ripreso)

Reti di testate identificate dal testo condiviso



236 testate in rete · 203 indipendenti (senza legami, non mostrate)

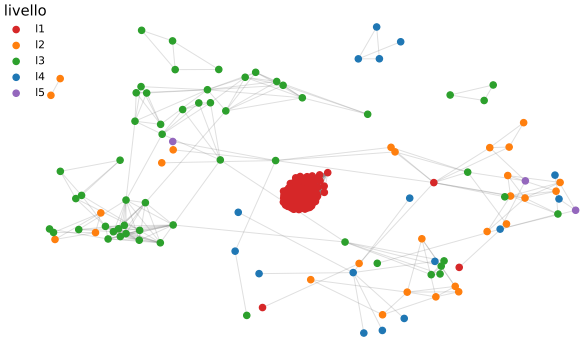
Un punto = una testata; una linea = almeno 2 articoli quasi uguali.

La distanza nel disegno non misura nulla.

Dagli articoli alle reti di testate

- Due testate sono **collegate** se hanno **almeno 2 articoli** quasi uguali in comune (una sola copia può essere un pezzo ripreso)
- Una **rete** = testate collegate anche **a catena**: A–B e B–C ⇒ A, B, C nella stessa rete

Reti di testate identificate dal testo condiviso



236 testate in rete · 203 indipendenti (senza legami, non mostrate)

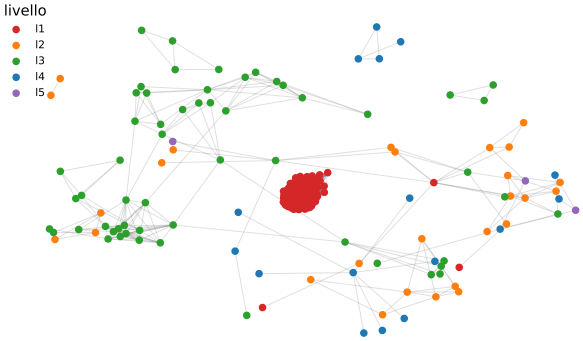
Un punto = una testata; una linea = almeno 2 articoli quasi uguali.

La distanza nel disegno non misura nulla.

Dagli articoli alle reti di testate

- Due testate sono **collegate** se hanno **almeno 2 articoli** quasi uguali in comune (una sola copia può essere un pezzo ripreso)
- Una **rete** = testate collegate anche **a catena**: A–B e B–C ⇒ A, B, C nella stessa rete
- **10 reti**, con dentro **236 testate su 439**; la più grande ha **131 siti**

Reti di testate identificate dal testo condiviso



236 testate in rete · 203 indipendenti (senza legami, non mostrate)

Un punto = una testata; una linea = almeno 2 articoli quasi uguali.

La distanza nel disegno non misura nulla.

Chi c'è dietro una rete: l'owner di NewsGuard

- Per ogni sito NewsGuard indica anche il **proprietario** (campo **Owner**): per esempio Metric Media LLC, Boone Newspapers, Salem Media Group

Chi c'è dietro una rete: l'owner di NewsGuard

- Per ogni sito NewsGuard indica anche il **proprietario** (campo **Owner**): per esempio Metric Media LLC, Boone Newspapers, Salem Media Group
- Le reti le ho trovate **solo dal testo**; l'owner l'ho usato **dopo**, per controllarle:

Chi c'è dietro una rete: l'owner di NewsGuard

- Per ogni sito NewsGuard indica anche il **proprietario** (campo **Owner**): per esempio Metric Media LLC, Boone Newspapers, Salem Media Group
- Le reti le ho trovate **solo dal testo**; l'owner l'ho usato **dopo**, per controllarle:

  precisione 0,93: le testate di una stessa rete hanno quasi sempre lo stesso proprietario

Chi c'è dietro una rete: l'owner di NewsGuard

- Per ogni sito NewsGuard indica anche il **proprietario** (campo **Owner**): per esempio Metric Media LLC, Boone Newspapers, Salem Media Group
- Le reti le ho trovate **solo dal testo**; l'owner l'ho usato **dopo**, per controllarle:

  precisione 0,93: le testate di una stessa rete hanno quasi sempre lo stesso proprietario

  recall 0,87: le testate di uno stesso proprietario finiscono quasi sempre nella stessa rete

Chi c'è dietro una rete: l'owner di NewsGuard

- Per ogni sito NewsGuard indica anche il **proprietario** (campo **Owner**): per esempio Metric Media LLC, Boone Newspapers, Salem Media Group
- Le reti le ho trovate **solo dal testo**; l'owner l'ho usato **dopo**, per controllarle:

  precisione 0,93: le testate di una stessa rete hanno quasi sempre lo stesso proprietario

  recall 0,87: le testate di uno stesso proprietario finiscono quasi sempre nella stessa rete
- La rete da 131 siti: **tutti di Metric Media LLC**, tutti con lo **stesso punteggio** NewsGuard (32): siti di "notizie locali" che pubblicano articoli-modello come quello di prima

Chi c'è dietro una rete: l'owner di NewsGuard

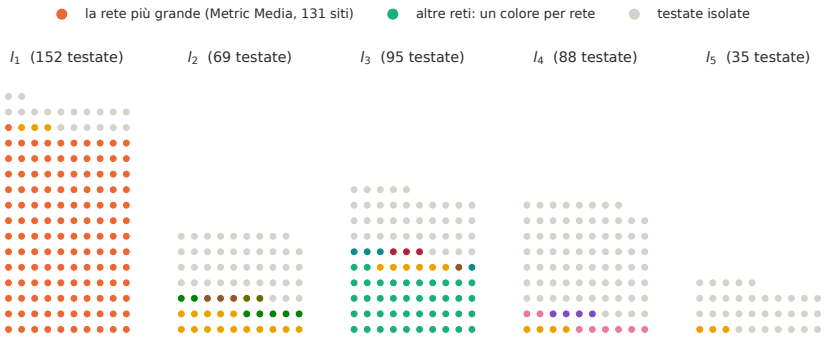
- Per ogni sito NewsGuard indica anche il **proprietario** (campo **Owner**): per esempio Metric Media LLC, Boone Newspapers, Salem Media Group
- Le reti le ho trovate **solo dal testo**; l'owner l'ho usato **dopo**, per controllarle:

  precisione 0,93: le testate di una stessa rete hanno quasi sempre lo stesso proprietario

  recall 0,87: le testate di uno stesso proprietario finiscono quasi sempre nella stessa rete
- La rete da 131 siti: **tutti di Metric Media LLC**, tutti con lo **stesso punteggio** NewsGuard (32): siti di "notizie locali" che pubblicano articoli-modello come quello di prima

  Quindi: stessa rete = testo quasi uguale (non sempre identico) e, quasi sempre, stesso proprietario.

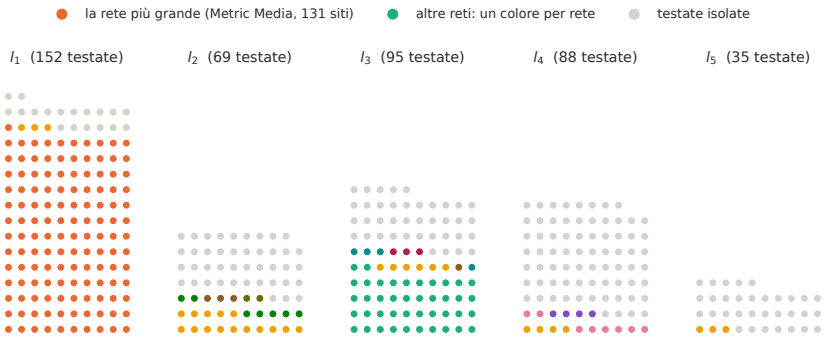
Le reti, livello per livello



Un pallino = una testata; un colore = una rete.

- l_1: **131 testate su 152** sono la stessa rete di Metric Media; solo **20** sono isolate

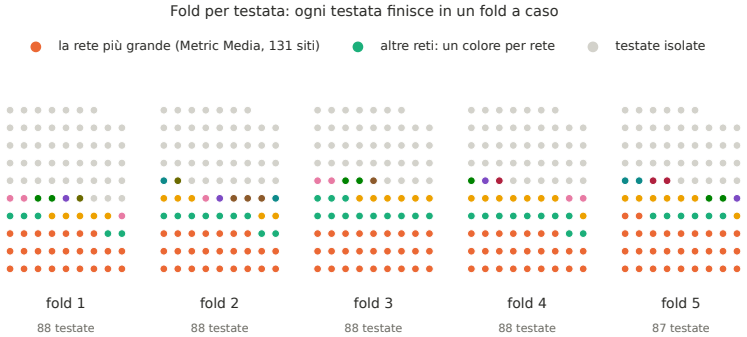
Le reti, livello per livello



Un pallino = una testata; un colore = una rete.

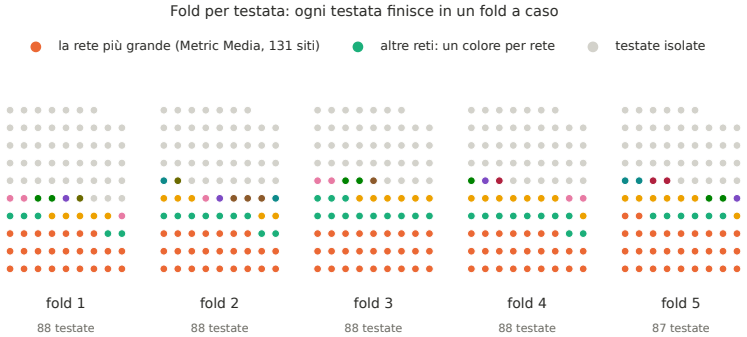
- l_1: **131 testate su 152** sono la stessa rete di Metric Media; solo **20** sono isolate
- l_3: molte catene di giornali locali; l_4 e l_5: quasi tutte isolate

Fold per testata: le sorelle stanno da tutte e due le parti



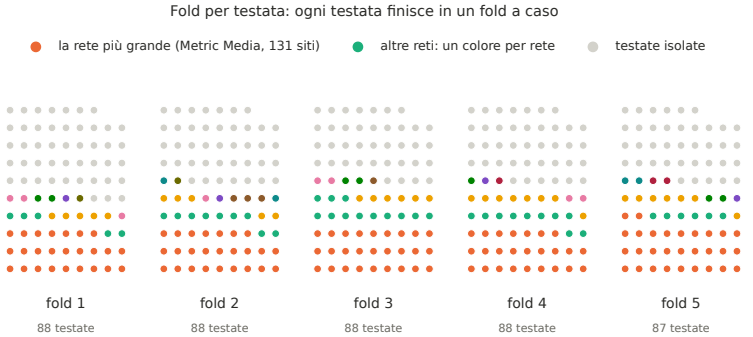
- Come nel paper: ogni testata va in un fold **a caso**, e i 131 siti di Metric Media si spargono in **tutti e 5** i fold (25–29 per fold)

Fold per testata: le sorelle stanno da tutte e due le parti



- Come nel paper: ogni testata va in un fold **a caso**, e i 131 siti di Metric Media si spargono in **tutti e 5** i fold (25–29 per fold)
- Lo stesso per le altre reti: ogni colore compare in più fold, in media **3,5**

Fold per testata: le sorelle stanno da tutte e due le parti



- Come nel paper: ogni testata va in un fold **a caso**, e i 131 siti di Metric Media si spargono in **tutti e 5** i fold (25–29 per fold)
- Lo stesso per le altre reti: ogni colore compare in più fold, in media **3,5**
- Quando il fold 1 è il test, gli altri **106 siti** di Metric Media sono nel training: il modello ha già visto gli stessi articoli-modello

Ripulire il primo dataset: cosa ho tolto e come

	Regola	Con quale indice	Quanto
1	lo stesso articolo su più testate: se ne tiene **una copia**	$J \geq 0{,}9$ (stesso testo con poche parole cambiate)	-1.835 articoli
2	copie rimaste tra **reti diverse**: si tolgono tutte e due	$J \geq 0{,}5$	-46 articoli
3	**paragrafi identici** in almeno 2 testate (didascalie, appelli, avvisi): tolti **dal testo**, l'articolo resta	uguaglianza del paragrafo normalizzato	5,5% delle parole
4	articoli rimasti con **100 parole o meno**	—	-1.325 articoli

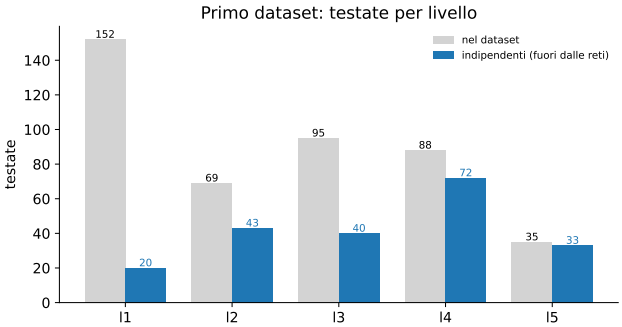
- Verifica: coppie di articoli quasi uguali tra reti diverse, rifacendo il MinHash sul testo pulito: da **1,45 milioni** a **0**

Ripulire il primo dataset: cosa ho tolto e come

	Regola	Con quale indice	Quanto
1	lo stesso articolo su più testate: se ne tiene **una copia**	$J \geq 0{,}9$ (stesso testo con poche parole cambiate)	-1.835 articoli
2	copie rimaste tra **reti diverse**: si tolgono tutte e due	$J \geq 0{,}5$	-46 articoli
3	**paragrafi identici** in almeno 2 testate (didascalie, appelli, avvisi): tolti **dal testo**, l'articolo resta	uguaglianza del paragrafo normalizzato	5,5% delle parole
4	articoli rimasti con **100 parole o meno**	—	-1.325 articoli

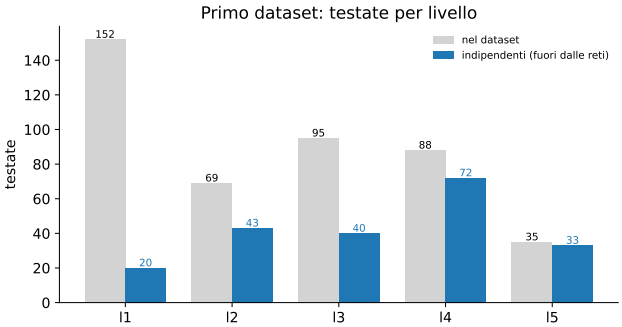
- Verifica: coppie di articoli quasi uguali tra reti diverse, rifacendo il MinHash sul testo pulito: da **1,45 milioni** a **0**
- Le regole **non guardano le etichette**: si applicano uguali a tutti i livelli

Pulito e valutato per gruppo, il primo dataset non basta



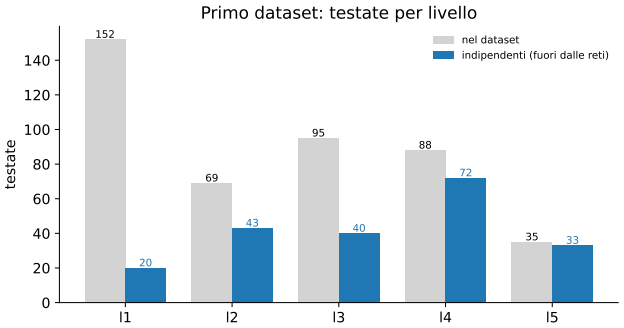
- TF-IDF sul dataset pulito, fold per gruppo: **0,40** di accuratezza, **0,33** di F1 macro

Pulito e valutato per gruppo, il primo dataset non basta



- TF-IDF sul dataset pulito, fold per gruppo: **0,40** di accuratezza, **0,33** di F1 macro
- Testate **indipendenti** (fuori dalle reti): solo **20** l_1; il resto di l_1 è una rete sola, che conta come **un** esempio

Pulito e valutato per gruppo, il primo dataset non basta



- TF-IDF sul dataset pulito, fold per gruppo: **0,40** di accuratezza, **0,33** di F1 macro
- Testate **indipendenti** (fuori dalle reti): solo **20** l_1; il resto di l_1 è una rete sola, che conta come **un** esempio
- Troppo poche testate indipendenti per livello: per andare avanti serve un **dataset nuovo**, più grande, pulito con lo stesso rigore

Il nuovo dataset

come l'ho costruito, passo per passo

Lo scraping: due giri nella stessa settimana

- **13 ottobre**, primo giro: le testate NewsGuard in inglese, con un punteggio, il cui argomento è **esattamente** “Political news or commentary”: **1.921**

Lo scraping: due giri nella stessa settimana

- **13 ottobre**, primo giro: le testate NewsGuard in inglese, con un punteggio, il cui argomento è **esattamente** "Political news or commentary": **1.921**
- Non bastano: molti siti **bloccano** lo scraper, molti articoli **sporchi** si tolgono, e il tetto di **5 testate per gruppo** (rete o stesso owner, passo 3) ne scarta tante. Serve il dataset **più grande possibile**

Lo scraping: due giri nella stessa settimana

- **13 ottobre**, primo giro: le testate NewsGuard in inglese, con un punteggio, il cui argomento è **esattamente** "Political news or commentary": **1.921**
- Non bastano: molti siti **bloccano** lo scraper, molti articoli **sporchi** si tolgono, e il tetto di **5 testate per gruppo** (rete o stesso owner, passo 3) ne scarta tante. Serve il dataset **più grande possibile**
- **18 ottobre**, secondo giro, **stesso scraper** e stessi parametri: le testate il cui argomento **contiene** "Political news or commentary" insieme ad altri: **+1.207**. Nessuna testata in comune: gli articoli dei due giri si **sommano**

Lo scraping: due giri nella stessa settimana

- **13 ottobre**, primo giro: le testate NewsGuard in inglese, con un punteggio, il cui argomento è **esattamente** "Political news or commentary": **1.921**
- Non bastano: molti siti **bloccano** lo scraper, molti articoli **sporchi** si tolgono, e il tetto di **5 testate per gruppo** (rete o stesso owner, passo 3) ne scarta tante. Serve il dataset **più grande possibile**
- **18 ottobre**, secondo giro, **stesso scraper** e stessi parametri: le testate il cui argomento **contiene** "Political news or commentary" insieme ad altri: **+1.207**. Nessuna testata in comune: gli articoli dei due giri si **sommano**
- In tutto **3.128** testate tentate, **1.528** raggiunte (bloccata quasi tutta una rete di 1.076 siti l_1, più 176 altre)

Lo scraping: due giri nella stessa settimana

- **13 ottobre**, primo giro: le testate NewsGuard in inglese, con un punteggio, il cui argomento è **esattamente** "Political news or commentary": **1.921**
- Non bastano: molti siti **bloccano** lo scraper, molti articoli **sporchi** si tolgono, e il tetto di **5 testate per gruppo** (rete o stesso owner, passo 3) ne scarta tante. Serve il dataset **più grande possibile**
- **18 ottobre**, secondo giro, **stesso scraper** e stessi parametri: le testate il cui argomento **contiene** "Political news or commentary" insieme ad altri: **+1.207**. Nessuna testata in comune: gli articoli dei due giri si **sommano**
- In tutto **3.128** testate tentate, **1.528** raggiunte (bloccata quasi tutta una rete di 1.076 siti I_1, più 176 altre)
- In **ordine casuale** e **senza guardare il livello**; fino a 200 articoli recenti per testata, con l'**HTML grezzo**

Lo scraping: due giri nella stessa settimana

- **13 ottobre**, primo giro: le testate NewsGuard in inglese, con un punteggio, il cui argomento è **esattamente** "Political news or commentary": **1.921**
- Non bastano: molti siti **bloccano** lo scraper, molti articoli **sporchi** si tolgono, e il tetto di **5 testate per gruppo** (rete o stesso owner, passo 3) ne scarta tante. Serve il dataset **più grande possibile**
- **18 ottobre**, secondo giro, **stesso scraper** e stessi parametri: le testate il cui argomento **contiene** "Political news or commentary" insieme ad altri: **+1.207**. Nessuna testata in comune: gli articoli dei due giri si **sommano**
- In tutto **3.128** testate tentate, **1.528** raggiunte (bloccata quasi tutta una rete di 1.076 siti l_1, più 176 altre)
- In **ordine casuale** e **senza guardare il livello**; fino a 200 articoli recenti per testata, con l'**HTML grezzo**
- I due giri sono a **5 giorni** di distanza, con lo stesso strumento: un dataset **coerente**

Prima di questo dataset: altri tentativi

- Prima di arrivare qui ho fatto **altri tentativi**, provando **più strategie di pulizia**

Prima di questo dataset: altri tentativi

- Prima di arrivare qui ho fatto **altri tentativi**, provando **più strategie di pulizia**
- Ogni volta il feature **batteva ancora** i transformer, e in parte per lo **sporco** rimasto nel dataset: testo del sito ripetuto in tutti gli articoli, pagine uguali per tutta una testata, reti di siti non separate

Prima di questo dataset: altri tentativi

- Prima di arrivare qui ho fatto **altri tentativi**, provando **più strategie di pulizia**
- Ogni volta il feature **batteva ancora** i transformer, e in parte per lo **sporco** rimasto nel dataset: testo del sito ripetuto in tutti gli articoli, pagine uguali per tutta una testata, reti di siti non separate
- Allora ho reso la pulizia **più aggressiva**: non più solo le copie tra testate, come nel primo dataset, ma anche il testo che appartiene al sito e non all'articolo, e le reti trovate anche dall'HTML

Prima di questo dataset: altri tentativi

- Prima di arrivare qui ho fatto **altri tentativi**, provando **più strategie di pulizia**
- Ogni volta il feature **batteva ancora** i transformer, e in parte per lo **sporco** rimasto nel dataset: testo del sito ripetuto in tutti gli articoli, pagine uguali per tutta una testata, reti di siti non separate
- Allora ho reso la pulizia **più aggressiva**: non più solo le copie tra testate, come nel primo dataset, ma anche il testo che appartiene al sito e non all'articolo, e le reti trovate anche dall'HTML
- Con un limite: si toglie solo quello che **non è dell'articolo**; citazioni e pezzi ripresi restano

Come ho costruito il dataset, in breve

1. **Pulire il testo degli articoli**: togliere quello che non è dell'articolo ma **del sito** (appelli, firme, titolo ripetuto, data). Un modello lo userebbe per riconoscere il sito, non l'affidabilità

Come ho costruito il dataset, in breve

1. **Pulire il testo degli articoli**: togliere quello che non è dell'articolo ma **del sito** (appelli, firme, titolo ripetuto, data). Un modello lo userebbe per riconoscere il sito, non l'affidabilità
2. **Trovare le testate parenti** (le reti), **senza guardare NewsGuard**: dalle tracce che lasciano, come testi uguali, stessi codici nell'HTML, stessi autori

Come ho costruito il dataset, in breve

1. **Pulire il testo degli articoli**: togliere quello che non è dell'articolo ma **del sito** (appelli, firme, titolo ripetuto, data). Un modello lo userebbe per riconoscere il sito, non l'affidabilità
2. **Trovare le testate parenti** (le reti), **senza guardare NewsGuard**: dalle tracce che lasciano, come testi uguali, stessi codici nell'HTML, stessi autori
3. **Fare i gruppi e i fold**: le testate parenti vanno tutte dalla stessa parte, e nessun gruppo può essere troppo grande

Come ho costruito il dataset, in breve

1. **Pulire il testo degli articoli**: togliere quello che non è dell'articolo ma **del sito** (appelli, firme, titolo ripetuto, data). Un modello lo userebbe per riconoscere il sito, non l'affidabilità
2. **Trovare le testate parenti** (le reti), **senza guardare NewsGuard**: dalle tracce che lasciano, come testi uguali, stessi codici nell'HTML, stessi autori
3. **Fare i gruppi e i fold**: le testate parenti vanno tutte dalla stessa parte, e nessun gruppo può essere troppo grande

Ogni passo è una **regola scritta nel codice**, applicata uguale a tutte le testate: **nessun testo tolto a mano** o da un LLM. Rieseguendo i notebook (random state fissati) dai dati dello scraping esce sempre lo stesso dataset.

1. Pulire gli articoli

- Si toglie dal testo quello che **appartiene al sito**, non all'articolo:

1. Pulire gli articoli

- Si toglie dal testo quello che **appartiene al sito**, non all'articolo:

  le frasi che si **ripetono** in molti articoli della stessa testata: appelli, firme, "iscriviti alla newsletter". Per esempio truthout.org ha lo stesso appello per le donazioni in **200 articoli su 200**

1. Pulire gli articoli

- Si toglie dal testo quello che **appartiene al sito**, non all'articolo:

  le frasi che si **ripetono** in molti articoli della stessa testata: appelli, firme, "iscriviti alla newsletter". Per esempio truthout.org ha lo stesso appello per le donazioni in **200 articoli su 200**

  la **cornice della pagina**: il titolo e la data che alcuni siti mettono all'inizio del testo

1. Pulire gli articoli

- Si toglie dal testo quello che **appartiene al sito**, non all'articolo:

  le frasi che si **ripetono** in molti articoli della stessa testata: appelli, firme, "iscriviti alla newsletter". Per esempio truthout.org ha lo stesso appello per le donazioni in **200 articoli su 200**

  la **cornice della pagina**: il titolo e la data che alcuni siti mettono all'inizio del testo

- Si tolgono gli articoli **vecchi** (prima del 2025), i **doppioni** dello stesso pezzo e quelli rimasti **troppo corti**

1. Pulire gli articoli

- Si toglie dal testo quello che **appartiene al sito**, non all'articolo:

  le frasi che si **ripetono** in molti articoli della stessa testata: appelli, firme, "iscriviti alla newsletter". Per esempio truthout.org ha lo stesso appello per le donazioni in **200 articoli su 200**

  la **cornice della pagina**: il titolo e la data che alcuni siti mettono all'inizio del testo
- Si tolgono gli articoli **vecchi** (prima del 2025), i **doppioni** dello stesso pezzo e quelli rimasti **troppo corti**
- Sono **impronte del sito**: lasciate lì, un modello riconoscerebbe la testata invece di leggere l'articolo

1. Pulire gli articoli

- Si toglie dal testo quello che **appartiene al sito**, non all'articolo:

  le frasi che si **ripetono** in molti articoli della stessa testata: appelli, firme, "iscriviti alla newsletter". Per esempio truthout.org ha lo stesso appello per le donazioni in **200 articoli su 200**

  la **cornice della pagina**: il titolo e la data che alcuni siti mettono all'inizio del testo
- Si tolgono gli articoli **vecchi** (prima del 2025), i **doppioni** dello stesso pezzo e quelli rimasti **troppo corti**
- Sono **impronte del sito**: lasciate lì, un modello riconoscerebbe la testata invece di leggere l'articolo
- Tutto con **regole automatiche** nel codice, nessuna modifica a mano. Risultato: via il 5% delle parole; da 101.887 a **76.091** articoli

1. Pulire gli articoli

- Si toglie dal testo quello che **appartiene al sito**, non all'articolo:

  le frasi che si **ripetono** in molti articoli della stessa testata: appelli, firme, "iscriviti alla newsletter". Per esempio truthout.org ha lo stesso appello per le donazioni in **200 articoli su 200**

  la **cornice della pagina**: il titolo e la data che alcuni siti mettono all'inizio del testo
- Si tolgono gli articoli **vecchi** (prima del 2025), i **doppioni** dello stesso pezzo e quelli rimasti **troppo corti**
- Sono **impronte del sito**: lasciate lì, un modello riconoscerebbe la testata invece di leggere l'articolo
- Tutto con **regole automatiche** nel codice, nessuna modifica a mano. Risultato: via il 5% delle parole; da 101.887 a **76.091** articoli

  Con lo stesso MinHash del primo dataset si trovano anche le copie tra testate: servono al passo 2.

2. Trovare le testate parenti: le tracce

Traccia	Quando due testate sono parenti	Esempio
copie	hanno articoli quasi uguali in comune (MinHash, $J \geq 0{,}5$): almeno 2, e almeno il 10% degli articoli della più piccola	catene di giornali locali
codici di account	nell'HTML di ogni pagina c'è il **numero di conto** di AdSense, Google Analytics, pixel di Facebook… (es. `ca-pub-1234...`): due siti con **lo stesso numero** usano lo stesso conto. Conta solo se è in almeno metà delle pagine	FiveZero: 18 siti, un solo conto AdSense
privacy policy	il link "Privacy policy" porta alla **stessa pagina** su un altro dominio, cioè lo stesso titolare. Non contano Google, WordPress, Substack e simili, uguali per tutti i clienti	8 siti, tutti verso la privacy policy di `salemmedia.com`
dominio	sottodomini dello stesso sito, o la homepage che **reindirizza** allo stesso dominio	le edizioni di HuffPost
autori	la firma dell'articolo: gli **stessi nomi di persona** (non "Staff" o le agenzie) firmano almeno il 10% degli articoli della più piccola	la rete da 426 siti

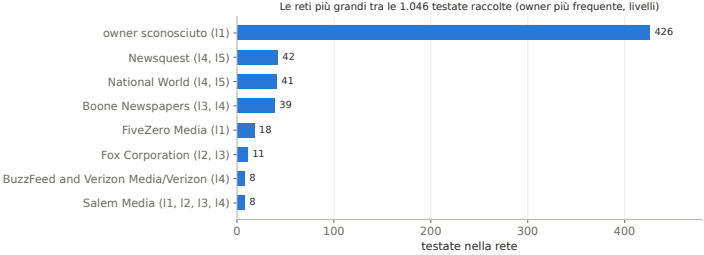
- Basta **una** traccia per collegare due testate; una **rete** = testate collegate, anche a catena (come nel primo dataset)

2. Trovare le testate parenti: le tracce

Traccia	Quando due testate sono parenti	Esempio
copie	hanno articoli quasi uguali in comune (MinHash, $J \geq 0{,}5$): almeno 2, e almeno il 10% degli articoli della più piccola	catene di giornali locali
codici di account	nell'HTML di ogni pagina c'è il **numero di conto** di AdSense, Google Analytics, pixel di Facebook… (es. `ca-pub-1234...`): due siti con **lo stesso numero** usano lo stesso conto. Conta solo se è in almeno metà delle pagine	FiveZero: 18 siti, un solo conto AdSense
privacy policy	il link "Privacy policy" porta alla **stessa pagina** su un altro dominio, cioè lo stesso titolare. Non contano Google, WordPress, Substack e simili, uguali per tutti i clienti	8 siti, tutti verso la privacy policy di `salemmedia.com`
dominio	sottodomini dello stesso sito, o la homepage che **reindirizza** allo stesso dominio	le edizioni di HuffPost
autori	la firma dell'articolo: gli **stessi nomi di persona** (non "Staff" o le agenzie) firmano almeno il 10% degli articoli della più piccola	la rete da 426 siti

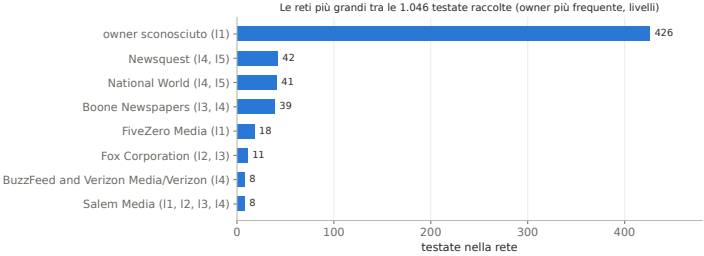
- Basta **una** traccia per collegare due testate; una **rete** = testate collegate, anche a catena (come nel primo dataset)
- Le soglie del 10% evitano di collegare due testate per un pezzo d'agenzia o un collaboratore in comune

2. Le reti trovate



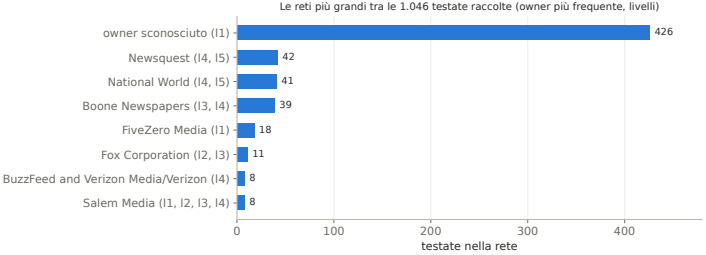
- **725 testate su 1.046** stanno in una rete con altre

2. Le reti trovate



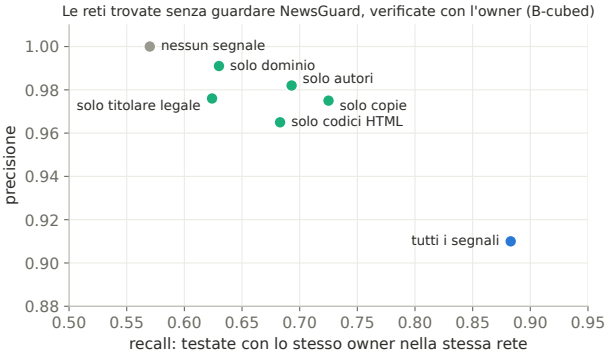
- **725 testate su 1.046** stanno in una rete con altre
- La più grande ha **426 siti**, legati soprattutto dagli **stessi autori**. Per NewsGuard l'owner è **sconosciuto**

2. Le reti trovate



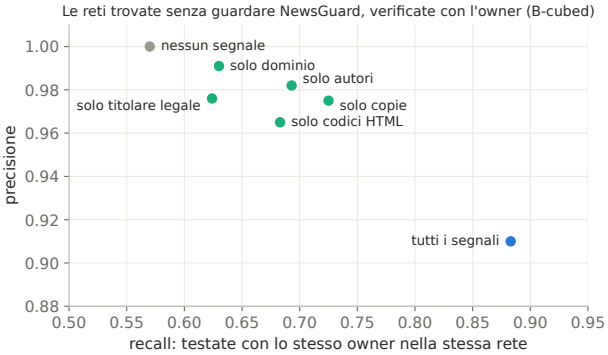
- **725 testate su 1.046** stanno in una rete con altre
- La più grande ha **426 siti**, legati soprattutto dagli **stessi autori**. Per NewsGuard l'owner è **sconosciuto**
- Controllo a parte: tutti hanno lo **stesso punteggio** (5) e nel campo "Parent Domain" di NewsGuard **425 su 426** dicono `naturalnews.com`. È la rete di Natural News

2. Il controllo con l'owner di NewsGuard



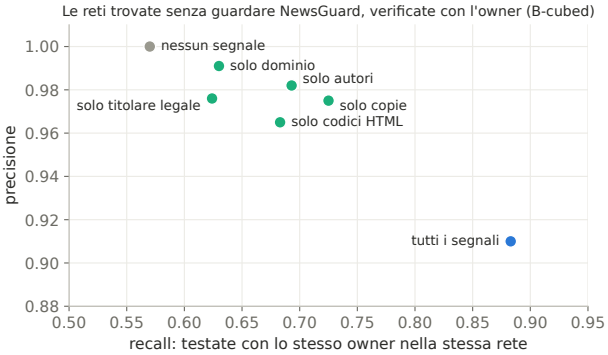
- Le reti le ho trovate **senza** l'owner: ora lo uso per vedere se sono giuste

2. Il controllo con l'owner di NewsGuard



- Le reti le ho trovate **senza** l'owner: ora lo uso per vedere se sono giuste
- Per ogni testata con un owner noto:

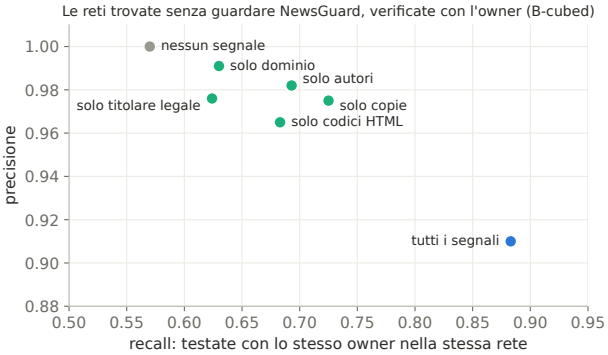
2. Il controllo con l'owner di NewsGuard



- Le reti le ho trovate **senza** l'owner: ora lo uso per vedere se sono giuste
- Per ogni testata con un owner noto:

  precisione: le testate della sua rete hanno il suo stesso owner?

2. Il controllo con l'owner di NewsGuard

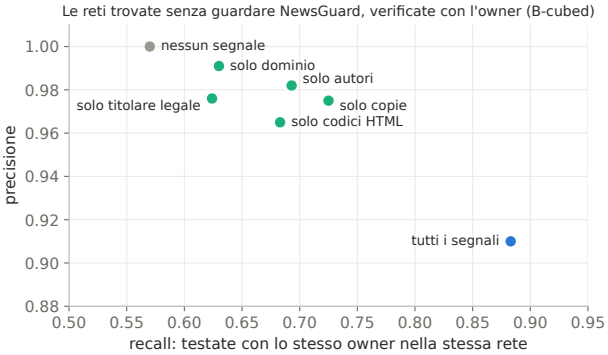


- Le reti le ho trovate **senza** l'owner: ora lo uso per vedere se sono giuste
- Per ogni testata con un owner noto:

  precisione: le testate della sua rete hanno il suo stesso owner?

  recall: le testate del suo owner sono nella sua rete?

2. Il controllo con l'owner di NewsGuard



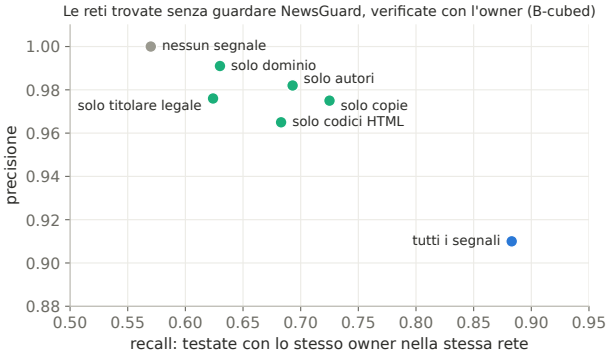
- Le reti le ho trovate **senza** l'owner: ora lo uso per vedere se sono giuste
- Per ogni testata con un owner noto:

  precisione: le testate della sua rete hanno il suo stesso owner?

  recall: le testate del suo owner sono nella sua rete?

  e poi la media su tutte le testate

2. Il controllo con l'owner di NewsGuard



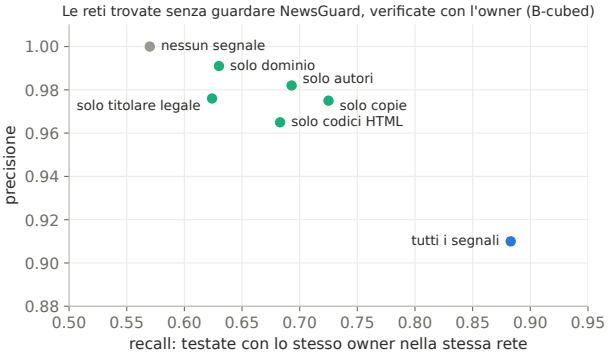
- Le reti le ho trovate **senza** l'owner: ora lo uso per vedere se sono giuste
- Per ogni testata con un owner noto:

  precisione: le testate della sua rete hanno il suo stesso owner?

  recall: le testate del suo owner sono nella sua rete?

  e poi la media su tutte le testate
- Ogni traccia da sola è precisa ma trova poco; **tutte insieme**: precisione **0,91**, recall **0,88**

2. Il controllo con l'owner di NewsGuard



- Le reti le ho trovate **senza** l'owner: ora lo uso per vedere se sono giuste
- Per ogni testata con un owner noto:

  precisione: le testate della sua rete hanno il suo stesso owner?

  recall: le testate del suo owner sono nella sua rete?

  e poi la media su tutte le testate
- Ogni traccia da sola è precisa ma trova poco; **tutte insieme**: precisione **0,91**, recall **0,88**
- Le testate con owner sconosciuto non entrano nel conto: si controllano a parte, come Natural News

3. I gruppi

- **Gruppo** = rete trovata **oppure** stesso owner NewsGuard: basta uno dei due. L'owner aggiunge le parentele che non lasciano tracce

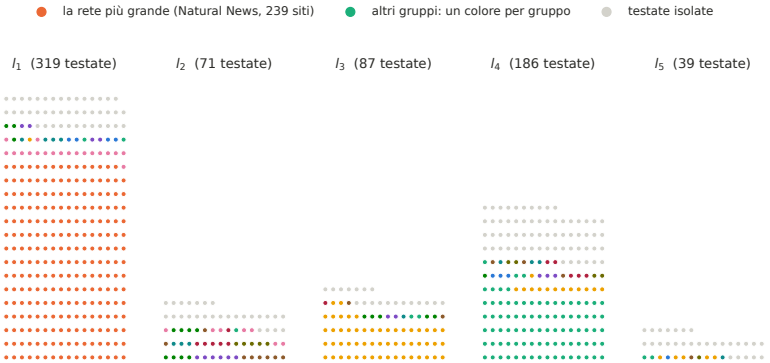
3. I gruppi

- **Gruppo** = rete trovata **oppure** stesso owner NewsGuard: basta uno dei due. L'owner aggiunge le parentele che non lasciano tracce
- Lo stesso articolo in **due gruppi diversi**: si tiene la copia più vecchia (-461 articoli). Così lo stesso testo non sta mai nel training e nel test

3. I gruppi

- **Gruppo** = rete trovata **oppure** stesso owner NewsGuard: basta uno dei due. L'owner aggiunge le parentele che non lasciano tracce
- Lo stesso articolo in **due gruppi diversi**: si tiene la copia più vecchia (-461 articoli). Così lo stesso testo non sta mai nel training e nel test
- Testate con almeno **20 articoli** (per il voto di maggioranza): **702**

3. I gruppi, livello per livello

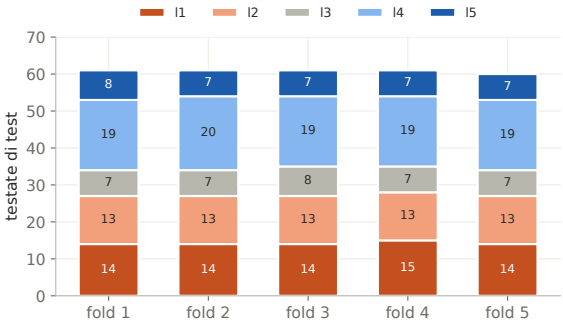


Le 702 testate con almeno 20 articoli. Un pallino = una testata; un colore = un gruppo.

- Natural News fa **239 delle 319** testate l_1: lo stesso problema di Metric Media nel primo dataset

3. Il tetto e i fold

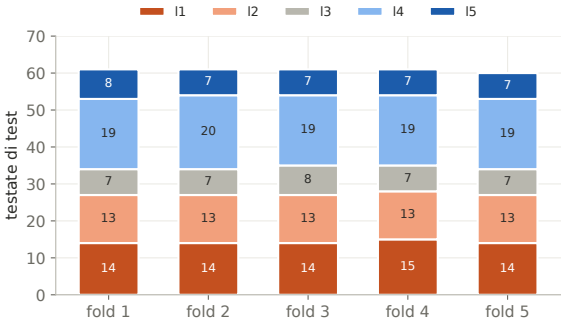
- Al massimo **5 testate per gruppo**, scelte **a caso**: Natural News conta come gli altri gruppi, non riempie più l_1



Testate per livello in ogni fold di test

3. Il tetto e i fold

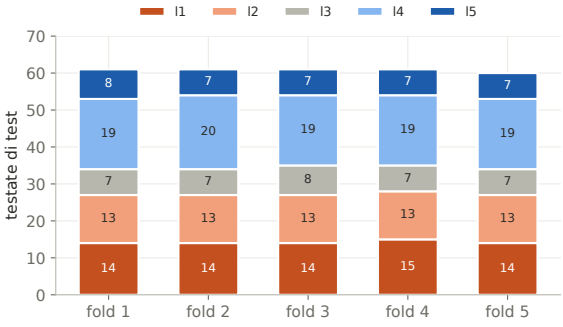
- Al massimo **5 testate per gruppo**, scelte **a caso**: Natural News conta come gli altri gruppi, non riempie più l_1
- Restano **304 testate** in **220 gruppi**



Testate per livello in ogni fold di test

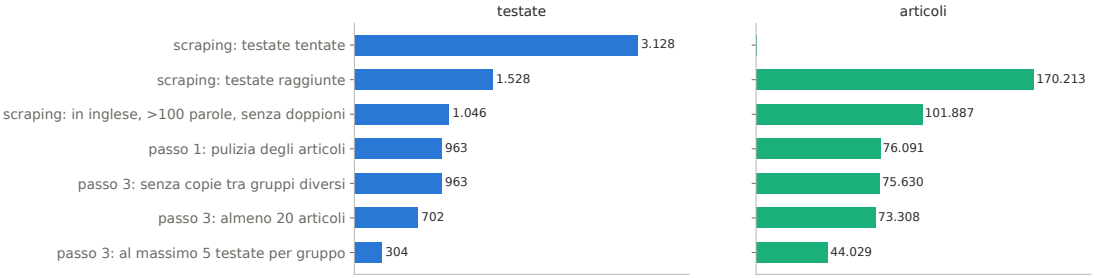
3. Il tetto e i fold

- Al massimo **5 testate per gruppo**, scelte **a caso**: Natural News conta come gli altri gruppi, non riempie più l_1
- Restano **304 testate** in **220 gruppi**
- **5 fold per gruppo**: ogni gruppo sta in un fold solo, e ogni fold ha lo stesso numero di testate per livello



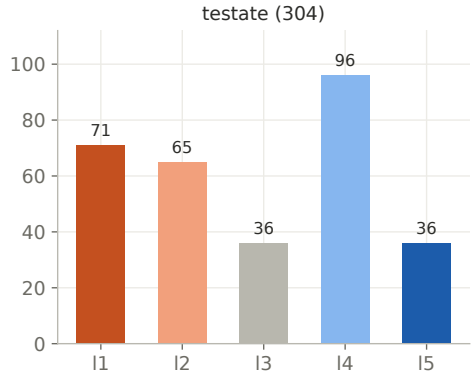
Testate per livello in ogni fold di test

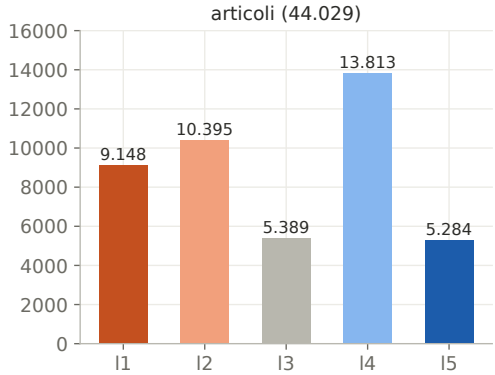
Quanto resta a ogni passo



Il passo 2 non toglie articoli: serve a fare i gruppi.

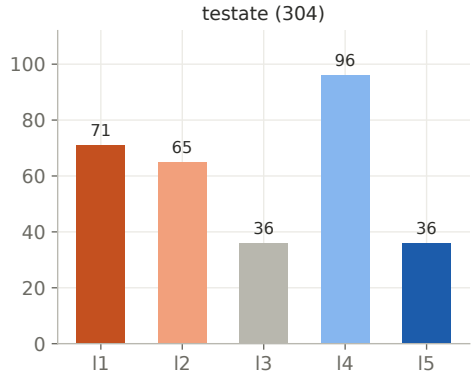
Il dataset finale

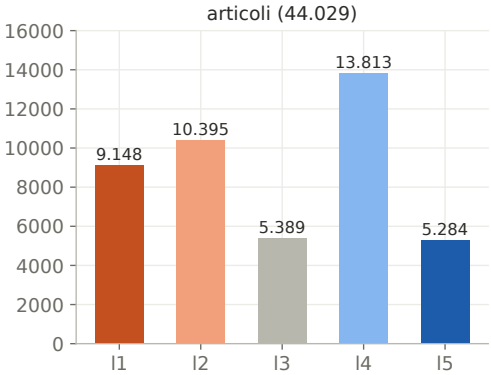




- **304 testate**, **44.029 articoli**, **220 gruppi** indipendenti

Il dataset finale



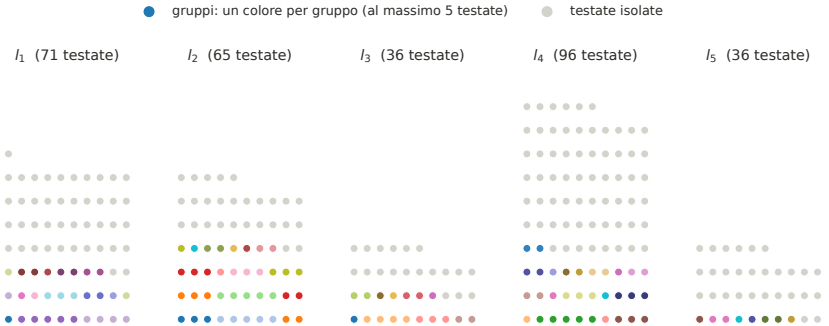


- **304 testate**, **44.029 articoli**, **220 gruppi** indipendenti
- Più del doppio delle testate I_1 indipendenti rispetto al primo dataset (56 gruppi contro 20)

La sporcizia è andata?

gli stessi grafici, sul dataset nuovo

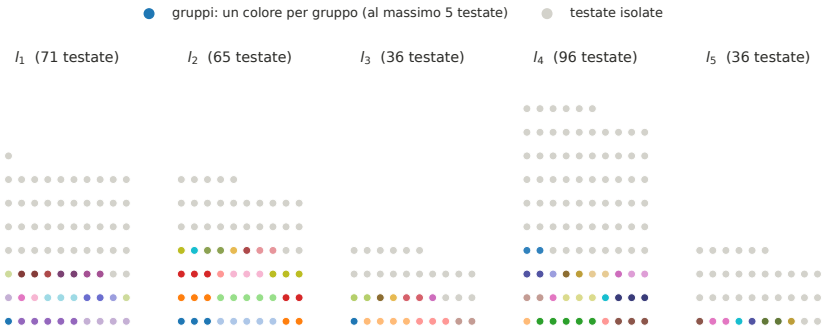
Le reti livello per livello, ora



Un pallino = una testata; un colore = un gruppo.

- Prima: **131 testate l_1 su 152** erano una rete sola. Ora nessun gruppo ha più di **5 testate**

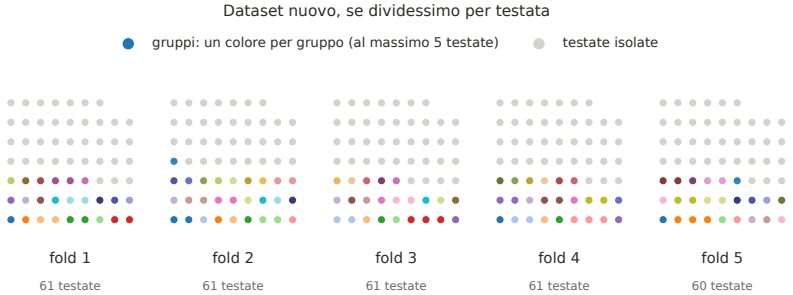
Le reti livello per livello, ora



Un pallino = una testata; un colore = un gruppo.

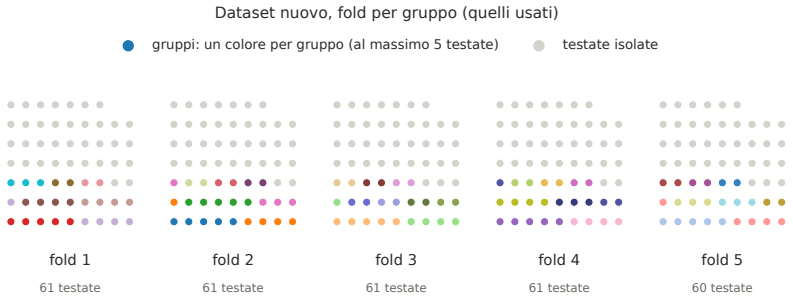
- Prima: **131 testate l_1 su 152** erano una rete sola. Ora nessun gruppo ha più di **5 testate**
- **181 testate isolate** e **123** in 39 gruppi piccoli; in l_1, 43 isolate su 71

I fold, ora



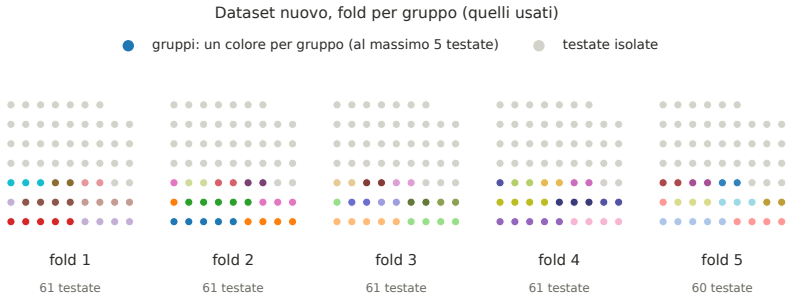
- Se dividessimo **per testata**, un gruppo starebbe in media in **2,4 fold**: le sorelle di nuovo da tutte e due le parti

I fold, ora



- Se dividessimo **per testata**, un gruppo starebbe in media in **2,4 fold**: le sorelle di nuovo da tutte e due le parti
- Con i fold **per gruppo** (quelli usati) ogni colore sta in **un solo fold**

I fold, ora



- Se dividessimo **per testata**, un gruppo starebbe in media in **2,4 fold**: le sorelle di nuovo da tutte e due le parti
- Con i fold **per gruppo** (quelli usati) ogni colore sta in **un solo fold**
- È una divisione **in più**, non al posto di quella per testata: gli articoli di una testata stanno **sempre** in un solo fold, e in più le testate di un gruppo stanno insieme

Versione 1: i risultati

TF-IDF contro transformer, sul dataset nuovo (18 ottobre)

I modelli a confronto, in breve

- **TF-IDF + regressione logistica**: parole e coppie di parole pesate per rarità; il parametro di regolarizzazione scelto in una validazione sul solo training (**riferimento**, fissato prima)

I modelli a confronto, in breve

- **TF-IDF + regressione logistica**: parole e coppie di parole pesate per rarità; il parametro di regolarizzazione scelto in una validazione sul solo training (**riferimento**, fissato prima)
- **ModernBERT** (base 150M e large 400M parametri), **fine-tuning**: impara a dire il livello di ogni articolo; la testata è la media delle probabilità dei suoi articoli

I modelli a confronto, in breve

- **TF-IDF + regressione logistica**: parole e coppie di parole pesate per rarità; il parametro di regolarizzazione scelto in una validazione sul solo training (**riferimento**, fissato prima)
- **ModernBERT** (base 150M e large 400M parametri), **fine-tuning**: impara a dire il livello di ogni articolo; la testata è la media delle probabilità dei suoi articoli

  La ricetta, uguale per tutti e nata dai tentativi precedenti: primi 1024 token, 2 epoche fisse (l'early stopping su poche testate sceglieva quasi a caso), 20 articoli a caso per testata a ogni epoca, pesi di classe

I modelli a confronto, in breve

- **TF-IDF + regressione logistica**: parole e coppie di parole pesate per rarità; il parametro di regolarizzazione scelto in una validazione sul solo training (**riferimento**, fissato prima)
- **ModernBERT** (base 150M e large 400M parametri), **fine-tuning**: impara a dire il livello di ogni articolo; la testata è la media delle probabilità dei suoi articoli

  La ricetta, uguale per tutti e nata dai tentativi precedenti: primi 1024 token, 2 epoche fisse (l'early stopping su poche testate sceglieva quasi a caso), 20 articoli a caso per testata a ogni epoca, pesi di classe

  Ogni ModernBERT con **3 seed**: tra un seed e l'altro la F1 cambia di 3–5 punti, quindi il risultato principale è l'**ensemble** (media delle probabilità dei 3 modelli)

I modelli a confronto, in breve

- **TF-IDF + regressione logistica**: parole e coppie di parole pesate per rarità; il parametro di regolarizzazione scelto in una validazione sul solo training (**riferimento**, fissato prima)
- **ModernBERT** (base 150M e large 400M parametri), **fine-tuning**: impara a dire il livello di ogni articolo; la testata è la media delle probabilità dei suoi articoli

  La ricetta, uguale per tutti e nata dai tentativi precedenti: primi 1024 token, 2 epoche fisse (l'early stopping su poche testate sceglieva quasi a caso), 20 articoli a caso per testata a ogni epoca, pesi di classe

  Ogni ModernBERT con **3 seed**: tra un seed e l'altro la F1 cambia di 3–5 punti, quindi il risultato principale è l'**ensemble** (media delle probabilità dei 3 modelli)
- **Embedding congelati** (e5-large, bge-large): nessun addestramento, un vettore per articolo, media per testata e la stessa regressione logistica del TF-IDF

I risultati della Versione 1

Modello	F1 macro	accuratezza	tolerant 1	binario
TF-IDF (riferimento)	**0,380**	0,424	0,770	0,740
TF-IDF, parametri di default	0,368	**0,454**	**0,803**	**0,776**
ModernBERT-base, ensemble di 3 seed	0,366	0,398	0,780	0,717
ModernBERT-large, ensemble di 3 seed	0,348	0,405	0,799	0,743
e5-large / bge-large congelati	0,331 / 0,325	0,391 / 0,382	0,786 / 0,789	0,727 / 0,730
classe di maggioranza / a caso	0,096 / 0,214	0,316 / 0,243	0,553 / 0,533	0,553 / 0,510

Per testata, 304 testate, fold per gruppo. Tolerant 1: un errore di un livello vale un punto.

- Tutti **ben sopra** maggioranza e caso: dal solo testo un segnale c'è

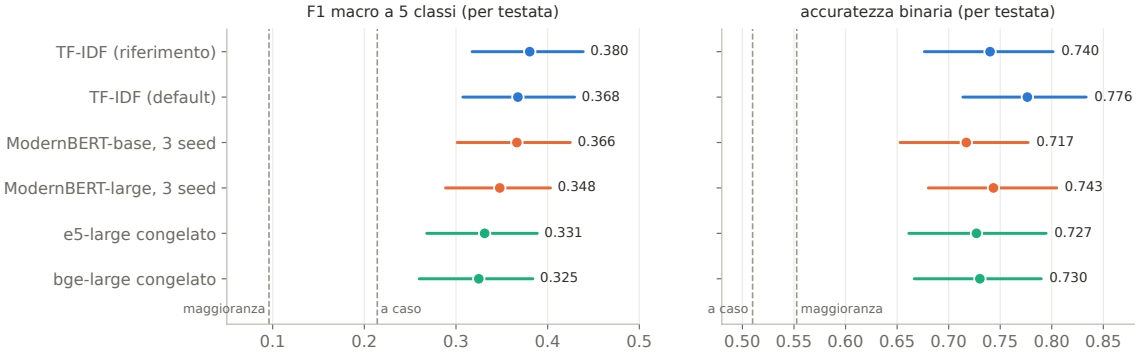
I risultati della Versione 1

Modello	F1 macro	accuratezza	tolerant 1	binario
TF-IDF (riferimento)	**0,380**	0,424	0,770	0,740
TF-IDF, parametri di default	0,368	**0,454**	**0,803**	**0,776**
ModernBERT-base, ensemble di 3 seed	0,366	0,398	0,780	0,717
ModernBERT-large, ensemble di 3 seed	0,348	0,405	0,799	0,743
e5-large / bge-large congelati	0,331 / 0,325	0,391 / 0,382	0,786 / 0,789	0,727 / 0,730
classe di maggioranza / a caso	0,096 / 0,214	0,316 / 0,243	0,553 / 0,533	0,553 / 0,510

Per testata, 304 testate, fold per gruppo. Tolerant 1: un errore di un livello vale un punto.

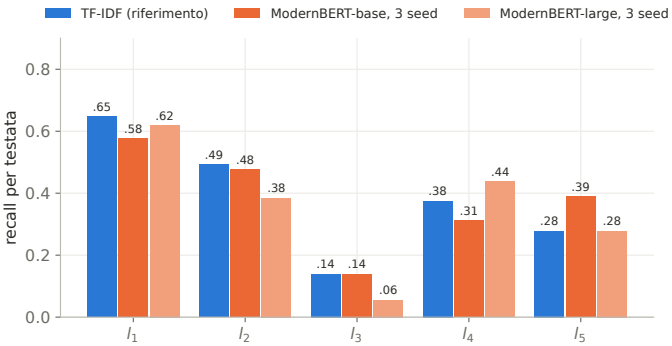
- Tutti **ben sopra** maggioranza e caso: dal solo testo un segnale c'è
- **Nessun transformer batte il TF-IDF** in modo significativo; il modello più grande e gli embedding congelati non aiutano

Con gli intervalli



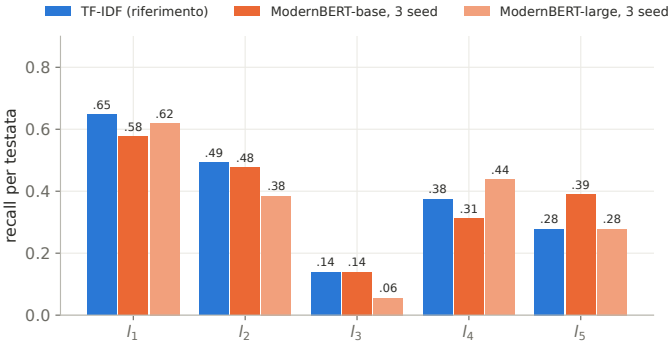
Intervalli al 95% con un bootstrap per gruppo: le differenze tra i modelli stanno tutte dentro.

Chi riconosce cosa



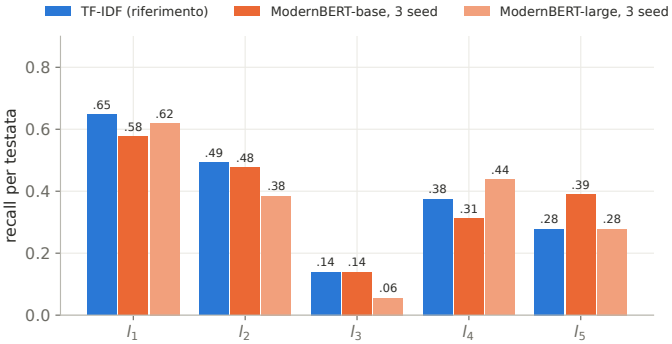
- Il TF-IDF riconosce meglio le testate **inaffidabili** (l_1), ModernBERT le **più affidabili** (l_4, l_5): sbagliano in modo **diverso**

Chi riconosce cosa



- Il TF-IDF riconosce meglio le testate **inaffidabili** (l_1), ModernBERT le **più affidabili** (l_4, l_5): sbagliano in modo **diverso**
- Il vantaggio del TF-IDF su l_1 **non viene dalle reti**: indovina le l_1 isolate (30/43) e quelle in un gruppo (20/28) allo stesso modo

Chi riconosce cosa



- Il TF-IDF riconosce meglio le testate **inaffidabili** (l_1), ModernBERT le **più affidabili** (l_4, l_5): sbagliano in modo **diverso**
- Il vantaggio del TF-IDF su l_1 **non viene dalle reti**: indovina le l_1 isolate (30/43) e quelle in un gruppo (20/28) allo stesso modo
- Il perché lo spiega l'analisi più avanti: il TF-IDF legge il **genere** della testata

Come ho provato a battere il TF-IDF

tre tentativi dopo la Versione 1, 19–22 ottobre

Quattro versioni, lo stesso risultato

	L'idea	TF-IDF	ModernBERT	Δ [IC 95%]
V1	la pipeline pulita (reti, gruppi, fold per gruppo)	0,380	0,366	−0,01 [−0,07; +0,04]
V2	più pulizia e più testate nel training	0,370	0,341	−0,03 [−0,10; +0,04]
V3	togliere il genere: affidabile sì/no dentro ogni orientamento*	0,593	0,551	−0,04 [−0,10; +0,02]
V4	il titolo letto con l'articolo, i criteri NewsGuard come etichette	0,390	0,360	−0,03 [−0,10; +0,04]

F1 macro per testata (V3: accuratezza bilanciata media sugli orientamenti), 304 testate, fold per gruppo; ModernBERT = ensemble di 3 seed (V3: 5); Δ con bootstrap per gruppo.*

Il TF-IDF resta sempre **un po' avanti**, mai in modo significativo.

V2 — più pulizia e più dati

- **Cosa**: via i resti di link e tweet incorporati (il TF-IDF li usava per l_1); nel training anche le testate escluse dal tetto, **863** invece di 304; una combinazione TF-IDF + ModernBERT
- **Risultato**: TF-IDF 0,370, ModernBERT 0,341, combinazione 0,355. Niente cambia
- **Perché ha fallito**: i resti di link non erano il motivo del vantaggio del TF-IDF, e più testate della stessa rete non insegnano niente di nuovo

V2 — l'analisi: che cosa legge il TF-IDF

Il TF-IDF su…	**F1**
il testo intero	0,387
senza nomi propri	0,383
solo parole funzione	**0,364**
solo metadati NewsGuard	**0,339**

- Il segnale è **sparso**: regge senza nomi e con le sole parole funzione
- Segue il **genere** della testata: l_1 = estrema destra e complotti, l_2 = destra di parte, l_4/l_5 = testate internazionali e d'inchiesta
- I soli metadati (orientamento, paese, tipo), senza testo, fanno quasi quanto lui

Un segnale lessicale e diffuso: il TF-IDF lo prende tutto, al transformer resta poco.

V3 — togliere il genere

- **Cosa**: compito binario (affidabile sì/no), pesi che rendono l'orientamento politico inutile per indovinare, valutazione **dentro** ogni orientamento (i soli metadati fanno 0,50)
- **Risultato**: TF-IDF 0,59–0,62, ModernBERT 0,55 (ensemble di 5 seed), embedding congelati 0,50–0,57
- **Perché ha fallito**: oltre il genere resta un segnale modesto ed è **stile** (il TF-IDF sulle sole parole funzione fa 0,618, come sul testo intero): di nuovo lessicale

Unico indizio a favore: nell'orientamento Slightly Right tutti i seed di ModernBERT battono il TF-IDF (0,57–0,71 contro 0,51). Su 78 testate, a posteriori.

V4 — quello che un TF-IDF non vede

- **Cosa**: ModernBERT legge **titolo [SEP] articolo**, così può confrontarli ("titoli ingannevoli" è un criterio NewsGuard); in più impara i 5 criteri NewsGuard visibili nel testo come etichette in più
- **Risultato**: ModernBERT da 0,341 a 0,356 con il titolo, 0,360 con i criteri. Ma il TF-IDF con il titolo passa da 0,370 a **0,390**
- **Perché ha fallito**: il titolo aiuta tutti e due allo stesso modo, quindi il distacco resta; i criteri aggiungono pochissimo. Tra un seed e l'altro ModernBERT varia di 4 punti, più di ogni effetto trovato

Oltre il testo

link citati e pagina HTML (tentativo 09, 22–23 ottobre)

L'idea

- Non solo **che cosa scrive** una testata, ma **chi cita** e **com'è fatto il suo sito**, tutto dall'HTML già scaricato. Una riga per testata, tre famiglie:

  testo: la media TF-IDF dei suoi articoli (e, in più, ModernBERT: 3 semi)

  link: i domini citati negli articoli e l'affidabilità dei siti citati (dalle sole etichette del training)

  pagina: tracker e pubblicità, pagine di trasparenza (chi siamo, rettifiche, redazione...), firma, paywall, video incorporati

- **Modelli** (regressioni logistiche): uno per famiglia; uno che le **combina** (stacking sulle probabilità fuori fold); uno **"alla NewsGuard"** che stima i 9 criteri e somma i punti pubblici
- I criteri **non** entrano mai come ingresso: il punteggio è esattamente la loro somma pesata, per tutte le 9.222 testate NewsGuard
- **Stessa valutazione**: 301 testate, gruppi reti $\cup$ owner $\cup$ Parent Domain, bootstrap per gruppo. Riferimento: il TF-IDF per articolo, ricalcolato

I risultati

Modello	F1 a 5 livelli	Δ dal riferimento [IC 95%]	binario
riferimento: TF-IDF per articolo	**0,340**	—	0,684
testo (TF-IDF per testata)	0,339	−0,00 [−0,05; +0,04]	0,684
ModernBERT (3 semi)	0,325	−0,02 [−0,07; +0,04]	0,708
link	0,247	−0,09 [−0,15; −0,03]	0,641
pagina	0,241	−0,10 [−0,16; −0,03]	0,615
combinato testo + pagina	**0,354**	+0,01 [−0,06; +0,09]	0,711
combinato tutte	0,347	+0,01 [−0,07; +0,09]	0,688
combinato tutte + ModernBERT	0,318	−0,02 [−0,10; +0,05]	0,714
alla NewsGuard	0,319	−0,02 [−0,10; +0,06]	**0,718**

Per testata, 301 testate valutate. Maggioranza: F1 0,096, binario 0,561; a caso: F1 0,176. In rosso: significativamente peggio del riferimento.

Nessun modello batte il testo in modo significativo; link e pagina da soli hanno segnale, ma meno del testo.

Che cosa si riesce a stimare

Criterio (alla NewsGuard)	acc. bil.
informazione responsabile	0,77
titoli non ingannevoli	0,72
corregge gli errori	0,70
niente contenuti falsi	0,67
firma gli articoli	0,63
dice chi comanda	0,62
notizie e opinioni	0,61
proprietà e finanziamento	0,56
segnala la pubblicità	0,54

Si stimano i criteri di **contenuto**, non quelli **di pagina**: proprio il contrario di quello che ci aspettavamo

I segnali più forti

- **I5** cita bbc.com, apple.news, siti governativi (army.mil, canada.ca, mod.uk); ha redazione, rettifiche, paywall, newsletter
- **I1** cita t.me, gab.com, rt-english.com, pravda.ru; incorpora video da Rumble, Brighteon e simili
- **I2** cita twitter.com, dailywire.com, rasmussenreports.com; ha più circuiti pubblicitari
- qualche segnale spurio (link riscritti dai filtri email: urldefense, proofpoint)

Che cosa ne concludiamo

- Testo letto in due modi, link, pagina, criteri: **tutto arriva allo stesso tetto**, F1 circa 0,34 e binario circa 0,70
- Link e pagina hanno segnale, ma **non aggiungono** al testo: probabilmente raccontano di nuovo il genere della testata, che il testo vede già
- La **variabilità dei fold** è grande quanto le differenze tra modelli: con i gruppi nuovi (Parent Domain) il riferimento passa da 0,357 a 0,340 sulle stesse 284 testate, e 118 di loro cambiano previsione
- Con 301 testate in 218 gruppi non si distinguono differenze sotto i 6–7 punti
- Per il paper: con una valutazione che tiene conto delle reti, il tetto non dipende dal segnale; lo 0,68 che si ottiene senza gruppi era fuga tra training e test
- Possibile passo successivo: ripetere tutto con più divisioni in fold, per stringere gli intervalli (solo CPU, circa un'ora a divisione)