Verso Web Science 2027

Riprendere il paper bocciato: recap del lavoro e prossimi passi

Riunione di gruppo

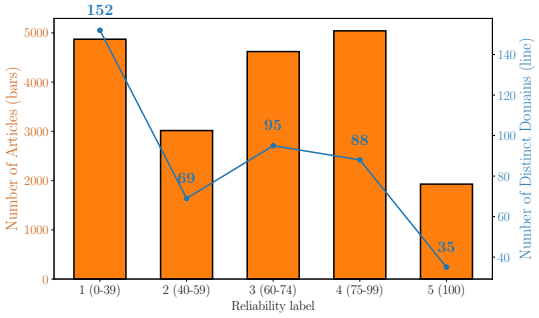
IMT Lucca & IIT-CNR Pisa

Recap del paper bocciato

non la versione sottomessa a IR for Good

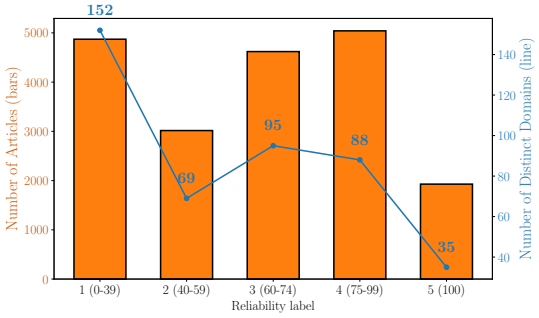
Dati

- Scraping con **newspaper3k**
- 439 editori, 19.476 articoli politici in inglese
- Etichette **NewsGuard**: 5 livelli l_1–l_5 (da 0–100)
- Ogni articolo **eredita** l'etichetta del suo editore



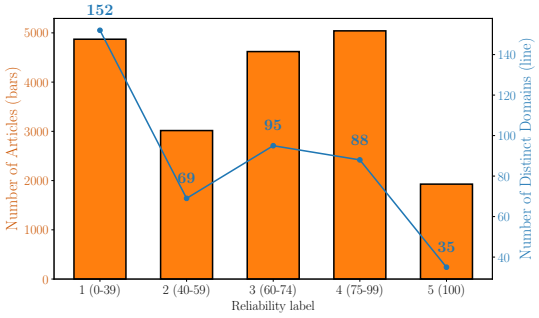
Dati

- Scraping con **newspaper3k**
- 439 editori, 19.476 articoli politici in inglese
- Etichette **NewsGuard**: 5 livelli l_1–l_5 (da 0–100)
- Ogni articolo **eredita** l'etichetta del suo editore



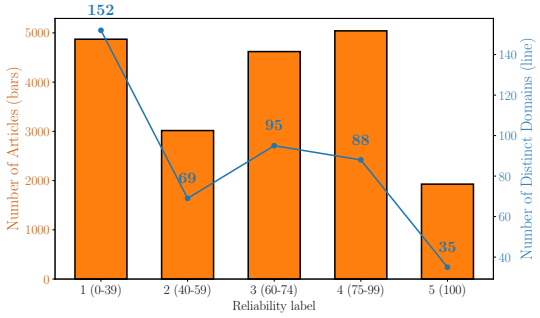
Dati

- Scraping con **newspaper3k**
- 439 editori, 19.476 articoli politici in inglese
- Etichette **NewsGuard**: 5 livelli l_1–l_5 (da 0–100)
- Ogni articolo **eredita** l'etichetta del suo editore



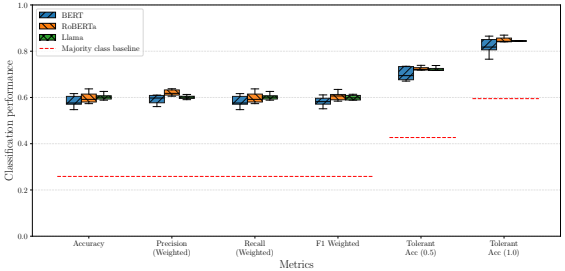
Dati

- Scraping con **newspaper3k**
- 439 editori, 19.476 articoli politici in inglese
- Etichette **NewsGuard**: 5 livelli l_1–l_5 (da 0–100)
- Ogni articolo **eredita** l'etichetta del suo editore



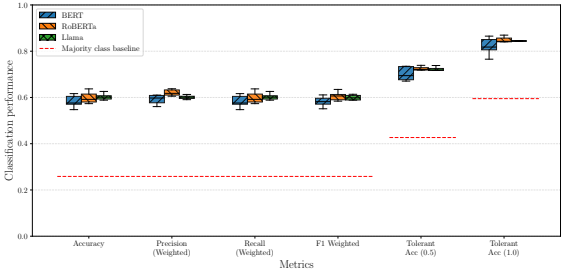
Classificazione — livello articolo

- Quattro transformer: **BERT, RoBERTa, Llama, Mistral**
- Encoder full fine-tuning, decoder con **LoRA**
- Input **256 token** (1024 per Mistral)
- Split **publisher-disjoint**: editori di test mai visti



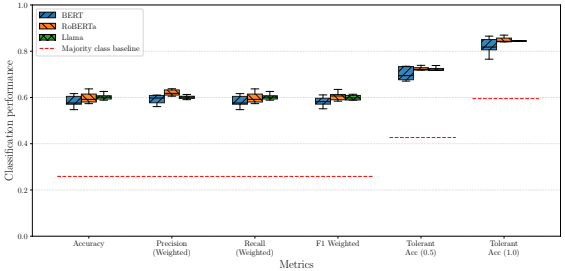
Classificazione — livello articolo

- Quattro transformer: **BERT, RoBERTa, Llama, Mistral**
- Encoder full fine-tuning, decoder con **LoRA**
- Input **256 token** (1024 per Mistral)
- Split **publisher-disjoint**: editori di test mai visti



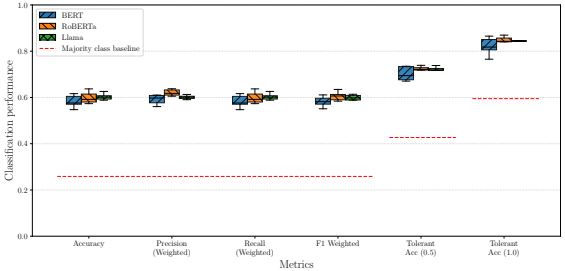
Classificazione — livello articolo

- Quattro transformer: **BERT, RoBERTa, Llama, Mistral**
- Encoder full fine-tuning, decoder con **LoRA**
- Input **256 token** (1024 per Mistral)
- Split **publisher-disjoint**: editori di test mai visti



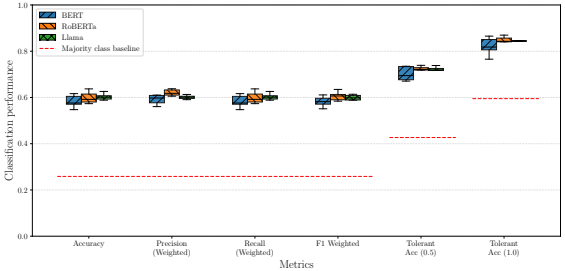
Classificazione — livello articolo

- Quattro transformer: **BERT, RoBERTa, Llama, Mistral**
- Encoder full fine-tuning, decoder con **LoRA**
- Input **256 token** (1024 per Mistral)
- Split **publisher-disjoint**: editori di test mai visti



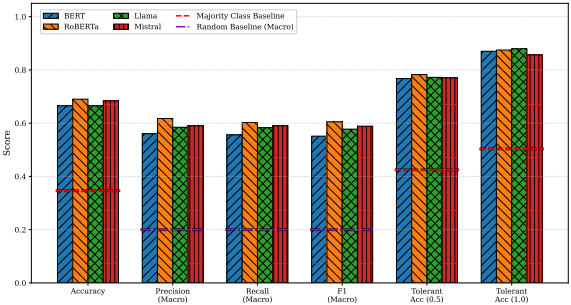
Classificazione — livello articolo

- Quattro transformer: **BERT, RoBERTa, Llama, Mistral**
- Encoder full fine-tuning, decoder con **LoRA**
- Input **256 token** (1024 per Mistral)
- Split **publisher-disjoint**: editori di test mai visti



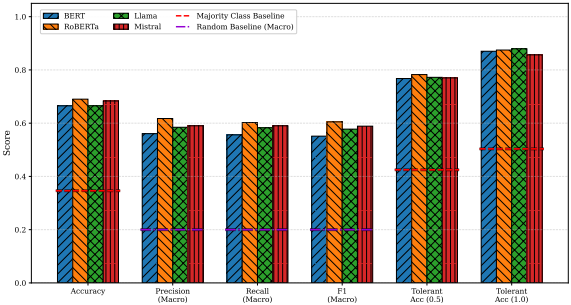
Aggregazione — livello editore

- Dall'articolo all'editore con **majority voting**
- Si usano **tutti** gli articoli della testata: nessun cap in aggregazione (fino a 200, mediana $\sim$34)
- Valutazione su editori **mai visti** in addestramento



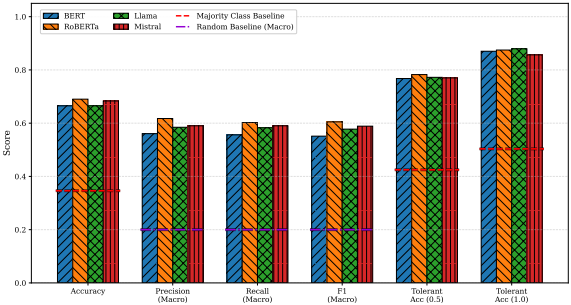
Aggregazione — livello editore

- Dall'articolo all'editore con **majority voting**
- Si usano **tutti** gli articoli della testata: nessun cap in aggregazione (fino a 200, mediana $\sim$34)
- Valutazione su editori **mai visti** in addestramento



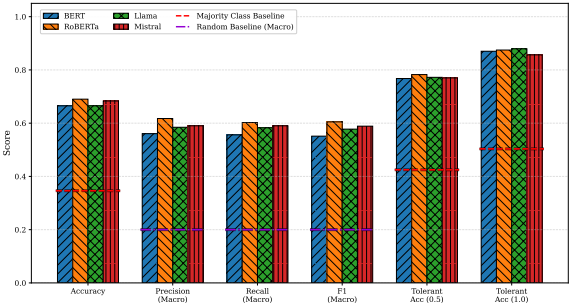
Aggregazione — livello editore

- Dall'articolo all'editore con **majority voting**
- Si usano **tutti** gli articoli della testata: nessun cap in aggregazione (fino a 200, mediana $\sim$34)
- Valutazione su editori **mai visti** in addestramento



Aggregazione — livello editore

- Dall'articolo all'editore con **majority voting**
- Si usano **tutti** gli articoli della testata: nessun cap in aggregazione (fino a 200, mediana $\sim$34)
- Valutazione su editori **mai visti** in addestramento



Perché analizziamo gli errori

- Oltre alle metriche aggregate, vogliamo capire **come** e **perché** i modelli sbagliano

  "Beyond aggregate performance, we investigate how and why models fail."

- Obiettivo: trovare **debolezze strutturali** — su quali livelli sbaglia e se sovra/sottostima

  "To detect structural weaknesses. . . "

Perché analizziamo gli errori

- Oltre alle metriche aggregate, vogliamo capire **come** e **perché** i modelli sbagliano

  "Beyond aggregate performance, we investigate how and why models fail."

- Obiettivo: trovare **debolezze strutturali** — su quali livelli sbaglia e se sovra/sottostima

  "To detect structural weaknesses..."

Perché analizziamo gli errori

- Oltre alle metriche aggregate, vogliamo capire **come** e **perché** i modelli sbagliano

  "Beyond aggregate performance, we investigate how and why models fail."

- Obiettivo: trovare **debolezze strutturali** — su quali livelli sbaglia e se sovra/sottostima

  "To detect structural weaknesses. . . "

Perché analizziamo gli errori

- Oltre alle metriche aggregate, vogliamo capire **come** e **perché** i modelli sbagliano

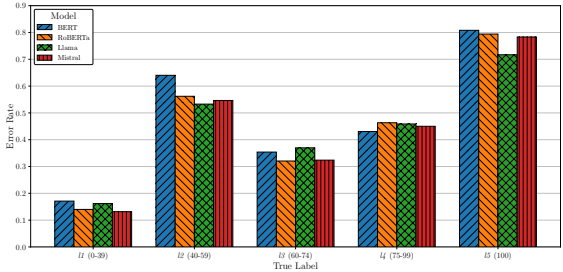
  "Beyond aggregate performance, we investigate how and why models fail."

- Obiettivo: trovare **debolezze strutturali** — su quali livelli sbaglia e se sovra/sottostima

  "To detect structural weaknesses. . . "

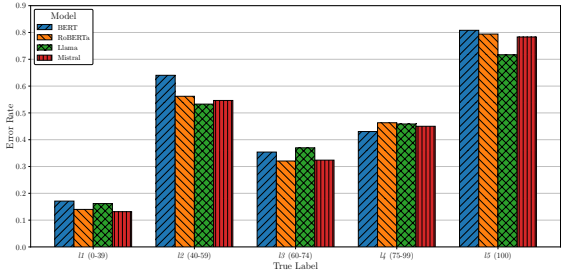
Analisi dell'errore — per livello

- **Error rate** per ogni livello di affidabilità
- l_1 il più **facile**: contenuti molto inaffidabili riconoscibili
- l_5 il più **difficile**: si confonde con l_4
- l_2 difficile, l_3 intermedio



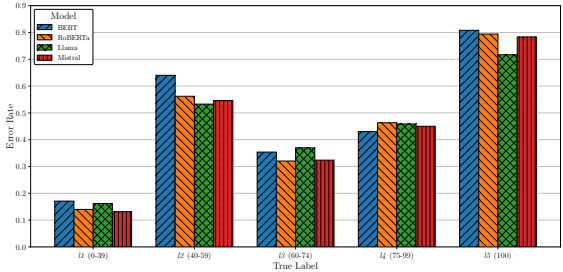
Analisi dell'errore — per livello

- **Error rate** per ogni livello di affidabilità
- l_1 il più **facile**: contenuti molto inaffidabili riconoscibili
- l_5 il più **difficile**: si confonde con l_4
- l_2 difficile, l_3 intermedio



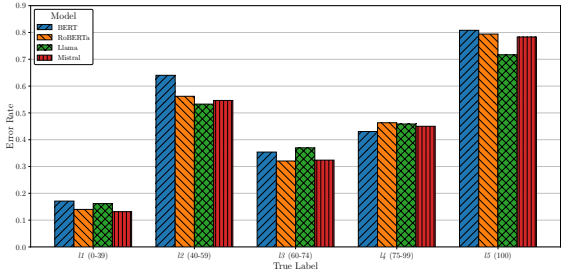
Analisi dell'errore — per livello

- **Error rate** per ogni livello di affidabilità
- l_1 il più **facile**: contenuti molto inaffidabili riconoscibili
- l_5 il più **difficile**: si confonde con l_4
- l_2 difficile, l_3 intermedio



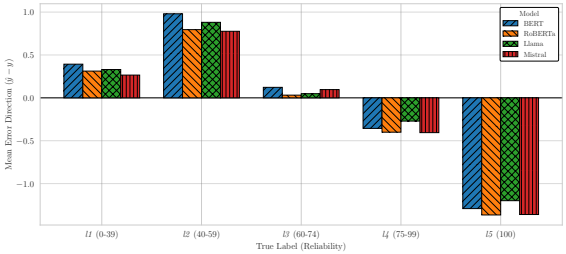
Analisi dell'errore — per livello

- **Error rate** per ogni livello di affidabilità
- l_1 il più **facile**: contenuti molto inaffidabili riconoscibili
- l_5 il più **difficile**: si confonde con l_4
- l_2 difficile, l_3 intermedio



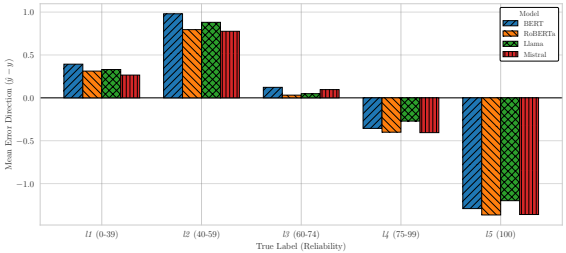
Analisi dell'errore — direzione

- **Mean Error Direction**: l'errore *sovrastima* (+) o *sottostima* (−) l'affidabilità
- Livelli **bassi sovrastimati**, livelli **alti sottostimati**
- Gli errori "tirano verso il **centro**" della scala



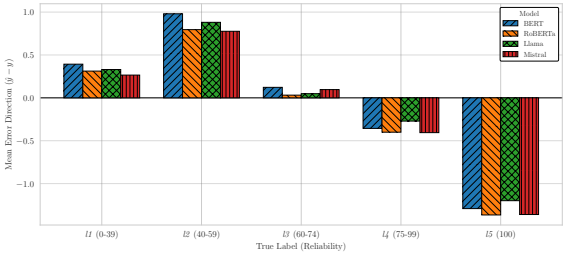
Analisi dell'errore — direzione

- **Mean Error Direction**: l'errore *sovrastima* (+) o *sottostima* (−) l'affidabilità
- Livelli **bassi sovrastimati**, livelli **alti sottostimati**
- Gli errori "tirano verso il **centro**" della scala



Analisi dell'errore — direzione

- **Mean Error Direction**: l'errore *sovrastima* (+) o *sottostima* (−) l'affidabilità
- Livelli **bassi sovrastimati**, livelli **alti sottostimati**
- Gli errori "tirano verso il **centro**" della scala



Perché analizziamo il bias politico

- Vogliamo sapere se il modello **tratta allo stesso modo** tutto lo spettro politico, o se **penalizza** certi orientamenti

  "...determine if the models exhibit political bias...whether the models treat all sides of the political spectrum equally or if they penalize specific orientations."

- Serve una valutazione **bias-aware**: un sistema in uso con bias politico può fare danni

  "...the need for bias-aware evaluation protocols..."

Perché analizziamo il bias politico

- Vogliamo sapere se il modello **tratta allo stesso modo** tutto lo spettro politico, o se **penalizza** certi orientamenti

  "...determine if the models exhibit political bias...whether the models treat all sides of the political spectrum equally or if they penalize specific orientations."

- Serve una valutazione **bias-aware**: un sistema in uso con bias politico può fare danni

  "...the need for bias-aware evaluation protocols..."

Perché analizziamo il bias politico

- Vogliamo sapere se il modello **tratta allo stesso modo** tutto lo spettro politico, o se **penalizza** certi orientamenti

  "... determine if the models exhibit political bias... whether the models treat all sides of the political spectrum equally or if they penalize specific orientations."

- Serve una valutazione **bias-aware**: un sistema in uso con bias politico può fare danni

  "... the need for bias-aware evaluation protocols..."

Perché analizziamo il bias politico

- Vogliamo sapere se il modello **tratta allo stesso modo** tutto lo spettro politico, o se **penalizza** certi orientamenti

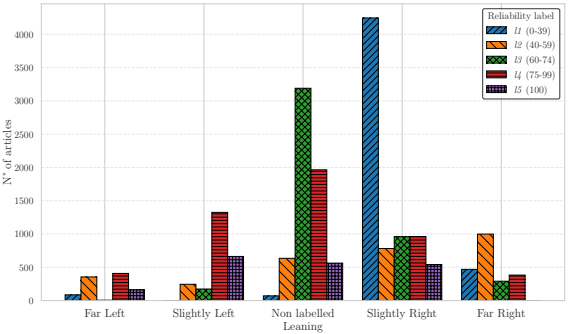
  "...determine if the models exhibit political bias...whether the models treat all sides of the political spectrum equally or if they penalize specific orientations."

- Serve una valutazione **bias-aware**: un sistema in uso con bias politico può fare danni

  "...the need for bias-aware evaluation protocols..."

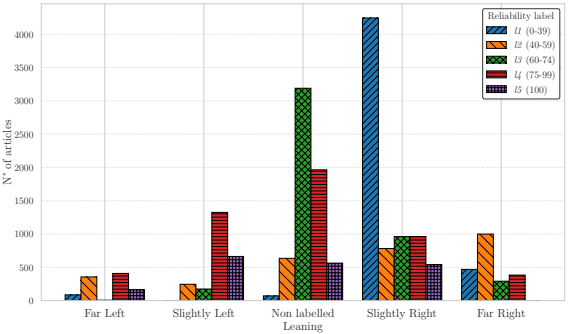
Bias politico — distribuzione dei dati

- Orientamento ereditato dall'editore (analisi *a posteriori*)
- Dentro ogni orientamento, come si distribuiscono i livelli
- Distribuzione molto **sbilanciata** (proprietà del sistema mediatico)
- Per questo gli error rate si calcolano **classe per classe**



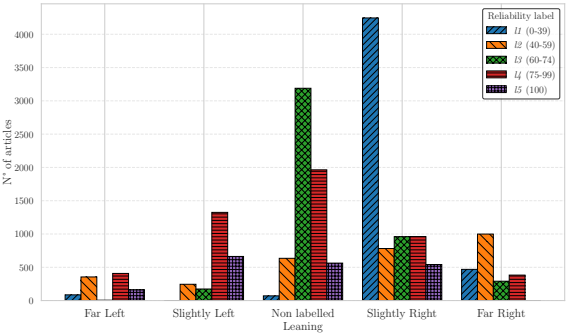
Bias politico — distribuzione dei dati

- Orientamento ereditato dall'editore (analisi *a posteriori*)
- Dentro ogni orientamento, come si distribuiscono i livelli
- Distribuzione molto **sbilanciata** (proprietà del sistema mediatico)
- Per questo gli error rate si calcolano **classe per classe**



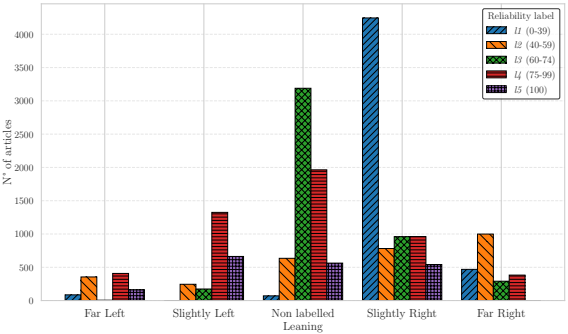
Bias politico — distribuzione dei dati

- Orientamento ereditato dall'editore (analisi *a posteriori*)
- Dentro ogni orientamento, come si distribuiscono i livelli
- Distribuzione molto **sbilanciata** (proprietà del sistema mediatico)
- Per questo gli error rate si calcolano **classe per classe**



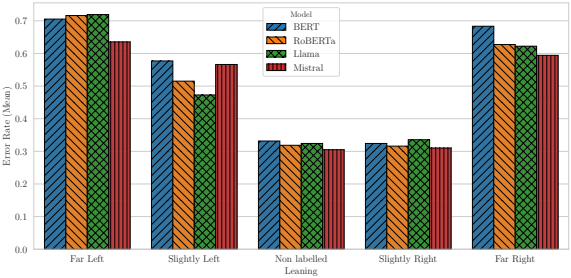
Bias politico — distribuzione dei dati

- Orientamento ereditato dall'editore (analisi *a posteriori*)
- Dentro ogni orientamento, come si distribuiscono i livelli
- Distribuzione molto **sbilanciata** (proprietà del sistema mediatico)
- Per questo gli error rate si calcolano **classe per classe**



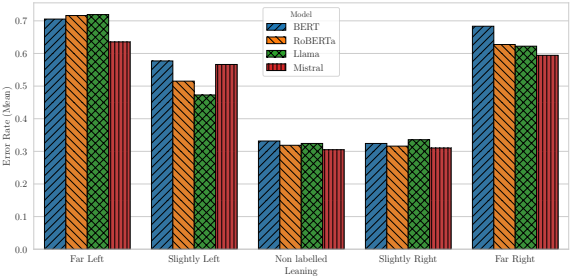
Bias politico — error rate

- **Error rate** per orientamento politico
- Gli estremi (**far left**, **far right**) sbagliano molto di più
- Slightly right e non labelled i più **facili**



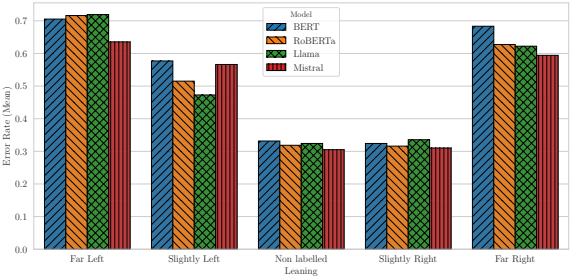
Bias politico — error rate

- **Error rate** per orientamento politico
- Gli estremi (**far left**, **far right**) sbagliano molto di più
- Slightly right e non labelled i più **facili**



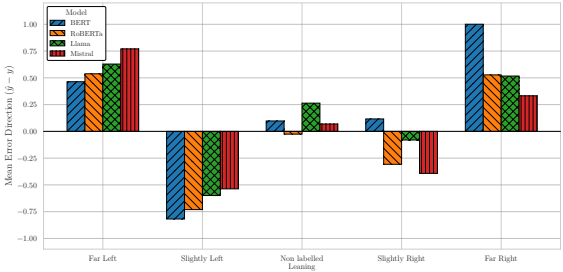
Bias politico — error rate

- **Error rate** per orientamento politico
- Gli estremi (**far left**, **far right**) sbagliano molto di più
- Slightly right e non labelled i più **facili**



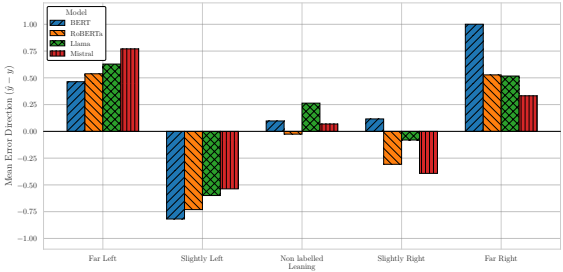
Bias politico — direzione dell'errore

- **Mean Error Direction** per orientamento
- Estremi (far left, far right) **sovrastimati**
- Slightly left **sottostimato**
- Slightly right e non labelled: deviazioni piccole



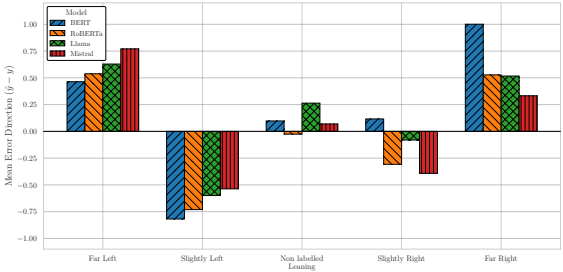
Bias politico — direzione dell'errore

- **Mean Error Direction** per orientamento
- Estremi (far left, far right) **sovrastimati**
- Slightly left **sottostimato**
- Slightly right e non labelled: deviazioni piccole



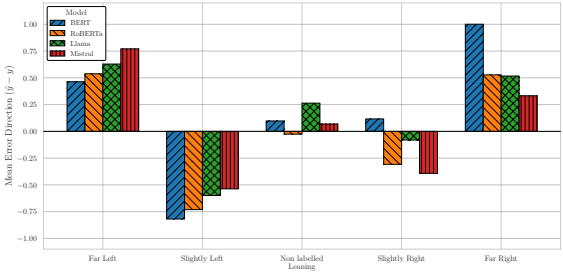
Bias politico — direzione dell'errore

- **Mean Error Direction** per orientamento
- Estremi (far left, far right) **sovrastimati**
- Slightly left **sottostimato**
- Slightly right e non labelled: deviazioni piccole



Bias politico — direzione dell'errore

- **Mean Error Direction** per orientamento
- Estremi (far left, far right) **sovrastimati**
- Slightly left **sottostimato**
- Slightly right e non labelled: deviazioni piccole



È un vero legame o è un caso?

- Vediamo error rate diversi tra gli orientamenti.
- Ma potrebbe essere solo **rumore** dei dati.
- Serve un **test statistico** che dica: questo legame è reale?

Strumento usato: il **test del chi-quadro (χ^2) di indipendenza**.

È un vero legame o è un caso?

- Vediamo error rate diversi tra gli orientamenti.
- Ma potrebbe essere solo **rumore** dei dati.
- Serve un **test statistico** che dica: questo legame è reale?

Strumento usato: il **test del chi-quadro (χ^2) di indipendenza**.

È un vero legame o è un caso?

- Vediamo error rate diversi tra gli orientamenti.
- Ma potrebbe essere solo **rumore** dei dati.
- Serve un **test statistico** che dica: questo legame è reale?

Strumento usato: il **test del chi-quadro (χ^2) di indipendenza**.

È un vero legame o è un caso?

- Vediamo error rate diversi tra gli orientamenti.
- Ma potrebbe essere solo **rumore** dei dati.
- Serve un **test statistico** che dica: questo legame è reale?

Strumento usato: il **test del chi-quadro (χ^2) di indipendenza**.

Passo 1 — mettiamo gli errori in tabella

- Per ogni orientamento contiamo **giusti** e **sbagliati**
- È la **tabella di contingenza**
- Agli estremi gli sbagliati superano i giusti

Orientamento	Giusti	Sbagliati
Far Left	299	716
Slightly Left	1018	1389
Non labelled	4292	2130
Slightly Right	5062	2428
Far Right	678	1464

(esempio: BERT)

Passo 1 — mettiamo gli errori in tabella

- Per ogni orientamento contiamo **giusti** e **sbagliati**
- È la **tabella di contingenza**
- Agli estremi gli sbagliati superano i giusti

Orientamento	**Giusti**	**Sbagliati**
Far Left	299	716
Slightly Left	1018	1389
Non labelled	4292	2130
Slightly Right	5062	2428
Far Right	678	1464

(esempio: BERT)

Passo 1 — mettiamo gli errori in tabella

- Per ogni orientamento contiamo **giusti** e **sbagliati**
- È la **tabella di contingenza**
- Agli estremi gli sbagliati superano i giusti

Orientamento	**Giusti**	**Sbagliati**
Far Left	299	716
Slightly Left	1018	1389
Non labelled	4292	2130
Slightly Right	5062	2428
Far Right	678	1464

(esempio: BERT)

Passo 2 — l'idea del chi-quadro

- Immaginiamo che l'orientamento **non c'entri** con gli errori.
- Allora ogni gruppo dovrebbe sbagliare **nella stessa proporzione** (circa la media, $\sim$42%).
- Il χ^2 misura **quanto** gli errori *osservati* si allontanano da questo scenario "senza legame".
- Più grande è lo scarto $\rightarrow$ χ^2 grande $\rightarrow$ più probabile che un legame ci sia.

Passo 2 — l'idea del chi-quadro

- Immaginiamo che l'orientamento **non c'entri** con gli errori.
- Allora ogni gruppo dovrebbe sbagliare **nella stessa proporzione** (circa la media, $\sim$42%).
- Il χ^2 misura **quanto** gli errori *osservati* si allontanano da questo scenario "senza legame".
- Più grande è lo scarto $\rightarrow$ χ^2 grande $\rightarrow$ più probabile che un legame ci sia.

Passo 2 — l'idea del chi-quadro

- Immaginiamo che l'orientamento **non c'entri** con gli errori.
- Allora ogni gruppo dovrebbe sbagliare **nella stessa proporzione** (circa la media, $\sim$42%).
- Il χ^2 misura **quanto** gli errori *osservati* si allontanano da questo scenario "senza legame".
- Più grande è lo scarto $\rightarrow$ χ^2 grande $\rightarrow$ più probabile che un legame ci sia.

Passo 2 — l'idea del chi-quadro

- Immaginiamo che l'orientamento **non c'entri** con gli errori.
- Allora ogni gruppo dovrebbe sbagliare **nella stessa proporzione** (circa la media, $\sim$42%).
- Il χ^2 misura **quanto** gli errori *osservati* si allontanano da questo scenario "senza legame".
- Più grande è lo scarto $\rightarrow$ χ^2 grande $\rightarrow$ più probabile che un legame ci sia.

Passo 3 — il p-value

- Un χ^2 grande potrebbe capitare **per caso**?
- Il p-**value** è la probabilità di vedere uno scarto così grande *se non ci fosse nessun legame*.
- p piccolissimo (es. $p < 0.001$) $\rightarrow$ quasi impossibile che sia un caso.
- Quindi il legame è **reale**, non fortuna.

Passo 3 — il p-value

- Un χ^2 grande potrebbe capitare **per caso**?
- Il p-**value** è la probabilità di vedere uno scarto così grande *se non ci fosse nessun legame*.
- p piccolissimo (es. $p < 0.001$) $\rightarrow$ quasi impossibile che sia un caso.
- Quindi il legame è **reale**, non fortuna.

Passo 3 — il p-value

- Un χ^2 grande potrebbe capitare **per caso**?
- Il p-**value** è la probabilità di vedere uno scarto così grande *se non ci fosse nessun legame*.
- p piccolissimo (es. $p < 0.001$) $\rightarrow$ quasi impossibile che sia un caso.
- Quindi il legame è **reale**, non fortuna.

Passo 3 — il p-value

- Un χ^2 grande potrebbe capitare **per caso**?
- Il p-**value** è la probabilità di vedere uno scarto così grande *se non ci fosse nessun legame*.
- p piccolissimo (es. $p < 0.001$) $\rightarrow$ quasi impossibile che sia un caso.
- Quindi il legame è **reale**, non fortuna.

Passo 4 — quanto è forte? (Cramér's V)

- Il *p*-value dice **se** c'è un legame, non **quanto** è forte.
- Con tanti dati anche un legame **piccolo** risulta "significativo".
- **Cramér's V** misura la **forza**: 0 = nessun legame, 1 = legame massimo.

Passo 4 — quanto è forte? (Cramér's V)

- Il *p*-value dice **se** c'è un legame, non **quanto** è forte.
- Con tanti dati anche un legame **piccolo** risulta "significativo".
- **Cramér's V** misura la **forza**: 0 = nessun legame, 1 = legame massimo.

Passo 4 — quanto è forte? (Cramér's V)

- Il *p*-value dice **se** c'è un legame, non **quanto** è forte.
- Con tanti dati anche un legame **piccolo** risulta "significativo".
- **Cramér's V** misura la **forza**: 0 = nessun legame, 1 = legame massimo.

In sintesi

- Legame **statisticamente significativo** (tutti i modelli)
- Forza **piccola–moderata** (V $\approx$ 0.25–0.29)
- Direzione: estremi **sovrastimati**, slightly left **sottostimati**

Model	χ^2	p	V
BERT	1684	$< 10^{-300}$	0.294
RoBERTa	1418	$< 10^{-300}$	0.270
Llama	1208	$< 10^{-250}$	0.249
Mistral	1344	$< 10^{-300}$	0.263

In sintesi

- Legame **statisticamente significativo** (tutti i modelli)
- Forza **piccola–moderata** (V ≈ 0.25–0.29)
- Direzione: estremi **sovrastimati**, slightly left **sottostimati**

Model	χ^2	p	**V**
BERT	1684	$< 10^{-300}$	0.294
RoBERTa	1418	$< 10^{-300}$	0.270
Llama	1208	$< 10^{-250}$	0.249
Mistral	1344	$< 10^{-300}$	0.263

In sintesi

- Legame **statisticamente significativo** (tutti i modelli)
- Forza **piccola–moderata** (V $\approx$ 0.25–0.29)
- Direzione: estremi **sovrastimati**, slightly left **sottostimati**

Model	χ^2	p	**V**
BERT	1684	$< 10^{-300}$	0.294
RoBERTa	1418	$< 10^{-300}$	0.270
Llama	1208	$< 10^{-250}$	0.249
Mistral	1344	$< 10^{-300}$	0.263

Nel materiale supplementare

- Matrici di confusione per **fold** (livello articolo)
- Matrici di confusione a **livello editore** (dopo aggregazione)
- Matrici di confusione per **orientamento politico**
- **Analisi di convergenza**: curve di loss (Llama, Mistral)

Dettagli a supporto delle analisi del paper, non nuovi risultati.

Nel materiale supplementare

- Matrici di confusione per **fold** (livello articolo)
- Matrici di confusione a **livello editore** (dopo aggregazione)
- Matrici di confusione per **orientamento politico**
- **Analisi di convergenza**: curve di loss (Llama, Mistral)

Dettagli a supporto delle analisi del paper, non nuovi risultati.

Nel materiale supplementare

- Matrici di confusione per **fold** (livello articolo)
- Matrici di confusione a **livello editore** (dopo aggregazione)
- Matrici di confusione per **orientamento politico**
- **Analisi di convergenza**: curve di loss (Llama, Mistral)

Dettagli a supporto delle analisi del paper, non nuovi risultati.

Nel materiale supplementare

- Matrici di confusione per **fold** (livello articolo)
- Matrici di confusione a **livello editore** (dopo aggregazione)
- Matrici di confusione per **orientamento politico**
- **Analisi di convergenza**: curve di loss (Llama, Mistral)

Dettagli a supporto delle analisi del paper, non nuovi risultati.

Nel materiale supplementare

- Matrici di confusione per **fold** (livello articolo)
- Matrici di confusione a **livello editore** (dopo aggregazione)
- Matrici di confusione per **orientamento politico**
- **Analisi di convergenza**: curve di loss (Llama, Mistral)

Dettagli a supporto delle analisi del paper, non nuovi risultati.

Le review dei revisori

quali critiche affrontare

Revisore 1 — (1) Novità metodologica limitata

English

"The two-stage framework is essentially standard fine-tuning of pretrained language models followed by majority voting. The main contribution seems to be the task formulation, dataset construction, and evaluation setup, rather than a new model architecture, learning objective, or aggregation method."

Revisore 1 — (2) Il guadagno dell'aggregazione non è misurato pulito

English

"The comparison between the article-level score ($\sim$0.60) and the publisher-level score ($\sim$0.69) changes both the evaluation unit and the weighting of publishers. As a result, the improvement cannot be attributed to aggregation alone."

Revisore 1 — (3) Bias confuso con il livello di affidabilità

English

"The distribution of reliability labels differs substantially across political leanings, and some reliability levels are clearly more difficult to classify than others. The relationship between political leaning and prediction error should therefore be tested again after controlling for the true reliability level."

Revisore 1 — (4) Il chi-quadro ignora il clustering

English

"Political leaning and reliability are publisher-level attributes shared by multiple articles from the same publisher. Using all articles as independent observations may lead to pseudo-replication and overstate the effective sample size and significance of the results."

Revisore 1 — (5) Indizi dell'editore e artefatti non esclusi

English

"The paper does not include systematic text cleaning, source-identifier masking, or sanitized-text ablations. It is therefore difficult to tell whether the model is learning reliability-related content or simply exploiting publisher-specific signals and scraping artifacts."

Revisore 1 — (6) Possibile bias di selezione nello scraping

English

"Only 439 of the 669 candidate publishers were included in the final dataset, and the scraping success rates differ across reliability levels. The paper does not examine whether the publishers that were successfully scraped differ systematically from those that were not."

Revisore 1 — (7) Confronto sulla taglia del modello non controllato

English

"The models differ in architecture, fine-tuning strategy, training schedule, and context length, in addition to parameter count. The observed performance differences therefore cannot be attributed to model size alone."

Revisore 1 — (8) Nessuna stima di incertezza

English

"Differences such as 0.69 versus 0.68 are small, but the paper does not report confidence intervals, bootstrap results, or paired significance tests. It is therefore unclear whether these differences are meaningful."

Revisore 2 — (1) Motivazione debole del passaggio a livello editore

English

"publisher reliability is, by construction, obtained as a fixed aggregation of article-level outputs. . . the re-formulation does not introduce substantial new insight beyond a change in the unit of evaluation."

Revisore 2 — (2) Mancano confronti con altri scorer

English

"Publisher-level scores can equally be produced by first scoring individual articles with a model pretrained specifically for article-level reliability classification, or with a general-purpose LLM such as Qwen, and then applying the same voting strategy. . . No such comparison is reported."

Revisore 2 — (3) Il dataset non è “large-scale”

English

“Although the corpus contains 19,476 articles, the objective of the paper is scoring at the level of the publisher, and the dataset comprises only 439 publishers. The dataset is therefore unlikely to support effective use in real-world applications.”

Oltre le review: due analisi

Marinella con ChatGPT · Fabio con Claude

Due analisi di supporto

- Oltre ai due revisori del journal, due analisi del paper fatte con strumenti AI
- **Marinella** con **ChatGPT** — focalizzata sulla statistica del bias
- **Fabio** con **Claude** — review completa + analisi quantitativa del bias
- Fatte in modo **indipendente**: le riassumiamo qui, così le conosciamo tutti

Due analisi di supporto

- Oltre ai due revisori del journal, due analisi del paper fatte con strumenti AI
- **Marinella** con **ChatGPT** — focalizzata sulla statistica del bias
- **Fabio** con **Claude** — review completa + analisi quantitativa del bias
- Fatte in modo **indipendente**: le riassumiamo qui, così le conosciamo tutti

Due analisi di supporto

- Oltre ai due revisori del journal, due analisi del paper fatte con strumenti AI
- **Marinella** con **ChatGPT** — focalizzata sulla statistica del bias
- **Fabio** con **Claude** — review completa + analisi quantitativa del bias
- Fatte in modo **indipendente**: le riassumiamo qui, così le conosciamo tutti

Due analisi di supporto

- Oltre ai due revisori del journal, due analisi del paper fatte con strumenti AI
- **Marinella** con **ChatGPT** — focalizzata sulla statistica del bias
- **Fabio** con **Claude** — review completa + analisi quantitativa del bias
- Fatte in modo **indipendente**: le riassumiamo qui, così le conosciamo tutti

Marinella × ChatGPT — cos'è

- Marinella ha dato a ChatGPT la **parte statistica** del bias e gli ha chiesto di controllarla
- Ha trovato una serie di **problemi**: li vediamo uno a uno, in modo semplice
- Tutti ruotano attorno a una domanda: **possiamo davvero dire che c'è un bias politico?**

Marinella × ChatGPT — cos'è

- Marinella ha dato a ChatGPT la **parte statistica** del bias e gli ha chiesto di controllarla
- Ha trovato una serie di **problemi**: li vediamo uno a uno, in modo semplice
- Tutti ruotano attorno a una domanda: **possiamo davvero dire che c'è un bias politico?**

Marinella × ChatGPT — cos'è

- Marinella ha dato a ChatGPT la **parte statistica** del bias e gli ha chiesto di controllarla
- Ha trovato una serie di **problemi**: li vediamo uno a uno, in modo semplice
- Tutti ruotano attorno a una domanda: **possiamo davvero dire che c'è un bias politico?**

Problema 1 — il χ^2 conta troppo

- La domanda del test: l'errore del modello dipende dall'**orientamento politico**?
- Lo calcola contando i **singoli articoli**: 19.476 "prove"
- Ma l'orientamento è **fisso per testata**: tutti gli articoli di una testata hanno lo stesso orientamento (come hanno la stessa affidabilità — anche se sono due cose diverse)
- Quindi gli articoli di una stessa testata **non sono prove indipendenti**

Problema 1 — il χ^2 conta troppo

- La domanda del test: l'errore del modello dipende dall'**orientamento politico**?
- Lo calcola contando i **singoli articoli**: 19.476 "prove"
- Ma l'orientamento è **fisso per testata**: tutti gli articoli di una testata hanno lo stesso orientamento (come hanno la stessa affidabilità — anche se sono due cose diverse)
- Quindi gli articoli di una stessa testata **non sono prove indipendenti**

Problema 1 — il χ^2 conta troppo

- La domanda del test: l'errore del modello dipende dall'**orientamento politico**?
- Lo calcola contando i **singoli articoli**: 19.476 "prove"
- Ma l'orientamento è **fisso per testata**: tutti gli articoli di una testata hanno lo stesso orientamento (come hanno la stessa affidabilità — anche se sono due cose diverse)
- Quindi gli articoli di una stessa testata **non sono prove indipendenti**

Problema 1 — il χ^2 conta troppo

- La domanda del test: l'errore del modello dipende dall'**orientamento politico**?
- Lo calcola contando i **singoli articoli**: 19.476 "prove"
- Ma l'orientamento è **fisso per testata**: tutti gli articoli di una testata hanno lo stesso orientamento (come hanno la stessa affidabilità — anche se sono due cose diverse)
- Quindi gli articoli di una stessa testata **non sono prove indipendenti**

Problema 1 — l'esempio

- Una testata di destra, 200 articoli, tutti affidabilità l_4
- Il modello la trova difficile → sbaglia quasi tutti: 200 errori "di destra"
- Il test li legge come **200 prove** che "destra → errore"
- Ma è **una** testata difficile, non 200 fatti diversi

  Come chiedere l'opinione politica a 200 persone della stessa famiglia: non sono 200 opinioni indipendenti, è quasi una sola.

- Le prove vere sono le **testate** (439), non gli articoli (19.476): più il campione è (finto) grande, più ogni differenza sembra "significativa"
- Soluzione: un conteggio **per testata**

Problema 1 — l'esempio

- Una testata di destra, 200 articoli, tutti affidabilità l_4
- Il modello la trova difficile → sbaglia quasi tutti: 200 errori "di destra"
- Il test li legge come **200 prove** che "destra → errore"
- Ma è **una** testata difficile, non 200 fatti diversi

  Come chiedere l'opinione politica a 200 persone della stessa famiglia: non sono 200 opinioni indipendenti, è quasi una sola.

- Le prove vere sono le **testate** (439), non gli articoli (19.476): più il campione è (finto) grande, più ogni differenza sembra "significativa"
- Soluzione: un conteggio **per testata**

Problema 1 — l'esempio

- Una testata di destra, 200 articoli, tutti affidabilità l_4
- Il modello la trova difficile → sbaglia quasi tutti: 200 errori "di destra"
- Il test li legge come **200 prove** che "destra → errore"
- Ma è **una** testata difficile, non 200 fatti diversi

  Come chiedere l'opinione politica a 200 persone della stessa famiglia: non sono 200 opinioni indipendenti, è quasi una sola.

- Le prove vere sono le **testate** (439), non gli articoli (19.476): più il campione è (finto) grande, più ogni differenza sembra "significativa"
- Soluzione: un conteggio **per testata**

Problema 1 — l'esempio

- Una testata di destra, 200 articoli, tutti affidabilità l_4
- Il modello la trova difficile → sbaglia quasi tutti: 200 errori "di destra"
- Il test li legge come **200 prove** che "destra → errore"
- Ma è **una** testata difficile, non 200 fatti diversi

Come chiedere l'opinione politica a 200 persone della stessa famiglia: non sono 200 opinioni indipendenti, è quasi una sola.

- Le prove vere sono le **testate** (439), non gli articoli (19.476): più il campione è (finto) grande, più ogni differenza sembra "significativa"
- Soluzione: un conteggio **per testata**

Problema 1 — l'esempio

- Una testata di destra, 200 articoli, tutti affidabilità l_4
- Il modello la trova difficile $\rightarrow$ sbaglia quasi tutti: 200 errori "di destra"
- Il test li legge come **200 prove** che "destra $\rightarrow$ errore"
- Ma è **una** testata difficile, non 200 fatti diversi

  Come chiedere l'opinione politica a 200 persone della stessa famiglia: non sono 200 opinioni indipendenti, è quasi una sola.

- Le prove vere sono le **testate** (439), non gli articoli (19.476): più il campione è (finto) grande, più ogni differenza sembra "significativa"
- Soluzione: un conteggio **per testata**

Problema 1 — l'esempio

- Una testata di destra, 200 articoli, tutti affidabilità l_4
- Il modello la trova difficile $\rightarrow$ sbaglia quasi tutti: 200 errori "di destra"
- Il test li legge come **200 prove** che "destra $\rightarrow$ errore"
- Ma è **una** testata difficile, non 200 fatti diversi

  Come chiedere l'opinione politica a 200 persone della stessa famiglia: non sono 200 opinioni indipendenti, è quasi una sola.

- Le prove vere sono le **testate** (439), non gli articoli (19.476): più il campione è (finto) grande, più ogni differenza sembra "significativa"
- Soluzione: un conteggio **per testata**

Problema 1 — l'esempio

- Una testata di destra, 200 articoli, tutti affidabilità l_4
- Il modello la trova difficile → sbaglia quasi tutti: 200 errori "di destra"
- Il test li legge come **200 prove** che "destra → errore"
- Ma è **una** testata difficile, non 200 fatti diversi

  Come chiedere l'opinione politica a 200 persone della stessa famiglia: non sono 200 opinioni indipendenti, è quasi una sola.

- Le prove vere sono le **testate** (439), non gli articoli (19.476): più il campione è (finto) grande, più ogni differenza sembra "significativa"
- Soluzione: un conteggio **per testata**

Osservazione di John — ma è vero?

- La critica regge solo se gli errori si **ripetono** dentro la stessa testata
- Se il modello facesse **un po' giusti e un po' sbagliati a caso**, ogni articolo sarebbe una prova nuova: contarli tutti sarebbe giusto
- Se invece **azzecca (o sbaglia) quasi tutta** la testata insieme, i suoi articoli dicono **la stessa cosa**: contarli tutti è come **ripetere la stessa prova**
- La domanda: quando sbaglia su una testata, sbaglia su **quasi tutti** i suoi articoli? Lo misuriamo.

Osservazione di John — ma è vero?

- La critica regge solo se gli errori si **ripetono** dentro la stessa testata
- Se il modello facesse **un po' giusti e un po' sbagliati a caso**, ogni articolo sarebbe una prova nuova: contarli tutti sarebbe giusto
- Se invece **azzecca (o sbaglia) quasi tutta** la testata insieme, i suoi articoli dicono **la stessa cosa**: contarli tutti è come **ripetere la stessa prova**
- La domanda: quando sbaglia su una testata, sbaglia su **quasi tutti** i suoi articoli? Lo misuriamo.

Osservazione di John — ma è vero?

- La critica regge solo se gli errori si **ripetono** dentro la stessa testata
- Se il modello facesse **un po' giusti e un po' sbagliati a caso**, ogni articolo sarebbe una prova nuova: contarli tutti sarebbe giusto
- Se invece **azzecca (o sbaglia) quasi tutta** la testata insieme, i suoi articoli dicono **la stessa cosa**: contarli tutti è come **ripetere la stessa prova**
- La domanda: quando sbaglia su una testata, sbaglia su **quasi tutti** i suoi articoli? Lo misuriamo.

Osservazione di John — ma è vero?

- La critica regge solo se gli errori si **ripetono** dentro la stessa testata
- Se il modello facesse **un po' giusti e un po' sbagliati a caso**, ogni articolo sarebbe una prova nuova: contarli tutti sarebbe giusto
- Se invece **azzecca (o sbaglia) quasi tutta** la testata insieme, i suoi articoli dicono **la stessa cosa**: contarli tutti è come **ripetere la stessa prova**
- La domanda: quando sbaglia su una testata, sbaglia su **quasi tutti** i suoi articoli? Lo misuriamo.

Cos'è l'ICC — l'idea

- Per ogni testata guardiamo: che **quota di articoli** sbaglia il modello?
- Se sbagliasse **a caso** dentro la testata, ogni testata starebbe vicino alla **media** ($\sim$42%)
- L'ICC dice quanto invece le testate si **spaccano** tra "quasi tutte giuste" e "quasi tutte sbagliate"
- **0** = tutte vicine alla media (nessuna correlazione) **1** = ognuna a un estremo

Come una classe di studenti: se vanno tutti bene o tutti male insieme, i voti sono "correlati".

Cos'è l'ICC — l'idea

- Per ogni testata guardiamo: che **quota di articoli** sbaglia il modello?
- Se sbagliasse **a caso** dentro la testata, ogni testata starebbe vicino alla **media** ($\sim$42%)
- L'ICC dice quanto invece le testate si **spaccano** tra "quasi tutte giuste" e "quasi tutte sbagliate"
- **0** = tutte vicine alla media (nessuna correlazione) **1** = ognuna a un estremo

Come una classe di studenti: se vanno tutti bene o tutti male insieme, i voti sono "correlati".

Cos'è l'ICC — l'idea

- Per ogni testata guardiamo: che **quota di articoli** sbaglia il modello?
- Se sbagliasse **a caso** dentro la testata, ogni testata starebbe vicino alla **media** ($\sim$42%)
- L'ICC dice quanto invece le testate si **spaccano** tra "quasi tutte giuste" e "quasi tutte sbagliate"
- **0** = tutte vicine alla media (nessuna correlazione) **1** = ognuna a un estremo

Come una classe di studenti: se vanno tutti bene o tutti male insieme, i voti sono "correlati".

Cos'è l'ICC — l'idea

- Per ogni testata guardiamo: che **quota di articoli** sbaglia il modello?
- Se sbagliasse **a caso** dentro la testata, ogni testata starebbe vicino alla **media** ($\sim$42%)
- L'ICC dice quanto invece le testate si **spaccano** tra "quasi tutte giuste" e "quasi tutte sbagliate"
- **0** = tutte vicine alla media (nessuna correlazione) **1** = ognuna a un estremo

Come una classe di studenti: se vanno tutti bene o tutti male insieme, i voti sono "correlati".

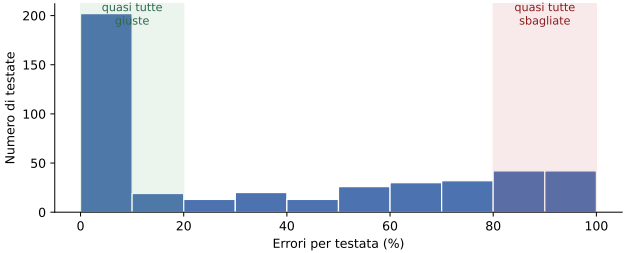
Cos'è l'ICC — l'idea

- Per ogni testata guardiamo: che **quota di articoli** sbaglia il modello?
- Se sbagliasse **a caso** dentro la testata, ogni testata starebbe vicino alla **media** ($\sim$42%)
- L'ICC dice quanto invece le testate si **spaccano** tra "quasi tutte giuste" e "quasi tutte sbagliate"
- **0** = tutte vicine alla media (nessuna correlazione) **1** = ognuna a un estremo

Come una classe di studenti: se vanno tutti bene o tutti male insieme, i voti sono "correlati".

Osservazione di John — cosa troviamo

- Su **439 testate**:
  - **221** quasi tutte giuste
  - **84** quasi tutte sbagliate
  - solo 134 “a metà”
- L’esito lo decide quasi la **testata**, non il singolo articolo
- Riassunto in un numero: ICC ≈ 0.6 (a caso ≈ 0.14)



Osservazione di John — cosa troviamo

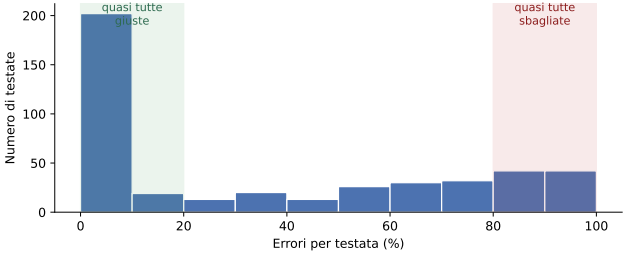
- Su **439 testate**:

  221 quasi tutte giuste

  84 quasi tutte sbagliate

  solo 134 “a metà”

- L’esito lo decide quasi la **testata**, non il singolo articolo
- Riassunto in un numero: ICC ≈ 0.6 (a caso ≈ 0.14)



Osservazione di John — cosa troviamo

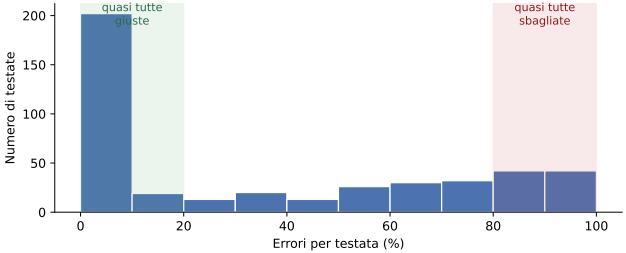
- Su **439 testate**:

  221 quasi tutte giuste

  84 quasi tutte sbagliate

  solo 134 “a metà”

- L’esito lo decide quasi la **testata**, non il singolo articolo
- Riassunto in un numero: ICC ≈ 0.6 (a caso ≈ 0.14)



Osservazione di John — cosa troviamo

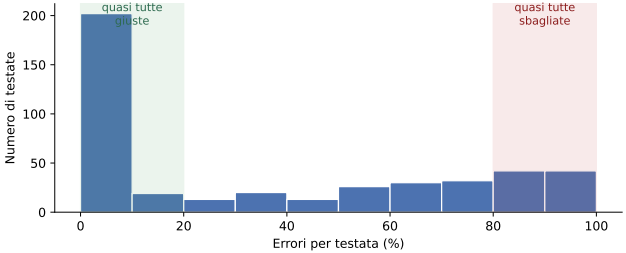
- Su **439 testate**:

  221 quasi tutte giuste

  84 quasi tutte sbagliate

  solo 134 “a metà”

- L’esito lo decide quasi la **testata**, non il singolo articolo
- Riassunto in un numero: ICC ≈ 0.6 (a caso ≈ 0.14)



Osservazione di John — cosa troviamo

- Su **439 testate**:

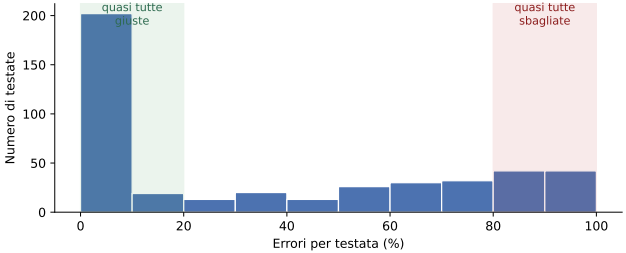
  221 quasi tutte giuste

  84 quasi tutte sbagliate

  solo 134 “a metà”

- L’esito lo decide quasi la **testata**, non il singolo articolo

- Riassunto in un numero: ICC ≈ 0.6 (a caso ≈ 0.14)



Osservazione di John — cosa troviamo

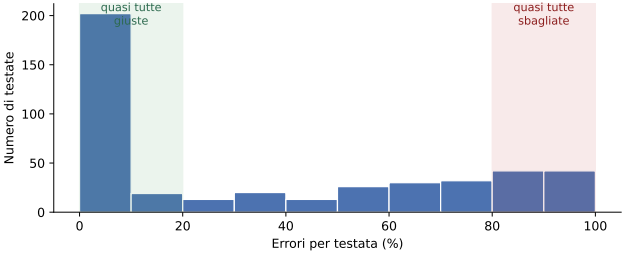
- Su **439 testate**:

  221 quasi tutte giuste

  84 quasi tutte sbagliate

  solo 134 “a metà”

- L’esito lo decide quasi la **testata**, non il singolo articolo
- Riassunto in un numero: ICC ≈ 0.6 (a caso ≈ 0.14)



Osservazione di John — la conclusione

- Gli articoli di una testata **non sono prove indipendenti**
- Quindi l'unità giusta per il test sono le **439 testate**, non i 19.476 articoli

  E vale anche a parità di livello: non è solo perché l_5 è difficile.
- La correzione è semplice: fare il test **per testata**

Osservazione di John — la conclusione

- Gli articoli di una testata **non sono prove indipendenti**
- Quindi l'unità giusta per il test sono le **439 testate**, non i 19.476 articoli

E vale anche a parità di livello: non è solo perché l_5 è difficile.

- La correzione è semplice: fare il test **per testata**

Osservazione di John — la conclusione

- Gli articoli di una testata **non sono prove indipendenti**
- Quindi l'unità giusta per il test sono le **439 testate**, non i 19.476 articoli

  E vale anche a parità di livello: non è solo perché l_5 è difficile.

- La correzione è semplice: fare il test **per testata**

Osservazione di John — la conclusione

- Gli articoli di una testata **non sono prove indipendenti**
- Quindi l'unità giusta per il test sono le **439 testate**, non i 19.476 articoli

  E vale anche a parità di livello: non è solo perché l_5 è difficile.

- La correzione è semplice: fare il test **per testata**

Problema 2 — cosa dice ChatGPT

- Nel paper l'errore è calcolato **separatamente per ogni orientamento**
- E si afferma che così è "**indipendente dalla frequenza delle classi**"
- In altre parole: calcolarlo separatamente dovrebbe renderlo **non influenzato** da come sono distribuiti i dati
- ChatGPT fa notare: è vero **solo a metà**

Problema 2 — cosa dice ChatGPT

- Nel paper l'errore è calcolato **separatamente per ogni orientamento**
- E si afferma che così è "**indipendente dalla frequenza delle classi**"
- In altre parole: calcolarlo separatamente dovrebbe renderlo **non influenzato** da come sono distribuiti i dati
- ChatGPT fa notare: è vero **solo a metà**

Problema 2 — cosa dice ChatGPT

- Nel paper l'errore è calcolato **separatamente per ogni orientamento**
- E si afferma che così è "**indipendente dalla frequenza delle classi**"
- In altre parole: calcolarlo separatamente dovrebbe renderlo **non influenzato** da come sono distribuiti i dati
- ChatGPT fa notare: è vero **solo a metà**

Problema 2 — cosa dice ChatGPT

- Nel paper l'errore è calcolato **separatamente per ogni orientamento**
- E si afferma che così è "**indipendente dalla frequenza delle classi**"
- In altre parole: calcolarlo separatamente dovrebbe renderlo **non influenzato** da come sono distribuiti i dati
- ChatGPT fa notare: è vero **solo a metà**

Problema 2 — perché solo a metà

- Calcolarlo separatamente toglie l'effetto della **dimensione** del gruppo (quanti articoli ha)
- Ma **non** toglie l'effetto di **quali livelli** ci sono dentro
- E il livello pesa tanto: l_1 facile, l_5 difficile
- Ogni orientamento ha un **mix di livelli diverso**

Problema 2 — perché solo a metà

- Calcolarlo separatamente toglie l'effetto della **dimensione** del gruppo (quanti articoli ha)
- Ma **non** toglie l'effetto di **quali livelli** ci sono dentro
- E il livello pesa tanto: l_1 facile, l_5 difficile
- Ogni orientamento ha un **mix di livelli diverso**

Problema 2 — perché solo a metà

- Calcolarlo separatamente toglie l'effetto della **dimensione** del gruppo (quanti articoli ha)
- Ma **non** toglie l'effetto di **quali livelli** ci sono dentro
- E il livello pesa tanto: l_1 facile, l_5 difficile
- Ogni orientamento ha un **mix di livelli diverso**

Problema 2 — perché solo a metà

- Calcolarlo separatamente toglie l'effetto della **dimensione** del gruppo (quanti articoli ha)
- Ma **non** toglie l'effetto di **quali livelli** ci sono dentro
- E il livello pesa tanto: l_1 facile, l_5 difficile
- Ogni orientamento ha un **mix di livelli diverso**

Problema 2 — l'esempio

- Slightly Right è quasi tutto l_1 (il livello facile)
- Quindi il suo errore basso dipende dal fatto che è **pieno di articoli facili**...

  ...non dal fatto che il modello "tratti meglio" la destra.
- Conclusione: la frase va riscritta — l'errore per orientamento **dipende ancora** dalla composizione dei livelli

Problema 2 — l'esempio

- Slightly Right è quasi tutto l_1 (il livello facile)
- Quindi il suo errore basso dipende dal fatto che è **pieno di articoli facili**...

  ...non dal fatto che il modello "tratti meglio" la destra.

- Conclusione: la frase va riscritta — l'errore per orientamento **dipende ancora** dalla composizione dei livelli

Problema 2 — l'esempio

- Slightly Right è quasi tutto l_1 (il livello facile)
- Quindi il suo errore basso dipende dal fatto che è **pieno di articoli facili**...

  ...non dal fatto che il modello "tratti meglio" la destra.

- Conclusione: la frase va riscritta — l'errore per orientamento **dipende ancora** dalla composizione dei livelli

Problema 2 — l'esempio

- Slightly Right è quasi tutto l_1 (il livello facile)
- Quindi il suo errore basso dipende dal fatto che è **pieno di articoli facili**...

  ...non dal fatto che il modello "tratti meglio" la destra.

- Conclusione: la frase va riscritta — l'errore per orientamento **dipende ancora** dalla composizione dei livelli

Problema 2 — commento di John

- ChatGPT dà per scontato che i livelli abbiano **difficoltà diverse**
- Ma questa cosa **non è mai dimostrata**
- Il modello sbaglia meno su l_1 — ma "**sbaglia meno**" non vuol dire "**è più facile**"

  Potrebbe sbagliare meno per tanti altri motivi: orientamento, tema, com'è fatto il dataset.
- Non ha senso dire che l_1 è più facile di l_2 solo perché il modello **sbaglia meno**

Problema 2 — commento di John

- ChatGPT dà per scontato che i livelli abbiano **difficoltà diverse**
- Ma questa cosa **non è mai dimostrata**
- Il modello sbaglia meno su l_1 — ma "**sbaglia meno**" non vuol dire "**è più facile**"

  Potrebbe sbagliare meno per tanti altri motivi: orientamento, tema, com'è fatto il dataset.
- Non ha senso dire che l_1 è più facile di l_2 solo perché il modello **sbaglia meno**

Problema 2 — commento di John

- ChatGPT dà per scontato che i livelli abbiano **difficoltà diverse**
- Ma questa cosa **non è mai dimostrata**
- Il modello sbaglia meno su l_1 — ma "**sbaglia meno**" non vuol dire "**è più facile**"

Potrebbe sbagliare meno per tanti altri motivi: orientamento, tema, com'è fatto il dataset.

- Non ha senso dire che l_1 è più facile di l_2 solo perché il modello **sbaglia meno**

Problema 2 — commento di John

- ChatGPT dà per scontato che i livelli abbiano **difficoltà diverse**
- Ma questa cosa **non è mai dimostrata**
- Il modello sbaglia meno su l_1 — ma "**sbaglia meno**" non vuol dire "**è più facile**"

  Potrebbe sbagliare meno per tanti altri motivi: orientamento, tema, com'è fatto il dataset.

- Non ha senso dire che l_1 è più facile di l_2 solo perché il modello **sbaglia meno**

Problema 2 — commento di John

- ChatGPT dà per scontato che i livelli abbiano **difficoltà diverse**
- Ma questa cosa **non è mai dimostrata**
- Il modello sbaglia meno su l_1 — ma "**sbaglia meno**" non vuol dire "**è più facile**"

  Potrebbe sbagliare meno per tanti altri motivi: orientamento, tema, com'è fatto il dataset.
- Non ha senso dire che l_1 è più facile di l_2 solo perché il modello **sbaglia meno**

Problema 3 — orientamento e affidabilità sono "incollati"

- Non solo intrecciati: in alcune combinazioni i dati **mancano del tutto**
- Nessuna testata far-right è in I_5; 142 su 207 slightly-right sono in I_1
- Quando due variabili sono così sovrapposte, **nessuna analisi** può separarle del tutto

Quindi "controllare per l'affidabilità" suona più sicuro di quanto sia.

Problema 3 — orientamento e affidabilità sono "incollati"

- Non solo intrecciati: in alcune combinazioni i dati **mancano del tutto**
- Nessuna testata far-right è in I_5; 142 su 207 slightly-right sono in I_1
- Quando due variabili sono così sovrapposte, **nessuna analisi** può separarle del tutto

Quindi "controllare per l'affidabilità" suona più sicuro di quanto sia.

Problema 3 — orientamento e affidabilità sono "incollati"

- Non solo intrecciati: in alcune combinazioni i dati **mancano del tutto**
- Nessuna testata far-right è in I_5; 142 su 207 slightly-right sono in I_1
- Quando due variabili sono così sovrapposte, **nessuna analisi** può separarle del tutto

Quindi "controllare per l'affidabilità" suona più sicuro di quanto sia.

Problema 3 — orientamento e affidabilità sono "incollati"

- Non solo intrecciati: in alcune combinazioni i dati **mancano del tutto**
- Nessuna testata far-right è in l_5; 142 su 207 slightly-right sono in l_1
- Quando due variabili sono così sovrapposte, **nessuna analisi** può separarle del tutto

Quindi "controllare per l'affidabilità" suona più sicuro di quanto sia.

Problema 4 — cosa dice ChatGPT

- Nel paper: gli estremi (far left/right) hanno **4–6 volte** più errori del gruppo di riferimento
- È un "odds ratio": quante volte più spesso sbagliano, a parità del resto
- ChatGPT: un numero così, **da solo**, non basta

Problema 4 — cosa dice ChatGPT

- Nel paper: gli estremi (far left/right) hanno **4–6 volte** più errori del gruppo di riferimento
- È un "odds ratio": quante volte più spesso sbagliano, a parità del resto
- ChatGPT: un numero così, **da solo**, non basta

Problema 4 — cosa dice ChatGPT

- Nel paper: gli estremi (far left/right) hanno **4–6 volte** più errori del gruppo di riferimento
- È un "odds ratio": quante volte più spesso sbagliano, a parità del resto
- ChatGPT: un numero così, **da solo**, non basta

Problema 4 — cosa manca

- Serve il suo **margine di incertezza** (intervallo di confidenza)

  Invece di "6 volte" potrebbe essere "tra 2 e 19 volte": molto incerto.

- E **quante testate** ci sono dietro ogni gruppo

  Se il "6 volte" nasce da 2–3 testate, può essere fortuna.

- E va calcolato **per testata**, non per articolo (come nel Problema 1)

Problema 4 — cosa manca

- Serve il suo **margine di incertezza** (intervallo di confidenza)

  Invece di "6 volte" potrebbe essere "tra 2 e 19 volte": molto incerto.

- E **quante testate** ci sono dietro ogni gruppo

  Se il "6 volte" nasce da 2–3 testate, può essere fortuna.

- E va calcolato **per testata**, non per articolo (come nel Problema 1)

Problema 4 — cosa manca

- Serve il suo **margine di incertezza** (intervallo di confidenza)

  Invece di "6 volte" potrebbe essere "tra 2 e 19 volte": molto incerto.

- E **quante testate** ci sono dietro ogni gruppo

  Se il "6 volte" nasce da 2–3 testate, può essere fortuna.

- E va calcolato **per testata**, non per articolo (come nel Problema 1)

Problema 4 — cosa manca

- Serve il suo **margine di incertezza** (intervallo di confidenza)

  Invece di "6 volte" potrebbe essere "tra 2 e 19 volte": molto incerto.

- E **quante testate** ci sono dietro ogni gruppo

  Se il "6 volte" nasce da 2–3 testate, può essere fortuna.

- E va calcolato **per testata**, non per articolo (come nel Problema 1)

Problema 4 — cosa manca

- Serve il suo **margine di incertezza** (intervallo di confidenza)

  Invece di "6 volte" potrebbe essere "tra 2 e 19 volte": molto incerto.

- E **quante testate** ci sono dietro ogni gruppo

  Se il "6 volte" nasce da 2–3 testate, può essere fortuna.

- E va calcolato **per testata**, non per articolo (come nel Problema 1)

Problema 5 — il χ^2 ha bisogno di abbastanza dati

- Il χ^2 confronta, in ogni casella, quello che **osserva** con quello che **si aspetterebbe**
- Funziona solo se in ogni casella c'è **abbastanza** roba (regola pratica: almeno $\sim$5 attesi)
- Con poche testate, alcune caselle sono quasi **vuote**

Problema 5 — il χ^2 ha bisogno di abbastanza dati

- Il χ^2 confronta, in ogni casella, quello che **osserva** con quello che **si aspetterebbe**
- Funziona solo se in ogni casella c'è **abbastanza** roba (regola pratica: almeno $\sim$5 attesi)
- Con poche testate, alcune caselle sono quasi **vuote**

Problema 5 — il χ^2 ha bisogno di abbastanza dati

- Il χ^2 confronta, in ogni casella, quello che **osserva** con quello che **si aspetterebbe**
- Funziona solo se in ogni casella c'è **abbastanza** roba (regola pratica: almeno $\sim$5 attesi)
- Con poche testate, alcune caselle sono quasi **vuote**

Problema 5 — nel nostro caso

- 439 testate divise in 5 orientamenti: **Far Left ne ha solo 20**
- Nella casella "Far Left sbagliate" ne aspettiamo appena $\sim$**6**: proprio al limite
- E guardando orientamento *e* livello insieme, alcune caselle sono **vuote**: nessuna far-right di livello 5, nessuna slightly-left di livello 1

Lì il χ^2 non ha più senso.

Problema 5 — nel nostro caso

- 439 testate divise in 5 orientamenti: **Far Left ne ha solo 20**
- Nella casella "Far Left sbagliate" ne aspettiamo appena $\sim$**6**: proprio al limite
- E guardando orientamento *e* livello insieme, alcune caselle sono **vuote**: nessuna far-right di livello 5, nessuna slightly-left di livello 1

  Lì il χ^2 non ha più senso.

Problema 5 — nel nostro caso

- 439 testate divise in 5 orientamenti: **Far Left ne ha solo 20**
- Nella casella "Far Left sbagliate" ne aspettiamo appena $\sim$**6**: proprio al limite
- E guardando orientamento *e* livello insieme, alcune caselle sono **vuote**: nessuna far-right di livello 5, nessuna slightly-left di livello 1

Lì il χ^2 non ha più senso.

Problema 5 — nel nostro caso

- 439 testate divise in 5 orientamenti: **Far Left ne ha solo 20**
- Nella casella "Far Left sbagliate" ne aspettiamo appena $\sim$**6**: proprio al limite
- E guardando orientamento *e* livello insieme, alcune caselle sono **vuote**: nessuna far-right di livello 5, nessuna slightly-left di livello 1

  Lì il χ^2 non ha più senso.

Problema 5 — la soluzione

- Invece di fidarsi dell'approssimazione, si **mescolano a caso** le etichette tante volte (es. 10.000)
- Si guarda quanto spesso il puro caso dà un legame forte come il nostro

  Se quasi mai → il nostro legame è vero.
- Nessuna approssimazione → funziona **anche con pochi dati** ("test esatto" o "di permutazione")

Problema 5 — la soluzione

- Invece di fidarsi dell'approssimazione, si **mescolano a caso** le etichette tante volte (es. 10.000)
- Si guarda quanto spesso il puro caso dà un legame forte come il nostro

  Se quasi mai → il nostro legame è vero.
- Nessuna approssimazione → funziona **anche con pochi dati** ("test esatto" o "di permutazione")

Problema 5 — la soluzione

- Invece di fidarsi dell'approssimazione, si **mescolano a caso** le etichette tante volte (es. 10.000)
- Si guarda quanto spesso il puro caso dà un legame forte come il nostro

  Se quasi mai → il nostro legame è vero.
- Nessuna approssimazione → funziona **anche con pochi dati** ("test esatto" o "di permutazione")

Problema 5 — la soluzione

- Invece di fidarsi dell'approssimazione, si **mescolano a caso** le etichette tante volte (es. 10.000)
- Si guarda quanto spesso il puro caso dà un legame forte come il nostro

  Se quasi mai → il nostro legame è vero.
- Nessuna approssimazione → funziona **anche con pochi dati** ("test esatto" o "di permutazione")

Problema 6 — la MED guarda solo gli errori

- La MED misura la direzione dell'errore **solo quando il modello sbaglia**
- Non tiene conto di **quanto spesso** sbaglia

Problema 6 — la MED guarda solo gli errori

- La MED misura la direzione dell'errore **solo quando il modello sbaglia**
- Non tiene conto di **quanto spesso** sbaglia

Problema 6 — l'esempio

- Gruppo A: sbaglia il **70%** degli articoli, e quando sbaglia sovrastima di mezzo livello (MED $+0.5$)
- Gruppo B: sbaglia il **10%**, con la stessa MED $+0.5$
- Stessa MED, ma l'effetto totale è **diversissimo**: A viene spinto in alto 7 volte su 10, B solo 1 su 10

  Nel paper gli estremi sbagliano il 60–72%, i non-labelled il 30%: confrontare le loro MED inganna.

- Soluzione: riportare anche la direzione media su **tutti** gli articoli

Problema 6 — l'esempio

- Gruppo A: sbaglia il **70%** degli articoli, e quando sbaglia sovrastima di mezzo livello (MED $+0.5$)
- Gruppo B: sbaglia il **10%**, con la stessa MED $+0.5$
- Stessa MED, ma l'effetto totale è **diversissimo**: A viene spinto in alto 7 volte su 10, B solo 1 su 10

  Nel paper gli estremi sbagliano il 60–72%, i non-labelled il 30%: confrontare le loro MED inganna.

- Soluzione: riportare anche la direzione media su **tutti** gli articoli

Problema 6 — l'esempio

- Gruppo A: sbaglia il **70%** degli articoli, e quando sbaglia sovrastima di mezzo livello (MED $+0.5$)
- Gruppo B: sbaglia il **10%**, con la stessa MED $+0.5$
- Stessa MED, ma l'effetto totale è **diversissimo**: A viene spinto in alto 7 volte su 10, B solo 1 su 10

Nel paper gli estremi sbagliano il 60–72%, i non-labelled il 30%: confrontare le loro MED inganna.

- Soluzione: riportare anche la direzione media su **tutti** gli articoli

Problema 6 — l'esempio

- Gruppo A: sbaglia il **70%** degli articoli, e quando sbaglia sovrastima di mezzo livello (MED $+0.5$)
- Gruppo B: sbaglia il **10%**, con la stessa MED $+0.5$
- Stessa MED, ma l'effetto totale è **diversissimo**: A viene spinto in alto 7 volte su 10, B solo 1 su 10

  Nel paper gli estremi sbagliano il 60–72%, i non-labelled il 30%: confrontare le loro MED inganna.

- Soluzione: riportare anche la direzione media su **tutti** gli articoli

Problema 6 — l'esempio

- Gruppo A: sbaglia il **70%** degli articoli, e quando sbaglia sovrastima di mezzo livello (MED $+0.5$)
- Gruppo B: sbaglia il **10%**, con la stessa MED $+0.5$
- Stessa MED, ma l'effetto totale è **diversissimo**: A viene spinto in alto 7 volte su 10, B solo 1 su 10

  Nel paper gli estremi sbagliano il 60–72%, i non-labelled il 30%: confrontare le loro MED inganna.

- Soluzione: riportare anche la direzione media su **tutti** gli articoli

Problema 7 — la direzione è “obbligata” dai bordi

- Se una testata è in l_1 (il più basso), l’errore può solo andare **verso l’alto**; se è in l_5, solo verso il basso
- Far-left e far-right stanno quasi tutti nei livelli bassi $\rightarrow$ i loro errori sono “per forza” positivi

Quindi la sovrastima degli estremi può dipendere dalla composizione, non dall’orientamento.

Problema 7 — la direzione è “obbligata” dai bordi

- Se una testata è in l_1 (il più basso), l’errore può solo andare **verso l’alto**; se è in l_5, solo verso il basso
- Far-left e far-right stanno quasi tutti nei livelli bassi $\rightarrow$ i loro errori sono “per forza” positivi

Quindi la sovrastima degli estremi può dipendere dalla composizione, non dall’orientamento.

Problema 7 — la direzione è “obbligata” dai bordi

- Se una testata è in l_1 (il più basso), l’errore può solo andare **verso l’alto**; se è in l_5, solo verso il basso
- Far-left e far-right stanno quasi tutti nei livelli bassi $\rightarrow$ i loro errori sono “per forza” positivi

Quindi la sovrastima degli estremi può dipendere dalla composizione, non dall’orientamento.

Problema 8 — la frase sul deployment

- Nel paper: *"the disparity would appear in deployment whatever its mechanism"*
- Vuol dire: la disparità si vedrà comunque quando il modello è usato davvero, **qualunque** ne sia la causa
- ChatGPT: non possiamo saperlo — dipende da quali testate, dal cambio di dominio, da come si aggrega
- Meglio: "il modello **potrebbe** riprodurla"

Problema 8 — la frase sul deployment

- Nel paper: *"the disparity would appear in deployment whatever its mechanism"*
- Vuol dire: la disparità si vedrà comunque quando il modello è usato davvero, **qualunque** ne sia la causa
- ChatGPT: non possiamo saperlo — dipende da quali testate, dal cambio di dominio, da come si aggrega
- Meglio: "il modello **potrebbe** riprodurla"

Problema 8 — la frase sul deployment

- Nel paper: *"the disparity would appear in deployment whatever its mechanism"*
- Vuol dire: la disparità si vedrà comunque quando il modello è usato davvero, **qualunque** ne sia la causa
- ChatGPT: non possiamo saperlo — dipende da quali testate, dal cambio di dominio, da come si aggrega
- Meglio: "il modello **potrebbe** riprodurla"

Problema 8 — la frase sul deployment

- Nel paper: *"the disparity would appear in deployment whatever its mechanism"*
- Vuol dire: la disparità si vedrà comunque quando il modello è usato davvero, **qualunque** ne sia la causa
- ChatGPT: non possiamo saperlo — dipende da quali testate, dal cambio di dominio, da come si aggrega
- Meglio: "il modello **potrebbe** riprodurla"

Problema 8 — la forza del legame (Cramér's V)

- Nel paper l'effetto è definito "**small-to-moderate**" (piccolo-moderato)
- Cramér's V misura la **forza** del legame (lo abbiamo visto)
- ChatGPT: le soglie "piccolo/moderato" **non sono universali** → meglio "associazione non trascurabile"

(minore) "ground truth" → "reference labels": tema politicamente sensibile.

Problema 8 — la forza del legame (Cramér's V)

- Nel paper l'effetto è definito "**small-to-moderate**" (piccolo-moderato)
- Cramér's V misura la **forza** del legame (lo abbiamo visto)
- ChatGPT: le soglie "piccolo/moderato" **non sono universali** → meglio "associazione non trascurabile"

(minore) "ground truth" → "reference labels": tema politicamente sensibile.

Problema 8 — la forza del legame (Cramér's V)

- Nel paper l'effetto è definito "**small-to-moderate**" (piccolo-moderato)
- Cramér's V misura la **forza** del legame (lo abbiamo visto)
- ChatGPT: le soglie "piccolo/moderato" **non sono universali** → meglio "associazione non trascurabile"

(minore) "ground truth" → "reference labels": tema politicamente sensibile.

Problema 8 — la forza del legame (Cramér's V)

- Nel paper l'effetto è definito "**small-to-moderate**" (piccolo-moderato)
- Cramér's V misura la **forza** del legame (lo abbiamo visto)
- ChatGPT: le soglie "piccolo/moderato" **non sono universali** $\rightarrow$ meglio "associazione non trascurabile"

(minore) "ground truth" $\rightarrow$ "reference labels": tema politicamente sensibile.

Risposta di John a ChatGPT (1)

- L'affidabilità l'abbiamo **stratificata** nei fold (tenuta sotto controllo)
- L'orientamento invece **no**: è lasciato a caso
- E nel dataset orientamento $\times$ livello è **sbilanciatissimo**
- Alcune combinazioni **non esistono**: nessuna slightly-left di livello 1, nessuna far-right di livello 5

Risposta di John a ChatGPT (1)

- L'affidabilità l'abbiamo **stratificata** nei fold (tenuta sotto controllo)
- L'orientamento invece **no**: è lasciato a caso
- E nel dataset orientamento $\times$ livello è **sbilanciatissimo**
- Alcune combinazioni **non esistono**: nessuna slightly-left di livello 1, nessuna far-right di livello 5

Risposta di John a ChatGPT (1)

- L'affidabilità l'abbiamo **stratificata** nei fold (tenuta sotto controllo)
- L'orientamento invece **no**: è lasciato a caso
- E nel dataset orientamento $\times$ livello è **sbilanciatissimo**
- Alcune combinazioni **non esistono**: nessuna slightly-left di livello 1, nessuna far-right di livello 5

Risposta di John a ChatGPT (1)

- L'affidabilità l'abbiamo **stratificata** nei fold (tenuta sotto controllo)
- L'orientamento invece **no**: è lasciato a caso
- E nel dataset orientamento $\times$ livello è **sbilanciatissimo**
- Alcune combinazioni **non esistono**: nessuna slightly-left di livello 1, nessuna far-right di livello 5

Risposta di John a ChatGPT (2)

- Quando dividiamo in fold, a volte il modello vede **zero** esempi di una combinazione che poi deve indovinare
- Es. (fold 1): nessun Far Left di livello 1 o 3 in addestramento, ma viene testato proprio su quelli

  Naturale che sbagli: non li ha mai visti.
- Quindi parte di questi "errori politici" è un **artefatto** del dataset e dei fold

Risposta di John a ChatGPT (2)

- Quando dividiamo in fold, a volte il modello vede **zero** esempi di una combinazione che poi deve indovinare
- Es. (fold 1): nessun Far Left di livello 1 o 3 in addestramento, ma viene testato proprio su quelli

  Naturale che sbagli: non li ha mai visti.
- Quindi parte di questi "errori politici" è un **artefatto** del dataset e dei fold

Risposta di John a ChatGPT (2)

- Quando dividiamo in fold, a volte il modello vede **zero** esempi di una combinazione che poi deve indovinare
- Es. (fold 1): nessun Far Left di livello 1 o 3 in addestramento, ma viene testato proprio su quelli

  Naturale che sbagli: non li ha mai visti.
- Quindi parte di questi "errori politici" è un **artefatto** del dataset e dei fold

Risposta di John a ChatGPT (2)

- Quando dividiamo in fold, a volte il modello vede **zero** esempi di una combinazione che poi deve indovinare
- Es. (fold 1): nessun Far Left di livello 1 o 3 in addestramento, ma viene testato proprio su quelli

  Naturale che sbagli: non li ha mai visti.
- Quindi parte di questi "errori politici" è un **artefatto** del dataset e dei fold

Risposta di John a ChatGPT (3)

- Questa analisi del bias è **molto specifica**: vale per *questo* dataset, *questi* modelli, *questo* training
- Non è un risultato generale sul "comportamento politico" dei modelli
- Se la teniamo, va detto **chiaramente**

È un po' un'analisi fine a sé stessa.

Risposta di John a ChatGPT (3)

- Questa analisi del bias è **molto specifica**: vale per *questo* dataset, *questi* modelli, *questo* training
- Non è un risultato generale sul "comportamento politico" dei modelli
- Se la teniamo, va detto **chiaramente**

È un po' un'analisi fine a sé stessa.

Risposta di John a ChatGPT (3)

- Questa analisi del bias è **molto specifica**: vale per *questo* dataset, *questi* modelli, *questo* training
- Non è un risultato generale sul "comportamento politico" dei modelli
- Se la teniamo, va detto **chiaramente**

È un po' un'analisi fine a sé stessa.

Risposta di John a ChatGPT (3)

- Questa analisi del bias è **molto specifica**: vale per *questo* dataset, *questi* modelli, *questo* training
- Non è un risultato generale sul "comportamento politico" dei modelli
- Se la teniamo, va detto **chiaramente**

  È un po' un'analisi fine a sé stessa.

Fabio × Claude — (1) idee e review

- Tre parti: idee sui modelli, una review completa, un'analisi quantitativa del bias
- **Modelli**: gli LLM grandi "conoscono" le testate per nome (contaminazione) → i piccoli fine-tuned sono lo strumento giusto; baseline LLM con **mascheramento dei nomi**
- Idee nuove: LLM come **estrattore di feature** + classificatore; **embeddings + multiple-instance learning**
- **Review** (major revision): baseline deboli, aggregazione non studiata, incertezza mancante, bias confuso

Fabio × Claude — (1) idee e review

- Tre parti: idee sui modelli, una review completa, un'analisi quantitativa del bias
- **Modelli**: gli LLM grandi "conoscono" le testate per nome (contaminazione) → i piccoli fine-tuned sono lo strumento giusto; baseline LLM con **mascheramento dei nomi**
- Idee nuove: LLM come **estrattore di feature** + classificatore; **embeddings + multiple-instance learning**
- **Review** (major revision): baseline deboli, aggregazione non studiata, incertezza mancante, bias confuso

Fabio × Claude — (1) idee e review

- Tre parti: idee sui modelli, una review completa, un'analisi quantitativa del bias
- **Modelli**: gli LLM grandi "conoscono" le testate per nome (contaminazione) → i piccoli fine-tuned sono lo strumento giusto; baseline LLM con **mascheramento dei nomi**
- Idee nuove: LLM come **estrattore di feature** + classificatore; **embeddings + multiple-instance learning**
- **Review** (major revision): baseline deboli, aggregazione non studiata, incertezza mancante, bias confuso

Fabio × Claude — (1) idee e review

- Tre parti: idee sui modelli, una review completa, un'analisi quantitativa del bias
- **Modelli**: gli LLM grandi "conoscono" le testate per nome (contaminazione) → i piccoli fine-tuned sono lo strumento giusto; baseline LLM con **mascheramento dei nomi**
- Idee nuove: LLM come **estrattore di feature** + classificatore; **embeddings + multiple-instance learning**
- **Review** (major revision): baseline deboli, aggregazione non studiata, incertezza mancante, bias confuso

Fabio × Claude — (2) l'analisi del bias

- Dalle matrici di confusione ha ricostruito l'errore per **(livello × orientamento)**
- "Slightly Left sottostimata" è un **artefatto di composizione** → va tolta
- "Gli estremi sbagliano di più" regge, ma perché sono la **minoranza** del loro livello
- Il modello ha imparato l'orientamento come **scorciatoia** → spiega anche il nullo di Mistral
- È la riformulazione più forte della sezione bias

Fabio × Claude — (2) l'analisi del bias

- Dalle matrici di confusione ha ricostruito l'errore per **(livello × orientamento)**
- "Slightly Left sottostimata" è un **artefatto di composizione** → va tolta
- "Gli estremi sbagliano di più" regge, ma perché sono la **minoranza** del loro livello
- Il modello ha imparato l'orientamento come **scorciatoia** → spiega anche il nullo di Mistral
- È la riformulazione più forte della sezione bias

Fabio × Claude — (2) l'analisi del bias

- Dalle matrici di confusione ha ricostruito l'errore per **(livello × orientamento)**
- "Slightly Left sottostimata" è un **artefatto di composizione** → va tolta
- "Gli estremi sbagliano di più" regge, ma perché sono la **minoranza** del loro livello
- Il modello ha imparato l'orientamento come **scorciatoia** → spiega anche il nullo di Mistral
- È la riformulazione più forte della sezione bias

Fabio × Claude — (2) l'analisi del bias

- Dalle matrici di confusione ha ricostruito l'errore per **(livello × orientamento)**
- "Slightly Left sottostimata" è un **artefatto di composizione** → va tolta
- "Gli estremi sbagliano di più" regge, ma perché sono la **minoranza** del loro livello
- Il modello ha imparato l'orientamento come **scorciatoia** → spiega anche il nullo di Mistral
- È la riformulazione più forte della sezione bias

Fabio × Claude — (2) l'analisi del bias

- Dalle matrici di confusione ha ricostruito l'errore per **(livello × orientamento)**
- "Slightly Left sottostimata" è un **artefatto di composizione** → va tolta
- "Gli estremi sbagliano di più" regge, ma perché sono la **minoranza** del loro livello
- Il modello ha imparato l'orientamento come **scorciatoia** → spiega anche il nullo di Mistral
- È la riformulazione più forte della sezione bias

Cosa hanno in comune

- Entrambe convergono col Revisore 1: il nodo è il **confondimento** leaning/reliability e il **clustering**
- Fabio va oltre: lo **quantifica** e propone la riscrittura
- La sezione bias è il punto che decide il nuovo paper

Cosa hanno in comune

- Entrambe convergono col Revisore 1: il nodo è il **confondimento** leaning/reliability e il **clustering**
- Fabio va oltre: lo **quantifica** e propone la riscrittura
- La sezione bias è il punto che decide il nuovo paper

Cosa hanno in comune

- Entrambe convergono col Revisore 1: il nodo è il **confondimento** leaning/reliability e il **clustering**
- Fabio va oltre: lo **quantifica** e propone la riscrittura
- La sezione bias è il punto che decide il nuovo paper