Verso Web Science 2027

Riprendere il paper bocciato: recap del lavoro e prossimi passi

Riunione di gruppo

IMT Lucca & IIT-CNR Pisa

Recap del paper bocciato

non la versione sottomessa a IR for Good

Dati

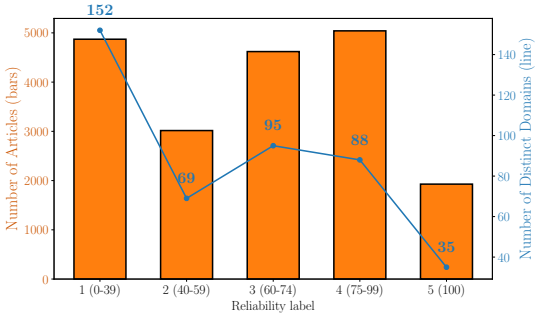
- Scraping con **newspaper3k**
- 439 editori, 19.476 articoli politici in inglese
- Etichette **NewsGuard**: 5 livelli l_1–l_5 (da 0–100)
- Ogni articolo **eredita** l'etichetta del suo editore

Dati

- Scraping con **newspaper3k**
- 439 editori, 19.476 articoli politici in inglese
- Etichette **NewsGuard**: 5 livelli l_1–l_5 (da 0–100)
- Ogni articolo **eredita** l'etichetta del suo editore

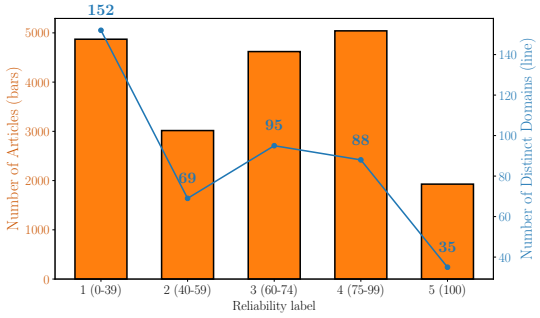
Dati

- Scraping con **newspaper3k**
- 439 editori, 19.476 articoli politici in inglese
- Etichette **NewsGuard**: 5 livelli l_1–l_5 (da 0–100)
- Ogni articolo **eredita** l'etichetta del suo editore



Dati

- Scraping con **newspaper3k**
- 439 editori, 19.476 articoli politici in inglese
- Etichette **NewsGuard**: 5 livelli l_1–l_5 (da 0–100)
- Ogni articolo **eredita** l'etichetta del suo editore



Classificazione — livello articolo

- Quattro transformer: **BERT, RoBERTa, Llama, Mistral**
- Encoder full fine-tuning, decoder con **LoRA**
- Input **256 token** (1024 per Mistral)
- Split **publisher-disjoint**: editori di test mai visti

Classificazione — livello articolo

- Quattro transformer: **BERT, RoBERTa, Llama, Mistral**
- Encoder full fine-tuning, decoder con **LoRA**
- Input **256 token** (1024 per Mistral)
- Split **publisher-disjoint**: editori di test mai visti

Classificazione — livello articolo

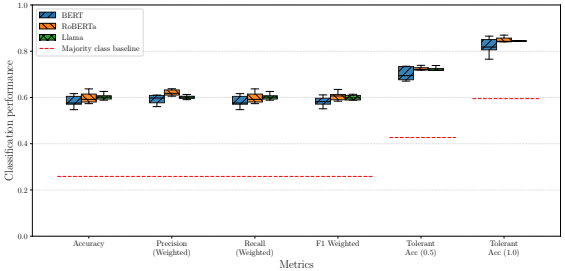
- Quattro transformer: **BERT, RoBERTa, Llama, Mistral**
- Encoder full fine-tuning, decoder con **LoRA**
- Input **256 token** (1024 per Mistral)
- Split **publisher-disjoint**: editori di test mai visti

Classificazione — livello articolo

- Quattro transformer: **BERT, RoBERTa, Llama, Mistral**
- Encoder full fine-tuning, decoder con **LoRA**
- Input **256 token** (1024 per Mistral)
- Split **publisher-disjoint**: editori di test mai visti

Classificazione — livello articolo

- Quattro transformer: **BERT, RoBERTa, Llama, Mistral**
- Encoder full fine-tuning, decoder con **LoRA**
- Input **256 token** (1024 per Mistral)
- Split **publisher-disjoint**: editori di test mai visti



Aggregazione — livello editore

- Dall'articolo all'editore con **majority voting**
- Si usano **tutti** gli articoli della testata: nessun cap in aggregazione (fino a 200, mediana $\sim$34)
- Valutazione su editori **mai visti** in addestramento

Aggregazione — livello editore

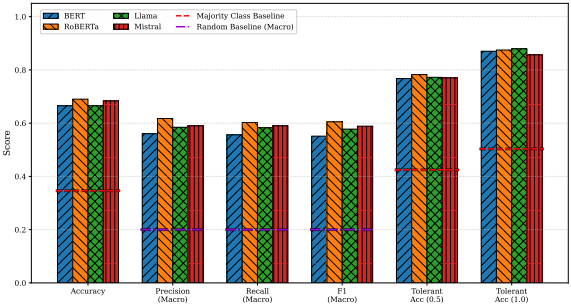
- Dall'articolo all'editore con **majority voting**
- Si usano **tutti** gli articoli della testata: nessun cap in aggregazione (fino a 200, mediana $\sim$34)
- Valutazione su editori **mai visti** in addestramento

Aggregazione — livello editore

- Dall'articolo all'editore con **majority voting**
- Si usano **tutti** gli articoli della testata: nessun cap in aggregazione (fino a 200, mediana $\sim$34)
- Valutazione su editori **mai visti** in addestramento

Aggregazione — livello editore

- Dall'articolo all'editore con **majority voting**
- Si usano **tutti** gli articoli della testata: nessun cap in aggregazione (fino a 200, mediana $\sim$34)
- Valutazione su editori **mai visti** in addestramento



Perché analizziamo gli errori

- Oltre alle metriche aggregate, vogliamo capire **come** e **perché** i modelli sbagliano

  "Beyond aggregate performance, we investigate how and why models fail."

- Obiettivo: trovare **debolezze strutturali** — su quali livelli sbaglia e se sovra/sottostima

  "To detect structural weaknesses. . . "

Perché analizziamo gli errori

- Oltre alle metriche aggregate, vogliamo capire **come** e **perché** i modelli sbagliano

  "Beyond aggregate performance, we investigate how and why models fail."

- Obiettivo: trovare **debolezze strutturali** — su quali livelli sbaglia e se sovra/sottostima

  "To detect structural weaknesses. . . "

Perché analizziamo gli errori

- Oltre alle metriche aggregate, vogliamo capire **come** e **perché** i modelli sbagliano

  "Beyond aggregate performance, we investigate how and why models fail."

- Obiettivo: trovare **debolezze strutturali** — su quali livelli sbaglia e se sovra/sottostima

  "To detect structural weaknesses. . . "

Perché analizziamo gli errori

- Oltre alle metriche aggregate, vogliamo capire **come** e **perché** i modelli sbagliano

  "Beyond aggregate performance, we investigate how and why models fail."

- Obiettivo: trovare **debolezze strutturali** — su quali livelli sbaglia e se sovra/sottostima

  "To detect structural weaknesses. . . "

Analisi dell'errore — per livello

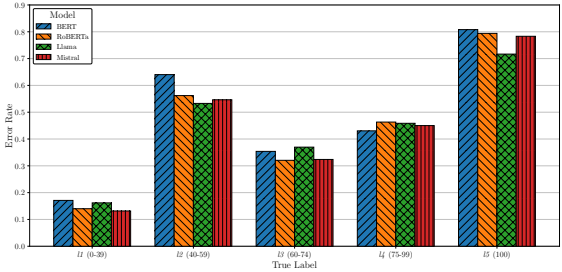
- **Error rate** per ogni livello di affidabilità
- l_1: errore più **basso** ($< 20\%$)
- l_5: errore più **alto** ($> 70\%$), spesso confuso con l_4
- l_2 sopra il 50%, l_3 intorno al 35%

Sappiamo solo dove sbaglia di più o di meno, non perché.

Analisi dell'errore — per livello

- **Error rate** per ogni livello di affidabilità
- l_1: errore più **basso** ($< 20\%$)
- l_5: errore più **alto** ($> 70\%$), spesso confuso con l_4
- l_2 sopra il 50%, l_3 intorno al 35%

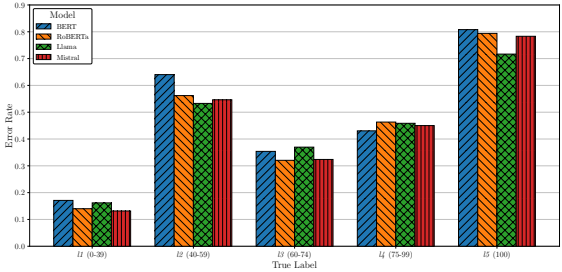
Sappiamo solo dove sbaglia di più o di meno, non perché.



Analisi dell'errore — per livello

- **Error rate** per ogni livello di affidabilità
- l_1: errore più **basso** ($< 20\%$)
- l_5: errore più **alto** ($> 70\%$), spesso confuso con l_4
- l_2 sopra il 50%, l_3 intorno al 35%

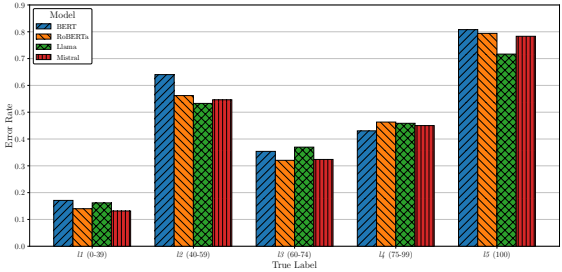
Sappiamo solo dove sbaglia di più o di meno, non perché.



Analisi dell'errore — per livello

- **Error rate** per ogni livello di affidabilità
- l_1: errore più **basso** ($< 20\%$)
- l_5: errore più **alto** ($> 70\%$), spesso confuso con l_4
- l_2 sopra il 50%, l_3 intorno al 35%

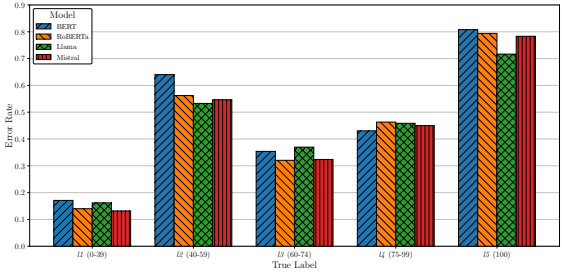
Sappiamo solo dove sbaglia di più o di meno, non perché.



Analisi dell'errore — per livello

- **Error rate** per ogni livello di affidabilità
- l_1: errore più **basso** ($< 20\%$)
- l_5: errore più **alto** ($> 70\%$), spesso confuso con l_4
- l_2 sopra il 50%, l_3 intorno al 35%

Sappiamo solo dove sbaglia di più o di meno, non perché.

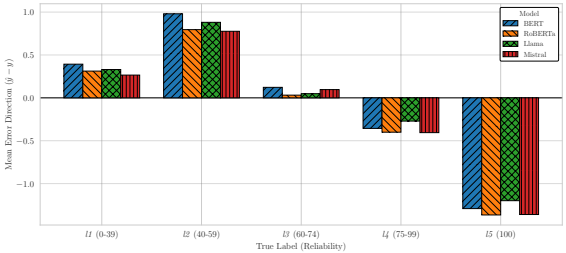


Analisi dell'errore — direzione

- **Mean Error Direction**: l'errore *sovrastima* $(+)$ o *sottostima* $(-)$ l'affidabilità
- Livelli **bassi sovrastimati**, livelli **alti sottostimati**
- Gli errori "tirano verso il **centro**" della scala

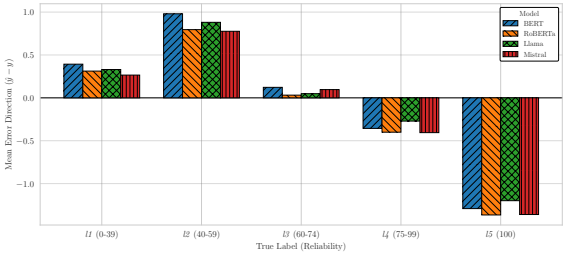
Analisi dell'errore — direzione

- **Mean Error Direction**: l'errore *sovrastima* (+) o *sottostima* (−) l'affidabilità
- Livelli **bassi sovrastimati**, livelli **alti sottostimati**
- Gli errori "tirano verso il **centro**" della scala



Analisi dell'errore — direzione

- **Mean Error Direction**: l'errore *sovrastima* (+) o *sottostima* (−) l'affidabilità
- Livelli **bassi sovrastimati**, livelli **alti sottostimati**
- Gli errori "tirano verso il **centro**" della scala



Perché analizziamo il bias politico

- Vogliamo sapere se il modello **tratta allo stesso modo** tutto lo spettro politico, o se **penalizza** certi orientamenti

  "...determine if the models exhibit political bias...whether the models treat all sides of the political spectrum equally or if they penalize specific orientations."

- Serve una valutazione **bias-aware**: un sistema in uso con bias politico può fare danni

  "...the need for bias-aware evaluation protocols..."

Perché analizziamo il bias politico

- Vogliamo sapere se il modello **tratta allo stesso modo** tutto lo spettro politico, o se **penalizza** certi orientamenti

  "...determine if the models exhibit political bias...whether the models treat all sides of the political spectrum equally or if they penalize specific orientations."

- Serve una valutazione **bias-aware**: un sistema in uso con bias politico può fare danni

  "...the need for bias-aware evaluation protocols..."

Perché analizziamo il bias politico

- Vogliamo sapere se il modello **tratta allo stesso modo** tutto lo spettro politico, o se **penalizza** certi orientamenti

  "...determine if the models exhibit political bias...whether the models treat all sides of the political spectrum equally or if they penalize specific orientations."

- Serve una valutazione **bias-aware**: un sistema in uso con bias politico può fare danni

  "...the need for bias-aware evaluation protocols..."

Perché analizziamo il bias politico

- Vogliamo sapere se il modello **tratta allo stesso modo** tutto lo spettro politico, o se **penalizza** certi orientamenti

  "...determine if the models exhibit political bias...whether the models treat all sides of the political spectrum equally or if they penalize specific orientations."

- Serve una valutazione **bias-aware**: un sistema in uso con bias politico può fare danni

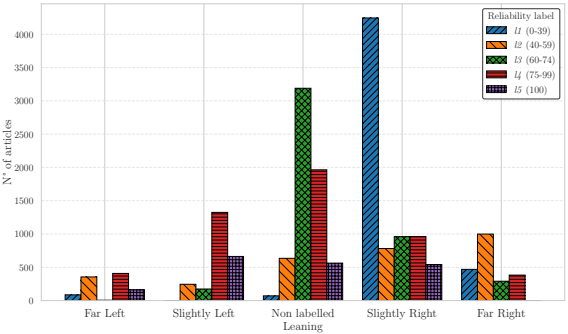
  "...the need for bias-aware evaluation protocols..."

Bias politico — distribuzione dei dati

- Orientamento ereditato dall'editore (analisi *a posteriori*)
- Dentro ogni orientamento, come si distribuiscono i livelli
- Distribuzione molto **sbilanciata** (proprietà del sistema mediatico)
- Per questo gli error rate si calcolano **classe per classe**

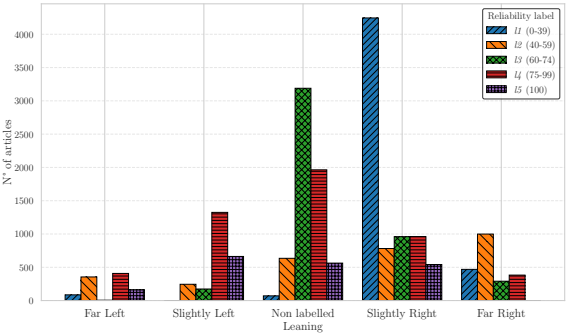
Bias politico — distribuzione dei dati

- Orientamento ereditato dall'editore (analisi *a posteriori*)
- Dentro ogni orientamento, come si distribuiscono i livelli
- Distribuzione molto **sbilanciata** (proprietà del sistema mediatico)
- Per questo gli error rate si calcolano **classe per classe**



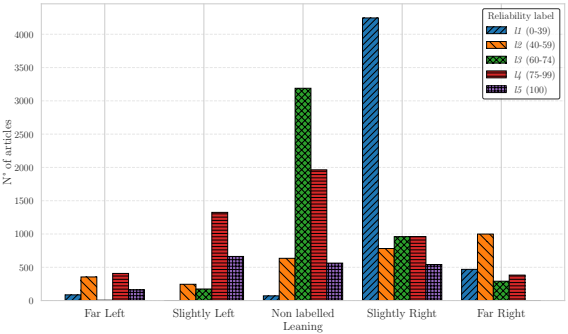
Bias politico — distribuzione dei dati

- Orientamento ereditato dall'editore (analisi *a posteriori*)
- Dentro ogni orientamento, come si distribuiscono i livelli
- Distribuzione molto **sbilanciata** (proprietà del sistema mediatico)
- Per questo gli error rate si calcolano **classe per classe**



Bias politico — distribuzione dei dati

- Orientamento ereditato dall'editore (analisi *a posteriori*)
- Dentro ogni orientamento, come si distribuiscono i livelli
- Distribuzione molto **sbilanciata** (proprietà del sistema mediatico)
- Per questo gli error rate si calcolano **classe per classe**

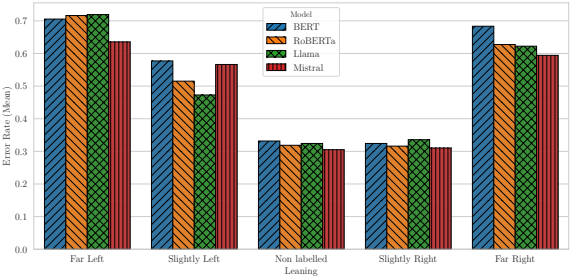


Bias politico — error rate

- **Error rate** per orientamento politico
- Gli estremi (**far left**, **far right**) sbagliano molto di più
- Slightly right e non labelled sbagliano **meno**

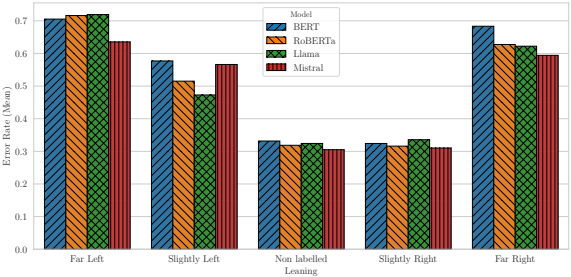
Bias politico — error rate

- **Error rate** per orientamento politico
- Gli estremi (**far left**, **far right**) sbagliano molto di più
- Slightly right e non labelled sbagliano **meno**



Bias politico — error rate

- **Error rate** per orientamento politico
- Gli estremi (**far left**, **far right**) sbagliano molto di più
- Slightly right e non labelled sbagliano **meno**

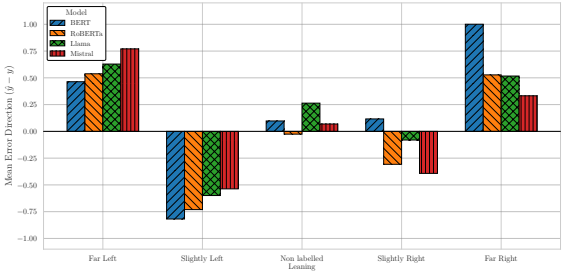


Bias politico — direzione dell'errore

- **Mean Error Direction** per orientamento
- Estremi (far left, far right) **sovrastimati**
- Slightly left **sottostimato**
- Slightly right e non labelled: deviazioni piccole

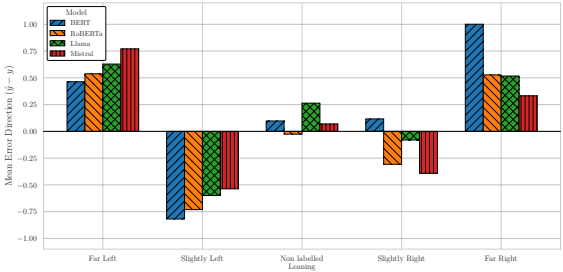
Bias politico — direzione dell'errore

- **Mean Error Direction** per orientamento
- Estremi (far left, far right) **sovrastimati**
- Slightly left **sottostimato**
- Slightly right e non labelled: deviazioni piccole



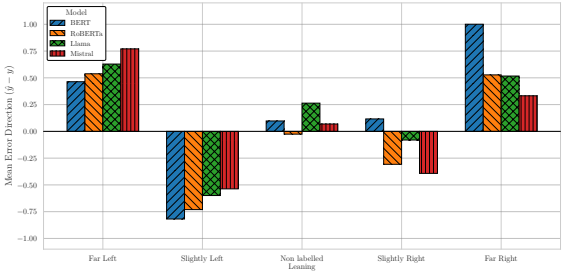
Bias politico — direzione dell'errore

- **Mean Error Direction** per orientamento
- Estremi (far left, far right) **sovrastimati**
- Slightly left **sottostimato**
- Slightly right e non labelled: deviazioni piccole



Bias politico — direzione dell'errore

- **Mean Error Direction** per orientamento
- Estremi (far left, far right) **sovrastimati**
- Slightly left **sottostimato**
- Slightly right e non labelled: deviazioni piccole



È un vero legame o è un caso?

- Vediamo error rate diversi tra gli orientamenti.
- Ma potrebbe essere solo **rumore** dei dati.
- Serve un **test statistico** che dica: questo legame è reale?

Strumento usato: il **test del chi-quadro (χ^2) di indipendenza**.

È un vero legame o è un caso?

- Vediamo error rate diversi tra gli orientamenti.
- Ma potrebbe essere solo **rumore** dei dati.
- Serve un **test statistico** che dica: questo legame è reale?

Strumento usato: il **test del chi-quadro (χ^2) di indipendenza**.

È un vero legame o è un caso?

- Vediamo error rate diversi tra gli orientamenti.
- Ma potrebbe essere solo **rumore** dei dati.
- Serve un **test statistico** che dica: questo legame è reale?

Strumento usato: il **test del chi-quadro (χ^2) di indipendenza**.

È un vero legame o è un caso?

- Vediamo error rate diversi tra gli orientamenti.
- Ma potrebbe essere solo **rumore** dei dati.
- Serve un **test statistico** che dica: questo legame è reale?

Strumento usato: il **test del chi-quadro (χ^2) di indipendenza**.

Passo 1 — mettiamo gli errori in tabella

- Per ogni orientamento contiamo **giusti** e **sbagliati**
- È la **tabella di contingenza**
- Agli estremi gli sbagliati superano i giusti

Orientamento	Giusti	Sbagliati
Far Left	299	716
Slightly Left	1018	1389
Non labelled	4292	2130
Slightly Right	5062	2428
Far Right	678	1464

(esempio: BERT)

Passo 1 — mettiamo gli errori in tabella

- Per ogni orientamento contiamo **giusti** e **sbagliati**
- È la **tabella di contingenza**
- Agli estremi gli sbagliati superano i giusti

Orientamento	**Giusti**	**Sbagliati**
Far Left	299	716
Slightly Left	1018	1389
Non labelled	4292	2130
Slightly Right	5062	2428
Far Right	678	1464

(esempio: BERT)

Passo 1 — mettiamo gli errori in tabella

- Per ogni orientamento contiamo **giusti** e **sbagliati**
- È la **tabella di contingenza**
- Agli estremi gli sbagliati superano i giusti

Orientamento	**Giusti**	**Sbagliati**
Far Left	299	716
Slightly Left	1018	1389
Non labelled	4292	2130
Slightly Right	5062	2428
Far Right	678	1464

(esempio: BERT)

Passo 2 — l'idea del chi-quadro

- Immaginiamo che l'orientamento **non c'entri** con gli errori.
- Allora ogni gruppo dovrebbe sbagliare **nella stessa proporzione** (circa la media, $\sim$42%).
- Il χ^2 misura **quanto** gli errori *osservati* si allontanano da questo scenario "senza legame".
- Più grande è lo scarto $\rightarrow$ χ^2 grande $\rightarrow$ più probabile che un legame ci sia.

Passo 2 — l'idea del chi-quadro

- Immaginiamo che l'orientamento **non c'entri** con gli errori.
- Allora ogni gruppo dovrebbe sbagliare **nella stessa proporzione** (circa la media, $\sim$42%).
- Il χ^2 misura **quanto** gli errori *osservati* si allontanano da questo scenario "senza legame".
- Più grande è lo scarto $\rightarrow$ χ^2 grande $\rightarrow$ più probabile che un legame ci sia.

Passo 2 — l'idea del chi-quadro

- Immaginiamo che l'orientamento **non c'entri** con gli errori.
- Allora ogni gruppo dovrebbe sbagliare **nella stessa proporzione** (circa la media, $\sim$42%).
- Il χ^2 misura **quanto** gli errori *osservati* si allontanano da questo scenario "senza legame".
- Più grande è lo scarto $\rightarrow$ χ^2 grande $\rightarrow$ più probabile che un legame ci sia.

Passo 2 — l'idea del chi-quadro

- Immaginiamo che l'orientamento **non c'entri** con gli errori.
- Allora ogni gruppo dovrebbe sbagliare **nella stessa proporzione** (circa la media, $\sim$42%).
- Il χ^2 misura **quanto** gli errori *osservati* si allontanano da questo scenario "senza legame".
- Più grande è lo scarto $\rightarrow$ χ^2 grande $\rightarrow$ più probabile che un legame ci sia.

Passo 2 — quanto vale il nostro χ^2

- Se **non** ci fosse nessun legame, il χ^2 starebbe intorno a **4** (un valore che dipende solo dalla grandezza della tabella)
- Per puro caso supererebbe **9,5** solo 1 volta su 20: è la soglia classica
- Il nostro: **1.208–1.684**, a seconda del modello

  Oltre cento volte la soglia: lontanissimo dallo scenario "senza legame".
- Attenzione: il χ^2 cresce con il **numero di dati** (qui 19.476 articoli): per giudicare la *forza* del legame serve Cramér's V (Passo 4)

Passo 2 — quanto vale il nostro χ^2

- Se **non** ci fosse nessun legame, il χ^2 starebbe intorno a **4** (un valore che dipende solo dalla grandezza della tabella)
- Per puro caso supererebbe **9,5** solo 1 volta su 20: è la soglia classica
- Il nostro: **1.208–1.684**, a seconda del modello

  Oltre cento volte la soglia: lontanissimo dallo scenario "senza legame".
- Attenzione: il χ^2 cresce con il **numero di dati** (qui 19.476 articoli): per giudicare la *forza* del legame serve Cramér's V (Passo 4)

Passo 2 — quanto vale il nostro χ^2

- Se **non** ci fosse nessun legame, il χ^2 starebbe intorno a **4** (un valore che dipende solo dalla grandezza della tabella)
- Per puro caso supererebbe **9,5** solo 1 volta su 20: è la soglia classica
- Il nostro: **1.208–1.684**, a seconda del modello

Oltre cento volte la soglia: lontanissimo dallo scenario "senza legame".

- Attenzione: il χ^2 cresce con il **numero di dati** (qui 19.476 articoli): per giudicare la *forza* del legame serve Cramér's V (Passo 4)

Passo 2 — quanto vale il nostro χ^2

- Se **non** ci fosse nessun legame, il χ^2 starebbe intorno a **4** (un valore che dipende solo dalla grandezza della tabella)
- Per puro caso supererebbe **9,5** solo 1 volta su 20: è la soglia classica
- Il nostro: **1.208–1.684**, a seconda del modello

  Oltre cento volte la soglia: lontanissimo dallo scenario "senza legame".

- Attenzione: il χ^2 cresce con il **numero di dati** (qui 19.476 articoli): per giudicare la *forza* del legame serve Cramér's V (Passo 4)

Passo 2 — quanto vale il nostro χ^2

- Se **non** ci fosse nessun legame, il χ^2 starebbe intorno a **4** (un valore che dipende solo dalla grandezza della tabella)
- Per puro caso supererebbe **9,5** solo 1 volta su 20: è la soglia classica
- Il nostro: **1.208–1.684**, a seconda del modello

  Oltre cento volte la soglia: lontanissimo dallo scenario "senza legame".
- Attenzione: il χ^2 cresce con il **numero di dati** (qui 19.476 articoli): per giudicare la *forza* del legame serve Cramér's V (Passo 4)

Passo 3 — il p-value

- Un χ^2 grande potrebbe capitare **per caso**?
- Il p-**value** è la probabilità di vedere uno scarto così grande *se non ci fosse nessun legame*.
- p piccolissimo (es. $p < 0.001$) $\rightarrow$ quasi impossibile che sia un caso.
- Quindi il legame è **reale**, non fortuna.

Passo 3 — il p-value

- Un χ^2 grande potrebbe capitare **per caso**?
- Il p-**value** è la probabilità di vedere uno scarto così grande *se non ci fosse nessun legame*.
- p piccolissimo (es. $p < 0.001$) $\rightarrow$ quasi impossibile che sia un caso.
- Quindi il legame è **reale**, non fortuna.

Passo 3 — il p-value

- Un χ^2 grande potrebbe capitare **per caso**?
- Il p-**value** è la probabilità di vedere uno scarto così grande *se non ci fosse nessun legame*.
- p piccolissimo (es. $p < 0.001$) $\rightarrow$ quasi impossibile che sia un caso.
- Quindi il legame è **reale**, non fortuna.

Passo 3 — il p-value

- Un χ^2 grande potrebbe capitare **per caso**?
- Il p-**value** è la probabilità di vedere uno scarto così grande *se non ci fosse nessun legame*.
- p piccolissimo (es. $p < 0.001$) $\rightarrow$ quasi impossibile che sia un caso.
- Quindi il legame è **reale**, non fortuna.

Passo 4 — quanto è forte? (Cramér's V)

- Il *p*-value dice **se** c'è un legame, non **quanto** è forte.
- Con tanti dati anche un legame **piccolo** risulta "significativo".
- **Cramér's V** misura la **forza**: 0 = nessun legame, 1 = legame massimo.

Passo 4 — quanto è forte? (Cramér's V)

- Il *p*-value dice **se** c'è un legame, non **quanto** è forte.
- Con tanti dati anche un legame **piccolo** risulta "significativo".
- **Cramér's V** misura la **forza**: 0 = nessun legame, 1 = legame massimo.

Passo 4 — quanto è forte? (Cramér's V)

- Il *p*-value dice **se** c'è un legame, non **quanto** è forte.
- Con tanti dati anche un legame **piccolo** risulta "significativo".
- **Cramér's V** misura la **forza**: 0 = nessun legame, 1 = legame massimo.

In sintesi

- Legame **statisticamente significativo** (tutti i modelli)
- Forza **piccola–moderata** (V ≈ 0.25–0.29)
- Direzione: estremi **sovrastimati**, slightly left **sottostimati**

Model	χ^2	p	V
BERT	1684	$< 10^{-300}$	0.294
RoBERTa	1418	$< 10^{-300}$	0.270
Llama	1208	$< 10^{-250}$	0.249
Mistral	1344	$< 10^{-300}$	0.263

In sintesi

- Legame **statisticamente significativo** (tutti i modelli)
- Forza **piccola–moderata** (V $\approx$ 0.25–0.29)
- Direzione: estremi **sovrastimati**, slightly left **sottostimati**

Model	χ^2	p	**V**
BERT	1684	$< 10^{-300}$	0.294
RoBERTa	1418	$< 10^{-300}$	0.270
Llama	1208	$< 10^{-250}$	0.249
Mistral	1344	$< 10^{-300}$	0.263

In sintesi

- Legame **statisticamente significativo** (tutti i modelli)
- Forza **piccola–moderata** (V $\approx$ 0.25–0.29)
- Direzione: estremi **sovrastimati**, slightly left **sottostimati**

Model	χ^2	p	**V**
BERT	1684	$< 10^{-300}$	0.294
RoBERTa	1418	$< 10^{-300}$	0.270
Llama	1208	$< 10^{-250}$	0.249
Mistral	1344	$< 10^{-300}$	0.263

Nel materiale supplementare

- Matrici di confusione per **fold** (livello articolo)
- Matrici di confusione a **livello editore** (dopo aggregazione)
- Matrici di confusione per **orientamento politico**
- **Analisi di convergenza**: curve di loss (Llama, Mistral)

Dettagli a supporto delle analisi del paper, non nuovi risultati.

Nel materiale supplementare

- Matrici di confusione per **fold** (livello articolo)
- Matrici di confusione a **livello editore** (dopo aggregazione)
- Matrici di confusione per **orientamento politico**
- **Analisi di convergenza**: curve di loss (Llama, Mistral)

Dettagli a supporto delle analisi del paper, non nuovi risultati.

Nel materiale supplementare

- Matrici di confusione per **fold** (livello articolo)
- Matrici di confusione a **livello editore** (dopo aggregazione)
- Matrici di confusione per **orientamento politico**
- **Analisi di convergenza**: curve di loss (Llama, Mistral)

Dettagli a supporto delle analisi del paper, non nuovi risultati.

Nel materiale supplementare

- Matrici di confusione per **fold** (livello articolo)
- Matrici di confusione a **livello editore** (dopo aggregazione)
- Matrici di confusione per **orientamento politico**
- **Analisi di convergenza**: curve di loss (Llama, Mistral)

Dettagli a supporto delle analisi del paper, non nuovi risultati.

Nel materiale supplementare

- Matrici di confusione per **fold** (livello articolo)
- Matrici di confusione a **livello editore** (dopo aggregazione)
- Matrici di confusione per **orientamento politico**
- **Analisi di convergenza**: curve di loss (Llama, Mistral)

Dettagli a supporto delle analisi del paper, non nuovi risultati.

Le review dei revisori

quali critiche affrontare

Revisore 1 — (1) Novità metodologica limitata

English

"The two-stage framework is essentially standard fine-tuning of pretrained language models followed by majority voting. The main contribution seems to be the task formulation, dataset construction, and evaluation setup, rather than a new model architecture, learning objective, or aggregation method."

Revisore 1 — (1) Novità metodologica limitata

English

"The two-stage framework is essentially standard fine-tuning of pretrained language models followed by majority voting. The main contribution seems to be the task formulation, dataset construction, and evaluation setup, rather than a new model architecture, learning objective, or aggregation method."

Commento di John

Dopo parliamo degli esperimenti in più: questo punto si dovrebbe addressare.

Revisore 1 — (2) Il guadagno dell'aggregazione non è misurato pulito

English

"The comparison between the article-level score (∼0.60) and the publisher-level score (∼0.69) changes both the evaluation unit and the weighting of publishers. As a result, the improvement cannot be attributed to aggregation alone."

Revisore 1 — (2) Il guadagno dell'aggregazione non è misurato pulito

English

"The comparison between the article-level score (∼0.60) and the publisher-level score (∼0.69) changes both the evaluation unit and the weighting of publishers. As a result, the improvement cannot be attributed to aggregation alone."

Commento di John

Questa non l'ho capita. Forse dovremmo spiegare meglio perché aggregare ha senso? Forse ha senso solo aggregare, e non andrebbe fatta la valutazione per singolo articolo?

Revisore 1 — (3) Bias confuso con il livello di affidabilità

English

"The distribution of reliability labels differs substantially across political leanings, and some reliability levels are clearly more difficult to classify than others. The relationship between political leaning and prediction error should therefore be tested again after controlling for the true reliability level."

Revisore 1 — (3) Bias confuso con il livello di affidabilità

English

"The distribution of reliability labels differs substantially across political leanings, and some reliability levels are clearly more difficult to classify than others. The relationship between political leaning and prediction error should therefore be tested again after controlling for the true reliability level."

Commento di John

Di questa ne parliamo dopo in modo approfondito. Comunque non ha senso dire che alcune label sono più difficili da classificare di altre: non ci sono i dati per dirlo.

Revisore 1 — (4) Il chi-quadro ignora il clustering

English

"Political leaning and reliability are publisher-level attributes shared by multiple articles from the same publisher. Using all articles as independent observations may lead to pseudo-replication and overstate the effective sample size and significance of the results."

Revisore 1 — (4) Il chi-quadro ignora il clustering

English

"Political leaning and reliability are publisher-level attributes shared by multiple articles from the same publisher. Using all articles as independent observations may lead to pseudo-replication and overstate the effective sample size and significance of the results."

Commento di John

Questa la vediamo dopo nel dettaglio: è una critica importante.

Revisore 1 — (5) Indizi dell'editore e artefatti non esclusi

English

"The paper does not include systematic text cleaning, source-identifier masking, or sanitized-text ablations. It is therefore difficult to tell whether the model is learning reliability-related content or simply exploiting publisher-specific signals and scraping artifacts."

Revisore 1 — (5) Indizi dell'editore e artefatti non esclusi

English

"The paper does not include systematic text cleaning, source-identifier masking, or sanitized-text ablations. It is therefore difficult to tell whether the model is learning reliability-related content or simply exploiting publisher-specific signals and scraping artifacts."

Commento di John

Anche questa la vediamo più avanti.

Revisore 1 — (6) Possibile bias di selezione nello scraping

English

"Only 439 of the 669 candidate publishers were included in the final dataset, and the scraping success rates differ across reliability levels. The paper does not examine whether the publishers that were successfully scraped differ systematically from those that were not."

Revisore 1 — (6) Possibile bias di selezione nello scraping

English

"Only 439 of the 669 candidate publishers were included in the final dataset, and the scraping success rates differ across reliability levels. The paper does not examine whether the publishers that were successfully scraped differ systematically from those that were not."

Commento di John

Non so se questa ha senso.

Revisore 1 — (7) Confronto sulla taglia del modello non controllato

English

"The models differ in architecture, fine-tuning strategy, training schedule, and context length, in addition to parameter count. The observed performance differences therefore cannot be attributed to model size alone."

Revisore 1 — (7) Confronto sulla taglia del modello non controllato

English

"The models differ in architecture, fine-tuning strategy, training schedule, and context length, in addition to parameter count. The observed performance differences therefore cannot be attributed to model size alone."

Commento di John

Ma praticamente non ci sono differenze di performance tra i vari modelli.

Revisore 1 — (8) Nessuna stima di incertezza

English

"Differences such as 0.69 versus 0.68 are small, but the paper does not report confidence intervals, bootstrap results, or paired significance tests. It is therefore unclear whether these differences are meaningful."

Revisore 1 — (8) Nessuna stima di incertezza

English

"Differences such as 0.69 versus 0.68 are small, but the paper does not report confidence intervals, bootstrap results, or paired significance tests. It is therefore unclear whether these differences are meaningful."

Commento di Claude

- **Bootstrap**: si ricampionano a caso le 439 testate migliaia di volte e ogni volta si ricalcola l'accuracy; la variazione dà un **intervallo di confidenza** (es. "0,69" diventa un intervallo come 0,65–0,73).
- **Test appaiato**: si confrontano due modelli *sulle stesse testate*, contando quelle dove uno ha ragione e l'altro torto (es. test di McNemar); dice se 0,69 contro 0,68 è una differenza reale.
- Nel paper bocciato non ci sono né intervalli né test: critica giusta e veloce da risolvere. Su 439 testate, 0,69 contro 0,68 vuol dire circa 4 testate di differenza.

Revisore 2 — (1) Motivazione debole del passaggio a livello editore

English

"publisher reliability is, by construction, obtained as a fixed aggregation of article-level outputs. . . the re-formulation does not introduce substantial new insight beyond a change in the unit of evaluation."

Revisore 2 — (1) Motivazione debole del passaggio a livello editore

English

"publisher reliability is, by construction, obtained as a fixed aggregation of article-level outputs. . . the re-formulation does not introduce substantial new insight beyond a change in the unit of evaluation."

Commento di John

Non so che dire.

Revisore 2 — (2) Mancano confronti con altri scorer

English

"Publisher-level scores can equally be produced by first scoring individual articles with a model pretrained specifically for article-level reliability classification, or with a general-purpose LLM such as Qwen, and then applying the same voting strategy. . . No such comparison is reported."

Revisore 2 — (2) Mancano confronti con altri scorer

English

"Publisher-level scores can equally be produced by first scoring individual articles with a model pretrained specifically for article-level reliability classification, or with a general-purpose LLM such as Qwen, and then applying the same voting strategy. . . No such comparison is reported."

Commento di John

Anche qui non so che dire: non ho capito cosa c'entra Qwen.

Revisore 2 — (2) Mancano confronti con altri scorer

English

"Publisher-level scores can equally be produced by first scoring individual articles with a model pretrained specifically for article-level reliability classification, or with a general-purpose LLM such as Qwen, and then applying the same voting strategy. . . No such comparison is reported."

Commento di John

Anche qui non so che dire: non ho capito cosa c'entra Qwen.

Commento di Claude

Il nostro schema è "voto a ogni articolo, poi maggioranza". Il revisore nota che il voto per articolo potrebbe darlo anche un modello *già esistente* per l'affidabilità degli articoli, o un *LLM generalista* interrogato direttamente. Qwen è solo un esempio di LLM open-source. Vuole sapere se i nostri modelli battono queste alternative "pronte": è vicino all'esperimento con e senza nomi proposto da Fabio.

Revisore 2 — (3) Il dataset non è “large-scale”

English

“Although the corpus contains 19,476 articles, the objective of the paper is scoring at the level of the publisher, and the dataset comprises only 439 publishers. The dataset is therefore unlikely to support effective use in real-world applications.”

Revisore 2 — (3) Il dataset non è “large-scale”

English

“Although the corpus contains 19,476 articles, the objective of the paper is scoring at the level of the publisher, and the dataset comprises only 439 publishers. The dataset is therefore unlikely to support effective use in real-world applications.”

Commento di John

Secondo me invece i dati sono sufficienti.

Revisore 2 — (3) Il dataset non è “large-scale”

English

“Although the corpus contains 19,476 articles, the objective of the paper is scoring at the level of the publisher, and the dataset comprises only 439 publishers. The dataset is therefore unlikely to support effective use in real-world applications.”

Commento di John

Secondo me invece i dati sono sufficienti.

Commento di Claude

In parte d’accordo con John: 439 testate bastano per misurare le prestazioni, se riportiamo gli intervalli di confidenza. Ma il revisore ha ragione su un punto: l’unità del compito è la testata, quindi il campione vero è 439, non 19.476 (lo conferma anche l’ICC). “Large-scale” è la parola sbagliata: basta toglierla. Che i dati non bastino per un uso reale è un’affermazione del revisore, non dimostrata.

Oltre le review: due analisi

Marinella con ChatGPT · Fabio con Claude

Due analisi di supporto

- Oltre ai due revisori del journal, due analisi del paper fatte con strumenti AI
- **Marinella** con **ChatGPT** — focalizzata sulla statistica del bias
- **Fabio** con **Claude** — review completa + analisi quantitativa del bias
- Fatte in modo **indipendente**: le riassumiamo qui, così le conosciamo tutti

Due analisi di supporto

- Oltre ai due revisori del journal, due analisi del paper fatte con strumenti AI
- **Marinella** con **ChatGPT** — focalizzata sulla statistica del bias
- **Fabio** con **Claude** — review completa + analisi quantitativa del bias
- Fatte in modo **indipendente**: le riassumiamo qui, così le conosciamo tutti

Due analisi di supporto

- Oltre ai due revisori del journal, due analisi del paper fatte con strumenti AI
- **Marinella** con **ChatGPT** — focalizzata sulla statistica del bias
- **Fabio** con **Claude** — review completa + analisi quantitativa del bias
- Fatte in modo **indipendente**: le riassumiamo qui, così le conosciamo tutti

Due analisi di supporto

- Oltre ai due revisori del journal, due analisi del paper fatte con strumenti AI
- **Marinella** con **ChatGPT** — focalizzata sulla statistica del bias
- **Fabio** con **Claude** — review completa + analisi quantitativa del bias
- Fatte in modo **indipendente**: le riassumiamo qui, così le conosciamo tutti

Marinella × ChatGPT — cos'è

- Marinella ha dato a ChatGPT la **parte statistica** del bias e gli ha chiesto di controllarla
- Ha trovato una serie di **problemi**: li vediamo uno a uno, in modo semplice
- Tutti ruotano attorno a una domanda: **possiamo davvero dire che c'è un bias politico?**

Marinella × ChatGPT — cos'è

- Marinella ha dato a ChatGPT la **parte statistica** del bias e gli ha chiesto di controllarla
- Ha trovato una serie di **problemi**: li vediamo uno a uno, in modo semplice
- Tutti ruotano attorno a una domanda: **possiamo davvero dire che c'è un bias politico?**

Marinella × ChatGPT — cos'è

- Marinella ha dato a ChatGPT la **parte statistica** del bias e gli ha chiesto di controllarla
- Ha trovato una serie di **problemi**: li vediamo uno a uno, in modo semplice
- Tutti ruotano attorno a una domanda: **possiamo davvero dire che c'è un bias politico?**

Problema 1 — il χ^2 conta troppo

- La domanda del test: l'errore del modello dipende dall'**orientamento politico**?
- Lo calcola contando i **singoli articoli**: 19.476 "prove"
- Ma l'orientamento è **fisso per testata**: tutti gli articoli di una testata hanno lo stesso orientamento (come hanno la stessa affidabilità — anche se sono due cose diverse)
- Quindi gli articoli di una stessa testata **non sono prove indipendenti**

Problema 1 — il χ^2 conta troppo

- La domanda del test: l'errore del modello dipende dall'**orientamento politico**?
- Lo calcola contando i **singoli articoli**: 19.476 "prove"
- Ma l'orientamento è **fisso per testata**: tutti gli articoli di una testata hanno lo stesso orientamento (come hanno la stessa affidabilità — anche se sono due cose diverse)
- Quindi gli articoli di una stessa testata **non sono prove indipendenti**

Problema 1 — il χ^2 conta troppo

- La domanda del test: l'errore del modello dipende dall'**orientamento politico**?
- Lo calcola contando i **singoli articoli**: 19.476 "prove"
- Ma l'orientamento è **fisso per testata**: tutti gli articoli di una testata hanno lo stesso orientamento (come hanno la stessa affidabilità — anche se sono due cose diverse)
- Quindi gli articoli di una stessa testata **non sono prove indipendenti**

Problema 1 — il χ^2 conta troppo

- La domanda del test: l'errore del modello dipende dall'**orientamento politico**?
- Lo calcola contando i **singoli articoli**: 19.476 "prove"
- Ma l'orientamento è **fisso per testata**: tutti gli articoli di una testata hanno lo stesso orientamento (come hanno la stessa affidabilità — anche se sono due cose diverse)
- Quindi gli articoli di una stessa testata **non sono prove indipendenti**

Problema 1 — l'esempio

- Una testata di destra, 200 articoli, tutti affidabilità l_4
- Il modello la trova difficile → sbaglia quasi tutti: 200 errori "di destra"
- Il test li legge come **200 prove** che "destra → errore"
- Ma è **una** testata difficile, non 200 fatti diversi

  Come chiedere l'opinione politica a 200 persone della stessa famiglia: non sono 200 opinioni indipendenti, è quasi una sola.

- Le prove vere sono le **testate** (439), non gli articoli (19.476): più il campione è (finto) grande, più ogni differenza sembra "significativa"
- Soluzione: un conteggio **per testata**

Problema 1 — l'esempio

- Una testata di destra, 200 articoli, tutti affidabilità l_4
- Il modello la trova difficile → sbaglia quasi tutti: 200 errori "di destra"
- Il test li legge come **200 prove** che "destra → errore"
- Ma è **una** testata difficile, non 200 fatti diversi

  Come chiedere l'opinione politica a 200 persone della stessa famiglia: non sono 200 opinioni indipendenti, è quasi una sola.

- Le prove vere sono le **testate** (439), non gli articoli (19.476): più il campione è (finto) grande, più ogni differenza sembra "significativa"
- Soluzione: un conteggio **per testata**

Problema 1 — l'esempio

- Una testata di destra, 200 articoli, tutti affidabilità l_4
- Il modello la trova difficile → sbaglia quasi tutti: 200 errori "di destra"
- Il test li legge come **200 prove** che "destra → errore"
- Ma è **una** testata difficile, non 200 fatti diversi

  Come chiedere l'opinione politica a 200 persone della stessa famiglia: non sono 200 opinioni indipendenti, è quasi una sola.

- Le prove vere sono le **testate** (439), non gli articoli (19.476): più il campione è (finto) grande, più ogni differenza sembra "significativa"
- Soluzione: un conteggio **per testata**

Problema 1 — l'esempio

- Una testata di destra, 200 articoli, tutti affidabilità l_4
- Il modello la trova difficile → sbaglia quasi tutti: 200 errori "di destra"
- Il test li legge come **200 prove** che "destra → errore"
- Ma è **una** testata difficile, non 200 fatti diversi

Come chiedere l'opinione politica a 200 persone della stessa famiglia: non sono 200 opinioni indipendenti, è quasi una sola.

- Le prove vere sono le **testate** (439), non gli articoli (19.476): più il campione è (finto) grande, più ogni differenza sembra "significativa"
- Soluzione: un conteggio **per testata**

Problema 1 — l'esempio

- Una testata di destra, 200 articoli, tutti affidabilità l_4
- Il modello la trova difficile → sbaglia quasi tutti: 200 errori "di destra"
- Il test li legge come **200 prove** che "destra → errore"
- Ma è **una** testata difficile, non 200 fatti diversi

  Come chiedere l'opinione politica a 200 persone della stessa famiglia: non sono 200 opinioni indipendenti, è quasi una sola.

- Le prove vere sono le **testate** (439), non gli articoli (19.476): più il campione è (finto) grande, più ogni differenza sembra "significativa"
- Soluzione: un conteggio **per testata**

Problema 1 — l'esempio

- Una testata di destra, 200 articoli, tutti affidabilità l_4
- Il modello la trova difficile $\rightarrow$ sbaglia quasi tutti: 200 errori "di destra"
- Il test li legge come **200 prove** che "destra $\rightarrow$ errore"
- Ma è **una** testata difficile, non 200 fatti diversi

  Come chiedere l'opinione politica a 200 persone della stessa famiglia: non sono 200 opinioni indipendenti, è quasi una sola.

- Le prove vere sono le **testate** (439), non gli articoli (19.476): più il campione è (finto) grande, più ogni differenza sembra "significativa"
- Soluzione: un conteggio **per testata**

Problema 1 — l'esempio

- Una testata di destra, 200 articoli, tutti affidabilità l_4
- Il modello la trova difficile $\rightarrow$ sbaglia quasi tutti: 200 errori "di destra"
- Il test li legge come **200 prove** che "destra $\rightarrow$ errore"
- Ma è **una** testata difficile, non 200 fatti diversi

  Come chiedere l'opinione politica a 200 persone della stessa famiglia: non sono 200 opinioni indipendenti, è quasi una sola.

- Le prove vere sono le **testate** (439), non gli articoli (19.476): più il campione è (finto) grande, più ogni differenza sembra "significativa"
- Soluzione: un conteggio **per testata**

Osservazione di John — ma è vero?

- La critica regge solo se gli errori si **ripetono** dentro la stessa testata
- Se il modello facesse **un po' giusti e un po' sbagliati a caso**, ogni articolo sarebbe una prova nuova: contarli tutti sarebbe giusto
- Se invece **azzecca (o sbaglia) quasi tutta** la testata insieme, i suoi articoli dicono **la stessa cosa**: contarli tutti è come **ripetere la stessa prova**
- La domanda: quando sbaglia su una testata, sbaglia su **quasi tutti** i suoi articoli? Lo misuriamo.

Osservazione di John — ma è vero?

- La critica regge solo se gli errori si **ripetono** dentro la stessa testata
- Se il modello facesse **un po' giusti e un po' sbagliati a caso**, ogni articolo sarebbe una prova nuova: contarli tutti sarebbe giusto
- Se invece **azzecca (o sbaglia) quasi tutta** la testata insieme, i suoi articoli dicono **la stessa cosa**: contarli tutti è come **ripetere la stessa prova**
- La domanda: quando sbaglia su una testata, sbaglia su **quasi tutti** i suoi articoli? Lo misuriamo.

Osservazione di John — ma è vero?

- La critica regge solo se gli errori si **ripetono** dentro la stessa testata
- Se il modello facesse **un po' giusti e un po' sbagliati a caso**, ogni articolo sarebbe una prova nuova: contarli tutti sarebbe giusto
- Se invece **azzecca (o sbaglia) quasi tutta** la testata insieme, i suoi articoli dicono **la stessa cosa**: contarli tutti è come **ripetere la stessa prova**
- La domanda: quando sbaglia su una testata, sbaglia su **quasi tutti** i suoi articoli? Lo misuriamo.

Osservazione di John — ma è vero?

- La critica regge solo se gli errori si **ripetono** dentro la stessa testata
- Se il modello facesse **un po' giusti e un po' sbagliati a caso**, ogni articolo sarebbe una prova nuova: contarli tutti sarebbe giusto
- Se invece **azzecca (o sbaglia) quasi tutta** la testata insieme, i suoi articoli dicono **la stessa cosa**: contarli tutti è come **ripetere la stessa prova**
- La domanda: quando sbaglia su una testata, sbaglia su **quasi tutti** i suoi articoli? Lo misuriamo.

Cos'è l'ICC — l'idea

- Per ogni testata guardiamo: che **quota di articoli** sbaglia il modello?
- Se sbagliasse **a caso** dentro la testata, ogni testata starebbe vicino alla **media** ($\sim$42%)
- L'ICC dice quanto invece le testate si **spaccano** tra "quasi tutte giuste" e "quasi tutte sbagliate"
- **0** = tutte vicine alla media (nessuna correlazione) **1** = ognuna a un estremo

Come una classe di studenti: se vanno tutti bene o tutti male insieme, i voti sono "correlati".

Cos'è l'ICC — l'idea

- Per ogni testata guardiamo: che **quota di articoli** sbaglia il modello?
- Se sbagliasse **a caso** dentro la testata, ogni testata starebbe vicino alla **media** ($\sim$42%)
- L'ICC dice quanto invece le testate si **spaccano** tra "quasi tutte giuste" e "quasi tutte sbagliate"
- **0** = tutte vicine alla media (nessuna correlazione) **1** = ognuna a un estremo

Come una classe di studenti: se vanno tutti bene o tutti male insieme, i voti sono "correlati".

Cos'è l'ICC — l'idea

- Per ogni testata guardiamo: che **quota di articoli** sbaglia il modello?
- Se sbagliasse **a caso** dentro la testata, ogni testata starebbe vicino alla **media** ($\sim$42%)
- L'ICC dice quanto invece le testate si **spaccano** tra "quasi tutte giuste" e "quasi tutte sbagliate"
- **0** = tutte vicine alla media (nessuna correlazione) **1** = ognuna a un estremo

Come una classe di studenti: se vanno tutti bene o tutti male insieme, i voti sono "correlati".

Cos'è l'ICC — l'idea

- Per ogni testata guardiamo: che **quota di articoli** sbaglia il modello?
- Se sbagliasse **a caso** dentro la testata, ogni testata starebbe vicino alla **media** ($\sim$42%)
- L'ICC dice quanto invece le testate si **spaccano** tra "quasi tutte giuste" e "quasi tutte sbagliate"
- **0** = tutte vicine alla media (nessuna correlazione) **1** = ognuna a un estremo

Come una classe di studenti: se vanno tutti bene o tutti male insieme, i voti sono "correlati".

Cos'è l'ICC — l'idea

- Per ogni testata guardiamo: che **quota di articoli** sbaglia il modello?
- Se sbagliasse **a caso** dentro la testata, ogni testata starebbe vicino alla **media** ($\sim$42%)
- L'ICC dice quanto invece le testate si **spaccano** tra "quasi tutte giuste" e "quasi tutte sbagliate"
- **0** = tutte vicine alla media (nessuna correlazione) **1** = ognuna a un estremo

Come una classe di studenti: se vanno tutti bene o tutti male insieme, i voti sono "correlati".

Osservazione di John — cosa troviamo

- Su **439 testate**:

  221 quasi tutte giuste

  84 quasi tutte sbagliate

  solo 134 “a metà”

- L’esito lo decide quasi la **testata**, non il singolo articolo
- Riassunto in un numero: ICC ≈ 0.6 (a caso ≈ 0.14)

Osservazione di John — cosa troviamo

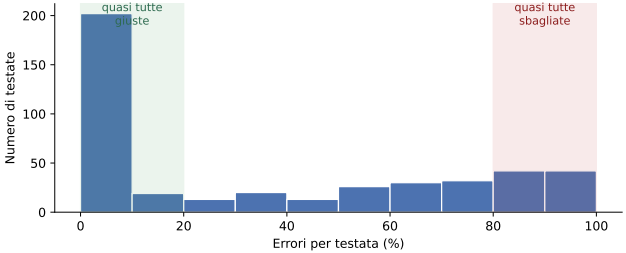
- Su **439 testate**:

  221 quasi tutte giuste

  84 quasi tutte sbagliate

  solo 134 “a metà”

- L’esito lo decide quasi la **testata**, non il singolo articolo
- Riassunto in un numero: ICC ≈ 0.6 (a caso ≈ 0.14)



Osservazione di John — cosa troviamo

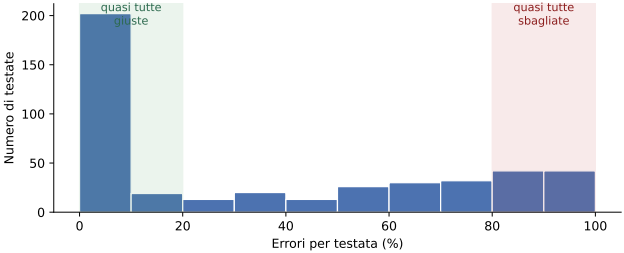
- Su **439 testate**:

  221 quasi tutte giuste

  84 quasi tutte sbagliate

  solo 134 “a metà”

- L’esito lo decide quasi la **testata**, non il singolo articolo
- Riassunto in un numero: ICC ≈ 0.6 (a caso ≈ 0.14)



Osservazione di John — cosa troviamo

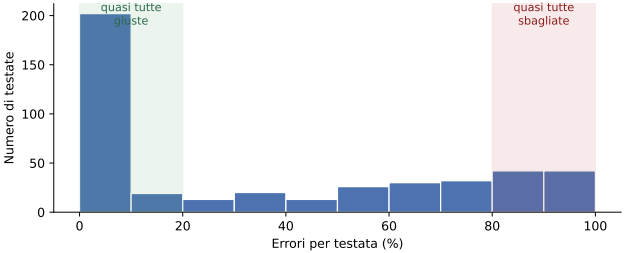
- Su **439 testate**:

  221 quasi tutte giuste

  84 quasi tutte sbagliate

  solo 134 “a metà”

- L’esito lo decide quasi la **testata**, non il singolo articolo
- Riassunto in un numero: ICC ≈ 0.6 (a caso ≈ 0.14)



Osservazione di John — cosa troviamo

- Su **439 testate**:

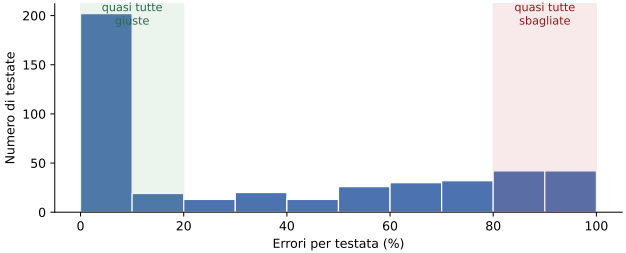
  221 quasi tutte giuste

  84 quasi tutte sbagliate

  solo 134 “a metà”

- L’esito lo decide quasi la **testata**, non il singolo articolo

- Riassunto in un numero: ICC ≈ 0.6 (a caso ≈ 0.14)



Osservazione di John — cosa troviamo

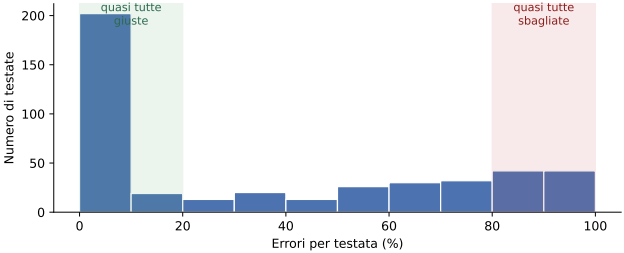
- Su **439 testate**:

  221 quasi tutte giuste

  84 quasi tutte sbagliate

  solo 134 “a metà”

- L’esito lo decide quasi la **testata**, non il singolo articolo
- Riassunto in un numero: ICC ≈ 0.6 (a caso ≈ 0.14)



Osservazione di John — la conclusione

- Gli articoli di una testata **non sono prove indipendenti**
- Quindi l'unità giusta per il test sono le **439 testate**, non i 19.476 articoli

  E vale anche a parità di livello: non è solo perché su l_5 il modello sbaglia di più.
- La correzione è semplice: fare il test **per testata**

Osservazione di John — la conclusione

- Gli articoli di una testata **non sono prove indipendenti**
- Quindi l'unità giusta per il test sono le **439 testate**, non i 19.476 articoli

E vale anche a parità di livello: non è solo perché su l_5 il modello sbaglia di più.

- La correzione è semplice: fare il test **per testata**

Osservazione di John — la conclusione

- Gli articoli di una testata **non sono prove indipendenti**
- Quindi l'unità giusta per il test sono le **439 testate**, non i 19.476 articoli

  E vale anche a parità di livello: non è solo perché su l_5 il modello sbaglia di più.

- La correzione è semplice: fare il test **per testata**

Osservazione di John — la conclusione

- Gli articoli di una testata **non sono prove indipendenti**
- Quindi l'unità giusta per il test sono le **439 testate**, non i 19.476 articoli

  E vale anche a parità di livello: non è solo perché su l_5 il modello sbaglia di più.
- La correzione è semplice: fare il test **per testata**

Problema 2 — cosa dice ChatGPT

- Nel paper l'errore è calcolato **separatamente per ogni orientamento**
- E si afferma che così è "**indipendente dalla frequenza delle classi**"
- In altre parole: calcolarlo separatamente dovrebbe renderlo **non influenzato** da come sono distribuiti i dati
- ChatGPT fa notare: è vero **solo a metà**

Problema 2 — cosa dice ChatGPT

- Nel paper l'errore è calcolato **separatamente per ogni orientamento**
- E si afferma che così è "**indipendente dalla frequenza delle classi**"
- In altre parole: calcolarlo separatamente dovrebbe renderlo **non influenzato** da come sono distribuiti i dati
- ChatGPT fa notare: è vero **solo a metà**

Problema 2 — cosa dice ChatGPT

- Nel paper l'errore è calcolato **separatamente per ogni orientamento**
- E si afferma che così è "**indipendente dalla frequenza delle classi**"
- In altre parole: calcolarlo separatamente dovrebbe renderlo **non influenzato** da come sono distribuiti i dati
- ChatGPT fa notare: è vero **solo a metà**

Problema 2 — cosa dice ChatGPT

- Nel paper l'errore è calcolato **separatamente per ogni orientamento**
- E si afferma che così è "**indipendente dalla frequenza delle classi**"
- In altre parole: calcolarlo separatamente dovrebbe renderlo **non influenzato** da come sono distribuiti i dati
- ChatGPT fa notare: è vero **solo a metà**

Problema 2 — perché solo a metà

- Calcolarlo separatamente toglie l'effetto della **dimensione** del gruppo (quanti articoli ha)
- Ma **non** toglie l'effetto di **quali livelli** ci sono dentro
- E il livello pesa tanto: l_1 facile, l_5 difficile
- Ogni orientamento ha un **mix di livelli diverso**

Problema 2 — perché solo a metà

- Calcolarlo separatamente toglie l'effetto della **dimensione** del gruppo (quanti articoli ha)
- Ma **non** toglie l'effetto di **quali livelli** ci sono dentro
- E il livello pesa tanto: l_1 facile, l_5 difficile
- Ogni orientamento ha un **mix di livelli diverso**

Problema 2 — perché solo a metà

- Calcolarlo separatamente toglie l'effetto della **dimensione** del gruppo (quanti articoli ha)
- Ma **non** toglie l'effetto di **quali livelli** ci sono dentro
- E il livello pesa tanto: l_1 facile, l_5 difficile
- Ogni orientamento ha un **mix di livelli diverso**

Problema 2 — perché solo a metà

- Calcolarlo separatamente toglie l'effetto della **dimensione** del gruppo (quanti articoli ha)
- Ma **non** toglie l'effetto di **quali livelli** ci sono dentro
- E il livello pesa tanto: l_1 facile, l_5 difficile
- Ogni orientamento ha un **mix di livelli diverso**

Problema 2 — l'esempio

- Slightly Right è quasi tutto l_1 (il livello facile)
- Quindi il suo errore basso dipende dal fatto che è **pieno di articoli facili**...

  ...non dal fatto che il modello "tratti meglio" la destra.
- Conclusione: la frase va riscritta — l'errore per orientamento **dipende ancora** dalla composizione dei livelli

Problema 2 — l'esempio

- Slightly Right è quasi tutto l_1 (il livello facile)
- Quindi il suo errore basso dipende dal fatto che è **pieno di articoli facili**...

  ...non dal fatto che il modello "tratti meglio" la destra.

- Conclusione: la frase va riscritta — l'errore per orientamento **dipende ancora** dalla composizione dei livelli

Problema 2 — l'esempio

- Slightly Right è quasi tutto l_1 (il livello facile)
- Quindi il suo errore basso dipende dal fatto che è **pieno di articoli facili**...

  ...non dal fatto che il modello "tratti meglio" la destra.

- Conclusione: la frase va riscritta — l'errore per orientamento **dipende ancora** dalla composizione dei livelli

Problema 2 — l'esempio

- Slightly Right è quasi tutto l_1 (il livello facile)
- Quindi il suo errore basso dipende dal fatto che è **pieno di articoli facili**...

  ...non dal fatto che il modello "tratti meglio" la destra.
- Conclusione: la frase va riscritta — l'errore per orientamento **dipende ancora** dalla composizione dei livelli

Problema 2 — commento di John

- ChatGPT dà per scontato che i livelli abbiano **difficoltà diverse**
- Ma questa cosa **non è mai dimostrata**
- Il modello sbaglia meno su l_1 — ma "**sbaglia meno**" non vuol dire "**è più facile**"

  Potrebbe sbagliare meno per tanti altri motivi: orientamento, tema, com'è fatto il dataset.
- Non ha senso dire che l_1 è più facile di l_2 solo perché il modello **sbaglia meno**

Problema 2 — commento di John

- ChatGPT dà per scontato che i livelli abbiano **difficoltà diverse**
- Ma questa cosa **non è mai dimostrata**
- Il modello sbaglia meno su l_1 — ma "**sbaglia meno**" non vuol dire "**è più facile**"

  Potrebbe sbagliare meno per tanti altri motivi: orientamento, tema, com'è fatto il dataset.
- Non ha senso dire che l_1 è più facile di l_2 solo perché il modello **sbaglia meno**

Problema 2 — commento di John

- ChatGPT dà per scontato che i livelli abbiano **difficoltà diverse**
- Ma questa cosa **non è mai dimostrata**
- Il modello sbaglia meno su l_1 — ma "**sbaglia meno**" non vuol dire "**è più facile**"

Potrebbe sbagliare meno per tanti altri motivi: orientamento, tema, com'è fatto il dataset.

- Non ha senso dire che l_1 è più facile di l_2 solo perché il modello **sbaglia meno**

Problema 2 — commento di John

- ChatGPT dà per scontato che i livelli abbiano **difficoltà diverse**
- Ma questa cosa **non è mai dimostrata**
- Il modello sbaglia meno su l_1 — ma "**sbaglia meno**" non vuol dire "**è più facile**"

  Potrebbe sbagliare meno per tanti altri motivi: orientamento, tema, com'è fatto il dataset.

- Non ha senso dire che l_1 è più facile di l_2 solo perché il modello **sbaglia meno**

Problema 2 — commento di John

- ChatGPT dà per scontato che i livelli abbiano **difficoltà diverse**
- Ma questa cosa **non è mai dimostrata**
- Il modello sbaglia meno su l_1 — ma "**sbaglia meno**" non vuol dire "**è più facile**"

  Potrebbe sbagliare meno per tanti altri motivi: orientamento, tema, com'è fatto il dataset.
- Non ha senso dire che l_1 è più facile di l_2 solo perché il modello **sbaglia meno**

Problema 3 — orientamento e affidabilità sono "incollati"

- Non solo intrecciati: in alcune combinazioni i dati **mancano del tutto**
- Nessuna testata far-right è in l_5; 142 su 207 slightly-right sono in l_1
- Quando due variabili sono così sovrapposte, **nessuna analisi** può separarle del tutto

Problema 3 — orientamento e affidabilità sono "incollati"

- Non solo intrecciati: in alcune combinazioni i dati **mancano del tutto**
- Nessuna testata far-right è in I_5; 142 su 207 slightly-right sono in I_1
- Quando due variabili sono così sovrapposte, **nessuna analisi** può separarle del tutto

Problema 3 — orientamento e affidabilità sono “incollati”

- Non solo intrecciati: in alcune combinazioni i dati **mancano del tutto**
- Nessuna testata far-right è in I_5; 142 su 207 slightly-right sono in I_1
- Quando due variabili sono così sovrapposte, **nessuna analisi** può separarle del tutto

Problema 4 — il χ^2 ha bisogno di abbastanza dati

- Il χ^2 confronta, in ogni casella, quello che **osserva** con quello che **si aspetterebbe**
- Funziona solo se in ogni casella ci sono **abbastanza osservazioni** (regola pratica: almeno $\sim$5 attese)
- Con poche testate, alcune caselle sono quasi **vuote**

Problema 4 — il χ^2 ha bisogno di abbastanza dati

- Il χ^2 confronta, in ogni casella, quello che **osserva** con quello che **si aspetterebbe**
- Funziona solo se in ogni casella ci sono **abbastanza osservazioni** (regola pratica: almeno $\sim$5 attese)
- Con poche testate, alcune caselle sono quasi **vuote**

Problema 4 — il χ^2 ha bisogno di abbastanza dati

- Il χ^2 confronta, in ogni casella, quello che **osserva** con quello che **si aspetterebbe**
- Funziona solo se in ogni casella ci sono **abbastanza osservazioni** (regola pratica: almeno $\sim$5 attese)
- Con poche testate, alcune caselle sono quasi **vuote**

Problema 4 — nel nostro caso

- 439 testate divise in 5 orientamenti: **Far Left ne ha solo 20**
- Nella casella "Far Left sbagliate" ne aspettiamo appena $\sim$**6**: proprio al limite
- E guardando orientamento *e* livello insieme, alcune caselle sono **vuote**: nessuna far-right di livello 5, nessuna slightly-left di livello 1

  Lì il χ^2 non ha più senso.

Problema 4 — nel nostro caso

- 439 testate divise in 5 orientamenti: **Far Left ne ha solo 20**
- Nella casella "Far Left sbagliate" ne aspettiamo appena $\sim$**6**: proprio al limite
- E guardando orientamento *e* livello insieme, alcune caselle sono **vuote**: nessuna far-right di livello 5, nessuna slightly-left di livello 1

  Lì il χ^2 non ha più senso.

Problema 4 — nel nostro caso

- 439 testate divise in 5 orientamenti: **Far Left ne ha solo 20**
- Nella casella "Far Left sbagliate" ne aspettiamo appena $\sim$**6**: proprio al limite
- E guardando orientamento *e* livello insieme, alcune caselle sono **vuote**: nessuna far-right di livello 5, nessuna slightly-left di livello 1

Lì il χ^2 non ha più senso.

Problema 4 — nel nostro caso

- 439 testate divise in 5 orientamenti: **Far Left ne ha solo 20**
- Nella casella "Far Left sbagliate" ne aspettiamo appena $\sim$**6**: proprio al limite
- E guardando orientamento *e* livello insieme, alcune caselle sono **vuote**: nessuna far-right di livello 5, nessuna slightly-left di livello 1

  Lì il χ^2 non ha più senso.

Problema 5 — la MED guarda solo gli errori

- La MED misura la direzione dell'errore **solo quando il modello sbaglia**
- Non tiene conto di **quanto spesso** sbaglia

Problema 5 — la MED guarda solo gli errori

- La MED misura la direzione dell'errore **solo quando il modello sbaglia**
- Non tiene conto di **quanto spesso** sbaglia

Problema 5 — l'esempio

- Gruppo A: sbaglia il **70%** degli articoli, e quando sbaglia sovrastima di mezzo livello (MED $+0.5$)
- Gruppo B: sbaglia il **10%**, con la stessa MED $+0.5$
- Stessa MED, ma l'effetto totale è **diversissimo**: A viene spinto in alto 7 volte su 10, B solo 1 su 10

  Nel paper gli estremi sbagliano il 60–72%, i non-labelled il 30%: confrontare le loro MED inganna.

- Soluzione: riportare anche la direzione media su **tutti** gli articoli, compresi quelli classificati **correttamente** (che contano zero)

Problema 5 — l'esempio

- Gruppo A: sbaglia il **70%** degli articoli, e quando sbaglia sovrastima di mezzo livello (MED $+0.5$)
- Gruppo B: sbaglia il **10%**, con la stessa MED $+0.5$
- Stessa MED, ma l'effetto totale è **diversissimo**: A viene spinto in alto 7 volte su 10, B solo 1 su 10

  Nel paper gli estremi sbagliano il 60–72%, i non-labelled il 30%: confrontare le loro MED inganna.

- Soluzione: riportare anche la direzione media su **tutti** gli articoli, compresi quelli classificati **correttamente** (che contano zero)

Problema 5 — l'esempio

- Gruppo A: sbaglia il **70%** degli articoli, e quando sbaglia sovrastima di mezzo livello (MED $+0.5$)
- Gruppo B: sbaglia il **10%**, con la stessa MED $+0.5$
- Stessa MED, ma l'effetto totale è **diversissimo**: A viene spinto in alto 7 volte su 10, B solo 1 su 10

Nel paper gli estremi sbagliano il 60–72%, i non-labelled il 30%: confrontare le loro MED inganna.

- Soluzione: riportare anche la direzione media su **tutti** gli articoli, compresi quelli classificati **correttamente** (che contano zero)

Problema 5 — l'esempio

- Gruppo A: sbaglia il **70%** degli articoli, e quando sbaglia sovrastima di mezzo livello (MED $+0.5$)
- Gruppo B: sbaglia il **10%**, con la stessa MED $+0.5$
- Stessa MED, ma l'effetto totale è **diversissimo**: A viene spinto in alto 7 volte su 10, B solo 1 su 10

Nel paper gli estremi sbagliano il 60–72%, i non-labelled il 30%: confrontare le loro MED inganna.

- Soluzione: riportare anche la direzione media su **tutti** gli articoli, compresi quelli classificati **correttamente** (che contano zero)

Problema 5 — l'esempio

- Gruppo A: sbaglia il **70%** degli articoli, e quando sbaglia sovrastima di mezzo livello (MED $+0.5$)
- Gruppo B: sbaglia il **10%**, con la stessa MED $+0.5$
- Stessa MED, ma l'effetto totale è **diversissimo**: A viene spinto in alto 7 volte su 10, B solo 1 su 10

  Nel paper gli estremi sbagliano il 60–72%, i non-labelled il 30%: confrontare le loro MED inganna.

- Soluzione: riportare anche la direzione media su **tutti** gli articoli, compresi quelli classificati **correttamente** (che contano zero)

Problema 5 — un'incoerenza nel paper bocciato

- La **formula** della MED usa solo gli articoli **sbagliati**
- Ma i numeri **per livello** (es. $l_5 \approx -1{,}30$) sono calcolati su **tutti** gli articoli
- Mentre quelli **per orientamento** (estremi da $+0{,}33$ a $+1{,}00$) solo sugli **errori**

Due definizioni diverse nello stesso paper: nel nuovo va scelta una sola, e dichiarata.

Problema 5 — un'incoerenza nel paper bocciato

- La **formula** della MED usa solo gli articoli **sbagliati**
- Ma i numeri **per livello** (es. $l_5 \approx -1{,}30$) sono calcolati su **tutti** gli articoli
- Mentre quelli **per orientamento** (estremi da $+0{,}33$ a $+1{,}00$) solo sugli **errori**

Due definizioni diverse nello stesso paper: nel nuovo va scelta una sola, e dichiarata.

Problema 5 — un'incoerenza nel paper bocciato

- La **formula** della MED usa solo gli articoli **sbagliati**
- Ma i numeri **per livello** (es. $l_5 \approx -1{,}30$) sono calcolati su **tutti** gli articoli
- Mentre quelli **per orientamento** (estremi da $+0{,}33$ a $+1{,}00$) solo sugli **errori**

Due definizioni diverse nello stesso paper: nel nuovo va scelta una sola, e dichiarata.

Problema 5 — un'incoerenza nel paper bocciato

- La **formula** della MED usa solo gli articoli **sbagliati**
- Ma i numeri **per livello** (es. $l_5 \approx -1{,}30$) sono calcolati su **tutti** gli articoli
- Mentre quelli **per orientamento** (estremi da $+0{,}33$ a $+1{,}00$) solo sugli **errori**

Due definizioni diverse nello stesso paper: nel nuovo va scelta una sola, e dichiarata.

Problema 6 — la direzione è “obbligata” dai bordi

- Se una testata è in l_1 (il più basso), l’errore può solo andare **verso l’alto**; se è in l_5, solo verso il basso
- Far-left e far-right stanno quasi tutti nei livelli bassi $\rightarrow$ i loro errori sono “per forza” positivi

Quindi la sovrastima degli estremi può dipendere dalla composizione, non dall’orientamento.

Problema 6 — la direzione è “obbligata” dai bordi

- Se una testata è in l_1 (il più basso), l’errore può solo andare **verso l’alto**; se è in l_5, solo verso il basso
- Far-left e far-right stanno quasi tutti nei livelli bassi $\rightarrow$ i loro errori sono “per forza” positivi

Quindi la sovrastima degli estremi può dipendere dalla composizione, non dall’orientamento.

Problema 6 — la direzione è “obbligata” dai bordi

- Se una testata è in l_1 (il più basso), l’errore può solo andare **verso l’alto**; se è in l_5, solo verso il basso
- Far-left e far-right stanno quasi tutti nei livelli bassi $\rightarrow$ i loro errori sono “per forza” positivi

Quindi la sovrastima degli estremi può dipendere dalla composizione, non dall’orientamento.

Considerazione di John a ChatGPT (1)

- L'affidabilità l'abbiamo **stratificata** nei fold (tenuta sotto controllo)
- L'orientamento invece **no**: è lasciato a caso
- E nel dataset orientamento $\times$ livello è **sbilanciatissimo**
- Alcune combinazioni **non esistono**: nessuna slightly-left di livello 1, nessuna far-right di livello 5

Considerazione di John a ChatGPT (1)

- L'affidabilità l'abbiamo **stratificata** nei fold (tenuta sotto controllo)
- L'orientamento invece **no**: è lasciato a caso
- E nel dataset orientamento $\times$ livello è **sbilanciatissimo**
- Alcune combinazioni **non esistono**: nessuna slightly-left di livello 1, nessuna far-right di livello 5

Considerazione di John a ChatGPT (1)

- L'affidabilità l'abbiamo **stratificata** nei fold (tenuta sotto controllo)
- L'orientamento invece **no**: è lasciato a caso
- E nel dataset orientamento $\times$ livello è **sbilanciatissimo**
- Alcune combinazioni **non esistono**: nessuna slightly-left di livello 1, nessuna far-right di livello 5

Considerazione di John a ChatGPT (1)

- L'affidabilità l'abbiamo **stratificata** nei fold (tenuta sotto controllo)
- L'orientamento invece **no**: è lasciato a caso
- E nel dataset orientamento $\times$ livello è **sbilanciatissimo**
- Alcune combinazioni **non esistono**: nessuna slightly-left di livello 1, nessuna far-right di livello 5

Considerazione di John a ChatGPT (2)

- Quando dividiamo in fold, a volte il modello vede **zero** esempi di una combinazione che poi deve indovinare
- Es. (fold 1): nessun Far Left di livello 1 o 3 in addestramento, ma viene testato proprio su quelli

  Naturale che sbagli: non li ha mai visti.
- Quindi parte di questi "errori politici" è un **artefatto** del dataset e dei fold

Considerazione di John a ChatGPT (2)

- Quando dividiamo in fold, a volte il modello vede **zero** esempi di una combinazione che poi deve indovinare
- Es. (fold 1): nessun Far Left di livello 1 o 3 in addestramento, ma viene testato proprio su quelli

  Naturale che sbagli: non li ha mai visti.
- Quindi parte di questi "errori politici" è un **artefatto** del dataset e dei fold

Considerazione di John a ChatGPT (2)

- Quando dividiamo in fold, a volte il modello vede **zero** esempi di una combinazione che poi deve indovinare
- Es. (fold 1): nessun Far Left di livello 1 o 3 in addestramento, ma viene testato proprio su quelli

  Naturale che sbagli: non li ha mai visti.
- Quindi parte di questi "errori politici" è un **artefatto** del dataset e dei fold

Considerazione di John a ChatGPT (2)

- Quando dividiamo in fold, a volte il modello vede **zero** esempi di una combinazione che poi deve indovinare
- Es. (fold 1): nessun Far Left di livello 1 o 3 in addestramento, ma viene testato proprio su quelli

  Naturale che sbagli: non li ha mai visti.
- Quindi parte di questi "errori politici" è un **artefatto** del dataset e dei fold

Considerazione di John a ChatGPT (3)

- Questa analisi del bias è **molto specifica**: vale per *questo* dataset, *questi* modelli, *questo* training
- Non è un risultato generale sul "comportamento politico" dei modelli
- Se la teniamo, va detto **chiaramente**

È un po' un'analisi fine a sé stessa.

Considerazione di John a ChatGPT (3)

- Questa analisi del bias è **molto specifica**: vale per *questo* dataset, *questi* modelli, *questo* training
- Non è un risultato generale sul "comportamento politico" dei modelli
- Se la teniamo, va detto **chiaramente**

È un po' un'analisi fine a sé stessa.

Considerazione di John a ChatGPT (3)

- Questa analisi del bias è **molto specifica**: vale per *questo* dataset, *questi* modelli, *questo* training
- Non è un risultato generale sul "comportamento politico" dei modelli
- Se la teniamo, va detto **chiaramente**

È un po' un'analisi fine a sé stessa.

Considerazione di John a ChatGPT (3)

- Questa analisi del bias è **molto specifica**: vale per *questo* dataset, *questi* modelli, *questo* training
- Non è un risultato generale sul "comportamento politico" dei modelli
- Se la teniamo, va detto **chiaramente**

  È un po' un'analisi fine a sé stessa.

Considerazione di John — che cos'è una testata?

Una critica nostra, non a ChatGPT

Nel paper una testata coincide con **l'insieme dei suoi articoli**. Ma è davvero così?

- Oggi una testata è anche le sue **pagine social**, le **newsletter**, i **podcast**, i video
- Noi guardiamo solo gli **articoli del sito**: una parte della testata, non la testata intera

Rischiamo di giudicare la testata guardandone solo una parte.

- Nel paper non dovremmo darlo per scontato: va detto chiaramente **che cosa** stiamo giudicando

Considerazione di John — che cos'è una testata?

Una critica nostra, non a ChatGPT

Nel paper una testata coincide con **l'insieme dei suoi articoli**. Ma è davvero così?

- Oggi una testata è anche le sue **pagine social**, le **newsletter**, i **podcast**, i video
- Noi guardiamo solo gli **articoli del sito**: una parte della testata, non la testata intera

Rischiamo di giudicare la testata guardandone solo una parte.

- Nel paper non dovremmo darlo per scontato: va detto chiaramente **che cosa** stiamo giudicando

Considerazione di John — che cos'è una testata?

Una critica nostra, non a ChatGPT

Nel paper una testata coincide con **l'insieme dei suoi articoli**. Ma è davvero così?

- Oggi una testata è anche le sue **pagine social**, le **newsletter**, i **podcast**, i video
- Noi guardiamo solo gli **articoli del sito**: una parte della testata, non la testata intera

Rischiamo di giudicare la testata guardandone solo una parte.

- Nel paper non dovremmo darlo per scontato: va detto chiaramente **che cosa** stiamo giudicando

Considerazione di John — che cos'è una testata?

Una critica nostra, non a ChatGPT

Nel paper una testata coincide con **l'insieme dei suoi articoli**. Ma è davvero così?

- Oggi una testata è anche le sue **pagine social**, le **newsletter**, i **podcast**, i video
- Noi guardiamo solo gli **articoli del sito**: una parte della testata, non la testata intera

  Rischiamo di giudicare la testata guardandone solo una parte.
- Nel paper non dovremmo darlo per scontato: va detto chiaramente **che cosa** stiamo giudicando

Fabio × Claude — cos'è

- Fabio ha chiesto a Claude tre cose: come usare i modelli grandi, una review del paper, come impostare l'analisi del bias
- Il bias l'abbiamo **già visto**: non ci torniamo
- Qui solo le **proposte nuove**: esperimenti, metodi, aggregazione, correzioni

Fabio × Claude — cos'è

- Fabio ha chiesto a Claude tre cose: come usare i modelli grandi, una review del paper, come impostare l'analisi del bias
- Il bias l'abbiamo **già visto**: non ci torniamo
- Qui solo le **proposte nuove**: esperimenti, metodi, aggregazione, correzioni

Fabio × Claude — cos'è

- Fabio ha chiesto a Claude tre cose: come usare i modelli grandi, una review del paper, come impostare l'analisi del bias
- Il bias l'abbiamo **già visto**: non ci torniamo
- Qui solo le **proposte nuove**: esperimenti, metodi, aggregazione, correzioni

Fabio — il problema della “contaminazione”

- Domanda di ogni lettore: “perché non chiedere direttamente a GPT?”
- Ma un LLM grande **conosce già** queste testate: le ha lette in addestramento e ne sa la reputazione
- E negli articoli il nome della testata compare spesso (firma, piè di pagina, link)
- Quindi GPT potrebbe **ricordare la reputazione** invece di leggere il testo

Come far giudicare un vino “alla cieca” lasciando l’etichetta sulla bottiglia.

Fabio — il problema della "contaminazione"

- Domanda di ogni lettore: "perché non chiedere direttamente a GPT?"
- Ma un LLM grande **conosce già** queste testate: le ha lette in addestramento e ne sa la reputazione
- E negli articoli il nome della testata compare spesso (firma, piè di pagina, link)
- Quindi GPT potrebbe **ricordare la reputazione** invece di leggere il testo

Come far giudicare un vino "alla cieca" lasciando l'etichetta sulla bottiglia.

Fabio — il problema della "contaminazione"

- Domanda di ogni lettore: "perché non chiedere direttamente a GPT?"
- Ma un LLM grande **conosce già** queste testate: le ha lette in addestramento e ne sa la reputazione
- E negli articoli il nome della testata compare spesso (firma, piè di pagina, link)
- Quindi GPT potrebbe **ricordare la reputazione** invece di leggere il testo

Come far giudicare un vino "alla cieca" lasciando l'etichetta sulla bottiglia.

Fabio — il problema della "contaminazione"

- Domanda di ogni lettore: "perché non chiedere direttamente a GPT?"
- Ma un LLM grande **conosce già** queste testate: le ha lette in addestramento e ne sa la reputazione
- E negli articoli il nome della testata compare spesso (firma, piè di pagina, link)
- Quindi GPT potrebbe **ricordare la reputazione** invece di leggere il testo

Come far giudicare un vino "alla cieca" lasciando l'etichetta sulla bottiglia.

Fabio — il problema della "contaminazione"

- Domanda di ogni lettore: "perché non chiedere direttamente a GPT?"
- Ma un LLM grande **conosce già** queste testate: le ha lette in addestramento e ne sa la reputazione
- E negli articoli il nome della testata compare spesso (firma, piè di pagina, link)
- Quindi GPT potrebbe **ricordare la reputazione** invece di leggere il testo

Come far giudicare un vino "alla cieca" lasciando l'etichetta sulla bottiglia.

Fabio — l'esperimento: con e senza nomi

- Si fa valutare a un LLM lo stesso articolo due volte: **normale** e con nomi, siti e firme **cancellati**
- Se senza nomi va molto peggio → prima stava **riconoscendo la testata**, non giudicando il testo
- Trasforma la domanda "perché non GPT?" in un **risultato**
- E spiega perché i modelli piccoli addestrati da noi sono lo strumento giusto per *questa* domanda

Fabio — l'esperimento: con e senza nomi

- Si fa valutare a un LLM lo stesso articolo due volte: **normale** e con nomi, siti e firme **cancellati**
- Se senza nomi va molto peggio → prima stava **riconoscendo la testata**, non giudicando il testo
- Trasforma la domanda "perché non GPT?" in un **risultato**
- E spiega perché i modelli piccoli addestrati da noi sono lo strumento giusto per *questa* domanda

Fabio — l'esperimento: con e senza nomi

- Si fa valutare a un LLM lo stesso articolo due volte: **normale** e con nomi, siti e firme **cancellati**
- Se senza nomi va molto peggio → prima stava **riconoscendo la testata**, non giudicando il testo
- Trasforma la domanda "perché non GPT?" in un **risultato**
- E spiega perché i modelli piccoli addestrati da noi sono lo strumento giusto per *questa* domanda

Fabio — l'esperimento: con e senza nomi

- Si fa valutare a un LLM lo stesso articolo due volte: **normale** e con nomi, siti e firme **cancellati**
- Se senza nomi va molto peggio → prima stava **riconoscendo la testata**, non giudicando il testo
- Trasforma la domanda "perché non GPT?" in un **risultato**
- E spiega perché i modelli piccoli addestrati da noi sono lo strumento giusto per *questa* domanda

Fabio — una baseline semplice: TF-IDF

- Oggi confrontiamo i transformer solo con baseline “stupide” (classe più frequente, caso)
- Fabio: aggiungere un modello **semplice ma serio**, senza reti neurali
- **TF-IDF**: conta le parole di ogni articolo, dando più peso a quelle rare e distintive; sopra, una regressione logistica

  Se un “contatore di parole” arriva vicino ai transformer, i transformer non stanno aggiungendo molto.
- Costa pochissimo da fare

Fabio — una baseline semplice: TF-IDF

- Oggi confrontiamo i transformer solo con baseline “stupide” (classe più frequente, caso)
- Fabio: aggiungere un modello **semplice ma serio**, senza reti neurali
- **TF-IDF**: conta le parole di ogni articolo, dando più peso a quelle rare e distintive; sopra, una regressione logistica

  Se un “contatore di parole” arriva vicino ai transformer, i transformer non stanno aggiungendo molto.

- Costa pochissimo da fare

Fabio — una baseline semplice: TF-IDF

- Oggi confrontiamo i transformer solo con baseline “stupide” (classe più frequente, caso)
- Fabio: aggiungere un modello **semplice ma serio**, senza reti neurali
- **TF-IDF**: conta le parole di ogni articolo, dando più peso a quelle rare e distintive; sopra, una regressione logistica

  Se un “contatore di parole” arriva vicino ai transformer, i transformer non stanno aggiungendo molto.

- Costa pochissimo da fare

Fabio — una baseline semplice: TF-IDF

- Oggi confrontiamo i transformer solo con baseline “stupide” (classe più frequente, caso)
- Fabio: aggiungere un modello **semplice ma serio**, senza reti neurali
- **TF-IDF**: conta le parole di ogni articolo, dando più peso a quelle rare e distintive; sopra, una regressione logistica

  Se un “contatore di parole” arriva vicino ai transformer, i transformer non stanno aggiungendo molto.

- Costa pochissimo da fare

Fabio — una baseline semplice: TF-IDF

- Oggi confrontiamo i transformer solo con baseline “stupide” (classe più frequente, caso)
- Fabio: aggiungere un modello **semplice ma serio**, senza reti neurali
- **TF-IDF**: conta le parole di ogni articolo, dando più peso a quelle rare e distintive; sopra, una regressione logistica

  Se un “contatore di parole” arriva vicino ai transformer, i transformer non stanno aggiungendo molto.

- Costa pochissimo da fare

Fabio — LLM come estrattore di segnali: l'idea

- Invece di chiedere all'LLM "è affidabile?", gli si chiede un **voto su segnali precisi**

  Sensazionalismo, fonti citate, toni prudenti, opinione o cronaca, titolo acchiappa-clic, presenza di rettifiche...

- Ogni articolo diventa una **lista di voti**

  Es.: sensazionalismo 8/10, fonti citate 2/10, opinione 9/10, ...

- Poi un classificatore semplice impara **quali segnali contano**

Fabio — LLM come estrattore di segnali: l'idea

- Invece di chiedere all'LLM "è affidabile?", gli si chiede un **voto su segnali precisi**

  Sensazionalismo, fonti citate, toni prudenti, opinione o cronaca, titolo acchiappa-clic, presenza di rettifiche...

- Ogni articolo diventa una **lista di voti**

  Es.: sensazionalismo 8/10, fonti citate 2/10, opinione 9/10, ...

- Poi un classificatore semplice impara **quali segnali contano**

Fabio — LLM come estrattore di segnali: l'idea

- Invece di chiedere all'LLM "è affidabile?", gli si chiede un **voto su segnali precisi**

  Sensazionalismo, fonti citate, toni prudenti, opinione o cronaca, titolo acchiappa-clic, presenza di rettifiche...

- Ogni articolo diventa una **lista di voti**

  Es.: sensazionalismo 8/10, fonti citate 2/10, opinione 9/10, ...

- Poi un classificatore semplice impara **quali segnali contano**

Fabio — LLM come estrattore di segnali: l'idea

- Invece di chiedere all'LLM "è affidabile?", gli si chiede un **voto su segnali precisi**

  Sensazionalismo, fonti citate, toni prudenti, opinione o cronaca, titolo acchiappa-clic, presenza di rettifiche...

- Ogni articolo diventa una **lista di voti**

  Es.: sensazionalismo 8/10, fonti citate 2/10, opinione 9/10, ...

- Poi un classificatore semplice impara **quali segnali contano**

Fabio — LLM come estrattore di segnali: l'idea

- Invece di chiedere all'LLM "è affidabile?", gli si chiede un **voto su segnali precisi**

  Sensazionalismo, fonti citate, toni prudenti, opinione o cronaca, titolo acchiappa-clic, presenza di rettifiche...

- Ogni articolo diventa una **lista di voti**

  Es.: sensazionalismo 8/10, fonti citate 2/10, opinione 9/10, ...

- Poi un classificatore semplice impara **quali segnali contano**

Fabio — LLM come estrattore di segnali: perché

- **Costa poco**: una chiamata all'LLM per articolo ($\sim$20.000 in tutto)
- **Si capisce**: sappiamo *quali* segnali distinguono una testata affidabile
- Aggregare è naturale: il profilo di una testata è la **media** dei voti dei suoi articoli
- Per Fabio è la proposta con il miglior rapporto novità/fatica, insieme all'esperimento con e senza nomi

Fabio — LLM come estrattore di segnali: perché

- **Costa poco**: una chiamata all'LLM per articolo ($\sim$20.000 in tutto)
- **Si capisce**: sappiamo *quali* segnali distinguono una testata affidabile
- Aggregare è naturale: il profilo di una testata è la **media** dei voti dei suoi articoli
- Per Fabio è la proposta con il miglior rapporto novità/fatica, insieme all'esperimento con e senza nomi

Fabio — LLM come estrattore di segnali: perché

- **Costa poco**: una chiamata all'LLM per articolo ($\sim$20.000 in tutto)
- **Si capisce**: sappiamo *quali* segnali distinguono una testata affidabile
- Aggregare è naturale: il profilo di una testata è la **media** dei voti dei suoi articoli
- Per Fabio è la proposta con il miglior rapporto novità/fatica, insieme all'esperimento con e senza nomi

Fabio — LLM come estrattore di segnali: perché

- **Costa poco**: una chiamata all'LLM per articolo ($\sim$20.000 in tutto)
- **Si capisce**: sappiamo *quali* segnali distinguono una testata affidabile
- Aggregare è naturale: il profilo di una testata è la **media** dei voti dei suoi articoli
- Per Fabio è la proposta con il miglior rapporto novità/fatica, insieme all'esperimento con e senza nomi

Fabio — multiple-instance learning: l'idea

- Oggi: classifichiamo **ogni articolo**, poi **votiamo**
- Ma l'etichetta vera è della **testata**, non del singolo articolo
- Idea: addestrare il modello direttamente su "**sacchetti**" di articoli: tutti quelli di una testata insieme, con l'etichetta della testata

  Come giudicare un ristorante leggendo tutte le recensioni insieme, invece di dare un voto a ciascuna e fare la maggioranza.

Fabio — multiple-instance learning: l'idea

- Oggi: classifichiamo **ogni articolo**, poi **votiamo**
- Ma l'etichetta vera è della **testata**, non del singolo articolo
- Idea: addestrare il modello direttamente su "**sacchetti**" di articoli: tutti quelli di una testata insieme, con l'etichetta della testata

  Come giudicare un ristorante leggendo tutte le recensioni insieme, invece di dare un voto a ciascuna e fare la maggioranza.

Fabio — multiple-instance learning: l'idea

- Oggi: classifichiamo **ogni articolo**, poi **votiamo**
- Ma l'etichetta vera è della **testata**, non del singolo articolo
- Idea: addestrare il modello direttamente su "**sacchetti**" di articoli: tutti quelli di una testata insieme, con l'etichetta della testata

Come giudicare un ristorante leggendo tutte le recensioni insieme, invece di dare un voto a ciascuna e fare la maggioranza.

Fabio — multiple-instance learning: l'idea

- Oggi: classifichiamo **ogni articolo**, poi **votiamo**
- Ma l'etichetta vera è della **testata**, non del singolo articolo
- Idea: addestrare il modello direttamente su "**sacchetti**" di articoli: tutti quelli di una testata insieme, con l'etichetta della testata

  Come giudicare un ristorante leggendo tutte le recensioni insieme, invece di dare un voto a ciascuna e fare la maggioranza.

Fabio — multiple-instance learning: come

- Ogni articolo viene trasformato una volta in un **embedding**: una lista di numeri che ne riassume il significato
- Il modello impara a combinare gli embedding di una testata (media, o pesando di più gli articoli più utili)
- 439 testate sono poche: si creano tanti sacchetti **a caso** da 10–20 articoli della stessa testata $\rightarrow$ migliaia di esempi
- In più dà una **misura di confidenza** sul giudizio della testata

Fabio — multiple-instance learning: come

- Ogni articolo viene trasformato una volta in un **embedding**: una lista di numeri che ne riassume il significato
- Il modello impara a combinare gli embedding di una testata (media, o pesando di più gli articoli più utili)
- 439 testate sono poche: si creano tanti sacchetti **a caso** da 10–20 articoli della stessa testata $\rightarrow$ migliaia di esempi
- In più dà una **misura di confidenza** sul giudizio della testata

Fabio — multiple-instance learning: come

- Ogni articolo viene trasformato una volta in un **embedding**: una lista di numeri che ne riassume il significato
- Il modello impara a combinare gli embedding di una testata (media, o pesando di più gli articoli più utili)
- 439 testate sono poche: si creano tanti sacchetti **a caso** da 10–20 articoli della stessa testata $\rightarrow$ migliaia di esempi
- In più dà una **misura di confidenza** sul giudizio della testata

Fabio — multiple-instance learning: come

- Ogni articolo viene trasformato una volta in un **embedding**: una lista di numeri che ne riassume il significato
- Il modello impara a combinare gli embedding di una testata (media, o pesando di più gli articoli più utili)
- 439 testate sono poche: si creano tanti sacchetti **a caso** da 10–20 articoli della stessa testata $\rightarrow$ migliaia di esempi
- In più dà una **misura di confidenza** sul giudizio della testata

Fabio — modelli più recenti e altre idee

- BERT e Llama 3 sembrano “datati”: stessa ricetta con modelli attuali (**ModernBERT**, **DeBERTa-v3**, piccoli decoder recenti)

  Quasi solo estetica, ma toglie un appiglio ai revisori.

- **Pulizia delle etichette**: un LLM segnala gli articoli atipici per la loro testata e si dà loro meno peso
- **Distillazione**: poco utile, le etichette le abbiamo già
- **Agente**: visita la testata, legge le pagine “chi siamo”, proprietà, rettifiche, e valuta i 9 criteri di NewsGuard

  È un altro task (non solo testo): lavoro futuro.

Fabio — modelli più recenti e altre idee

- BERT e Llama 3 sembrano “datati”: stessa ricetta con modelli attuali (**ModernBERT**, **DeBERTa-v3**, piccoli decoder recenti)

  Quasi solo estetica, ma toglie un appiglio ai revisori.

- **Pulizia delle etichette**: un LLM segnala gli articoli atipici per la loro testata e si dà loro meno peso
- **Distillazione**: poco utile, le etichette le abbiamo già
- **Agente**: visita la testata, legge le pagine “chi siamo”, proprietà, rettifiche, e valuta i 9 criteri di NewsGuard

  È un altro task (non solo testo): lavoro futuro.

Fabio — modelli più recenti e altre idee

- BERT e Llama 3 sembrano “datati”: stessa ricetta con modelli attuali (**ModernBERT**, **DeBERTa-v3**, piccoli decoder recenti)

  Quasi solo estetica, ma toglie un appiglio ai revisori.

- **Pulizia delle etichette**: un LLM segnala gli articoli atipici per la loro testata e si dà loro meno peso
- **Distillazione**: poco utile, le etichette le abbiamo già
- **Agente**: visita la testata, legge le pagine “chi siamo”, proprietà, rettifiche, e valuta i 9 criteri di NewsGuard

  È un altro task (non solo testo): lavoro futuro.

Fabio — modelli più recenti e altre idee

- BERT e Llama 3 sembrano “datati”: stessa ricetta con modelli attuali (**ModernBERT**, **DeBERTa-v3**, piccoli decoder recenti)

  Quasi solo estetica, ma toglie un appiglio ai revisori.

- **Pulizia delle etichette**: un LLM segnala gli articoli atipici per la loro testata e si dà loro meno peso
- **Distillazione**: poco utile, le etichette le abbiamo già
- **Agente**: visita la testata, legge le pagine “chi siamo”, proprietà, rettifiche, e valuta i 9 criteri di NewsGuard

  È un altro task (non solo testo): lavoro futuro.

Fabio — modelli più recenti e altre idee

- BERT e Llama 3 sembrano “datati”: stessa ricetta con modelli attuali (**ModernBERT**, **DeBERTa-v3**, piccoli decoder recenti)

  Quasi solo estetica, ma toglie un appiglio ai revisori.

- **Pulizia delle etichette**: un LLM segnala gli articoli atipici per la loro testata e si dà loro meno peso
- **Distillazione**: poco utile, le etichette le abbiamo già
- **Agente**: visita la testata, legge le pagine “chi siamo”, proprietà, rettifiche, e valuta i 9 criteri di NewsGuard

  È un altro task (non solo testo): lavoro futuro.

Fabio — modelli più recenti e altre idee

- BERT e Llama 3 sembrano “datati”: stessa ricetta con modelli attuali (**ModernBERT**, **DeBERTa-v3**, piccoli decoder recenti)

  Quasi solo estetica, ma toglie un appiglio ai revisori.

- **Pulizia delle etichette**: un LLM segnala gli articoli atipici per la loro testata e si dà loro meno peso
- **Distillazione**: poco utile, le etichette le abbiamo già
- **Agente**: visita la testata, legge le pagine “chi siamo”, proprietà, rettifiche, e valuta i 9 criteri di NewsGuard

  È un altro task (non solo testo): lavoro futuro.

Fabio — confrontare modi di aggregare

- Oggi usiamo un solo modo: il **voto di maggioranza**
- Alternative: **media** dei livelli, **mediana**, media delle **probabilità**
- Esempio, 10 articoli: 4 dicono l_2, 3 dicono l_3, 3 dicono l_4

  Maggioranza: l_2 Media: $(4{\cdot}2 + 3{\cdot}3 + 3{\cdot}4)/10 = 2{,}9 \to l_3$
- Risposte **diverse**: vale la pena confrontarle

Fabio — confrontare modi di aggregare

- Oggi usiamo un solo modo: il **voto di maggioranza**
- Alternative: **media** dei livelli, **mediana**, media delle **probabilità**
- Esempio, 10 articoli: 4 dicono l_2, 3 dicono l_3, 3 dicono l_4

  Maggioranza: l_2 Media: $(4{\cdot}2 + 3{\cdot}3 + 3{\cdot}4)/10 = 2{,}9 \to l_3$
- Risposte **diverse**: vale la pena confrontarle

Fabio — confrontare modi di aggregare

- Oggi usiamo un solo modo: il **voto di maggioranza**
- Alternative: **media** dei livelli, **mediana**, media delle **probabilità**
- Esempio, 10 articoli: 4 dicono l_2, 3 dicono l_3, 3 dicono l_4

  Maggioranza: l_2 Media: $(4{\cdot}2 + 3{\cdot}3 + 3{\cdot}4)/10 = 2{,}9 \to l_3$
- Risposte **diverse**: vale la pena confrontarle

Fabio — confrontare modi di aggregare

- Oggi usiamo un solo modo: il **voto di maggioranza**
- Alternative: **media** dei livelli, **mediana**, media delle **probabilità**
- Esempio, 10 articoli: 4 dicono l_2, 3 dicono l_3, 3 dicono l_4

  Maggioranza: l_2 Media: $(4{\cdot}2 + 3{\cdot}3 + 3{\cdot}4)/10 = 2{,}9 \to l_3$
- Risposte **diverse**: vale la pena confrontarle

Fabio — confrontare modi di aggregare

- Oggi usiamo un solo modo: il **voto di maggioranza**
- Alternative: **media** dei livelli, **mediana**, media delle **probabilità**
- Esempio, 10 articoli: 4 dicono l_2, 3 dicono l_3, 3 dicono l_4

  Maggioranza: l_2 Media: $(4{\cdot}2 + 3{\cdot}3 + 3{\cdot}4)/10 = 2{,}9 \to l_3$
- Risposte **diverse**: vale la pena confrontarle

Fabio — quanti articoli servono?

- Domanda pratica: per giudicare una testata **nuova**, quanti articoli mi servono?
- La curva: accuratezza sulla testata usando 5, 10, 20, 50… articoli
- Con fino a 200 articoli il voto è probabilmente già "saturo": la domanda interessante è **con pochi**

È l'informazione più utile per chi volesse usare il sistema davvero.

Fabio — quanti articoli servono?

- Domanda pratica: per giudicare una testata **nuova**, quanti articoli mi servono?
- La curva: accuratezza sulla testata usando 5, 10, 20, 50… articoli
- Con fino a 200 articoli il voto è probabilmente già "saturo": la domanda interessante è **con pochi**

È l'informazione più utile per chi volesse usare il sistema davvero.

Fabio — quanti articoli servono?

- Domanda pratica: per giudicare una testata **nuova**, quanti articoli mi servono?
- La curva: accuratezza sulla testata usando 5, 10, 20, 50… articoli
- Con fino a 200 articoli il voto è probabilmente già “saturo”: la domanda interessante è **con pochi**

È l’informazione più utile per chi volesse usare il sistema davvero.

Fabio — quanti articoli servono?

- Domanda pratica: per giudicare una testata **nuova**, quanti articoli mi servono?
- La curva: accuratezza sulla testata usando 5, 10, 20, 50… articoli
- Con fino a 200 articoli il voto è probabilmente già "saturo": la domanda interessante è **con pochi**

È l'informazione più utile per chi volesse usare il sistema davvero.

Fabio — l'early stopping

- Nel paper: un *early stopping* "che salva il modello con la validation loss minima"
- Ma non si dice **su quali dati** si calcola la validation loss
- Se fosse il fold di **test**, avremmo scelto il modello guardando il test: risultati **gonfiati**

Dal codice: lo usa solo Llama, su un 10% degli articoli di training, quindi nessuna contaminazione. Ma va scritto.

Fabio — l'early stopping

- Nel paper: un *early stopping* "che salva il modello con la validation loss minima"
- Ma non si dice **su quali dati** si calcola la validation loss
- Se fosse il fold di **test**, avremmo scelto il modello guardando il test: risultati **gonfiati**

Dal codice: lo usa solo Llama, su un 10% degli articoli di training, quindi nessuna contaminazione. Ma va scritto.

Fabio — l'early stopping

- Nel paper: un *early stopping* "che salva il modello con la validation loss minima"
- Ma non si dice **su quali dati** si calcola la validation loss
- Se fosse il fold di **test**, avremmo scelto il modello guardando il test: risultati **gonfiati**

Dal codice: lo usa solo Llama, su un 10% degli articoli di training, quindi nessuna contaminazione. Ma va scritto.

Fabio — l'early stopping

- Nel paper: un *early stopping* "che salva il modello con la validation loss minima"
- Ma non si dice **su quali dati** si calcola la validation loss
- Se fosse il fold di **test**, avremmo scelto il modello guardando il test: risultati **gonfiati**

Dal codice: lo usa solo Llama, su un 10% degli articoli di training, quindi nessuna contaminazione. Ma va scritto.

Fabio — tema e periodo

- Gli articoli sono presi dalle homepage in un **periodo breve**: ogni testata porta i **temi del momento**
- Se tema e affidabilità vanno insieme, il modello potrebbe imparare il **tema**, non l'affidabilità

  Es.: se quella settimana le testate inaffidabili parlano tutte dello stesso argomento, basta riconoscere l'argomento.
- Controllo: classificare il tema degli articoli e vedere se è legato al livello

Fabio — tema e periodo

- Gli articoli sono presi dalle homepage in un **periodo breve**: ogni testata porta i **temi del momento**
- Se tema e affidabilità vanno insieme, il modello potrebbe imparare il **tema**, non l'affidabilità

  Es.: se quella settimana le testate inaffidabili parlano tutte dello stesso argomento, basta riconoscere l'argomento.

- Controllo: classificare il tema degli articoli e vedere se è legato al livello

Fabio — tema e periodo

- Gli articoli sono presi dalle homepage in un **periodo breve**: ogni testata porta i **temi del momento**
- Se tema e affidabilità vanno insieme, il modello potrebbe imparare il **tema**, non l'affidabilità

  Es.: se quella settimana le testate inaffidabili parlano tutte dello stesso argomento, basta riconoscere l'argomento.

- Controllo: classificare il tema degli articoli e vedere se è legato al livello

Fabio — tema e periodo

- Gli articoli sono presi dalle homepage in un **periodo breve**: ogni testata porta i **temi del momento**
- Se tema e affidabilità vanno insieme, il modello potrebbe imparare il **tema**, non l'affidabilità

  Es.: se quella settimana le testate inaffidabili parlano tutte dello stesso argomento, basta riconoscere l'argomento.
- Controllo: classificare il tema degli articoli e vedere se è legato al livello

Fabio — la classe l_5 e l'ordine dei livelli

- l_5 = punteggio **esattamente 100**: classe piccola e quasi impossibile da distinguere da l_4
- Proposta: **unire** l_4 e l_5, o riportare anche i risultati a 4 classi
- I livelli sono **ordinati**, ma il modello è addestrato come se fossero categorie slegate

In addestramento confondere l_5 con l_4 costa quanto confonderlo con l_1: va almeno detto come limite.

Fabio — la classe l_5 e l'ordine dei livelli

- l_5 = punteggio **esattamente 100**: classe piccola e quasi impossibile da distinguere da l_4
- Proposta: **unire** l_4 e l_5, o riportare anche i risultati a 4 classi
- I livelli sono **ordinati**, ma il modello è addestrato come se fossero categorie slegate

  In addestramento confondere l_5 con l_4 costa quanto confonderlo con l_1: va almeno detto come limite.

Fabio — la classe l_5 e l'ordine dei livelli

- l_5 = punteggio **esattamente 100**: classe piccola e quasi impossibile da distinguere da l_4
- Proposta: **unire** l_4 e l_5, o riportare anche i risultati a 4 classi
- I livelli sono **ordinati**, ma il modello è addestrato come se fossero categorie slegate

In addestramento confondere l_5 con l_4 costa quanto confonderlo con l_1: va almeno detto come limite.

Fabio — la classe l_5 e l'ordine dei livelli

- l_5 = punteggio **esattamente 100**: classe piccola e quasi impossibile da distinguere da l_4
- Proposta: **unire** l_4 e l_5, o riportare anche i risultati a 4 classi
- I livelli sono **ordinati**, ma il modello è addestrato come se fossero categorie slegate

  In addestramento confondere l_5 con l_4 costa quanto confonderlo con l_1: va almeno detto come limite.

Fabio — correzioni di scrittura (verificate)

- Bibliografia doppia: [4] = [15] (Przybyła & Soto), [5] = [20] (Srba et al.)
- [30] cita “Mixtral of Experts” per Mistral 24B: è un modello diverso
- Rinvii sbagliati: “In V-B we instantiate Agg” (è V-E), “Section IV-0c”
- Tabella II: BERT 58,27%, mentre il testo dice “around 0.60” (dato complessivo contro media sui fold)
- Il contributo 4 è un **risultato**, non un contributo; i contributi 1–2 si sovrappongono a Burdisso et al. [7]
- Dire chiaramente se il dataset è **rilasciabile** (etichette NewsGuard proprietarie)

Fabio — correzioni di scrittura (verificate)

- Bibliografia doppia: [4] = [15] (Przybyła & Soto), [5] = [20] (Srba et al.)
- [30] cita “Mixtral of Experts” per Mistral 24B: è un modello diverso
- Rinvii sbagliati: “In V-B we instantiate Agg” (è V-E), “Section IV-0c”
- Tabella II: BERT 58,27%, mentre il testo dice “around 0.60” (dato complessivo contro media sui fold)
- Il contributo 4 è un **risultato**, non un contributo; i contributi 1–2 si sovrappongono a Burdisso et al. [7]
- Dire chiaramente se il dataset è **rilasciabile** (etichette NewsGuard proprietarie)

Fabio — correzioni di scrittura (verificate)

- Bibliografia doppia: [4] = [15] (Przybyła & Soto), [5] = [20] (Srba et al.)
- [30] cita “Mixtral of Experts” per Mistral 24B: è un modello diverso
- Rinvii sbagliati: “In V-B we instantiate Agg” (è V-E), “Section IV-0c”
- Tabella II: BERT 58,27%, mentre il testo dice “around 0.60” (dato complessivo contro media sui fold)
- Il contributo 4 è un **risultato**, non un contributo; i contributi 1–2 si sovrappongono a Burdisso et al. [7]
- Dire chiaramente se il dataset è **rilasciabile** (etichette NewsGuard proprietarie)

Fabio — correzioni di scrittura (verificate)

- Bibliografia doppia: [4] = [15] (Przybyła & Soto), [5] = [20] (Srba et al.)
- [30] cita “Mixtral of Experts” per Mistral 24B: è un modello diverso
- Rinvii sbagliati: “In V-B we instantiate Agg” (è V-E), “Section IV-0c”
- Tabella II: BERT 58,27%, mentre il testo dice “around 0.60” (dato complessivo contro media sui fold)
- Il contributo 4 è un **risultato**, non un contributo; i contributi 1–2 si sovrappongono a Burdisso et al. [7]
- Dire chiaramente se il dataset è **rilasciabile** (etichette NewsGuard proprietarie)

Fabio — correzioni di scrittura (verificate)

- Bibliografia doppia: [4] = [15] (Przybyła & Soto), [5] = [20] (Srba et al.)
- [30] cita “Mixtral of Experts” per Mistral 24B: è un modello diverso
- Rinvii sbagliati: “In V-B we instantiate Agg” (è V-E), “Section IV-0c”
- Tabella II: BERT 58,27%, mentre il testo dice “around 0.60” (dato complessivo contro media sui fold)
- Il contributo 4 è un **risultato**, non un contributo; i contributi 1–2 si sovrappongono a Burdisso et al. [7]
- Dire chiaramente se il dataset è **rilasciabile** (etichette NewsGuard proprietarie)

Fabio — correzioni di scrittura (verificate)

- Bibliografia doppia: [4] = [15] (Przybyła & Soto), [5] = [20] (Srba et al.)
- [30] cita “Mixtral of Experts” per Mistral 24B: è un modello diverso
- Rinvii sbagliati: “In V-B we instantiate Agg” (è V-E), “Section IV-0c”
- Tabella II: BERT 58,27%, mentre il testo dice “around 0.60” (dato complessivo contro media sui fold)
- Il contributo 4 è un **risultato**, non un contributo; i contributi 1–2 si sovrappongono a Burdisso et al. [7]
- Dire chiaramente se il dataset è **rilasciabile** (etichette NewsGuard proprietarie)