Verso Web Science 2027

Riprendere il paper bocciato: recap del lavoro e prossimi passi

Riunione di gruppo

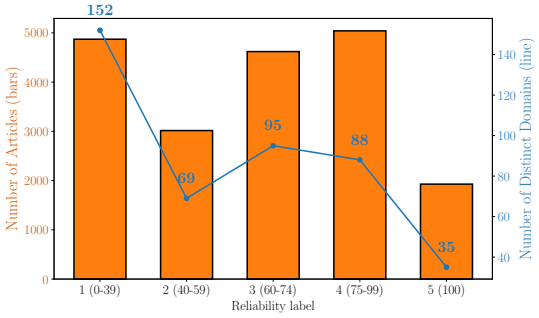
IMT Lucca & IIT-CNR Pisa

Recap del paper bocciato

non la versione sottomessa a IR for Good

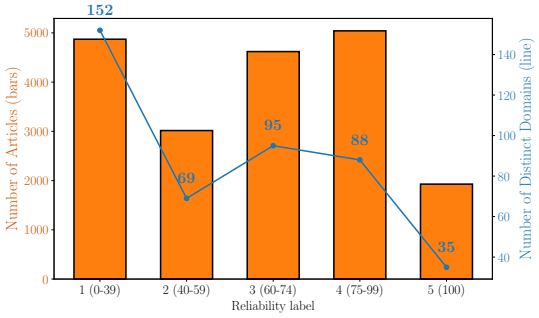
Dati

- Scraping con **newspaper3k**
- 439 editori, 19.476 articoli politici in inglese
- Etichette **NewsGuard**: 5 livelli l_1–l_5 (da 0–100)
- Ogni articolo **eredita** l'etichetta del suo editore



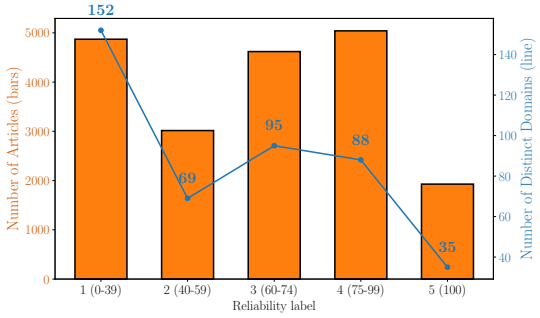
Dati

- Scraping con **newspaper3k**
- 439 editori, 19.476 articoli politici in inglese
- Etichette **NewsGuard**: 5 livelli l_1–l_5 (da 0–100)
- Ogni articolo **eredita** l'etichetta del suo editore



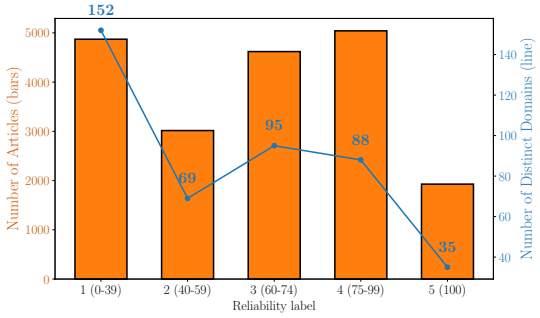
Dati

- Scraping con **newspaper3k**
- 439 editori, 19.476 articoli politici in inglese
- Etichette **NewsGuard**: 5 livelli l_1–l_5 (da 0–100)
- Ogni articolo **eredita** l'etichetta del suo editore



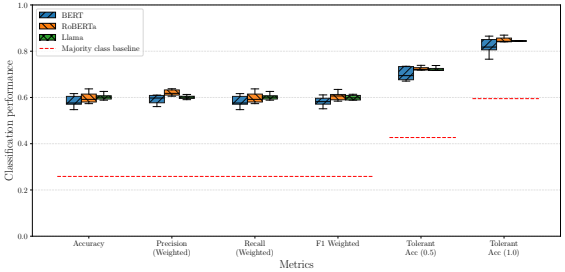
Dati

- Scraping con **newspaper3k**
- 439 editori, 19.476 articoli politici in inglese
- Etichette **NewsGuard**: 5 livelli l_1–l_5 (da 0–100)
- Ogni articolo **eredita** l'etichetta del suo editore



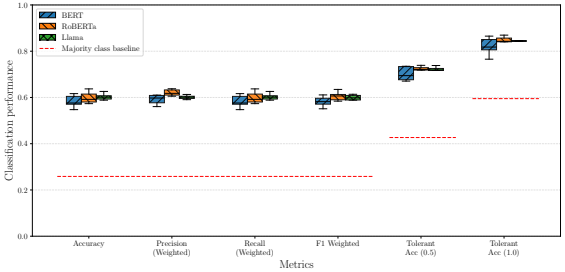
Classificazione — livello articolo

- Quattro transformer: **BERT, RoBERTa, Llama, Mistral**
- Encoder full fine-tuning, decoder con **LoRA**
- Input **256 token** (1024 per Mistral)
- Split **publisher-disjoint**: editori di test mai visti



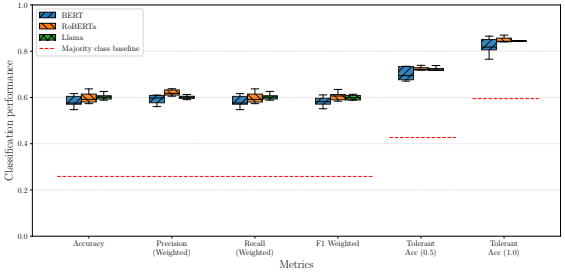
Classificazione — livello articolo

- Quattro transformer: **BERT, RoBERTa, Llama, Mistral**
- Encoder full fine-tuning, decoder con **LoRA**
- Input **256 token** (1024 per Mistral)
- Split **publisher-disjoint**: editori di test mai visti



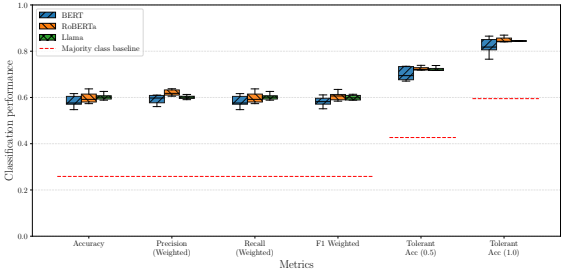
Classificazione — livello articolo

- Quattro transformer: **BERT, RoBERTa, Llama, Mistral**
- Encoder full fine-tuning, decoder con **LoRA**
- Input **256 token** (1024 per Mistral)
- Split **publisher-disjoint**: editori di test mai visti



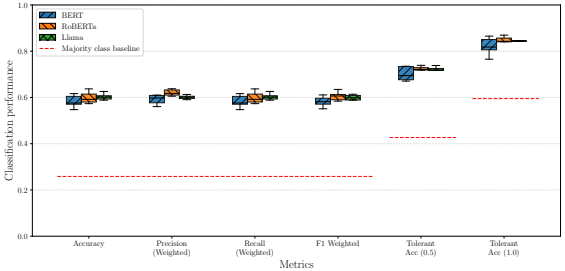
Classificazione — livello articolo

- Quattro transformer: **BERT, RoBERTa, Llama, Mistral**
- Encoder full fine-tuning, decoder con **LoRA**
- Input **256 token** (1024 per Mistral)
- Split **publisher-disjoint**: editori di test mai visti



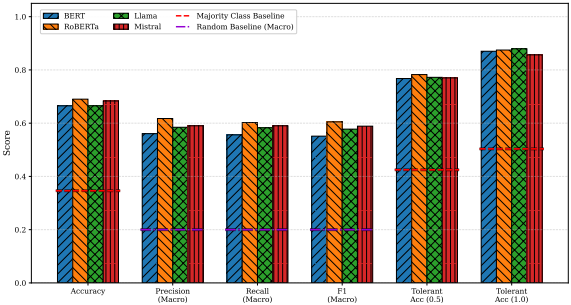
Classificazione — livello articolo

- Quattro transformer: **BERT, RoBERTa, Llama, Mistral**
- Encoder full fine-tuning, decoder con **LoRA**
- Input **256 token** (1024 per Mistral)
- Split **publisher-disjoint**: editori di test mai visti



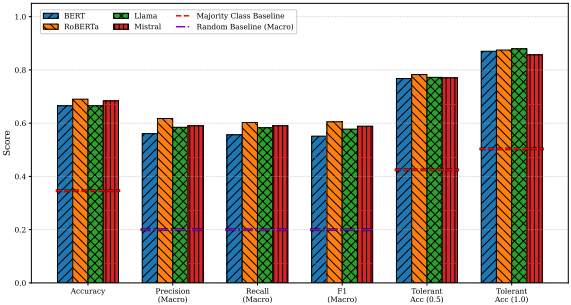
Aggregazione — livello editore

- Dall'articolo all'editore con **majority voting**
- Si usano **tutti** gli articoli della testata: nessun cap in aggregazione (fino a 200, mediana $\sim$34)
- Valutazione su editori **mai visti** in addestramento



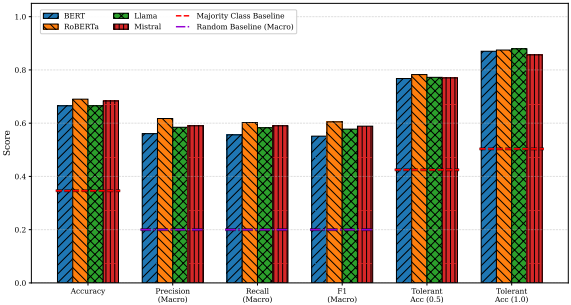
Aggregazione — livello editore

- Dall'articolo all'editore con **majority voting**
- Si usano **tutti** gli articoli della testata: nessun cap in aggregazione (fino a 200, mediana $\sim$34)
- Valutazione su editori **mai visti** in addestramento



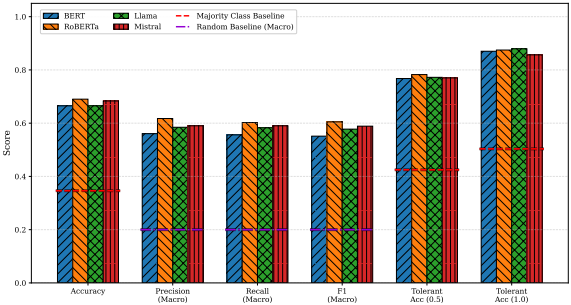
Aggregazione — livello editore

- Dall'articolo all'editore con **majority voting**
- Si usano **tutti** gli articoli della testata: nessun cap in aggregazione (fino a 200, mediana $\sim$34)
- Valutazione su editori **mai visti** in addestramento



Aggregazione — livello editore

- Dall'articolo all'editore con **majority voting**
- Si usano **tutti** gli articoli della testata: nessun cap in aggregazione (fino a 200, mediana $\sim$34)
- Valutazione su editori **mai visti** in addestramento



Perché analizziamo gli errori

- Oltre alle metriche aggregate, vogliamo capire **come** e **perché** i modelli sbagliano

  "Beyond aggregate performance, we investigate how and why models fail."

- Obiettivo: trovare **debolezze strutturali** — su quali livelli sbaglia e se sovra/sottostima

  "To detect structural weaknesses. . . "

Perché analizziamo gli errori

- Oltre alle metriche aggregate, vogliamo capire **come** e **perché** i modelli sbagliano

  "Beyond aggregate performance, we investigate how and why models fail."

- Obiettivo: trovare **debolezze strutturali** — su quali livelli sbaglia e se sovra/sottostima

  "To detect structural weaknesses. . . "

Perché analizziamo gli errori

- Oltre alle metriche aggregate, vogliamo capire **come** e **perché** i modelli sbagliano

  "Beyond aggregate performance, we investigate how and why models fail."

- Obiettivo: trovare **debolezze strutturali** — su quali livelli sbaglia e se sovra/sottostima

  "To detect structural weaknesses. . . "

Perché analizziamo gli errori

- Oltre alle metriche aggregate, vogliamo capire **come** e **perché** i modelli sbagliano

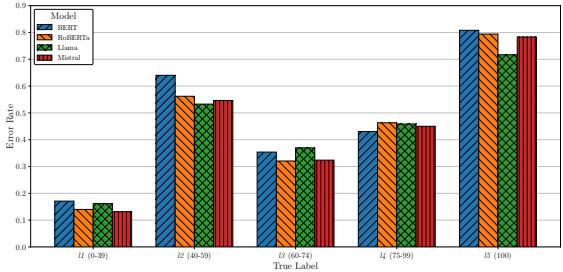
  "Beyond aggregate performance, we investigate how and why models fail."

- Obiettivo: trovare **debolezze strutturali** — su quali livelli sbaglia e se sovra/sottostima

  "To detect structural weaknesses. . . "

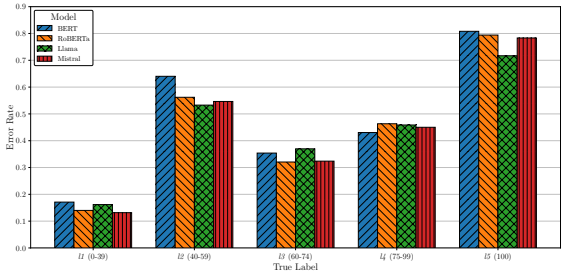
Analisi dell'errore — per livello

- **Error rate** per ogni livello di affidabilità
- l_1 il più **facile**: contenuti molto inaffidabili riconoscibili
- l_5 il più **difficile**: si confonde con l_4
- l_2 difficile, l_3 intermedio



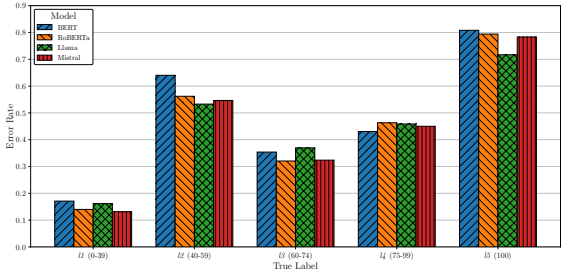
Analisi dell'errore — per livello

- **Error rate** per ogni livello di affidabilità
- l_1 il più **facile**: contenuti molto inaffidabili riconoscibili
- l_5 il più **difficile**: si confonde con l_4
- l_2 difficile, l_3 intermedio



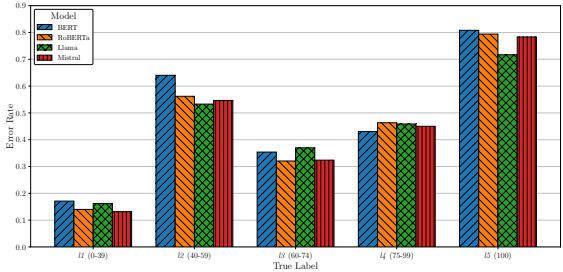
Analisi dell'errore — per livello

- **Error rate** per ogni livello di affidabilità
- l_1 il più **facile**: contenuti molto inaffidabili riconoscibili
- l_5 il più **difficile**: si confonde con l_4
- l_2 difficile, l_3 intermedio



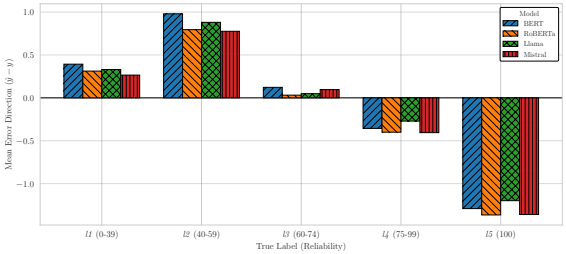
Analisi dell'errore — per livello

- **Error rate** per ogni livello di affidabilità
- l_1 il più **facile**: contenuti molto inaffidabili riconoscibili
- l_5 il più **difficile**: si confonde con l_4
- l_2 difficile, l_3 intermedio



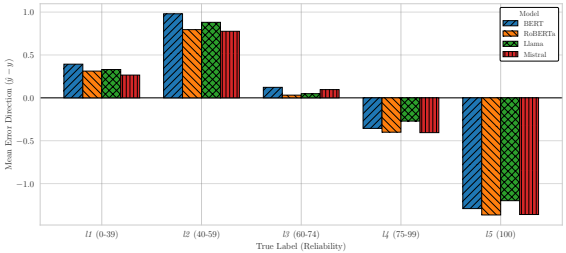
Analisi dell'errore — direzione

- **Mean Error Direction**: l'errore *sovrastima* (+) o *sottostima* (−) l'affidabilità
- Livelli **bassi sovrastimati**, livelli **alti sottostimati**
- Gli errori "tirano verso il **centro**" della scala



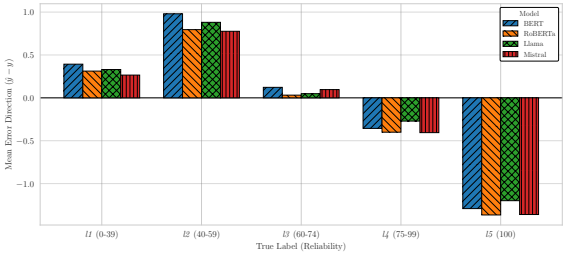
Analisi dell'errore — direzione

- **Mean Error Direction**: l'errore *sovrastima* (+) o *sottostima* (−) l'affidabilità
- Livelli **bassi sovrastimati**, livelli **alti sottostimati**
- Gli errori "tirano verso il **centro**" della scala



Analisi dell'errore — direzione

- **Mean Error Direction**: l'errore *sovrastima* (+) o *sottostima* (−) l'affidabilità
- Livelli **bassi sovrastimati**, livelli **alti sottostimati**
- Gli errori "tirano verso il **centro**" della scala



Perché analizziamo il bias politico

- Vogliamo sapere se il modello **tratta allo stesso modo** tutto lo spettro politico, o se **penalizza** certi orientamenti

  "...determine if the models exhibit political bias...whether the models treat all sides of the political spectrum equally or if they penalize specific orientations."

- Serve una valutazione **bias-aware**: un sistema in uso con bias politico può fare danni

  "...the need for bias-aware evaluation protocols..."

Perché analizziamo il bias politico

- Vogliamo sapere se il modello **tratta allo stesso modo** tutto lo spettro politico, o se **penalizza** certi orientamenti

  "...determine if the models exhibit political bias...whether the models treat all sides of the political spectrum equally or if they penalize specific orientations."

- Serve una valutazione **bias-aware**: un sistema in uso con bias politico può fare danni

  "...the need for bias-aware evaluation protocols..."

Perché analizziamo il bias politico

- Vogliamo sapere se il modello **tratta allo stesso modo** tutto lo spettro politico, o se **penalizza** certi orientamenti

  "... determine if the models exhibit political bias... whether the models treat all sides of the political spectrum equally or if they penalize specific orientations."

- Serve una valutazione **bias-aware**: un sistema in uso con bias politico può fare danni

  "... the need for bias-aware evaluation protocols..."

Perché analizziamo il bias politico

- Vogliamo sapere se il modello **tratta allo stesso modo** tutto lo spettro politico, o se **penalizza** certi orientamenti

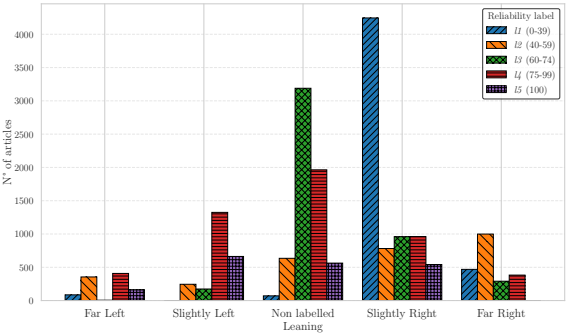
  "...determine if the models exhibit political bias...whether the models treat all sides of the political spectrum equally or if they penalize specific orientations."

- Serve una valutazione **bias-aware**: un sistema in uso con bias politico può fare danni

  "...the need for bias-aware evaluation protocols..."

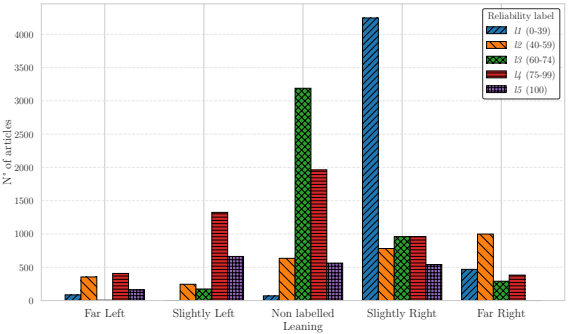
Bias politico — distribuzione dei dati

- Orientamento ereditato dall'editore (analisi *a posteriori*)
- Dentro ogni orientamento, come si distribuiscono i livelli
- Distribuzione molto **sbilanciata** (proprietà del sistema mediatico)
- Per questo gli error rate si calcolano **classe per classe**



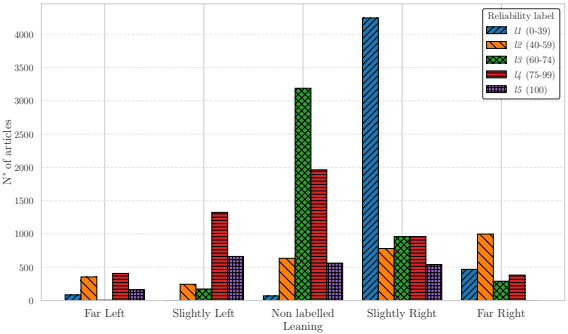
Bias politico — distribuzione dei dati

- Orientamento ereditato dall'editore (analisi *a posteriori*)
- Dentro ogni orientamento, come si distribuiscono i livelli
- Distribuzione molto **sbilanciata** (proprietà del sistema mediatico)
- Per questo gli error rate si calcolano **classe per classe**



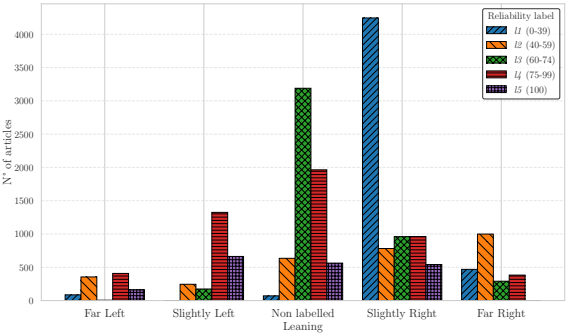
Bias politico — distribuzione dei dati

- Orientamento ereditato dall'editore (analisi *a posteriori*)
- Dentro ogni orientamento, come si distribuiscono i livelli
- Distribuzione molto **sbilanciata** (proprietà del sistema mediatico)
- Per questo gli error rate si calcolano **classe per classe**



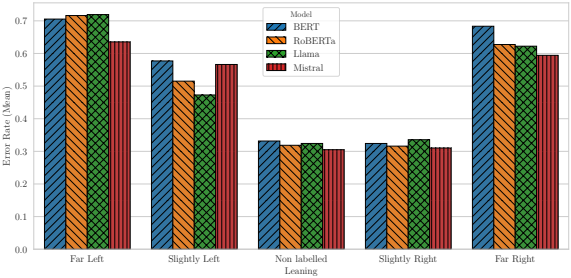
Bias politico — distribuzione dei dati

- Orientamento ereditato dall'editore (analisi *a posteriori*)
- Dentro ogni orientamento, come si distribuiscono i livelli
- Distribuzione molto **sbilanciata** (proprietà del sistema mediatico)
- Per questo gli error rate si calcolano **classe per classe**



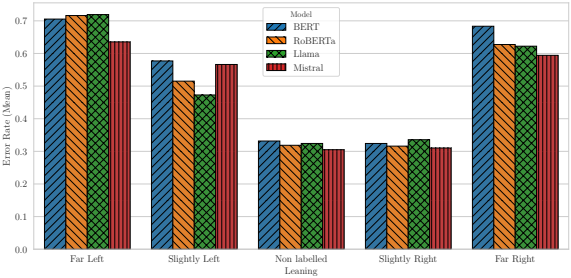
Bias politico — error rate

- **Error rate** per orientamento politico
- Gli estremi (**far left**, **far right**) sbagliano molto di più
- Slightly right e non labelled i più **facili**



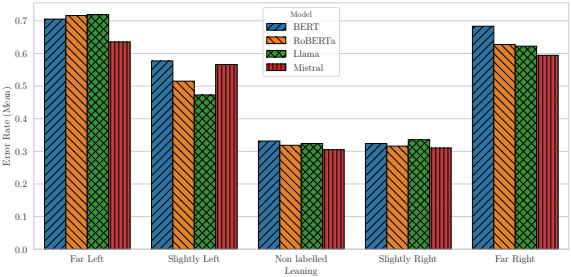
Bias politico — error rate

- **Error rate** per orientamento politico
- Gli estremi (**far left**, **far right**) sbagliano molto di più
- Slightly right e non labelled i più **facili**



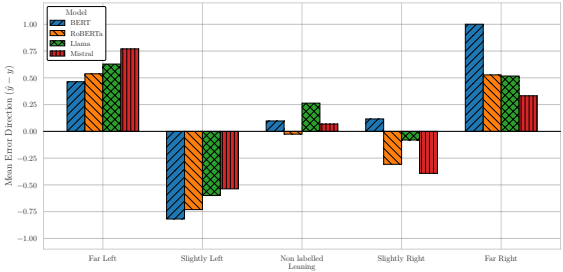
Bias politico — error rate

- **Error rate** per orientamento politico
- Gli estremi (**far left**, **far right**) sbagliano molto di più
- Slightly right e non labelled i più **facili**



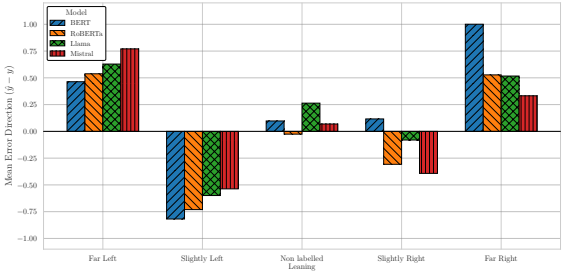
Bias politico — direzione dell'errore

- **Mean Error Direction** per orientamento
- Estremi (far left, far right) **sovrastimati**
- Slightly left **sottostimato**
- Slightly right e non labelled: deviazioni piccole



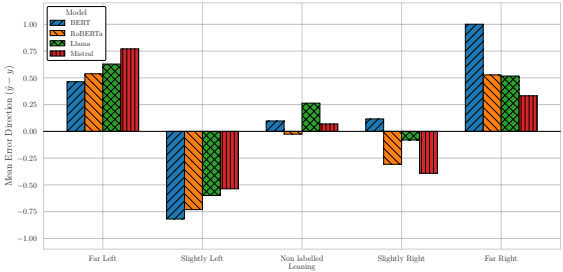
Bias politico — direzione dell'errore

- **Mean Error Direction** per orientamento
- Estremi (far left, far right) **sovrastimati**
- Slightly left **sottostimato**
- Slightly right e non labelled: deviazioni piccole



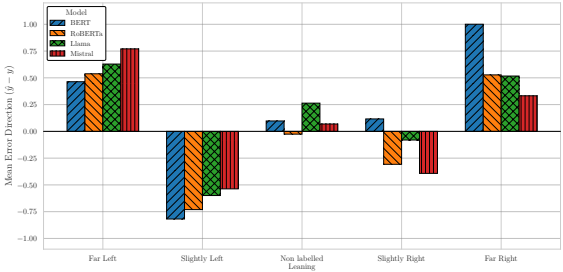
Bias politico — direzione dell'errore

- **Mean Error Direction** per orientamento
- Estremi (far left, far right) **sovrastimati**
- Slightly left **sottostimato**
- Slightly right e non labelled: deviazioni piccole



Bias politico — direzione dell'errore

- **Mean Error Direction** per orientamento
- Estremi (far left, far right) **sovrastimati**
- Slightly left **sottostimato**
- Slightly right e non labelled: deviazioni piccole



È un vero legame o è un caso?

- Vediamo error rate diversi tra gli orientamenti.
- Ma potrebbe essere solo **rumore** dei dati.
- Serve un **test statistico** che dica: questo legame è reale?

Strumento usato: il **test del chi-quadro (χ^2) di indipendenza**.

È un vero legame o è un caso?

- Vediamo error rate diversi tra gli orientamenti.
- Ma potrebbe essere solo **rumore** dei dati.
- Serve un **test statistico** che dica: questo legame è reale?

Strumento usato: il **test del chi-quadro (χ^2) di indipendenza**.

È un vero legame o è un caso?

- Vediamo error rate diversi tra gli orientamenti.
- Ma potrebbe essere solo **rumore** dei dati.
- Serve un **test statistico** che dica: questo legame è reale?

Strumento usato: il **test del chi-quadro (χ^2) di indipendenza**.

È un vero legame o è un caso?

- Vediamo error rate diversi tra gli orientamenti.
- Ma potrebbe essere solo **rumore** dei dati.
- Serve un **test statistico** che dica: questo legame è reale?

Strumento usato: il **test del chi-quadro (χ^2) di indipendenza**.

Passo 1 — mettiamo gli errori in tabella

- Per ogni orientamento contiamo **giusti** e **sbagliati**
- È la **tabella di contingenza**
- Agli estremi gli sbagliati superano i giusti

Orientamento	Giusti	Sbagliati
Far Left	299	716
Slightly Left	1018	1389
Non labelled	4292	2130
Slightly Right	5062	2428
Far Right	678	1464

(esempio: BERT)

Passo 1 — mettiamo gli errori in tabella

- Per ogni orientamento contiamo **giusti** e **sbagliati**
- È la **tabella di contingenza**
- Agli estremi gli sbagliati superano i giusti

Orientamento	**Giusti**	**Sbagliati**
Far Left	299	716
Slightly Left	1018	1389
Non labelled	4292	2130
Slightly Right	5062	2428
Far Right	678	1464

(esempio: BERT)

Passo 1 — mettiamo gli errori in tabella

- Per ogni orientamento contiamo **giusti** e **sbagliati**
- È la **tabella di contingenza**
- Agli estremi gli sbagliati superano i giusti

Orientamento	**Giusti**	**Sbagliati**
Far Left	299	716
Slightly Left	1018	1389
Non labelled	4292	2130
Slightly Right	5062	2428
Far Right	678	1464

(esempio: BERT)

Passo 2 — l'idea del chi-quadro

- Immaginiamo che l'orientamento **non c'entri** con gli errori.
- Allora ogni gruppo dovrebbe sbagliare **nella stessa proporzione** (circa la media, $\sim$42%).
- Il χ^2 misura **quanto** gli errori *osservati* si allontanano da questo scenario "senza legame".
- Più grande è lo scarto $\rightarrow$ χ^2 grande $\rightarrow$ più probabile che un legame ci sia.

Passo 2 — l'idea del chi-quadro

- Immaginiamo che l'orientamento **non c'entri** con gli errori.
- Allora ogni gruppo dovrebbe sbagliare **nella stessa proporzione** (circa la media, $\sim$42%).
- Il χ^2 misura **quanto** gli errori *osservati* si allontanano da questo scenario "senza legame".
- Più grande è lo scarto $\rightarrow$ χ^2 grande $\rightarrow$ più probabile che un legame ci sia.

Passo 2 — l'idea del chi-quadro

- Immaginiamo che l'orientamento **non c'entri** con gli errori.
- Allora ogni gruppo dovrebbe sbagliare **nella stessa proporzione** (circa la media, $\sim$42%).
- Il χ^2 misura **quanto** gli errori *osservati* si allontanano da questo scenario "senza legame".
- Più grande è lo scarto $\rightarrow$ χ^2 grande $\rightarrow$ più probabile che un legame ci sia.

Passo 2 — l'idea del chi-quadro

- Immaginiamo che l'orientamento **non c'entri** con gli errori.
- Allora ogni gruppo dovrebbe sbagliare **nella stessa proporzione** (circa la media, $\sim$42%).
- Il χ^2 misura **quanto** gli errori *osservati* si allontanano da questo scenario "senza legame".
- Più grande è lo scarto $\rightarrow$ χ^2 grande $\rightarrow$ più probabile che un legame ci sia.

Passo 3 — il p-value

- Un χ^2 grande potrebbe capitare **per caso**?
- Il p-**value** è la probabilità di vedere uno scarto così grande *se non ci fosse nessun legame*.
- p piccolissimo (es. $p < 0.001$) $\rightarrow$ quasi impossibile che sia un caso.
- Quindi il legame è **reale**, non fortuna.

Passo 3 — il p-value

- Un χ^2 grande potrebbe capitare **per caso**?
- Il p-**value** è la probabilità di vedere uno scarto così grande *se non ci fosse nessun legame*.
- p piccolissimo (es. $p < 0.001$) $\rightarrow$ quasi impossibile che sia un caso.
- Quindi il legame è **reale**, non fortuna.

Passo 3 — il p-value

- Un χ^2 grande potrebbe capitare **per caso**?
- Il p-**value** è la probabilità di vedere uno scarto così grande *se non ci fosse nessun legame*.
- p piccolissimo (es. $p < 0.001$) $\rightarrow$ quasi impossibile che sia un caso.
- Quindi il legame è **reale**, non fortuna.

Passo 3 — il p-value

- Un χ^2 grande potrebbe capitare **per caso**?
- Il p-**value** è la probabilità di vedere uno scarto così grande *se non ci fosse nessun legame*.
- p piccolissimo (es. $p < 0.001$) $\rightarrow$ quasi impossibile che sia un caso.
- Quindi il legame è **reale**, non fortuna.

Passo 4 — quanto è forte? (Cramér's V)

- Il *p*-value dice **se** c'è un legame, non **quanto** è forte.
- Con tanti dati anche un legame **piccolo** risulta "significativo".
- **Cramér's V** misura la **forza**: 0 = nessun legame, 1 = legame massimo.

Passo 4 — quanto è forte? (Cramér's V)

- Il *p*-value dice **se** c'è un legame, non **quanto** è forte.
- Con tanti dati anche un legame **piccolo** risulta "significativo".
- **Cramér's V** misura la **forza**: 0 = nessun legame, 1 = legame massimo.

Passo 4 — quanto è forte? (Cramér's V)

- Il *p*-value dice **se** c'è un legame, non **quanto** è forte.
- Con tanti dati anche un legame **piccolo** risulta "significativo".
- **Cramér's V** misura la **forza**: 0 = nessun legame, 1 = legame massimo.

In sintesi

- Legame **statisticamente significativo** (tutti i modelli)
- Forza **piccola–moderata** (V $\approx$ 0.25–0.29)
- Direzione: estremi **sovrastimati**, slightly left **sottostimati**

Model	χ^2	p	V
BERT	1684	$< 10^{-300}$	0.294
RoBERTa	1418	$< 10^{-300}$	0.270
Llama	1208	$< 10^{-250}$	0.249
Mistral	1344	$< 10^{-300}$	0.263

In sintesi

- Legame **statisticamente significativo** (tutti i modelli)
- Forza **piccola–moderata** (V $\approx$ 0.25–0.29)
- Direzione: estremi **sovrastimati**, slightly left **sottostimati**

Model	χ^2	p	**V**
BERT	1684	$< 10^{-300}$	0.294
RoBERTa	1418	$< 10^{-300}$	0.270
Llama	1208	$< 10^{-250}$	0.249
Mistral	1344	$< 10^{-300}$	0.263

In sintesi

- Legame **statisticamente significativo** (tutti i modelli)
- Forza **piccola–moderata** (V $\approx$ 0.25–0.29)
- Direzione: estremi **sovrastimati**, slightly left **sottostimati**

Model	χ^2	p	**V**
BERT	1684	$< 10^{-300}$	0.294
RoBERTa	1418	$< 10^{-300}$	0.270
Llama	1208	$< 10^{-250}$	0.249
Mistral	1344	$< 10^{-300}$	0.263

Nel materiale supplementare

- Matrici di confusione per **fold** (livello articolo)
- Matrici di confusione a **livello editore** (dopo aggregazione)
- Matrici di confusione per **orientamento politico**
- **Analisi di convergenza**: curve di loss (Llama, Mistral)

Dettagli a supporto delle analisi del paper, non nuovi risultati.

Nel materiale supplementare

- Matrici di confusione per **fold** (livello articolo)
- Matrici di confusione a **livello editore** (dopo aggregazione)
- Matrici di confusione per **orientamento politico**
- **Analisi di convergenza**: curve di loss (Llama, Mistral)

Dettagli a supporto delle analisi del paper, non nuovi risultati.

Nel materiale supplementare

- Matrici di confusione per **fold** (livello articolo)
- Matrici di confusione a **livello editore** (dopo aggregazione)
- Matrici di confusione per **orientamento politico**
- **Analisi di convergenza**: curve di loss (Llama, Mistral)

Dettagli a supporto delle analisi del paper, non nuovi risultati.

Nel materiale supplementare

- Matrici di confusione per **fold** (livello articolo)
- Matrici di confusione a **livello editore** (dopo aggregazione)
- Matrici di confusione per **orientamento politico**
- **Analisi di convergenza**: curve di loss (Llama, Mistral)

Dettagli a supporto delle analisi del paper, non nuovi risultati.

Nel materiale supplementare

- Matrici di confusione per **fold** (livello articolo)
- Matrici di confusione a **livello editore** (dopo aggregazione)
- Matrici di confusione per **orientamento politico**
- **Analisi di convergenza**: curve di loss (Llama, Mistral)

Dettagli a supporto delle analisi del paper, non nuovi risultati.

Le review dei revisori

quali critiche affrontare

Revisore 1 — (1) Novità metodologica limitata

"The two-stage framework is essentially standard fine-tuning of pretrained language models followed by majority voting. The main contribution seems to be the task formulation, dataset construction, and evaluation setup, rather than a new model architecture, learning objective, or aggregation method."

Revisore 1 — (2) Il guadagno dell'aggregazione non è misurato pulito

"The comparison between the article-level score (∼0.60) and the publisher-level score (∼0.69) changes both the evaluation unit and the weighting of publishers. As a result, the improvement cannot be attributed to aggregation alone."

Revisore 1 — (3) Bias confuso con il livello di affidabilità

"The distribution of reliability labels differs substantially across political leanings, and some reliability levels are clearly more difficult to classify than others. The relationship between political leaning and prediction error should therefore be tested again after controlling for the true reliability level."

Revisore 1 — (4) Il chi-quadro ignora il clustering

"Political leaning and reliability are publisher-level attributes shared by multiple articles from the same publisher. Using all articles as independent observations may lead to pseudo-replication and overstate the effective sample size and significance of the results."

Revisore 1 — (5) Indizi dell'editore e artefatti non esclusi

"The paper does not include systematic text cleaning, source-identifier masking, or sanitized-text ablations. It is therefore difficult to tell whether the model is learning reliability-related content or simply exploiting publisher-specific signals and scraping artifacts."

Revisore 1 — (6) Possibile bias di selezione nello scraping

"Only 439 of the 669 candidate publishers were included in the final dataset, and the scraping success rates differ across reliability levels. The paper does not examine whether the publishers that were successfully scraped differ systematically from those that were not."

Revisore 1 — (7) Confronto sulla taglia del modello non controllato

"The models differ in architecture, fine-tuning strategy, training schedule, and context length, in addition to parameter count. The observed performance differences therefore cannot be attributed to model size alone."

Revisore 1 — (8) Nessuna stima di incertezza

"Differences such as 0.69 versus 0.68 are small, but the paper does not report confidence intervals, bootstrap results, or paired significance tests. It is therefore unclear whether these differences are meaningful."

Revisore 2 — (1) Motivazione debole del passaggio a livello editore

"publisher reliability is, by construction, obtained as a fixed aggregation of article-level outputs. . . the re-formulation does not introduce substantial new insight beyond a change in the unit of evaluation."

Revisore 2 — (2) Mancano confronti con altri scorer

"Publisher-level scores can equally be produced by first scoring individual articles with a model pretrained specifically for article-level reliability classification, or with a general-purpose LLM such as Qwen, and then applying the same voting strategy. . . No such comparison is reported."

Revisore 2 — (3) Il dataset non è “large-scale”

“Although the corpus contains 19,476 articles, the objective of the paper is scoring at the level of the publisher, and the dataset comprises only 439 publishers. The dataset is therefore unlikely to support effective use in real-world applications.”

Oltre le review: due analisi

Marinella con ChatGPT · Fabio con Claude

Due analisi di supporto

- Oltre ai due revisori del journal, due analisi del paper fatte con strumenti AI
- **Marinella** con **ChatGPT** — focalizzata sulla statistica del bias
- **Fabio** con **Claude** — review completa + analisi quantitativa del bias
- Fatte in modo **indipendente**: le riassumiamo qui, così le conosciamo tutti

Due analisi di supporto

- Oltre ai due revisori del journal, due analisi del paper fatte con strumenti AI
- **Marinella** con **ChatGPT** — focalizzata sulla statistica del bias
- **Fabio** con **Claude** — review completa + analisi quantitativa del bias
- Fatte in modo **indipendente**: le riassumiamo qui, così le conosciamo tutti

Due analisi di supporto

- Oltre ai due revisori del journal, due analisi del paper fatte con strumenti AI
- **Marinella** con **ChatGPT** — focalizzata sulla statistica del bias
- **Fabio** con **Claude** — review completa + analisi quantitativa del bias
- Fatte in modo **indipendente**: le riassumiamo qui, così le conosciamo tutti

Due analisi di supporto

- Oltre ai due revisori del journal, due analisi del paper fatte con strumenti AI
- **Marinella** con **ChatGPT** — focalizzata sulla statistica del bias
- **Fabio** con **Claude** — review completa + analisi quantitativa del bias
- Fatte in modo **indipendente**: le riassumiamo qui, così le conosciamo tutti

Marinella × ChatGPT

- È una revisione **statistica** della sezione bias
- Il χ^2 ad articolo non è un test valido come analisi principale (articoli non indipendenti) → test a livello di editore
- Leaning e reliability: problema di **overlap/positivity**, non solo "entangled" — "controlling for reliability" rischia di sembrare più conclusivo di quanto sia
- La MED calcolata solo sugli errori può fuorviare → riportare anche il bias su *tutti* gli articoli
- Linguaggio: "reference labels" invece di "ground truth"; cautela su "small-to-moderate"
- Messaggio: stiamo misurando un'**associazione**, non una discriminazione causata dal modello

Marinella × ChatGPT

- È una revisione **statistica** della sezione bias
- Il χ^2 ad articolo non è un test valido come analisi principale (articoli non indipendenti) $\rightarrow$ test a livello di editore
- Leaning e reliability: problema di **overlap/positivity**, non solo "entangled" — "controlling for reliability" rischia di sembrare più conclusivo di quanto sia
- La MED calcolata solo sugli errori può fuorviare $\rightarrow$ riportare anche il bias su *tutti* gli articoli
- Linguaggio: "reference labels" invece di "ground truth"; cautela su "small-to-moderate"
- Messaggio: stiamo misurando un'**associazione**, non una discriminazione causata dal modello

Marinella × ChatGPT

- È una revisione **statistica** della sezione bias
- Il χ^2 ad articolo non è un test valido come analisi principale (articoli non indipendenti) $\rightarrow$ test a livello di editore
- Leaning e reliability: problema di **overlap/positivity**, non solo "entangled" — "controlling for reliability" rischia di sembrare più conclusivo di quanto sia
- La MED calcolata solo sugli errori può fuorviare $\rightarrow$ riportare anche il bias su *tutti* gli articoli
- Linguaggio: "reference labels" invece di "ground truth"; cautela su "small-to-moderate"
- Messaggio: stiamo misurando un'**associazione**, non una discriminazione causata dal modello

Marinella × ChatGPT

- È una revisione **statistica** della sezione bias
- Il χ^2 ad articolo non è un test valido come analisi principale (articoli non indipendenti) $\rightarrow$ test a livello di editore
- Leaning e reliability: problema di **overlap/positivity**, non solo "entangled" — "controlling for reliability" rischia di sembrare più conclusivo di quanto sia
- La MED calcolata solo sugli errori può fuorviare $\rightarrow$ riportare anche il bias su *tutti* gli articoli
- Linguaggio: "reference labels" invece di "ground truth"; cautela su "small-to-moderate"
- Messaggio: stiamo misurando un'**associazione**, non una discriminazione causata dal modello

Marinella × ChatGPT

- È una revisione **statistica** della sezione bias
- Il χ^2 ad articolo non è un test valido come analisi principale (articoli non indipendenti) $\rightarrow$ test a livello di editore
- Leaning e reliability: problema di **overlap/positivity**, non solo "entangled" — "controlling for reliability" rischia di sembrare più conclusivo di quanto sia
- La MED calcolata solo sugli errori può fuorviare $\rightarrow$ riportare anche il bias su *tutti* gli articoli
- Linguaggio: "reference labels" invece di "ground truth"; cautela su "small-to-moderate"
- Messaggio: stiamo misurando un'**associazione**, non una discriminazione causata dal modello

Marinella × ChatGPT

- È una revisione **statistica** della sezione bias
- Il χ^2 ad articolo non è un test valido come analisi principale (articoli non indipendenti) $\rightarrow$ test a livello di editore
- Leaning e reliability: problema di **overlap/positivity**, non solo "entangled" — "controlling for reliability" rischia di sembrare più conclusivo di quanto sia
- La MED calcolata solo sugli errori può fuorviare $\rightarrow$ riportare anche il bias su *tutti* gli articoli
- Linguaggio: "reference labels" invece di "ground truth"; cautela su "small-to-moderate"
- Messaggio: stiamo misurando un'**associazione**, non una discriminazione causata dal modello

Fabio × Claude — (1) idee e review

- Tre parti: idee sui modelli, una review completa, un'analisi quantitativa del bias
- **Modelli**: gli LLM grandi "conoscono" le testate per nome (contaminazione) → i piccoli fine-tuned sono lo strumento giusto; baseline LLM con **mascheramento dei nomi**
- Idee nuove: LLM come **estrattore di feature** + classificatore; **embeddings + multiple-instance learning**
- **Review** (major revision): baseline deboli, aggregazione non studiata, incertezza mancante, bias confuso

Fabio × Claude — (1) idee e review

- Tre parti: idee sui modelli, una review completa, un'analisi quantitativa del bias
- **Modelli**: gli LLM grandi "conoscono" le testate per nome (contaminazione) → i piccoli fine-tuned sono lo strumento giusto; baseline LLM con **mascheramento dei nomi**
- Idee nuove: LLM come **estrattore di feature** + classificatore; **embeddings + multiple-instance learning**
- **Review** (major revision): baseline deboli, aggregazione non studiata, incertezza mancante, bias confuso

Fabio × Claude — (1) idee e review

- Tre parti: idee sui modelli, una review completa, un'analisi quantitativa del bias
- **Modelli**: gli LLM grandi "conoscono" le testate per nome (contaminazione) → i piccoli fine-tuned sono lo strumento giusto; baseline LLM con **mascheramento dei nomi**
- Idee nuove: LLM come **estrattore di feature** + classificatore; **embeddings + multiple-instance learning**
- **Review** (major revision): baseline deboli, aggregazione non studiata, incertezza mancante, bias confuso

Fabio × Claude — (1) idee e review

- Tre parti: idee sui modelli, una review completa, un'analisi quantitativa del bias
- **Modelli**: gli LLM grandi "conoscono" le testate per nome (contaminazione) → i piccoli fine-tuned sono lo strumento giusto; baseline LLM con **mascheramento dei nomi**
- Idee nuove: LLM come **estrattore di feature** + classificatore; **embeddings + multiple-instance learning**
- **Review** (major revision): baseline deboli, aggregazione non studiata, incertezza mancante, bias confuso

Fabio × Claude — (2) l'analisi del bias

- Dalle matrici di confusione ha ricostruito l'errore per **(livello × orientamento)**
- "Slightly Left sottostimata" è un **artefatto di composizione** → va tolta
- "Gli estremi sbagliano di più" regge, ma perché sono la **minoranza** del loro livello
- Il modello ha imparato l'orientamento come **scorciatoia** → spiega anche il nullo di Mistral
- È la riformulazione più forte della sezione bias

Fabio × Claude — (2) l'analisi del bias

- Dalle matrici di confusione ha ricostruito l'errore per **(livello × orientamento)**
- "Slightly Left sottostimata" è un **artefatto di composizione** → va tolta
- "Gli estremi sbagliano di più" regge, ma perché sono la **minoranza** del loro livello
- Il modello ha imparato l'orientamento come **scorciatoia** → spiega anche il nullo di Mistral
- È la riformulazione più forte della sezione bias

Fabio × Claude — (2) l'analisi del bias

- Dalle matrici di confusione ha ricostruito l'errore per **(livello × orientamento)**
- "Slightly Left sottostimata" è un **artefatto di composizione** → va tolta
- "Gli estremi sbagliano di più" regge, ma perché sono la **minoranza** del loro livello
- Il modello ha imparato l'orientamento come **scorciatoia** → spiega anche il nullo di Mistral
- È la riformulazione più forte della sezione bias

Fabio × Claude — (2) l'analisi del bias

- Dalle matrici di confusione ha ricostruito l'errore per **(livello × orientamento)**
- "Slightly Left sottostimata" è un **artefatto di composizione** → va tolta
- "Gli estremi sbagliano di più" regge, ma perché sono la **minoranza** del loro livello
- Il modello ha imparato l'orientamento come **scorciatoia** → spiega anche il nullo di Mistral
- È la riformulazione più forte della sezione bias

Fabio × Claude — (2) l'analisi del bias

- Dalle matrici di confusione ha ricostruito l'errore per **(livello × orientamento)**
- "Slightly Left sottostimata" è un **artefatto di composizione** → va tolta
- "Gli estremi sbagliano di più" regge, ma perché sono la **minoranza** del loro livello
- Il modello ha imparato l'orientamento come **scorciatoia** → spiega anche il nullo di Mistral
- È la riformulazione più forte della sezione bias

Cosa hanno in comune

- Entrambe convergono col Revisore 1: il nodo è il **confondimento** leaning/reliability e il **clustering**
- Fabio va oltre: lo **quantifica** e propone la riscrittura
- La sezione bias è il punto che decide il nuovo paper

Cosa hanno in comune

- Entrambe convergono col Revisore 1: il nodo è il **confondimento** leaning/reliability e il **clustering**
- Fabio va oltre: lo **quantifica** e propone la riscrittura
- La sezione bias è il punto che decide il nuovo paper

Cosa hanno in comune

- Entrambe convergono col Revisore 1: il nodo è il **confondimento** leaning/reliability e il **clustering**
- Fabio va oltre: lo **quantifica** e propone la riscrittura
- La sezione bias è il punto che decide il nuovo paper