# Verso Web Science 2027

## Riprendere il paper bocciato: recap del lavoro e prossimi passi

Riunione di gruppo

IMT Lucca & IIT-CNR Pisa

# Recap del paper bocciato

non la versione sottomessa a IR for Good

# Dati

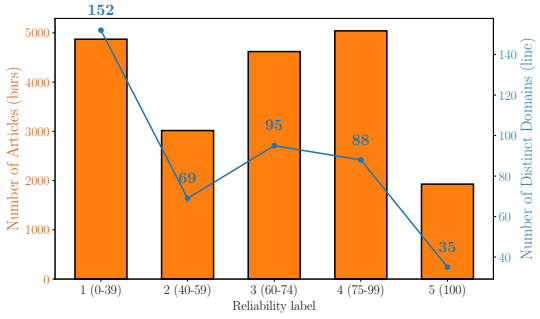
- Scraping con **newspaper3k**

# Dati

- Scraping con **newspaper3k**
- 439 editori, 19.476 articoli politici in inglese

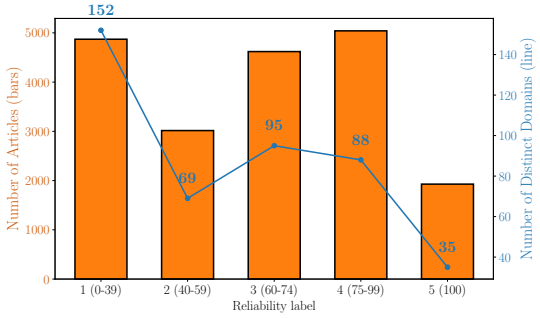
# Dati

- Scraping con **newspaper3k**
- 439 editori, 19.476 articoli politici in inglese
- Etichette **NewsGuard**: 5 livelli $l_1$–$l_5$ (da 0–100)



# Dati

- Scraping con **newspaper3k**
- 439 editori, 19.476 articoli politici in inglese
- Etichette **NewsGuard**: 5 livelli $l_1$–$l_5$ (da 0–100)
- Ogni articolo **eredita** l'etichetta del suo editore



# Classificazione — livello articolo

- Quattro transformer: **BERT, RoBERTa, Llama, Mistral**

# Classificazione — livello articolo

- Quattro transformer: **BERT, RoBERTa, Llama, Mistral**
- Encoder full fine-tuning, decoder con **LoRA**

# Classificazione — livello articolo

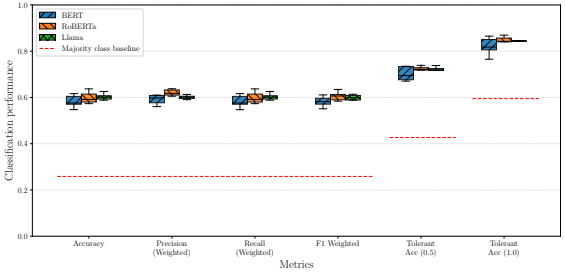
- Quattro transformer: **BERT, RoBERTa, Llama, Mistral**
- Encoder full fine-tuning, decoder con **LoRA**
- Input **256 token** (1024 per Mistral)

# Classificazione — livello articolo

- Quattro transformer: **BERT, RoBERTa, Llama, Mistral**
- Encoder full fine-tuning, decoder con **LoRA**
- Input **256 token** (1024 per Mistral)
- Split **publisher-disjoint**: editori di test mai visti

# Classificazione — livello articolo

- Quattro transformer: **BERT, RoBERTa, Llama, Mistral**
- Encoder full fine-tuning, decoder con **LoRA**
- Input **256 token** (1024 per Mistral)
- Split **publisher-disjoint**: editori di test mai visti



# Aggregazione — livello editore

- Dall'articolo all'editore con **majority voting**

# Aggregazione — livello editore

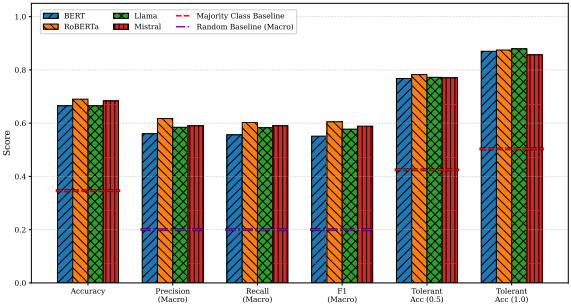
- Dall'articolo all'editore con **majority voting**
- Si usano **tutti** gli articoli della testata: nessun cap in aggregazione (fino a 200, mediana $\sim$34)

# Aggregazione — livello editore

- Dall'articolo all'editore con **majority voting**
- Si usano **tutti** gli articoli della testata: nessun cap in aggregazione (fino a 200, mediana $\sim$34)
- Valutazione su editori **mai visti** in addestramento

# Aggregazione — livello editore

- Dall'articolo all'editore con **majority voting**
- Si usano **tutti** gli articoli della testata: nessun cap in aggregazione (fino a 200, mediana $\sim$34)
- Valutazione su editori **mai visti** in addestramento



# Perché analizziamo gli errori

- Oltre alle metriche aggregate, vogliamo capire **come** e **perché** i modelli sbagliano

# Perché analizziamo gli errori

- Oltre alle metriche aggregate, vogliamo capire **come** e **perché** i modelli sbagliano

  *"Beyond aggregate performance, we investigate how and why models fail."*

# Perché analizziamo gli errori

- Oltre alle metriche aggregate, vogliamo capire **come** e **perché** i modelli sbagliano

  *"Beyond aggregate performance, we investigate how and why models fail."*

- Obiettivo: trovare **debolezze strutturali** — su quali livelli sbaglia e se sovra/sottostima

# Perché analizziamo gli errori

- Oltre alle metriche aggregate, vogliamo capire **come** e **perché** i modelli sbagliano

  *"Beyond aggregate performance, we investigate how and why models fail."*

- Obiettivo: trovare **debolezze strutturali** — su quali livelli sbaglia e se sovra/sottostima

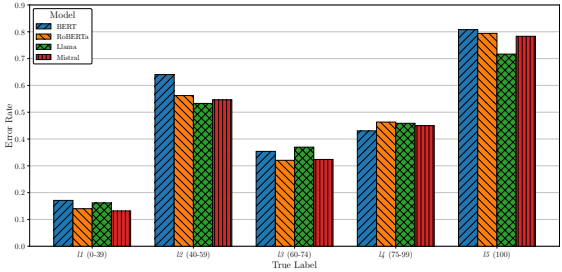
  *"To detect structural weaknesses. . . "*

# Analisi dell'errore — per livello

- **Error rate** per ogni livello di affidabilità

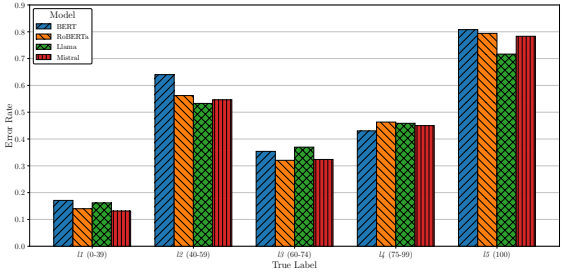
# Analisi dell'errore — per livello

- **Error rate** per ogni livello di affidabilità
- $l_1$: errore più **basso** ($< 20\%$)



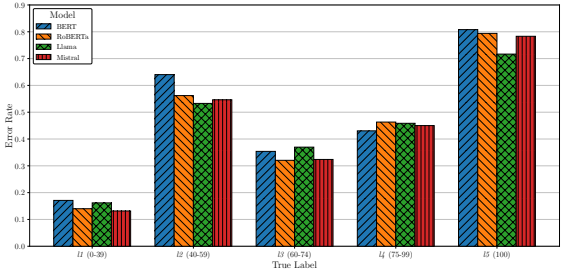
# Analisi dell'errore — per livello

- **Error rate** per ogni livello di affidabilità
- $l_1$: errore più **basso** ($< 20\%$)
- $l_5$: errore più **alto** ($> 70\%$), spesso confuso con $l_4$



# Analisi dell'errore — per livello

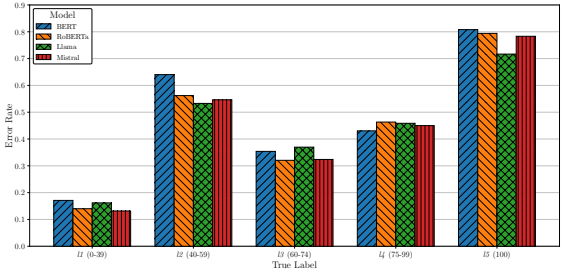
- **Error rate** per ogni livello di affidabilità
- $l_1$: errore più **basso** ($< 20\%$)
- $l_5$: errore più **alto** ($> 70\%$), spesso confuso con $l_4$
- $l_2$ sopra il 50%, $l_3$ intorno al 35%



# Analisi dell'errore — per livello

- **Error rate** per ogni livello di affidabilità
- $l_1$: errore più **basso** ($< 20\%$)
- $l_5$: errore più **alto** ($> 70\%$), spesso confuso con $l_4$
- $l_2$ sopra il 50%, $l_3$ intorno al 35%

*Sappiamo solo dove sbaglia di più o di meno, non perché.*

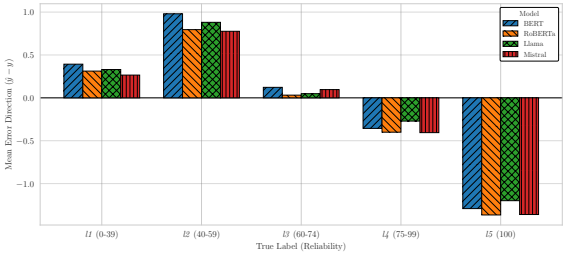


# Analisi dell'errore — direzione

- **Mean Error Direction**: l'errore *sovrastima* $(+)$ o *sottostima* $(-)$ l'affidabilità

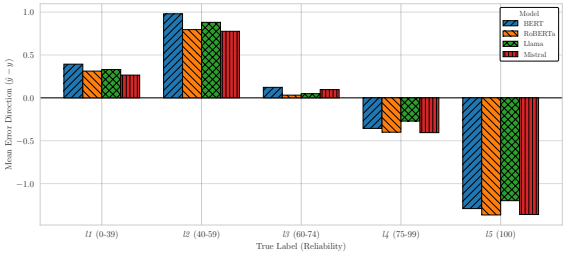
# Analisi dell'errore — direzione

- **Mean Error Direction**: l'errore *sovrastima* (+) o *sottostima* (−) l'affidabilità
- Livelli **bassi sovrastimati**, livelli **alti sottostimati**



# Analisi dell'errore — direzione

- **Mean Error Direction**: l'errore *sovrastima* (+) o *sottostima* (−) l'affidabilità
- Livelli **bassi sovrastimati**, livelli **alti sottostimati**
- Gli errori "tirano verso il **centro**" della scala



# Perché analizziamo il bias politico

- Vogliamo sapere se il modello **tratta allo stesso modo** tutto lo spettro politico, o se **penalizza** certi orientamenti

# Perché analizziamo il bias politico

- Vogliamo sapere se il modello **tratta allo stesso modo** tutto lo spettro politico, o se **penalizza** certi orientamenti

*"...determine if the models exhibit political bias...whether the models treat all sides of the political spectrum equally or if they penalize specific orientations."*

# Perché analizziamo il bias politico

- Vogliamo sapere se il modello **tratta allo stesso modo** tutto lo spettro politico, o se **penalizza** certi orientamenti

  *"...determine if the models exhibit political bias...whether the models treat all sides of the political spectrum equally or if they penalize specific orientations."*

- Serve una valutazione **bias-aware**: un sistema in uso con bias politico può fare danni

# Perché analizziamo il bias politico

- Vogliamo sapere se il modello **tratta allo stesso modo** tutto lo spettro politico, o se **penalizza** certi orientamenti

  *"...determine if the models exhibit political bias...whether the models treat all sides of the political spectrum equally or if they penalize specific orientations."*

- Serve una valutazione **bias-aware**: un sistema in uso con bias politico può fare danni

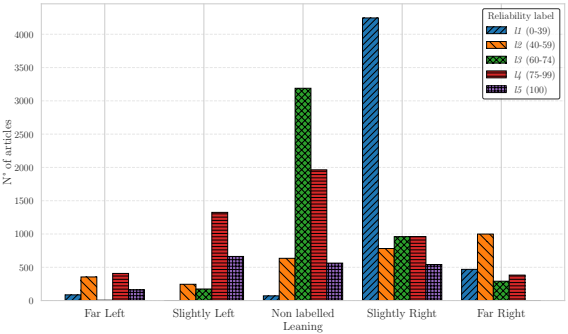
  *"...the need for bias-aware evaluation protocols..."*

# Bias politico — distribuzione dei dati

- Orientamento ereditato dall'editore (analisi *a posteriori*)

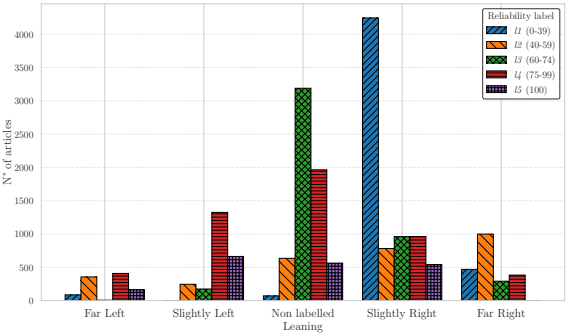
# Bias politico — distribuzione dei dati

- Orientamento ereditato dall'editore (analisi *a posteriori*)
- Dentro ogni orientamento, come si distribuiscono i livelli



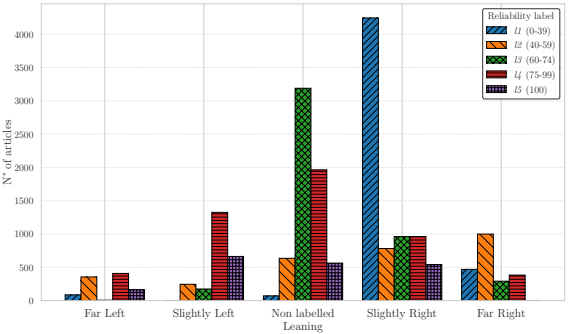
# Bias politico — distribuzione dei dati

- Orientamento ereditato dall'editore (analisi *a posteriori*)
- Dentro ogni orientamento, come si distribuiscono i livelli
- Distribuzione molto **sbilanciata** (proprietà del sistema mediatico)



# Bias politico — distribuzione dei dati

- Orientamento ereditato dall'editore (analisi *a posteriori*)
- Dentro ogni orientamento, come si distribuiscono i livelli
- Distribuzione molto **sbilanciata** (proprietà del sistema mediatico)
- Per questo gli error rate si calcolano **classe per classe**

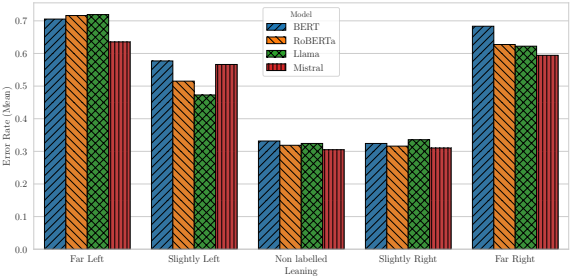


# Bias politico — error rate

- **Error rate** per orientamento politico

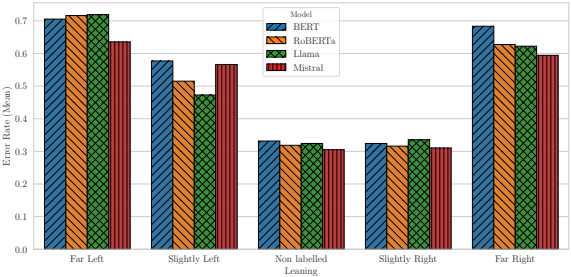
# Bias politico — error rate

- **Error rate** per orientamento politico
- Gli estremi (**far left**, **far right**) sbagliano molto di più



# Bias politico — error rate

- **Error rate** per orientamento politico
- Gli estremi (**far left**, **far right**) sbagliano molto di più
- Slightly right e non labelled sbagliano **meno**

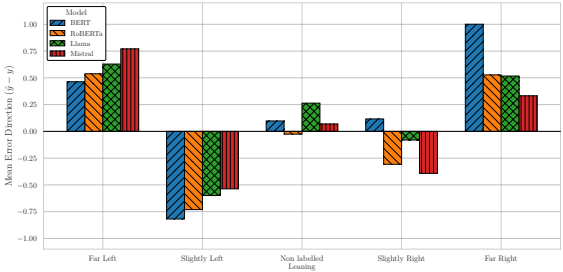


# Bias politico — direzione dell'errore

- **Mean Error Direction** per orientamento

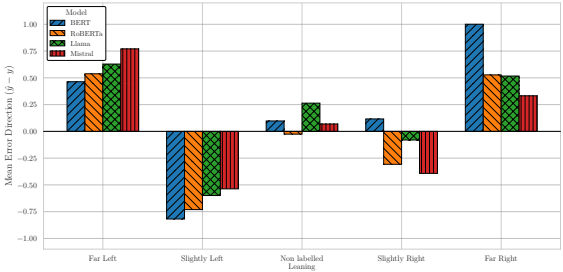
# Bias politico — direzione dell'errore

- **Mean Error Direction** per orientamento
- Estremi (far left, far right) **sovrastimati**



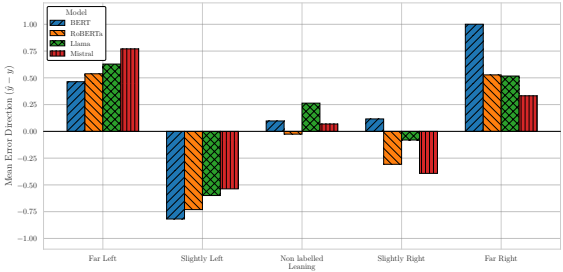
# Bias politico — direzione dell'errore

- **Mean Error Direction** per orientamento
- Estremi (far left, far right) **sovrastimati**
- Slightly left **sottostimato**



# Bias politico — direzione dell'errore

- **Mean Error Direction** per orientamento
- Estremi (far left, far right) **sovrastimati**
- Slightly left **sottostimato**
- Slightly right e non labelled: deviazioni piccole



# È un vero legame o è un caso?

- Vediamo error rate diversi tra gli orientamenti.

# È un vero legame o è un caso?

- Vediamo error rate diversi tra gli orientamenti.
- Ma potrebbe essere solo **rumore** dei dati.

# È un vero legame o è un caso?

- Vediamo error rate diversi tra gli orientamenti.
- Ma potrebbe essere solo **rumore** dei dati.
- Serve un **test statistico** che dica: questo legame è reale?

# È un vero legame o è un caso?

- Vediamo error rate diversi tra gli orientamenti.
- Ma potrebbe essere solo **rumore** dei dati.
- Serve un **test statistico** che dica: questo legame è reale?

Strumento usato: il **test del chi-quadro ($\chi^2$) di indipendenza**.

# Passo 1 — mettiamo gli errori in tabella

- Per ogni orientamento contiamo **giusti** e **sbagliati**

# Passo 1 — mettiamo gli errori in tabella

- Per ogni orientamento contiamo **giusti** e **sbagliati**
- È la **tabella di contingenza**

| **Orientamento** | **Giusti** | **Sbagliati** |
|---|---|---|
| Far Left | 299 | 716 |
| Slightly Left | 1018 | 1389 |
| Non labelled | 4292 | 2130 |
| Slightly Right | 5062 | 2428 |
| Far Right | 678 | 1464 |

(esempio: BERT)

# Passo 1 — mettiamo gli errori in tabella

- Per ogni orientamento contiamo **giusti** e **sbagliati**
- È la **tabella di contingenza**
- Agli estremi gli sbagliati superano i giusti

| **Orientamento** | **Giusti** | **Sbagliati** |
|---|---|---|
| Far Left | 299 | 716 |
| Slightly Left | 1018 | 1389 |
| Non labelled | 4292 | 2130 |
| Slightly Right | 5062 | 2428 |
| Far Right | 678 | 1464 |

(esempio: BERT)

# Passo 2 — l'idea del chi-quadro

- Immaginiamo che l'orientamento **non c'entri** con gli errori.

# Passo 2 — l'idea del chi-quadro

- Immaginiamo che l'orientamento **non c'entri** con gli errori.
- Allora ogni gruppo dovrebbe sbagliare **nella stessa proporzione** (circa la media, $\sim$42%).

# Passo 2 — l'idea del chi-quadro

- Immaginiamo che l'orientamento **non c'entri** con gli errori.
- Allora ogni gruppo dovrebbe sbagliare **nella stessa proporzione** (circa la media, $\sim$42%).
- Il $\chi^2$ misura **quanto** gli errori *osservati* si allontanano da questo scenario "senza legame".

# Passo 2 — l'idea del chi-quadro

- Immaginiamo che l'orientamento **non c'entri** con gli errori.
- Allora ogni gruppo dovrebbe sbagliare **nella stessa proporzione** (circa la media, $\sim$42%).
- Il $\chi^2$ misura **quanto** gli errori *osservati* si allontanano da questo scenario "senza legame".
- Più grande è lo scarto $\rightarrow$ $\chi^2$ grande $\rightarrow$ più probabile che un legame ci sia.

# Passo 2 — quanto vale il nostro $\chi^2$

- Se **non** ci fosse nessun legame, il $\chi^2$ starebbe intorno a **4** (un valore che dipende solo dalla grandezza della tabella)

# Passo 2 — quanto vale il nostro $\chi^2$

- Se **non** ci fosse nessun legame, il $\chi^2$ starebbe intorno a **4** (un valore che dipende solo dalla grandezza della tabella)
- Per puro caso supererebbe **9,5** solo 1 volta su 20: è la soglia classica

# Passo 2 — quanto vale il nostro $\chi^2$

- Se **non** ci fosse nessun legame, il $\chi^2$ starebbe intorno a **4** (un valore che dipende solo dalla grandezza della tabella)
- Per puro caso supererebbe **9,5** solo 1 volta su 20: è la soglia classica
- Il nostro: **1.208–1.684**, a seconda del modello

# Passo 2 — quanto vale il nostro $\chi^2$

- Se **non** ci fosse nessun legame, il $\chi^2$ starebbe intorno a **4** (un valore che dipende solo dalla grandezza della tabella)
- Per puro caso supererebbe **9,5** solo 1 volta su 20: è la soglia classica
- Il nostro: **1.208–1.684**, a seconda del modello

*Oltre cento volte la soglia: lontanissimo dallo scenario "senza legame".*

# Passo 2 — quanto vale il nostro $\chi^2$

- Se **non** ci fosse nessun legame, il $\chi^2$ starebbe intorno a **4** (un valore che dipende solo dalla grandezza della tabella)
- Per puro caso supererebbe **9,5** solo 1 volta su 20: è la soglia classica
- Il nostro: **1.208–1.684**, a seconda del modello

  *Oltre cento volte la soglia: lontanissimo dallo scenario "senza legame".*
- Attenzione: il $\chi^2$ cresce con il **numero di dati** (qui 19.476 articoli): per giudicare la *forza* del legame serve Cramér's V (Passo 4)

# Passo 3 — il $p$-value

- Un $\chi^2$ grande potrebbe capitare **per caso**?

# Passo 3 — il *p*-value

- Un $\chi^2$ grande potrebbe capitare **per caso**?
- Il ***p*-value** è la probabilità di vedere uno scarto così grande *se non ci fosse nessun legame*.

# Passo 3 — il $p$-value

- Un $\chi^2$ grande potrebbe capitare **per caso**?
- Il $p$-**value** è la probabilità di vedere uno scarto così grande *se non ci fosse nessun legame*.
- $p$ piccolissimo (es. $p < 0.001$) $\rightarrow$ quasi impossibile che sia un caso.

# Passo 3 — il $p$-value

- Un $\chi^2$ grande potrebbe capitare **per caso**?
- Il $p$-**value** è la probabilità di vedere uno scarto così grande *se non ci fosse nessun legame*.
- $p$ piccolissimo (es. $p < 0.001$) $\rightarrow$ quasi impossibile che sia un caso.
- Quindi il legame è **reale**, non fortuna.

# Passo 4 — quanto è forte? (Cramér's V)

- Il *p*-value dice **se** c'è un legame, non **quanto** è forte.

# Passo 4 — quanto è forte? (Cramér's V)

- Il *p*-value dice **se** c'è un legame, non **quanto** è forte.
- Con tanti dati anche un legame **piccolo** risulta "significativo".

# Passo 4 — quanto è forte? (Cramér's V)

- Il *p*-value dice **se** c'è un legame, non **quanto** è forte.
- Con tanti dati anche un legame **piccolo** risulta "significativo".
- **Cramér's V** misura la **forza**: 0 = nessun legame, 1 = legame massimo.

# In sintesi

- Legame **statisticamente significativo** (tutti i modelli)

# In sintesi

- Legame **statisticamente significativo** (tutti i modelli)
- Forza **piccola–moderata** (V $\approx$ 0.25–0.29)

| **Model** | $\chi^2$ | $p$ | **V** |
|---|---|---|---|
| BERT | 1684 | $< 10^{-300}$ | 0.294 |
| RoBERTa | 1418 | $< 10^{-300}$ | 0.270 |
| Llama | 1208 | $< 10^{-250}$ | 0.249 |
| Mistral | 1344 | $< 10^{-300}$ | 0.263 |

# In sintesi

- Legame **statisticamente significativo** (tutti i modelli)
- Forza **piccola–moderata** (V $\approx$ 0.25–0.29)
- Direzione: estremi **sovrastimati**, slightly left **sottostimati**

| **Model** | $\chi^2$ | $p$ | **V** |
|---|---|---|---|
| BERT | 1684 | $< 10^{-300}$ | 0.294 |
| RoBERTa | 1418 | $< 10^{-300}$ | 0.270 |
| Llama | 1208 | $< 10^{-250}$ | 0.249 |
| Mistral | 1344 | $< 10^{-300}$ | 0.263 |

# Nel materiale supplementare

- Matrici di confusione per **fold** (livello articolo)

# Nel materiale supplementare

- Matrici di confusione per **fold** (livello articolo)
- Matrici di confusione a **livello editore** (dopo aggregazione)

# Nel materiale supplementare

- Matrici di confusione per **fold** (livello articolo)
- Matrici di confusione a **livello editore** (dopo aggregazione)
- Matrici di confusione per **orientamento politico**

# Nel materiale supplementare

- Matrici di confusione per **fold** (livello articolo)
- Matrici di confusione a **livello editore** (dopo aggregazione)
- Matrici di confusione per **orientamento politico**
- **Analisi di convergenza**: curve di loss (Llama, Mistral)

# Nel materiale supplementare

- Matrici di confusione per **fold** (livello articolo)
- Matrici di confusione a **livello editore** (dopo aggregazione)
- Matrici di confusione per **orientamento politico**
- **Analisi di convergenza**: curve di loss (Llama, Mistral)

Dettagli a supporto delle analisi del paper, non nuovi risultati.

# Le review dei revisori

quali critiche affrontare

# Revisore 1 — (1) Novità metodologica limitata

**English**

*"The two-stage framework is essentially standard fine-tuning of pretrained language models followed by majority voting. The main contribution seems to be the task formulation, dataset construction, and evaluation setup, rather than a new model architecture, learning objective, or aggregation method."*

# Revisore 1 — (1) Novità metodologica limitata

**English**

*"The two-stage framework is essentially standard fine-tuning of pretrained language models followed by majority voting. The main contribution seems to be the task formulation, dataset construction, and evaluation setup, rather than a new model architecture, learning objective, or aggregation method."*

**Commento di John**

Dopo parliamo degli esperimenti in più: questo punto si dovrebbe addressare.

# Revisore 1 — (2) Il guadagno dell'aggregazione non è misurato pulito

**English**

*"The comparison between the article-level score ($\sim$0.60) and the publisher-level score ($\sim$0.69) changes both the evaluation unit and the weighting of publishers. As a result, the improvement cannot be attributed to aggregation alone."*

# Revisore 1 — (2) Il guadagno dell'aggregazione non è misurato pulito

**English**

*"The comparison between the article-level score (∼0.60) and the publisher-level score (∼0.69) changes both the evaluation unit and the weighting of publishers. As a result, the improvement cannot be attributed to aggregation alone."*

**Commento di John**

Questa non l'ho capita. Forse dovremmo spiegare meglio perché aggregare ha senso? Forse ha senso solo aggregare, e non andrebbe fatta la valutazione per singolo articolo?

# Revisore 1 — (3) Bias confuso con il livello di affidabilità

**English**

*"The distribution of reliability labels differs substantially across political leanings, and some reliability levels are clearly more difficult to classify than others. The relationship between political leaning and prediction error should therefore be tested again after controlling for the true reliability level."*

# Revisore 1 — (3) Bias confuso con il livello di affidabilità

**English**

*"The distribution of reliability labels differs substantially across political leanings, and some reliability levels are clearly more difficult to classify than others. The relationship between political leaning and prediction error should therefore be tested again after controlling for the true reliability level."*

**Commento di John**

Di questa ne parliamo dopo in modo approfondito. Comunque non ha senso dire che alcune label sono più difficili da classificare di altre: non ci sono i dati per dirlo.

# Revisore 1 — (4) Il chi-quadro ignora il clustering

**English**

*"Political leaning and reliability are publisher-level attributes shared by multiple articles from the same publisher. Using all articles as independent observations may lead to pseudo-replication and overstate the effective sample size and significance of the results."*

# Revisore 1 — (4) Il chi-quadro ignora il clustering

**English**

*"Political leaning and reliability are publisher-level attributes shared by multiple articles from the same publisher. Using all articles as independent observations may lead to pseudo-replication and overstate the effective sample size and significance of the results."*

**Commento di John**

Questa la vediamo dopo nel dettaglio: è una critica importante.

# Revisore 1 — (5) Indizi dell'editore e artefatti non esclusi

**English**

*"The paper does not include systematic text cleaning, source-identifier masking, or sanitized-text ablations. It is therefore difficult to tell whether the model is learning reliability-related content or simply exploiting publisher-specific signals and scraping artifacts."*

# Revisore 1 — (5) Indizi dell'editore e artefatti non esclusi

**English**

*"The paper does not include systematic text cleaning, source-identifier masking, or sanitized-text ablations. It is therefore difficult to tell whether the model is learning reliability-related content or simply exploiting publisher-specific signals and scraping artifacts."*

**Commento di John**

Anche questa la vediamo più avanti.

# Revisore 1 — (6) Possibile bias di selezione nello scraping

**English**

*"Only 439 of the 669 candidate publishers were included in the final dataset, and the scraping success rates differ across reliability levels. The paper does not examine whether the publishers that were successfully scraped differ systematically from those that were not."*

# Revisore 1 — (6) Possibile bias di selezione nello scraping

**English**

*"Only 439 of the 669 candidate publishers were included in the final dataset, and the scraping success rates differ across reliability levels. The paper does not examine whether the publishers that were successfully scraped differ systematically from those that were not."*

**Commento di John**

Non so se questa ha senso.

# Revisore 1 — (7) Confronto sulla taglia del modello non controllato

**English**

*"The models differ in architecture, fine-tuning strategy, training schedule, and context length, in addition to parameter count. The observed performance differences therefore cannot be attributed to model size alone."*

# Revisore 1 — (7) Confronto sulla taglia del modello non controllato

**English**

*"The models differ in architecture, fine-tuning strategy, training schedule, and context length, in addition to parameter count. The observed performance differences therefore cannot be attributed to model size alone."*

**Commento di John**

Ma praticamente non ci sono differenze di performance tra i vari modelli.

# Revisore 1 — (8) Nessuna stima di incertezza

**English**

*"Differences such as 0.69 versus 0.68 are small, but the paper does not report confidence intervals, bootstrap results, or paired significance tests. It is therefore unclear whether these differences are meaningful."*

# Revisore 1 — (8) Nessuna stima di incertezza

**English**

*"Differences such as 0.69 versus 0.68 are small, but the paper does not report confidence intervals, bootstrap results, or paired significance tests. It is therefore unclear whether these differences are meaningful."*

**Commento di Claude**

- **Bootstrap**: si ricampionano a caso le 439 testate migliaia di volte e ogni volta si ricalcola l'accuracy; la variazione dà un **intervallo di confidenza** (es. "0,69" diventa un intervallo come 0,65–0,73).
- **Test appaiato**: si confrontano due modelli *sulle stesse testate*, contando quelle dove uno ha ragione e l'altro torto (es. test di McNemar); dice se 0,69 contro 0,68 è una differenza reale.
- Nel paper bocciato non ci sono né intervalli né test: critica giusta e veloce da risolvere. Su 439 testate, 0,69 contro 0,68 vuol dire circa 4 testate di differenza.

# Revisore 2 — (1) Motivazione debole del passaggio a livello editore

**English**

*"publisher reliability is, by construction, obtained as a fixed aggregation of article-level outputs. . . the re-formulation does not introduce substantial new insight beyond a change in the unit of evaluation."*

# Revisore 2 — (1) Motivazione debole del passaggio a livello editore

**English**

*"publisher reliability is, by construction, obtained as a fixed aggregation of article-level outputs. . . the re-formulation does not introduce substantial new insight beyond a change in the unit of evaluation."*

**Commento di John**

Non so che dire.

# Revisore 2 — (2) Mancano confronti con altri scorer

**English**

*"Publisher-level scores can equally be produced by first scoring individual articles with a model pretrained specifically for article-level reliability classification, or with a general-purpose LLM such as Qwen, and then applying the same voting strategy. . . No such comparison is reported."*

# Revisore 2 — (2) Mancano confronti con altri scorer

**English**

*"Publisher-level scores can equally be produced by first scoring individual articles with a model pretrained specifically for article-level reliability classification, or with a general-purpose LLM such as Qwen, and then applying the same voting strategy. . . No such comparison is reported."*

**Commento di John**

Anche qui non so che dire: non ho capito cosa c'entra Qwen.

# Revisore 2 — (2) Mancano confronti con altri scorer

**English**

*"Publisher-level scores can equally be produced by first scoring individual articles with a model pretrained specifically for article-level reliability classification, or with a general-purpose LLM such as Qwen, and then applying the same voting strategy. . . No such comparison is reported."*

**Commento di John**

Anche qui non so che dire: non ho capito cosa c'entra Qwen.

**Commento di Claude**

Il nostro schema è "voto a ogni articolo, poi maggioranza". Il revisore nota che il voto per articolo potrebbe darlo anche un modello *già esistente* per l'affidabilità degli articoli, o un *LLM generalista* interrogato direttamente. Qwen è solo un esempio di LLM open-source. Vuole sapere se i nostri modelli battono queste alternative "pronte": è vicino all'esperimento con e senza nomi proposto da Fabio.

# Revisore 2 — (3) Il dataset non è “large-scale”

**English**

*“Although the corpus contains 19,476 articles, the objective of the paper is scoring at the level of the publisher, and the dataset comprises only 439 publishers. The dataset is therefore unlikely to support effective use in real-world applications.”*

# Revisore 2 — (3) Il dataset non è “large-scale”

**English**

*“Although the corpus contains 19,476 articles, the objective of the paper is scoring at the level of the publisher, and the dataset comprises only 439 publishers. The dataset is therefore unlikely to support effective use in real-world applications.”*

**Commento di John**

Secondo me invece i dati sono sufficienti.

# Revisore 2 — (3) Il dataset non è “large-scale”

**English**

*“Although the corpus contains 19,476 articles, the objective of the paper is scoring at the level of the publisher, and the dataset comprises only 439 publishers. The dataset is therefore unlikely to support effective use in real-world applications.”*

**Commento di John**

Secondo me invece i dati sono sufficienti.

**Commento di Claude**

In parte d’accordo con John: 439 testate bastano per misurare le prestazioni, se riportiamo gli intervalli di confidenza. Ma il revisore ha ragione su un punto: l’unità del compito è la testata, quindi il campione vero è 439, non 19.476 (lo conferma anche l’ICC). “Large-scale” è la parola sbagliata: basta toglierla. Che i dati non bastino per un uso reale è un’affermazione del revisore, non dimostrata.

# Oltre le review: due analisi

Marinella con ChatGPT · Fabio con Claude

# Due analisi di supporto

- Oltre ai due revisori del journal, due analisi del paper fatte con strumenti AI

# Due analisi di supporto

- Oltre ai due revisori del journal, due analisi del paper fatte con strumenti AI
- **Marinella** con **ChatGPT** — focalizzata sulla statistica del bias

# Due analisi di supporto

- Oltre ai due revisori del journal, due analisi del paper fatte con strumenti AI
- **Marinella** con **ChatGPT** — focalizzata sulla statistica del bias
- **Fabio** con **Claude** — review completa + analisi quantitativa del bias

# Due analisi di supporto

- Oltre ai due revisori del journal, due analisi del paper fatte con strumenti AI
- **Marinella** con **ChatGPT** — focalizzata sulla statistica del bias
- **Fabio** con **Claude** — review completa + analisi quantitativa del bias
- Fatte in modo **indipendente**: le riassumiamo qui, così le conosciamo tutti

# Marinella × ChatGPT — cos'è

- Marinella ha dato a ChatGPT la **parte statistica** del bias e gli ha chiesto di controllarla

# Marinella × ChatGPT — cos'è

- Marinella ha dato a ChatGPT la **parte statistica** del bias e gli ha chiesto di controllarla
- Ha trovato una serie di **problemi**: li vediamo uno a uno, in modo semplice

# Marinella × ChatGPT — cos'è

- Marinella ha dato a ChatGPT la **parte statistica** del bias e gli ha chiesto di controllarla
- Ha trovato una serie di **problemi**: li vediamo uno a uno, in modo semplice
- Tutti ruotano attorno a una domanda: **possiamo davvero dire che c'è un bias politico?**

# Problema 1 — il $\chi^2$ conta troppo

- La domanda del test: l'errore del modello dipende dall'**orientamento politico**?

# Problema 1 — il $\chi^2$ conta troppo

- La domanda del test: l'errore del modello dipende dall'**orientamento politico**?
- Nel paper viene calcolato contando i **singoli articoli**: 19.476 "prove"

# Problema 1 — il $\chi^2$ conta troppo

- La domanda del test: l'errore del modello dipende dall'**orientamento politico**?
- Nel paper viene calcolato contando i **singoli articoli**: 19.476 "prove"
- Ma l'orientamento è **fisso per testata**: tutti gli articoli di una testata hanno lo stesso orientamento (come hanno la stessa affidabilità — anche se sono due cose diverse)

# Problema 1 — il $\chi^2$ conta troppo

- La domanda del test: l'errore del modello dipende dall'**orientamento politico**?
- Nel paper viene calcolato contando i **singoli articoli**: 19.476 "prove"
- Ma l'orientamento è **fisso per testata**: tutti gli articoli di una testata hanno lo stesso orientamento (come hanno la stessa affidabilità — anche se sono due cose diverse)
- Quindi gli articoli di una stessa testata **non sono prove indipendenti**

# Problema 1 — l'esempio

- Una testata di destra, 200 articoli, tutti affidabilità $l_4$

# Problema 1 — l'esempio

- Una testata di destra, 200 articoli, tutti affidabilità $l_4$
- Il modello la trova difficile $\rightarrow$ sbaglia quasi tutti: 200 errori "di destra"

# Problema 1 — l'esempio

- Una testata di destra, 200 articoli, tutti affidabilità $l_4$
- Il modello la trova difficile → sbaglia quasi tutti: 200 errori "di destra"
- Il test li legge come **200 prove** che "destra → errore"

# Problema 1 — l'esempio

- Una testata di destra, 200 articoli, tutti affidabilità $l_4$
- Il modello la trova difficile $\rightarrow$ sbaglia quasi tutti: 200 errori "di destra"
- Il test li legge come **200 prove** che "destra $\rightarrow$ errore"
- Ma è **una** testata difficile, non 200 fatti diversi

# Problema 1 — l'esempio

- Una testata di destra, 200 articoli, tutti affidabilità $l_4$
- Il modello la trova difficile $\rightarrow$ sbaglia quasi tutti: 200 errori "di destra"
- Il test li legge come **200 prove** che "destra $\rightarrow$ errore"
- Ma è **una** testata difficile, non 200 fatti diversi

  *Come chiedere l'opinione politica a 200 persone della stessa famiglia: non sono 200 opinioni indipendenti, è quasi una sola.*

# Problema 1 — l'esempio

- Una testata di destra, 200 articoli, tutti affidabilità $l_4$
- Il modello la trova difficile → sbaglia quasi tutti: 200 errori "di destra"
- Il test li legge come **200 prove** che "destra → errore"
- Ma è **una** testata difficile, non 200 fatti diversi

  *Come chiedere l'opinione politica a 200 persone della stessa famiglia: non sono 200 opinioni indipendenti, è quasi una sola.*

- Le prove vere sono le **testate** (439), non gli articoli (19.476): più il campione è (finto) grande, più ogni differenza sembra "significativa"

# Problema 1 — l'esempio

- Una testata di destra, 200 articoli, tutti affidabilità $l_4$
- Il modello la trova difficile $\rightarrow$ sbaglia quasi tutti: 200 errori "di destra"
- Il test li legge come **200 prove** che "destra $\rightarrow$ errore"
- Ma è **una** testata difficile, non 200 fatti diversi

  *Come chiedere l'opinione politica a 200 persone della stessa famiglia: non sono 200 opinioni indipendenti, è quasi una sola.*

- Le prove vere sono le **testate** (439), non gli articoli (19.476): più il campione è (finto) grande, più ogni differenza sembra "significativa"
- Soluzione: un conteggio **per testata**

# Osservazione di John — ma è vero?

- La critica regge solo se gli errori si **ripetono** dentro la stessa testata

# Osservazione di John — ma è vero?

- La critica regge solo se gli errori si **ripetono** dentro la stessa testata
- Se il modello facesse **un po' giusti e un po' sbagliati a caso**, ogni articolo sarebbe una prova nuova: contarli tutti sarebbe giusto

# Osservazione di John — ma è vero?

- La critica regge solo se gli errori si **ripetono** dentro la stessa testata
- Se il modello facesse **un po' giusti e un po' sbagliati a caso**, ogni articolo sarebbe una prova nuova: contarli tutti sarebbe giusto
- Se invece **azzecca (o sbaglia) quasi tutta** la testata insieme, i suoi articoli dicono **la stessa cosa**: contarli tutti è come **ripetere la stessa prova**

# Osservazione di John — ma è vero?

- La critica regge solo se gli errori si **ripetono** dentro la stessa testata
- Se il modello facesse **un po' giusti e un po' sbagliati a caso**, ogni articolo sarebbe una prova nuova: contarli tutti sarebbe giusto
- Se invece **azzecca (o sbaglia) quasi tutta** la testata insieme, i suoi articoli dicono **la stessa cosa**: contarli tutti è come **ripetere la stessa prova**
- La domanda: quando sbaglia su una testata, sbaglia su **quasi tutti** i suoi articoli? Lo misuriamo.

# Cos'è l'ICC — l'idea

- Per ogni testata guardiamo: che **quota di articoli** sbaglia il modello?

# Cos'è l'ICC — l'idea

- Per ogni testata guardiamo: che **quota di articoli** sbaglia il modello?
- Se sbagliasse **a caso** dentro la testata, ogni testata starebbe vicino alla **media** ($\sim$42%)

# Cos'è l'ICC — l'idea

- Per ogni testata guardiamo: che **quota di articoli** sbaglia il modello?
- Se sbagliasse **a caso** dentro la testata, ogni testata starebbe vicino alla **media** ($\sim$42%)
- L'ICC dice quanto invece le testate si **spaccano** tra "quasi tutte giuste" e "quasi tutte sbagliate"

# Cos'è l'ICC — l'idea

- Per ogni testata guardiamo: che **quota di articoli** sbaglia il modello?
- Se sbagliasse **a caso** dentro la testata, ogni testata starebbe vicino alla **media** ($\sim$42%)
- L'ICC dice quanto invece le testate si **spaccano** tra "quasi tutte giuste" e "quasi tutte sbagliate"
- **0** = tutte vicine alla media (nessuna correlazione) **1** = ognuna a un estremo

# Cos'è l'ICC — l'idea

- Per ogni testata guardiamo: che **quota di articoli** sbaglia il modello?
- Se sbagliasse **a caso** dentro la testata, ogni testata starebbe vicino alla **media** ($\sim$42%)
- L'ICC dice quanto invece le testate si **spaccano** tra "quasi tutte giuste" e "quasi tutte sbagliate"
- **0** = tutte vicine alla media (nessuna correlazione) **1** = ognuna a un estremo

*Come una classe di studenti: se vanno tutti bene o tutti male insieme, i voti sono "correlati".*

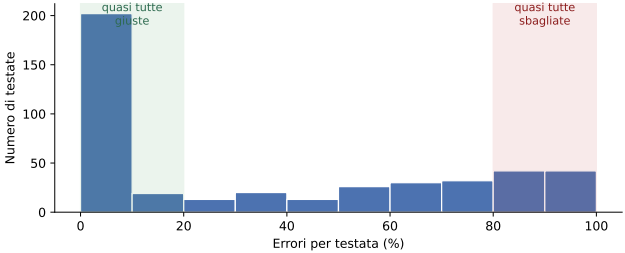
# Osservazione di John — cosa troviamo

- Su **439 testate**:

# Osservazione di John — cosa troviamo

- Su **439 testate**:

  **221** quasi tutte giuste

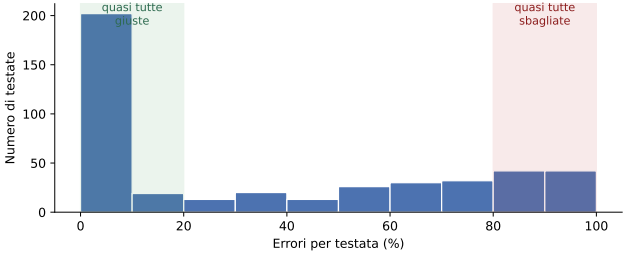


# Osservazione di John — cosa troviamo

- Su **439 testate**:

  **221** quasi tutte giuste

  **84** quasi tutte sbagliate



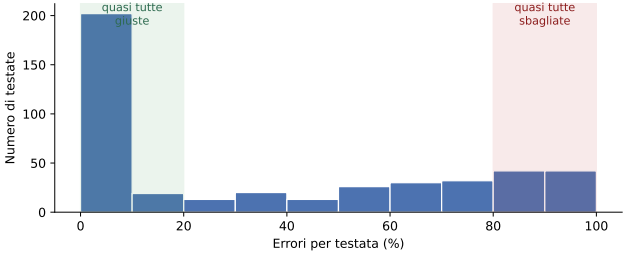
# Osservazione di John — cosa troviamo

- Su **439 testate**:

  **221** quasi tutte giuste

  **84** quasi tutte sbagliate

  solo 134 “a metà”



# Osservazione di John — cosa troviamo

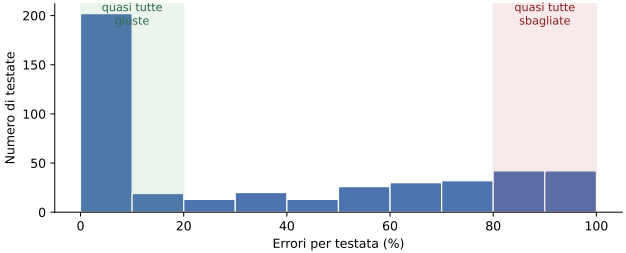
- Su **439 testate**:

  **221** quasi tutte giuste

  **84** quasi tutte sbagliate

  solo 134 “a metà”

- L’esito lo decide quasi la **testata**, non il singolo articolo



# Osservazione di John — cosa troviamo

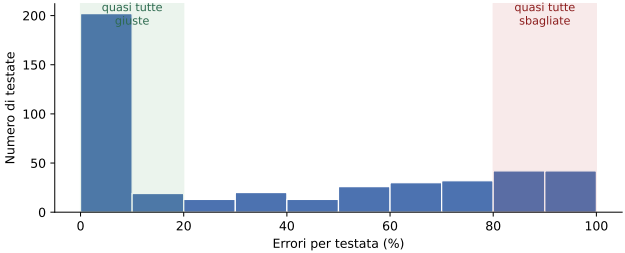
- Su **439 testate**:

  **221** quasi tutte giuste

  **84** quasi tutte sbagliate

  solo 134 “a metà”

- L’esito lo decide quasi la **testata**, non il singolo articolo
- Riassunto in un numero: ICC $\approx 0{,}6$ (come leggerlo: slide successiva)



# Osservazione di John — come leggere 0,6

- Prova: **rimescoliamo a caso** gli errori tra le testate (tenendo fisso il livello), così la testata non può più contare

# Osservazione di John — come leggere 0,6

- Prova: **rimescoliamo a caso** gli errori tra le testate (tenendo fisso il livello), così la testata non può più contare
- In questo mondo "a caso" l'ICC viene circa **0,14**

# Osservazione di John — come leggere 0,6

- Prova: **rimescoliamo a caso** gli errori tra le testate (tenendo fisso il livello), così la testata non può più contare
- In questo mondo "a caso" l'ICC viene circa **0,14**
- L'abbiamo rifatto 100 volte: non è **mai** andato oltre $\sim$0,17

# Osservazione di John — come leggere 0,6

- Prova: **rimescoliamo a caso** gli errori tra le testate (tenendo fisso il livello), così la testata non può più contare
- In questo mondo "a caso" l'ICC viene circa **0,14**
- L'abbiamo rifatto 100 volte: non è **mai** andato oltre $\sim$0,17
- Il nostro è **0,6**: più di 4 volte tanto

# Osservazione di John — come leggere 0,6

- Prova: **rimescoliamo a caso** gli errori tra le testate (tenendo fisso il livello), così la testata non può più contare
- In questo mondo "a caso" l'ICC viene circa **0,14**
- L'abbiamo rifatto 100 volte: non è **mai** andato oltre $\sim$0,17
- Il nostro è **0,6**: più di 4 volte tanto
- Quindi il risultato **non è casuale**: gli errori si concentrano davvero in alcune testate

# Osservazione di John — la conclusione

- Gli articoli di una testata **non sono prove indipendenti**

# Osservazione di John — la conclusione

- Gli articoli di una testata **non sono prove indipendenti**
- Quindi l'unità giusta per il test sono le **439 testate**, non i 19.476 articoli

# Osservazione di John — la conclusione

- Gli articoli di una testata **non sono prove indipendenti**
- Quindi l'unità giusta per il test sono le **439 testate**, non i 19.476 articoli

*E vale anche a parità di livello: non è solo perché su $l_5$ il modello sbaglia di più.*

# Osservazione di John — la conclusione

- Gli articoli di una testata **non sono prove indipendenti**
- Quindi l'unità giusta per il test sono le **439 testate**, non i 19.476 articoli

  *E vale anche a parità di livello: non è solo perché su $l_5$ il modello sbaglia di più.*
- La correzione è semplice: fare il test **per testata**

# Osservazione di John — come si fa il test per testata

- Per ogni testata, il **voto di maggioranza** dei suoi articoli dà **un solo giudizio**

# Osservazione di John — come si fa il test per testata

- Per ogni testata, il **voto di maggioranza** dei suoi articoli dà **un solo giudizio**

  *Es.: una testata di livello 1 con 9 articoli: 7 predetti $l_2$, 1 $l_5$, 1 $l_1$ $\rightarrow$ voto $l_2$ $\rightarrow$ testata sbagliata.*

# Osservazione di John — come si fa il test per testata

- Per ogni testata, il **voto di maggioranza** dei suoi articoli dà **un solo giudizio**

  *Es.: una testata di livello 1 con 9 articoli: 7 predetti $l_2$, 1 $l_5$, 1 $l_1$ $\rightarrow$ voto $l_2$ $\rightarrow$ testata sbagliata.*

- Ogni testata conta **una volta sola**: giusta o sbagliata

# Osservazione di John — come si fa il test per testata

- Per ogni testata, il **voto di maggioranza** dei suoi articoli dà **un solo giudizio**

  *Es.: una testata di livello 1 con 9 articoli: 7 predetti $l_2$, 1 $l_5$, 1 $l_1$ $\rightarrow$ voto $l_2$ $\rightarrow$ testata sbagliata.*

- Ogni testata conta **una volta sola**: giusta o sbagliata
- Si rifà la stessa tabella di prima (orientamento $\times$ giusta/sbagliata), ma con **439 testate** invece di 19.476 articoli

# Osservazione di John — il test per testata: il risultato

- $\chi^2$ per testata: **18,8** (contro 1.418 per articolo)

# Osservazione di John — il test per testata: il risultato

- $\chi^2$ per testata: **18,8** (contro 1.418 per articolo)
- Ancora sopra la soglia di 9,5: il legame **resta**...

RoBERTa, una riga per orientamento

| **Orientamento** | **Giuste** | **Sbagliate** |
|---|---|---|
| Far Left | 9 | 11 |
| Slightly Left | 29 | 21 |
| Non labelled | 81 | 29 |
| Slightly Right | 156 | 51 |
| Far Right | 28 | 24 |

# Osservazione di John — il test per testata: il risultato

- $\chi^2$ per testata: **18,8** (contro 1.418 per articolo)
- Ancora sopra la soglia di 9,5: il legame **resta**...
- ...ma è molto meno "clamoroso"

RoBERTa, una riga per orientamento

| **Orientamento** | **Giuste** | **Sbagliate** |
|---|---|---|
| Far Left | 9 | 11 |
| Slightly Left | 29 | 21 |
| Non labelled | 81 | 29 |
| Slightly Right | 156 | 51 |
| Far Right | 28 | 24 |

# Osservazione di John — il test per testata: il risultato

- $\chi^2$ per testata: **18,8** (contro 1.418 per articolo)
- Ancora sopra la soglia di 9,5: il legame **resta**...
- ...ma è molto meno "clamoroso"

*Esempio con RoBERTa; gli altri modelli danno da 19 a 45.*

RoBERTa, una riga per orientamento

| **Orientamento** | **Giuste** | **Sbagliate** |
|---|---|---|
| Far Left | 9 | 11 |
| Slightly Left | 29 | 21 |
| Non labelled | 81 | 29 |
| Slightly Right | 156 | 51 |
| Far Right | 28 | 24 |

# Problema 2 — cosa dice ChatGPT

- Nel paper l'errore è calcolato **separatamente per ogni orientamento**

# Problema 2 — cosa dice ChatGPT

- Nel paper l'errore è calcolato **separatamente per ogni orientamento**
- E si afferma che così è "**indipendente dalla frequenza delle classi**"

# Problema 2 — cosa dice ChatGPT

- Nel paper l'errore è calcolato **separatamente per ogni orientamento**
- E si afferma che così è "**indipendente dalla frequenza delle classi**"
- In altre parole: calcolarlo separatamente dovrebbe renderlo **non influenzato** da come sono distribuiti i dati

# Problema 2 — cosa dice ChatGPT

- Nel paper l'errore è calcolato **separatamente per ogni orientamento**
- E si afferma che così è "**indipendente dalla frequenza delle classi**"
- In altre parole: calcolarlo separatamente dovrebbe renderlo **non influenzato** da come sono distribuiti i dati
- ChatGPT fa notare: è vero **solo a metà**

# Problema 2 — perché solo a metà

- Calcolarlo separatamente toglie l'effetto della **dimensione** del gruppo (quanti articoli ha)

# Problema 2 — perché solo a metà

- Calcolarlo separatamente toglie l'effetto della **dimensione** del gruppo (quanti articoli ha)
- Ma **non** toglie l'effetto di **quali livelli** ci sono dentro

# Problema 2 — perché solo a metà

- Calcolarlo separatamente toglie l'effetto della **dimensione** del gruppo (quanti articoli ha)
- Ma **non** toglie l'effetto di **quali livelli** ci sono dentro
- E il livello pesa tanto: $l_1$ facile, $l_5$ difficile

# Problema 2 — perché solo a metà

- Calcolarlo separatamente toglie l'effetto della **dimensione** del gruppo (quanti articoli ha)
- Ma **non** toglie l'effetto di **quali livelli** ci sono dentro
- E il livello pesa tanto: $l_1$ facile, $l_5$ difficile
- Ogni orientamento ha un **mix di livelli diverso**

# Problema 2 — l'esempio

- Slightly Right è quasi tutto $I_1$ (il livello facile)

# Problema 2 — l'esempio

- Slightly Right è quasi tutto $I_1$ (il livello facile)
- Quindi il suo errore basso dipende dal fatto che è **pieno di articoli facili**...

# Problema 2 — l'esempio

- Slightly Right è quasi tutto $l_1$ (il livello facile)
- Quindi il suo errore basso dipende dal fatto che è **pieno di articoli facili**...

  *...non dal fatto che il modello "tratti meglio" la destra.*

# Problema 2 — l'esempio

- Slightly Right è quasi tutto $l_1$ (il livello facile)
- Quindi il suo errore basso dipende dal fatto che è **pieno di articoli facili**...

  *...non dal fatto che il modello "tratti meglio" la destra.*

- Conclusione: la frase va riscritta — l'errore per orientamento **dipende ancora** dalla composizione dei livelli

# Problema 2 — commento di John

- ChatGPT dà per scontato che i livelli abbiano **difficoltà diverse**

# Problema 2 — commento di John

- ChatGPT dà per scontato che i livelli abbiano **difficoltà diverse**
- Ma questa cosa **non è mai dimostrata**

# Problema 2 — commento di John

- ChatGPT dà per scontato che i livelli abbiano **difficoltà diverse**
- Ma questa cosa **non è mai dimostrata**
- Il modello sbaglia meno su $l_1$ — ma "**sbaglia meno**" non vuol dire "**è più facile**"

# Problema 2 — commento di John

- ChatGPT dà per scontato che i livelli abbiano **difficoltà diverse**
- Ma questa cosa **non è mai dimostrata**
- Il modello sbaglia meno su $l_1$ — ma "**sbaglia meno**" non vuol dire "**è più facile**"

  *Potrebbe sbagliare meno per tanti altri motivi: orientamento, tema, com'è fatto il dataset.*

# Problema 2 — commento di John

- ChatGPT dà per scontato che i livelli abbiano **difficoltà diverse**
- Ma questa cosa **non è mai dimostrata**
- Il modello sbaglia meno su $l_1$ — ma "**sbaglia meno**" non vuol dire "**è più facile**"

  *Potrebbe sbagliare meno per tanti altri motivi: orientamento, tema, com'è fatto il dataset.*
- Non ha senso dire che $l_1$ è più facile di $l_2$ solo perché il modello **sbaglia meno**

# Problema 3 — orientamento e affidabilità sono “incollati”

- Non solo intrecciati: in alcune combinazioni i dati **mancano del tutto**

# Problema 3 — orientamento e affidabilità sono “incollati”

- Non solo intrecciati: in alcune combinazioni i dati **mancano del tutto**
- Nessuna testata far-right è in $l_5$; 142 su 207 slightly-right sono in $l_1$

# Problema 3 — orientamento e affidabilità sono “incollati”

- Non solo intrecciati: in alcune combinazioni i dati **mancano del tutto**
- Nessuna testata far-right è in $I_5$; 142 su 207 slightly-right sono in $I_1$
- Quando due variabili sono così sovrapposte, **nessuna analisi** può separarle del tutto

# Problema 4 — il $\chi^2$ ha bisogno di abbastanza dati

- Il $\chi^2$ confronta, in ogni casella, quello che **osserva** con quello che **si aspetterebbe**

# Problema 4 — il $\chi^2$ ha bisogno di abbastanza dati

- Il $\chi^2$ confronta, in ogni casella, quello che **osserva** con quello che **si aspetterebbe**
- Funziona solo se in ogni casella ci sono **abbastanza osservazioni** (regola pratica: almeno $\sim$5 attese)

# Problema 4 — il $\chi^2$ ha bisogno di abbastanza dati

- Il $\chi^2$ confronta, in ogni casella, quello che **osserva** con quello che **si aspetterebbe**
- Funziona solo se in ogni casella ci sono **abbastanza osservazioni** (regola pratica: almeno $\sim$5 attese)
- Con poche testate, alcune caselle sono quasi **vuote**

# Problema 4 — nel nostro caso

- Testate divise in 5 orientamenti: **Far Left ne ha solo 20**

# Problema 4 — nel nostro caso

- Testate divise in 5 orientamenti: **Far Left ne ha solo 20**
- Nella casella "Far Left sbagliate" ne aspettiamo appena **6,2**: proprio al limite (perché: slide successive)

Test per testata, RoBERTa

| | | Sbagliate | |
|---|---|---|---|
| **Orientamento** | **Testate** | **osservate** | **attese** |
| Far Left | 20 | 11 | **6,2** |
| Slightly Left | 50 | 21 | 15,5 |
| Non labelled | 110 | 29 | 34,1 |
| Slightly Right | 207 | 51 | 64,1 |
| Far Right | 52 | 24 | 16,1 |

# Problema 4 — nel nostro caso

- Testate divise in 5 orientamenti: **Far Left ne ha solo 20**
- Nella casella "Far Left sbagliate" ne aspettiamo appena **6,2**: proprio al limite (perché: slide successive)
- E guardando orientamento *e* livello insieme, alcune caselle sono **vuote**: nessuna far-right di livello 5, nessuna slightly-left di livello 1

Test per testata, RoBERTa

| | | Sbagliate | |
|---|---|---|---|
| **Orientamento** | **Testate** | **osservate** | **attese** |
| Far Left | 20 | 11 | **6,2** |
| Slightly Left | 50 | 21 | 15,5 |
| Non labelled | 110 | 29 | 34,1 |
| Slightly Right | 207 | 51 | 64,1 |
| Far Right | 52 | 24 | 16,1 |

# Problema 4 — nel nostro caso

- Testate divise in 5 orientamenti: **Far Left ne ha solo 20**
- Nella casella "Far Left sbagliate" ne aspettiamo appena **6,2**: proprio al limite (perché: slide successive)
- E guardando orientamento *e* livello insieme, alcune caselle sono **vuote**: nessuna far-right di livello 5, nessuna slightly-left di livello 1

*Lì il $\chi^2$ non ha più senso.*

Test per testata, RoBERTa

| | | Sbagliate | |
|---|---|---|---|
| **Orientamento** | **Testate** | **osservate** | **attese** |
| Far Left | 20 | 11 | **6,2** |
| Slightly Left | 50 | 21 | 15,5 |
| Non labelled | 110 | 29 | 34,1 |
| Slightly Right | 207 | 51 | 64,1 |
| Far Right | 52 | 24 | 16,1 |

# Problema 4 — perché servono caselle piene (1)

- Il $\chi^2$ somma, casella per casella: $\dfrac{(\text{osservato} - \text{atteso})^2}{\text{atteso}}$

# Problema 4 — perché servono caselle piene (1)

- Il $\chi^2$ somma, casella per casella: $\dfrac{(\text{osservato} - \text{atteso})^2}{\text{atteso}}$
- Poi confronta il totale con la soglia di **9,5**: ma quella soglia è calcolata supponendo caselle **abbastanza piene**

# Problema 4 — perché servono caselle piene (1)

- Il $\chi^2$ somma, casella per casella: $\dfrac{(\text{osservato} - \text{atteso})^2}{\text{atteso}}$
- Poi confronta il totale con la soglia di **9,5**: ma quella soglia è calcolata supponendo caselle **abbastanza piene**
- Con caselle piccole, **una sola testata** pesa moltissimo:

# Problema 4 — perché servono caselle piene (1)

- Il $\chi^2$ somma, casella per casella: $\dfrac{(\text{osservato} - \text{atteso})^2}{\text{atteso}}$
- Poi confronta il totale con la soglia di **9,5**: ma quella soglia è calcolata supponendo caselle **abbastanza piene**
- Con caselle piccole, **una sola testata** pesa moltissimo:

  casella con 2 attese, ne osservo 4: $(4-2)^2/2 = \mathbf{2}$

# Problema 4 — perché servono caselle piene (1)

- Il $\chi^2$ somma, casella per casella: $\dfrac{(\text{osservato} - \text{atteso})^2}{\text{atteso}}$
- Poi confronta il totale con la soglia di **9,5**: ma quella soglia è calcolata supponendo caselle **abbastanza piene**
- Con caselle piccole, **una sola testata** pesa moltissimo:

  casella con 2 attese, ne osservo 4: $(4-2)^2/2 = \mathbf{2}$

  casella con 50 attese, ne osservo 52: $(52-50)^2/50 = \mathbf{0{,}08}$

# Problema 4 — perché servono caselle piene (1)

- Il $\chi^2$ somma, casella per casella: $\dfrac{(\text{osservato} - \text{atteso})^2}{\text{atteso}}$
- Poi confronta il totale con la soglia di **9,5**: ma quella soglia è calcolata supponendo caselle **abbastanza piene**
- Con caselle piccole, **una sola testata** pesa moltissimo:

  casella con 2 attese, ne osservo 4: $(4-2)^2/2 = \mathbf{2}$

  casella con 50 attese, ne osservo 52: $(52-50)^2/50 = \mathbf{0{,}08}$

  *Stessa differenza di 2 testate, peso 25 volte diverso.*

# Problema 4 — perché servono caselle piene (2)

- Nel nostro caso (RoBERTa) il $\chi^2$ per testata vale **18,8**

# Problema 4 — perché servono caselle piene (2)

- Nel nostro caso (RoBERTa) il $\chi^2$ per testata vale **18,8**
- Le sole 20 testate Far Left ne portano **5,4**: quasi un terzo

# Problema 4 — perché servono caselle piene (2)

- Nel nostro caso (RoBERTa) il $\chi^2$ per testata vale **18,8**
- Le sole 20 testate Far Left ne portano **5,4**: quasi un terzo
- Se **una** testata Far Left passasse da sbagliata a giusta: $\chi^2$ da 18,8 a **16,9**

# Problema 4 — perché servono caselle piene (2)

- Nel nostro caso (RoBERTa) il $\chi^2$ per testata vale **18,8**
- Le sole 20 testate Far Left ne portano **5,4**: quasi un terzo
- Se **una** testata Far Left passasse da sbagliata a giusta: $\chi^2$ da 18,8 a **16,9**
- Se lo facesse una testata Slightly Right: da 18,8 a 19,5

# Problema 4 — perché servono caselle piene (2)

- Nel nostro caso (RoBERTa) il $\chi^2$ per testata vale **18,8**
- Le sole 20 testate Far Left ne portano **5,4**: quasi un terzo
- Se **una** testata Far Left passasse da sbagliata a giusta: $\chi^2$ da 18,8 a **16,9**
- Se lo facesse una testata Slightly Right: da 18,8 a 19,5

*Il risultato dipende molto da pochissime testate.*

# Problema 4 — perché servono caselle piene (2)

- Nel nostro caso (RoBERTa) il $\chi^2$ per testata vale **18,8**
- Le sole 20 testate Far Left ne portano **5,4**: quasi un terzo
- Se **una** testata Far Left passasse da sbagliata a giusta: $\chi^2$ da 18,8 a **16,9**
- Se lo facesse una testata Slightly Right: da 18,8 a 19,5

  *Il risultato dipende molto da pochissime testate.*

- Regola pratica: almeno **5 attese** per casella. Noi ne abbiamo 6,2: appena sopra, **al limite**

# Problema 5 — la MED guarda solo gli errori

- La MED misura la direzione dell'errore **solo quando il modello sbaglia**

# Problema 5 — la MED guarda solo gli errori

- La MED misura la direzione dell'errore **solo quando il modello sbaglia**
- Non tiene conto di **quanto spesso** sbaglia

# Problema 5 — l'esempio

- Gruppo A: sbaglia il **70%** degli articoli, e quando sbaglia sovrastima di mezzo livello (MED $+0.5$)

# Problema 5 — l'esempio

- Gruppo A: sbaglia il **70%** degli articoli, e quando sbaglia sovrastima di mezzo livello (MED $+0.5$)
- Gruppo B: sbaglia il **10%**, con la stessa MED $+0.5$

# Problema 5 — l'esempio

- Gruppo A: sbaglia il **70%** degli articoli, e quando sbaglia sovrastima di mezzo livello (MED $+0.5$)
- Gruppo B: sbaglia il **10%**, con la stessa MED $+0.5$
- Stessa MED, ma l'effetto totale è **diversissimo**: A viene spinto in alto 7 volte su 10, B solo 1 su 10

# Problema 5 — l'esempio

- Gruppo A: sbaglia il **70%** degli articoli, e quando sbaglia sovrastima di mezzo livello (MED $+0.5$)
- Gruppo B: sbaglia il **10%**, con la stessa MED $+0.5$
- Stessa MED, ma l'effetto totale è **diversissimo**: A viene spinto in alto 7 volte su 10, B solo 1 su 10

*Nel paper gli estremi sbagliano il 60–72%, i non-labelled il 30%: confrontare le loro MED inganna.*

# Problema 5 — l'esempio

- Gruppo A: sbaglia il **70%** degli articoli, e quando sbaglia sovrastima di mezzo livello (MED $+0.5$)
- Gruppo B: sbaglia il **10%**, con la stessa MED $+0.5$
- Stessa MED, ma l'effetto totale è **diversissimo**: A viene spinto in alto 7 volte su 10, B solo 1 su 10

  *Nel paper gli estremi sbagliano il 60–72%, i non-labelled il 30%: confrontare le loro MED inganna.*

- Soluzione: riportare anche la direzione media su **tutti** gli articoli, compresi quelli classificati **correttamente** (che contano zero)

# Problema 5 — un'incoerenza nel paper bocciato

- La **formula** della MED usa solo gli articoli **sbagliati**

# Problema 5 — un'incoerenza nel paper bocciato

- La **formula** della MED usa solo gli articoli **sbagliati**
- Ma i numeri **per livello** (es. $l_5 \approx -1{,}30$) sono calcolati su **tutti** gli articoli

# Problema 5 — un'incoerenza nel paper bocciato

- La **formula** della MED usa solo gli articoli **sbagliati**
- Ma i numeri **per livello** (es. $l_5 \approx -1{,}30$) sono calcolati su **tutti** gli articoli
- Mentre quelli **per orientamento** (estremi da $+0{,}33$ a $+1{,}00$) solo sugli **errori**

# Problema 5 — un'incoerenza nel paper bocciato

- La **formula** della MED usa solo gli articoli **sbagliati**
- Ma i numeri **per livello** (es. $l_5 \approx -1{,}30$) sono calcolati su **tutti** gli articoli
- Mentre quelli **per orientamento** (estremi da $+0{,}33$ a $+1{,}00$) solo sugli **errori**

*Due definizioni diverse nello stesso paper: nel nuovo va scelta una sola, e dichiarata.*

# Problema 6 — la direzione è “obbligata” dai bordi

- Se una testata è in $l_1$ (il più basso), l’errore può solo andare **verso l’alto**; se è in $l_5$, solo verso il basso

# Problema 6 — la direzione è “obbligata” dai bordi

- Se una testata è in $l_1$ (il più basso), l’errore può solo andare **verso l’alto**; se è in $l_5$, solo verso il basso
- Far-left e far-right stanno quasi tutti nei livelli bassi $\rightarrow$ i loro errori sono “per forza” positivi

# Problema 6 — la direzione è “obbligata” dai bordi

- Se una testata è in $l_1$ (il più basso), l’errore può solo andare **verso l’alto**; se è in $l_5$, solo verso il basso
- Far-left e far-right stanno quasi tutti nei livelli bassi $\rightarrow$ i loro errori sono “per forza” positivi

*Quindi la sovrastima degli estremi può dipendere dalla composizione, non dall’orientamento.*

# Considerazione di John a ChatGPT (1)

- L'affidabilità l'abbiamo **stratificata** nei fold (tenuta sotto controllo)

# Considerazione di John a ChatGPT (1)

- L'affidabilità l'abbiamo **stratificata** nei fold (tenuta sotto controllo)
- L'orientamento invece **no**: è lasciato a caso

# Considerazione di John a ChatGPT (1)

- L'affidabilità l'abbiamo **stratificata** nei fold (tenuta sotto controllo)
- L'orientamento invece **no**: è lasciato a caso
- E nel dataset orientamento $\times$ livello è **sbilanciatissimo**

# Considerazione di John a ChatGPT (1)

- L'affidabilità l'abbiamo **stratificata** nei fold (tenuta sotto controllo)
- L'orientamento invece **no**: è lasciato a caso
- E nel dataset orientamento $\times$ livello è **sbilanciatissimo**
- Alcune combinazioni **non esistono**: nessuna slightly-left di livello 1, nessuna far-right di livello 5

# Considerazione di John a ChatGPT (2)

- Quando dividiamo in fold, a volte il modello vede **zero** esempi di una combinazione che poi deve indovinare

# Considerazione di John a ChatGPT (2)

- Quando dividiamo in fold, a volte il modello vede **zero** esempi di una combinazione che poi deve indovinare
- Es. (fold 1): nessun Far Left di livello 1 o 3 in addestramento, ma viene testato proprio su quelli

# Considerazione di John a ChatGPT (2)

- Quando dividiamo in fold, a volte il modello vede **zero** esempi di una combinazione che poi deve indovinare
- Es. (fold 1): nessun Far Left di livello 1 o 3 in addestramento, ma viene testato proprio su quelli

  *Naturale che sbagli: non li ha mai visti.*

# Considerazione di John a ChatGPT (2)

- Quando dividiamo in fold, a volte il modello vede **zero** esempi di una combinazione che poi deve indovinare
- Es. (fold 1): nessun Far Left di livello 1 o 3 in addestramento, ma viene testato proprio su quelli

  *Naturale che sbagli: non li ha mai visti.*
- Quindi parte di questi "errori politici" è un **artefatto** del dataset e dei fold

# Considerazione di John a ChatGPT (3)

- Questa analisi del bias è **molto specifica**: vale per *questo* dataset, *questi* modelli, *questo* training

# Considerazione di John a ChatGPT (3)

- Questa analisi del bias è **molto specifica**: vale per *questo* dataset, *questi* modelli, *questo* training
- Non è un risultato generale sul "comportamento politico" dei modelli

# Considerazione di John a ChatGPT (3)

- Questa analisi del bias è **molto specifica**: vale per *questo* dataset, *questi* modelli, *questo* training
- Non è un risultato generale sul "comportamento politico" dei modelli
- Se la teniamo, va detto **chiaramente**

# Considerazione di John a ChatGPT (3)

- Questa analisi del bias è **molto specifica**: vale per *questo* dataset, *questi* modelli, *questo* training
- Non è un risultato generale sul "comportamento politico" dei modelli
- Se la teniamo, va detto **chiaramente**

  *È un po' un'analisi fine a sé stessa.*

# Considerazione di John — che cos'è una testata?

**Una critica nostra, non a ChatGPT**

Nel paper una testata coincide con **l'insieme dei suoi articoli**. Ma è davvero così?

- Oggi una testata è anche le sue **pagine social**, le **newsletter**, i **podcast**, i video

# Considerazione di John — che cos'è una testata?

**Una critica nostra, non a ChatGPT**

Nel paper una testata coincide con **l'insieme dei suoi articoli**. Ma è davvero così?

- Oggi una testata è anche le sue **pagine social**, le **newsletter**, i **podcast**, i video
- Noi guardiamo solo gli **articoli del sito**: una parte della testata, non la testata intera

# Considerazione di John — che cos'è una testata?

**Una critica nostra, non a ChatGPT**

Nel paper una testata coincide con **l'insieme dei suoi articoli**. Ma è davvero così?

- Oggi una testata è anche le sue **pagine social**, le **newsletter**, i **podcast**, i video
- Noi guardiamo solo gli **articoli del sito**: una parte della testata, non la testata intera

*Rischiamo di giudicare la testata guardandone solo una parte.*

# Considerazione di John — che cos'è una testata?

**Una critica nostra, non a ChatGPT**

Nel paper una testata coincide con **l'insieme dei suoi articoli**. Ma è davvero così?

- Oggi una testata è anche le sue **pagine social**, le **newsletter**, i **podcast**, i video
- Noi guardiamo solo gli **articoli del sito**: una parte della testata, non la testata intera

  *Rischiamo di giudicare la testata guardandone solo una parte.*
- Nel paper non dovremmo darlo per scontato: va detto chiaramente **che cosa** stiamo giudicando

# Fabio × Claude — cos'è

- Fabio ha chiesto a Claude tre cose: come usare i modelli grandi, una review del paper, come impostare l'analisi del bias

# Fabio × Claude — cos'è

- Fabio ha chiesto a Claude tre cose: come usare i modelli grandi, una review del paper, come impostare l'analisi del bias
- Il bias l'abbiamo **già visto**: non ci torniamo

# Fabio × Claude — cos'è

- Fabio ha chiesto a Claude tre cose: come usare i modelli grandi, una review del paper, come impostare l'analisi del bias
- Il bias l'abbiamo **già visto**: non ci torniamo
- Qui solo le **proposte nuove**: esperimenti, metodi, aggregazione, correzioni

# Fabio — il problema della “contaminazione”

- Domanda di ogni lettore: “perché non chiedere direttamente a GPT?”

# Fabio — il problema della “contaminazione”

- Domanda di ogni lettore: “perché non chiedere direttamente a GPT?”
- Ma un LLM grande **conosce già** queste testate: le ha lette in addestramento e ne sa la reputazione

# Fabio — il problema della “contaminazione”

- Domanda di ogni lettore: “perché non chiedere direttamente a GPT?”
- Ma un LLM grande **conosce già** queste testate: le ha lette in addestramento e ne sa la reputazione
- E negli articoli il nome della testata compare spesso (firma, piè di pagina, link)

# Fabio — il problema della “contaminazione”

- Domanda di ogni lettore: “perché non chiedere direttamente a GPT?”
- Ma un LLM grande **conosce già** queste testate: le ha lette in addestramento e ne sa la reputazione
- E negli articoli il nome della testata compare spesso (firma, piè di pagina, link)
- Quindi GPT potrebbe **ricordare la reputazione** invece di leggere il testo

# Fabio — il problema della "contaminazione"

- Domanda di ogni lettore: "perché non chiedere direttamente a GPT?"
- Ma un LLM grande **conosce già** queste testate: le ha lette in addestramento e ne sa la reputazione
- E negli articoli il nome della testata compare spesso (firma, piè di pagina, link)
- Quindi GPT potrebbe **ricordare la reputazione** invece di leggere il testo

*Come far giudicare un vino "alla cieca" lasciando l'etichetta sulla bottiglia.*

# Fabio — l'esperimento: con e senza nomi

- Si fa valutare a un LLM lo stesso articolo due volte: **normale** e con nomi, siti e firme **cancellati**

# Fabio — l'esperimento: con e senza nomi

- Si fa valutare a un LLM lo stesso articolo due volte: **normale** e con nomi, siti e firme **cancellati**
- Se senza nomi va molto peggio → prima stava **riconoscendo la testata**, non giudicando il testo

# Fabio — l'esperimento: con e senza nomi

- Si fa valutare a un LLM lo stesso articolo due volte: **normale** e con nomi, siti e firme **cancellati**
- Se senza nomi va molto peggio → prima stava **riconoscendo la testata**, non giudicando il testo
- Trasforma la domanda "perché non GPT?" in un **risultato**

# Fabio — l'esperimento: con e senza nomi

- Si fa valutare a un LLM lo stesso articolo due volte: **normale** e con nomi, siti e firme **cancellati**
- Se senza nomi va molto peggio → prima stava **riconoscendo la testata**, non giudicando il testo
- Trasforma la domanda "perché non GPT?" in un **risultato**
- E spiega perché i modelli piccoli addestrati da noi sono lo strumento giusto per *questa* domanda

# Fabio — una baseline semplice: TF-IDF

- Oggi confrontiamo i transformer solo con baseline “stupide” (classe più frequente, caso)

# Fabio — una baseline semplice: TF-IDF

- Oggi confrontiamo i transformer solo con baseline “stupide” (classe più frequente, caso)
- Fabio: aggiungere un modello **semplice ma serio**, senza reti neurali

# Fabio — una baseline semplice: TF-IDF

- Oggi confrontiamo i transformer solo con baseline “stupide” (classe più frequente, caso)
- Fabio: aggiungere un modello **semplice ma serio**, senza reti neurali
- **TF-IDF**: conta le parole di ogni articolo, dando più peso a quelle rare e distintive; sopra, una regressione logistica

# Fabio — una baseline semplice: TF-IDF

- Oggi confrontiamo i transformer solo con baseline “stupide” (classe più frequente, caso)
- Fabio: aggiungere un modello **semplice ma serio**, senza reti neurali
- **TF-IDF**: conta le parole di ogni articolo, dando più peso a quelle rare e distintive; sopra, una regressione logistica

  *Se un “contatore di parole” arriva vicino ai transformer, i transformer non stanno aggiungendo molto.*

# Fabio — una baseline semplice: TF-IDF

- Oggi confrontiamo i transformer solo con baseline “stupide” (classe più frequente, caso)
- Fabio: aggiungere un modello **semplice ma serio**, senza reti neurali
- **TF-IDF**: conta le parole di ogni articolo, dando più peso a quelle rare e distintive; sopra, una regressione logistica

  *Se un “contatore di parole” arriva vicino ai transformer, i transformer non stanno aggiungendo molto.*

- Costa pochissimo da fare

# Fabio — LLM come estrattore di segnali: l'idea

- Invece di chiedere all'LLM "è affidabile?", gli si chiede un **voto su segnali precisi**

# Fabio — LLM come estrattore di segnali: l'idea

- Invece di chiedere all'LLM "è affidabile?", gli si chiede un **voto su segnali precisi**

  *Sensazionalismo, fonti citate, toni prudenti, opinione o cronaca, titolo acchiappa-clic, presenza di rettifiche. . .*

# Fabio — LLM come estrattore di segnali: l'idea

- Invece di chiedere all'LLM "è affidabile?", gli si chiede un **voto su segnali precisi**

  *Sensazionalismo, fonti citate, toni prudenti, opinione o cronaca, titolo acchiappa-clic, presenza di rettifiche...*

- Ogni articolo diventa una **lista di voti**

# Fabio — LLM come estrattore di segnali: l'idea

- Invece di chiedere all'LLM "è affidabile?", gli si chiede un **voto su segnali precisi**

  *Sensazionalismo, fonti citate, toni prudenti, opinione o cronaca, titolo acchiappa-clic, presenza di rettifiche. . .*

- Ogni articolo diventa una **lista di voti**

  *Es.: sensazionalismo 8/10, fonti citate 2/10, opinione 9/10, . . .*

# Fabio — LLM come estrattore di segnali: l'idea

- Invece di chiedere all'LLM "è affidabile?", gli si chiede un **voto su segnali precisi**

  *Sensazionalismo, fonti citate, toni prudenti, opinione o cronaca, titolo acchiappa-clic, presenza di rettifiche...*

- Ogni articolo diventa una **lista di voti**

  *Es.: sensazionalismo 8/10, fonti citate 2/10, opinione 9/10, ...*

- Poi un classificatore semplice impara **quali segnali contano**

# Fabio — LLM come estrattore di segnali: perché

- **Costa poco**: una chiamata all'LLM per articolo ($\sim$20.000 in tutto)

# Fabio — LLM come estrattore di segnali: perché

- **Costa poco**: una chiamata all'LLM per articolo ($\sim$20.000 in tutto)
- **Si capisce**: sappiamo *quali* segnali distinguono una testata affidabile

# Fabio — LLM come estrattore di segnali: perché

- **Costa poco**: una chiamata all'LLM per articolo ($\sim$20.000 in tutto)
- **Si capisce**: sappiamo *quali* segnali distinguono una testata affidabile
- Aggregare è naturale: il profilo di una testata è la **media** dei voti dei suoi articoli

# Fabio — LLM come estrattore di segnali: perché

- **Costa poco**: una chiamata all'LLM per articolo ($\sim$20.000 in tutto)
- **Si capisce**: sappiamo *quali* segnali distinguono una testata affidabile
- Aggregare è naturale: il profilo di una testata è la **media** dei voti dei suoi articoli
- Per Fabio è la proposta con il miglior rapporto novità/fatica, insieme all'esperimento con e senza nomi

# Fabio — multiple-instance learning: l'idea

- Oggi: classifichiamo **ogni articolo**, poi **votiamo**

# Fabio — multiple-instance learning: l'idea

- Oggi: classifichiamo **ogni articolo**, poi **votiamo**
- Ma l'etichetta vera è della **testata**, non del singolo articolo

# Fabio — multiple-instance learning: l'idea

- Oggi: classifichiamo **ogni articolo**, poi **votiamo**
- Ma l'etichetta vera è della **testata**, non del singolo articolo
- Idea: addestrare il modello direttamente su "**sacchetti**" di articoli: tutti quelli di una testata insieme, con l'etichetta della testata

# Fabio — multiple-instance learning: l'idea

- Oggi: classifichiamo **ogni articolo**, poi **votiamo**
- Ma l'etichetta vera è della **testata**, non del singolo articolo
- Idea: addestrare il modello direttamente su "**sacchetti**" di articoli: tutti quelli di una testata insieme, con l'etichetta della testata

  *Come giudicare un ristorante leggendo tutte le recensioni insieme, invece di dare un voto a ciascuna e fare la maggioranza.*

# Fabio — multiple-instance learning: come

- Ogni articolo viene trasformato una volta in un **embedding**: una lista di numeri che ne riassume il significato

# Fabio — multiple-instance learning: come

- Ogni articolo viene trasformato una volta in un **embedding**: una lista di numeri che ne riassume il significato
- Il modello impara a combinare gli embedding di una testata (media, o pesando di più gli articoli più utili)

# Fabio — multiple-instance learning: come

- Ogni articolo viene trasformato una volta in un **embedding**: una lista di numeri che ne riassume il significato
- Il modello impara a combinare gli embedding di una testata (media, o pesando di più gli articoli più utili)
- 439 testate sono poche: si creano tanti sacchetti **a caso** da 10–20 articoli della stessa testata $\rightarrow$ migliaia di esempi

# Fabio — multiple-instance learning: come

- Ogni articolo viene trasformato una volta in un **embedding**: una lista di numeri che ne riassume il significato
- Il modello impara a combinare gli embedding di una testata (media, o pesando di più gli articoli più utili)
- 439 testate sono poche: si creano tanti sacchetti **a caso** da 10–20 articoli della stessa testata $\rightarrow$ migliaia di esempi
- In più dà una **misura di confidenza** sul giudizio della testata

# Fabio — modelli più recenti e altre idee

- BERT e Llama 3 sembrano “datati”: stessa ricetta con modelli attuali (**ModernBERT**, **DeBERTa-v3**, piccoli decoder recenti)

# Fabio — modelli più recenti e altre idee

- BERT e Llama 3 sembrano “datati”: stessa ricetta con modelli attuali (**ModernBERT**, **DeBERTa-v3**, piccoli decoder recenti)

  *Quasi solo estetica, ma toglie un appiglio ai revisori.*

# Fabio — modelli più recenti e altre idee

- BERT e Llama 3 sembrano “datati”: stessa ricetta con modelli attuali (**ModernBERT**, **DeBERTa-v3**, piccoli decoder recenti)

  *Quasi solo estetica, ma toglie un appiglio ai revisori.*

- **Pulizia delle etichette**: un LLM segnala gli articoli atipici per la loro testata e si dà loro meno peso

# Fabio — modelli più recenti e altre idee

- BERT e Llama 3 sembrano “datati”: stessa ricetta con modelli attuali (**ModernBERT**, **DeBERTa-v3**, piccoli decoder recenti)

  *Quasi solo estetica, ma toglie un appiglio ai revisori.*

- **Pulizia delle etichette**: un LLM segnala gli articoli atipici per la loro testata e si dà loro meno peso
- **Agente**: visita la testata, legge le pagine “chi siamo”, proprietà, rettifiche, e valuta i 9 criteri di NewsGuard

# Fabio — modelli più recenti e altre idee

- BERT e Llama 3 sembrano “datati”: stessa ricetta con modelli attuali (**ModernBERT**, **DeBERTa-v3**, piccoli decoder recenti)

  *Quasi solo estetica, ma toglie un appiglio ai revisori.*

- **Pulizia delle etichette**: un LLM segnala gli articoli atipici per la loro testata e si dà loro meno peso
- **Agente**: visita la testata, legge le pagine “chi siamo”, proprietà, rettifiche, e valuta i 9 criteri di NewsGuard

  *È un altro task (non solo testo): lavoro futuro.*

# Fabio — la distillazione: cos'è

- Un modello **grande** ("insegnante", es. un LLM) serve ad addestrare un modello **piccolo** ("studente")

# Fabio — la distillazione: cos'è

- Un modello **grande** ("insegnante", es. un LLM) serve ad addestrare un modello **piccolo** ("studente")
- L'insegnante legge gli articoli e dà le sue risposte; lo studente impara a **imitarle**

# Fabio — la distillazione: cos'è

- Un modello **grande** ("insegnante", es. un LLM) serve ad addestrare un modello **piccolo** ("studente")
- L'insegnante legge gli articoli e dà le sue risposte; lo studente impara a **imitarle**

  *Come uno studente che impara dagli appunti del professore, non solo dal libro.*

# Fabio — la distillazione: cos'è

- Un modello **grande** ("insegnante", es. un LLM) serve ad addestrare un modello **piccolo** ("studente")
- L'insegnante legge gli articoli e dà le sue risposte; lo studente impara a **imitarle**

  *Come uno studente che impara dagli appunti del professore, non solo dal libro.*
- Per Fabio, nella forma base serve a poco: le etichette giuste (NewsGuard) le abbiamo già, e l'insegnante porterebbe dentro la sua **contaminazione** (riconosce le testate)

# Fabio — la distillazione: come andrebbe fatta

1. Per ogni articolo l'LLM scrive una **breve spiegazione**: perché sembra affidabile o no

# Fabio — la distillazione: come andrebbe fatta

1. Per ogni articolo l'LLM scrive una **breve spiegazione**: perché sembra affidabile o no

   *Es.: "titolo sensazionalistico, nessuna fonte citata, tono da opinione".*

# Fabio — la distillazione: come andrebbe fatta

1. Per ogni articolo l'LLM scrive una **breve spiegazione**: perché sembra affidabile o no

   *Es.: "titolo sensazionalistico, nessuna fonte citata, tono da opinione".*

2. Il modello piccolo viene addestrato a dare **l'etichetta NewsGuard** *e* a riprodurre la **spiegazione**

# Fabio — la distillazione: come andrebbe fatta

1. Per ogni articolo l'LLM scrive una **breve spiegazione**: perché sembra affidabile o no

   *Es.: "titolo sensazionalistico, nessuna fonte citata, tono da opinione".*

2. Il modello piccolo viene addestrato a dare **l'etichetta NewsGuard** *e* a riprodurre la **spiegazione**

3. Così impara *su cosa* guardare, non solo il risultato → gli servono **meno dati**

# Fabio — la distillazione: come andrebbe fatta

1. Per ogni articolo l'LLM scrive una **breve spiegazione**: perché sembra affidabile o no

   *Es.: "titolo sensazionalistico, nessuna fonte citata, tono da opinione".*

2. Il modello piccolo viene addestrato a dare **l'etichetta NewsGuard** *e* a riprodurre la **spiegazione**

3. Così impara *su cosa* guardare, non solo il risultato → gli servono **meno dati**

*Per Fabio: guadagno incerto e parecchio lavoro, non prioritaria.*

# Fabio — confrontare modi di aggregare

- Oggi usiamo un solo modo: il **voto di maggioranza**

# Fabio — confrontare modi di aggregare

- Oggi usiamo un solo modo: il **voto di maggioranza**
- Alternative: **media** dei livelli, **mediana**, media delle **probabilità**

# Fabio — confrontare modi di aggregare

- Oggi usiamo un solo modo: il **voto di maggioranza**
- Alternative: **media** dei livelli, **mediana**, media delle **probabilità**
- Esempio, 10 articoli: 4 dicono $l_2$, 3 dicono $l_3$, 3 dicono $l_4$

# Fabio — confrontare modi di aggregare

- Oggi usiamo un solo modo: il **voto di maggioranza**
- Alternative: **media** dei livelli, **mediana**, media delle **probabilità**
- Esempio, 10 articoli: 4 dicono $l_2$, 3 dicono $l_3$, 3 dicono $l_4$

  Maggioranza: $l_2$ Media: $(4{\cdot}2 + 3{\cdot}3 + 3{\cdot}4)/10 = 2{,}9 \to l_3$

# Fabio — confrontare modi di aggregare

- Oggi usiamo un solo modo: il **voto di maggioranza**
- Alternative: **media** dei livelli, **mediana**, media delle **probabilità**
- Esempio, 10 articoli: 4 dicono $l_2$, 3 dicono $l_3$, 3 dicono $l_4$

  Maggioranza: $l_2$ Media: $(4{\cdot}2 + 3{\cdot}3 + 3{\cdot}4)/10 = 2{,}9 \to l_3$
- Risposte **diverse**: vale la pena confrontarle

# Fabio — quanti articoli servono?

- Domanda pratica: per giudicare una testata **nuova**, quanti articoli mi servono?

# Fabio — quanti articoli servono?

- Domanda pratica: per giudicare una testata **nuova**, quanti articoli mi servono?
- La curva: accuratezza sulla testata usando 5, 10, 20, 50... articoli

# Fabio — quanti articoli servono?

- Domanda pratica: per giudicare una testata **nuova**, quanti articoli mi servono?
- La curva: accuratezza sulla testata usando 5, 10, 20, 50... articoli
- Con fino a 200 articoli il voto è probabilmente già "saturo": la domanda interessante è **con pochi**

# Fabio — quanti articoli servono?

- Domanda pratica: per giudicare una testata **nuova**, quanti articoli mi servono?
- La curva: accuratezza sulla testata usando 5, 10, 20, 50… articoli
- Con fino a 200 articoli il voto è probabilmente già "saturo": la domanda interessante è **con pochi**

*È l'informazione più utile per chi volesse usare il sistema davvero.*

# Fabio — l'early stopping: cos'è

- Il modello si addestra in più "giri" sugli stessi dati (le **epoche**)

# Fabio — l'early stopping: cos'è

- Il modello si addestra in più "giri" sugli stessi dati (le **epoche**)
- Dopo un po' comincia a **imparare a memoria** gli esempi e peggiora sui dati nuovi

# Fabio — l'early stopping: cos'è

- Il modello si addestra in più "giri" sugli stessi dati (le **epoche**)
- Dopo un po' comincia a **imparare a memoria** gli esempi e peggiora sui dati nuovi
- Early stopping: dopo ogni giro misuro l'errore su dati **messi da parte** ("validation") e tengo la versione migliore

# Fabio — l'early stopping: cos'è

- Il modello si addestra in più "giri" sugli stessi dati (le **epoche**)
- Dopo un po' comincia a **imparare a memoria** gli esempi e peggiora sui dati nuovi
- Early stopping: dopo ogni giro misuro l'errore su dati **messi da parte** ("validation") e tengo la versione migliore

| **Giro** | 1 | 2 | 3 | 4 | 5 |
|---|---|---|---|---|---|
| **Errore sulla validation** | 0,60 | 0,50 | 0,46 | **0,44** | 0,47 |

# Fabio — l'early stopping: cos'è

- Il modello si addestra in più "giri" sugli stessi dati (le **epoche**)
- Dopo un po' comincia a **imparare a memoria** gli esempi e peggiora sui dati nuovi
- Early stopping: dopo ogni giro misuro l'errore su dati **messi da parte** ("validation") e tengo la versione migliore

| **Giro** | 1 | 2 | 3 | 4 | 5 |
|---|---|---|---|---|---|
| **Errore sulla validation** | 0,60 | 0,50 | 0,46 | **0,44** | 0,47 |

*Tengo il giro 4: dopo, il modello peggiora (come Llama nel paper, minimo al giro 4).*

# Fabio — l'early stopping: il rischio

- I dati di validation devono essere **diversi** da quelli di test

# Fabio — l'early stopping: il rischio

- I dati di validation devono essere **diversi** da quelli di test
- Se scegliessi il giro migliore guardando il **test**, sceglierei la versione che *per caso* va meglio proprio sul test

# Fabio — l'early stopping: il rischio

- I dati di validation devono essere **diversi** da quelli di test
- Se scegliessi il giro migliore guardando il **test**, sceglierei la versione che *per caso* va meglio proprio sul test

  *Come scegliere quale compito consegnare dopo aver visto le soluzioni: il voto sembra più alto di quello che vali.*

# Fabio — l'early stopping: il rischio

- I dati di validation devono essere **diversi** da quelli di test
- Se scegliessi il giro migliore guardando il **test**, sceglierei la versione che *per caso* va meglio proprio sul test

  *Come scegliere quale compito consegnare dopo aver visto le soluzioni: il voto sembra più alto di quello che vali.*

- Il risultato riportato sarebbe **gonfiato**

# Fabio — l'early stopping: nel nostro caso

- Nel paper: "early stopping che salva il modello con la validation loss minima", senza dire **su quali dati**

# Fabio — l'early stopping: nel nostro caso

- Nel paper: "early stopping che salva il modello con la validation loss minima", senza dire **su quali dati**
- Dal codice: lo usa **solo Llama**, su un 10% degli articoli di **training**; gli altri modelli fanno un numero fisso di giri

# Fabio — l'early stopping: nel nostro caso

- Nel paper: "early stopping che salva il modello con la validation loss minima", senza dire **su quali dati**
- Dal codice: lo usa **solo Llama**, su un 10% degli articoli di **training**; gli altri modelli fanno un numero fisso di giri
- Quindi nessuna contaminazione, ma **va scritto** chiaramente

# Fabio — tema e periodo

- Gli articoli sono presi dalle homepage in un **periodo breve**: ogni testata porta i **temi del momento**

# Fabio — tema e periodo

- Gli articoli sono presi dalle homepage in un **periodo breve**: ogni testata porta i **temi del momento**
- Se tema e affidabilità vanno insieme, il modello potrebbe imparare il **tema**, non l'affidabilità

# Fabio — tema e periodo

- Gli articoli sono presi dalle homepage in un **periodo breve**: ogni testata porta i **temi del momento**
- Se tema e affidabilità vanno insieme, il modello potrebbe imparare il **tema**, non l'affidabilità

  *Es.: se quella settimana le testate inaffidabili parlano tutte dello stesso argomento, basta riconoscere l'argomento.*

# Fabio — tema e periodo

- Gli articoli sono presi dalle homepage in un **periodo breve**: ogni testata porta i **temi del momento**
- Se tema e affidabilità vanno insieme, il modello potrebbe imparare il **tema**, non l'affidabilità

  *Es.: se quella settimana le testate inaffidabili parlano tutte dello stesso argomento, basta riconoscere l'argomento.*
- Controllo: classificare il tema degli articoli e vedere se è legato al livello

# Fabio — la classe $l_5$ e l'ordine dei livelli

- $l_5$ = punteggio **esattamente 100**: classe piccola e quasi impossibile da distinguere da $l_4$

# Fabio — la classe $l_5$ e l'ordine dei livelli

- $l_5$ = punteggio **esattamente 100**: classe piccola e quasi impossibile da distinguere da $l_4$
- Proposta: **unire** $l_4$ e $l_5$, o riportare anche i risultati a 4 classi

# Fabio — la classe $l_5$ e l'ordine dei livelli

- $l_5$ = punteggio **esattamente 100**: classe piccola e quasi impossibile da distinguere da $l_4$
- Proposta: **unire** $l_4$ e $l_5$, o riportare anche i risultati a 4 classi
- I livelli sono **ordinati**, ma il modello è addestrato come se fossero categorie slegate

# Fabio — la classe $l_5$ e l'ordine dei livelli

- $l_5$ = punteggio **esattamente 100**: classe piccola e quasi impossibile da distinguere da $l_4$
- Proposta: **unire** $l_4$ e $l_5$, o riportare anche i risultati a 4 classi
- I livelli sono **ordinati**, ma il modello è addestrato come se fossero categorie slegate

  *In addestramento confondere $l_5$ con $l_4$ costa quanto confonderlo con $l_1$: va almeno detto come limite.*

# Fabio — correzioni di scrittura (verificate)

- Bibliografia doppia: [4] = [15] (Przybyła & Soto), [5] = [20] (Srba et al.)

# Fabio — correzioni di scrittura (verificate)

- Bibliografia doppia: [4] = [15] (Przybyła & Soto), [5] = [20] (Srba et al.)
- [30] cita “Mixtral of Experts” per Mistral 24B: è un modello diverso

# Fabio — correzioni di scrittura (verificate)

- Bibliografia doppia: [4] = [15] (Przybyła & Soto), [5] = [20] (Srba et al.)
- [30] cita “Mixtral of Experts” per Mistral 24B: è un modello diverso
- Rinvii sbagliati: “In V-B we instantiate Agg” (è V-E), “Section IV-0c”

# Fabio — correzioni di scrittura (verificate)

- Bibliografia doppia: [4] = [15] (Przybyła & Soto), [5] = [20] (Srba et al.)
- [30] cita “Mixtral of Experts” per Mistral 24B: è un modello diverso
- Rinvii sbagliati: “In V-B we instantiate Agg” (è V-E), “Section IV-0c”
- Tabella II: BERT 58,27%, mentre il testo dice “around 0.60” (dato complessivo contro media sui fold)

# Fabio — correzioni di scrittura (verificate)

- Bibliografia doppia: [4] = [15] (Przybyła & Soto), [5] = [20] (Srba et al.)
- [30] cita “Mixtral of Experts” per Mistral 24B: è un modello diverso
- Rinvii sbagliati: “In V-B we instantiate Agg” (è V-E), “Section IV-0c”
- Tabella II: BERT 58,27%, mentre il testo dice “around 0.60” (dato complessivo contro media sui fold)
- Il contributo 4 è un **risultato**, non un contributo; i contributi 1–2 si sovrappongono a Burdisso et al. [7]

# Fabio — correzioni di scrittura (verificate)

- Bibliografia doppia: [4] = [15] (Przybyła & Soto), [5] = [20] (Srba et al.)
- [30] cita “Mixtral of Experts” per Mistral 24B: è un modello diverso
- Rinvii sbagliati: “In V-B we instantiate Agg” (è V-E), “Section IV-0c”
- Tabella II: BERT 58,27%, mentre il testo dice “around 0.60” (dato complessivo contro media sui fold)
- Il contributo 4 è un **risultato**, non un contributo; i contributi 1–2 si sovrappongono a Burdisso et al. [7]
- Dire chiaramente se il dataset è **rilasciabile** (etichette NewsGuard proprietarie)

# Esperimenti preliminari

sul primo dataset, in breve

# Il punto di partenza

- Primo dataset (quello di IrForGood): 439 testate, 19.476 articoli

# Il punto di partenza

- Primo dataset (quello di IrForGood): 439 testate, 19.476 articoli
- Prima di classificare, un controllo: le testate sono davvero **indipendenti**?

# Il punto di partenza

- Primo dataset (quello di IrForGood): 439 testate, 19.476 articoli
- Prima di classificare, un controllo: le testate sono davvero **indipendenti**?
- No: molte pubblicano lo **stesso testo** (reti di siti, catene, articoli ripresi)

# Il punto di partenza

- Primo dataset (quello di IrForGood): 439 testate, 19.476 articoli
- Prima di classificare, un controllo: le testate sono davvero **indipendenti**?
- No: molte pubblicano lo **stesso testo** (reti di siti, catene, articoli ripresi)

*Nelle prossime slide vediamo come abbiamo identificato questi insiemi di siti.*

# Ripulire il primo dataset non bastava

- **Rimozione dei duplicati e dei gruppi** dal primo dataset, e nuova classificazione

# Ripulire il primo dataset non bastava

- **Rimozione dei duplicati e dei gruppi** dal primo dataset, e nuova classificazione
- Valutata su testate **davvero nuove**: risultati **scarsi**

# Ripulire il primo dataset non bastava

- **Rimozione dei duplicati e dei gruppi** dal primo dataset, e nuova classificazione
- Valutata su testate **davvero nuove**: risultati **scarsi**
- In più, $l_1$ quasi tutto **una sola rete**: poche testate indipendenti per livello

# Ripulire il primo dataset non bastava

- **Rimozione dei duplicati e dei gruppi** dal primo dataset, e nuova classificazione
- Valutata su testate **davvero nuove**: risultati **scarsi**
- In più, $l_1$ quasi tutto **una sola rete**: poche testate indipendenti per livello
- Decisione: **creare un nuovo dataset**, più grande e vario

# Il nuovo dataset

come l'abbiamo costruito, passo per passo

# Un nuovo scraping

- **Tutte** le testate politiche in inglese di NewsGuard con un punteggio: 1.921

# Un nuovo scraping

- **Tutte** le testate politiche in inglese di NewsGuard con un punteggio: 1.921
- Scaricate in **ordine casuale** (seme fisso): se lo scraping non finisce, quelle raccolte restano un **campione non sbilanciato** (non le prime in ordine alfabetico, né per livello)

# Un nuovo scraping

- **Tutte** le testate politiche in inglese di NewsGuard con un punteggio: 1.921
- Scaricate in **ordine casuale** (seme fisso): se lo scraping non finisce, quelle raccolte restano un **campione non sbilanciato** (non le prime in ordine alfabetico, né per livello)
- La selezione **non guarda il livello** di affidabilità: il dataset si costruisce **prima** e **indipendentemente** da ciò che vogliamo predire

# Un nuovo scraping

- **Tutte** le testate politiche in inglese di NewsGuard con un punteggio: 1.921
- Scaricate in **ordine casuale** (seme fisso): se lo scraping non finisce, quelle raccolte restano un **campione non sbilanciato** (non le prime in ordine alfabetico, né per livello)
- La selezione **non guarda il livello** di affidabilità: il dataset si costruisce **prima** e **indipendentemente** da ciò che vogliamo predire

  *Così la scelta delle testate non può favorire il risultato.*

# Un nuovo scraping

- **Tutte** le testate politiche in inglese di NewsGuard con un punteggio: 1.921
- Scaricate in **ordine casuale** (seme fisso): se lo scraping non finisce, quelle raccolte restano un **campione non sbilanciato** (non le prime in ordine alfabetico, né per livello)
- La selezione **non guarda il livello** di affidabilità: il dataset si costruisce **prima** e **indipendentemente** da ciò che vogliamo predire

  *Così la scelta delle testate non può favorire il risultato.*
- Fino a 200 articoli recenti per testata + le **pagine del sito** (about, contatti, redazione, correzioni, proprietà)

# Passo 1 — trovare gli articoli gemelli

- Ogni articolo in **pezzetti di 5 parole**, numeri ignorati

# Passo 1 — trovare gli articoli gemelli

- Ogni articolo in **pezzetti di 5 parole**, numeri ignorati
- **Gemelli** = almeno metà dei pezzetti in comune (MinHash, Jaccard $\geq 0{,}5$)

# Passo 1 — trovare gli articoli gemelli

- Ogni articolo in **pezzetti di 5 parole**, numeri ignorati
- **Gemelli** = almeno metà dei pezzetti in comune (MinHash, Jaccard $\geq 0{,}5$)
- Il **24%** degli articoli ha una copia su un'altra testata

**Testata A**

"There was a single gas station in cities across **Phillips County** selling regular gas at the price of $3.09 per gallon in the week ending Mar. 15. . . "

**Testata B**

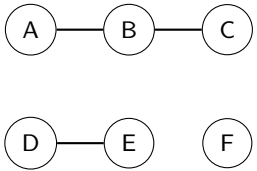
"There was a single gas station in cities across **Escambia County** selling regular gas at the lowest price of $2.65 per gallon in the week ending Mar. 15. . . "

# Passo 2 — che cosa intendiamo per “gruppo”

- Due testate **collegate** se hanno almeno **2 articoli gemelli** in comune

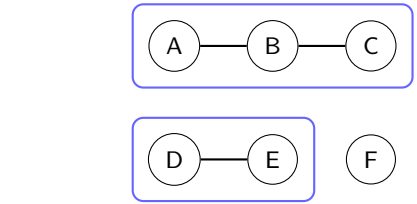
# Passo 2 — che cosa intendiamo per “gruppo”

- Due testate **collegate** se hanno almeno **2 articoli gemelli** in comune
- Un **gruppo** = testate collegate anche a catena (A–B, B–C ⇒ insieme)



# Passo 2 — che cosa intendiamo per “gruppo”

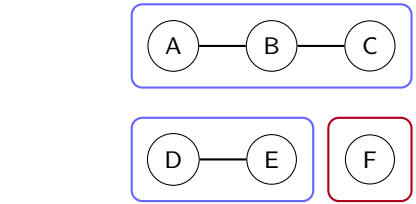
- Due testate **collegate** se hanno almeno **2 articoli gemelli** in comune
- Un **gruppo** = testate collegate anche a catena (A–B, B–C ⇒ insieme)
- Una testata senza legami è un gruppo **da sola** (indipendente)




gruppo {A,B,C}  gruppo {D,E}

# Passo 2 — che cosa intendiamo per “gruppo”

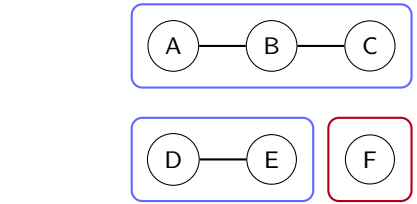
- Due testate **collegate** se hanno almeno **2 articoli gemelli** in comune
- Un **gruppo** = testate collegate anche a catena (A–B, B–C ⇒ insieme)
- Una testata senza legami è un gruppo **da sola** (indipendente)




gruppo {A,B,C}  gruppo {D,E}  {F} indipendente

# Passo 2 — che cosa intendiamo per “gruppo”

- Due testate **collegate** se hanno almeno **2 articoli gemelli** in comune
- Un **gruppo** = testate collegate anche a catena (A–B, B–C ⇒ insieme)
- Una testata senza legami è un gruppo **da sola** (indipendente)




gruppo {A,B,C} gruppo {D,E} {F} indipendente

Nel nuovo dataset: **15 gruppi** con più testate (73 testate in rete), **199 indipendenti**.

# Passo 2 — la verifica con l'"owner" di NewsGuard

- Nel dataset NewsGuard c'è un campo **"Owner"**: chi possiede ogni sito

# Passo 2 — la verifica con l'"owner" di NewsGuard

- Nel dataset NewsGuard c'è un campo **"Owner"**: chi possiede ogni sito
- È un dato che **non abbiamo usato** per costruire i gruppi (quelli nascono solo dal testo)

# Passo 2 — la verifica con l'"owner" di NewsGuard

- Nel dataset NewsGuard c'è un campo **"Owner"**: chi possiede ogni sito
- È un dato che **non abbiamo usato** per costruire i gruppi (quelli nascono solo dal testo)
- Lo usiamo per **controllarli**, con due misure sulle coppie di testate:

# Passo 2 — la verifica con l'"owner" di NewsGuard

- Nel dataset NewsGuard c'è un campo **"Owner"**: chi possiede ogni sito
- È un dato che **non abbiamo usato** per costruire i gruppi (quelli nascono solo dal testo)
- Lo usiamo per **controllarli**, con due misure sulle coppie di testate:

  – **precision**: tra le coppie che mettiamo nello **stesso gruppo**, quante hanno davvero lo stesso owner

# Passo 2 — la verifica con l'"owner" di NewsGuard

- Nel dataset NewsGuard c'è un campo **"Owner"**: chi possiede ogni sito
- È un dato che **non abbiamo usato** per costruire i gruppi (quelli nascono solo dal testo)
- Lo usiamo per **controllarli**, con due misure sulle coppie di testate:

  – **precision**: tra le coppie che mettiamo nello **stesso gruppo**, quante hanno davvero lo stesso owner

  – **recall**: tra le coppie con lo **stesso owner**, quante mettiamo nello stesso gruppo

# Passo 2 — la verifica con l'"owner" di NewsGuard

- Nel dataset NewsGuard c'è un campo **"Owner"**: chi possiede ogni sito
- È un dato che **non abbiamo usato** per costruire i gruppi (quelli nascono solo dal testo)
- Lo usiamo per **controllarli**, con due misure sulle coppie di testate:

  – **precision**: tra le coppie che mettiamo nello **stesso gruppo**, quante hanno davvero lo stesso owner

  – **recall**: tra le coppie con lo **stesso owner**, quante mettiamo nello stesso gruppo
- Risultato: precision **0,87**, recall **0,76** $\rightarrow$ i gruppi trovati dal testo coincidono quasi sempre con la **proprietà reale**

# Passo 3 — la pulizia degli articoli

1. Una sola copia per articolo **gemello** (somiglianza $\geq 0{,}9$): dei pezzi ripresi se ne tiene uno

# Passo 3 — la pulizia degli articoli

1. Una sola copia per articolo **gemello** (somiglianza $\geq 0{,}9$): dei pezzi ripresi se ne tiene uno
2. Via le copie che attraversano **gruppi diversi**

# Passo 3 — la pulizia degli articoli

1. Una sola copia per articolo **gemello** (somiglianza $\geq 0{,}9$): dei pezzi ripresi se ne tiene uno
2. Via le copie che attraversano **gruppi diversi**

   *I fold per gruppo non le coprono: le due testate sono in gruppi diversi, finirebbero una in train e una in test.*

# Passo 3 — la pulizia degli articoli

1. Una sola copia per articolo **gemello** (somiglianza $\geq 0{,}9$): dei pezzi ripresi se ne tiene uno
2. Via le copie che attraversano **gruppi diversi**

   *I fold per gruppo non le coprono: le due testate sono in gruppi diversi, finirebbero una in train e una in test.*
3. Via i **paragrafi condivisi** da più testate (template, didascalie, appelli)

# Passo 3 — la pulizia degli articoli

1. Una sola copia per articolo **gemello** (somiglianza $\geq 0{,}9$): dei pezzi ripresi se ne tiene uno
2. Via le copie che attraversano **gruppi diversi**

   *I fold per gruppo non le coprono: le due testate sono in gruppi diversi, finirebbero una in train e una in test.*
3. Via i **paragrafi condivisi** da più testate (template, didascalie, appelli)
4. Via gli articoli rimasti con **100 parole o meno**

*La pulizia tocca solo le testate con testo copiato: le **indipendenti** restano quasi intatte (99,6%).*

# Passo 3 — e come si valuta

- I **gruppi** diventano l'unità con cui si dividono i fold

# Passo 3 — e come si valuta

- I **gruppi** diventano l'unità con cui si dividono i fold
- **Fold per gruppo**: ogni gruppo tutto in un fold, nessuna testata ha **sorelle** nel training

# Passo 3 — e come si valuta

- I **gruppi** diventano l'unità con cui si dividono i fold
- **Fold per gruppo**: ogni gruppo tutto in un fold, nessuna testata ha **sorelle** nel training
- Perché pulire *e* dividere per gruppo? Coprono fughe diverse:

# Passo 3 — e come si valuta

- I **gruppi** diventano l'unità con cui si dividono i fold
- **Fold per gruppo**: ogni gruppo tutto in un fold, nessuna testata ha **sorelle** nel training
- Perché pulire *e* dividere per gruppo? Coprono fughe diverse:
  - la **pulizia** toglie il testo copiato **esplicito** (anche tra gruppi diversi)

# Passo 3 — e come si valuta

- I **gruppi** diventano l'unità con cui si dividono i fold
- **Fold per gruppo**: ogni gruppo tutto in un fold, nessuna testata ha **sorelle** nel training
- Perché pulire *e* dividere per gruppo? Coprono fughe diverse:

  – la **pulizia** toglie il testo copiato **esplicito** (anche tra gruppi diversi)

  – i **fold per gruppo** tolgono la fuga **implicita**: siti fratelli riconoscibili per stile o argomenti

# Passo 4 — anche le pagine vanno ripulite

- Problema: anche le pagine (terms, about...) sono spesso **condivise** tra testate diverse

# Passo 4 — anche le pagine vanno ripulite

- Problema: anche le pagine (terms, about. . . ) sono spesso **condivise** tra testate diverse

  *Stessa fuga delle reti: la stessa pagina in train e in test per lo stesso livello.*

# Passo 4 — anche le pagine vanno ripulite

- Problema: anche le pagine (terms, about...) sono spesso **condivise** tra testate diverse

  *Stessa fuga delle reti: la stessa pagina in train e in test per lo stesso livello.*

- Soluzione: via i tipi solo-boilerplate (terms, advertise) e via i **paragrafi condivisi**

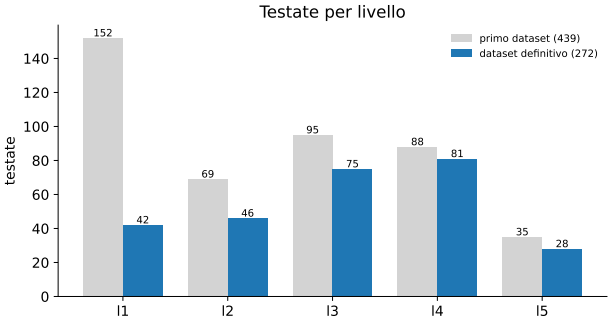
# Passo 4 — anche le pagine vanno ripulite

- Problema: anche le pagine (terms, about...) sono spesso **condivise** tra testate diverse

  *Stessa fuga delle reti: la stessa pagina in train e in test per lo stesso livello.*

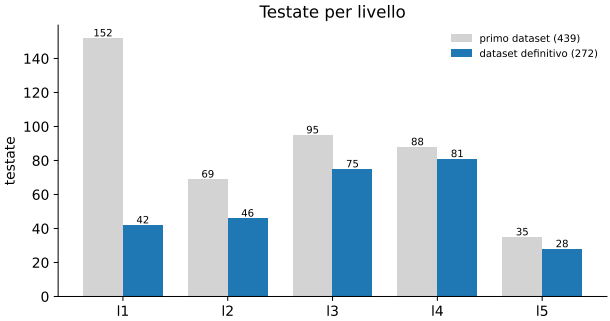
- Soluzione: via i tipi solo-boilerplate (terms, advertise) e via i **paragrafi condivisi**
- Dopo: pagine quasi uguali tra gruppi diversi da 625 a **0**

# Passo 5 — il dataset definitivo



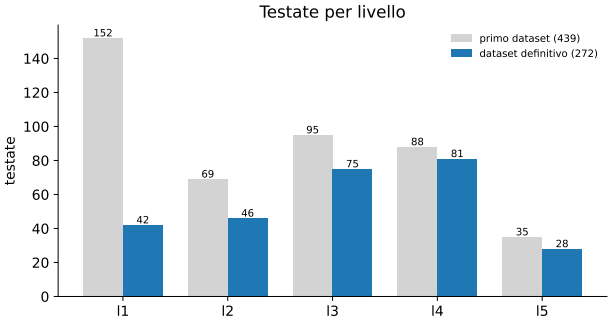

- Teniamo le testate con **almeno 20 articoli** (voto di maggioranza affidabile)

# Passo 5 — il dataset definitivo



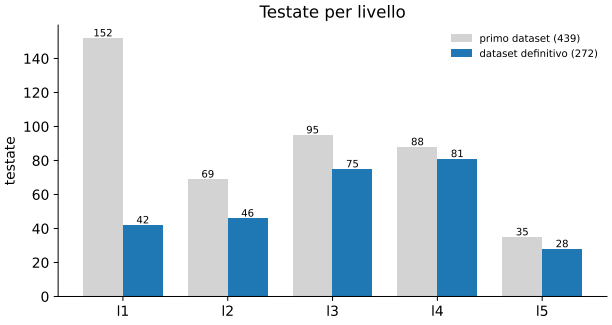

- Teniamo le testate con **almeno 20 articoli** (voto di maggioranza affidabile)
- . . . e con una **pagina about** utile

# Passo 5 — il dataset definitivo




- Teniamo le testate con **almeno 20 articoli** (voto di maggioranza affidabile)
- . . . e con una **pagina about** utile
- Risultato: **272 testate**, 44.935 articoli

# Passo 5 — il dataset definitivo




- Teniamo le testate con **almeno 20 articoli** (voto di maggioranza affidabile)
- . . . e con una **pagina about** utile
- Risultato: **272 testate**, 44.935 articoli
- $l_1$ ora è fatto di testate **indipendenti**, non di una rete

# Classificazione sul nuovo dataset

il disegno

# Due input, due letture

- Due addestramenti:

# Due input, due letture

- Due addestramenti:

  **A** — solo testo degli articoli

# Due input, due letture

- Due addestramenti:

  **A** — solo testo degli articoli

  **C** — articoli + **pagine del sito** (attaccate in coda)

# Due input, due letture

- Due addestramenti:

  **A** — solo testo degli articoli

  **C** — articoli + **pagine del sito** (attaccate in coda)

- Due letture della stessa predizione:

# Due input, due letture

- Due addestramenti:

  **A** — solo testo degli articoli

  **C** — articoli + **pagine del sito** (attaccate in coda)

- Due letture della stessa predizione:

  **per articolo** e **per testata** (voto di maggioranza)

# Due input, due letture

- Due addestramenti:

  **A** — solo testo degli articoli

  **C** — articoli + **pagine del sito** (attaccate in coda)

- Due letture della stessa predizione:

  **per articolo** e **per testata** (voto di maggioranza)

- Fold **per gruppo** (onesto) e per testata (confronto); salviamo **probabilità e loss** di tutto

# Le quattro letture

| | **per articolo** | **per testata (voto)** |
|---|---|---|
| **A** solo articoli | A-articolo | A-testata |
| **C** articoli + pagine | C-articolo | C-testata |

- Modelli: **classificatore a feature** (TF-IDF), **BERT** (confronto), **ModernBERT** (finale)

# Le quattro letture

| | **per articolo** | **per testata (voto)** |
|---|---|---|
| **A** solo articoli | A-articolo | A-testata |
| **C** articoli + pagine | C-articolo | C-testata |

- Modelli: **classificatore a feature** (TF-IDF), **BERT** (confronto), **ModernBERT** (finale)
- Domanda: quanto aggiungono le **pagine del sito** rispetto ai soli articoli?

# Risultati provvisori (un fold, valutazione per gruppo)

| **Modello** | **Input** | **art. 5 cl** | **testata 5 cl** | **testata bin.** |
|---|---|---|---|---|
| feature | A, solo articoli | 0,62 | 0,70 | 0,91 |
| | C, + pagine | **0,73** | 0,71 | **0,94** |
| ModernBERT | A, solo articoli | 0,60 | 0,65 | 0,90 |
| | C, + pagine | 0,60 | 0,59 | 0,86 |

- Le pagine **aiutano il classificatore a feature**; non ModernBERT

# Risultati provvisori (un fold, valutazione per gruppo)

| **Modello** | **Input** | **art. 5 cl** | **testata 5 cl** | **testata bin.** |
|---|---|---|---|---|
| feature | A, solo articoli | 0,62 | 0,70 | 0,91 |
| | C, + pagine | **0,73** | 0,71 | **0,94** |
| ModernBERT | A, solo articoli | 0,60 | 0,65 | 0,90 |
| | C, + pagine | 0,60 | 0,59 | 0,86 |

- Le pagine **aiutano il classificatore a feature**; non ModernBERT
- ModernBERT con le pagine va in **overfitting**: memorizza le testate del training (loss $\rightarrow 0$)

# Risultati provvisori (un fold, valutazione per gruppo)

| **Modello** | **Input** | **art. 5 cl** | **testata 5 cl** | **testata bin.** |
|---|---|---|---|---|
| feature | A, solo articoli | 0,62 | 0,70 | 0,91 |
| | C, + pagine | **0,73** | 0,71 | **0,94** |
| ModernBERT | A, solo articoli | 0,60 | 0,65 | 0,90 |
| | C, + pagine | 0,60 | 0,59 | 0,86 |

- Le pagine **aiutano il classificatore a feature**; non ModernBERT
- ModernBERT con le pagine va in **overfitting**: memorizza le testate del training (loss $\to 0$)

*Un solo fold (69 testate, molte $l_3$): numeri **direzionali**, non definitivi. In corso: tutti e 5 i fold.*