Verso Web Science 2027

Riprendere il paper bocciato: recap del lavoro e prossimi passi

Riunione di gruppo

IMT Lucca & IIT-CNR Pisa

Recap del paper bocciato

non la versione sottomessa a IR for Good

Dati

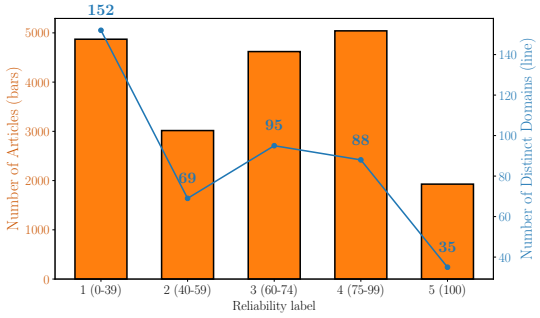
- Scraping con **newspaper3k**

Dati

- Scraping con **newspaper3k**
- 439 editori, 19.476 articoli politici in inglese

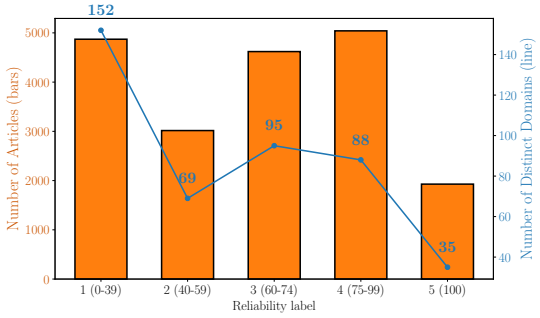
Dati

- Scraping con **newspaper3k**
- 439 editori, 19.476 articoli politici in inglese
- Etichette **NewsGuard**: 5 livelli l_1–l_5 (da 0–100)



Dati

- Scraping con **newspaper3k**
- 439 editori, 19.476 articoli politici in inglese
- Etichette **NewsGuard**: 5 livelli l_1–l_5 (da 0–100)
- Ogni articolo **eredita** l'etichetta del suo editore



Classificazione — livello articolo

- Quattro transformer: **BERT, RoBERTa, Llama, Mistral**

Classificazione — livello articolo

- Quattro transformer: **BERT, RoBERTa, Llama, Mistral**
- Encoder full fine-tuning, decoder con **LoRA**

Classificazione — livello articolo

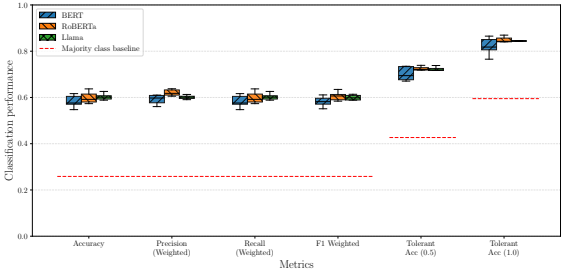
- Quattro transformer: **BERT, RoBERTa, Llama, Mistral**
- Encoder full fine-tuning, decoder con **LoRA**
- Input **256 token** (1024 per Mistral)

Classificazione — livello articolo

- Quattro transformer: **BERT, RoBERTa, Llama, Mistral**
- Encoder full fine-tuning, decoder con **LoRA**
- Input **256 token** (1024 per Mistral)
- Split **publisher-disjoint**: editori di test mai visti

Classificazione — livello articolo

- Quattro transformer: **BERT, RoBERTa, Llama, Mistral**
- Encoder full fine-tuning, decoder con **LoRA**
- Input **256 token** (1024 per Mistral)
- Split **publisher-disjoint**: editori di test mai visti



Aggregazione — livello editore

- Dall'articolo all'editore con **majority voting**

Aggregazione — livello editore

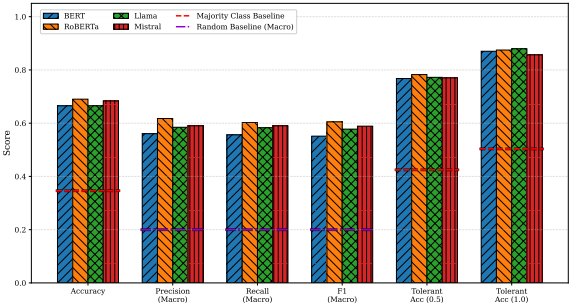
- Dall'articolo all'editore con **majority voting**
- Si usano **tutti** gli articoli della testata: nessun cap in aggregazione (fino a 200, mediana $\sim$34)

Aggregazione — livello editore

- Dall'articolo all'editore con **majority voting**
- Si usano **tutti** gli articoli della testata: nessun cap in aggregazione (fino a 200, mediana $\sim$34)
- Valutazione su editori **mai visti** in addestramento

Aggregazione — livello editore

- Dall'articolo all'editore con **majority voting**
- Si usano **tutti** gli articoli della testata: nessun cap in aggregazione (fino a 200, mediana $\sim$34)
- Valutazione su editori **mai visti** in addestramento



Perché analizziamo gli errori

- Oltre alle metriche aggregate, vogliamo capire **come** e **perché** i modelli sbagliano

Perché analizziamo gli errori

- Oltre alle metriche aggregate, vogliamo capire **come** e **perché** i modelli sbagliano

  "Beyond aggregate performance, we investigate how and why models fail."

Perché analizziamo gli errori

- Oltre alle metriche aggregate, vogliamo capire **come** e **perché** i modelli sbagliano

  "Beyond aggregate performance, we investigate how and why models fail."

- Obiettivo: trovare **debolezze strutturali** — su quali livelli sbaglia e se sovra/sottostima

Perché analizziamo gli errori

- Oltre alle metriche aggregate, vogliamo capire **come** e **perché** i modelli sbagliano

  "Beyond aggregate performance, we investigate how and why models fail."

- Obiettivo: trovare **debolezze strutturali** — su quali livelli sbaglia e se sovra/sottostima

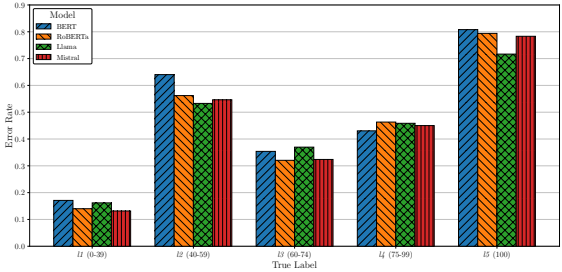
  "To detect structural weaknesses. . . "

Analisi dell'errore — per livello

- **Error rate** per ogni livello di affidabilità

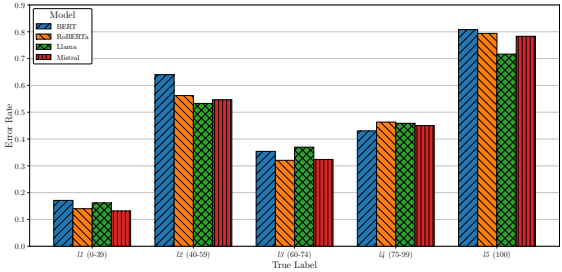
Analisi dell'errore — per livello

- **Error rate** per ogni livello di affidabilità
- l_1: errore più **basso** ($< 20\%$)



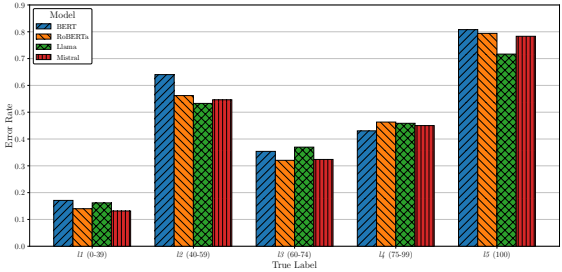
Analisi dell'errore — per livello

- **Error rate** per ogni livello di affidabilità
- l_1: errore più **basso** ($< 20\%$)
- l_5: errore più **alto** ($> 70\%$), spesso confuso con l_4



Analisi dell'errore — per livello

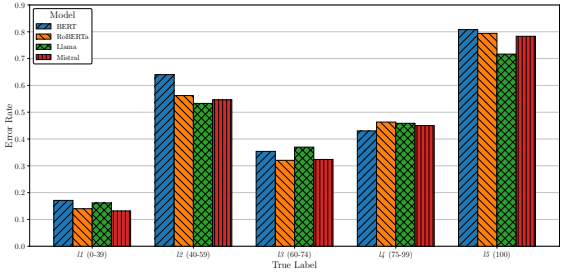
- **Error rate** per ogni livello di affidabilità
- l_1: errore più **basso** ($< 20\%$)
- l_5: errore più **alto** ($> 70\%$), spesso confuso con l_4
- l_2 sopra il 50%, l_3 intorno al 35%



Analisi dell'errore — per livello

- **Error rate** per ogni livello di affidabilità
- l_1: errore più **basso** ($< 20\%$)
- l_5: errore più **alto** ($> 70\%$), spesso confuso con l_4
- l_2 sopra il 50%, l_3 intorno al 35%

Sappiamo solo dove sbaglia di più o di meno, non perché.

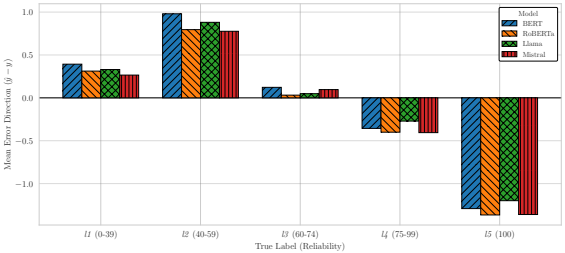


Analisi dell'errore — direzione

- **Mean Error Direction**: l'errore *sovrastima* $(+)$ o *sottostima* $(-)$ l'affidabilità

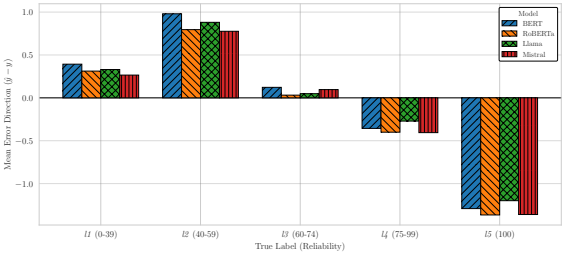
Analisi dell'errore — direzione

- **Mean Error Direction**: l'errore *sovrastima* (+) o *sottostima* (−) l'affidabilità
- Livelli **bassi sovrastimati**, livelli **alti sottostimati**



Analisi dell'errore — direzione

- **Mean Error Direction**: l'errore *sovrastima* (+) o *sottostima* (−) l'affidabilità
- Livelli **bassi sovrastimati**, livelli **alti sottostimati**
- Gli errori "tirano verso il **centro**" della scala



Perché analizziamo il bias politico

- Vogliamo sapere se il modello **tratta allo stesso modo** tutto lo spettro politico, o se **penalizza** certi orientamenti

Perché analizziamo il bias politico

- Vogliamo sapere se il modello **tratta allo stesso modo** tutto lo spettro politico, o se **penalizza** certi orientamenti

"...determine if the models exhibit political bias...whether the models treat all sides of the political spectrum equally or if they penalize specific orientations."

Perché analizziamo il bias politico

- Vogliamo sapere se il modello **tratta allo stesso modo** tutto lo spettro politico, o se **penalizza** certi orientamenti

  "...determine if the models exhibit political bias...whether the models treat all sides of the political spectrum equally or if they penalize specific orientations."

- Serve una valutazione **bias-aware**: un sistema in uso con bias politico può fare danni

Perché analizziamo il bias politico

- Vogliamo sapere se il modello **tratta allo stesso modo** tutto lo spettro politico, o se **penalizza** certi orientamenti

  "...determine if the models exhibit political bias...whether the models treat all sides of the political spectrum equally or if they penalize specific orientations."

- Serve una valutazione **bias-aware**: un sistema in uso con bias politico può fare danni

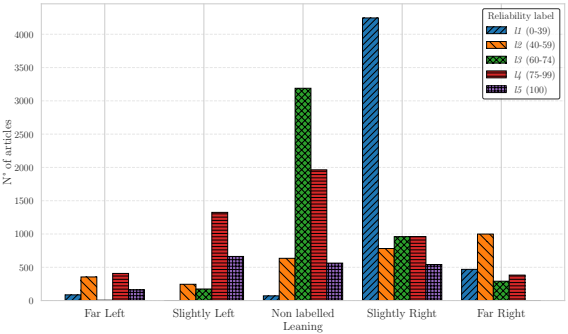
  "...the need for bias-aware evaluation protocols..."

Bias politico — distribuzione dei dati

- Orientamento ereditato dall'editore (analisi *a posteriori*)

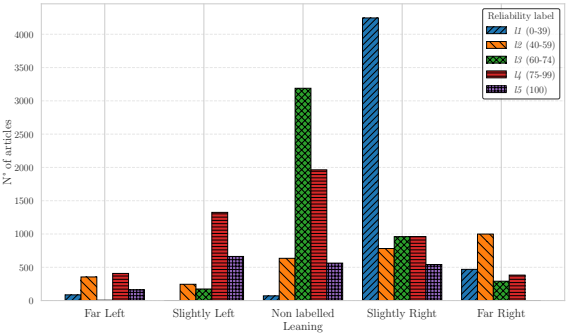
Bias politico — distribuzione dei dati

- Orientamento ereditato dall'editore (analisi *a posteriori*)
- Dentro ogni orientamento, come si distribuiscono i livelli



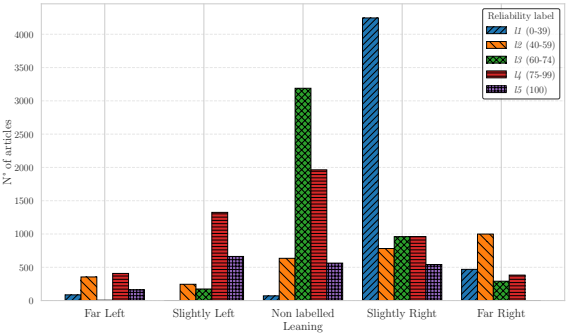
Bias politico — distribuzione dei dati

- Orientamento ereditato dall'editore (analisi *a posteriori*)
- Dentro ogni orientamento, come si distribuiscono i livelli
- Distribuzione molto **sbilanciata** (proprietà del sistema mediatico)



Bias politico — distribuzione dei dati

- Orientamento ereditato dall'editore (analisi *a posteriori*)
- Dentro ogni orientamento, come si distribuiscono i livelli
- Distribuzione molto **sbilanciata** (proprietà del sistema mediatico)
- Per questo gli error rate si calcolano **classe per classe**

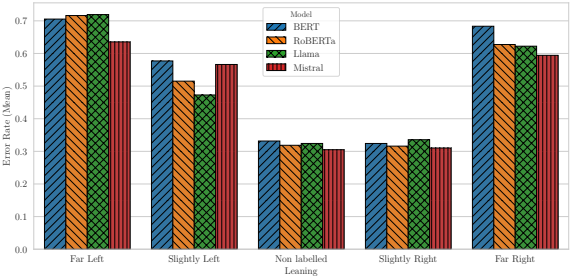


Bias politico — error rate

- **Error rate** per orientamento politico

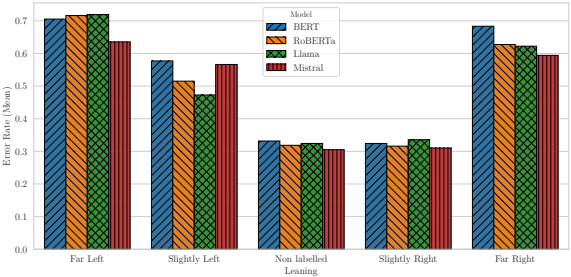
Bias politico — error rate

- **Error rate** per orientamento politico
- Gli estremi (**far left**, **far right**) sbagliano molto di più



Bias politico — error rate

- **Error rate** per orientamento politico
- Gli estremi (**far left**, **far right**) sbagliano molto di più
- Slightly right e non labelled sbagliano **meno**

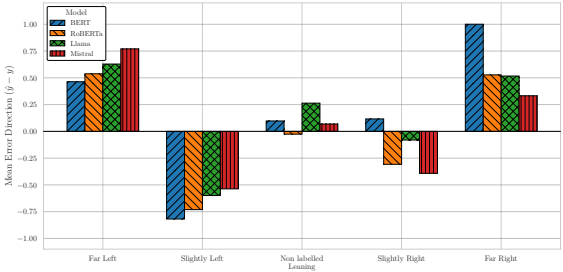


Bias politico — direzione dell'errore

- **Mean Error Direction** per orientamento

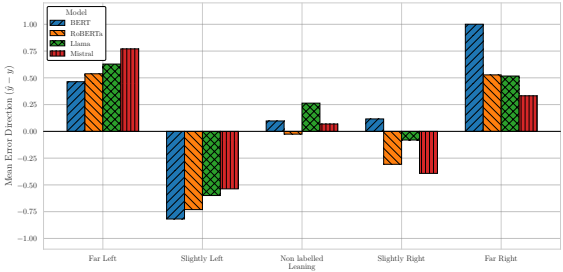
Bias politico — direzione dell'errore

- **Mean Error Direction** per orientamento
- Estremi (far left, far right) **sovrastimati**



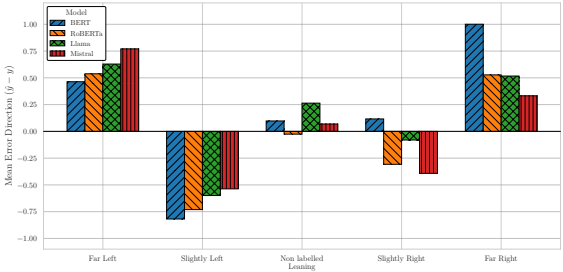
Bias politico — direzione dell'errore

- **Mean Error Direction** per orientamento
- Estremi (far left, far right) **sovrastimati**
- Slightly left **sottostimato**



Bias politico — direzione dell'errore

- **Mean Error Direction** per orientamento
- Estremi (far left, far right) **sovrastimati**
- Slightly left **sottostimato**
- Slightly right e non labelled: deviazioni piccole



È un vero legame o è un caso?

- Vediamo error rate diversi tra gli orientamenti.

È un vero legame o è un caso?

- Vediamo error rate diversi tra gli orientamenti.
- Ma potrebbe essere solo **rumore** dei dati.

È un vero legame o è un caso?

- Vediamo error rate diversi tra gli orientamenti.
- Ma potrebbe essere solo **rumore** dei dati.
- Serve un **test statistico** che dica: questo legame è reale?

È un vero legame o è un caso?

- Vediamo error rate diversi tra gli orientamenti.
- Ma potrebbe essere solo **rumore** dei dati.
- Serve un **test statistico** che dica: questo legame è reale?

Strumento usato: il **test del chi-quadro (χ^2) di indipendenza**.

Passo 1 — mettiamo gli errori in tabella

- Per ogni orientamento contiamo **giusti** e **sbagliati**

Passo 1 — mettiamo gli errori in tabella

- Per ogni orientamento contiamo **giusti** e **sbagliati**
- È la **tabella di contingenza**

Orientamento	**Giusti**	**Sbagliati**
Far Left	299	716
Slightly Left	1018	1389
Non labelled	4292	2130
Slightly Right	5062	2428
Far Right	678	1464

(esempio: BERT)

Passo 1 — mettiamo gli errori in tabella

- Per ogni orientamento contiamo **giusti** e **sbagliati**
- È la **tabella di contingenza**
- Agli estremi gli sbagliati superano i giusti

Orientamento	**Giusti**	**Sbagliati**
Far Left	299	716
Slightly Left	1018	1389
Non labelled	4292	2130
Slightly Right	5062	2428
Far Right	678	1464

(esempio: BERT)

Passo 2 — l'idea del chi-quadro

- Immaginiamo che l'orientamento **non c'entri** con gli errori.

Passo 2 — l'idea del chi-quadro

- Immaginiamo che l'orientamento **non c'entri** con gli errori.
- Allora ogni gruppo dovrebbe sbagliare **nella stessa proporzione** (circa la media, $\sim$42%).

Passo 2 — l'idea del chi-quadro

- Immaginiamo che l'orientamento **non c'entri** con gli errori.
- Allora ogni gruppo dovrebbe sbagliare **nella stessa proporzione** (circa la media, $\sim$42%).
- Il χ^2 misura **quanto** gli errori *osservati* si allontanano da questo scenario "senza legame".

Passo 2 — l'idea del chi-quadro

- Immaginiamo che l'orientamento **non c'entri** con gli errori.
- Allora ogni gruppo dovrebbe sbagliare **nella stessa proporzione** (circa la media, $\sim$42%).
- Il χ^2 misura **quanto** gli errori *osservati* si allontanano da questo scenario "senza legame".
- Più grande è lo scarto $\rightarrow$ χ^2 grande $\rightarrow$ più probabile che un legame ci sia.

Passo 2 — quanto vale il nostro χ^2

- La tabella ha 5 orientamenti $\times$ 2 esiti (giusto/sbagliato): i **gradi di libertà** sono $(5-1) \times (2-1) = \mathbf{4}$

Passo 2 — quanto vale il nostro χ^2

- La tabella ha 5 orientamenti $\times$ 2 esiti (giusto/sbagliato): i **gradi di libertà** sono $(5-1) \times (2-1) = \mathbf{4}$
- Se **non** ci fosse legame, il χ^2 varrebbe in media proprio **4** (quanto i gradi di libertà)

Passo 2 — quanto vale il nostro χ^2

- La tabella ha 5 orientamenti $\times$ 2 esiti (giusto/sbagliato): i **gradi di libertà** sono $(5-1) \times (2-1) = \mathbf{4}$
- Se **non** ci fosse legame, il χ^2 varrebbe in media proprio **4** (quanto i gradi di libertà)
- Con 4 gradi di libertà la soglia classica è **9,5**. È il valore che per puro caso si supera solo il **5% delle volte** (1 su 20)

Passo 2 — quanto vale il nostro χ^2

- La tabella ha 5 orientamenti $\times$ 2 esiti (giusto/sbagliato): i **gradi di libertà** sono $(5-1) \times (2-1) = \mathbf{4}$
- Se **non** ci fosse legame, il χ^2 varrebbe in media proprio **4** (quanto i gradi di libertà)
- Con 4 gradi di libertà la soglia classica è **9,5**. È il valore che per puro caso si supera solo il **5% delle volte** (1 su 20)
- Il nostro: **1.208–1.684**, a seconda del modello. Oltre **cento volte** la soglia

Passo 3 — il p-value

- Un χ^2 grande potrebbe capitare **per caso**?

Passo 3 — il *p*-value

- Un χ^2 grande potrebbe capitare **per caso**?
- Il ***p*-value** è la probabilità di vedere uno scarto così grande *se non ci fosse nessun legame*.

Passo 3 — il p-value

- Un χ^2 grande potrebbe capitare **per caso**?
- Il p-**value** è la probabilità di vedere uno scarto così grande *se non ci fosse nessun legame*.
- p piccolissimo (es. $p < 0.001$) $\rightarrow$ quasi impossibile che sia un caso.

Passo 3 — il p-value

- Un χ^2 grande potrebbe capitare **per caso**?
- Il p-**value** è la probabilità di vedere uno scarto così grande *se non ci fosse nessun legame*.
- p piccolissimo (es. $p < 0.001$) $\rightarrow$ quasi impossibile che sia un caso.
- Quindi il legame è **reale**, non fortuna.

Passo 4 — quanto è forte? (Cramér's V)

- Il *p*-value dice **se** c'è un legame, non **quanto** è forte.

Passo 4 — quanto è forte? (Cramér's V)

- Il *p*-value dice **se** c'è un legame, non **quanto** è forte.
- Il χ^2 cresce con il **numero di dati** (qui 19.476 articoli): con tanti dati anche un legame **piccolo** risulta "significativo".

Passo 4 — quanto è forte? (Cramér's V)

- Il *p*-value dice **se** c'è un legame, non **quanto** è forte.
- Il χ^2 cresce con il **numero di dati** (qui 19.476 articoli): con tanti dati anche un legame **piccolo** risulta "significativo".
- Serve una misura che **non** dipenda dalla quantità di dati.

Passo 4 — quanto è forte? (Cramér's V)

- Il p-value dice **se** c'è un legame, non **quanto** è forte.
- Il χ^2 cresce con il **numero di dati** (qui 19.476 articoli): con tanti dati anche un legame **piccolo** risulta "significativo".
- Serve una misura che **non** dipenda dalla quantità di dati.
- **Cramér's V** misura la **forza**: $0 =$ nessun legame, $1 =$ legame massimo.

In sintesi

- Legame **statisticamente significativo** (tutti i modelli)

In sintesi

- Legame **statisticamente significativo** (tutti i modelli)
- Forza **piccola–moderata** (V $\approx$ 0.25–0.29)

Model	χ^2	p	**V**
BERT	1684	$< 10^{-300}$	0.294
RoBERTa	1418	$< 10^{-300}$	0.270
Llama	1208	$< 10^{-250}$	0.249
Mistral	1344	$< 10^{-300}$	0.263

In sintesi

- Legame **statisticamente significativo** (tutti i modelli)
- Forza **piccola–moderata** (V $\approx$ 0.25–0.29)
- Direzione: estremi **sovrastimati**, slightly left **sottostimati**

Model	χ^2	p	**V**
BERT	1684	$< 10^{-300}$	0.294
RoBERTa	1418	$< 10^{-300}$	0.270
Llama	1208	$< 10^{-250}$	0.249
Mistral	1344	$< 10^{-300}$	0.263

Nel materiale supplementare

- Matrici di confusione per **fold** (livello articolo)

Nel materiale supplementare

- Matrici di confusione per **fold** (livello articolo)
- Matrici di confusione a **livello editore** (dopo aggregazione)

Nel materiale supplementare

- Matrici di confusione per **fold** (livello articolo)
- Matrici di confusione a **livello editore** (dopo aggregazione)
- Matrici di confusione per **orientamento politico**

Nel materiale supplementare

- Matrici di confusione per **fold** (livello articolo)
- Matrici di confusione a **livello editore** (dopo aggregazione)
- Matrici di confusione per **orientamento politico**
- **Analisi di convergenza**: curve di loss (Llama, Mistral)

Nel materiale supplementare

- Matrici di confusione per **fold** (livello articolo)
- Matrici di confusione a **livello editore** (dopo aggregazione)
- Matrici di confusione per **orientamento politico**
- **Analisi di convergenza**: curve di loss (Llama, Mistral)

Dettagli a supporto delle analisi del paper, non nuovi risultati.

Le review dei revisori

quali critiche affrontare

Revisore 1 — (1) Novità metodologica limitata

English

"The two-stage framework is essentially standard fine-tuning of pretrained language models followed by majority voting. The main contribution seems to be the task formulation, dataset construction, and evaluation setup, rather than a new model architecture, learning objective, or aggregation method."

Revisore 1 — (1) Novità metodologica limitata

English

"The two-stage framework is essentially standard fine-tuning of pretrained language models followed by majority voting. The main contribution seems to be the task formulation, dataset construction, and evaluation setup, rather than a new model architecture, learning objective, or aggregation method."

Commento di John

Con gli esperimenti nuovi che faremo questo punto si dovrebbe addressare.

Revisore 1 — (2) Il guadagno dell'aggregazione non è misurato pulito

English

"The comparison between the article-level score ($\sim$0.60) and the publisher-level score ($\sim$0.69) changes both the evaluation unit and the weighting of publishers. As a result, the improvement cannot be attributed to aggregation alone."

Revisore 1 — (2) Il guadagno dell'aggregazione non è misurato pulito

English

"The comparison between the article-level score (∼0.60) and the publisher-level score (∼0.69) changes both the evaluation unit and the weighting of publishers. As a result, the improvement cannot be attributed to aggregation alone."

Commento di John

Questa non l'ho capita. Forse dovremmo spiegare meglio perché aggregare ha senso? Forse ha senso solo aggregare, e non andrebbe fatta la valutazione per singolo articolo?

Revisore 1 — (3) Bias confuso con il livello di affidabilità

English

"The distribution of reliability labels differs substantially across political leanings, and some reliability levels are clearly more difficult to classify than others. The relationship between political leaning and prediction error should therefore be tested again after controlling for the true reliability level."

Revisore 1 — (3) Bias confuso con il livello di affidabilità

English

"The distribution of reliability labels differs substantially across political leanings, and some reliability levels are clearly more difficult to classify than others. The relationship between political leaning and prediction error should therefore be tested again after controlling for the true reliability level."

Commento di John

Di questa ne parliamo dopo in modo approfondito. Comunque non ha senso dire che alcune label sono più difficili da classificare di altre: non ci sono i dati per dirlo.

Revisore 1 — (4) Il chi-quadro ignora il clustering

English

"Political leaning and reliability are publisher-level attributes shared by multiple articles from the same publisher. Using all articles as independent observations may lead to pseudo-replication and overstate the effective sample size and significance of the results."

Revisore 1 — (5) Indizi dell'editore e artefatti non esclusi

English

"The paper does not include systematic text cleaning, source-identifier masking, or sanitized-text ablations. It is therefore difficult to tell whether the model is learning reliability-related content or simply exploiting publisher-specific signals and scraping artifacts."

Revisore 1 — (5) Indizi dell'editore e artefatti non esclusi

English

"The paper does not include systematic text cleaning, source-identifier masking, or sanitized-text ablations. It is therefore difficult to tell whether the model is learning reliability-related content or simply exploiting publisher-specific signals and scraping artifacts."

Commento di John

Anche questa la vediamo più avanti.

Revisore 1 — (6) Possibile bias di selezione nello scraping

English

"Only 439 of the 669 candidate publishers were included in the final dataset, and the scraping success rates differ across reliability levels. The paper does not examine whether the publishers that were successfully scraped differ systematically from those that were not."

Revisore 1 — (6) Possibile bias di selezione nello scraping

English

"Only 439 of the 669 candidate publishers were included in the final dataset, and the scraping success rates differ across reliability levels. The paper does not examine whether the publishers that were successfully scraped differ systematically from those that were not."

Commento di John

Non so se questa ha senso.

Revisore 1 — (7) Confronto sulla taglia del modello non controllato

English

"The models differ in architecture, fine-tuning strategy, training schedule, and context length, in addition to parameter count. The observed performance differences therefore cannot be attributed to model size alone."

Revisore 1 — (7) Confronto sulla taglia del modello non controllato

English

"The models differ in architecture, fine-tuning strategy, training schedule, and context length, in addition to parameter count. The observed performance differences therefore cannot be attributed to model size alone."

Commento di John

Ma praticamente non ci sono differenze di performance tra i vari modelli.

Revisore 1 — (8) Nessuna stima di incertezza

English

"Differences such as 0.69 versus 0.68 are small, but the paper does not report confidence intervals, bootstrap results, or paired significance tests. It is therefore unclear whether these differences are meaningful."

Revisore 1 — (8) Nessuna stima di incertezza

English

"Differences such as 0.69 versus 0.68 are small, but the paper does not report confidence intervals, bootstrap results, or paired significance tests. It is therefore unclear whether these differences are meaningful."

Commento di Claude

- **Bootstrap** (per dare un margine al numero). Il modello è addestrato **una volta sola**: sappiamo già quali delle 439 testate sono giuste o sbagliate. Si **rimescolano le 439 testate con ripetizione** (un campione casuale che può ripetere alcune testate e saltarne altre) e si **ricalcola l'accuracy** — niente nuovo addestramento, solo un nuovo conteggio. Ripetendolo migliaia di volte, la dispersione dei valori dà un **intervallo di confidenza**: "0,69" diventa es. 0,65–0,73.
- **Test appaiato** (per confrontare due modelli). Si guardano le *stesse* testate e contano solo quelle dove i due **non sono d'accordo** (uno giusto, l'altro sbagliato): il test di McNemar dice se 0,69 contro 0,68 è una differenza **vera** o solo fortuna.
- Nel paper bocciato mancano entrambi: critica giusta e veloce da risolvere. Su 439 testate, 0,69 contro 0,68 è circa 4 testate di differenza.

Revisore 2 — (1) Motivazione debole del passaggio a livello editore

English

"publisher reliability is, by construction, obtained as a fixed aggregation of article-level outputs. . . the re-formulation does not introduce substantial new insight beyond a change in the unit of evaluation."

Revisore 2 — (1) Motivazione debole del passaggio a livello editore

English

"publisher reliability is, by construction, obtained as a fixed aggregation of article-level outputs. . . the re-formulation does not introduce substantial new insight beyond a change in the unit of evaluation."

Commento di John

Non so che dire.

Revisore 2 — (2) Mancano confronti con altri scorer

English

"Publisher-level scores can equally be produced by first scoring individual articles with a model pretrained specifically for article-level reliability classification, or with a general-purpose LLM such as Qwen, and then applying the same voting strategy. . . No such comparison is reported."

Revisore 2 — (2) Mancano confronti con altri scorer

English

"Publisher-level scores can equally be produced by first scoring individual articles with a model pretrained specifically for article-level reliability classification, or with a general-purpose LLM such as Qwen, and then applying the same voting strategy. . . No such comparison is reported."

Commento di John

Anche qui non so che dire: non ho capito cosa c'entra Qwen.

Revisore 2 — (2) Mancano confronti con altri scorer

English

"Publisher-level scores can equally be produced by first scoring individual articles with a model pretrained specifically for article-level reliability classification, or with a general-purpose LLM such as Qwen, and then applying the same voting strategy. . . No such comparison is reported."

Commento di John

Anche qui non so che dire: non ho capito cosa c'entra Qwen.

Commento di Claude

Il nostro schema è "voto a ogni articolo, poi maggioranza". Il revisore nota che il voto per articolo potrebbe darlo anche un modello *già esistente* per l'affidabilità degli articoli, o un *LLM generalista* interrogato direttamente. Qwen è solo un esempio di LLM open-source. Vuole sapere se i nostri modelli battono queste alternative "pronte": è vicino all'esperimento con e senza nomi proposto da Fabio.

Revisore 2 — (3) Il dataset non è “large-scale”

English

“Although the corpus contains 19,476 articles, the objective of the paper is scoring at the level of the publisher, and the dataset comprises only 439 publishers. The dataset is therefore unlikely to support effective use in real-world applications.”

Revisore 2 — (3) Il dataset non è “large-scale”

English

“Although the corpus contains 19,476 articles, the objective of the paper is scoring at the level of the publisher, and the dataset comprises only 439 publishers. The dataset is therefore unlikely to support effective use in real-world applications.”

Commento di John

Secondo me invece i dati sono sufficienti.

Revisore 2 — (3) Il dataset non è “large-scale”

English

“Although the corpus contains 19,476 articles, the objective of the paper is scoring at the level of the publisher, and the dataset comprises only 439 publishers. The dataset is therefore unlikely to support effective use in real-world applications.”

Commento di John

Secondo me invece i dati sono sufficienti.

Commento di Claude

In parte d’accordo con John: 439 testate bastano per misurare le prestazioni, se riportiamo gli intervalli di confidenza. Ma il revisore ha ragione su un punto: l’unità del compito è la testata, quindi il campione vero è 439, non 19.476 (lo conferma anche l’ICC). “Large-scale” è la parola sbagliata: basta toglierla. Che i dati non bastino per un uso reale è un’affermazione del revisore, non dimostrata.

Oltre le review: due analisi

Marinella con ChatGPT · Fabio con Claude

Due analisi di supporto

- Oltre ai due revisori del journal, due analisi del paper fatte con strumenti AI

Due analisi di supporto

- Oltre ai due revisori del journal, due analisi del paper fatte con strumenti AI
- **Marinella** con **ChatGPT** — focalizzata sulla statistica del bias

Due analisi di supporto

- Oltre ai due revisori del journal, due analisi del paper fatte con strumenti AI
- **Marinella** con **ChatGPT** — focalizzata sulla statistica del bias
- **Fabio** con **Claude** — review completa + analisi quantitativa del bias

Due analisi di supporto

- Oltre ai due revisori del journal, due analisi del paper fatte con strumenti AI
- **Marinella** con **ChatGPT** — focalizzata sulla statistica del bias
- **Fabio** con **Claude** — review completa + analisi quantitativa del bias
- Fatte in modo **indipendente**: le riassumiamo qui, così le conosciamo tutti

Marinella × ChatGPT — cos'è

- Marinella ha dato a ChatGPT la **parte statistica** del bias e gli ha chiesto di controllarla

Marinella × ChatGPT — cos'è

- Marinella ha dato a ChatGPT la **parte statistica** del bias e gli ha chiesto di controllarla
- Ha trovato una serie di **problemi**: li vediamo uno a uno, in modo semplice

Marinella × ChatGPT — cos'è

- Marinella ha dato a ChatGPT la **parte statistica** del bias e gli ha chiesto di controllarla
- Ha trovato una serie di **problemi**: li vediamo uno a uno, in modo semplice
- Tutti ruotano attorno a una domanda: **possiamo davvero dire che c'è un bias politico?**

Problema 1 — il χ^2 conta troppo

- La domanda del test: l'errore del modello dipende dall'**orientamento politico**?

Problema 1 — il χ^2 conta troppo

- La domanda del test: l'errore del modello dipende dall'**orientamento politico**?
- Nel paper viene calcolato contando i **singoli articoli**: 19.476 "prove"

Problema 1 — il χ^2 conta troppo

- La domanda del test: l'errore del modello dipende dall'**orientamento politico**?
- Nel paper viene calcolato contando i **singoli articoli**: 19.476 "prove"
- Ma l'orientamento è **fisso per testata**: tutti gli articoli di una testata hanno lo stesso orientamento

Problema 1 — il χ^2 conta troppo

- La domanda del test: l'errore del modello dipende dall'**orientamento politico**?
- Nel paper viene calcolato contando i **singoli articoli**: 19.476 "prove"
- Ma l'orientamento è **fisso per testata**: tutti gli articoli di una testata hanno lo stesso orientamento
- Quindi gli articoli di una stessa testata **non sono prove indipendenti**

Problema 1 — l'esempio

- Una testata di destra, 200 articoli, tutti affidabilità l_4

Problema 1 — l'esempio

- Una testata di destra, 200 articoli, tutti affidabilità l_4
- Il modello la trova difficile $\rightarrow$ sbaglia quasi tutti: 200 errori "di destra"

Problema 1 — l'esempio

- Una testata di destra, 200 articoli, tutti affidabilità l_4
- Il modello la trova difficile $\rightarrow$ sbaglia quasi tutti: 200 errori "di destra"
- Il test li legge come **200 prove** che "destra $\rightarrow$ errore"

Problema 1 — l'esempio

- Una testata di destra, 200 articoli, tutti affidabilità l_4
- Il modello la trova difficile $\rightarrow$ sbaglia quasi tutti: 200 errori "di destra"
- Il test li legge come **200 prove** che "destra $\rightarrow$ errore"
- Ma è **una** testata difficile, non 200 fatti diversi

Problema 1 — l'esempio

- Una testata di destra, 200 articoli, tutti affidabilità l_4
- Il modello la trova difficile $\rightarrow$ sbaglia quasi tutti: 200 errori "di destra"
- Il test li legge come **200 prove** che "destra $\rightarrow$ errore"
- Ma è **una** testata difficile, non 200 fatti diversi
- Le prove vere sono le **testate** (439), non gli articoli (19.476): più il campione è (finto) grande, più ogni differenza sembra "significativa"

Problema 1 — l'esempio

- Una testata di destra, 200 articoli, tutti affidabilità l_4
- Il modello la trova difficile $\rightarrow$ sbaglia quasi tutti: 200 errori "di destra"
- Il test li legge come **200 prove** che "destra $\rightarrow$ errore"
- Ma è **una** testata difficile, non 200 fatti diversi
- Le prove vere sono le **testate** (439), non gli articoli (19.476): più il campione è (finto) grande, più ogni differenza sembra "significativa"
- Soluzione: un conteggio **per testata** con il majority voting

Osservazione di John — ma è vero?

- La critica regge solo se gli errori **sono consistenti** dentro la stessa testata

Osservazione di John — ma è vero?

- La critica regge solo se gli errori **sono consistenti** dentro la stessa testata
- Se il modello facesse **un po' giusti e un po' sbagliati a caso**, ogni articolo sarebbe una prova nuova: contarli tutti sarebbe giusto

Osservazione di John — ma è vero?

- La critica regge solo se gli errori **sono consistenti** dentro la stessa testata
- Se il modello facesse **un po' giusti e un po' sbagliati a caso**, ogni articolo sarebbe una prova nuova: contarli tutti sarebbe giusto
- Se invece **azzecca (o sbaglia) quasi tutta** la testata insieme, i suoi articoli dicono **la stessa cosa**: contarli tutti è come **ripetere la stessa prova**

Osservazione di John — ma è vero?

- La critica regge solo se gli errori **sono consistenti** dentro la stessa testata
- Se il modello facesse **un po' giusti e un po' sbagliati a caso**, ogni articolo sarebbe una prova nuova: contarli tutti sarebbe giusto
- Se invece **azzecca (o sbaglia) quasi tutta** la testata insieme, i suoi articoli dicono **la stessa cosa**: contarli tutti è come **ripetere la stessa prova**
- La domanda: quando sbaglia su una testata, sbaglia su **quasi tutti** i suoi articoli? Lo misuriamo.

Cos'è l'ICC — l'idea

- Per ogni testata guardiamo: che **quota di articoli** sbaglia il modello?

Cos'è l'ICC — l'idea

- Per ogni testata guardiamo: che **quota di articoli** sbaglia il modello?
- Se sbagliasse **a caso** dentro la testata, ogni testata starebbe vicino alla **media** ($\sim$42%)

Cos'è l'ICC — l'idea

- Per ogni testata guardiamo: che **quota di articoli** sbaglia il modello?
- Se sbagliasse **a caso** dentro la testata, ogni testata starebbe vicino alla **media** ($\sim$42%)
- L'ICC dice quanto invece le testate si **spaccano** tra "quasi tutte giuste" e "quasi tutte sbagliate"

Cos'è l'ICC — l'idea

- Per ogni testata guardiamo: che **quota di articoli** sbaglia il modello?
- Se sbagliasse **a caso** dentro la testata, ogni testata starebbe vicino alla **media** ($\sim$42%)
- L'ICC dice quanto invece le testate si **spaccano** tra "quasi tutte giuste" e "quasi tutte sbagliate"
- **0** = tutte vicine alla media (nessuna correlazione) **1** = ognuna a un estremo

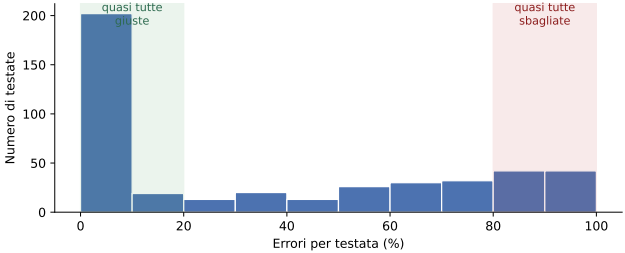
Osservazione di John — cosa troviamo

- Su **439 testate**:

Osservazione di John — cosa troviamo

- Su **439 testate**:

  221 quasi tutte giuste

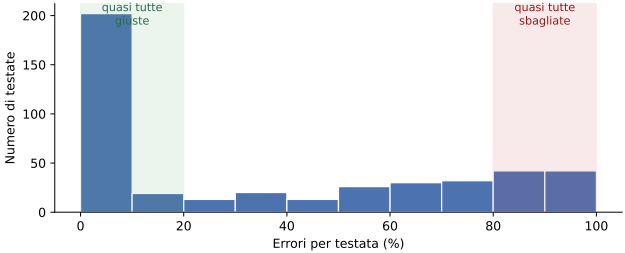


Osservazione di John — cosa troviamo

- Su **439 testate**:

  221 quasi tutte giuste

  84 quasi tutte sbagliate



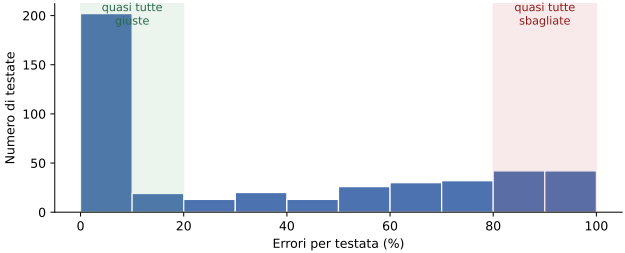
Osservazione di John — cosa troviamo

- Su **439 testate**:

  221 quasi tutte giuste

  84 quasi tutte sbagliate

  solo 134 “a metà”



Osservazione di John — cosa troviamo

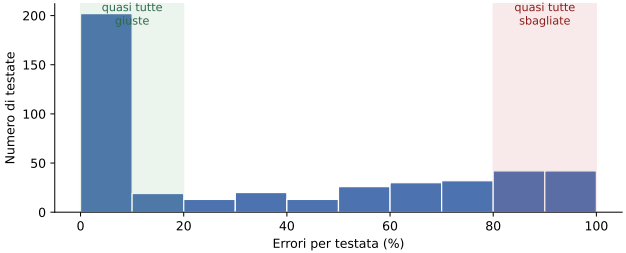
- Su **439 testate**:

  221 quasi tutte giuste

  84 quasi tutte sbagliate

  solo 134 “a metà”

- L’esito lo decide quasi la **testata**, non il singolo articolo



Osservazione di John — cosa troviamo

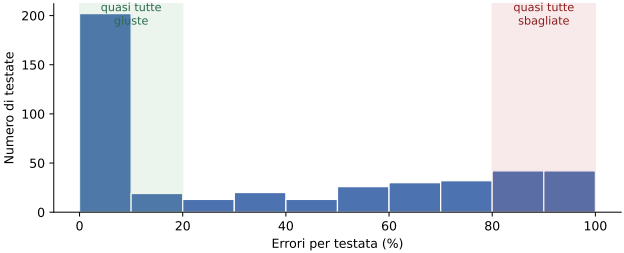
- Su **439 testate**:

  221 quasi tutte giuste

  84 quasi tutte sbagliate

  solo 134 “a metà”

- L’esito lo decide quasi la **testata**, non il singolo articolo
- Riassunto in un numero: ICC $\approx 0{,}6$ (come leggerlo: slide successiva)



Osservazione di John — come leggere 0,6

- Prova: **rimescoliamo a caso** gli errori tra le testate (tenendo fisso il livello), così la testata non può più contare

Osservazione di John — come leggere 0,6

- Prova: **rimescoliamo a caso** gli errori tra le testate (tenendo fisso il livello), così la testata non può più contare
- In questo mondo "a caso" l'ICC viene circa **0,14**

Osservazione di John — come leggere 0,6

- Prova: **rimescoliamo a caso** gli errori tra le testate (tenendo fisso il livello), così la testata non può più contare
- In questo mondo "a caso" l'ICC viene circa **0,14**
- L'abbiamo rifatto 100 volte: non è **mai** andato oltre $\sim$0,17

Osservazione di John — come leggere 0,6

- Prova: **rimescoliamo a caso** gli errori tra le testate (tenendo fisso il livello), così la testata non può più contare
- In questo mondo "a caso" l'ICC viene circa **0,14**
- L'abbiamo rifatto 100 volte: non è **mai** andato oltre $\sim$0,17
- Il nostro è **0,6**: più di 4 volte tanto

Osservazione di John — come leggere 0,6

- Prova: **rimescoliamo a caso** gli errori tra le testate (tenendo fisso il livello), così la testata non può più contare
- In questo mondo "a caso" l'ICC viene circa **0,14**
- L'abbiamo rifatto 100 volte: non è **mai** andato oltre $\sim$0,17
- Il nostro è **0,6**: più di 4 volte tanto
- Quindi il risultato **non è casuale**: gli errori si concentrano davvero in alcune testate

Osservazione di John — la conclusione

- Gli articoli di una testata **non sono prove indipendenti**

Osservazione di John — la conclusione

- Gli articoli di una testata **non sono prove indipendenti**
- Quindi l'unità giusta per il test sono le **439 testate**, non i 19.476 articoli

Osservazione di John — la conclusione

- Gli articoli di una testata **non sono prove indipendenti**
- Quindi l'unità giusta per il test sono le **439 testate**, non i 19.476 articoli

E vale anche a parità di livello: non è solo perché su l_5 il modello sbaglia di più.

Osservazione di John — la conclusione

- Gli articoli di una testata **non sono prove indipendenti**
- Quindi l'unità giusta per il test sono le **439 testate**, non i 19.476 articoli

  E vale anche a parità di livello: non è solo perché su l_5 il modello sbaglia di più.
- La correzione è semplice: fare il test **per testata**

Osservazione di John — come si fa il test per testata

- Per ogni testata, il **voto di maggioranza** dei suoi articoli dà **un solo giudizio**

Osservazione di John — come si fa il test per testata

- Per ogni testata, il **voto di maggioranza** dei suoi articoli dà **un solo giudizio**

  Es.: una testata di livello 1 con 9 articoli: 7 predetti l_2, 1 l_5, 1 l_1 $\rightarrow$ voto l_2 $\rightarrow$ testata sbagliata.

Osservazione di John — come si fa il test per testata

- Per ogni testata, il **voto di maggioranza** dei suoi articoli dà **un solo giudizio**

  Es.: una testata di livello 1 con 9 articoli: 7 predetti l_2, 1 l_5, 1 l_1 $\rightarrow$ voto l_2 $\rightarrow$ testata sbagliata.

- Ogni testata conta **una volta sola**: giusta o sbagliata

Osservazione di John — come si fa il test per testata

- Per ogni testata, il **voto di maggioranza** dei suoi articoli dà **un solo giudizio**

  Es.: una testata di livello 1 con 9 articoli: 7 predetti l_2, 1 l_5, 1 l_1 $\rightarrow$ voto l_2 $\rightarrow$ testata sbagliata.

- Ogni testata conta **una volta sola**: giusta o sbagliata
- Si rifà la stessa tabella di prima (orientamento $\times$ giusta/sbagliata), ma con **439 testate** invece di 19.476 articoli

Osservazione di John — il test per testata: il risultato

- χ^2 per testata: **18,8** (contro 1.418 per articolo)

Osservazione di John — il test per testata: il risultato

- χ^2 per testata: **18,8** (contro 1.418 per articolo)
- Ancora sopra la soglia di 9,5: il legame **resta**...

RoBERTa, una riga per orientamento

Orientamento	**Giuste**	**Sbagliate**
Far Left	9	11
Slightly Left	29	21
Non labelled	81	29
Slightly Right	156	51
Far Right	28	24

Osservazione di John — il test per testata: il risultato

- χ^2 per testata: **18,8** (contro 1.418 per articolo)
- Ancora sopra la soglia di 9,5: il legame **resta**...
- ...ma è molto meno "clamoroso"

RoBERTa, una riga per orientamento

Orientamento	**Giuste**	**Sbagliate**
Far Left	9	11
Slightly Left	29	21
Non labelled	81	29
Slightly Right	156	51
Far Right	28	24

Osservazione di John — il test per testata: il risultato

- χ^2 per testata: **18,8** (contro 1.418 per articolo)
- Ancora sopra la soglia di 9,5: il legame **resta**...
- ...ma è molto meno "clamoroso"

Esempio con RoBERTa; gli altri modelli danno da 19 a 45.

RoBERTa, una riga per orientamento

Orientamento	**Giuste**	**Sbagliate**
Far Left	9	11
Slightly Left	29	21
Non labelled	81	29
Slightly Right	156	51
Far Right	28	24

Problema 2 — cosa dice ChatGPT

- Nel paper l'errore è calcolato **separatamente per ogni orientamento**

Problema 2 — cosa dice ChatGPT

- Nel paper l'errore è calcolato **separatamente per ogni orientamento**
- E si afferma che così è "**indipendente dalla frequenza delle classi**"

Problema 2 — cosa dice ChatGPT

- Nel paper l'errore è calcolato **separatamente per ogni orientamento**
- E si afferma che così è "**indipendente dalla frequenza delle classi**"
- In altre parole: calcolarlo separatamente dovrebbe renderlo **non influenzato** da come sono distribuiti i dati

Problema 2 — cosa dice ChatGPT

- Nel paper l'errore è calcolato **separatamente per ogni orientamento**
- E si afferma che così è "**indipendente dalla frequenza delle classi**"
- In altre parole: calcolarlo separatamente dovrebbe renderlo **non influenzato** da come sono distribuiti i dati
- ChatGPT fa notare: è vero **solo a metà**

Problema 2 — perché solo a metà

- Calcolarlo separatamente toglie l'effetto della **dimensione** del gruppo (quanti articoli ha)

Problema 2 — perché solo a metà

- Calcolarlo separatamente toglie l'effetto della **dimensione** del gruppo (quanti articoli ha)
- Ma **non** toglie l'effetto di **quali livelli** ci sono dentro

Problema 2 — perché solo a metà

- Calcolarlo separatamente toglie l'effetto della **dimensione** del gruppo (quanti articoli ha)
- Ma **non** toglie l'effetto di **quali livelli** ci sono dentro
- E il livello pesa tanto: l_1 facile, l_5 difficile

Problema 2 — perché solo a metà

- Calcolarlo separatamente toglie l'effetto della **dimensione** del gruppo (quanti articoli ha)
- Ma **non** toglie l'effetto di **quali livelli** ci sono dentro
- E il livello pesa tanto: l_1 facile, l_5 difficile
- Ogni orientamento ha un **mix di livelli diverso**

Problema 2 — l'esempio

- Slightly Right è quasi tutto I_1 (il livello facile)

Problema 2 — l'esempio

- Slightly Right è quasi tutto l_1 (il livello facile)
- Quindi il suo errore basso dipende dal fatto che è **pieno di articoli facili**...

Problema 2 — l'esempio

- Slightly Right è quasi tutto l_1 (il livello facile)
- Quindi il suo errore basso dipende dal fatto che è **pieno di articoli facili**...

  ...non dal fatto che il modello "tratti meglio" la destra.

Problema 2 — l'esempio

- Slightly Right è quasi tutto l_1 (il livello facile)
- Quindi il suo errore basso dipende dal fatto che è **pieno di articoli facili**...

  ...non dal fatto che il modello "tratti meglio" la destra.
- Conclusione: la frase va riscritta — l'errore per orientamento **dipende ancora** dalla composizione dei livelli

Problema 2 — commento di John

- ChatGPT dà per scontato che i livelli abbiano **difficoltà diverse**

Problema 2 — commento di John

- ChatGPT dà per scontato che i livelli abbiano **difficoltà diverse**
- Ma questa cosa **non è mai dimostrata**

Problema 2 — commento di John

- ChatGPT dà per scontato che i livelli abbiano **difficoltà diverse**
- Ma questa cosa **non è mai dimostrata**
- Il modello sbaglia meno su l_1 — ma "**sbaglia meno**" non vuol dire "**è più facile**"

Problema 2 — commento di John

- ChatGPT dà per scontato che i livelli abbiano **difficoltà diverse**
- Ma questa cosa **non è mai dimostrata**
- Il modello sbaglia meno su l_1 — ma "**sbaglia meno**" non vuol dire "**è più facile**"

  Potrebbe sbagliare meno per tanti altri motivi: orientamento, tema, com'è fatto il dataset.

Problema 2 — commento di John

- ChatGPT dà per scontato che i livelli abbiano **difficoltà diverse**
- Ma questa cosa **non è mai dimostrata**
- Il modello sbaglia meno su l_1 — ma "**sbaglia meno**" non vuol dire "**è più facile**"

  Potrebbe sbagliare meno per tanti altri motivi: orientamento, tema, com'è fatto il dataset.
- Non ha senso dire che l_1 è più facile di l_2 solo perché il modello **sbaglia meno**

Problema 3 — orientamento e affidabilità sono “incollati”

- Non solo intrecciati: in alcune combinazioni i dati **mancano del tutto**

Problema 3 — orientamento e affidabilità sono “incollati”

- Non solo intrecciati: in alcune combinazioni i dati **mancano del tutto**
- Nessuna testata far-right è in l_5; 142 su 207 slightly-right sono in l_1

Problema 3 — orientamento e affidabilità sono “incollati”

- Non solo intrecciati: in alcune combinazioni i dati **mancano del tutto**
- Nessuna testata far-right è in I_5; 142 su 207 slightly-right sono in I_1
- Quando due variabili sono così sovrapposte, **nessuna analisi** può separarle del tutto

Problema 4 — il χ^2 ha bisogno di abbastanza dati

- Il χ^2 confronta, in ogni casella, quello che **osserva** con quello che **si aspetterebbe**

Problema 4 — il χ^2 ha bisogno di abbastanza dati

- Il χ^2 confronta, in ogni casella, quello che **osserva** con quello che **si aspetterebbe**
- Funziona solo se in ogni casella ci sono **abbastanza osservazioni** (regola pratica: almeno $\sim$5 attese)

Problema 4 — il χ^2 ha bisogno di abbastanza dati

- Il χ^2 confronta, in ogni casella, quello che **osserva** con quello che **si aspetterebbe**
- Funziona solo se in ogni casella ci sono **abbastanza osservazioni** (regola pratica: almeno $\sim$5 attese)
- Con poche testate, alcune caselle sono quasi **vuote**

Problema 4 — nel nostro caso

- Testate divise in 5 orientamenti: **Far Left ne ha solo 20**

Problema 4 — nel nostro caso

- Testate divise in 5 orientamenti: **Far Left ne ha solo 20**
- Nella casella "Far Left sbagliate" ne aspettiamo appena **6,2**: proprio al limite (perché: slide successive)

Test per testata, RoBERTa

		Sbagliate	
Orientamento	**Testate**	**osservate**	**attese**
Far Left	20	11	**6,2**
Slightly Left	50	21	15,5
Non labelled	110	29	34,1
Slightly Right	207	51	64,1
Far Right	52	24	16,1

Problema 4 — nel nostro caso

- Testate divise in 5 orientamenti: **Far Left ne ha solo 20**
- Nella casella "Far Left sbagliate" ne aspettiamo appena **6,2**: proprio al limite (perché: slide successive)
- E guardando orientamento *e* livello insieme, alcune caselle sono **vuote**: nessuna far-right di livello 5, nessuna slightly-left di livello 1

Test per testata, RoBERTa

		Sbagliate	
Orientamento	**Testate**	**osservate**	**attese**
Far Left	20	11	**6,2**
Slightly Left	50	21	15,5
Non labelled	110	29	34,1
Slightly Right	207	51	64,1
Far Right	52	24	16,1

Problema 4 — nel nostro caso

- Testate divise in 5 orientamenti: **Far Left ne ha solo 20**
- Nella casella "Far Left sbagliate" ne aspettiamo appena **6,2**: proprio al limite (perché: slide successive)
- E guardando orientamento *e* livello insieme, alcune caselle sono **vuote**: nessuna far-right di livello 5, nessuna slightly-left di livello 1

Lì il χ^2 non ha più senso.

Test per testata, RoBERTa

		Sbagliate	
Orientamento	**Testate**	**osservate**	**attese**
Far Left	20	11	**6,2**
Slightly Left	50	21	15,5
Non labelled	110	29	34,1
Slightly Right	207	51	64,1
Far Right	52	24	16,1

Problema 4 — perché servono caselle piene (1)

- Il χ^2 somma, casella per casella: $\dfrac{(\text{osservato} - \text{atteso})^2}{\text{atteso}}$

Problema 4 — perché servono caselle piene (1)

- Il χ^2 somma, casella per casella: $\dfrac{(\text{osservato} - \text{atteso})^2}{\text{atteso}}$
- Poi confronta il totale con la soglia di **9,5**: ma quella soglia è calcolata supponendo caselle **abbastanza piene**

Problema 4 — perché servono caselle piene (1)

- Il χ^2 somma, casella per casella: $\dfrac{(\text{osservato} - \text{atteso})^2}{\text{atteso}}$
- Poi confronta il totale con la soglia di **9,5**: ma quella soglia è calcolata supponendo caselle **abbastanza piene**
- Con caselle piccole, **una sola testata** pesa moltissimo:

Problema 4 — perché servono caselle piene (1)

- Il χ^2 somma, casella per casella: $\dfrac{(\text{osservato} - \text{atteso})^2}{\text{atteso}}$
- Poi confronta il totale con la soglia di **9,5**: ma quella soglia è calcolata supponendo caselle **abbastanza piene**
- Con caselle piccole, **una sola testata** pesa moltissimo:

  casella con 2 attese, ne osservo 4: $(4-2)^2/2 = \mathbf{2}$

Problema 4 — perché servono caselle piene (1)

- Il χ^2 somma, casella per casella: $\dfrac{(\text{osservato} - \text{atteso})^2}{\text{atteso}}$
- Poi confronta il totale con la soglia di **9,5**: ma quella soglia è calcolata supponendo caselle **abbastanza piene**
- Con caselle piccole, **una sola testata** pesa moltissimo:

  casella con 2 attese, ne osservo 4: $(4-2)^2/2 = \mathbf{2}$

  casella con 50 attese, ne osservo 52: $(52-50)^2/50 = \mathbf{0{,}08}$

Problema 4 — perché servono caselle piene (1)

- Il χ^2 somma, casella per casella: $\dfrac{(\text{osservato} - \text{atteso})^2}{\text{atteso}}$
- Poi confronta il totale con la soglia di **9,5**: ma quella soglia è calcolata supponendo caselle **abbastanza piene**
- Con caselle piccole, **una sola testata** pesa moltissimo:

  casella con 2 attese, ne osservo 4: $(4-2)^2/2 = \mathbf{2}$

  casella con 50 attese, ne osservo 52: $(52-50)^2/50 = \mathbf{0{,}08}$

  Stessa differenza di 2 testate, peso 25 volte diverso.

Problema 4 — perché servono caselle piene (2)

- Nel nostro caso (RoBERTa) il χ^2 per testata vale **18,8**

Problema 4 — perché servono caselle piene (2)

- Nel nostro caso (RoBERTa) il χ^2 per testata vale **18,8**
- Le sole 20 testate Far Left ne portano **5,4**: quasi un terzo

Problema 4 — perché servono caselle piene (2)

- Nel nostro caso (RoBERTa) il χ^2 per testata vale **18,8**
- Le sole 20 testate Far Left ne portano **5,4**: quasi un terzo
- Se **una** testata Far Left passasse da sbagliata a giusta: χ^2 da 18,8 a **16,9**

Problema 4 — perché servono caselle piene (2)

- Nel nostro caso (RoBERTa) il χ^2 per testata vale **18,8**
- Le sole 20 testate Far Left ne portano **5,4**: quasi un terzo
- Se **una** testata Far Left passasse da sbagliata a giusta: χ^2 da 18,8 a **16,9**
- Se lo facesse una testata Slightly Right: da 18,8 a 19,5

Problema 4 — perché servono caselle piene (2)

- Nel nostro caso (RoBERTa) il χ^2 per testata vale **18,8**
- Le sole 20 testate Far Left ne portano **5,4**: quasi un terzo
- Se **una** testata Far Left passasse da sbagliata a giusta: χ^2 da 18,8 a **16,9**
- Se lo facesse una testata Slightly Right: da 18,8 a 19,5

Il risultato dipende molto da pochissime testate.

Problema 4 — perché servono caselle piene (2)

- Nel nostro caso (RoBERTa) il χ^2 per testata vale **18,8**
- Le sole 20 testate Far Left ne portano **5,4**: quasi un terzo
- Se **una** testata Far Left passasse da sbagliata a giusta: χ^2 da 18,8 a **16,9**
- Se lo facesse una testata Slightly Right: da 18,8 a 19,5

  Il risultato dipende molto da pochissime testate.
- Regola pratica: almeno **5 attese** per casella. Noi ne abbiamo 6,2: appena sopra, **al limite**

Problema 5 — la MED guarda solo gli errori

- La MED misura la direzione dell'errore **solo quando il modello sbaglia**

Problema 5 — la MED guarda solo gli errori

- La MED misura la direzione dell'errore **solo quando il modello sbaglia**
- Non tiene conto di **quanto spesso** sbaglia

Problema 5 — l'esempio

- Gruppo A: sbaglia il **70%** degli articoli, e quando sbaglia sovrastima di mezzo livello (MED $+0.5$)

Problema 5 — l'esempio

- Gruppo A: sbaglia il **70%** degli articoli, e quando sbaglia sovrastima di mezzo livello (MED $+0.5$)
- Gruppo B: sbaglia il **10%**, con la stessa MED $+0.5$

Problema 5 — l'esempio

- Gruppo A: sbaglia il **70%** degli articoli, e quando sbaglia sovrastima di mezzo livello (MED $+0.5$)
- Gruppo B: sbaglia il **10%**, con la stessa MED $+0.5$
- Stessa MED, ma l'effetto totale è **diversissimo**: A viene spinto in alto 7 volte su 10, B solo 1 su 10

Problema 5 — l'esempio

- Gruppo A: sbaglia il **70%** degli articoli, e quando sbaglia sovrastima di mezzo livello (MED $+0.5$)
- Gruppo B: sbaglia il **10%**, con la stessa MED $+0.5$
- Stessa MED, ma l'effetto totale è **diversissimo**: A viene spinto in alto 7 volte su 10, B solo 1 su 10

Nel paper gli estremi sbagliano il 60–72%, i non-labelled il 30%: confrontare le loro MED inganna.

Problema 5 — l'esempio

- Gruppo A: sbaglia il **70%** degli articoli, e quando sbaglia sovrastima di mezzo livello (MED $+0.5$)
- Gruppo B: sbaglia il **10%**, con la stessa MED $+0.5$
- Stessa MED, ma l'effetto totale è **diversissimo**: A viene spinto in alto 7 volte su 10, B solo 1 su 10

  Nel paper gli estremi sbagliano il 60–72%, i non-labelled il 30%: confrontare le loro MED inganna.

- Soluzione: riportare anche la direzione media su **tutti** gli articoli, compresi quelli classificati **correttamente** (che contano zero)

Problema 5 — un'incoerenza nel paper bocciato

- La **formula** della MED usa solo gli articoli **sbagliati**

Problema 5 — un'incoerenza nel paper bocciato

- La **formula** della MED usa solo gli articoli **sbagliati**
- Ma i numeri **per livello** (es. $l_5 \approx -1{,}30$) sono calcolati su **tutti** gli articoli

Problema 5 — un'incoerenza nel paper bocciato

- La **formula** della MED usa solo gli articoli **sbagliati**
- Ma i numeri **per livello** (es. $l_5 \approx -1{,}30$) sono calcolati su **tutti** gli articoli
- Mentre quelli **per orientamento** (estremi da $+0{,}33$ a $+1{,}00$) solo sugli **errori**

Problema 5 — un'incoerenza nel paper bocciato

- La **formula** della MED usa solo gli articoli **sbagliati**
- Ma i numeri **per livello** (es. $l_5 \approx -1{,}30$) sono calcolati su **tutti** gli articoli
- Mentre quelli **per orientamento** (estremi da $+0{,}33$ a $+1{,}00$) solo sugli **errori**

Due definizioni diverse nello stesso paper: nel nuovo va scelta una sola, e dichiarata.

Problema 6 — la direzione è “obbligata” dai bordi

- Se una testata è in l_1 (il più basso), l’errore può solo andare **verso l’alto**; se è in l_5, solo verso il basso

Problema 6 — la direzione è “obbligata” dai bordi

- Se una testata è in l_1 (il più basso), l’errore può solo andare **verso l’alto**; se è in l_5, solo verso il basso
- Far-left e far-right stanno quasi tutti nei livelli bassi $\rightarrow$ i loro errori sono “per forza” positivi

Problema 6 — la direzione è “obbligata” dai bordi

- Se una testata è in l_1 (il più basso), l’errore può solo andare **verso l’alto**; se è in l_5, solo verso il basso
- Far-left e far-right stanno quasi tutti nei livelli bassi $\rightarrow$ i loro errori sono “per forza” positivi

Quindi la sovrastima degli estremi può dipendere dalla composizione, non dall’orientamento.

Considerazione di John a ChatGPT (1)

- L'affidabilità l'abbiamo **stratificata** nei fold (tenuta sotto controllo)

Considerazione di John a ChatGPT (1)

- L'affidabilità l'abbiamo **stratificata** nei fold (tenuta sotto controllo)
- L'orientamento invece **no**: è lasciato a caso

Considerazione di John a ChatGPT (1)

- L'affidabilità l'abbiamo **stratificata** nei fold (tenuta sotto controllo)
- L'orientamento invece **no**: è lasciato a caso
- E nel dataset orientamento $\times$ livello è **sbilanciatissimo**

Considerazione di John a ChatGPT (1)

- L'affidabilità l'abbiamo **stratificata** nei fold (tenuta sotto controllo)
- L'orientamento invece **no**: è lasciato a caso
- E nel dataset orientamento $\times$ livello è **sbilanciatissimo**
- Alcune combinazioni **non esistono**: nessuna slightly-left di livello 1, nessuna far-right di livello 5

Considerazione di John a ChatGPT (2)

- Quando dividiamo in fold, a volte il modello vede **zero** esempi di una combinazione che poi deve indovinare

Considerazione di John a ChatGPT (2)

- Quando dividiamo in fold, a volte il modello vede **zero** esempi di una combinazione che poi deve indovinare
- Es. (fold 1): nessun Far Left di livello 1 o 3 in addestramento, ma viene testato proprio su quelli

Considerazione di John a ChatGPT (2)

- Quando dividiamo in fold, a volte il modello vede **zero** esempi di una combinazione che poi deve indovinare
- Es. (fold 1): nessun Far Left di livello 1 o 3 in addestramento, ma viene testato proprio su quelli

  Naturale che sbagli: non li ha mai visti.

Considerazione di John a ChatGPT (2)

- Quando dividiamo in fold, a volte il modello vede **zero** esempi di una combinazione che poi deve indovinare
- Es. (fold 1): nessun Far Left di livello 1 o 3 in addestramento, ma viene testato proprio su quelli

  Naturale che sbagli: non li ha mai visti.
- Quindi parte di questi "errori politici" è un **artefatto** del dataset e dei fold

Considerazione di John a ChatGPT (3)

- Questa analisi del bias è **molto specifica**: vale per *questo* dataset, *questi* modelli, *questo* training

Considerazione di John a ChatGPT (3)

- Questa analisi del bias è **molto specifica**: vale per *questo* dataset, *questi* modelli, *questo* training
- Non è un risultato generale sul "comportamento politico" dei modelli

Considerazione di John a ChatGPT (3)

- Questa analisi del bias è **molto specifica**: vale per *questo* dataset, *questi* modelli, *questo* training
- Non è un risultato generale sul "comportamento politico" dei modelli
- Se la teniamo, va detto **chiaramente**

Considerazione di John a ChatGPT (3)

- Questa analisi del bias è **molto specifica**: vale per *questo* dataset, *questi* modelli, *questo* training
- Non è un risultato generale sul "comportamento politico" dei modelli
- Se la teniamo, va detto **chiaramente**

  È un po' un'analisi fine a sé stessa.

Considerazione di John — che cos'è una testata?

Una critica nostra, non a ChatGPT

Nel paper una testata coincide con **l'insieme dei suoi articoli**. Ma è davvero così?

- Oggi una testata è anche le sue **pagine social**, le **newsletter**, i **podcast**, i video

Considerazione di John — che cos'è una testata?

Una critica nostra, non a ChatGPT

Nel paper una testata coincide con **l'insieme dei suoi articoli**. Ma è davvero così?

- Oggi una testata è anche le sue **pagine social**, le **newsletter**, i **podcast**, i video
- Noi guardiamo solo gli **articoli del sito**: una parte della testata, non la testata intera

Considerazione di John — che cos'è una testata?

Una critica nostra, non a ChatGPT

Nel paper una testata coincide con **l'insieme dei suoi articoli**. Ma è davvero così?

- Oggi una testata è anche le sue **pagine social**, le **newsletter**, i **podcast**, i video
- Noi guardiamo solo gli **articoli del sito**: una parte della testata, non la testata intera

Rischiamo di giudicare la testata guardandone solo una parte.

Considerazione di John — che cos'è una testata?

Una critica nostra, non a ChatGPT

Nel paper una testata coincide con **l'insieme dei suoi articoli**. Ma è davvero così?

- Oggi una testata è anche le sue **pagine social**, le **newsletter**, i **podcast**, i video
- Noi guardiamo solo gli **articoli del sito**: una parte della testata, non la testata intera

  Rischiamo di giudicare la testata guardandone solo una parte.
- Nel paper non dovremmo darlo per scontato: va detto chiaramente **che cosa** stiamo giudicando

Fabio × Claude — cos'è

- Fabio ha chiesto a Claude tre cose: come usare i modelli grandi, una review del paper, come impostare l'analisi del bias

Fabio × Claude — cos'è

- Fabio ha chiesto a Claude tre cose: come usare i modelli grandi, una review del paper, come impostare l'analisi del bias
- Il bias l'abbiamo **già visto**: non ci torniamo

Fabio × Claude — cos'è

- Fabio ha chiesto a Claude tre cose: come usare i modelli grandi, una review del paper, come impostare l'analisi del bias
- Il bias l'abbiamo **già visto**: non ci torniamo
- Qui solo le **proposte nuove**: esperimenti, metodi, aggregazione, correzioni

Fabio — il problema della “contaminazione”

- Domanda di ogni lettore: “perché non chiedere direttamente a GPT?”

Fabio — il problema della “contaminazione”

- Domanda di ogni lettore: “perché non chiedere direttamente a GPT?”
- Ma un LLM grande **conosce già** queste testate: le ha lette in addestramento e ne sa la reputazione

Fabio — il problema della “contaminazione”

- Domanda di ogni lettore: “perché non chiedere direttamente a GPT?”
- Ma un LLM grande **conosce già** queste testate: le ha lette in addestramento e ne sa la reputazione
- E negli articoli il nome della testata compare spesso (firma, piè di pagina, link)

Fabio — il problema della “contaminazione”

- Domanda di ogni lettore: “perché non chiedere direttamente a GPT?”
- Ma un LLM grande **conosce già** queste testate: le ha lette in addestramento e ne sa la reputazione
- E negli articoli il nome della testata compare spesso (firma, piè di pagina, link)
- Quindi GPT potrebbe **ricordare la reputazione** invece di leggere il testo

Fabio — il problema della "contaminazione"

- Domanda di ogni lettore: "perché non chiedere direttamente a GPT?"
- Ma un LLM grande **conosce già** queste testate: le ha lette in addestramento e ne sa la reputazione
- E negli articoli il nome della testata compare spesso (firma, piè di pagina, link)
- Quindi GPT potrebbe **ricordare la reputazione** invece di leggere il testo

Come far giudicare un vino "alla cieca" lasciando l'etichetta sulla bottiglia.

Fabio — l'esperimento: con e senza nomi

- Si fa valutare a un LLM lo stesso articolo due volte: **normale** e con nomi, siti e firme **cancellati**

Fabio — l'esperimento: con e senza nomi

- Si fa valutare a un LLM lo stesso articolo due volte: **normale** e con nomi, siti e firme **cancellati**
- Se senza nomi va molto peggio → prima stava **riconoscendo la testata**, non giudicando il testo

Fabio — l'esperimento: con e senza nomi

- Si fa valutare a un LLM lo stesso articolo due volte: **normale** e con nomi, siti e firme **cancellati**
- Se senza nomi va molto peggio → prima stava **riconoscendo la testata**, non giudicando il testo
- Trasforma la domanda "perché non GPT?" in un **risultato**

Fabio — l'esperimento: con e senza nomi

- Si fa valutare a un LLM lo stesso articolo due volte: **normale** e con nomi, siti e firme **cancellati**
- Se senza nomi va molto peggio → prima stava **riconoscendo la testata**, non giudicando il testo
- Trasforma la domanda "perché non GPT?" in un **risultato**
- E spiega perché i modelli piccoli addestrati da noi sono lo strumento giusto per *questa* domanda

Fabio — una baseline semplice: TF-IDF

- Oggi confrontiamo i transformer solo con baseline “stupide” (classe più frequente, caso)

Fabio — una baseline semplice: TF-IDF

- Oggi confrontiamo i transformer solo con baseline “stupide” (classe più frequente, caso)
- Fabio: aggiungere un modello **semplice ma serio**, senza reti neurali

Fabio — una baseline semplice: TF-IDF

- Oggi confrontiamo i transformer solo con baseline “stupide” (classe più frequente, caso)
- Fabio: aggiungere un modello **semplice ma serio**, senza reti neurali
- **TF-IDF**: conta le parole di ogni articolo, dando più peso a quelle rare e distintive; sopra, una regressione logistica

Fabio — una baseline semplice: TF-IDF

- Oggi confrontiamo i transformer solo con baseline “stupide” (classe più frequente, caso)
- Fabio: aggiungere un modello **semplice ma serio**, senza reti neurali
- **TF-IDF**: conta le parole di ogni articolo, dando più peso a quelle rare e distintive; sopra, una regressione logistica

  Se un “contatore di parole” arriva vicino ai transformer, i transformer non stanno aggiungendo molto.

Fabio — una baseline semplice: TF-IDF

- Oggi confrontiamo i transformer solo con baseline “stupide” (classe più frequente, caso)
- Fabio: aggiungere un modello **semplice ma serio**, senza reti neurali
- **TF-IDF**: conta le parole di ogni articolo, dando più peso a quelle rare e distintive; sopra, una regressione logistica

  Se un “contatore di parole” arriva vicino ai transformer, i transformer non stanno aggiungendo molto.

- Costa pochissimo da fare

Fabio — LLM come estrattore di segnali: l'idea

- Invece di chiedere all'LLM "è affidabile?", gli si chiede un **voto su segnali precisi**

Fabio — LLM come estrattore di segnali: l'idea

- Invece di chiedere all'LLM "è affidabile?", gli si chiede un **voto su segnali precisi**

  Sensazionalismo, fonti citate, toni prudenti, opinione o cronaca, titolo acchiappa-clic, presenza di rettifiche...

Fabio — LLM come estrattore di segnali: l'idea

- Invece di chiedere all'LLM "è affidabile?", gli si chiede un **voto su segnali precisi**

  Sensazionalismo, fonti citate, toni prudenti, opinione o cronaca, titolo acchiappa-clic, presenza di rettifiche...

- Ogni articolo diventa una **lista di voti**

Fabio — LLM come estrattore di segnali: l'idea

- Invece di chiedere all'LLM "è affidabile?", gli si chiede un **voto su segnali precisi**

  Sensazionalismo, fonti citate, toni prudenti, opinione o cronaca, titolo acchiappa-clic, presenza di rettifiche...

- Ogni articolo diventa una **lista di voti**

  Es.: sensazionalismo 8/10, fonti citate 2/10, opinione 9/10, ...

Fabio — LLM come estrattore di segnali: l'idea

- Invece di chiedere all'LLM "è affidabile?", gli si chiede un **voto su segnali precisi**

  Sensazionalismo, fonti citate, toni prudenti, opinione o cronaca, titolo acchiappa-clic, presenza di rettifiche...

- Ogni articolo diventa una **lista di voti**

  Es.: sensazionalismo 8/10, fonti citate 2/10, opinione 9/10, ...

- Poi un classificatore semplice impara **quali segnali contano**

Fabio — LLM come estrattore di segnali: perché

- **Costa poco**: una chiamata all'LLM per articolo ($\sim$20.000 in tutto)

Fabio — LLM come estrattore di segnali: perché

- **Costa poco**: una chiamata all'LLM per articolo ($\sim$20.000 in tutto)
- **Si capisce**: sappiamo *quali* segnali distinguono una testata affidabile

Fabio — LLM come estrattore di segnali: perché

- **Costa poco**: una chiamata all'LLM per articolo ($\sim$20.000 in tutto)
- **Si capisce**: sappiamo *quali* segnali distinguono una testata affidabile
- Aggregare è naturale: il profilo di una testata è la **media** dei voti dei suoi articoli

Fabio — LLM come estrattore di segnali: perché

- **Costa poco**: una chiamata all'LLM per articolo ($\sim$20.000 in tutto)
- **Si capisce**: sappiamo *quali* segnali distinguono una testata affidabile
- Aggregare è naturale: il profilo di una testata è la **media** dei voti dei suoi articoli
- Per Fabio è la proposta con il miglior rapporto novità/fatica, insieme all'esperimento con e senza nomi

Fabio — multiple-instance learning: l'idea

- Oggi: classifichiamo **ogni articolo**, poi **votiamo**

Fabio — multiple-instance learning: l'idea

- Oggi: classifichiamo **ogni articolo**, poi **votiamo**
- Ma l'etichetta vera è della **testata**, non del singolo articolo

Fabio — multiple-instance learning: l'idea

- Oggi: classifichiamo **ogni articolo**, poi **votiamo**
- Ma l'etichetta vera è della **testata**, non del singolo articolo
- Idea: addestrare il modello direttamente su "**sacchetti**" di articoli: tutti quelli di una testata insieme, con l'etichetta della testata

Fabio — multiple-instance learning: come

- Ogni articolo viene trasformato una volta in un **embedding**: una lista di numeri che ne riassume il significato

Fabio — multiple-instance learning: come

- Ogni articolo viene trasformato una volta in un **embedding**: una lista di numeri che ne riassume il significato
- Il modello impara a combinare gli embedding di una testata (media, o pesando di più gli articoli più utili)

Fabio — multiple-instance learning: come

- Ogni articolo viene trasformato una volta in un **embedding**: una lista di numeri che ne riassume il significato
- Il modello impara a combinare gli embedding di una testata (media, o pesando di più gli articoli più utili)
- 439 testate sono poche: si creano tanti sacchetti **a caso** da 10–20 articoli della stessa testata $\rightarrow$ migliaia di esempi

Fabio — multiple-instance learning: come

- Ogni articolo viene trasformato una volta in un **embedding**: una lista di numeri che ne riassume il significato
- Il modello impara a combinare gli embedding di una testata (media, o pesando di più gli articoli più utili)
- 439 testate sono poche: si creano tanti sacchetti **a caso** da 10–20 articoli della stessa testata $\rightarrow$ migliaia di esempi
- In più dà una **misura di confidenza** sul giudizio della testata

Fabio — modelli più recenti e altre idee

- BERT e Llama 3 sembrano “datati”: stessa ricetta con modelli attuali (**ModernBERT**, **DeBERTa-v3**, piccoli decoder recenti)

Fabio — modelli più recenti e altre idee

- BERT e Llama 3 sembrano “datati”: stessa ricetta con modelli attuali (**ModernBERT**, **DeBERTa-v3**, piccoli decoder recenti)

  Quasi solo estetica, ma toglie un appiglio ai revisori.

Fabio — modelli più recenti e altre idee

- BERT e Llama 3 sembrano “datati”: stessa ricetta con modelli attuali (**ModernBERT**, **DeBERTa-v3**, piccoli decoder recenti)

  Quasi solo estetica, ma toglie un appiglio ai revisori.

- **Pulizia delle etichette**: un LLM segnala gli articoli atipici per la loro testata e si dà loro meno peso

Fabio — modelli più recenti e altre idee

- BERT e Llama 3 sembrano “datati”: stessa ricetta con modelli attuali (**ModernBERT**, **DeBERTa-v3**, piccoli decoder recenti)

  Quasi solo estetica, ma toglie un appiglio ai revisori.

- **Pulizia delle etichette**: un LLM segnala gli articoli atipici per la loro testata e si dà loro meno peso
- **Agente**: visita la testata, legge le pagine “chi siamo”, proprietà, rettifiche, e valuta i 9 criteri di NewsGuard

Fabio — modelli più recenti e altre idee

- BERT e Llama 3 sembrano “datati”: stessa ricetta con modelli attuali (**ModernBERT**, **DeBERTa-v3**, piccoli decoder recenti)

  Quasi solo estetica, ma toglie un appiglio ai revisori.

- **Pulizia delle etichette**: un LLM segnala gli articoli atipici per la loro testata e si dà loro meno peso
- **Agente**: visita la testata, legge le pagine “chi siamo”, proprietà, rettifiche, e valuta i 9 criteri di NewsGuard

  È un altro task (non solo testo): lavoro futuro.

Fabio — confrontare modi di aggregare

- Oggi usiamo un solo modo: il **voto di maggioranza**

Fabio — confrontare modi di aggregare

- Oggi usiamo un solo modo: il **voto di maggioranza**
- Alternative: **media** dei livelli, **mediana**, media delle **probabilità**

Fabio — confrontare modi di aggregare

- Oggi usiamo un solo modo: il **voto di maggioranza**
- Alternative: **media** dei livelli, **mediana**, media delle **probabilità**
- Esempio, 10 articoli: 4 dicono l_2, 3 dicono l_3, 3 dicono l_4

Fabio — confrontare modi di aggregare

- Oggi usiamo un solo modo: il **voto di maggioranza**
- Alternative: **media** dei livelli, **mediana**, media delle **probabilità**
- Esempio, 10 articoli: 4 dicono l_2, 3 dicono l_3, 3 dicono l_4

  Maggioranza: l_2 Media: $(4{\cdot}2 + 3{\cdot}3 + 3{\cdot}4)/10 = 2{,}9 \to l_3$

Fabio — confrontare modi di aggregare

- Oggi usiamo un solo modo: il **voto di maggioranza**
- Alternative: **media** dei livelli, **mediana**, media delle **probabilità**
- Esempio, 10 articoli: 4 dicono l_2, 3 dicono l_3, 3 dicono l_4

  Maggioranza: l_2 Media: $(4{\cdot}2 + 3{\cdot}3 + 3{\cdot}4)/10 = 2{,}9 \to l_3$
- Risposte **diverse**: vale la pena confrontarle

Fabio — quanti articoli servono?

- Domanda pratica: per giudicare una testata **nuova**, quanti articoli mi servono?

Fabio — quanti articoli servono?

- Domanda pratica: per giudicare una testata **nuova**, quanti articoli mi servono?
- La curva: accuratezza sulla testata usando 5, 10, 20, 50... articoli

Fabio — quanti articoli servono?

- Domanda pratica: per giudicare una testata **nuova**, quanti articoli mi servono?
- La curva: accuratezza sulla testata usando 5, 10, 20, 50... articoli
- Con fino a 200 articoli il voto è probabilmente già "saturo": la domanda interessante è **con pochi**

Fabio — quanti articoli servono?

- Domanda pratica: per giudicare una testata **nuova**, quanti articoli mi servono?
- La curva: accuratezza sulla testata usando 5, 10, 20, 50... articoli
- Con fino a 200 articoli il voto è probabilmente già "saturo": la domanda interessante è **con pochi**

È l'informazione più utile per chi volesse usare il sistema davvero.

Fabio — l'early stopping: cos'è

- Il modello si addestra in più "giri" sugli stessi dati (le **epoche**)

Fabio — l'early stopping: cos'è

- Il modello si addestra in più "giri" sugli stessi dati (le **epoche**)
- Dopo un po' comincia a **imparare a memoria** gli esempi e peggiora sui dati nuovi

Fabio — l'early stopping: cos'è

- Il modello si addestra in più "giri" sugli stessi dati (le **epoche**)
- Dopo un po' comincia a **imparare a memoria** gli esempi e peggiora sui dati nuovi
- Early stopping: dopo ogni giro misuro l'errore su dati **messi da parte** ("validation") e tengo la versione migliore

Fabio — l'early stopping: cos'è

- Il modello si addestra in più "giri" sugli stessi dati (le **epoche**)
- Dopo un po' comincia a **imparare a memoria** gli esempi e peggiora sui dati nuovi
- Early stopping: dopo ogni giro misuro l'errore su dati **messi da parte** ("validation") e tengo la versione migliore

Giro	1	2	3	4	5
Errore sulla validation	0,60	0,50	0,46	**0,44**	0,47

Fabio — l'early stopping: cos'è

- Il modello si addestra in più "giri" sugli stessi dati (le **epoche**)
- Dopo un po' comincia a **imparare a memoria** gli esempi e peggiora sui dati nuovi
- Early stopping: dopo ogni giro misuro l'errore su dati **messi da parte** ("validation") e tengo la versione migliore

Giro	1	2	3	4	5
Errore sulla validation	0,60	0,50	0,46	**0,44**	0,47

Tengo il giro 4: dopo, il modello peggiora (come Llama nel paper, minimo al giro 4).

Fabio — l'early stopping: il rischio

- I dati di validation devono essere **diversi** da quelli di test

Fabio — l'early stopping: il rischio

- I dati di validation devono essere **diversi** da quelli di test
- Se scegliessi il giro migliore guardando il **test**, sceglierei la versione che *per caso* va meglio proprio sul test

Fabio — l'early stopping: il rischio

- I dati di validation devono essere **diversi** da quelli di test
- Se scegliessi il giro migliore guardando il **test**, sceglierei la versione che *per caso* va meglio proprio sul test

  Come scegliere quale compito consegnare dopo aver visto le soluzioni: il voto sembra più alto di quello che vali.

Fabio — l'early stopping: il rischio

- I dati di validation devono essere **diversi** da quelli di test
- Se scegliessi il giro migliore guardando il **test**, sceglierei la versione che *per caso* va meglio proprio sul test

  Come scegliere quale compito consegnare dopo aver visto le soluzioni: il voto sembra più alto di quello che vali.

- Il risultato riportato sarebbe **gonfiato**

Fabio — l'early stopping: nel nostro caso

- Nel paper: "early stopping che salva il modello con la validation loss minima", senza dire **su quali dati**

Fabio — l'early stopping: nel nostro caso

- Nel paper: "early stopping che salva il modello con la validation loss minima", senza dire **su quali dati**
- Dal codice: lo usa **solo Llama**, su un 10% degli articoli di **training**; gli altri modelli fanno un numero fisso di giri

Fabio — l'early stopping: nel nostro caso

- Nel paper: "early stopping che salva il modello con la validation loss minima", senza dire **su quali dati**
- Dal codice: lo usa **solo Llama**, su un 10% degli articoli di **training**; gli altri modelli fanno un numero fisso di giri
- Quindi nessuna contaminazione, ma **va scritto** chiaramente

Fabio — tema e periodo

- Gli articoli sono presi dalle homepage in un **periodo breve**: ogni testata porta i **temi del momento**

Fabio — tema e periodo

- Gli articoli sono presi dalle homepage in un **periodo breve**: ogni testata porta i **temi del momento**
- Se tema e affidabilità vanno insieme, il modello potrebbe imparare il **tema**, non l'affidabilità

Fabio — tema e periodo

- Gli articoli sono presi dalle homepage in un **periodo breve**: ogni testata porta i **temi del momento**
- Se tema e affidabilità vanno insieme, il modello potrebbe imparare il **tema**, non l'affidabilità

  Es.: se quella settimana le testate inaffidabili parlano tutte dello stesso argomento, basta riconoscere l'argomento.

Fabio — tema e periodo

- Gli articoli sono presi dalle homepage in un **periodo breve**: ogni testata porta i **temi del momento**
- Se tema e affidabilità vanno insieme, il modello potrebbe imparare il **tema**, non l'affidabilità

  Es.: se quella settimana le testate inaffidabili parlano tutte dello stesso argomento, basta riconoscere l'argomento.
- Controllo: classificare il tema degli articoli e vedere se è legato al livello

Fabio — la classe l_5 e l'ordine dei livelli

- l_5 = punteggio **esattamente 100**: classe piccola e quasi impossibile da distinguere da l_4

Fabio — la classe l_5 e l'ordine dei livelli

- l_5 = punteggio **esattamente 100**: classe piccola e quasi impossibile da distinguere da l_4
- Proposta: **unire** l_4 e l_5, o riportare anche i risultati a 4 classi

Fabio — la classe l_5 e l'ordine dei livelli

- l_5 = punteggio **esattamente 100**: classe piccola e quasi impossibile da distinguere da l_4
- Proposta: **unire** l_4 e l_5, o riportare anche i risultati a 4 classi
- I livelli sono **ordinati**, ma il modello è addestrato come se fossero categorie slegate

Fabio — la classe l_5 e l'ordine dei livelli

- l_5 = punteggio **esattamente 100**: classe piccola e quasi impossibile da distinguere da l_4
- Proposta: **unire** l_4 e l_5, o riportare anche i risultati a 4 classi
- I livelli sono **ordinati**, ma il modello è addestrato come se fossero categorie slegate

  In addestramento confondere l_5 con l_4 costa quanto confonderlo con l_1: va almeno detto come limite.

Fabio — correzioni di scrittura (verificate)

- Bibliografia doppia: [4] = [15] (Przybyła & Soto), [5] = [20] (Srba et al.)

Fabio — correzioni di scrittura (verificate)

- Bibliografia doppia: [4] = [15] (Przybyła & Soto), [5] = [20] (Srba et al.)
- [30] cita “Mixtral of Experts” per Mistral 24B: è un modello diverso

Fabio — correzioni di scrittura (verificate)

- Bibliografia doppia: [4] = [15] (Przybyła & Soto), [5] = [20] (Srba et al.)
- [30] cita “Mixtral of Experts” per Mistral 24B: è un modello diverso
- Rinvii sbagliati: “In V-B we instantiate Agg” (è V-E), “Section IV-0c”

Fabio — correzioni di scrittura (verificate)

- Bibliografia doppia: [4] = [15] (Przybyła & Soto), [5] = [20] (Srba et al.)
- [30] cita “Mixtral of Experts” per Mistral 24B: è un modello diverso
- Rinvii sbagliati: “In V-B we instantiate Agg” (è V-E), “Section IV-0c”
- Tabella II: BERT 58,27%, mentre il testo dice “around 0.60” (dato complessivo contro media sui fold)

Fabio — correzioni di scrittura (verificate)

- Bibliografia doppia: [4] = [15] (Przybyła & Soto), [5] = [20] (Srba et al.)
- [30] cita “Mixtral of Experts” per Mistral 24B: è un modello diverso
- Rinvii sbagliati: “In V-B we instantiate Agg” (è V-E), “Section IV-0c”
- Tabella II: BERT 58,27%, mentre il testo dice “around 0.60” (dato complessivo contro media sui fold)
- Il contributo 4 è un **risultato**, non un contributo; i contributi 1–2 si sovrappongono a Burdisso et al. [7]

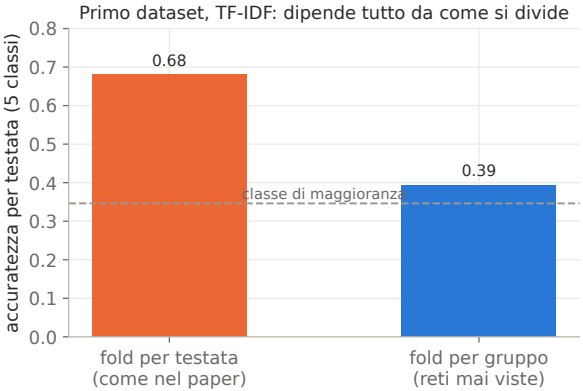
Fabio — correzioni di scrittura (verificate)

- Bibliografia doppia: [4] = [15] (Przybyła & Soto), [5] = [20] (Srba et al.)
- [30] cita “Mixtral of Experts” per Mistral 24B: è un modello diverso
- Rinvii sbagliati: “In V-B we instantiate Agg” (è V-E), “Section IV-0c”
- Tabella II: BERT 58,27%, mentre il testo dice “around 0.60” (dato complessivo contro media sui fold)
- Il contributo 4 è un **risultato**, non un contributo; i contributi 1–2 si sovrappongono a Burdisso et al. [7]
- Dire chiaramente se il dataset è **rilasciabile** (etichette NewsGuard proprietarie)

Il primo dataset

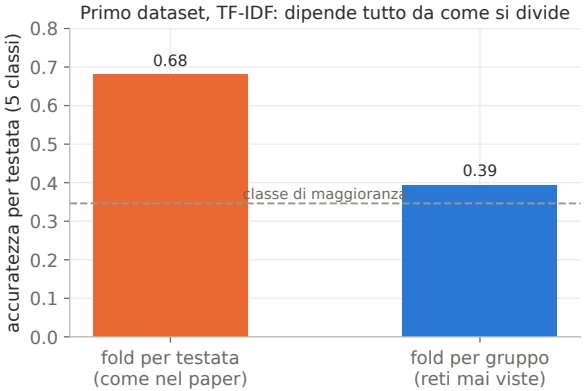
funzionava solo in apparenza

Il punto di partenza



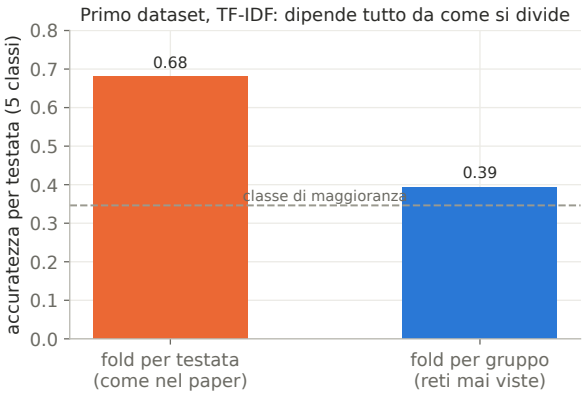
- Classificatore a feature (TF-IDF + regressione logistica) sul dataset di IrForGood: 439 testate, 19.476 articoli

Il punto di partenza



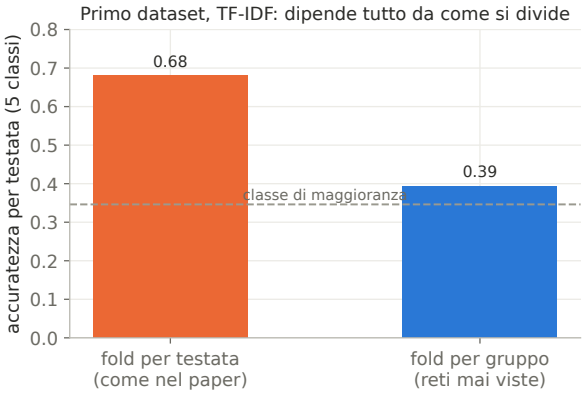
- Classificatore a feature (TF-IDF + regressione logistica) sul dataset di IrForGood: 439 testate, 19.476 articoli
- Testate divise tra training e test **come nel paper**: **0,68** di accuratezza per testata

Il punto di partenza



- Classificatore a feature (TF-IDF + regressione logistica) sul dataset di IrForGood: 439 testate, 19.476 articoli
- Testate divise tra training e test **come nel paper**: **0,68** di accuratezza per testata
- Testate divise **per rete** (nel test solo reti mai viste): **0,39**, appena sopra la classe di maggioranza (0,35)

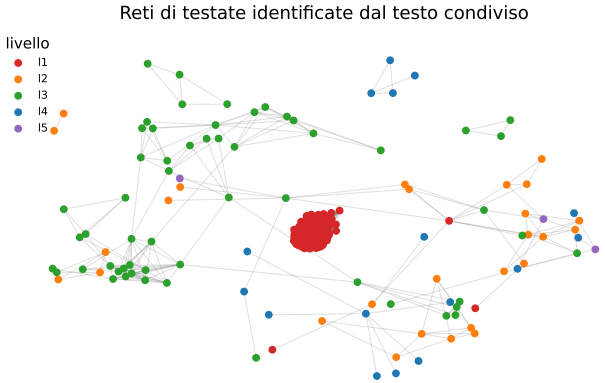
Il punto di partenza



- Classificatore a feature (TF-IDF + regressione logistica) sul dataset di IrForGood: 439 testate, 19.476 articoli
- Testate divise tra training e test **come nel paper**: **0,68** di accuratezza per testata
- Testate divise **per rete** (nel test solo reti mai viste): **0,39**, appena sopra la classe di maggioranza (0,35)

Il risultato dipendeva da come si dividevano le testate: c'era qualcosa nel dataset.

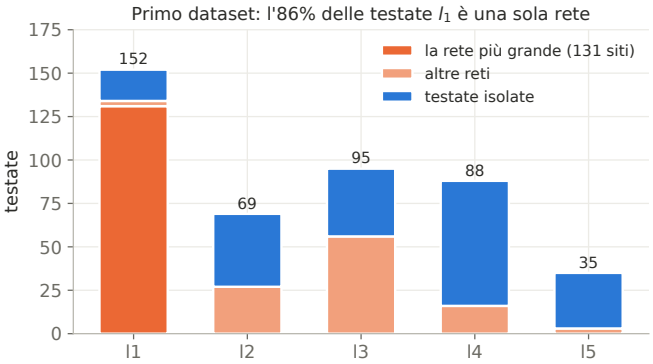
Dentro il dataset: reti di siti



Una linea = le due testate hanno **almeno 2 articoli quasi uguali** (somiglianza $\geq 0{,}5$, spesso lo stesso identico articolo). La distanza nel disegno non misura nulla.

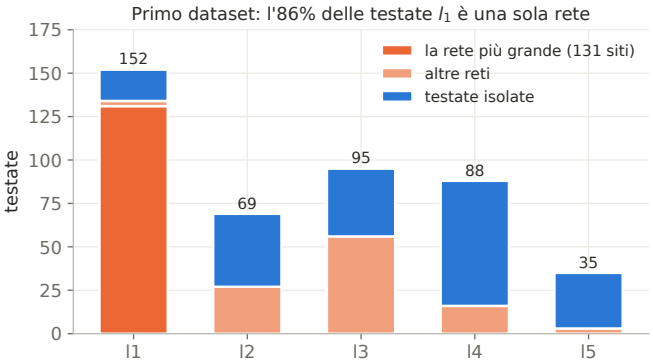
Il grumo rosso: **una rete di 131 siti** l_1 con lo stesso proprietario.

Una sola rete faceva quasi tutto il livello l_1



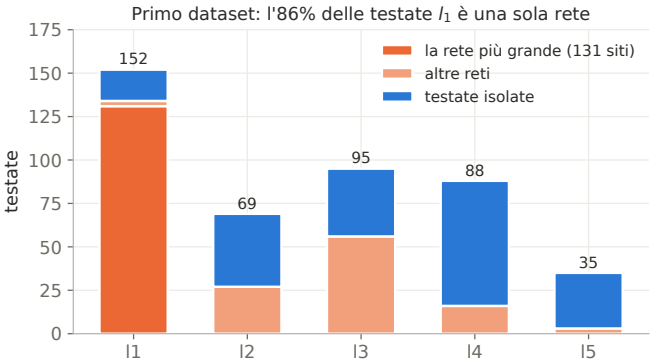
- 236 testate su 439 stanno in una **rete** (stesso testo, stesso proprietario)

Una sola rete faceva quasi tutto il livello l_1



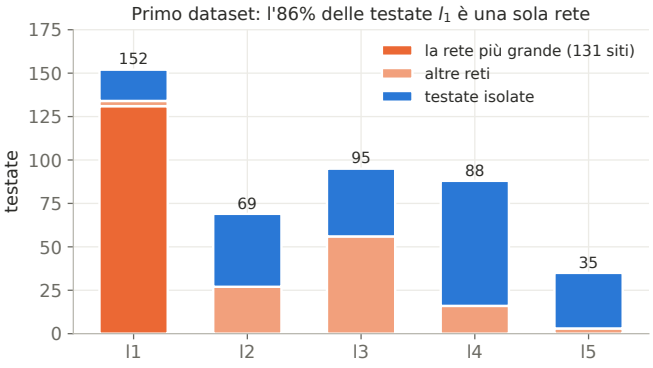
- 236 testate su 439 stanno in una **rete** (stesso testo, stesso proprietario)
- l_1: **131 testate su 152** sono la stessa rete

Una sola rete faceva quasi tutto il livello l_1



- 236 testate su 439 stanno in una **rete** (stesso testo, stesso proprietario)
- l_1: **131 testate su 152** sono la stessa rete
- l_3: soprattutto catene di giornali locali

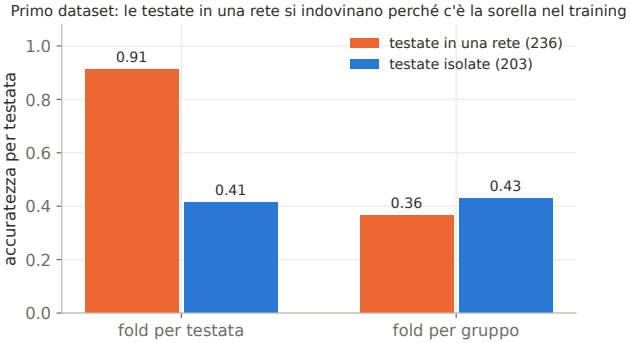
Una sola rete faceva quasi tutto il livello l_1



- 236 testate su 439 stanno in una **rete** (stesso testo, stesso proprietario)
- l_1: **131 testate su 152** sono la stessa rete
- l_3: soprattutto catene di giornali locali

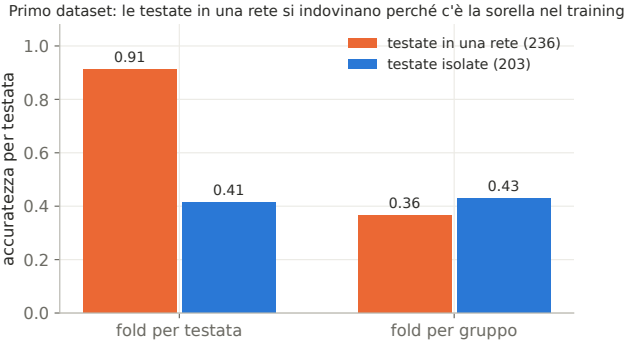
Con queste reti nel training e nel test, il modello riconosce la rete, non l'affidabilità.

Da dove veniva lo 0,68



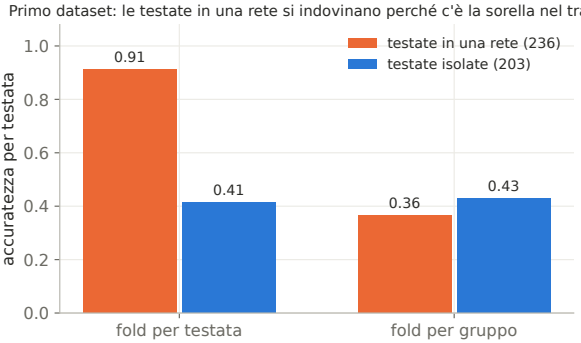
- Testate in una rete: **0,91** — ma solo perché una **sorella** sta nel training

Da dove veniva lo 0,68



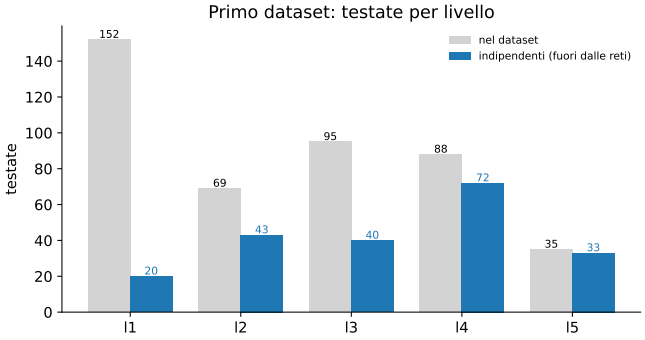
- Testate in una rete: **0,91** — ma solo perché una **sorella** sta nel training
- Basta mettere la rete tutta dalla stessa parte: **0,36**

Da dove veniva lo 0,68



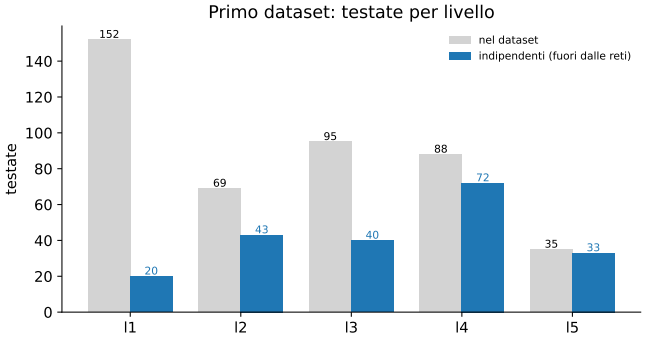
- Testate in una rete: **0,91** — ma solo perché una **sorella** sta nel training
- Basta mettere la rete tutta dalla stessa parte: **0,36**
- Le testate isolate restano a **0,41–0,43** in tutti e due i casi: è il valore vero

Pulito, il primo dataset era troppo piccolo



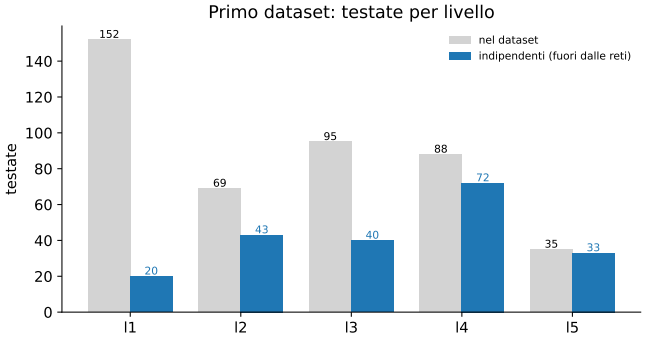
- Tolte copie e reti, l_1 crolla da **152 a 20** testate indipendenti

Pulito, il primo dataset era troppo piccolo



- Tolte copie e reti, l_1 crolla da **152 a 20** testate indipendenti
- Troppe poche testate per livello per addestrare e valutare

Pulito, il primo dataset era troppo piccolo



- Tolte copie e reti, l_1 crolla da **152 a 20** testate indipendenti
- Troppe poche testate per livello per addestrare e valutare
- Decisione: **raccogliere un dataset nuovo**, più grande, e pulirlo con un metodo rigoroso

Il nuovo dataset

come l'ho costruito, passo per passo

Lo scraping

- **Tutte** le testate NewsGuard in inglese, con un punteggio, il cui argomento **include** “Political news or commentary”: **3.128**

Lo scraping

- **Tutte** le testate NewsGuard in inglese, con un punteggio, il cui argomento **include** "Political news or commentary": **3.128**
- In **ordine casuale** (seme fisso) e **senza guardare il livello**: la scelta delle testate non può favorire il risultato

Lo scraping

- **Tutte** le testate NewsGuard in inglese, con un punteggio, il cui argomento **include** "Political news or commentary": **3.128**
- In **ordine casuale** (seme fisso) e **senza guardare il livello**: la scelta delle testate non può favorire il risultato
- Fino a 200 articoli recenti per testata (feed, sitemap, homepage); si archivia anche l'**HTML grezzo** di ogni articolo

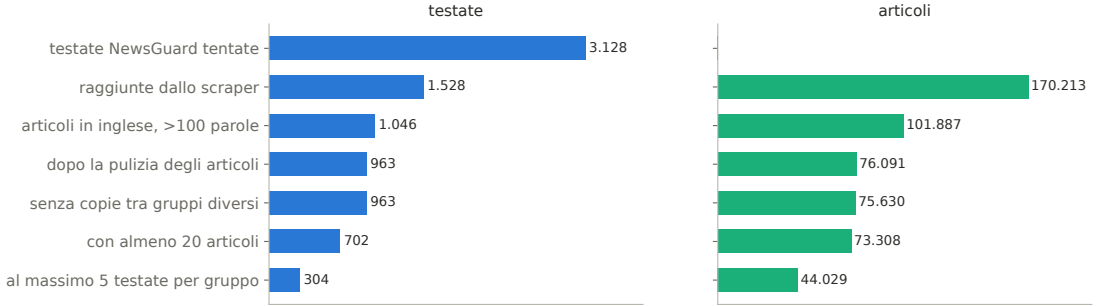
Lo scraping

- **Tutte** le testate NewsGuard in inglese, con un punteggio, il cui argomento **include** "Political news or commentary": **3.128**
- In **ordine casuale** (seme fisso) e **senza guardare il livello**: la scelta delle testate non può favorire il risultato
- Fino a 200 articoli recenti per testata (feed, sitemap, homepage); si archivia anche l'**HTML grezzo** di ogni articolo
- Raggiunte **1.528** testate; molte bloccano lo scraper (una rete di 1.076 siti l_1 quasi tutta, più 176 altre)

Lo scraping

- **Tutte** le testate NewsGuard in inglese, con un punteggio, il cui argomento **include** "Political news or commentary": **3.128**
- In **ordine casuale** (seme fisso) e **senza guardare il livello**: la scelta delle testate non può favorire il risultato
- Fino a 200 articoli recenti per testata (feed, sitemap, homepage); si archivia anche l'**HTML grezzo** di ogni articolo
- Raggiunte **1.528** testate; molte bloccano lo scraper (una rete di 1.076 siti l_1 quasi tutta, più 176 altre)
- Un solo strumento, una sola settimana (13–18 ottobre 2026): un dataset **coerente**

Dalle testate tentate al dataset finale



Ogni passo è un notebook che gira da solo sul server; le etichette NewsGuard si usano solo all'ultimo passo. Il processo è **deterministico**: rieseguito da zero (verifica fatta sulla versione del weekend), ha prodotto file **identici bit per bit**.

Passo 1 — pulire gli articoli (rigoroso, non eccessivo)

Cosa si toglie	**Quanto**	**Perché**
articoli non in inglese, $\leq$ 100 parole, doppioni	170.213 $\rightarrow$ 101.887	stessi filtri del vecchio scraping
articoli pubblicati prima del 2025	-22.055 articoli	archivi vecchi: temi d'epoca, non affidabilità
frasi ripetute in ≥ 3 articoli della testata	5,2% delle parole	firme, promozioni, avvisi: testo della testata, non dell'articolo
titolo e timbro all'inizio del testo	22.641 e 3.919 articoli	dipendono dal CMS: riconoscono il sito
doppioni della stessa testata, testi $<$ 100 parole	-3.723 articoli	lo stesso pezzo due volte

- **Restano** citazioni e paragrafi condivisi con altre testate: fanno parte di come si scrive una notizia

Passo 1 — pulire gli articoli (rigoroso, non eccessivo)

Cosa si toglie	Quanto	Perché
articoli non in inglese, $\leq$ 100 parole, doppioni	170.213 $\rightarrow$ 101.887	stessi filtri del vecchio scraping
articoli pubblicati prima del 2025	-22.055 articoli	archivi vecchi: temi d'epoca, non affidabilità
frasi ripetute in ≥ 3 articoli della testata	5,2% delle parole	firme, promozioni, avvisi: testo della testata, non dell'articolo
titolo e timbro all'inizio del testo	22.641 e 3.919 articoli	dipendono dal CMS: riconoscono il sito
doppioni della stessa testata, testi $<$ 100 parole	-3.723 articoli	lo stesso pezzo due volte

- **Restano** citazioni e paragrafi condivisi con altre testate: fanno parte di come si scrive una notizia
- Le copie tra testate (il 25% degli articoli) si **trovano** qui e si trattano al passo 3

Passo 2 — trovare le reti, senza guardare NewsGuard

Segnale	**Prova di parentela**	**Esempio**
copie	articoli in comune, almeno il 10% della testata più piccola	catene di giornali locali
codici di account	stesso ID di AdSense, Analytics, Tag Manager, Facebook… nell'HTML	FiveZero: 18 siti, un solo AdSense
titolare legale	la privacy policy è la **stessa pagina** su un altro dominio	36 giornali → carpentermedia-group.com
dominio	sottodomini; la homepage reindirizza allo stesso dominio	edizioni di HuffPost
autori	gli stessi autori firmano almeno il 10% degli articoli	la rete da 426 siti

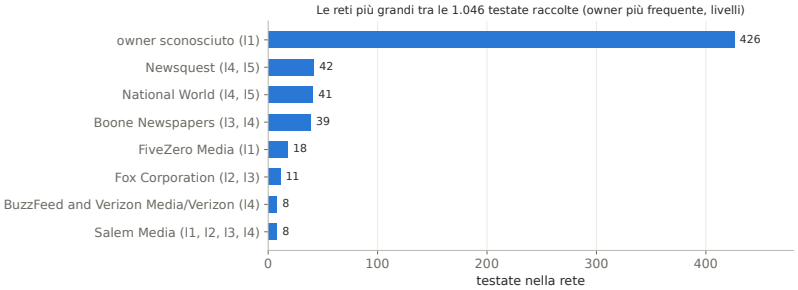
- Una **rete** = testate collegate da almeno un segnale (anche per catena)

Passo 2 — trovare le reti, senza guardare NewsGuard

Segnale	**Prova di parentela**	**Esempio**
copie	articoli in comune, almeno il 10% della testata più piccola	catene di giornali locali
codici di account	stesso ID di AdSense, Analytics, Tag Manager, Facebook… nell'HTML	FiveZero: 18 siti, un solo AdSense
titolare legale	la privacy policy è la **stessa pagina** su un altro dominio	36 giornali → carpentermedia-group.com
dominio	sottodomini; la homepage reindirizza allo stesso dominio	edizioni di HuffPost
autori	gli stessi autori firmano almeno il 10% degli articoli	la rete da 426 siti

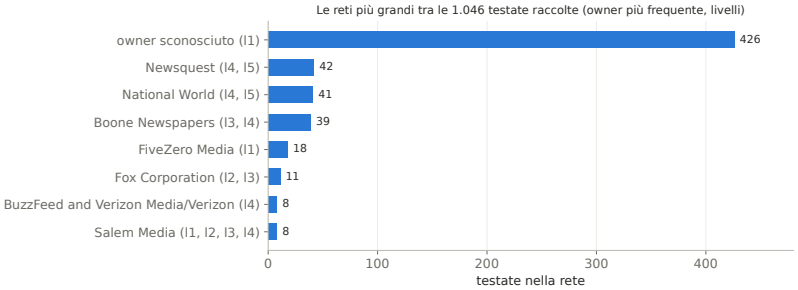
- Una **rete** = testate collegate da almeno un segnale (anche per catena)
- Un pezzo d'agenzia ripreso o un freelance in comune **non bastano**: serve una relazione sistematica

Le reti trovate



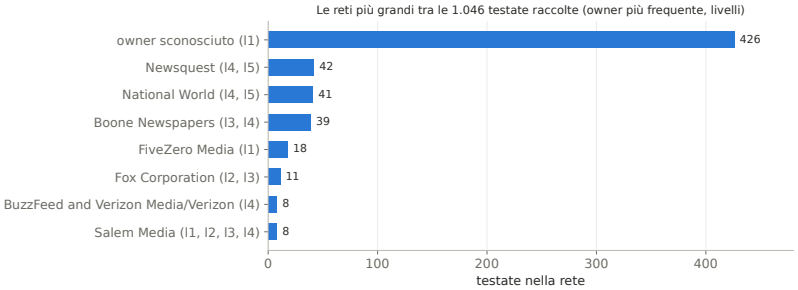
- 725 testate su 1.046 stanno in una rete con altre

Le reti trovate



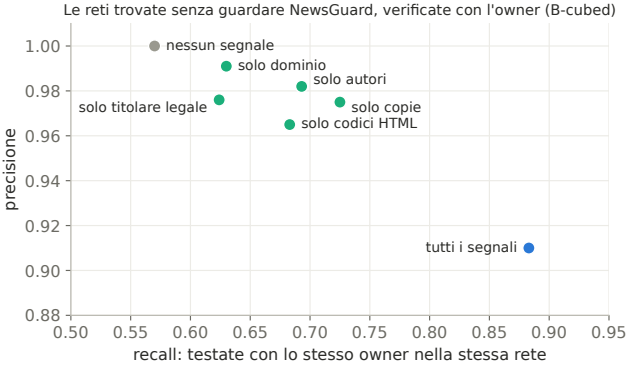
- 725 testate su 1.046 stanno in una rete con altre
- La più grande: **426 siti** $/_1$ con gli stessi autori; per NewsGuard l'owner è **sconosciuto**

Le reti trovate



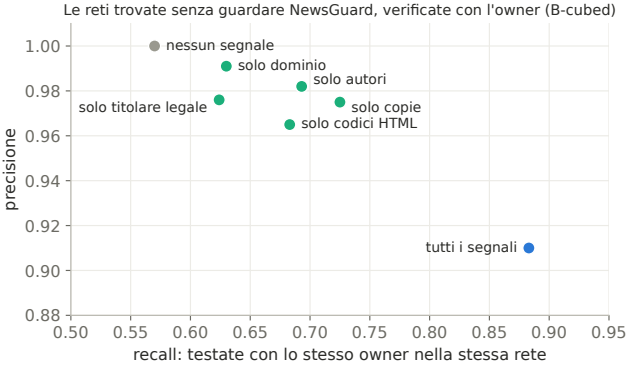
- 725 testate su 1.046 stanno in una rete con altre
- La più grande: **426 siti** l_1 con gli stessi autori; per NewsGuard l'owner è **sconosciuto**
- I giornali di Boone comprati da **Carpenter Media Group**: NewsGuard non lo sa ancora

La verifica con l'owner di NewsGuard



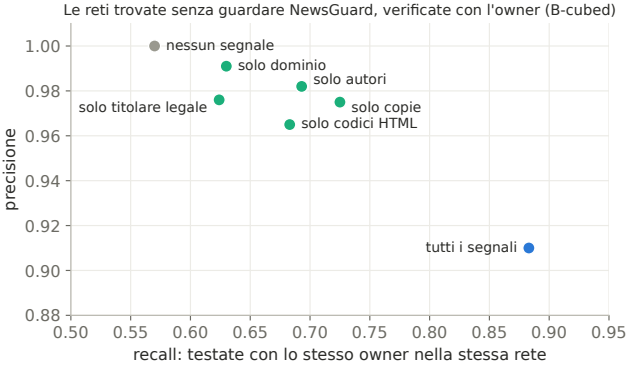
- Ogni segnale da solo è **preciso** ($\geq 0{,}96$) ma ne trova poche

La verifica con l'owner di NewsGuard



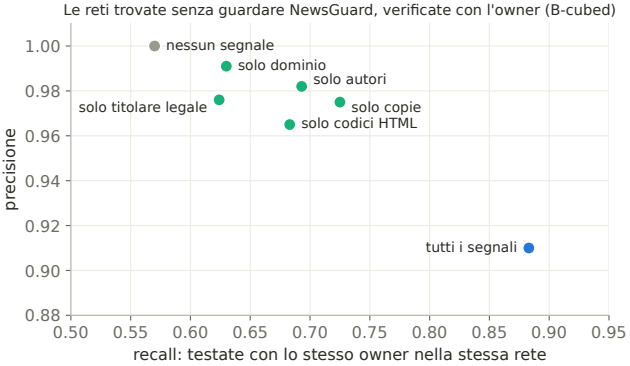
- Ogni segnale da solo è **preciso** ($\geq 0{,}96$) ma ne trova poche
- Insieme: precisione **0,91**, recall **0,88**

La verifica con l'owner di NewsGuard



- Ogni segnale da solo è **preciso** ($\geq$ 0,96) ma ne trova poche
- Insieme: precisione **0,91**, recall **0,88**
- Molti "errori" sono parentele vere che l'owner non riporta (Courier Newsroom e Good Information, Carpenter e Boone)

La verifica con l'owner di NewsGuard

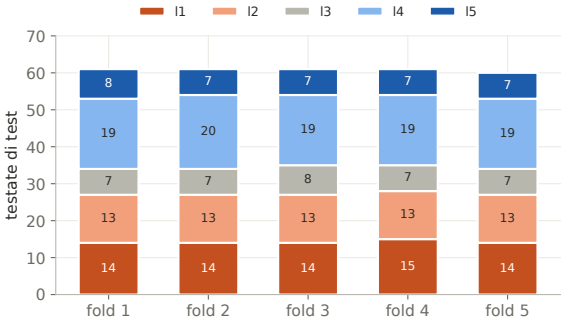


- Ogni segnale da solo è **preciso** ($\geq 0{,}96$) ma ne trova poche
- Insieme: precisione **0,91**, recall **0,88**
- Molti "errori" sono parentele vere che l'owner non riporta (Courier Newsroom e Good Information, Carpenter e Boone)

  Un contributo a sé: le reti si trovano senza i metadati di NewsGuard.

Passo 3 — gruppi, copie e fold

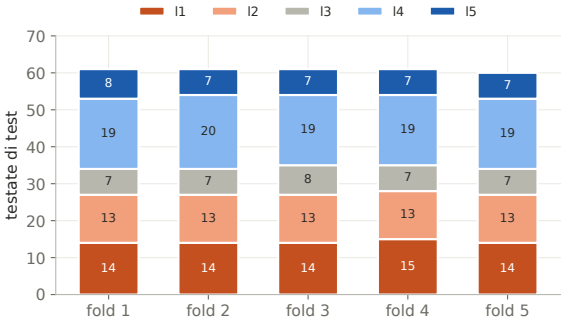
- **Gruppo** = rete trovata **oppure** stesso owner NewsGuard: un gruppo sta tutto nel training o tutto nel test



Ogni fold di test ha lo stesso numero di testate per livello

Passo 3 — gruppi, copie e fold

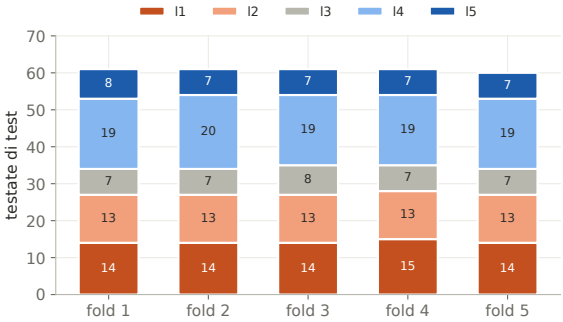
- **Gruppo** = rete trovata **oppure** stesso owner NewsGuard: un gruppo sta tutto nel training o tutto nel test
- Copie tra gruppi diversi: si tiene la più vecchia (−461 articoli)



Ogni fold di test ha lo stesso numero di testate per livello

Passo 3 — gruppi, copie e fold

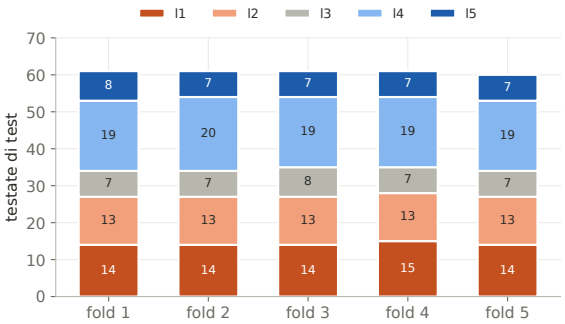
- **Gruppo** = rete trovata **oppure** stesso owner NewsGuard: un gruppo sta tutto nel training o tutto nel test
- Copie tra gruppi diversi: si tiene la più vecchia (-461 articoli)
- Testate con almeno **20 articoli** (voto di maggioranza)



Ogni fold di test ha lo stesso numero di testate per livello

Passo 3 — gruppi, copie e fold

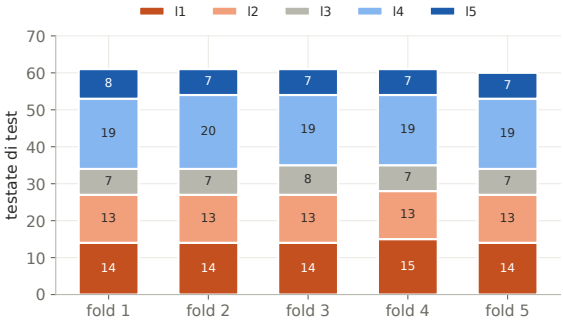
- **Gruppo** = rete trovata **oppure** stesso owner NewsGuard: un gruppo sta tutto nel training o tutto nel test
- Copie tra gruppi diversi: si tiene la più vecchia (-461 articoli)
- Testate con almeno **20 articoli** (voto di maggioranza)
- Al massimo **5 testate per gruppo**, scelte a caso: altrimenti la rete da 426 siti riempirebbe l_1



Ogni fold di test ha lo stesso numero di testate per livello

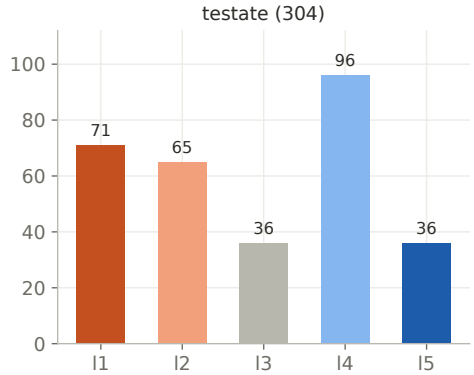
Passo 3 — gruppi, copie e fold

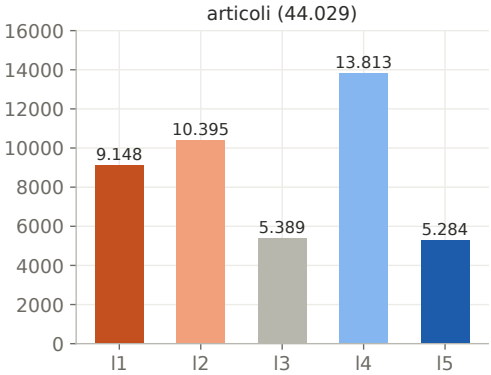
- **Gruppo** = rete trovata **oppure** stesso owner NewsGuard: un gruppo sta tutto nel training o tutto nel test
- Copie tra gruppi diversi: si tiene la più vecchia (-461 articoli)
- Testate con almeno **20 articoli** (voto di maggioranza)
- Al massimo **5 testate per gruppo**, scelte a caso: altrimenti la rete da 426 siti riempirebbe l_1
- 5 fold per gruppo, **stratificati per livello**



Ogni fold di test ha lo stesso numero di testate per livello

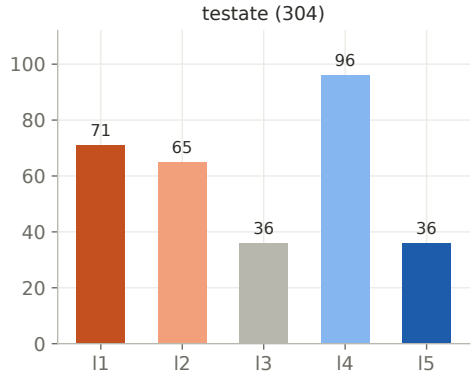
Il dataset finale

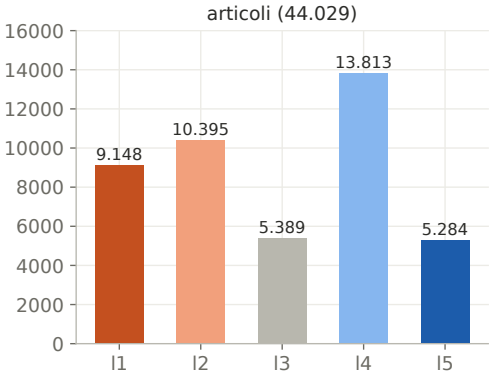




- **304 testate**, **44.029 articoli**, **220 gruppi** indipendenti

Il dataset finale



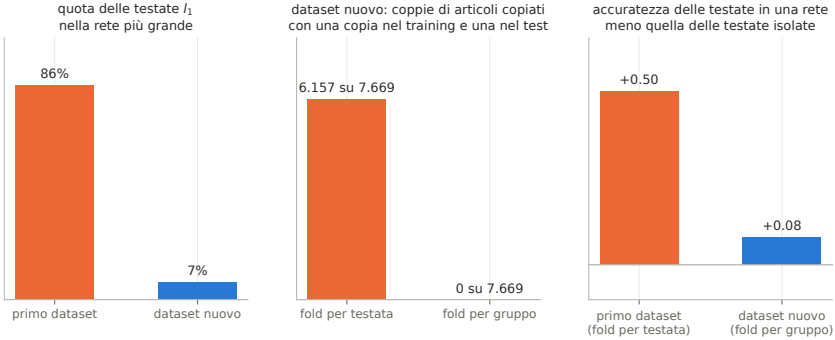


- **304 testate**, **44.029 articoli**, **220 gruppi** indipendenti
- Più del doppio delle testate I_1 indipendenti rispetto al primo dataset (56 gruppi contro 20)

La sporcizia è andata?

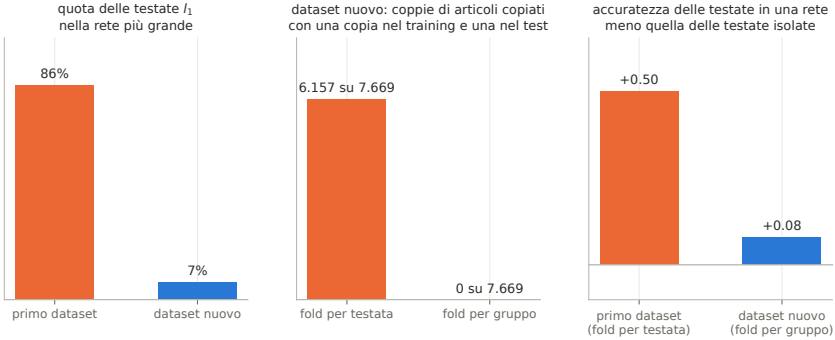
gli stessi controlli, sul dataset nuovo

Gli stessi controlli, prima e dopo



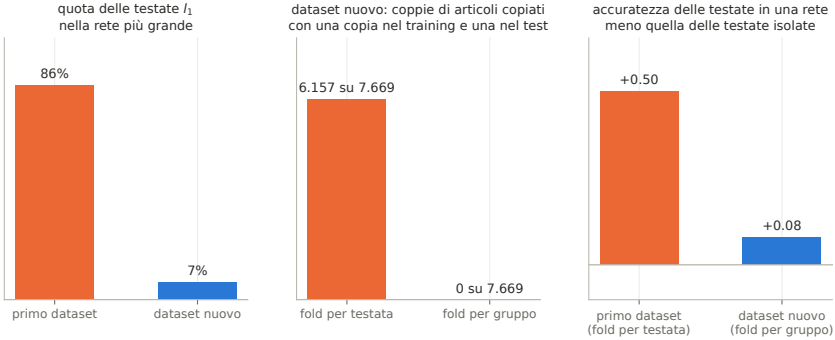
- Le testate l_1 nella rete più grande: dall'**86%** al **7%**

Gli stessi controlli, prima e dopo



- Le testate l_1 nella rete più grande: dall'**86%** al **7%**
- Articoli copiati con una copia nel training e una nel test: **0** (con i fold per testata sarebbero 6.157)

Gli stessi controlli, prima e dopo



- Le testate l_1 nella rete più grande: dall'**86%** al **7%**
- Articoli copiati con una copia nel training e una nel test: **0** (con i fold per testata sarebbero 6.157)
- Il vantaggio delle testate in una rete: da **+0,50** a **+0,08**; e ora le sorelle sono **nello stesso fold**, quindi non può venire dal training

Risultati

TF-IDF contro transformer, sul dataset nuovo

Il protocollo, fissato prima dei risultati

- Valutazione **per testata**, **5 fold per gruppo**; metriche principali: **F1 macro a 5 classi** e **binario** (affidabile $=$ punteggio ≥ 60)

Il protocollo, fissato prima dei risultati

- Valutazione **per testata**, **5 fold per gruppo**; metriche principali: **F1 macro a 5 classi** e **binario** (affidabile $=$ punteggio ≥ 60)
- **Feature**: TF-IDF $+$ regressione logistica, con il parametro C scelto in una **validazione interna** (solo training)

Il protocollo, fissato prima dei risultati

- Valutazione **per testata**, **5 fold per gruppo**; metriche principali: **F1 macro a 5 classi** e **binario** (affidabile = punteggio ≥ 60)
- **Feature**: TF-IDF + regressione logistica, con il parametro C scelto in una **validazione interna** (solo training)
- **ModernBERT** base e large: fine-tuning di 2 epoche, 20 articoli per testata a ogni epoca, pesi di classe, **3 seed** e il loro ensemble

Il protocollo, fissato prima dei risultati

- Valutazione **per testata**, **5 fold per gruppo**; metriche principali: **F1 macro a 5 classi** e **binario** (affidabile = punteggio ≥ 60)
- **Feature**: TF-IDF + regressione logistica, con il parametro C scelto in una **validazione interna** (solo training)
- **ModernBERT** base e large: fine-tuning di 2 epoche, 20 articoli per testata a ogni epoca, pesi di classe, **3 seed** e il loro ensemble
- **Embedding congelati** (e5-large, bge-large) + la stessa regressione logistica, una riga per testata

Il protocollo, fissato prima dei risultati

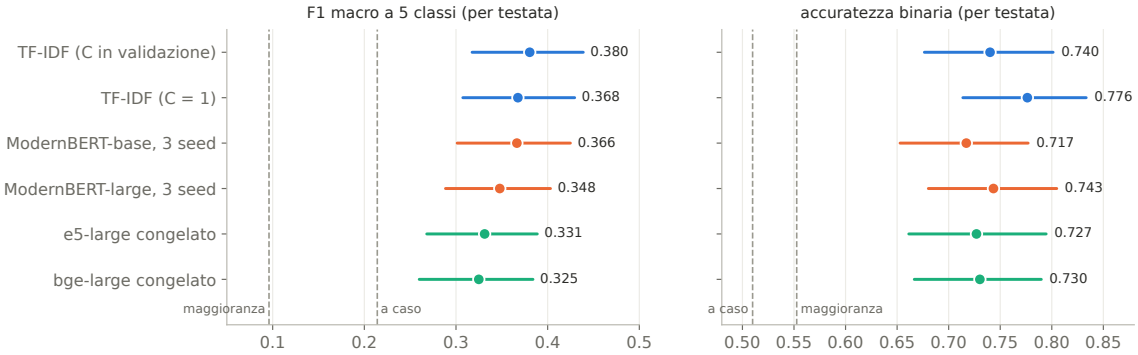
- Valutazione **per testata**, **5 fold per gruppo**; metriche principali: **F1 macro a 5 classi** e **binario** (affidabile = punteggio ≥ 60)
- **Feature**: TF-IDF + regressione logistica, con il parametro C scelto in una **validazione interna** (solo training)
- **ModernBERT** base e large: fine-tuning di 2 epoche, 20 articoli per testata a ogni epoca, pesi di classe, **3 seed** e il loro ensemble
- **Embedding congelati** (e5-large, bge-large) + la stessa regressione logistica, una riga per testata
- Intervalli al 95% con un **bootstrap per gruppo**; si riporta **tutto**, non solo il migliore

I risultati

Modello	F1 macro	acc. 5 cl.	tol. 0,5	tol. 1	binario	F1 bin.
TF-IDF, C in validazione (riferimento)	0,380	0,424	0,597	0,770	0,740	0,740
TF-IDF, $C = 1$	0,368	**0,454**	**0,628**	**0,803**	**0,776**	**0,776**
ModernBERT-base, 3 seed	0,366	0,398	0,589	0,780	0,717	0,717
ModernBERT-large, 3 seed	0,348	0,405	0,602	0,799	0,743	0,742
ModernBERT-base, seed 42	**0,383**	0,424	0,599	0,773	0,720	0,720
e5-large congelato	0,331	0,391	0,589	0,786	0,727	0,723
bge-large congelato	0,325	0,382	0,586	0,789	0,730	0,729
classe di maggioranza	0,096	0,316	0,434	0,553	0,553	0,356
a caso	0,214	0,243	0,388	0,533	0,510	0,505

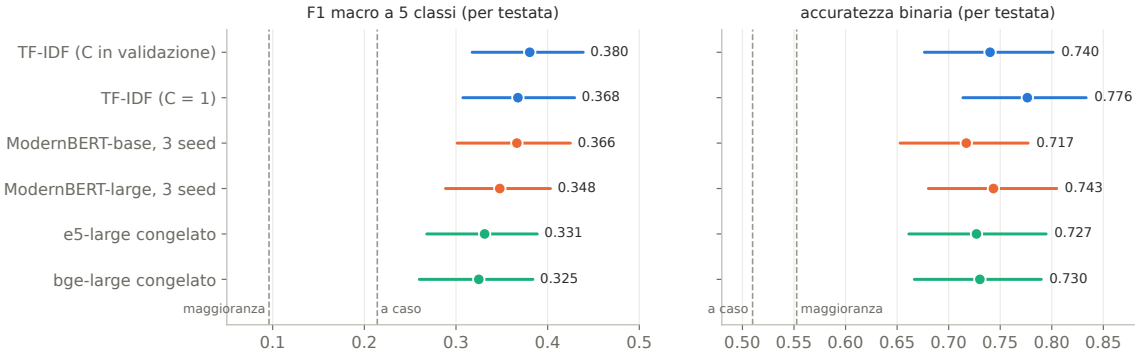
Per testata, 304 testate, fold per gruppo. "3 seed" = media delle probabilità dei tre modelli. Tolerant: un errore di un livello vale mezzo punto (0,5) o un punto (1).

Con gli intervalli



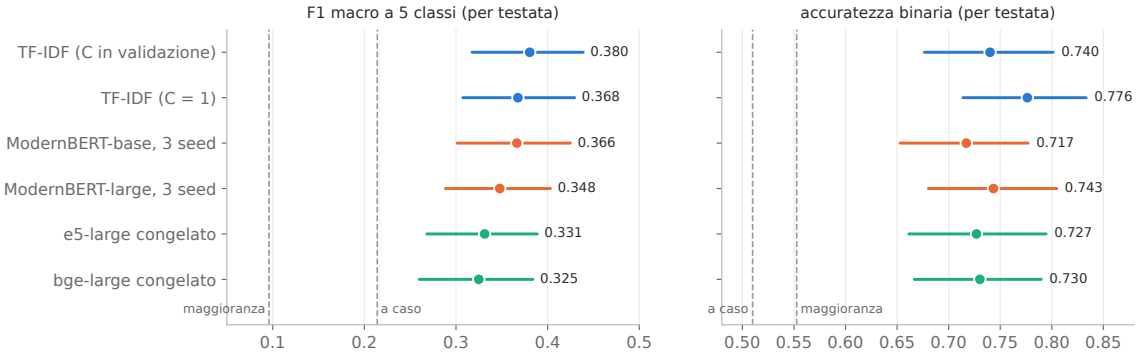
- Tutti i modelli stanno **ben sopra** maggioranza e caso: dal solo testo un segnale c'è

Con gli intervalli



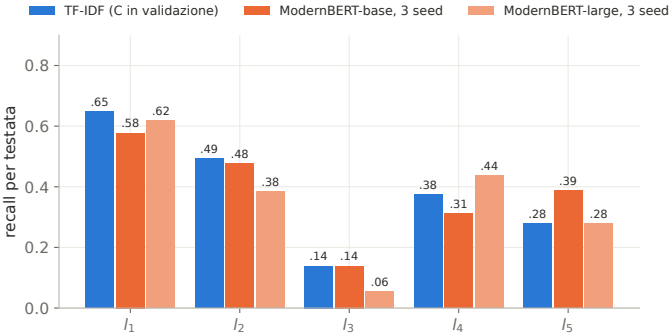
- Tutti i modelli stanno **ben sopra** maggioranza e caso: dal solo testo un segnale c'è
- **Nessun transformer batte il feature** in modo significativo: le differenze stanno tutte negli intervalli

Con gli intervalli



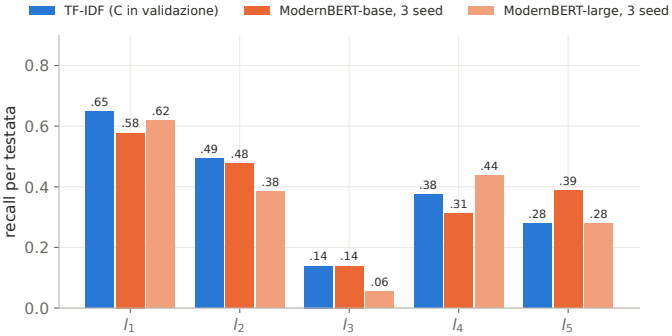
- Tutti i modelli stanno **ben sopra** maggioranza e caso: dal solo testo un segnale c'è
- **Nessun transformer batte il feature** in modo significativo: le differenze stanno tutte negli intervalli
- Il modello più grande e gli embedding congelati **non aiutano**

Chi riconosce cosa



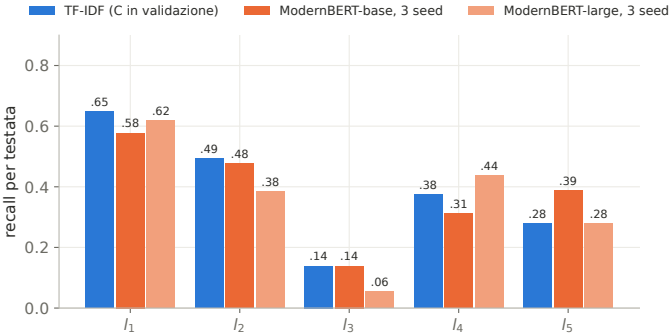
- Il feature riconosce meglio le testate **inaffidabili** (l_1)

Chi riconosce cosa



- Il feature riconosce meglio le testate **inaffidabili** (l_1)
- ModernBERT-base riconosce meglio le **più affidabili** (l_5); il large le l_4

Chi riconosce cosa



- Il feature riconosce meglio le testate **inaffidabili** (l_1)
- ModernBERT-base riconosce meglio le **più affidabili** (l_5); il large le l_4
- Gli errori sono **diversi**: i due modelli sono complementari

E senza la classe l_1?

Modello	F1 macro	Δ F1 [IC 95%]	acc.	tol. 0,5	tol. 1	binario	F1 bin.
TF-IDF, C in validazione	0,358	—	0,408	0,586	0,764	0,712	0,667
TF-IDF, C = 1	0,364	+0,007 [−0,04; +0,05]	**0,451**	0,616	0,781	**0,734**	0,683
ModernBERT-base, 3 seed	0,355	**0,000** [−0,07; +0,07]	0,395	0,607	0,820	0,717	0,673
ModernBERT-base, seed 42	**0,379**	+0,023 [−0,05; +0,09]	0,433	**0,624**	0,815	0,721	**0,688**
ModernBERT-large, 3 seed	0,311	−0,044 [−0,12; +0,02]	0,369	0,590	0,811	0,704	0,637
e5-large congelato	0,304	−0,053	0,361	0,597	**0,833**	0,717	0,634
classe di maggioranza (l_4)	0,146		0,412	0,567	0,721	0,721	0,419

233 testate (l_2–l_5); i modelli scelgono tra l_2 e l_5 (le probabilità salvate, senza riaddestrare). Binario: l_2 contro l_3–l_5.

- Senza l_1 il vantaggio del feature **sparisce**: ModernBERT-base è **pari** (e sulla tolerant 1 meglio)

E senza la classe l_1?

Modello	F1 macro	Δ F1 [IC 95%]	acc.	tol. 0,5	tol. 1	binario	F1 bin.
TF-IDF, C in validazione	0,358	—	0,408	0,586	0,764	0,712	0,667
TF-IDF, C = 1	0,364	+0,007 [−0,04; +0,05]	**0,451**	0,616	0,781	**0,734**	0,683
ModernBERT-base, 3 seed	0,355	**0,000** [−0,07; +0,07]	0,395	0,607	0,820	0,717	0,673
ModernBERT-base, seed 42	**0,379**	+0,023 [−0,05; +0,09]	0,433	**0,624**	0,815	0,721	**0,688**
ModernBERT-large, 3 seed	0,311	−0,044 [−0,12; +0,02]	0,369	0,590	0,811	0,704	0,637
e5-large congelato	0,304	−0,053	0,361	0,597	**0,833**	0,717	0,634
classe di maggioranza (l_4)	0,146		0,412	0,567	0,721	0,721	0,419

233 testate (l_2–l_5); i modelli scelgono tra l_2 e l_5 (le probabilità salvate, senza riaddestrare). Binario: l_2 contro l_3–l_5.

- Senza l_1 il vantaggio del feature **sparisce**: ModernBERT-base è **pari** (e sulla tolerant 1 meglio)
- *Analisi esplorativa, decisa dopo aver visto i risultati*

Perché il feature vince su l_1

Le parole che spingono di più verso l_1 nel modello TF-IDF sono di due tipi:

Contenuto e ideologia

president trump, abortion, kiev, lifesitenews, epoch times, preborn, nomi di stati e regioni

→ segnale vero, ma intrecciato con **temi e orientamento**: un confondente da discutere

Residui dell'estrazione

pic twitter, https, www, com, youtube, utc, qualche firma rimasta nel testo

→ resti di tweet, video e link incorporati: i siti l_1 ne usano molti di più, e il TF-IDF li **conta**

- Il vantaggio **non viene dalle reti**: il feature indovina le l_1 isolate (30/43) e quelle in un gruppo (20/28) allo stesso modo

Perché il feature vince su l_1

Le parole che spingono di più verso l_1 nel modello TF-IDF sono di due tipi:

Contenuto e ideologia

president trump, abortion, kiev, lifesitenews, epoch times, preborn, nomi di stati e regioni

→ segnale vero, ma intrecciato con **temi e orientamento**: un confondente da discutere

Residui dell'estrazione

pic twitter, https, www, com, youtube, utc, qualche firma rimasta nel testo

→ resti di tweet, video e link incorporati: i siti l_1 ne usano molti di più, e il TF-IDF li **conta**

- Il vantaggio **non viene dalle reti**: il feature indovina le l_1 isolate (30/43) e quelle in un gruppo (20/28) allo stesso modo
- I residui di link e contenuti incorporati sono **cornice della pagina**, come titolo e timbro che abbiamo già tolto

Perché è un risultato valido per il paper

- **Il problema**: con le testate divise come al solito i numeri sono gonfiati dalle reti (primo dataset: 0,68 $\rightarrow$ 0,39)

Perché è un risultato valido per il paper

- **Il problema**: con le testate divise come al solito i numeri sono gonfiati dalle reti (primo dataset: 0,68 $\rightarrow$ 0,39)
- **Il metodo**: reti trovate senza NewsGuard, da testo e HTML (precisione 0,91, recall 0,88), e valutazione per gruppo; processo deterministico e replicabile

Perché è un risultato valido per il paper

- **Il problema**: con le testate divise come al solito i numeri sono gonfiati dalle reti (primo dataset: 0,68 $\rightarrow$ 0,39)
- **Il metodo**: reti trovate senza NewsGuard, da testo e HTML (precisione 0,91, recall 0,88), e valutazione per gruppo; processo deterministico e replicabile
- **Il risultato**: con una valutazione onesta il testo da solo dà un segnale **moderato** (F1 0,38, binario 0,74–0,78); i transformer **non battono** un modello lessicale ben fatto, ma sbagliano in modo **diverso**

Perché è un risultato valido per il paper

- **Il problema**: con le testate divise come al solito i numeri sono gonfiati dalle reti (primo dataset: 0,68 $\rightarrow$ 0,39)
- **Il metodo**: reti trovate senza NewsGuard, da testo e HTML (precisione 0,91, recall 0,88), e valutazione per gruppo; processo deterministico e replicabile
- **Il risultato**: con una valutazione onesta il testo da solo dà un segnale **moderato** (F1 0,38, binario 0,74–0,78); i transformer **non battono** un modello lessicale ben fatto, ma sbagliano in modo **diverso**
- **Il dubbio**: parte del vantaggio del feature su l_1 sono residui di link e tweet incorporati

Da decidere insieme

1. Una **regola di pulizia** in più, uguale per tutti i modelli: togliere i resti di link e contenuti incorporati, poi rifare pulizia e classificazione (circa 7 ore sul server)

Da decidere insieme

1. Una **regola di pulizia** in più, uguale per tutti i modelli: togliere i resti di link e contenuti incorporati, poi rifare pulizia e classificazione (circa 7 ore sul server)
2. **Combinare** feature e transformer, con la combinazione scelta in validazione interna: sbagliano su testate diverse

Da decidere insieme

1. Una **regola di pulizia** in più, uguale per tutti i modelli: togliere i resti di link e contenuti incorporati, poi rifare pulizia e classificazione (circa 7 ore sul server)
2. **Combinare** feature e transformer, con la combinazione scelta in validazione interna: sbagliano su testate diverse
3. Come presentare il **confondente** tema/orientamento politico

In fondo: i tentativi messi da parte

ognuno ha insegnato qualcosa

I tentativi prima di quello finale

Tentativo	**Perché è stato messo da parte**
Primo dataset (IrForGood, 439 testate)	una rete di 131 siti fa l'86% di I_1; pulito resta troppo piccolo
Nuovo scraping + pagine del sito (272 testate)	il feature con le pagine arrivava a 0,60, ma i gruppi trovati solo dalle copie non separavano le reti di proprietà (con l'owner: 0,36); pagine about troppo sporche
Solo articoli, solo argomento "Political news" esatto (193 testate)	tutti i modelli poco sopra la maggioranza: troppe poche testate
Due scraping uniti (vecchio + nuovo, 269 testate)	l'origine è legata all'etichetta (l'89% degli articoli I_1 viene dal nuovo scraping): epoche e strumenti diversi

- Tutto archiviato in `EsperimentiPreliminari/`, con il motivo di ogni scelta