Stato dei lavori

Web Science 2027: cosa abbiamo fatto e cosa faremo

John Bianchi

IMT Lucca & IIT-CNR Pisa

Il primo dataset

dai transformer del paper a un classificatore più semplice

Il punto di partenza: i transformer del paper

- Il dataset di IrForGood: **439 testate**, **19.476 articoli**; 5 fold, nel test solo testate **mai viste** in addestramento

Il punto di partenza: i transformer del paper

- Il dataset di IrForGood: **439 testate**, **19.476 articoli**; 5 fold, nel test solo testate **mai viste** in addestramento
- **Per articolo**: accuratezza intorno a **0,60** (da 0,58 di BERT a 0,61 di Mistral), F1 macro 0,52–0,55

Il punto di partenza: i transformer del paper

- Il dataset di IrForGood: **439 testate**, **19.476 articoli**; 5 fold, nel test solo testate **mai viste** in addestramento
- **Per articolo**: accuratezza intorno a **0,60** (da 0,58 di BERT a 0,61 di Mistral), F1 macro 0,52–0,55
- **Per testata** (voto di maggioranza dei suoi articoli): accuratezza fino a **0,69** (RoBERTa; Mistral 0,68), tolerant 1 fino a 0,88

Il punto di partenza: i transformer del paper

- Il dataset di IrForGood: **439 testate**, **19.476 articoli**; 5 fold, nel test solo testate **mai viste** in addestramento
- **Per articolo**: accuratezza intorno a **0,60** (da 0,58 di BERT a 0,61 di Mistral), F1 macro 0,52–0,55
- **Per testata** (voto di maggioranza dei suoi articoli): accuratezza fino a **0,69** (RoBERTa; Mistral 0,68), tolerant 1 fino a 0,88

Modelli da 110 milioni a 24 miliardi di parametri, tutti più o meno allo stesso livello.

Un classificatore a feature fa lo stesso, se non meglio

- **TF-IDF**: ogni articolo diventa l'elenco delle sue parole (e coppie di parole), pesate per quanto sono rare; sopra, una **regressione logistica**. Nessuna rete neurale: si addestra in un minuto

Un classificatore a feature fa lo stesso, se non meglio

- **TF-IDF**: ogni articolo diventa l'elenco delle sue parole (e coppie di parole), pesate per quanto sono rare; sopra, una **regressione logistica**. Nessuna rete neurale: si addestra in un minuto
- Sugli **stessi fold** del paper:

Un classificatore a feature fa lo stesso, se non meglio

- **TF-IDF**: ogni articolo diventa l'elenco delle sue parole (e coppie di parole), pesate per quanto sono rare; sopra, una **regressione logistica**. Nessuna rete neurale: si addestra in un minuto
- Sugli **stessi fold** del paper:

	per articolo		**per testata**	
	accuratezza	F1 macro	accuratezza	tolerant 1
migliore dei 4 transformer (misura per misura)	0,61	0,55	0,69	0,88
TF-IDF + regressione logistica	0,58	0,52	**0,68**	**0,88**

Un classificatore a feature fa lo stesso, se non meglio

- **TF-IDF**: ogni articolo diventa l'elenco delle sue parole (e coppie di parole), pesate per quanto sono rare; sopra, una **regressione logistica**. Nessuna rete neurale: si addestra in un minuto
- Sugli **stessi fold** del paper:

	per articolo		**per testata**	
	accuratezza	F1 macro	accuratezza	tolerant 1
migliore dei 4 transformer (misura per misura)	0,61	0,55	0,69	0,88
TF-IDF + regressione logistica	0,58	0,52	**0,68**	**0,88**

- Come fa un modello che **conta parole** ad andare come Mistral da 24 miliardi di parametri?

Un classificatore a feature fa lo stesso, se non meglio

- **TF-IDF**: ogni articolo diventa l'elenco delle sue parole (e coppie di parole), pesate per quanto sono rare; sopra, una **regressione logistica**. Nessuna rete neurale: si addestra in un minuto
- Sugli **stessi fold** del paper:

	per articolo		**per testata**	
	accuratezza	F1 macro	accuratezza	tolerant 1
migliore dei 4 transformer (misura per misura)	0,61	0,55	0,69	0,88
TF-IDF + regressione logistica	0,58	0,52	**0,68**	**0,88**

- Come fa un modello che **conta parole** ad andare come Mistral da 24 miliardi di parametri?
- Per capirlo ho guardato **dentro il dataset**

Quanto si somigliano due articoli? (1) I pezzetti di 5 parole

- Il testo si **normalizza**: minuscole, niente punteggiatura, i numeri diventano #

Quanto si somigliano due articoli? (1) I pezzetti di 5 parole

- Il testo si **normalizza**: minuscole, niente punteggiatura, i numeri diventano #
- Poi si spezza in tutti i **pezzetti di 5 parole consecutive**:

Quanto si somigliano due articoli? (1) I pezzetti di 5 parole

- Il testo si **normalizza**: minuscole, niente punteggiatura, i numeri diventano #
- Poi si spezza in tutti i **pezzetti di 5 parole consecutive**:

  `there was a single gas station in cities across phillips county`

  → `[there was a single gas]` `[was a single gas station]` `[a single gas station in]` ...

Quanto si somigliano due articoli? (1) I pezzetti di 5 parole

- Il testo si **normalizza**: minuscole, niente punteggiatura, i numeri diventano #
- Poi si spezza in tutti i **pezzetti di 5 parole consecutive**:

  `there was a single gas station in cities across phillips county`

  → `[there was a single gas]` `[was a single gas station]` `[a single gas station in]` ...

- **Somiglianza di Jaccard** tra due articoli A e B:

$$J(A,B) = \frac{\text{pezzetti in comune}}{\text{pezzetti di tutti e due, contati una volta}} = \frac{|A \cap B|}{|A \cup B|}$$

Quanto si somigliano due articoli? (1) I pezzetti di 5 parole

- Il testo si **normalizza**: minuscole, niente punteggiatura, i numeri diventano #
- Poi si spezza in tutti i **pezzetti di 5 parole consecutive**:

  `there was a single gas station in cities across phillips county`

  → `[there was a single gas]` `[was a single gas station]` `[a single gas station in]` ...

- **Somiglianza di Jaccard** tra due articoli A e B:

$$J(A,B) = \frac{\text{pezzetti in comune}}{\text{pezzetti di tutti e due, contati una volta}} = \frac{|A \cap B|}{|A \cup B|}$$

- $J = 0$: niente in comune; $J = 1$: lo stesso testo. $J \geq 0{,}5$: più di metà dei pezzetti in comune, gli articoli sono **quasi uguali** (non per forza identici)

Quanto si somigliano due articoli? (2) Un esempio vero

ncindianananews.com

Federal Energy Regulatory Commission (FERC)
Commissioner Mark C. Christie | www.ferc.gov

There was a single gas station in cities across **White County** selling premium gas at the lowest price of **$3.81** per gallon . . .

savannahstandard.com

Federal Energy Regulatory Commission (FERC)
Commissioner Mark C. Christie | www.ferc.gov

There were two gas stations in cities across **Bulloch County** selling premium gas at the lowest price of **$3.79** per gallon . . .

- Due siti diversi, lo **stesso articolo-modello**: cambiano solo la contea e i numeri

Quanto si somigliano due articoli? (2) Un esempio vero

ncindiananews.com

Federal Energy Regulatory Commission (FERC) Commissioner Mark C. Christie | www.ferc.gov

There was a single gas station in cities across **White County** selling premium gas at the lowest price of **$3.81** per gallon . . .

savannahstandard.com

Federal Energy Regulatory Commission (FERC) Commissioner Mark C. Christie | www.ferc.gov

There were two gas stations in cities across **Bulloch County** selling premium gas at the lowest price of **$3.79** per gallon . . .

- Due siti diversi, lo **stesso articolo-modello**: cambiano solo la contea e i numeri
- Sono articoli **generati in serie** da una rete di siti locali: il testo è quasi tutto uguale (J tra 0,6 e 1)

Quanto si somigliano due articoli? (2) Un esempio vero

ncindiananews.com

Federal Energy Regulatory Commission (FERC)
Commissioner Mark C. Christie | www.ferc.gov

There was a single gas station in cities across **White County** selling premium gas at the lowest price of **$3.81** per gallon . . .

savannahstandard.com

Federal Energy Regulatory Commission (FERC)
Commissioner Mark C. Christie | www.ferc.gov

There were two gas stations in cities across **Bulloch County** selling premium gas at the lowest price of **$3.79** per gallon . . .

- Due siti diversi, lo **stesso articolo-modello**: cambiano solo la contea e i numeri
- Sono articoli **generati in serie** da una rete di siti locali: il testo è quasi tutto uguale (J tra 0,6 e 1)
- Un classificatore che ha visto uno di questi nel training riconosce subito l'altro nel test

Quanto si somigliano due articoli? (3) Confrontarli tutti

- 19.476 articoli sono quasi **190 milioni di coppie**: calcolare J esatto su tutte, testo contro testo, è **impossibile** in tempi ragionevoli

Quanto si somigliano due articoli? (3) Confrontarli tutti

- 19.476 articoli sono quasi **190 milioni di coppie**: calcolare J esatto su tutte, testo contro testo, è **impossibile** in tempi ragionevoli
- **MinHash** e **LSH** servono a questo: calcolano la somiglianza di Jaccard in modo **fattibile**, accettando una piccola **approssimazione**

Quanto si somigliano due articoli? (3) Confrontarli tutti

- 19.476 articoli sono quasi **190 milioni di coppie**: calcolare J esatto su tutte, testo contro testo, è **impossibile** in tempi ragionevoli
- **MinHash** e **LSH** servono a questo: calcolano la somiglianza di Jaccard in modo **fattibile**, accettando una piccola **approssimazione**

  MinHash riassume ogni articolo in un'**impronta** corta da cui si stima J; LSH propone solo le coppie che **probabilmente** si somigliano

Quanto si somigliano due articoli? (3) Confrontarli tutti

- 19.476 articoli sono quasi **190 milioni di coppie**: calcolare J esatto su tutte, testo contro testo, è **impossibile** in tempi ragionevoli
- **MinHash** e **LSH** servono a questo: calcolano la somiglianza di Jaccard in modo **fattibile**, accettando una piccola **approssimazione**

  MinHash riassume ogni articolo in un'**impronta** corta da cui si stima J; LSH propone solo le coppie che **probabilmente** si somigliano

  È la tecnica standard per togliere i duplicati dai dati di addestramento dei modelli linguistici.

Quanto si somigliano due articoli? (3) Confrontarli tutti

- 19.476 articoli sono quasi **190 milioni di coppie**: calcolare J esatto su tutte, testo contro testo, è **impossibile** in tempi ragionevoli
- **MinHash** e **LSH** servono a questo: calcolano la somiglianza di Jaccard in modo **fattibile**, accettando una piccola **approssimazione**

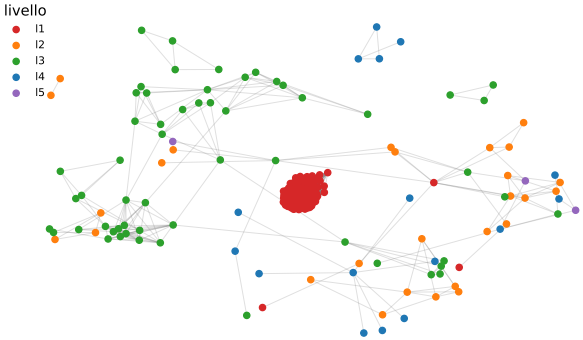
  MinHash riassume ogni articolo in un'**impronta** corta da cui si stima J; LSH propone solo le coppie che **probabilmente** si somigliano

  È la tecnica standard per togliere i duplicati dai dati di addestramento dei modelli linguistici.
- Risultato: **1.557** articoli hanno una copia **identica** su un'altra testata; **4.740** (il **24%**) una copia **quasi uguale** ($J \geq 0{,}5$)

Dagli articoli alle reti di testate

- Due testate sono **collegate** se hanno **almeno 2 articoli** quasi uguali in comune (una sola copia può essere un pezzo ripreso)

Reti di testate identificate dal testo condiviso



236 testate in rete · 203 indipendenti (senza legami, non mostrate)

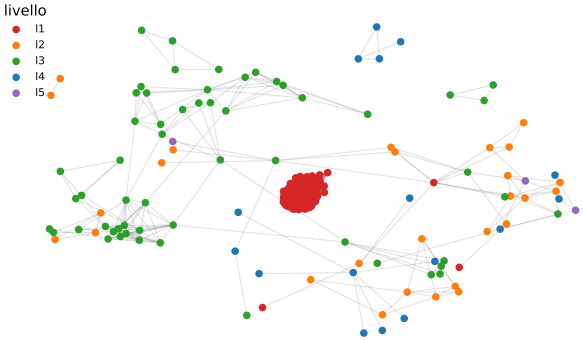
Un punto = una testata; una linea = almeno 2 articoli quasi uguali.

La distanza nel disegno non misura nulla.

Dagli articoli alle reti di testate

- Due testate sono **collegate** se hanno **almeno 2 articoli** quasi uguali in comune (una sola copia può essere un pezzo ripreso)
- Una **rete** = testate collegate anche **a catena**: A–B e B–C ⇒ A, B, C nella stessa rete

Reti di testate identificate dal testo condiviso



236 testate in rete · 203 indipendenti (senza legami, non mostrate)

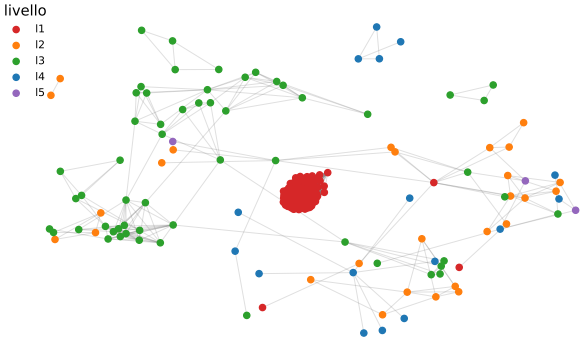
Un punto = una testata; una linea = almeno 2 articoli quasi uguali.

La distanza nel disegno non misura nulla.

Dagli articoli alle reti di testate

- Due testate sono **collegate** se hanno **almeno 2 articoli** quasi uguali in comune (una sola copia può essere un pezzo ripreso)
- Una **rete** = testate collegate anche **a catena**: A–B e B–C ⇒ A, B, C nella stessa rete
- **10 reti**, con dentro **236 testate su 439**; la più grande ha **131 siti**

Reti di testate identificate dal testo condiviso



236 testate in rete · 203 indipendenti (senza legami, non mostrate)

Un punto = una testata; una linea = almeno 2 articoli quasi uguali.

La distanza nel disegno non misura nulla.

Chi c'è dietro una rete: l'owner di NewsGuard

- Per ogni sito NewsGuard indica anche il **proprietario** (campo **Owner**): per esempio Metric Media LLC, Boone Newspapers, Salem Media Group

Chi c'è dietro una rete: l'owner di NewsGuard

- Per ogni sito NewsGuard indica anche il **proprietario** (campo **Owner**): per esempio Metric Media LLC, Boone Newspapers, Salem Media Group
- Le reti le ho trovate **solo dal testo**; l'owner l'ho usato **dopo**, per controllarle:

Chi c'è dietro una rete: l'owner di NewsGuard

- Per ogni sito NewsGuard indica anche il **proprietario** (campo **Owner**): per esempio Metric Media LLC, Boone Newspapers, Salem Media Group
- Le reti le ho trovate **solo dal testo**; l'owner l'ho usato **dopo**, per controllarle:

  precisione 0,93: le testate di una stessa rete hanno quasi sempre lo stesso proprietario

Chi c'è dietro una rete: l'owner di NewsGuard

- Per ogni sito NewsGuard indica anche il **proprietario** (campo **Owner**): per esempio Metric Media LLC, Boone Newspapers, Salem Media Group
- Le reti le ho trovate **solo dal testo**; l'owner l'ho usato **dopo**, per controllarle:

  precisione 0,93: le testate di una stessa rete hanno quasi sempre lo stesso proprietario

  recall 0,87: le testate di uno stesso proprietario finiscono quasi sempre nella stessa rete

Chi c'è dietro una rete: l'owner di NewsGuard

- Per ogni sito NewsGuard indica anche il **proprietario** (campo **Owner**): per esempio Metric Media LLC, Boone Newspapers, Salem Media Group
- Le reti le ho trovate **solo dal testo**; l'owner l'ho usato **dopo**, per controllarle:

  precisione 0,93: le testate di una stessa rete hanno quasi sempre lo stesso proprietario

  recall 0,87: le testate di uno stesso proprietario finiscono quasi sempre nella stessa rete
- La rete da 131 siti: **tutti di Metric Media LLC**, tutti con lo **stesso punteggio** NewsGuard (32): siti di "notizie locali" che pubblicano articoli-modello come quello di prima

Chi c'è dietro una rete: l'owner di NewsGuard

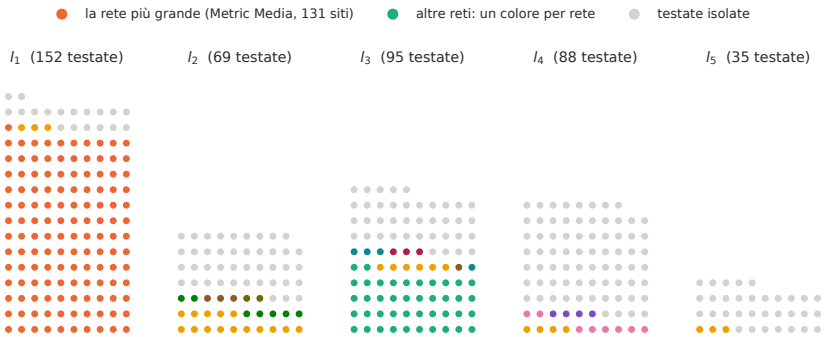
- Per ogni sito NewsGuard indica anche il **proprietario** (campo **Owner**): per esempio Metric Media LLC, Boone Newspapers, Salem Media Group
- Le reti le ho trovate **solo dal testo**; l'owner l'ho usato **dopo**, per controllarle:

  precisione 0,93: le testate di una stessa rete hanno quasi sempre lo stesso proprietario

  recall 0,87: le testate di uno stesso proprietario finiscono quasi sempre nella stessa rete
- La rete da 131 siti: **tutti di Metric Media LLC**, tutti con lo **stesso punteggio** NewsGuard (32): siti di "notizie locali" che pubblicano articoli-modello come quello di prima

  Quindi: stessa rete = testo quasi uguale (non sempre identico) e, quasi sempre, stesso proprietario.

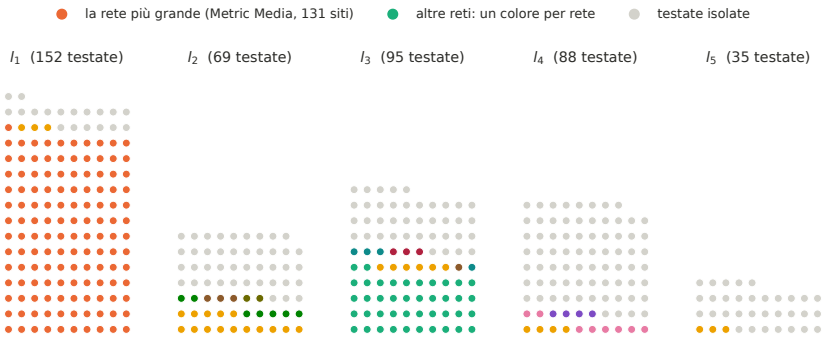
Le reti, livello per livello



Un pallino = una testata; un colore = una rete.

- l_1: **131 testate su 152** sono la stessa rete di Metric Media; solo **20** sono isolate

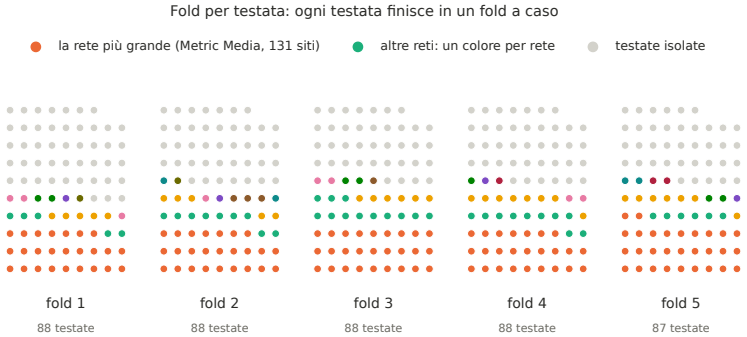
Le reti, livello per livello



Un pallino = una testata; un colore = una rete.

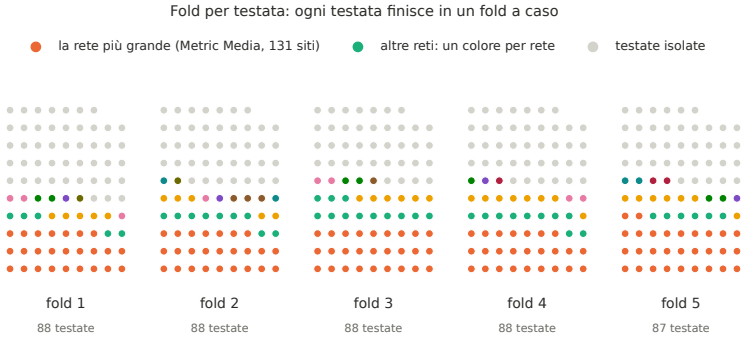
- l_1: **131 testate su 152** sono la stessa rete di Metric Media; solo **20** sono isolate
- l_3: molte catene di giornali locali; l_4 e l_5: quasi tutte isolate

Fold per testata: le sorelle stanno da tutte e due le parti



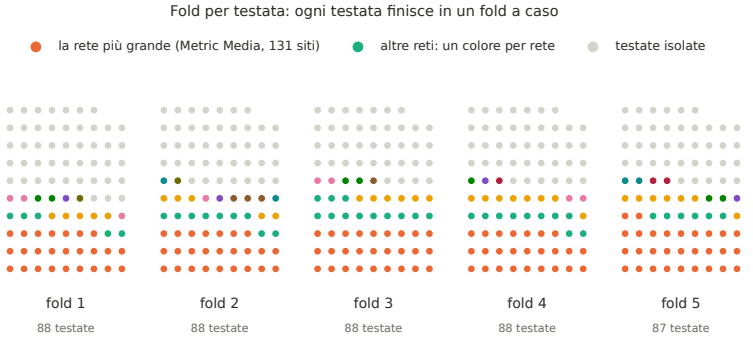
- Come nel paper: ogni testata va in un fold **a caso**, e i 131 siti di Metric Media si spargono in **tutti e 5** i fold (25–29 per fold)

Fold per testata: le sorelle stanno da tutte e due le parti



- Come nel paper: ogni testata va in un fold **a caso**, e i 131 siti di Metric Media si spargono in **tutti e 5** i fold (25–29 per fold)
- Lo stesso per le altre reti: ogni colore compare in più fold, in media **3,5**

Fold per testata: le sorelle stanno da tutte e due le parti



- Come nel paper: ogni testata va in un fold **a caso**, e i 131 siti di Metric Media si spargono in **tutti e 5** i fold (25–29 per fold)
- Lo stesso per le altre reti: ogni colore compare in più fold, in media **3,5**
- Quando il fold 1 è il test, gli altri **106 siti** di Metric Media sono nel training: il modello ha già visto gli stessi articoli-modello

Ripulire il primo dataset: cosa ho tolto e come

	Regola	Con quale indice	Quanto
1	lo stesso articolo su più testate: se ne tiene **una copia**	$J \geq 0{,}9$ (stesso testo con poche parole cambiate)	-1.835 articoli
2	copie rimaste tra **reti diverse**: si tolgono tutte e due	$J \geq 0{,}5$	-46 articoli
3	**paragrafi identici** in almeno 2 testate (didascalie, appelli, avvisi): tolti **dal testo**, l'articolo resta	uguaglianza del paragrafo normalizzato	5,5% delle parole
4	articoli rimasti con **100 parole o meno**	—	-1.325 articoli

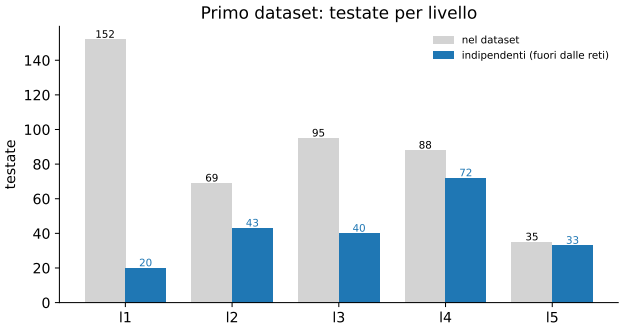
- Verifica: coppie di articoli quasi uguali tra reti diverse, rifacendo il MinHash sul testo pulito: da **1,45 milioni** a **0**

Ripulire il primo dataset: cosa ho tolto e come

	Regola	Con quale indice	Quanto
1	lo stesso articolo su più testate: se ne tiene **una copia**	$J \geq 0{,}9$ (stesso testo con poche parole cambiate)	-1.835 articoli
2	copie rimaste tra **reti diverse**: si tolgono tutte e due	$J \geq 0{,}5$	-46 articoli
3	**paragrafi identici** in almeno 2 testate (didascalie, appelli, avvisi): tolti **dal testo**, l'articolo resta	uguaglianza del paragrafo normalizzato	5,5% delle parole
4	articoli rimasti con **100 parole o meno**	—	-1.325 articoli

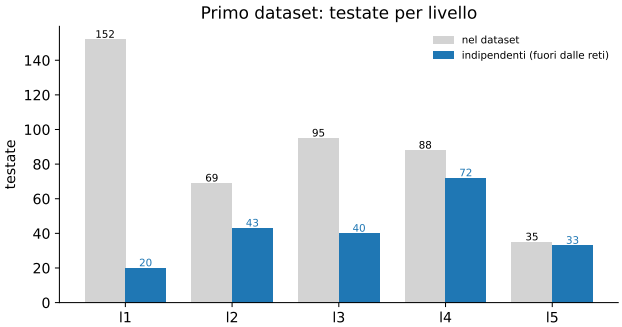
- Verifica: coppie di articoli quasi uguali tra reti diverse, rifacendo il MinHash sul testo pulito: da **1,45 milioni** a **0**
- Le regole **non guardano le etichette**: si applicano uguali a tutti i livelli

Pulito e valutato per gruppo, il primo dataset non basta



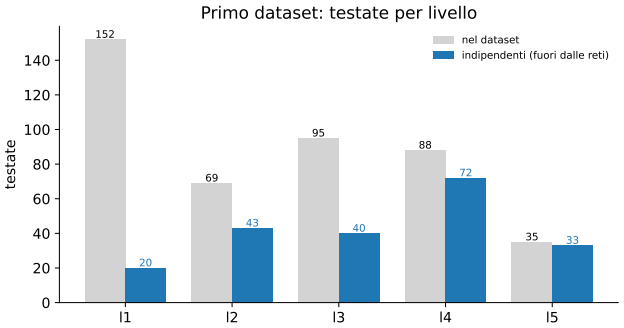
- TF-IDF sul dataset pulito, fold per gruppo: **0,40** di accuratezza, **0,33** di F1 macro

Pulito e valutato per gruppo, il primo dataset non basta



- TF-IDF sul dataset pulito, fold per gruppo: **0,40** di accuratezza, **0,33** di F1 macro
- Testate **indipendenti** (fuori dalle reti): solo **20** l_1; il resto di l_1 è una rete sola, che conta come **un** esempio

Pulito e valutato per gruppo, il primo dataset non basta



- TF-IDF sul dataset pulito, fold per gruppo: **0,40** di accuratezza, **0,33** di F1 macro
- Testate **indipendenti** (fuori dalle reti): solo **20** l_1; il resto di l_1 è una rete sola, che conta come **un** esempio
- Troppo poche testate indipendenti per livello: per andare avanti serve un **dataset nuovo**, più grande, pulito con lo stesso rigore

Il nuovo dataset

come l'ho costruito, passo per passo

Lo scraping: due giri nella stessa settimana

- **13 ottobre**, primo giro: le testate NewsGuard in inglese, con un punteggio, il cui argomento è **esattamente** “Political news or commentary”: **1.921**

Lo scraping: due giri nella stessa settimana

- **13 ottobre**, primo giro: le testate NewsGuard in inglese, con un punteggio, il cui argomento è **esattamente** "Political news or commentary": **1.921**
- Non bastano: molti siti **bloccano** lo scraper, molti articoli **sporchi** si tolgono, e il tetto di **5 testate per gruppo** (rete o stesso owner, passo 3) ne scarta tante. Serve il dataset **più grande possibile**

Lo scraping: due giri nella stessa settimana

- **13 ottobre**, primo giro: le testate NewsGuard in inglese, con un punteggio, il cui argomento è **esattamente** "Political news or commentary": **1.921**
- Non bastano: molti siti **bloccano** lo scraper, molti articoli **sporchi** si tolgono, e il tetto di **5 testate per gruppo** (rete o stesso owner, passo 3) ne scarta tante. Serve il dataset **più grande possibile**
- **18 ottobre**, secondo giro, **stesso scraper** e stessi parametri: le testate il cui argomento **contiene** "Political news or commentary" insieme ad altri: **+1.207**. Nessuna testata in comune: gli articoli dei due giri si **sommano**

Lo scraping: due giri nella stessa settimana

- **13 ottobre**, primo giro: le testate NewsGuard in inglese, con un punteggio, il cui argomento è **esattamente** "Political news or commentary": **1.921**
- Non bastano: molti siti **bloccano** lo scraper, molti articoli **sporchi** si tolgono, e il tetto di **5 testate per gruppo** (rete o stesso owner, passo 3) ne scarta tante. Serve il dataset **più grande possibile**
- **18 ottobre**, secondo giro, **stesso scraper** e stessi parametri: le testate il cui argomento **contiene** "Political news or commentary" insieme ad altri: **+1.207**. Nessuna testata in comune: gli articoli dei due giri si **sommano**
- In tutto **3.128** testate tentate, **1.528** raggiunte (bloccata quasi tutta una rete di 1.076 siti l_1, più 176 altre)

Lo scraping: due giri nella stessa settimana

- **13 ottobre**, primo giro: le testate NewsGuard in inglese, con un punteggio, il cui argomento è **esattamente** "Political news or commentary": **1.921**
- Non bastano: molti siti **bloccano** lo scraper, molti articoli **sporchi** si tolgono, e il tetto di **5 testate per gruppo** (rete o stesso owner, passo 3) ne scarta tante. Serve il dataset **più grande possibile**
- **18 ottobre**, secondo giro, **stesso scraper** e stessi parametri: le testate il cui argomento **contiene** "Political news or commentary" insieme ad altri: **+1.207**. Nessuna testata in comune: gli articoli dei due giri si **sommano**
- In tutto **3.128** testate tentate, **1.528** raggiunte (bloccata quasi tutta una rete di 1.076 siti l_1, più 176 altre)
- In **ordine casuale** e **senza guardare il livello**; fino a 200 articoli recenti per testata, con l'**HTML grezzo**

Lo scraping: due giri nella stessa settimana

- **13 ottobre**, primo giro: le testate NewsGuard in inglese, con un punteggio, il cui argomento è **esattamente** "Political news or commentary": **1.921**
- Non bastano: molti siti **bloccano** lo scraper, molti articoli **sporchi** si tolgono, e il tetto di **5 testate per gruppo** (rete o stesso owner, passo 3) ne scarta tante. Serve il dataset **più grande possibile**
- **18 ottobre**, secondo giro, **stesso scraper** e stessi parametri: le testate il cui argomento **contiene** "Political news or commentary" insieme ad altri: **+1.207**. Nessuna testata in comune: gli articoli dei due giri si **sommano**
- In tutto **3.128** testate tentate, **1.528** raggiunte (bloccata quasi tutta una rete di 1.076 siti l_1, più 176 altre)
- In **ordine casuale** e **senza guardare il livello**; fino a 200 articoli recenti per testata, con l'**HTML grezzo**
- I due giri sono a **5 giorni** di distanza, con lo stesso strumento: un dataset **coerente**

Prima di questo dataset: altri tentativi

- Prima di arrivare qui ho fatto **altri tentativi**, provando **più strategie di pulizia**

Prima di questo dataset: altri tentativi

- Prima di arrivare qui ho fatto **altri tentativi**, provando **più strategie di pulizia**
- Ogni volta il feature **batteva ancora** i transformer, e in parte per lo **sporco** rimasto nel dataset: testo del sito ripetuto in tutti gli articoli, pagine uguali per tutta una testata, reti di siti non separate

Prima di questo dataset: altri tentativi

- Prima di arrivare qui ho fatto **altri tentativi**, provando **più strategie di pulizia**
- Ogni volta il feature **batteva ancora** i transformer, e in parte per lo **sporco** rimasto nel dataset: testo del sito ripetuto in tutti gli articoli, pagine uguali per tutta una testata, reti di siti non separate
- Allora ho reso la pulizia **più aggressiva**: non più solo le copie tra testate, come nel primo dataset, ma anche il testo che appartiene al sito e non all'articolo, e le reti trovate anche dall'HTML

Prima di questo dataset: altri tentativi

- Prima di arrivare qui ho fatto **altri tentativi**, provando **più strategie di pulizia**
- Ogni volta il feature **batteva ancora** i transformer, e in parte per lo **sporco** rimasto nel dataset: testo del sito ripetuto in tutti gli articoli, pagine uguali per tutta una testata, reti di siti non separate
- Allora ho reso la pulizia **più aggressiva**: non più solo le copie tra testate, come nel primo dataset, ma anche il testo che appartiene al sito e non all'articolo, e le reti trovate anche dall'HTML
- Con un limite: si toglie solo quello che **non è dell'articolo**; citazioni e pezzi ripresi restano

Come ho costruito il dataset, in breve

1. **Pulire il testo degli articoli**: togliere quello che non è dell'articolo ma **del sito** (appelli, firme, titolo ripetuto, data). Un modello lo userebbe per riconoscere il sito, non l'affidabilità

Come ho costruito il dataset, in breve

1. **Pulire il testo degli articoli**: togliere quello che non è dell'articolo ma **del sito** (appelli, firme, titolo ripetuto, data). Un modello lo userebbe per riconoscere il sito, non l'affidabilità
2. **Trovare le testate parenti** (le reti), **senza guardare NewsGuard**: dalle tracce che lasciano, come testi uguali, stessi codici nell'HTML, stessi autori

Come ho costruito il dataset, in breve

1. **Pulire il testo degli articoli**: togliere quello che non è dell'articolo ma **del sito** (appelli, firme, titolo ripetuto, data). Un modello lo userebbe per riconoscere il sito, non l'affidabilità
2. **Trovare le testate parenti** (le reti), **senza guardare NewsGuard**: dalle tracce che lasciano, come testi uguali, stessi codici nell'HTML, stessi autori
3. **Fare i gruppi e i fold**: le testate parenti vanno tutte dalla stessa parte, e nessun gruppo può essere troppo grande

Come ho costruito il dataset, in breve

1. **Pulire il testo degli articoli**: togliere quello che non è dell'articolo ma **del sito** (appelli, firme, titolo ripetuto, data). Un modello lo userebbe per riconoscere il sito, non l'affidabilità
2. **Trovare le testate parenti** (le reti), **senza guardare NewsGuard**: dalle tracce che lasciano, come testi uguali, stessi codici nell'HTML, stessi autori
3. **Fare i gruppi e i fold**: le testate parenti vanno tutte dalla stessa parte, e nessun gruppo può essere troppo grande

Ogni passo è una **regola scritta nel codice**, applicata uguale a tutte le testate: **nessun testo tolto a mano** o da un LLM. Rieseguendo i notebook (random state fissati) dai dati dello scraping esce sempre lo stesso dataset.

1. Pulire gli articoli

- Si toglie dal testo quello che **appartiene al sito**, non all'articolo:

1. Pulire gli articoli

- Si toglie dal testo quello che **appartiene al sito**, non all'articolo:

  le frasi che si **ripetono** in molti articoli della stessa testata: appelli, firme, "iscriviti alla newsletter". Per esempio truthout.org ha lo stesso appello per le donazioni in **200 articoli su 200**

1. Pulire gli articoli

- Si toglie dal testo quello che **appartiene al sito**, non all'articolo:

  le frasi che si **ripetono** in molti articoli della stessa testata: appelli, firme, "iscriviti alla newsletter". Per esempio truthout.org ha lo stesso appello per le donazioni in **200 articoli su 200**

  la **cornice della pagina**: il titolo e la data che alcuni siti mettono all'inizio del testo

1. Pulire gli articoli

- Si toglie dal testo quello che **appartiene al sito**, non all'articolo:

  le frasi che si **ripetono** in molti articoli della stessa testata: appelli, firme, "iscriviti alla newsletter". Per esempio truthout.org ha lo stesso appello per le donazioni in **200 articoli su 200**

  la **cornice della pagina**: il titolo e la data che alcuni siti mettono all'inizio del testo

- Si tolgono gli articoli **vecchi** (prima del 2025), i **doppioni** dello stesso pezzo e quelli rimasti **troppo corti**

1. Pulire gli articoli

- Si toglie dal testo quello che **appartiene al sito**, non all'articolo:

  le frasi che si **ripetono** in molti articoli della stessa testata: appelli, firme, "iscriviti alla newsletter". Per esempio truthout.org ha lo stesso appello per le donazioni in **200 articoli su 200**

  la **cornice della pagina**: il titolo e la data che alcuni siti mettono all'inizio del testo
- Si tolgono gli articoli **vecchi** (prima del 2025), i **doppioni** dello stesso pezzo e quelli rimasti **troppo corti**
- Sono **impronte del sito**: lasciate lì, un modello riconoscerebbe la testata invece di leggere l'articolo

1. Pulire gli articoli

- Si toglie dal testo quello che **appartiene al sito**, non all'articolo:

  le frasi che si **ripetono** in molti articoli della stessa testata: appelli, firme, "iscriviti alla newsletter". Per esempio truthout.org ha lo stesso appello per le donazioni in **200 articoli su 200**

  la **cornice della pagina**: il titolo e la data che alcuni siti mettono all'inizio del testo
- Si tolgono gli articoli **vecchi** (prima del 2025), i **doppioni** dello stesso pezzo e quelli rimasti **troppo corti**
- Sono **impronte del sito**: lasciate lì, un modello riconoscerebbe la testata invece di leggere l'articolo
- Tutto con **regole automatiche** nel codice, nessuna modifica a mano. Risultato: via il 5% delle parole; da 101.887 a **76.091** articoli

1. Pulire gli articoli

- Si toglie dal testo quello che **appartiene al sito**, non all'articolo:

  le frasi che si **ripetono** in molti articoli della stessa testata: appelli, firme, "iscriviti alla newsletter". Per esempio truthout.org ha lo stesso appello per le donazioni in **200 articoli su 200**

  la **cornice della pagina**: il titolo e la data che alcuni siti mettono all'inizio del testo
- Si tolgono gli articoli **vecchi** (prima del 2025), i **doppioni** dello stesso pezzo e quelli rimasti **troppo corti**
- Sono **impronte del sito**: lasciate lì, un modello riconoscerebbe la testata invece di leggere l'articolo
- Tutto con **regole automatiche** nel codice, nessuna modifica a mano. Risultato: via il 5% delle parole; da 101.887 a **76.091** articoli

  Con lo stesso MinHash del primo dataset si trovano anche le copie tra testate: servono al passo 2.

2. Trovare le testate parenti: le tracce

Traccia	Quando due testate sono parenti	Esempio
copie	hanno articoli quasi uguali in comune (MinHash, $J \geq 0{,}5$): almeno 2, e almeno il 10% degli articoli della più piccola	catene di giornali locali
codici di account	nell'HTML di ogni pagina c'è il **numero di conto** di AdSense, Google Analytics, pixel di Facebook… (es. `ca-pub-1234...`): due siti con **lo stesso numero** usano lo stesso conto. Conta solo se è in almeno metà delle pagine	FiveZero: 18 siti, un solo conto AdSense
privacy policy	il link "Privacy policy" porta alla **stessa pagina** su un altro dominio, cioè lo stesso titolare. Non contano Google, WordPress, Substack e simili, uguali per tutti i clienti	8 siti, tutti verso la privacy policy di `salemmedia.com`
dominio	sottodomini dello stesso sito, o la homepage che **reindirizza** allo stesso dominio	le edizioni di HuffPost
autori	la firma dell'articolo: gli **stessi nomi di persona** (non "Staff" o le agenzie) firmano almeno il 10% degli articoli della più piccola	la rete da 426 siti

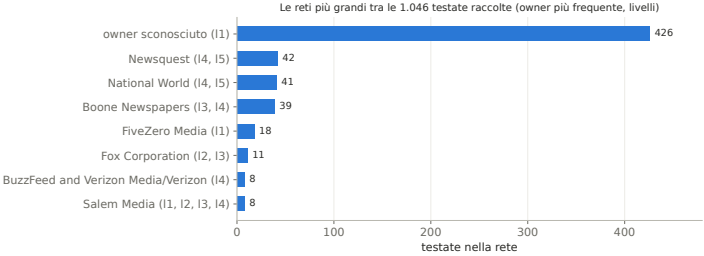
- Basta **una** traccia per collegare due testate; una **rete** = testate collegate, anche a catena (come nel primo dataset)

2. Trovare le testate parenti: le tracce

Traccia	Quando due testate sono parenti	Esempio
copie	hanno articoli quasi uguali in comune (MinHash, $J \geq 0{,}5$): almeno 2, e almeno il 10% degli articoli della più piccola	catene di giornali locali
codici di account	nell'HTML di ogni pagina c'è il **numero di conto** di AdSense, Google Analytics, pixel di Facebook… (es. `ca-pub-1234...`): due siti con **lo stesso numero** usano lo stesso conto. Conta solo se è in almeno metà delle pagine	FiveZero: 18 siti, un solo conto AdSense
privacy policy	il link "Privacy policy" porta alla **stessa pagina** su un altro dominio, cioè lo stesso titolare. Non contano Google, WordPress, Substack e simili, uguali per tutti i clienti	8 siti, tutti verso la privacy policy di `salemmedia.com`
dominio	sottodomini dello stesso sito, o la homepage che **reindirizza** allo stesso dominio	le edizioni di HuffPost
autori	la firma dell'articolo: gli **stessi nomi di persona** (non "Staff" o le agenzie) firmano almeno il 10% degli articoli della più piccola	la rete da 426 siti

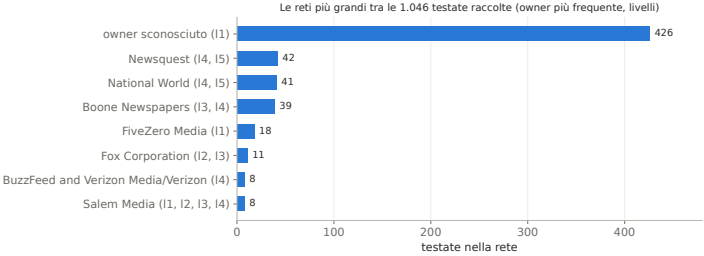
- Basta **una** traccia per collegare due testate; una **rete** = testate collegate, anche a catena (come nel primo dataset)
- Le soglie del 10% evitano di collegare due testate per un pezzo d'agenzia o un collaboratore in comune

2. Le reti trovate



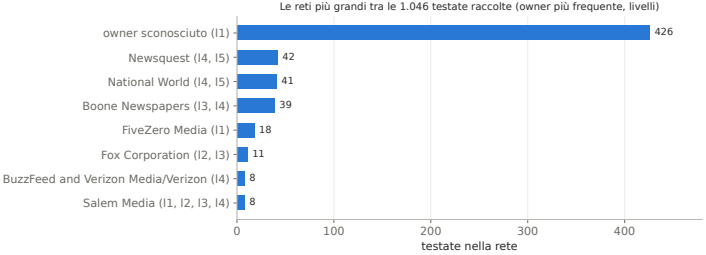
- **725 testate su 1.046** stanno in una rete con altre

2. Le reti trovate



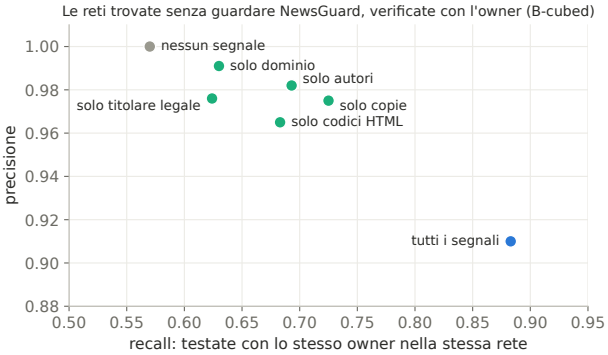
- **725 testate su 1.046** stanno in una rete con altre
- La più grande ha **426 siti**, legati soprattutto dagli **stessi autori**. Per NewsGuard l'owner è **sconosciuto**

2. Le reti trovate



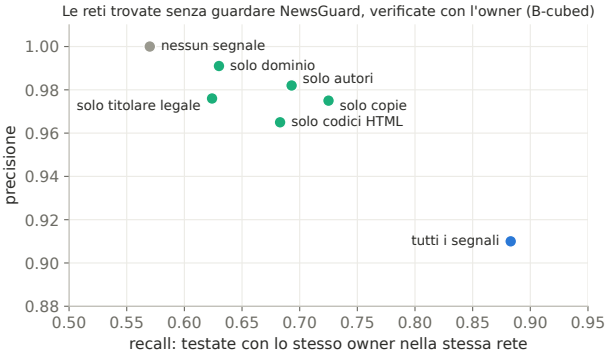
- **725 testate su 1.046** stanno in una rete con altre
- La più grande ha **426 siti**, legati soprattutto dagli **stessi autori**. Per NewsGuard l'owner è **sconosciuto**
- Controllo a parte: tutti hanno lo **stesso punteggio** (5) e nel campo "Parent Domain" di NewsGuard **425 su 426** dicono `naturalnews.com`. È la rete di Natural News

2. Il controllo con l'owner di NewsGuard



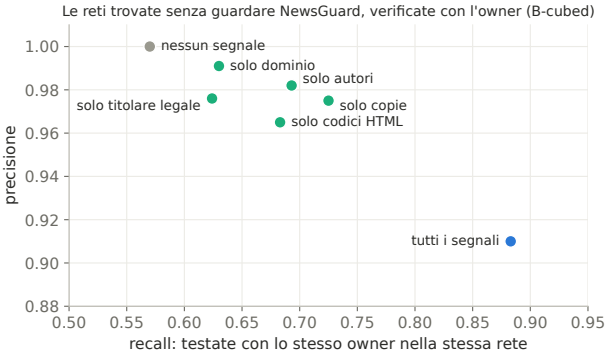
- Le reti le ho trovate **senza** l'owner: ora lo uso per vedere se sono giuste

2. Il controllo con l'owner di NewsGuard



- Le reti le ho trovate **senza** l'owner: ora lo uso per vedere se sono giuste
- Per ogni testata con un owner noto:

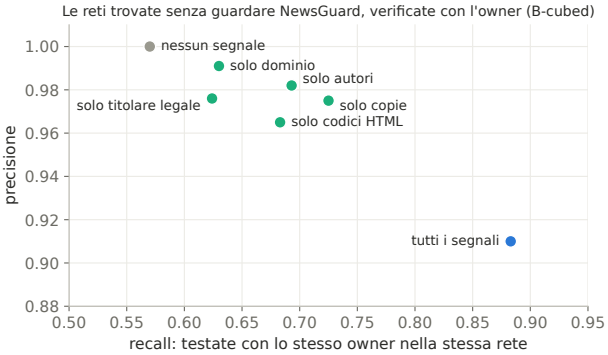
2. Il controllo con l'owner di NewsGuard



- Le reti le ho trovate **senza** l'owner: ora lo uso per vedere se sono giuste
- Per ogni testata con un owner noto:

  precisione: le testate della sua rete hanno il suo stesso owner?

2. Il controllo con l'owner di NewsGuard

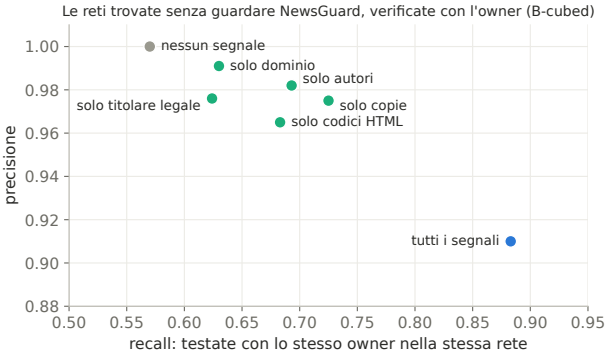


- Le reti le ho trovate **senza** l'owner: ora lo uso per vedere se sono giuste
- Per ogni testata con un owner noto:

  precisione: le testate della sua rete hanno il suo stesso owner?

  recall: le testate del suo owner sono nella sua rete?

2. Il controllo con l'owner di NewsGuard



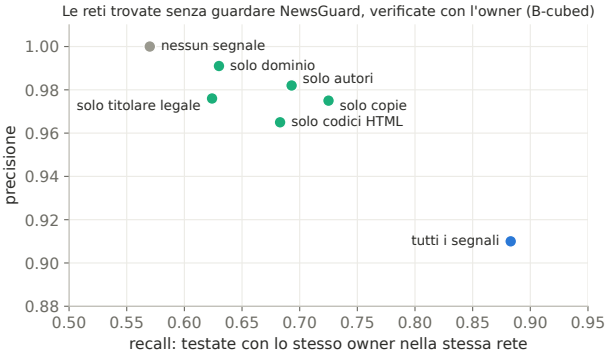
- Le reti le ho trovate **senza** l'owner: ora lo uso per vedere se sono giuste
- Per ogni testata con un owner noto:

  precisione: le testate della sua rete hanno il suo stesso owner?

  recall: le testate del suo owner sono nella sua rete?

  e poi la media su tutte le testate

2. Il controllo con l'owner di NewsGuard



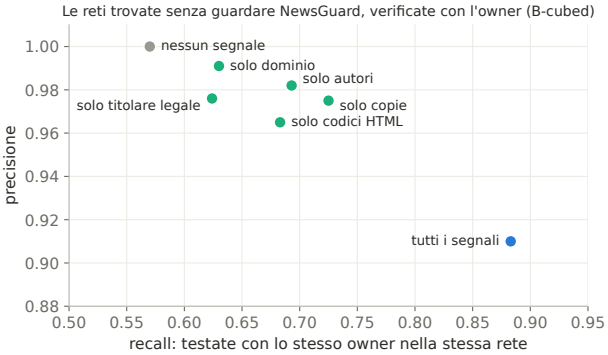
- Le reti le ho trovate **senza** l'owner: ora lo uso per vedere se sono giuste
- Per ogni testata con un owner noto:

  precisione: le testate della sua rete hanno il suo stesso owner?

  recall: le testate del suo owner sono nella sua rete?

  e poi la media su tutte le testate
- Ogni traccia da sola è precisa ma trova poco; **tutte insieme**: precisione **0,91**, recall **0,88**

2. Il controllo con l'owner di NewsGuard



- Le reti le ho trovate **senza** l'owner: ora lo uso per vedere se sono giuste
- Per ogni testata con un owner noto:

  precisione: le testate della sua rete hanno il suo stesso owner?

  recall: le testate del suo owner sono nella sua rete?

  e poi la media su tutte le testate
- Ogni traccia da sola è precisa ma trova poco; **tutte insieme**: precisione **0,91**, recall **0,88**
- Le testate con owner sconosciuto non entrano nel conto: si controllano a parte, come Natural News

3. I gruppi

- **Gruppo** = rete trovata **oppure** stesso owner NewsGuard: basta uno dei due. L'owner aggiunge le parentele che non lasciano tracce

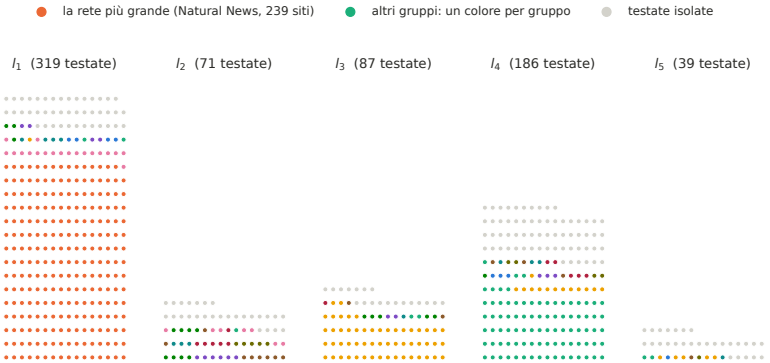
3. I gruppi

- **Gruppo** = rete trovata **oppure** stesso owner NewsGuard: basta uno dei due. L'owner aggiunge le parentele che non lasciano tracce
- Lo stesso articolo in **due gruppi diversi**: si tiene la copia più vecchia (-461 articoli). Così lo stesso testo non sta mai nel training e nel test

3. I gruppi

- **Gruppo** = rete trovata **oppure** stesso owner NewsGuard: basta uno dei due. L'owner aggiunge le parentele che non lasciano tracce
- Lo stesso articolo in **due gruppi diversi**: si tiene la copia più vecchia (-461 articoli). Così lo stesso testo non sta mai nel training e nel test
- Testate con almeno **20 articoli** (per il voto di maggioranza): **702**

3. I gruppi, livello per livello

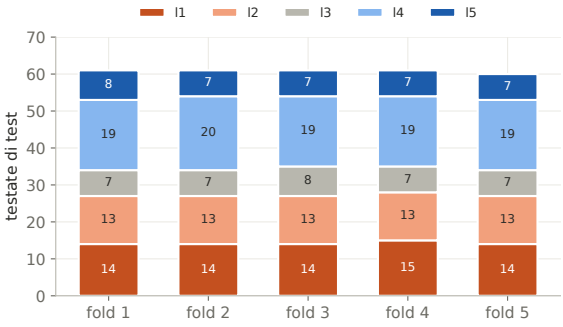


Le 702 testate con almeno 20 articoli. Un pallino = una testata; un colore = un gruppo.

- Natural News fa **239 delle 319** testate l_1: lo stesso problema di Metric Media nel primo dataset

3. Il tetto e i fold

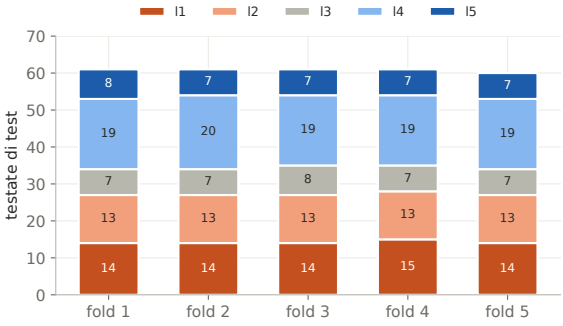
- Al massimo **5 testate per gruppo**, scelte **a caso**: Natural News conta come gli altri gruppi, non riempie più l_1



Testate per livello in ogni fold di test

3. Il tetto e i fold

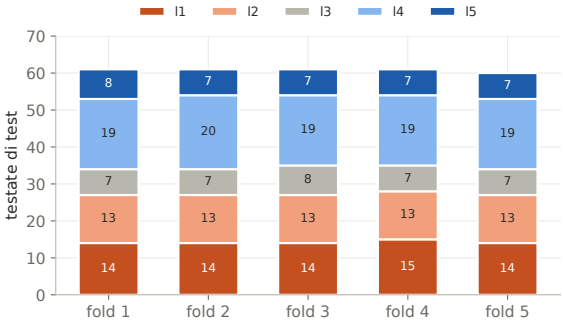
- Al massimo **5 testate per gruppo**, scelte **a caso**: Natural News conta come gli altri gruppi, non riempie più l_1
- Restano **304 testate** in **220 gruppi**



Testate per livello in ogni fold di test

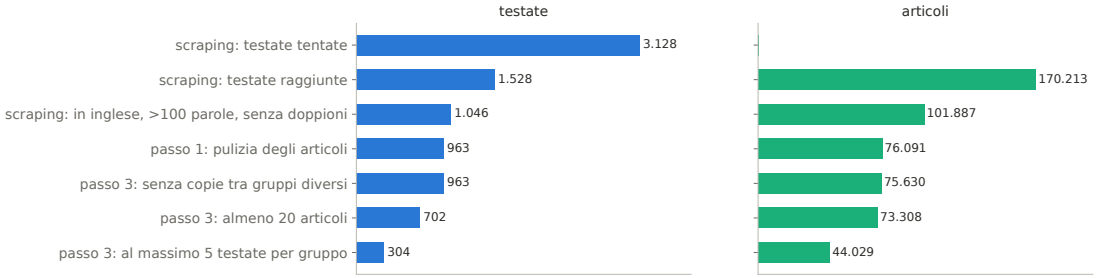
3. Il tetto e i fold

- Al massimo **5 testate per gruppo**, scelte **a caso**: Natural News conta come gli altri gruppi, non riempie più l_1
- Restano **304 testate** in **220 gruppi**
- **5 fold per gruppo**: ogni gruppo sta in un fold solo, e ogni fold ha lo stesso numero di testate per livello



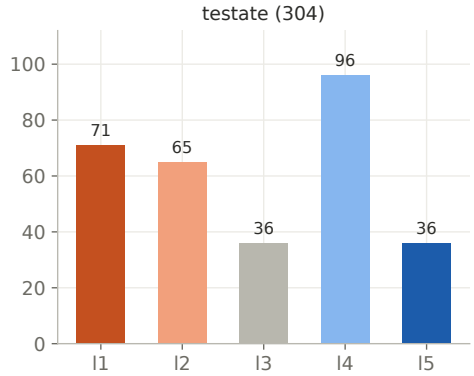
Testate per livello in ogni fold di test

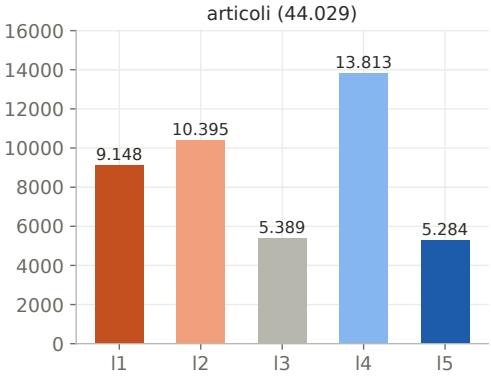
Quanto resta a ogni passo



Il passo 2 non toglie articoli: serve a fare i gruppi.

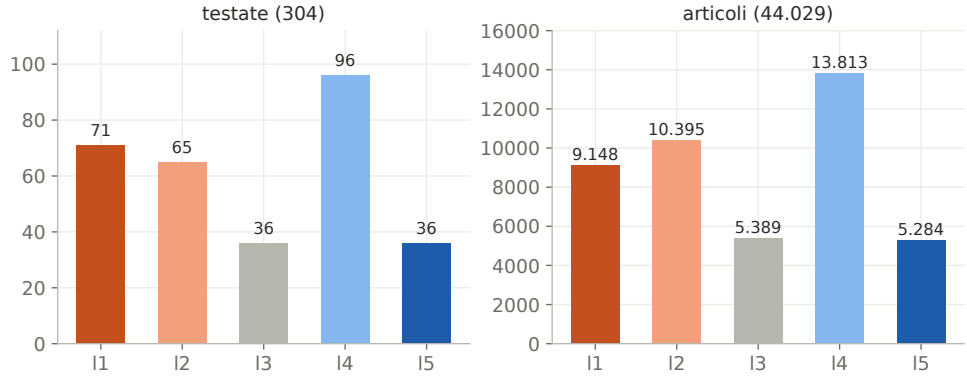
Il dataset finale





- **304 testate**, **44.029 articoli**, **220 gruppi** indipendenti

Il dataset finale

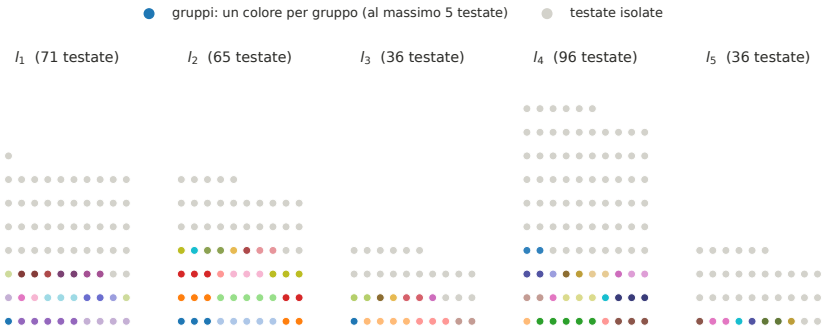


- **304 testate**, **44.029 articoli**, **220 gruppi** indipendenti
- Più del doppio delle testate I_1 indipendenti rispetto al primo dataset (56 gruppi contro 20)

La sporcizia è andata?

gli stessi grafici, sul dataset nuovo

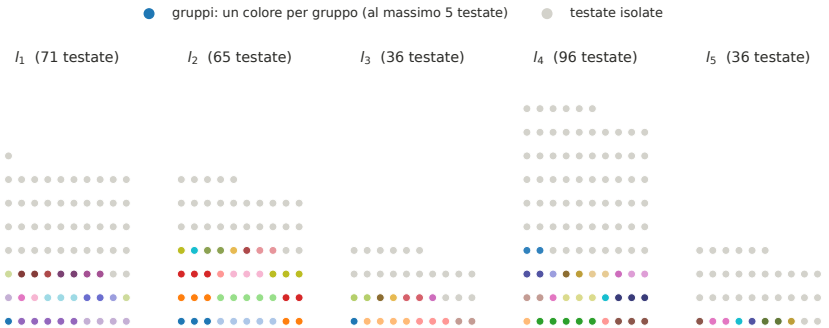
Le reti livello per livello, ora



Un pallino = una testata; un colore = un gruppo.

- Prima: **131 testate l_1 su 152** erano una rete sola. Ora nessun gruppo ha più di **5 testate**

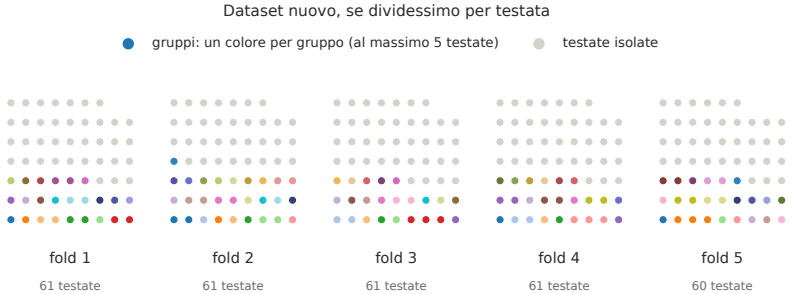
Le reti livello per livello, ora



Un pallino = una testata; un colore = un gruppo.

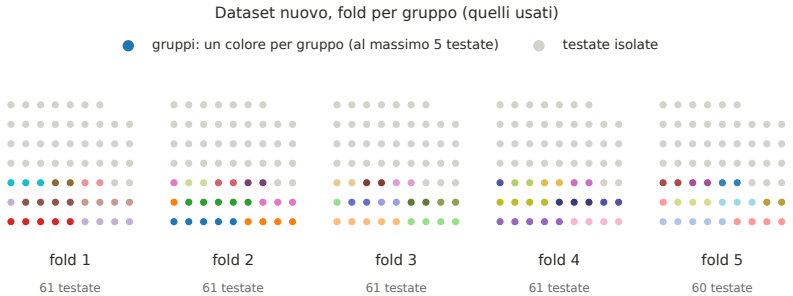
- Prima: **131 testate l_1 su 152** erano una rete sola. Ora nessun gruppo ha più di **5 testate**
- **181 testate isolate** e **123** in 39 gruppi piccoli; in l_1, 43 isolate su 71

I fold, ora



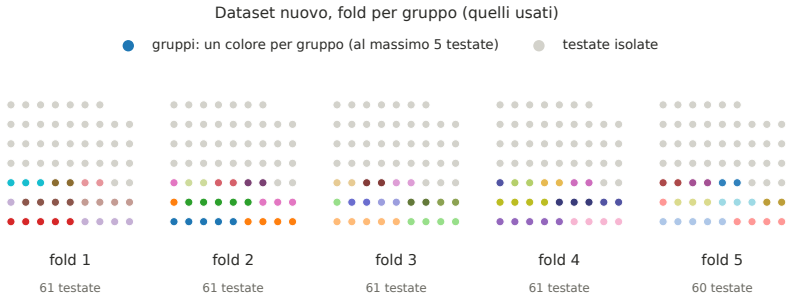
- Se dividessimo **per testata**, un gruppo starebbe in media in **2,4 fold**: le sorelle di nuovo da tutte e due le parti

I fold, ora



- Se dividessimo **per testata**, un gruppo starebbe in media in **2,4 fold**: le sorelle di nuovo da tutte e due le parti
- Con i fold **per gruppo** (quelli usati) ogni colore sta in **un solo fold**

I fold, ora



- Se dividessimo **per testata**, un gruppo starebbe in media in **2,4 fold**: le sorelle di nuovo da tutte e due le parti
- Con i fold **per gruppo** (quelli usati) ogni colore sta in **un solo fold**
- È una divisione **in più**, non al posto di quella per testata: gli articoli di una testata stanno **sempre** in un solo fold, e in più le testate di un gruppo stanno insieme

Risultati

TF-IDF contro transformer, sul dataset nuovo

Come sono arrivato alla ricetta dei transformer

Cosa è successo nei tentativi precedenti	**Cosa ho cambiato**
Con le pagine del sito ModernBERT **imparava a memoria** le testate: le pagine erano uguali in tutti i loro articoli, e la loss di training andava a zero già nella prima epoca	solo il testo degli articoli, pulito
Le testate con tanti articoli pesavano di più nell'addestramento, e i livelli con poche testate rischiavano di essere ignorati; l'analisi diceva che 5–20 articoli per testata bastano quasi del tutto	**20 articoli a caso per testata** a ogni epoca; **pesi di classe**
L'early stopping sceglieva l'epoca su una validazione di circa 22 testate: la F1 saltava da un'epoca all'altra (0,17 $\rightarrow$ 0,37 $\rightarrow$ 0,42 $\rightarrow$ 0,39) e la scelta era quasi a caso. E dopo 1–2 epoche il modello cominciava a imparare a memoria	**2 epoche fisse**, niente early stopping
2048 token non andavano meglio di 1024 (F1 0,242 contro 0,255)	**1024 token**
Cambiando solo il seed, la F1 cambiava quanto tra un modello e l'altro	**3 seed** e la loro media
Un ModernBERT **congelato**, senza addestramento, andava quasi come quello addestrato	provare gli **embedding congelati**
Large e base erano pari, ma su 193 testate	riprovare il **large** sul dataset più grande

La ricetta finale dei transformer

- **Fine-tuning**: si prende ModernBERT già pre-addestrato e lo si addestra ancora, sul nostro compito: leggere **un articolo** e dire il livello della sua testata

La ricetta finale dei transformer

- **Fine-tuning**: si prende ModernBERT già pre-addestrato e lo si addestra ancora, sul nostro compito: leggere **un articolo** e dire il livello della sua testata
- Per giudicare una **testata** si fa la **media delle probabilità** di tutti i suoi articoli

La ricetta finale dei transformer

- **Fine-tuning**: si prende ModernBERT già pre-addestrato e lo si addestra ancora, sul nostro compito: leggere **un articolo** e dire il livello della sua testata
- Per giudicare una **testata** si fa la **media delle probabilità** di tutti i suoi articoli
- Due taglie, **base** (150 milioni di parametri) e **large** (400 milioni), per vedere se un modello più grande aiuta

La ricetta finale dei transformer

- **Fine-tuning**: si prende ModernBERT già pre-addestrato e lo si addestra ancora, sul nostro compito: leggere **un articolo** e dire il livello della sua testata
- Per giudicare una **testata** si fa la **media delle probabilità** di tutti i suoi articoli
- Due taglie, **base** (150 milioni di parametri) e **large** (400 milioni), per vedere se un modello più grande aiuta
- La stessa ricetta per tutti, quella della slide prima: primi **1024 token** di ogni articolo, **2 epoche**, a ogni epoca **20 articoli a caso per testata**, **pesi di classe**

La ricetta finale dei transformer

- **Fine-tuning**: si prende ModernBERT già pre-addestrato e lo si addestra ancora, sul nostro compito: leggere **un articolo** e dire il livello della sua testata
- Per giudicare una **testata** si fa la **media delle probabilità** di tutti i suoi articoli
- Due taglie, **base** (150 milioni di parametri) e **large** (400 milioni), per vedere se un modello più grande aiuta
- La stessa ricetta per tutti, quella della slide prima: primi **1024 token** di ogni articolo, **2 epoche**, a ogni epoca **20 articoli a caso per testata**, **pesi di classe**
- Il TF-IDF in due versioni: con i parametri scelti in una validazione sul solo training (**riferimento**, fissato prima) e con quelli di default

Seed, ensemble ed embedding congelati

- Il **seed** è il numero che fissa il caso nell'addestramento: da dove parte il modello, quali 20 articoli si pescano, in che ordine. Con lo stesso dataset e la stessa ricetta, seed diversi danno modelli diversi

Seed, ensemble ed embedding congelati

- Il **seed** è il numero che fissa il caso nell'addestramento: da dove parte il modello, quali 20 articoli si pescano, in che ordine. Con lo stesso dataset e la stessa ricetta, seed diversi danno modelli diversi
- Quanto diversi? Qui ModernBERT-base fa F1 da **0,33 a 0,38** a seconda del seed: tanto quanto la differenza tra due modelli

Seed, ensemble ed embedding congelati

- Il **seed** è il numero che fissa il caso nell'addestramento: da dove parte il modello, quali 20 articoli si pescano, in che ordine. Con lo stesso dataset e la stessa ricetta, seed diversi danno modelli diversi
- Quanto diversi? Qui ModernBERT-base fa F1 da **0,33 a 0,38** a seconda del seed: tanto quanto la differenza tra due modelli
- Per questo ogni ModernBERT gira con **3 seed** (42, 1, 2), e il risultato principale è l'**ensemble**: la media delle probabilità dei tre modelli, che dipende meno dal caso. Il "seed 42" da solo lo riporto solo per far vedere quanto varia, non si sceglie il migliore

Seed, ensemble ed embedding congelati

- Il **seed** è il numero che fissa il caso nell'addestramento: da dove parte il modello, quali 20 articoli si pescano, in che ordine. Con lo stesso dataset e la stessa ricetta, seed diversi danno modelli diversi
- Quanto diversi? Qui ModernBERT-base fa F1 da **0,33 a 0,38** a seconda del seed: tanto quanto la differenza tra due modelli
- Per questo ogni ModernBERT gira con **3 seed** (42, 1, 2), e il risultato principale è l'**ensemble**: la media delle probabilità dei tre modelli, che dipende meno dal caso. Il "seed 42" da solo lo riporto solo per far vedere quanto varia, non si sceglie il migliore
- **Embedding congelati** (e5-large, bge-large): il modello **non si addestra**. Trasforma ogni articolo in 1024 numeri, si fa la media per testata e sopra si mette la stessa regressione logistica del TF-IDF

Seed, ensemble ed embedding congelati

- Il **seed** è il numero che fissa il caso nell'addestramento: da dove parte il modello, quali 20 articoli si pescano, in che ordine. Con lo stesso dataset e la stessa ricetta, seed diversi danno modelli diversi
- Quanto diversi? Qui ModernBERT-base fa F1 da **0,33 a 0,38** a seconda del seed: tanto quanto la differenza tra due modelli
- Per questo ogni ModernBERT gira con **3 seed** (42, 1, 2), e il risultato principale è l'**ensemble**: la media delle probabilità dei tre modelli, che dipende meno dal caso. Il "seed 42" da solo lo riporto solo per far vedere quanto varia, non si sceglie il migliore
- **Embedding congelati** (e5-large, bge-large): il modello **non si addestra**. Trasforma ogni articolo in 1024 numeri, si fa la media per testata e sopra si mette la stessa regressione logistica del TF-IDF

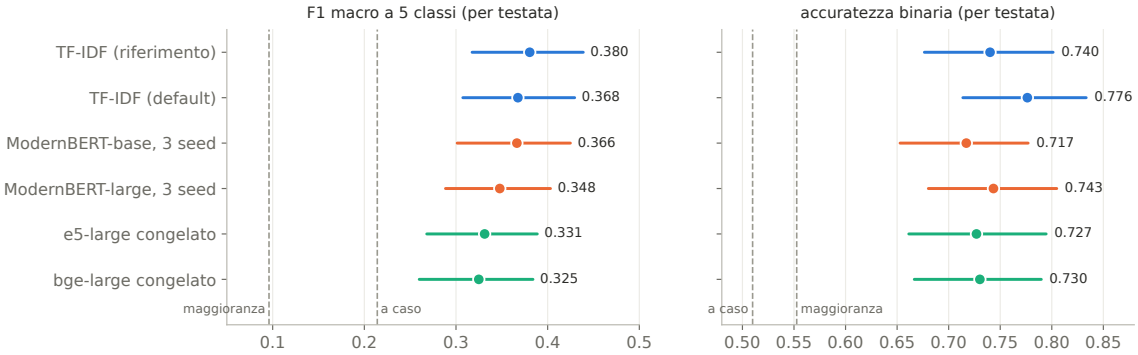
  Costano poco e **non possono imparare a memoria** le testate: dicono se basta una rappresentazione generica del testo

I risultati

Modello	F1 macro	acc. 5 cl.	tol. 0,5	tol. 1	binario	F1 bin.
TF-IDF, parametri in validazione (riferimento)	0,380	0,424	0,597	0,770	0,740	0,740
TF-IDF, parametri di default	0,368	**0,454**	**0,628**	**0,803**	**0,776**	**0,776**
ModernBERT-base, 3 seed	0,366	0,398	0,589	0,780	0,717	0,717
ModernBERT-large, 3 seed	0,348	0,405	0,602	0,799	0,743	0,742
ModernBERT-base, seed 42	**0,383**	0,424	0,599	0,773	0,720	0,720
e5-large congelato	0,331	0,391	0,589	0,786	0,727	0,723
bge-large congelato	0,325	0,382	0,586	0,789	0,730	0,729
classe di maggioranza	0,096	0,316	0,434	0,553	0,553	0,356
a caso	0,214	0,243	0,388	0,533	0,510	0,505

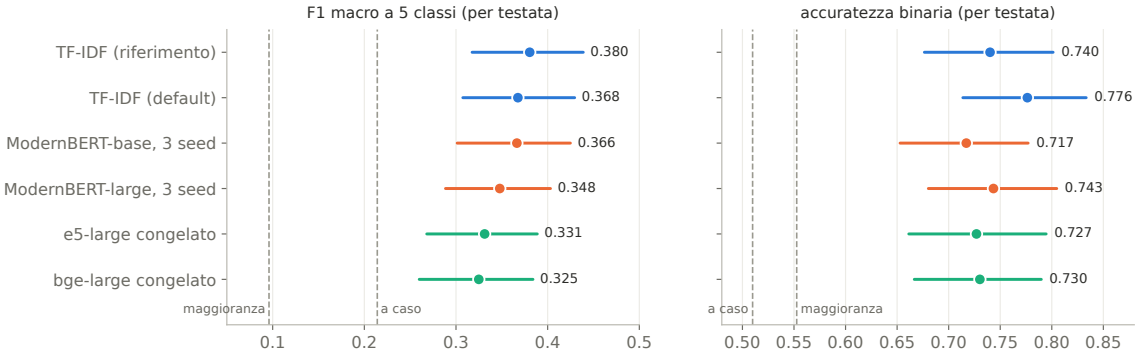
Per testata, 304 testate, fold per gruppo. Tolerant: un errore di un livello vale mezzo punto (0,5) o un punto (1).

Con gli intervalli



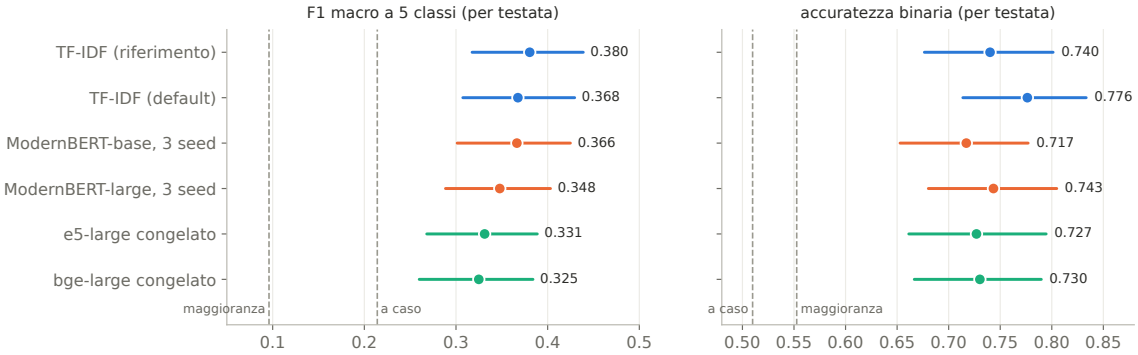
- Tutti i modelli stanno **ben sopra** maggioranza e caso: dal solo testo un segnale c'è

Con gli intervalli



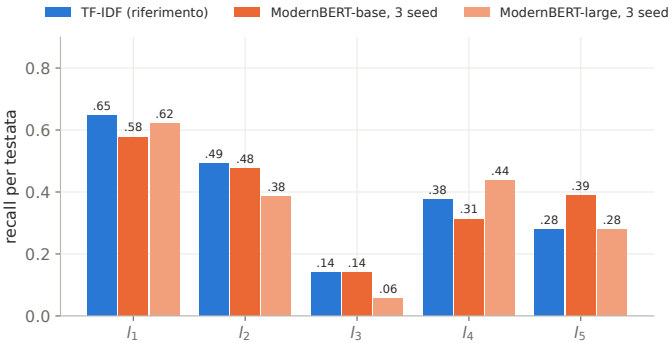
- Tutti i modelli stanno **ben sopra** maggioranza e caso: dal solo testo un segnale c'è
- **Nessun transformer batte il feature** in modo significativo: le differenze stanno tutte negli intervalli

Con gli intervalli



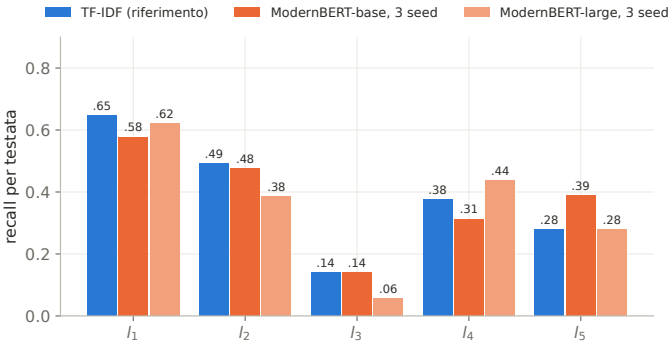
- Tutti i modelli stanno **ben sopra** maggioranza e caso: dal solo testo un segnale c'è
- **Nessun transformer batte il feature** in modo significativo: le differenze stanno tutte negli intervalli
- Il modello più grande e gli embedding congelati **non aiutano**

Chi riconosce cosa



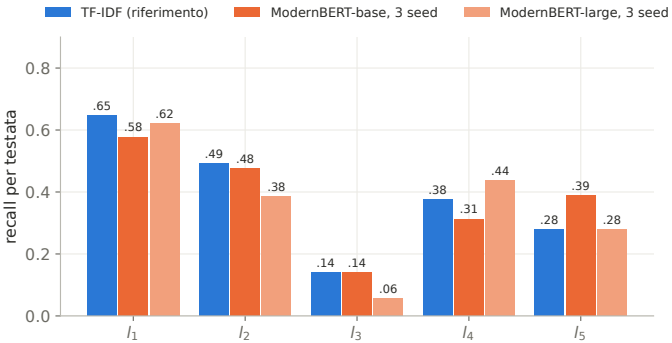
- Il feature riconosce meglio le testate **inaffidabili** (l_1)

Chi riconosce cosa



- Il feature riconosce meglio le testate **inaffidabili** (l_1)
- ModernBERT-base riconosce meglio le **più affidabili** (l_5); il large le l_4

Chi riconosce cosa



- Il feature riconosce meglio le testate **inaffidabili** (l_1)
- ModernBERT-base riconosce meglio le **più affidabili** (l_5); il large le l_4
- Gli errori sono **diversi**: i due modelli sono complementari

E senza la classe l_1?

Modello	F1 macro	acc. 4 cl.	tol. 0,5	tol. 1	binario	F1 bin.
TF-IDF, parametri in validazione (riferimento)	0,358	0,408	0,586	0,764	0,712	0,667
TF-IDF, parametri di default	0,364	**0,451**	0,616	0,781	**0,734**	0,683
ModernBERT-base, 3 seed	0,355	0,395	0,607	0,820	0,717	0,673
ModernBERT-large, 3 seed	0,311	0,369	0,590	0,811	0,704	0,637
ModernBERT-base, seed 42	**0,379**	0,433	**0,624**	0,815	0,721	**0,688**
e5-large congelato	0,304	0,361	0,597	**0,833**	0,717	0,634
bge-large congelato	0,297	0,352	0,579	0,807	0,700	0,627
classe di maggioranza (l_4)	0,146	0,412	0,567	0,721	0,721	0,419
a caso	0,251	0,300	0,479	0,657	0,584	0,485

233 testate (l_2–l_5); i modelli scelgono tra l_2 e l_5 (le probabilità salvate, senza riaddestrare). Binario: l_2 contro l_3–l_5.

- Senza l_1 il vantaggio del feature **sparisce**: ModernBERT-base, 3 seed, è **pari** (differenza di F1 0,000 [−0,07; +0,07]) e sulla tolerant 1 meglio

E senza la classe l_1?

Modello	F1 macro	acc. 4 cl.	tol. 0,5	tol. 1	binario	F1 bin.
TF-IDF, parametri in validazione (riferimento)	0,358	0,408	0,586	0,764	0,712	0,667
TF-IDF, parametri di default	0,364	**0,451**	0,616	0,781	**0,734**	0,683
ModernBERT-base, 3 seed	0,355	0,395	0,607	0,820	0,717	0,673
ModernBERT-large, 3 seed	0,311	0,369	0,590	0,811	0,704	0,637
ModernBERT-base, seed 42	**0,379**	0,433	**0,624**	0,815	0,721	**0,688**
e5-large congelato	0,304	0,361	0,597	**0,833**	0,717	0,634
bge-large congelato	0,297	0,352	0,579	0,807	0,700	0,627
classe di maggioranza (l_4)	0,146	0,412	0,567	0,721	0,721	0,419
a caso	0,251	0,300	0,479	0,657	0,584	0,485

233 testate (l_2–l_5); i modelli scelgono tra l_2 e l_5 (le probabilità salvate, senza riaddestrare). Binario: l_2 contro l_3–l_5.

- Senza l_1 il vantaggio del feature **sparisce**: ModernBERT-base, 3 seed, è **pari** (differenza di F1 0,000 [−0,07; +0,07]) e sulla tolerant 1 meglio
- *Analisi esplorativa, decisa dopo aver visto i risultati*

Perché il feature vince su l_1

Le parole che spingono di più verso l_1 nel modello TF-IDF sono di due tipi:

Contenuto e ideologia

president trump, abortion, kiev, lifesitenews, epoch times, preborn, nomi di stati e regioni

→ segnale vero, ma intrecciato con **temi e orientamento**: un confondente da discutere

Residui dell'estrazione

pic twitter, https, www, com, youtube, utc, qualche firma rimasta nel testo

→ resti di tweet, video e link incorporati: i siti l_1 ne usano molti di più, e il TF-IDF li **conta**

- Il vantaggio **non viene dalle reti**: il feature indovina le l_1 isolate (30/43) e quelle in un gruppo (20/28) allo stesso modo

Perché il feature vince su l_1

Le parole che spingono di più verso l_1 nel modello TF-IDF sono di due tipi:

Contenuto e ideologia

president trump, abortion, kiev, lifesitenews, epoch times, preborn, nomi di stati e regioni

→ segnale vero, ma intrecciato con **temi e orientamento**: un confondente da discutere

Residui dell'estrazione

pic twitter, https, www, com, youtube, utc, qualche firma rimasta nel testo

→ resti di tweet, video e link incorporati: i siti l_1 ne usano molti di più, e il TF-IDF li **conta**

- Il vantaggio **non viene dalle reti**: il feature indovina le l_1 isolate (30/43) e quelle in un gruppo (20/28) allo stesso modo
- I residui di link e contenuti incorporati sono **cornice della pagina**, come titolo e timbro che abbiamo già tolto

Perché è un risultato valido per il paper

- **Il problema**: con le testate divise come al solito i numeri sono gonfiati dalle reti (primo dataset: 0,68 $\rightarrow$ 0,39)

Perché è un risultato valido per il paper

- **Il problema**: con le testate divise come al solito i numeri sono gonfiati dalle reti (primo dataset: 0,68 $\rightarrow$ 0,39)
- **Il metodo**: reti trovate senza NewsGuard, da testo e HTML (precisione 0,91, recall 0,88), e valutazione per gruppo; processo deterministico e replicabile

Perché è un risultato valido per il paper

- **Il problema**: con le testate divise come al solito i numeri sono gonfiati dalle reti (primo dataset: 0,68 $\rightarrow$ 0,39)
- **Il metodo**: reti trovate senza NewsGuard, da testo e HTML (precisione 0,91, recall 0,88), e valutazione per gruppo; processo deterministico e replicabile
- **Il risultato**: con una valutazione onesta il testo da solo dà un segnale **moderato** (F1 0,38, binario 0,74–0,78); i transformer **non battono** un modello lessicale ben fatto, ma sbagliano in modo **diverso**

Perché è un risultato valido per il paper

- **Il problema**: con le testate divise come al solito i numeri sono gonfiati dalle reti (primo dataset: 0,68 $\rightarrow$ 0,39)
- **Il metodo**: reti trovate senza NewsGuard, da testo e HTML (precisione 0,91, recall 0,88), e valutazione per gruppo; processo deterministico e replicabile
- **Il risultato**: con una valutazione onesta il testo da solo dà un segnale **moderato** (F1 0,38, binario 0,74–0,78); i transformer **non battono** un modello lessicale ben fatto, ma sbagliano in modo **diverso**
- **Il dubbio**: parte del vantaggio del feature su l_1 sono residui di link e tweet incorporati

Prossimi passi

1. Una **regola di pulizia** in più, uguale per tutti i modelli: togliere i resti di link e contenuti incorporati, poi rifare pulizia e classificazione (circa 7 ore sul server)

Prossimi passi

1. Una **regola di pulizia** in più, uguale per tutti i modelli: togliere i resti di link e contenuti incorporati, poi rifare pulizia e classificazione (circa 7 ore sul server)
2. **Combinare** feature e transformer, con la combinazione scelta in validazione interna: sbagliano su testate diverse

Prossimi passi

1. Una **regola di pulizia** in più, uguale per tutti i modelli: togliere i resti di link e contenuti incorporati, poi rifare pulizia e classificazione (circa 7 ore sul server)
2. **Combinare** feature e transformer, con la combinazione scelta in validazione interna: sbagliano su testate diverse
3. Come presentare il **confondente** tema/orientamento politico

Proposta di Fabio

usare un modello grande (Claude) per costruire gli embedding — una parte ipotetica, ancora da provare

La proposta, in breve

- Fabio, nella chat con Claude: invece di addestrare solo modelli piccoli, **sfruttare un modello grande** senza addestrarlo

La proposta, in breve

- Fabio, nella chat con Claude: invece di addestrare solo modelli piccoli, **sfruttare un modello grande** senza addestrarlo
- **Strada A**: il modello grande **legge** ogni articolo e dà un voto su segnali precisi (sensazionalismo, fonti citate, opinione o cronaca...). I voti sono il vettore dell'articolo

La proposta, in breve

- Fabio, nella chat con Claude: invece di addestrare solo modelli piccoli, **sfruttare un modello grande** senza addestrarlo
- **Strada A**: il modello grande **legge** ogni articolo e dà un voto su segnali precisi (sensazionalismo, fonti citate, opinione o cronaca...). I voti sono il vettore dell'articolo
- **Strada B**: "training con LLM, embedding + MLP". Ogni articolo diventa un **embedding**, e sopra si addestra una piccola rete; meglio ancora se la rete legge **tutti gli articoli di una testata insieme**

La proposta, in breve

- Fabio, nella chat con Claude: invece di addestrare solo modelli piccoli, **sfruttare un modello grande** senza addestrarlo
- **Strada A**: il modello grande **legge** ogni articolo e dà un voto su segnali precisi (sensazionalismo, fonti citate, opinione o cronaca...). I voti sono il vettore dell'articolo
- **Strada B**: "training con LLM, embedding + MLP". Ogni articolo diventa un **embedding**, e sopra si addestra una piccola rete; meglio ancora se la rete legge **tutti gli articoli di una testata insieme**
- In tutte e due il modello grande si usa **una volta per articolo**; quello che si addestra è piccolo e veloce

Una precisazione: cosa vuol dire “embedding di Claude”

- L’API di Claude **scrive testo**: non restituisce i vettori interni del modello

Una precisazione: cosa vuol dire “embedding di Claude”

- L’API di Claude **scrive testo**: non restituisce i vettori interni del modello
- Quindi “embedding di Claude” si può fare in due modi:

Una precisazione: cosa vuol dire “embedding di Claude”

- L’API di Claude **scrive testo**: non restituisce i vettori interni del modello
- Quindi “embedding di Claude” si può fare in due modi:

  (A) un vettore che Claude scrive: per ogni articolo, una ventina di voti da 1 a 10 su domande fissate prima. È un embedding piccolo e **leggibile**: ogni numero ha un significato

Una precisazione: cosa vuol dire “embedding di Claude”

- L’API di Claude **scrive testo**: non restituisce i vettori interni del modello
- Quindi “embedding di Claude” si può fare in due modi:

  (A) un vettore che Claude scrive: per ogni articolo, una ventina di voti da 1 a 10 su domande fissate prima. È un embedding piccolo e **leggibile**: ogni numero ha un significato

  (B) un modello fatto apposta per gli embedding: un servizio a pagamento o un modello aperto basato su un LLM, più grande di e5 e bge e capace di leggere l’articolo intero

Una precisazione: cosa vuol dire “embedding di Claude”

- L’API di Claude **scrive testo**: non restituisce i vettori interni del modello
- Quindi “embedding di Claude” si può fare in due modi:

  (A) un vettore che Claude scrive: per ogni articolo, una ventina di voti da 1 a 10 su domande fissate prima. È un embedding piccolo e **leggibile**: ogni numero ha un significato

  (B) un modello fatto apposta per gli embedding: un servizio a pagamento o un modello aperto basato su un LLM, più grande di e5 e bge e capace di leggere l’articolo intero

- Le due strade si possono anche **sommare**: voti di Claude + embedding + TF-IDF

Strada A: Claude come lettore di segnali

- Per ogni articolo, un prompt **fisso**: “dai un voto da 1 a 10 a...”

Strada A: Claude come lettore di segnali

- Per ogni articolo, un prompt **fisso**: “dai un voto da 1 a 10 a...”
- Alcune domande vengono dai **criteri NewsGuard** che si vedono nel testo: distingue notizie e opinioni? titolo ingannevole? cita le fonti? corregge gli errori?

Strada A: Claude come lettore di segnali

- Per ogni articolo, un prompt **fisso**: “dai un voto da 1 a 10 a...”
- Alcune domande vengono dai **criteri NewsGuard** che si vedono nel testo: distingue notizie e opinioni? titolo ingannevole? cita le fonti? corregge gli errori?
- Altre dallo stile: linguaggio emotivo, sensazionalismo, attacchi personali, cautela nelle affermazioni

Strada A: Claude come lettore di segnali

- Per ogni articolo, un prompt **fisso**: "dai un voto da 1 a 10 a..."
- Alcune domande vengono dai **criteri NewsGuard** che si vedono nel testo: distingue notizie e opinioni? titolo ingannevole? cita le fonti? corregge gli errori?
- Altre dallo stile: linguaggio emotivo, sensazionalismo, attacchi personali, cautela nelle affermazioni
- La testata = **media dei voti** dei suoi articoli; sopra, la stessa regressione logistica del TF-IDF

Strada A: Claude come lettore di segnali

- Per ogni articolo, un prompt **fisso**: "dai un voto da 1 a 10 a..."
- Alcune domande vengono dai **criteri NewsGuard** che si vedono nel testo: distingue notizie e opinioni? titolo ingannevole? cita le fonti? corregge gli errori?
- Altre dallo stile: linguaggio emotivo, sensazionalismo, attacchi personali, cautela nelle affermazioni
- La testata = **media dei voti** dei suoi articoli; sopra, la stessa regressione logistica del TF-IDF

Perché può funzionare

Pochi numeri per testata (circa 20): con 304 testate un modello piccolo **non può imparare a memoria**

Sono segnali **diversi** dalle parole contate dal TF-IDF: possono aiutare dove il TF-IDF sbaglia

Si capisce **quali segnali contano**, e collega il lavoro ai criteri NewsGuard (il nostro obiettivo secondario)

Il rischio: Claude conosce già le testate

- Un modello grande ha letto quasi tutte queste testate e ne conosce la **reputazione**

Il rischio: Claude conosce già le testate

- Un modello grande ha letto quasi tutte queste testate e ne conosce la **reputazione**
- Se nell'articolo c'è il nome del sito, una firma o un link, Claude può **ricordare** invece di leggere: sarebbe la stessa scorciatoia delle reti, in un'altra forma

Il rischio: Claude conosce già le testate

- Un modello grande ha letto quasi tutte queste testate e ne conosce la **reputazione**
- Se nell'articolo c'è il nome del sito, una firma o un link, Claude può **ricordare** invece di leggere: sarebbe la stessa scorciatoia delle reti, in un'altra forma
- Cosa si fa:

Il rischio: Claude conosce già le testate

- Un modello grande ha letto quasi tutte queste testate e ne conosce la **reputazione**
- Se nell'articolo c'è il nome del sito, una firma o un link, Claude può **ricordare** invece di leggere: sarebbe la stessa scorciatoia delle reti, in un'altra forma
- Cosa si fa:

  mascherare prima di inviare: nomi delle testate, domini, firme, link (una regola in più nella pulizia, uguale per tutti)

Il rischio: Claude conosce già le testate

- Un modello grande ha letto quasi tutte queste testate e ne conosce la **reputazione**
- Se nell'articolo c'è il nome del sito, una firma o un link, Claude può **ricordare** invece di leggere: sarebbe la stessa scorciatoia delle reti, in un'altra forma
- Cosa si fa:

  mascherare prima di inviare: nomi delle testate, domini, firme, link (una regola in più nella pulizia, uguale per tutti)

  controllare: su un campione, voti con e senza maschera; e chiedere a Claude di indovinare la testata, per misurare quanto la riconosce

Il rischio: Claude conosce già le testate

- Un modello grande ha letto quasi tutte queste testate e ne conosce la **reputazione**
- Se nell'articolo c'è il nome del sito, una firma o un link, Claude può **ricordare** invece di leggere: sarebbe la stessa scorciatoia delle reti, in un'altra forma
- Cosa si fa:

  mascherare prima di inviare: nomi delle testate, domini, firme, link (una regola in più nella pulizia, uguale per tutti)

  controllare: su un campione, voti con e senza maschera; e chiedere a Claude di indovinare la testata, per misurare quanto la riconosce

  le **etichette NewsGuard** non si mandano mai

Strada B: embedding + rete piccola, per testata

- Oggi: e5 e bge congelati + regressione logistica fanno F1 **0,33**, contro 0,38 del TF-IDF. Ma leggono solo l'inizio dell'articolo e fanno una media semplice

Strada B: embedding + rete piccola, per testata

- Oggi: e5 e bge congelati + regressione logistica fanno F1 **0,33**, contro 0,38 del TF-IDF. Ma leggono solo l'inizio dell'articolo e fanno una media semplice
- Tre cose da migliorare:

Strada B: embedding + rete piccola, per testata

- Oggi: e5 e bge congelati + regressione logistica fanno F1 **0,33**, contro 0,38 del TF-IDF. Ma leggono solo l'inizio dell'articolo e fanno una media semplice
- Tre cose da migliorare:

  un modello di embedding **più grande**, che legga l'**articolo intero**

Strada B: embedding + rete piccola, per testata

- Oggi: e5 e bge congelati + regressione logistica fanno F1 **0,33**, contro 0,38 del TF-IDF. Ma leggono solo l'inizio dell'articolo e fanno una media semplice
- Tre cose da migliorare:

  un modello di embedding **più grande**, che legga l'**articolo intero**

  al posto della regressione logistica una **piccola rete** (MLP)

Strada B: embedding + rete piccola, per testata

- Oggi: e5 e bge congelati + regressione logistica fanno F1 **0,33**, contro 0,38 del TF-IDF. Ma leggono solo l'inizio dell'articolo e fanno una media semplice
- Tre cose da migliorare:

  un modello di embedding **più grande**, che legga l'**articolo intero**

  al posto della regressione logistica una **piccola rete** (MLP)

  i **sacchetti**: la rete riceve 10–20 articoli della stessa testata insieme e impara quali pesare di più (**attenzione**), con l'etichetta della testata, che è il livello a cui esiste davvero

Strada B: embedding + rete piccola, per testata

- Oggi: e5 e bge congelati + regressione logistica fanno F1 **0,33**, contro 0,38 del TF-IDF. Ma leggono solo l'inizio dell'articolo e fanno una media semplice
- Tre cose da migliorare:

  un modello di embedding **più grande**, che legga l'**articolo intero**

  al posto della regressione logistica una **piccola rete** (MLP)

  i **sacchetti**: la rete riceve 10–20 articoli della stessa testata insieme e impara quali pesare di più (**attenzione**), con l'etichetta della testata, che è il livello a cui esiste davvero
- Pescando sacchetti diversi dalla stessa testata si ottengono **migliaia di esempi** da 304 testate, e una misura di **confidenza** per testata

Come arrivare a risultati migliori

1. **Prova pilota**: 20 articoli per testata (circa 6.000 articoli, qualche milione di token), con un modello Claude piccolo e l'elaborazione in batch. Nelle prove precedenti 5–20 articoli per testata davano quasi tutto il segnale

Come arrivare a risultati migliori

1. **Prova pilota**: 20 articoli per testata (circa 6.000 articoli, qualche milione di token), con un modello Claude piccolo e l'elaborazione in batch. Nelle prove precedenti 5–20 articoli per testata davano quasi tutto il segnale
2. Stessi **fold per gruppo**, stesso bootstrap, prompt e domande **fissati prima** di guardare i risultati; risposte salvate e versione del modello fissata, per poter rifare tutto

Come arrivare a risultati migliori

1. **Prova pilota**: 20 articoli per testata (circa 6.000 articoli, qualche milione di token), con un modello Claude piccolo e l'elaborazione in batch. Nelle prove precedenti 5–20 articoli per testata davano quasi tutto il segnale
2. Stessi **fold per gruppo**, stesso bootstrap, prompt e domande **fissati prima** di guardare i risultati; risposte salvate e versione del modello fissata, per poter rifare tutto
3. **Combinare** i modelli: TF-IDF e ModernBERT sbagliano già su testate diverse, e i voti di Claude sarebbero un terzo punto di vista. Una combinazione scelta in una **validazione interna** al training (mai sul test) può battere ognuno da solo

Come arrivare a risultati migliori

1. **Prova pilota**: 20 articoli per testata (circa 6.000 articoli, qualche milione di token), con un modello Claude piccolo e l'elaborazione in batch. Nelle prove precedenti 5–20 articoli per testata davano quasi tutto il segnale
2. Stessi **fold per gruppo**, stesso bootstrap, prompt e domande **fissati prima** di guardare i risultati; risposte salvate e versione del modello fissata, per poter rifare tutto
3. **Combinare** i modelli: TF-IDF e ModernBERT sbagliano già su testate diverse, e i voti di Claude sarebbero un terzo punto di vista. Una combinazione scelta in una **validazione interna** al training (mai sul test) può battere ognuno da solo
4. Confronto onesto: anche **Claude da solo** ("quanto è affidabile questa testata?") con e senza maschera, come riferimento

Come arrivare a risultati migliori

1. **Prova pilota**: 20 articoli per testata (circa 6.000 articoli, qualche milione di token), con un modello Claude piccolo e l'elaborazione in batch. Nelle prove precedenti 5–20 articoli per testata davano quasi tutto il segnale
2. Stessi **fold per gruppo**, stesso bootstrap, prompt e domande **fissati prima** di guardare i risultati; risposte salvate e versione del modello fissata, per poter rifare tutto
3. **Combinare** i modelli: TF-IDF e ModernBERT sbagliano già su testate diverse, e i voti di Claude sarebbero un terzo punto di vista. Una combinazione scelta in una **validazione interna** al training (mai sul test) può battere ognuno da solo
4. Confronto onesto: anche **Claude da solo** ("quanto è affidabile questa testata?") con e senza maschera, come riferimento

Se la strada A funziona, la novità per il paper è doppia: prestazioni migliori e una spiegazione di quali segnali del testo dicono l'affidabilità.